Guía de ensayo para la Prueba 2

BME423 - Procesamiento de Imágenes 2026

Alejandro Veloz

Parte I. Formulario

Transformada discreta de Fourier. Para una imagen de $M \times N$, $F(u,v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x,y)\, e^{-j2\pi(ux/M + vy/N)}$ y $f(x,y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u,v)\, e^{j2\pi(ux/M+vy/N)}$. En una dimensión, $F(u) = \sum_{x=0}^{M-1} f(x)\, e^{-j2\pi ux/M}$. Espectro $|F| = \left[\mathrm{Re}^2(F) + \mathrm{Im}^2(F)\right]^{1/2}$, fase $\phi = \tan^{-1}\left[\mathrm{Im}(F)/\,\mathrm{Re}(F)\right]$ y potencia $P = |F|^2$. Componente continua $F(0,0) = MN\,\bar{f}$. Teorema de Parseval $\sum_{u,v} |F(u,v)|^2 = MN \sum_{x,y} |f(x,y)|^2$. Con $M = 4$, $e^{-j2\pi ux/4} = (-j)^{ux}$.

Propiedades. Linealidad. Centrado $f(x,y)(-1)^{x+y} \Leftrightarrow F(u - M/2,\, v - N/2)$. Traslación $f(x - x_0, y - y_0) \Leftrightarrow F(u,v)\, e^{-j2\pi(ux_0/M + vy_0/N)}$. Periodicidad $F(u,v) = F(u + kM,\, v + lN)$. Simetría conjugada $F(-u,-v) = F^*(u,v)$ si f es real. Una rotación de f rota F en el mismo ángulo. Convolución circular $f * h \Leftrightarrow F\,H$, y para evitar el solapamiento circular se rellena con ceros hasta $P \geq A + C - 1$ en cada dimensión, con A y C los tamaños de imagen y kernel. Función de transferencia de un kernel $H(u,v) = \sum_{s,t} w(s,t)\, e^{-j2\pi(us/M + vt/N)}$, con $H(0,0) = \sum_{s,t} w(s,t)$. Derivada $\mathcal{F}\left[d^n f/dx^n\right] = (j2\pi u)^n F(u)$, con u en ciclos por píxel.

Filtros en frecuencia. $D(u,v) = \left[(u - M/2)^2 + (v - N/2)^2\right]^{1/2}$ sobre el espectro centrado. Ideal (ILPF) $H = 1$ si $D \leq D_0$ y 0 si $D > D_0$. Butterworth de orden n (BLPF) $H = 1/\left[1 + (D/D_0)^{2n}\right]$. Gaussiano (GLPF) $H = \exp\left[-D^2/(2D_0^2)\right]$, equivalente a un kernel gaussiano espacial con $\sigma = M/(2\pi D_0)$. Pasa altos $H_{hp} = 1 - H_{lp}$, en particular Butterworth $1/\left[1 + (D_0/D)^{2n}\right]$ y gaussiano $1 - \exp\left[-D^2/(2D_0^2)\right]$. Potencia retenida $\alpha = 100 \sum_{D \leq D_0} P(u,v)/P_T$. Laplaciano $\nabla^2 f \Leftrightarrow -4\pi^2(u^2 + v^2)F$, con u, v en ciclos por píxel, y Laplaciano discreto de cuatro vecinos $H = -4\left[\sin^2(\pi u/M) + \sin^2(\pi v/N)\right]$. *High-boost* $H_{hb} = (A-1) + H_{hp}$ con $A \geq 1$. Énfasis de alta frecuencia $H_{hfe} = a + b\,H_{hp}$ con $a \geq 0$ y $b > a$. Un filtro *notch* anula un par de frecuencias conjugadas (u_0, v_0) y $(-u_0, -v_0)$ y deja pasar el resto.

Agrupamiento. k-means $J = \sum_{i=1}^{C} \sum_{\mathbf{x}_k \in G_i} \|\mathbf{x}_k - \mathbf{v}_i\|^2$, asignación al centroide más cercano y $\mathbf{v}_i = \frac{1}{|G_i|} \sum_{\mathbf{x}_k \in G_i} \mathbf{x}_k$. Fuzzy c-means $J_{\mathrm{fcm}} = \sum_i \sum_j u_{ij}^m\, d^2(\mathbf{x}_j, \mathbf{v}_i)$ con $\sum_i u_{ij} = 1$ y $m > 1$, $u_{ij} = 1 \Big/ \sum_{k=1}^{C} (d_{ij}/d_{kj})^{2/(m-1)}$ y $\mathbf{v}_i = \sum_j u_{ij}^m \mathbf{x}_j \Big/ \sum_j u_{ij}^m$, con $d_{ij} = d(\mathbf{x}_j, \mathbf{v}_i)$.

Mezclas y EM. $f(\mathbf{x}) = \sum_{i=1}^{C} w_i\, f_i(\mathbf{x} \mid \theta_i)$ con $\sum_i w_i = 1$, y en una dimensión $N(x \mid \mu, \sigma^2) = (2\pi\sigma^2)^{-1/2} \exp\left[-(x-\mu)^2/(2\sigma^2)\right]$. Paso E $\hat{h}_{ij} = w_i f_i(x_j) \Big/ \sum_l w_l f_l(x_j)$. Paso M $\hat{w}_i = \frac{1}{N} \sum_j \hat{h}_{ij}$, $\hat{\mu}_i = \sum_j \hat{h}_{ij} x_j \Big/ \sum_j \hat{h}_{ij}$ y $\hat{\sigma}_i^2 = \sum_j \hat{h}_{ij} (x_j - \hat{\mu}_i)^2 \Big/ \sum_j \hat{h}_{ij}$. Cada píxel se asigna a la clase de mayor posterior.

Campos aleatorios de Markov. Vecindad con $s \notin N_s$ y $r \in N_s \Leftrightarrow s \in N_r$. Espacio de soluciones de tamaño $K^{m \times n}$. Distribución de Gibbs $P(\mathbf{x}) = Z^{-1} \exp\left[-\beta\, U(\mathbf{x})\right]$ y potencial de Potts $V_{\{s,r\}} = -1$ si $x_s = x_r$ y $+1$ si no. Energía máxima a posteriori $E(\mathbf{x}) = \sum_s \left[(y_s - \mu_{x_s})^2/(2\sigma_{x_s}^2) + \log \sigma_{x_s}\right] + \beta \sum_{\{s,r\}} \mathbf{1}\{x_s \neq x_r\}$. Modo condicional iterado (ICM) $x_s \leftarrow \arg\min_\ell \left[(y_s - \mu_\ell)^2/(2\sigma_\ell^2) + \log \sigma_\ell + \beta\, n_s(\ell)\right]$, con $n_s(\ell)$ el número de vecinos de s con etiqueta distinta de ℓ.

Regiones. Crecimiento de regiones, en que un vóxel x se agrega a A_i si es 8-adyacente a la región y $|f(x) - f(g_i)| < T$. División y fusión, en que se subdivide en cuadrantes mientras el predicado $P(R)$ sea falso y luego se fusionan las regiones adyacentes cuya unión lo cumple.

Evaluación. Con S la segmentación y R la referencia, Ex $= V_{\mathrm{VP}}/V_R$, FP $= V_{\mathrm{FP}}/V_R$, FN $= V_{\mathrm{FN}}/V_R$, Dice $= 2|S \cap R|/(|S| + |R|)$ y Jaccard $= |S \cap R|/|S \cup R|$, relacionados por $\mathrm{J} = \mathrm{D}/(2 - \mathrm{D})$.

Parte II. Ideas centrales

La transformada de Fourier es un cambio de base, y la fase indica dónde están las estructuras

La transformada discreta escribe la imagen como una suma de exponenciales complejas. Cada coeficiente $F(u, v)$ es el producto interno de la imagen con una onda de u ciclos a lo largo de las filas y v ciclos a lo largo de las columnas, de modo que mide cuánto se parece la imagen a esa onda. El coeficiente $F(0, 0)$ es la suma de todos los píxeles, y por eso se llama componente continua.

Notación. Esta guía usa la convención sin factor en la transformada directa y con $1/MN$ en la inversa, que es la de numpy y la de las implementaciones habituales, de modo que $F(0, 0) = MN\,\bar{f}$. En las diapositivas el factor $1/MN$ aparece en la transformada directa y entonces $F(0, 0) = \bar{f}$. Ambas convenciones difieren sólo en ese factor global y conducen a los mismos filtros.

Cada coeficiente es un número complejo con magnitud y fase, y las dos cumplen funciones distintas. Por la propiedad de traslación, desplazar la imagen multiplica cada coeficiente por $e^{-j2\pi(ux_0/M+vy_0/N)}$, cuyo módulo es uno. **Una traslación cambia la fase y deja intacta la magnitud.** El espectro de magnitud describe entonces qué frecuencias hay, con qué orientación y con qué intensidad, mientras que la información sobre la ubicación de las estructuras reside en la fase. Si se combina la magnitud de una imagen con la fase de otra, el resultado se parece a la imagen que aportó la fase. Por esta razón todos los filtros del curso tienen H real, no negativo y con simetría $H(u, v) = H(-u, -v)$. Un filtro así multiplica cada magnitud por un número no negativo y conserva la fase, de modo que modifica el contraste de cada frecuencia sin desplazar ninguna estructura.

La lectura del espectro se apoya en cuatro reglas:

- Una sinusoide produce un par de impulsos conjugados en $\pm(u_0, v_0)$, ubicados sobre la recta perpendicular a las franjas y a una distancia del centro proporcional a su frecuencia. Si la imagen gira, el par gira con ella.
- El ancho de una estructura y el de su espectro son inversamente proporcionales. Un cuadrado de lado L produce un espectro tipo sinc cuyos ceros están en múltiplos de M/L, de modo que un objeto pequeño se extiende sobre todo el plano de frecuencias y uno grande se concentra cerca del origen.
- La componente continua domina la potencia total. Por Parseval, la fracción de potencia en $F(0, 0)$ vale $\bar{f}^2/(\bar{f}^2 + \sigma_f^2)$, con σ_f^2 la varianza de la imagen, valor cercano a uno en cualquier imagen médica. Por eso el espectro se despliega con la transformación logarítmica $\log(1 + |F|)$.
- Multiplicar la imagen por el tablero de ajedrez $(-1)^{x+y}$ desplaza el espectro en $(M/2, N/2)$ y lleva la componente continua al centro, que es lo mismo que hace `fftshift`. El tablero es la onda de frecuencia más alta que la grilla puede representar, la frecuencia de Nyquist, y por eso multiplicar por él traslada el espectro medio período.

Todo kernel tiene una función de transferencia, y la ganancia en continua es $H(0, 0)$

El teorema de convolución establece que filtrar con un kernel w equivale a multiplicar el espectro por su transformada H. Cada frecuencia sale multiplicada por $H(u, v)$, lo que permite leer el comportamiento de cualquier kernel espacial evaluando su función de transferencia. La suma de los coeficientes del kernel, que en la Prueba 1 se llamó ganancia en continua, es exactamente $H(0, 0)$.

Para el promedio de tres píxeles $[1\ 1\ 1]/3$ y para el Laplaciano $[1\ -2\ 1]$ se obtiene:

$$H_{\text{prom}}(u) = \frac{1 + 2\cos(2\pi u/M)}{3}, \qquad H_{\text{lap}}(u) = -2 + 2\cos(2\pi u/M) = -4\sin^2(\pi u/M).$$

El promedio no es un pasa bajos ideal. Vale uno en el origen, se anula en $u = M/3$, que corresponde a una onda de período tres cuyo ciclo completo cabe en la ventana, y toma el valor $-1/3$ en la frecuencia de Nyquist. Ese signo negativo significa que el patrón alternante sale atenuado y con el contraste invertido. El Laplaciano se anula en el origen, como corresponde a una máscara de derivada, y crece en magnitud hasta -4 en Nyquist. Para frecuencias bajas, $\sin x \approx x$ entrega $H_{\text{lap}} \approx -(2\pi u/M)^2$, que es el Laplaciano continuo $-4\pi^2u^2$ con u/M ciclos por píxel. En dos dimensiones con cuatro vecinos las contribuciones se suman y en el tablero de ajedrez se obtiene -8, que es el valor propio calculado en la Prueba 1. El realce $g = f - c\,\nabla^2 f$ tiene entonces $H = 1 + 4c\left[\sin^2(\pi u/M) + \sin^2(\pi v/N)\right]$, que vale uno en el origen y $1 + 8c$ en el tablero. **El realce amplifica más las frecuencias más altas, que es donde el ruido domina.**

El producto de transformadas discretas corresponde a la convolución circular, ya que la transformada discreta trata la imagen como un período de una señal periódica. Sin relleno, el kernel que se sale por un borde reaparece por el opuesto y mezcla el borde izquierdo con el derecho. Para que el resultado coincida con la convolución lineal se rellena con ceros hasta $P \geq A + C - 1$ en cada dimensión. En cuanto al costo, la convolución directa requiere del orden de K^2 productos por píxel con un kernel de $K \times K$, mientras que el camino por la FFT cuesta del orden de $\log(MN)$ por píxel. La convolución directa conviene con kernels pequeños y separables, y la FFT con kernels grandes o cuando se aplican varios filtros sobre la misma transformada.

La forma del filtro en frecuencia determina los artefactos en el espacio

El filtro ideal corta abruptamente en D_0. Su kernel espacial es una función tipo sinc, con un lóbulo central y lóbulos laterales que alternan de signo, y al convolucionar un borde cada lóbulo deja una réplica atenuada. **El filtro ideal produce anillos alrededor de los bordes**, separados una distancia inversamente proporcional a D_0. El filtro de Butterworth suaviza el corte y su orden n regula la transición. Con $n = 1$ no hay anillos visibles, con $n = 2$ son imperceptibles y al aumentar n el filtro se acerca al ideal y los anillos reaparecen. El filtro gaussiano es el único de los tres sin lóbulos negativos, porque la transformada de una gaussiana es otra gaussiana, y nunca produce anillos. La relación $\sigma = M/(2\pi D_0)$ cuantifica la inversión de escalas, ya que un corte más alto en frecuencia corresponde a un kernel más angosto en el espacio.

El parámetro D_0 no significa lo mismo en las tres familias. En $D = D_0$ el ideal vale uno, el de Butterworth vale $1/2$ para cualquier orden y el gaussiano vale $e^{-1/2} = 0{,}61$. Por eso una comparación justa entre familias debe hacerse con la misma potencia retenida o con el mismo valor de H en una frecuencia de referencia, y no con el mismo D_0.

La potencia retenida α mide energía, no información. Como la componente continua concentra casi toda la potencia, α supera el 95 % aun con un D_0 muy pequeño y una imagen fuertemente desenfocada. Los bordes y los detalles finos aportan poca energía y mucha información diagnóstica.

Los filtros de agudizado se obtienen como $H_{hp} = 1 - H_{lp}$ y heredan las mismas propiedades, con anillos en el ideal y sin ellos en el gaussiano. Un pasa altos puro anula la componente continua, por lo que la imagen resultante tiene media cero y se ve oscura y sin tonos. Las variantes *high-boost* y de énfasis de alta frecuencia agregan una fracción de la imagen original para conservar las bajas frecuencias:

$$H_{hb} = (A - 1) + H_{hp}, \qquad H_{hfe} = a + b\, H_{hp}, \qquad 1 + k\, H_{hp} \quad \text{para} \quad g = f + k\,(f - f_{lp})\,.$$

La escritura con k de la Prueba 1 es el énfasis de alta frecuencia con $a = 1$ y $b = k$, y tiene ganancia unitaria en continua. La escritura con A tiene ganancia $A - 1$ en continua, el mismo resultado que se obtuvo en el dominio espacial. Con $a < 1$ el énfasis de alta frecuencia atenúa la componente continua y comprime el rango de grises, y por eso suele seguirse de una ecualización de histograma.

El ruido periódico es global en el espacio y local en la frecuencia

La interferencia sinusoidal, como la de origen eléctrico en ultrasonido o en resonancia magnética, o las líneas de una grilla antidifusora en radiografía, ocupa toda la imagen pero en el espectro se reduce a un par de impulsos. Una perturbación $\eta(x, y) = A_\eta \cos\left[2\pi(u_0 x/M + v_0 y/N)\right]$ produce dos impulsos de magnitud $A_\eta MN/2$ en $\pm(u_0, v_0)$. Un filtro *notch* que anule ambos impulsos elimina la interferencia y altera sólo el contenido de la imagen que coincidía exactamente con esas frecuencias. Un pasa bajos no sirve si la interferencia está en frecuencias medias, porque para eliminarla tendría que borrar también todo el detalle anatómico de frecuencia mayor. En el espacio, la misma operación exigiría un kernel tan grande como la imagen, ya que un filtro muy angosto en frecuencia corresponde a un kernel muy ancho en el espacio. El *notch* debe anular siempre los dos impulsos del par, porque si se eliminara sólo uno el espectro dejaría de tener simetría conjugada y la imagen filtrada dejaría de ser real.

En el espacio de características, la frontera depende de qué se modela

Al describir cada píxel con un vector de varias modalidades registradas, la segmentación pasa a ser un problema de agrupamiento. Los tres métodos del curso trazan fronteras distintas sobre los mismos datos.

- **k-means** minimiza la varianza intraclase. Cada dato se asigna al centroide más cercano, de modo que la frontera entre dos clases es la mediatriz entre sus centroides, y en una dimensión es el punto medio. El algoritmo converge siempre, pero a un mínimo local que depende de la inicialización.
- **Fuzzy c-means** asigna pertenencias que dependen sólo de la razón entre distancias. Con $m = 2$ y un dato el doble de lejos de una clase que de la otra, las pertenencias son $1/(1+4) = 0{,}2$ y $0{,}8$. Cuando $m \to 1$ las pertenencias tienden a cero o uno y se recupera k-means, y cuando $m \to \infty$ tienden a $1/C$. Un dato equidistante de todas las clases recibe $1/C$ en cada una, cualquiera sea m. Los centros son promedios ponderados por u_{ij}^m, de modo que un dato ambiguo con $u = 0{,}5$ pesa $0{,}25$ en cada clase cuando $m = 2$.
- **El modelo de mezclas** pondera además por las probabilidades a priori y por las varianzas. Con dos gaussianas de igual varianza la frontera es

  $$x^* = \frac{\mu_1 + \mu_2}{2} + \frac{\sigma^2 \, \ln(w_1/w_2)}{\mu_2 - \mu_1},$$

  que coincide con la de k-means sólo si $w_1 = w_2$. Con $w_1 > w_2$ la frontera se desplaza hacia la clase minoritaria, y **una lesión pequeña tiende a quedar subestimada**, porque los píxeles de intensidad intermedia se asignan al tejido mayoritario. Con varianzas distintas la frontera es cuadrática y la clase más ancha reclama datos en ambas colas.

La probabilidad posterior cumple el papel de la pertenencia difusa, ya que suma uno sobre las clases y reparte cada dato. La diferencia es que proviene de un modelo probabilístico explícito y no de la construcción heurística controlada por m. El paso M es formalmente idéntico a la actualización de centros de fuzzy c-means, con $\hat{h}_{ij}$ en lugar de u_{ij}^m. Ninguno de estos tres métodos usa la posición de los píxeles, y por eso todos producen un resultado moteado.

La vecindad entra en la energía como un costo por desacuerdo

El campo aleatorio de Markov agrega a la fidelidad al dato un término que cuenta las parejas de vecinos con etiquetas distintas. En el modo condicional iterado cada píxel compara la diferencia de sus términos de dato, $\Delta_s = d_s(1) - d_s(2)$ con $d_s(\ell) = (y_s - \mu_\ell)^2/(2\sigma_\ell^2) + \log \sigma_\ell$, con la diferencia de desacuerdos ponderada por β:

$$E_s(1) < E_s(2) \quad \Longleftrightarrow \quad \Delta_s < \beta \, [n_s(2) - n_s(1)] \, .$$

Con vecindad de ocho, la diferencia $n_s(2) - n_s(1)$ depende sólo de la geometría local de la región. Para un píxel de la clase 2 rodeado por la clase 1, la siguiente tabla indica cuánto favorece el término espacial el paso a la clase 1:

Configuración del píxel de clase 2	Vecinos de clase 2	Vecinos de clase 1	$n_s(2) - n_s(1)$
Aislado	0	8	8
En una línea de un píxel de ancho	2	6	4
En la esquina de una región cuadrada	3	5	2
En un borde recto	5	3	-2

El campo elimina primero los píxeles aislados, luego las estructuras de un píxel de ancho, después redondea las esquinas, y nunca desplaza un borde recto, porque allí el término espacial favorece conservar la etiqueta. En todos los casos la estructura sobrevive si la evidencia del dato es suficientemente fuerte, esto es si Δ_s supera el umbral correspondiente. Con $\beta = 0$ la regla se reduce a la clasificación por máxima verosimilitud, y con β grande se borran estructuras finas legítimas, como los surcos corticales. La constante de normalización Z no depende de la configuración y desaparece al comparar energías, lo que hace posible el método.

Las regiones crecen por conectividad y se fugan por continuidad

El crecimiento de regiones impone la coherencia espacial desde el inicio, porque sólo se agregan píxeles adyacentes a la región. Su falla característica es la fuga. Basta un camino continuo de píxeles que satisfagan el criterio para que la región escape del objeto, aunque ese camino sea un único píxel de transición. El umbral T controla el resultado por completo, y existe típicamente una meseta de valores de T en la que la región coincide con el objeto, limitada abajo por los píxeles del objeto más alejados de la semilla y arriba por el primer puente hacia el exterior. Si el criterio se mide respecto de la media de la región y no respecto de la semilla, la media se desplaza a medida que la región crece y la fuga ocurre con umbrales menores. La división y fusión evita las semillas y con ello la variabilidad entre operadores, a cambio de un contorno que depende del tamaño mínimo de cuadrante.

Las métricas de solapamiento dependen del tamaño del objeto

La exactitud y las fracciones de falsos positivos y falsos negativos se normalizan por el volumen de la referencia y no son simétricas. Una segmentación que contiene a la referencia entera tiene una exactitud del 100 % aunque duplique su volumen, de modo que la exactitud sola no detecta la fuga. Los índices de Dice y de Jaccard tratan ambas máscaras por igual y se relacionan de forma monótona, $J = D/(2 - D)$, por lo que ordenan igual a los métodos aunque sus valores difieran, con $D \geq J$.

El mismo error de contorno pesa muy distinto según el tamaño del objeto. Una lesión de 3×3 píxeles segmentada con un desplazamiento de un píxel conserva seis de nueve píxeles y obtiene Dice $= 12/18 = 0{,}67$, mientras que una de 10×10 con el mismo desplazamiento conserva noventa de cien y obtiene 0,90. **Un Dice bajo en lesiones pequeñas no implica un método peor.** Además, la referencia manual tiene variabilidad entre observadores, y diferencias entre métodos menores que esa variabilidad carecen de significado. Un reporte completo incluye la curva del índice en función del parámetro, la reproducibilidad y el nivel de interacción exigido al operador.

Parte III. Problemas resueltos

Los ocho problemas siguientes equivalen aproximadamente a dos pruebas reales. Conviene resolverlos con papel y lápiz antes de mirar la solución.

Bloque A. Transformada discreta de Fourier

Problema A.1

a. Calcule la transformada discreta de la señal $f = [\,2,\ 1,\ 0,\ 1\,]$, con $M = 4$. Relacione $F(0)$ con la media de la señal, explique por qué todos los coeficientes resultan reales y verifique el teorema de Parseval.

b. Sea $f_1(x) = f(x-1)$ la traslación circular de f en una posición. Obtenga $F_1(u)$ mediante la propiedad de traslación, verifique $F_1(1)$ por cálculo directo y compare magnitud y fase con las de F. Luego calcule la transformada de $f(x)(-1)^x$ e indique dónde quedó la componente continua.

c. Considere la imagen de 4×4 cuyas cuatro filas son idénticas e iguales a $[\,150,\ 50,\ 150,\ 50\,]$, con x el índice de fila e y el de columna. Calcule $F(u,v)$, interprete cada coeficiente no nulo y diga dónde estaría la energía si la imagen se transpusiera.

Solución A.1

a. Con $M = 4$ se tiene $F(u) = \sum_x f(x)(-j)^{ux}$, y como $(-j)^2 = -1$ y $(-j)^3 = j$:

$$\begin{aligned} F(0) &= 2 + 1 + 0 + 1 = 4, \\ F(1) &= 2 + 1\cdot(-j) + 0\cdot(-1) + 1\cdot j = 2, \\ F(2) &= 2 + 1\cdot(-1) + 0\cdot 1 + 1\cdot(-1) = 0, \\ F(3) &= 2 + 1\cdot j + 0\cdot(-1) + 1\cdot(-j) = 2. \end{aligned}$$

El coeficiente $F(0) = 4 = M\bar{f}$ es la suma de la señal, con media $\bar{f} = 1$. Los coeficientes son reales porque la señal es real y par en sentido circular, ya que $f(1) = f(3)$. Los términos imaginarios de x y de $M - x$ tienen signos opuestos y se cancelan. Parseval se verifica con $\sum_u |F|^2 = 16 + 4 + 0 + 4 = 24$ y $M \sum_x f^2 = 4\,(4 + 1 + 0 + 1) = 24$.

b. La traslación multiplica cada coeficiente por $e^{-j2\pi u/4} = (-j)^u$:

$$F_1(u) = F(u)\,(-j)^u = [\,4,\ -2j,\ 0,\ 2j\,].$$

Directamente, con $f_1 = [\,1,\ 2,\ 1,\ 0\,]$, $F_1(1) = 1 + 2(-j) + 1\cdot(-1) + 0 = -2j$, que coincide. Las magnitudes son $[\,4,\ 2,\ 0,\ 2\,]$, idénticas a las de F. Las fases pasan de cero a $-\pi/2$ en $u = 1$ y a $+\pi/2$ en $u = 3$, esto es crecen linealmente con la frecuencia, $\phi_1(u) = \phi(u) - \pi u/2$. El espectro de magnitud no detecta la traslación, que queda registrada sólo en la fase.

Con $f(x)(-1)^x = [\,2,\ -1,\ 0,\ -1\,]$ se obtiene $[\,0,\ 2,\ 4,\ 2\,]$, que es $F(u-2)$. La componente continua pasó a $u = 2 = M/2$, el centro del intervalo de frecuencias, como establece la propiedad de centrado.

c. Como las filas son idénticas, la transformada se separa en un factor por filas y otro por columnas. El factor por filas, $\sum_{x=0}^{3} e^{-j2\pi ux/4}$, vale 4 si $u = 0$ y cero en otro caso. El factor por columnas es la transformada de $[\,150,\ 50,\ 150,\ 50\,]$:

$$G(0) = 400, \qquad G(1) = 150 - 50j - 150 + 50j = 0, \qquad G(2) = 150 - 50 + 150 - 50 = 200, \qquad G(3) = 0.$$

Entonces $F(0,0) = 4 \cdot 400 = 1600$ y $F(0,2) = 4 \cdot 200 = 800$, y todos los demás coeficientes son nulos. El primero es $MN\bar{f} = 16 \cdot 100$, la componente continua. El segundo corresponde a la alternancia entre columnas contiguas, que es una onda de frecuencia de Nyquist a lo largo de y con amplitud 50. Su magnitud es $50 \cdot MN = 800$ y no $50 \cdot MN/2$, porque en la frecuencia de Nyquist los dos impulsos conjugados $\pm v_0$ coinciden en el mismo coeficiente. La imagen varía sólo a lo largo de las columnas, de modo que toda la energía no continua cae sobre el eje v. Si se transpusiera, la energía pasaría a $F(2,0)$, sobre el eje u, de acuerdo con la propiedad de rotación.

Problema A.2

a. Para el promedio de tres píxeles con $h(0) = h(1) = h(M-1) = 1/3$, demuestre que $H(u) = [1 + 2\cos(2\pi u/M)]/3$, evalúela en $u = 0$, $M/4$, $M/3$ y $M/2$, e interprete los valores en $M/3$ y en $M/2$. Verifique el segundo aplicando el filtro directamente a $f(x) = (-1)^x$.

b. Obtenga la función de transferencia del Laplaciano $[1\ -2\ 1]$, muestre que para frecuencias bajas coincide con el Laplaciano continuo, extiéndala a dos dimensiones con cuatro vecinos y evalúe el realce $g = f - c\,\nabla^2 f$ con $c = 1$ en $(0,0)$, $(M/2, 0)$ y $(M/2, N/2)$.

c. Para $f = [\,2,\ 1,\ 0,\ 1\,]$, calcule la convolución circular con el promedio de tres directamente y mediante $G = F\,H$. Explique qué ocurre en $x = 0$ si f es parte de una señal no periódica y calcule el relleno mínimo para filtrar una imagen de 512×512 con un kernel de 15×15.

Solución A.2

a. Con la definición de la función de transferencia y usando $e^{-j2\pi u(M-1)/M} = e^{j2\pi u/M}$:

$$H(u) = \frac{1}{3}\left[1 + e^{-j2\pi u/M} + e^{j2\pi u/M}\right] = \frac{1 + 2\cos(2\pi u/M)}{3}.$$

u	0	$M/4$	$M/3$	$M/2$
$H(u)$	1	$1/3$	0	$-1/3$

En $u = M/3$ la onda tiene período de tres píxeles, la ventana contiene exactamente un ciclo y su suma es cero, por lo que esa frecuencia se elimina por completo. En $u = M/2$ el valor es negativo, de modo que el patrón alternante sale con un tercio de su amplitud y con el contraste invertido. Directamente,

$$g(x) = \frac{(-1)^{x-1} + (-1)^x + (-1)^{x+1}}{3} = (-1)^x\,\frac{-1+1-1}{3} = -\frac{1}{3}\,(-1)^x.$$

El promedio no es un pasa bajos ideal, ya que no corta en una frecuencia definida y tiene un lóbulo negativo en las frecuencias altas.

b. Del mismo modo,

$$H_{\text{lap}}(u) = e^{j2\pi u/M} - 2 + e^{-j2\pi u/M} = -2 + 2\cos(2\pi u/M) = -4\sin^2(\pi u/M),$$

y con $\sin x \approx x$ para x pequeño, $H_{\text{lap}} \approx -4\pi^2(u/M)^2$, que es el Laplaciano continuo $-4\pi^2 u^2$ con u/M ciclos por píxel. Con cuatro vecinos, el Laplaciano es la suma de una segunda diferencia por filas y otra por columnas, y por linealidad

$$H_{\text{lap}}(u,v) = -4\left[\sin^2(\pi u/M) + \sin^2(\pi v/N)\right], \qquad H_g = 1 + 4c\left[\sin^2(\pi u/M) + \sin^2(\pi v/N)\right].$$

Con $c = 1$ se obtiene $H_g(0,0) = 1$, $H_g(M/2,0) = 5$ y $H_g(M/2, N/2) = 9$. El primer valor es la ganancia en continua, igual a la suma de coeficientes del kernel $\delta - \boldsymbol{L}$. El segundo corresponde a franjas de período dos píxeles. El tercero corresponde al tablero de ajedrez y coincide con el factor $1 + 8c$ de la Prueba 1. La ganancia crece de forma monótona con la frecuencia, de modo que las componentes que más se amplifican son las de frecuencia más alta, donde se concentra el ruido.

c. Directamente, $g(x) = [f(x-1) + f(x) + f(x+1)]/3$ con índices módulo cuatro:

$$g(0) = \frac{1+2+1}{3} = \frac{4}{3}, \qquad g(1) = \frac{2+1+0}{3} = 1, \qquad g(2) = \frac{1+0+1}{3} = \frac{2}{3}, \qquad g(3) = \frac{0+1+2}{3} = 1.$$

Con $M = 4$, $H = [\,1,\ 1/3,\ -1/3,\ 1/3\,]$ y $F = [\,4,\ 2,\ 0,\ 2\,]$, de donde $G = F\,H = [\,4,\ 2/3,\ 0,\ 2/3\,]$. Directamente, $G(0) = 4/3 + 1 + 2/3 + 1 = 4$ y $G(1) = 4/3 - j - 2/3 + j = 2/3$, que coinciden.

El valor $g(0)$ usó $f(3)$ como vecino izquierdo, porque la transformada discreta trata la señal como periódica. Si f es parte de una señal no periódica, ese valor mezcla los dos extremos y es un artefacto de solapamiento circular. Para evitarlo se rellena con ceros hasta $P \geq A + C - 1$, que para la señal de cuatro muestras y el kernel de tres es $P \geq 6$, y para la imagen es $P \geq 512 + 15 - 1 = 526$ en cada dimensión.

Bloque B. Filtrado en el dominio de la frecuencia

Problema B.1

Use $e^{-1/8} = 0{,}88$, $e^{-1/2} = 0{,}61$, $e^{-2} = 0{,}14$ y $\pi \approx 3{,}14$.

a. Con $D_0 = 20$, evalúe el filtro ideal, el de Butterworth de orden 2 y el gaussiano en $D = 10$, 20 y 40, y obtenga los pasa altos correspondientes. Demuestre que el pasa altos de Butterworth del formulario es exactamente $1 - H_{lp}$ y comente los valores en $D = D_0$.

b. Explique por qué el filtro ideal produce anillos y el gaussiano no. Para una imagen de 256×256, calcule el ancho del kernel gaussiano espacial equivalente al filtro gaussiano con $D_0 = 20$, e indique qué le ocurre si D_0 se duplica.

c. Una región de tomografía tiene media 100 y desviación estándar 20. Calcule qué porcentaje de la potencia total retiene la componente continua por sí sola, use $10\,000/10\,400 = 0{,}962$, y explique qué implica para la interpretación de α y para la visualización del espectro.

Solución B.1

a. Con $r = D/D_0$, Butterworth vale $1/(1 + r^4)$ y el gaussiano $e^{-r^2/2}$.

D	10	20	40
Ideal, pasa bajos	1	1	0
Butterworth $n = 2$, pasa bajos	$1/1{,}0625 = 0{,}94$	0,50	$1/17 = 0{,}06$
Gaussiano, pasa bajos	$e^{-1/8} = 0{,}88$	$e^{-1/2} = 0{,}61$	$e^{-2} = 0{,}14$
Ideal, pasa altos	0	0	1
Butterworth $n = 2$, pasa altos	0,06	0,50	0,94
Gaussiano, pasa altos	0,12	0,39	0,86

Para Butterworth,

$$1 - \frac{1}{1 + r^{2n}} = \frac{r^{2n}}{1 + r^{2n}} = \frac{1}{1 + r^{-2n}} = \frac{1}{1 + (D_0/D)^{2n}},$$

que es la expresión del formulario. En $D = D_0$ el ideal todavía vale uno, el de Butterworth vale $1/2$ cualquiera sea su orden y el gaussiano vale 0,61. El mismo D_0 corresponde entonces a cortes distintos, y comparar familias con igual D_0 no es una comparación justa.

b. El kernel espacial del filtro ideal es una función tipo sinc, con lóbulos laterales que alternan de signo. Al convolucionar un borde, cada lóbulo deja una réplica atenuada del borde a una distancia fija, y el resultado son anillos concéntricos alrededor de las estructuras, separados por una distancia inversamente proporcional a D_0. La transformada de una gaussiana es otra gaussiana, positiva en todo el plano y sin lóbulos laterales, de modo que el filtro gaussiano sólo desenfoca.

El kernel equivalente tiene

$$\sigma = \frac{M}{2\pi D_0} = \frac{256}{2 \cdot 3{,}14 \cdot 20} = \frac{256}{125{,}6} \approx 2 \text{ píxeles.}$$

Si D_0 se duplica, σ se reduce a la mitad, esto es a un píxel. Un corte más alto en frecuencia deja pasar más detalle y corresponde a un kernel más angosto en el espacio.

c. La componente continua vale $F(0,0) = MN\bar{f}$, de modo que su potencia es $(MN\bar{f})^2$. Por Parseval la potencia total es $MN \sum f^2 = (MN)^2 \left(\bar{f}^2 + \sigma_f^2\right)$, de donde

$$\frac{|F(0,0)|^2}{P_T} = \frac{\bar{f}^2}{\bar{f}^2 + \sigma_f^2} = \frac{10\,000}{10\,400} = 0{,}962.$$

La componente continua retiene por sí sola el 96,2

Problema B.2

a. Con el pasa altos gaussiano de $D_0 = 20$ del problema anterior, evalúe en $D = 0$, 20 y 40 el filtro *high-boost* con $A = 2$ y el énfasis de alta frecuencia con $a = 0{,}5$ y $b = 2$. Interprete la ganancia en continua de cada uno, y relacione ambos con el realce $g = f + k\,(f - f_{lp})$.

b. Una imagen de resonancia de 256×256 está contaminada por la interferencia aditiva $\eta(x, y) = 20\cos(2\pi \cdot 32\,y/256)$. Ubique los impulsos en el espectro centrado, calcule su magnitud, diseñe un filtro para eliminarlos y explique por qué un pasa bajos no es una alternativa razonable.

c. Demuestre que un filtro real, no negativo y simétrico conserva la fase de cada coeficiente. Explique qué ocurriría si el filtro de la parte b anulara sólo uno de los dos impulsos, y qué hace el filtro $H(u) = e^{-j2\pi u x_0/M}$, cuya magnitud vale uno en todas las frecuencias.

Solución B.2

a. El pasa altos gaussiano vale 0, 0,39 y 0,86 en las tres distancias.

D	0	20	40
H_{hp}	0	0,39	0,86
$H_{hb} = 1 + H_{hp}$	1	1,39	1,86
$H_{hfe} = 0{,}5 + 2H_{hp}$	0,5	1,28	2,22

El *high-boost* con $A = 2$ tiene ganancia uno en continua, de modo que conserva el brillo medio y amplifica las altas frecuencias hasta casi el doble. El énfasis de alta frecuencia reduce a la mitad la componente continua y amplifica más de dos veces las altas frecuencias, con lo cual la imagen pierde rango tonal. Por eso suele seguirse de una ecualización de histograma, que redistribuye los niveles de gris sobre todo el rango.

El realce $g = f + k\,(f - f_{lp})$ tiene transformada $G = [1 + k\,(1 - H_{lp})]\,F = (1 + k\,H_{hp})\,F$, que es el énfasis de alta frecuencia con $a = 1$ y $b = k$. El *high-boost* con $A = 2$ coincide con el caso $k = 1$. En general $H_{hb}(0) = A - 1$, y sólo $A = 2$ preserva el brillo medio, el mismo resultado que se obtuvo en el dominio espacial.

b. La interferencia varía sólo a lo largo de y con $v_0 = 32$ ciclos, de modo que produce impulsos en $(0, \pm 32)$, que en el espectro centrado están en (128, 96) y (128, 160). Como $\cos\theta = \left(e^{j\theta} + e^{-j\theta}\right)/2$, cada impulso tiene magnitud

$$20 \cdot \frac{MN}{2} = 10 \cdot 65\,536 = 655\,360.$$

El filtro adecuado es un *notch* que valga cero en ambos puntos y uno en el resto, por ejemplo con discos de radio pequeño D_N centrados en los dos impulsos, o con una versión gaussiana para evitar anillos. La componente continua no se modifica, de modo que el brillo medio se conserva. Un pasa bajos que eliminara la interferencia necesitaría $D_0 < 32$ y borraría todo el detalle anatómico de frecuencia mayor, mientras que el *notch* altera sólo el contenido de la imagen que coincide exactamente con esas dos frecuencias.

c. Si $H(u, v)$ es real y no negativo, $G = H\,F$ tiene magnitud $H|F|$ y la misma fase que F donde $H > 0$. Si además $H(-u, -v) = H(u, v)$ y f es real, $G(-u, -v) = H(u, v)F^*(u, v) = G^*(u, v)$, de modo que G conserva la simetría conjugada y la imagen filtrada es real. Ninguna estructura se desplaza.

Si se anulara sólo uno de los impulsos, quedaría $10\,e^{j2\pi \cdot 32y/256}$, una exponencial compleja. El espectro perdería la simetría conjugada, la transformada inversa sería compleja y su parte real conservaría una interferencia de amplitud 10, la mitad de la original.

El filtro $H(u) = e^{-j2\pi u x_0/M}$ no modifica ninguna magnitud y sin embargo, por la propiedad de traslación, desplaza la imagen en x_0 píxeles. Es la prueba directa de que la posición de las estructuras está codificada en la fase.

Bloque C. Agrupamiento y modelos de mezclas

Problema C.1

Las intensidades de siete píxeles son $x = \{10,\ 14,\ 18,\ 32,\ 42,\ 46,\ 50\}$.

a. Aplique k-means con $C = 2$ partiendo de $\mathbf{v} = (10,\ 20)$. Muestre la partición y los centroides en cada iteración hasta la convergencia, calcule J final y la frontera de decisión.

b. Con $C = 3$, tres inicializaciones distintas convergen a las particiones $\{10\}\{14,18\}\{32,42,46,50\}$, $\{10,14,18\}\{32\}\{42,46,50\}$ y $\{10,14,18\}\{32,42\}\{46,50\}$. Verifique que cada una es un punto fijo del algoritmo, calcule su J e indique cuál conservaría.

c. Con fuzzy c-means, centros $v_1 = 20$ y $v_2 = 50$, calcule las pertenencias de $x = 40$ para $m = 2$, $m = 3$ y $m = 1{,}5$, y sus límites cuando $m \to 1$ y $m \to \infty$. Repita para $x = 35$. Luego, para los datos $\{10,\ 30,\ 50\}$ con pertenencias a la clase 1 iguales a $\{1;\ 0{,}5;\ 0\}$ y $m = 2$, calcule v_1 y compárelo con el centroide de k-means si el dato 30 se asigna a la clase 1.

Solución C.1

a.

Iteración	Centroides	Partición	Centroides nuevos
1	(10; 20)	{10, 14} {18, 32, 42, 46, 50}	(12; 37,6)
2	(12; 37,6)	{10, 14, 18} {32, 42, 46, 50}	(14; 42,5)
3	(14; 42,5)	{10, 14, 18} {32, 42, 46, 50}	(14; 42,5)

En la primera iteración el dato 14 queda en la clase 1 porque $|14-10| = 4 < |14-20| = 6$, y el 18 en la clase 2 porque $|18-20| = 2$. El centroide de la clase 2 es $188/5 = 37{,}6$. En la segunda, el 18 cambia de clase, ya que $|18-12| = 6 < |18-37{,}6| = 19{,}6$. En la tercera ningún dato cambia y el algoritmo se detiene. El costo final es

$$J = (16 + 0 + 16) + \left(10{,}5^2 + 0{,}5^2 + 3{,}5^2 + 7{,}5^2\right) = 32 + 179 = 211,$$

y la frontera es el punto medio $(14 + 42{,}5)/2 = 28{,}25$.

b. Una partición es un punto fijo si, con los centroides que ella misma produce, cada dato sigue asignado a su centroide más cercano.

Partición	Centroides	Datos críticos	J
$\{10\}\{14,18\}\{32,42,46,50\}$	10; 16; 42,5	14 a distancias 4 y 2; 32 a 16 y 10,5	$0 + 8 + 179 = 187$
$\{10,14,18\}\{32\}\{42,46,50\}$	14; 32; 46	18 a 4 y 14; 42 a 10 y 4	$32 + 0 + 32 = 64$
$\{10,14,18\}\{32,42\}\{46,50\}$	14; 37; 48	42 a 5 y 6; 32 a 18 y 5	$32 + 50 + 8 = 90$

Las tres son puntos fijos, de modo que el algoritmo se detiene en cada una, pero sólo la segunda es el mínimo global de las tres. Se conserva la de menor J, esto es $J = 64$. El ejemplo muestra por qué la práctica habitual consiste en repetir el ajuste con varias inicializaciones y quedarse con la de menor costo, o bien inicializar de manera informada. La dependencia de la inicialización afecta directamente la reproducibilidad del método.

c. Con dos clases, $u_1 = 1/\left[1 + (d_1/d_2)^{2/(m-1)}\right]$. Para $x = 40$ se tiene $d_1 = 20$ y $d_2 = 10$, con razón $d_1/d_2 = 2$.

m	$m \to 1$	1,5	2	3	$m \to \infty$
Exponente $2/(m-1)$	∞	4	2	1	0
u_1	0	$1/17 = 0{,}06$	$1/5 = 0{,}20$	$1/3 = 0{,}33$	0,50
u_2	1	0,94	0,80	0,67	0,50

Para $x = 35$ las dos distancias valen 15, la razón es uno y $u_1 = u_2 = 1/2$ para cualquier m. El exponente m regula cuánta ambigüedad se conserva, desde la pertenencia estricta de k-means hasta el reparto uniforme.

Para el centro, con pesos $u^m = \{1;\ 0{,}25;\ 0\}$,

$$v_1 = \frac{1 \cdot 10 + 0{,}25 \cdot 30 + 0 \cdot 50}{1 + 0{,}25 + 0} = \frac{17{,}5}{1{,}25} = 14.$$

En k-means, con el 30 asignado a la clase 1, el centroide sería $(10+30)/2 = 20$. El dato ambiguo pesa un cuarto en fuzzy c-means y por eso desplaza menos el centro. Esa es la razón por la cual fuzzy c-means es algo más robusto que k-means frente a datos de frontera o atípicos.

Problema C.2

Un histograma de resonancia se modela con dos gaussianas, tejido sano con $w_1 = 0{,}75$ y $\mu_1 = 40$, y lesión con $w_2 = 0{,}25$ y $\mu_2 = 80$, ambas con $\sigma = 10$. Use $e^4 = 54{,}6$, $\ln 3 = 1{,}10$ y $\ln 9 = 2{,}20$.

a. Calcule las probabilidades posteriores de un píxel con $x = 60$ y de uno con $x = 70$, y asígnelos.

b. Deduzca la frontera de decisión y compárela con la de k-means con centroides en las mismas medias. Recalcule la frontera si la lesión ocupa sólo el 10 % de la imagen y explique la consecuencia para el volumen estimado. Describa cualitativamente qué cambia si la lesión tiene $\sigma_2 = 20$.

c. En una iteración de EM sobre los datos $x = \{40,\ 50,\ 70,\ 80\}$ se obtienen las posteriores de la clase 1 $\hat{h}_1 = \{1;\ 0{,}8;\ 0{,}2;\ 0\}$. Calcule el paso M para ambas clases y compare con las medias y varianzas de la partición estricta $\{40, 50\}\{70, 80\}$.

Solución C.2

a. Con varianzas iguales, el factor $(2\pi\sigma^2)^{-1/2}$ se cancela en la posterior. En $x = 60$ ambas distancias valen 20, las verosimilitudes son iguales y

$$\hat{h}_1 = \frac{0{,}75}{0{,}75 + 0{,}25} = 0{,}75, \qquad \hat{h}_2 = 0{,}25.$$

El píxel equidistante de ambas medias se asigna al tejido sano, por efecto de la probabilidad a priori. En $x = 70$,

$$\frac{f_2(70)}{f_1(70)} = \exp\left[\frac{(70-40)^2 - (70-80)^2}{2\cdot 100}\right] = \exp\left[\frac{900-100}{200}\right] = e^4 = 54{,}6,$$

$$\hat{h}_2 = \frac{0{,}25 \cdot 54{,}6}{0{,}75 + 0{,}25 \cdot 54{,}6} = \frac{13{,}65}{14{,}40} = 0{,}95, \qquad \hat{h}_1 = 0{,}05,$$

y el píxel se asigna a la lesión.

b. La frontera cumple $w_1 f_1(x) = w_2 f_2(x)$. Tomando logaritmos,

$$\ln w_1 - \frac{(x-\mu_1)^2}{2\sigma^2} = \ln w_2 - \frac{(x-\mu_2)^2}{2\sigma^2} \quad \Longrightarrow \quad x^* = \frac{\mu_1+\mu_2}{2} + \frac{\sigma^2 \ln(w_1/w_2)}{\mu_2 - \mu_1},$$

donde se usó $(x-\mu_2)^2 - (x-\mu_1)^2 = (\mu_1-\mu_2)(2x-\mu_1-\mu_2)$. Con los datos,

$$x^* = 60 + \frac{100 \cdot \ln 3}{40} = 60 + 2{,}5 \cdot 1{,}10 = 62{,}75.$$

La frontera de k-means es el punto medio 60. La mezcla desplaza la frontera 2,75 niveles hacia la lesión, y los píxeles con intensidad entre 60 y 62,75 pasan al tejido sano. Con $w_2 = 0{,}1$ la frontera es $60 + 2{,}5 \cdot \ln 9 = 60 + 5{,}5 = 65{,}5$. Cuanto menor es la lesión, más se desplaza la frontera hacia ella, y los píxeles de volumen parcial del borde se asignan al tejido sano. El volumen de la lesión queda subestimado, con un sesgo relativo mayor en las lesiones pequeñas.

Con $\sigma_2 = 20$ los términos cuadráticos ya no se cancelan y la frontera es cuadrática, con dos puntos de corte. Entre ellos gana el tejido, y fuera de ellos gana la lesión, porque su gaussiana más ancha decae más lentamente y termina superando a la del tejido en ambas colas. Con los valores del enunciado los cortes están cerca de 61 y de -8, de modo que sobre el rango útil la frontera superior baja levemente y la lesión reclama también los valores muy bajos, lejos de su media.

c. Para la clase 1, $\sum_j \hat{h}_{1j} = 2$, de modo que $\hat{w}_1 = 2/4 = 0{,}5$ y

$$\hat{\mu}_1 = \frac{40 + 0{,}8\cdot 50 + 0{,}2 \cdot 70}{2} = \frac{94}{2} = 47, \qquad \hat{\sigma}_1^2 = \frac{1\cdot 49 + 0{,}8 \cdot 9 + 0{,}2 \cdot 529}{2} = \frac{49 + 7{,}2 + 105{,}8}{2} = 81.$$

Para la clase 2, $\hat{h}_2 = \{0;\ 0{,}2;\ 0{,}8;\ 1\}$, $\hat{w}_2 = 0{,}5$ y

$$\hat{\mu}_2 = \frac{0{,}2 \cdot 50 + 0{,}8 \cdot 70 + 80}{2} = \frac{146}{2} = 73, \qquad \hat{\sigma}_2^2 = \frac{0{,}2 \cdot 529 + 0{,}8 \cdot 9 + 1 \cdot 49}{2} = 81.$$

La partición estricta da medias 45 y 75 y varianzas 25. Con posteriores las medias se acercan, porque los datos intermedios contribuyen a ambas clases, y las varianzas se triplican, porque esos mismos datos quedan lejos de la media de la clase a la que pertenecen sólo parcialmente. La mezcla reconoce el solapamiento entre las clases, mientras que la partición estricta lo oculta y subestima la dispersión de cada tejido.

Bloque D. Campos de Markov, regiones y evaluación

Problema D.1

Una imagen tiene dos clases, tejido ($\ell = 1$, $\mu_1 = 50$) y lesión ($\ell = 2$, $\mu_2 = 100$), ambas con $\sigma = 10$. Se aplica el modo condicional iterado con prior de Potts en vecindad de ocho.

a. Un píxel con $y_s = 80$ tiene seis vecinos etiquetados como tejido y dos como lesión. Calcule los términos de dato, la etiqueta por máxima verosimilitud y la etiqueta que asigna ICM con $\beta = 0{,}5$ y con $\beta = 1$. Determine el valor crítico de β.

b. Deduzca la condición general para que un píxel etiquetado como lesión pase a tejido. Aplíquela con $\beta = 1$ y con $\beta = 2$ a un píxel de lesión aislado, a uno en una línea de un píxel de ancho, a uno en la esquina de una región cuadrada y a uno en un borde recto, para $y_s = 95$ y para $y_s = 80$.

c. Para una imagen de 256×256 con cuatro clases, indique el tamaño del espacio de soluciones. Explique por qué la constante Z no interviene, por qué ICM converge, a qué converge, y qué se obtiene con $\beta = 0$.

Solución D.1

a. Con varianzas iguales el término $\log \sigma$ es común a ambas clases y se omite, de modo que $d_s(\ell) = (y_s - \mu_\ell)^2/200$.

$$d_s(1) = \frac{30^2}{200} = 4{,}5, \qquad d_s(2) = \frac{20^2}{200} = 2{,}0,$$

y por máxima verosimilitud el píxel es lesión. Con la etiqueta 1 discrepa de dos vecinos y con la etiqueta 2 de seis:

$$E_s(1) = 4{,}5 + 2\beta, \qquad E_s(2) = 2{,}0 + 6\beta.$$

Con $\beta = 0{,}5$, $E_s(1) = 5{,}5$ y $E_s(2) = 5{,}0$, y el píxel sigue siendo lesión. Con $\beta = 1$, $E_s(1) = 6{,}5$ y $E_s(2) = 8{,}0$, y pasa a tejido. El cambio ocurre cuando $4{,}5 + 2\beta < 2 + 6\beta$, esto es $\beta > 2{,}5/4 = 0{,}625$.

b. El píxel pasa a tejido si $E_s(1) < E_s(2)$, esto es si

$$\Delta_s = d_s(1) - d_s(2) < \beta\,[n_s(2) - n_s(1)]\,.$$

Para $y_s = 95$, $\Delta_s = (45^2 - 5^2)/200 = 2000/200 = 10$. Para $y_s = 80$, $\Delta_s = 4{,}5 - 2 = 2{,}5$. La diferencia de desacuerdos vale 8 para el píxel aislado, 4 en la línea, 2 en la esquina y -2 en el borde recto.

Configuración	$\beta[n_s(2) - n_s(1)]$, $\beta = 1$	$\beta = 2$	$y_s = 95$ ($\Delta_s = 10$)	$y_s = 80$ ($\Delta_s = 2{,}5$)
Aislado	8	16	Pasa sólo con $\beta = 2$	Pasa con ambos
Línea	4	8	Se conserva	Pasa con ambos
Esquina	2	4	Se conserva	Pasa sólo con $\beta = 2$
Borde recto	-2	-4	Se conserva	Se conserva

Con evidencia débil, $y_s = 80$, el campo elimina el píxel aislado y la línea fina ya con $\beta = 1$, y con $\beta = 2$ redondea además la esquina. Con evidencia fuerte, $y_s = 95$, sólo el píxel aislado desaparece y únicamente con $\beta = 2$. El borde recto nunca se desplaza, porque allí el término espacial favorece conservar la etiqueta. El parámetro β fija qué estructuras se consideran ruido, y un valor alto borra estructuras finas legítimas como los surcos corticales.

c. El espacio de soluciones tiene $4^{65\,536}$ configuraciones, de modo que ninguna búsqueda exhaustiva es viable. La constante Z es la suma sobre todas esas configuraciones y no depende de $\mathbf{x}$, por lo que desaparece al comparar energías o al maximizar la posterior. Cada actualización de ICM elige la etiqueta que minimiza la energía local con los vecinos fijos, y por lo tanto la energía total no aumenta. Como el número de configuraciones es finito, el procedimiento se detiene en pocas pasadas, pero en un mínimo local que depende de la clasificación inicial. Con $\beta = 0$ el término espacial desaparece y se obtiene la clasificación por máxima verosimilitud píxel a píxel, que es la que produce el moteado.

Problema D.2

Se aplica crecimiento de regiones con vecindad de ocho y criterio $|f(x) - f(g)| < T$, con semilla en el píxel $(2, 2)$ de la imagen siguiente, con filas y columnas indexadas desde cero. La referencia manual R está formada por los diez píxeles con valores entre 75 y 102.

$$f = \begin{bmatrix} 30 & 32 & 31 & 30 & 33 & 30 \\ 31 & 75 & 84 & 90 & 34 & 30 \\ 30 & 88 & \mathbf{80} & 102 & 112 & 32 \\ 32 & 79 & 95 & 86 & 115 & 108 \\ 31 & 33 & 85 & 34 & 31 & 110 \\ 30 & 31 & 32 & 30 & 33 & 112 \end{bmatrix}$$

a. Haga crecer la región con $T = 20$ y con $T = 40$, indicando los píxeles agregados en cada pasada. Explique la diferencia y determine el intervalo de valores de T para el cual la región coincide con la referencia.

b. Repita con $T = 30$ usando como criterio la distancia a la media de la región, actualizada al final de cada pasada, y compare con el criterio respecto de la semilla.

c. Para $T = 20$ y $T = 40$ calcule los verdaderos positivos, falsos positivos y falsos negativos, la exactitud, las fracciones FP y FN, Dice y Jaccard, y verifique la relación entre los dos últimos. Comente qué métrica detecta la fuga.

Solución D.2

a. Con $T = 20$ se aceptan valores en el intervalo abierto $(60, 100)$.

Pasada	Píxeles agregados	Tamaño
1	75, 84, 90, 88, 79, 95, 86	8
2	85 en $(4, 2)$	9

El 102 queda fuera porque $|102 - 80| = 22 \geq 20$, y la región termina con nueve píxeles.

Con $T = 40$ se aceptan valores en $(40, 120)$.

Pasada	Píxeles agregados	Tamaño
1	75, 84, 90, 88, 102, 79, 95, 86	9
2	112 en $(2, 4)$, 115 en $(3, 4)$, 85 en $(4, 2)$	12
3	108 en $(3, 5)$, 110 en $(4, 5)$	14
4	112 en $(5, 5)$	15

El 102 actúa como puente. Una vez dentro de la región, sus vecinos 112 y 115 quedan a menos de 40 de la semilla, y desde ellos la región avanza por la estructura brillante de la derecha, que no pertenece a la lesión. Es la fuga característica del método. El fondo, con valores entre 30 y 34, queda fuera porque su distancia a la semilla supera 40.

La región coincide con la referencia cuando incluye el 102, lo que exige $T > 22$, y excluye el 112 vecino, lo que exige $T \leq 32$. La meseta es $22 < T \leq 32$.

b. En la primera pasada la media de la región es la semilla, de modo que se agregan los mismos ocho píxeles que con el criterio fijo y $T = 30$, incluido el 102. La suma de la región es 779 y la media pasa a $779/9 = 86{,}6$. En la segunda pasada se comparan los vecinos con esa media, $|112 - 86{,}6| = 25{,}4 < 30$ y $|115 - 86{,}6| = 28{,}4 < 30$, de modo que entran el 112, el 115 y el 85, y la media sube a $1091/12 = 90{,}9$. En la tercera entran el 108 y el 110, la media sube a 93,5, y en la cuarta entra el último 112. La región termina con quince píxeles, igual que con el criterio fijo y $T = 40$.

Con el criterio respecto de la semilla y $T = 30$, el 112 queda fuera porque $|112 - 80| = 32$, y la región coincide con la referencia. Con el criterio adaptativo, cada píxel brillante que entra eleva la media y facilita la entrada del siguiente, y la región deriva hacia la estructura vecina con un umbral menor.

c. La referencia tiene $|R| = 10$ píxeles.

T	$\lvert S\rvert$	VP	FP	FN	Ex	FP/V_R	FN/V_R	Dice	Jaccard
20	9	9	0	1	0,90	0	0,10	$18/19 = 0{,}95$	$9/10 = 0{,}90$
40	15	10	5	0	1,00	0,50	0	$20/25 = 0{,}80$	$10/15 = 0{,}67$

La relación se verifica con $0{,}947/(2 - 0{,}947) = 0{,}90$ y $0{,}8/1{,}2 = 0{,}67$.

Con $T = 40$ la exactitud vale 100

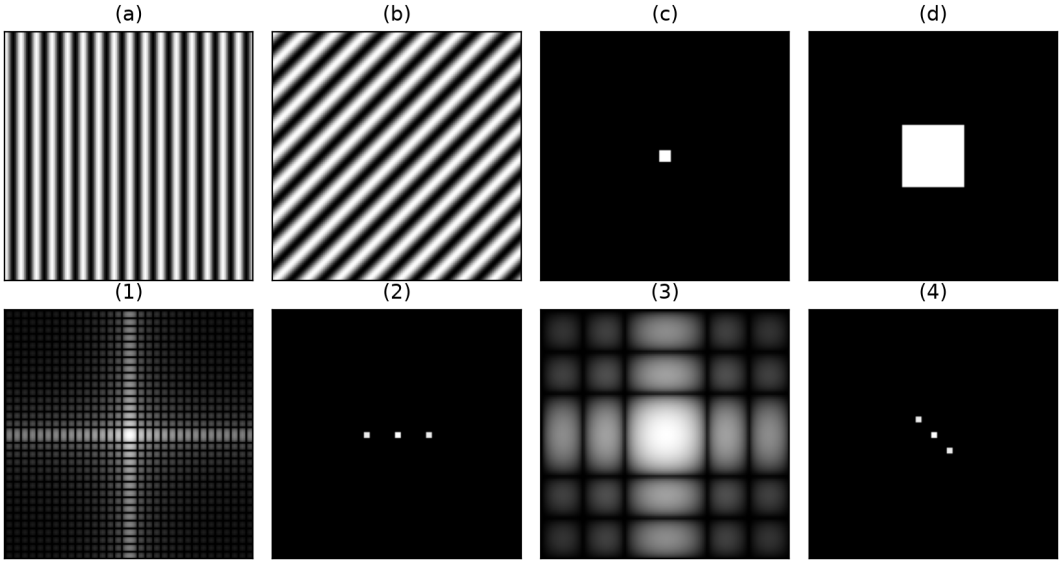
Parte IV. Problemas propuestos

Se entrega sólo la respuesta final. El desarrollo es parte del ejercicio.

1. Calcule la transformada de $[\,1,\ 0,\ 0,\ 0\,]$ y de $[\,3,\ 3,\ 3,\ 3\,]$. *Respuesta.* $[\,1,\ 1,\ 1,\ 1\,]$ y $[\,12,\ 0,\ 0,\ 0\,]$. Un impulso contiene todas las frecuencias por igual y una constante sólo la continua.

2. Calcule la transformada de $[\,1,\ -1,\ 1,\ -1\,]$ y de $[\,1,\ 0,\ -1,\ 0\,]$. *Respuesta.* $[\,0,\ 0,\ 4,\ 0\,]$ y $[\,0,\ 2,\ 0,\ 2\,]$. La primera es la onda de Nyquist y la segunda una onda de período cuatro, con su par conjugado en $u = 1$ y $u = 3$.

3. La figura muestra cuatro imágenes de 128×128 y sus espectros de magnitud centrados, en escala logarítmica y en otro orden. Asocie cada imagen con su espectro y justifique.



Respuesta. (a) con (2), (b) con (4), (c) con (3) y (d) con (1). Las franjas verticales producen un par de impulsos sobre el eje horizontal, y las diagonales un par sobre la diagonal perpendicular a ellas. El cuadrado pequeño produce la sinc más ancha y el grande la más angosta, porque el ancho en el espacio y en la frecuencia son inversamente proporcionales.

4. Evalúe el pasa bajos de Butterworth en $D = 2D_0$ con $n = 1$ y con $n = 3$. *Respuesta.* $1/5 = 0{,}20$ y $1/65 = 0{,}015$. Al aumentar el orden el corte se vuelve más abrupto.

5. Determine la distancia a la cual el pasa bajos gaussiano vale $1/2$, usando $\ln 2 = 0{,}69$ y $\sqrt{1{,}39} = 1{,}18$. *Respuesta.* $D = D_0\sqrt{2 \ln 2} = 1{,}18\, D_0$.

6. Indique el tamaño mínimo de relleno para filtrar en frecuencia una imagen de 300×300 con un kernel de 31×31. *Respuesta.* 330×330.

7. Obtenga la función de transferencia del kernel $[1\ 2\ 1]/4$ y evalúela en $u = 0$, $M/4$ y $M/2$. *Respuesta.* $H(u) = [1 + \cos(2\pi u/M)]\,/2 = \cos^2(\pi u/M)$, con valores 1, 1/2 y 0. A diferencia del promedio de tres, no tiene lóbulo negativo y elimina la frecuencia de Nyquist.

8. Un énfasis de alta frecuencia con $a = 1$ y $b = 3$ usa un pasa altos de Butterworth de orden 2 con $D_0 = 20$. Calcule su ganancia en $D = 0$, 20 y 40, y el valor de k del realce espacial equivalente. *Respuesta.* 1, 2,5 y 3,82, con $k = 3$.

9. Con fuzzy c-means y tres clases, un dato está a igual distancia de los tres centros. Indique sus pertenencias para $m = 2$ y $m = 5$. *Respuesta.* 1/3 en cada clase, para cualquier m.

10. Dos clases con $w_1 = 0{,}9$, $w_2 = 0{,}1$, $\mu_1 = 30$, $\mu_2 = 90$ y $\sigma = 10$. Calcule la frontera de la mezcla y la de k-means, con $\ln 9 = 2{,}20$. *Respuesta.* 63,7 y 60.

11. Aplique división y fusión a la imagen siguiente con el predicado $P(R)$ verdadero si $\max R - \min R \leq 5$, y tamaño mínimo de un píxel.

$$\begin{bmatrix} 10 & 12 & 50 & 52 \\ 11 & 13 & 51 & 90 \\ 10 & 10 & 52 & 50 \\ 12 & 11 & 50 & 51 \end{bmatrix}$$

Respuesta. La imagen completa no cumple el predicado. Tres cuadrantes lo cumplen y el superior derecho se divide en cuatro píxeles, de modo que el quadtree tiene siete hojas. Tras la fusión quedan tres regiones, la mitad izquierda, los siete píxeles con valores entre 50 y 52, y el píxel de valor 90.

12. Con $\mu_1 = 50$, $\mu_2 = 100$ y $\sigma = 10$, un píxel con $y_s = 90$ está etiquetado como lesión y sus ocho vecinos como tejido. Determine el valor de β a partir del cual ICM lo cambia a tejido. *Respuesta.* $\Delta_s = (1600 - 100)/200 = 7{,}5$, de modo que cambia si $\beta > 7{,}5/8 = 0{,}94$.

13. Convierta Dice $= 0{,}8$ en Jaccard y Jaccard $= 0{,}5$ en Dice. *Respuesta.* 0,67 y 0,67.

14. Una lesión de 4×4 píxeles se segmenta con un cuadrado del mismo tamaño desplazado un píxel en horizontal y otro en vertical. Calcule Dice y repita para una lesión de 20×20. *Respuesta.* $2 \cdot 9/32 = 0{,}56$ y $2 \cdot 361/800 = 0{,}90$.