

Procesamiento de imágenes médicas

Segmentación de imágenes

Parte II

Alejandro Veloz

Objetivos

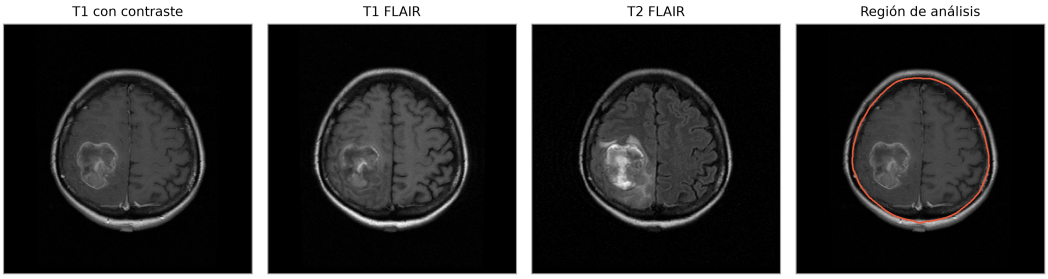
- Construir el espacio de características de una imagen y reconocer la diferencia entre el caso monoespectral y el multiespectral.
- Aplicar k-means y fuzzy c-means, e interpretar el grado de pertenencia como información clínica.
- Formular la segmentación como el ajuste de un modelo de mezclas y estimarlo mediante el algoritmo EM.
- Incorporar dependencia espacial entre etiquetas mediante campos aleatorios de Markov.
- Aplicar crecimiento de regiones y división y fusión, y analizar la elección de semillas y umbrales.
- Evaluar el desempeño de una segmentación con métricas de solapamiento y discutir la variabilidad del estándar de referencia.

En la Parte I la decisión se tomaba píxel a píxel, usando la intensidad propia o la de una vecindad pequeña. Ese enfoque tiene dos limitaciones.

- Una sola imagen suele ser insuficiente para separar tejidos cuyas intensidades se solapan.
- La decisión aislada de cada píxel ignora que los tejidos forman regiones espacialmente coherentes.

La Parte II ataca ambas limitaciones. La primera se resuelve describiendo cada píxel con un vector de varias modalidades. La segunda se resuelve incorporando la vecindad, ya sea de forma explícita en el crecimiento de regiones o de forma probabilística en los campos aleatorios de Markov.

Caso de estudio

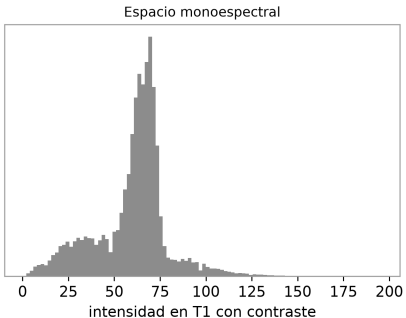


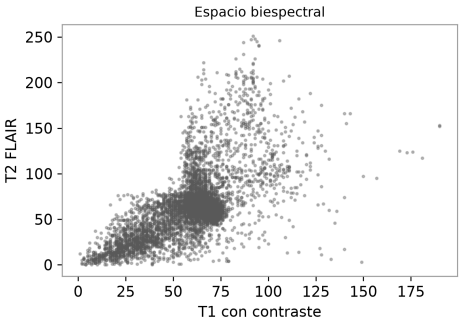
Glioblastoma multiforme en resonancia magnética. Tres modalidades co-registradas del mismo corte axial.

Agrupamiento en el espacio de características

Espacio de características

Cada píxel deja de ser un número y pasa a ser un vector con tantas componentes como imágenes disponibles.

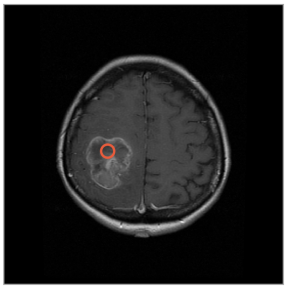




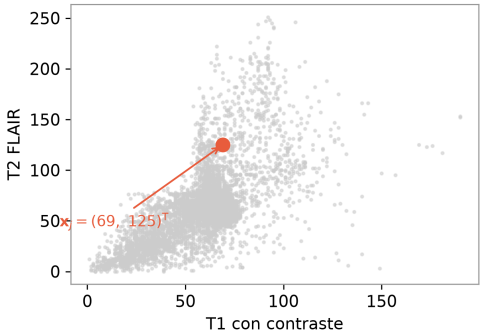
Con una imagen el espacio es el histograma. Con dos o más aparecen agrupamientos que ninguna modalidad separa por sí sola.

Vector de características

Un píxel del tumor

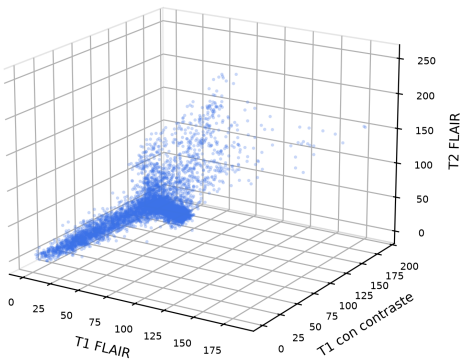


Vector de características



El conjunto de datos es $X = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ con $\mathbf{x}_j \in \mathbb{R}^p$, donde p es el número de modalidades.

Espacio multiespectral



- Una imagen produce un espacio monoespectral.
- Varias imágenes registradas producen un espacio multiespectral.
- La dimensión crece con el número de secuencias, y con ella el costo y la necesidad de datos.

Agrupamiento con k-means

Sea el conjunto $D = \{\mathbf{x}_k \mid \mathbf{x}_k \in \mathbb{R}^p,\ k = 1, \dots, N\}$. Se busca asignar a cada elemento una pertenencia estricta a una de C clases definidas a priori, minimizando

$$J(U, V) = \sum_{i=1}^{C} \sum_{\mathbf{x}_k \in G_i} \|\mathbf{x}_k - \mathbf{v}_i\|^2 ,$$

donde $V = (\mathbf{v}_1, \dots, \mathbf{v}_C)$ reúne los centroides, G_i es el conjunto de datos asignados a la clase i y U es la matriz de partición, con $u_{ik} = 1$ si $\mathbf{x}_k \in G_i$ y 0 en caso contrario. La distancia $d(\mathbf{x}, \mathbf{v}) = \|\mathbf{x} - \mathbf{v}\|$ es la euclidiana.

Algoritmo de k-means

1. Generar C valores iniciales para los centroides $\mathbf{v}_i$, con $i = 1, \ldots, C$.
2. Asignar cada objeto $\mathbf{x}_k$ a la clase del centroide más cercano,

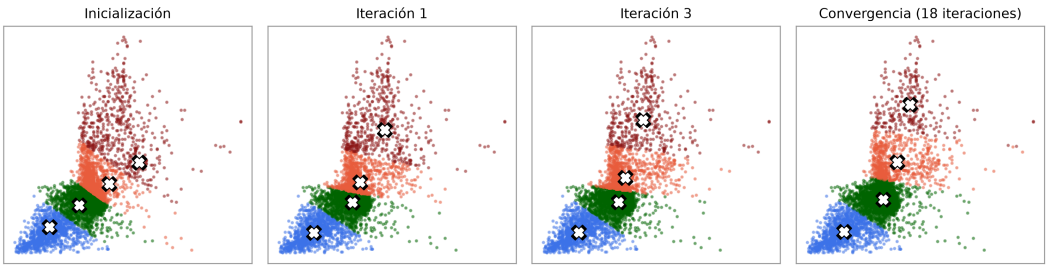
$$\mathbf{x}_k \in G_i \iff i = \arg \min_{1 \leq j \leq C} d(\mathbf{x}_k, \mathbf{v}_j).$$

3. Recalcular cada centroide como el centro de gravedad de su clase,

$$\mathbf{v}_i = \frac{1}{|G_i|} \sum_{\mathbf{x}_k \in G_i} \mathbf{x}_k.$$

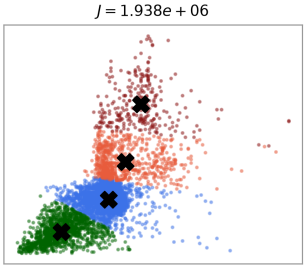
4. Detenerse si ningún objeto cambia de clase o si ningún centroide se desplaza. En caso contrario, volver al paso 2.

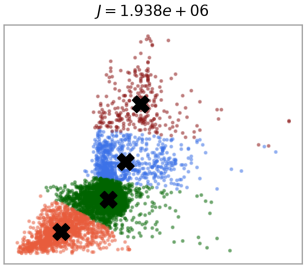
Evolución de los centroides

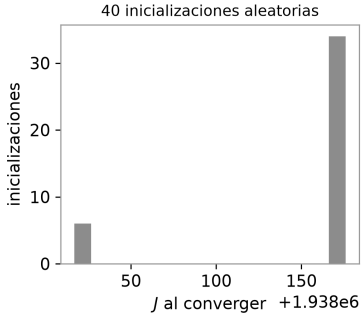


Espacio biespectral del caso de estudio, con $C = 4$ y una inicialización deliberadamente alejada.

Dependencia de la inicialización

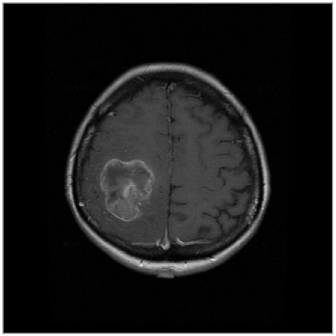




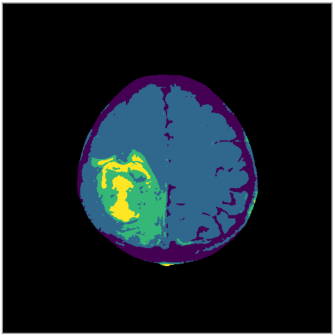


Resultado sobre la imagen

T1 con contraste



Etiquetas de k-means, $C = 4$



Clase de centroide más alto



De la pertenencia estricta a la difusa

En una imagen médica el volumen parcial hace que un mismo vóxel contenga más de un tejido. Forzar una pertenencia estricta descarta esa información.

Fuzzy c-means asigna a cada dato $\mathbf{x}_j$ un grado de pertenencia u_{ij} en cada una de las C clases, sujeto a

$$\sum_{i=1}^{C} u_{ij} = 1, \qquad u_{ij} \in [0,1], \qquad j = 1, \dots, N.$$

Función objetivo de fuzzy c-means

Se minimiza de manera iterativa:

$$J_{\text{fcm}}(U, V) = \sum_{i=1}^{C} \sum_{j=1}^{N} (u_{ij})^m \, d^2(\mathbf{x}_j, \mathbf{v}_i),$$

donde $\mathbf{v}_i$ es el centroide de la clase i, u_{ij} el grado de pertenencia del dato j en la clase i, y $m > 1$ el exponente de difusividad.

Cuando $m \to 1$ las pertenencias tienden a cero o uno y el método se reduce a k-means.

Solución por multiplicadores de Lagrange

Incorporando la restricción de suma unitaria,

$$L = J_{\text{fcm}}(U, V) + \sum_{j=1}^{N} \lambda_j \left(\sum_{i=1}^{C} u_{ij} - 1 \right), \qquad \frac{\partial L}{\partial u_{ij}} = m \left(u_{ij}\right)^{m-1} d^2(\mathbf{x}_j, \mathbf{v}_i) + \lambda_j =$$

Despejando y usando $\sum_i u_{ij} = 1$ se elimina el multiplicador y se obtiene

$$u_{ij} = \frac{1}{\sum_{k=1}^{C} \left(\frac{d(\mathbf{x}_j, \mathbf{v}_i)}{d(\mathbf{x}_j, \mathbf{v}_k)} \right)^{\frac{2}{m-1}}}.$$

Actualización de los centros

Derivando respecto de $\mathbf{v}_i$ e igualando a cero,

$$\frac{\partial J_{\text{fcm}}(U,V)}{\partial \mathbf{v}_i} = 0 \qquad \Longrightarrow \qquad \mathbf{v}_i = \frac{\sum_{j=1}^{N} (u_{ij})^m \, \mathbf{x}_j}{\sum_{j=1}^{N} (u_{ij})^m}.$$

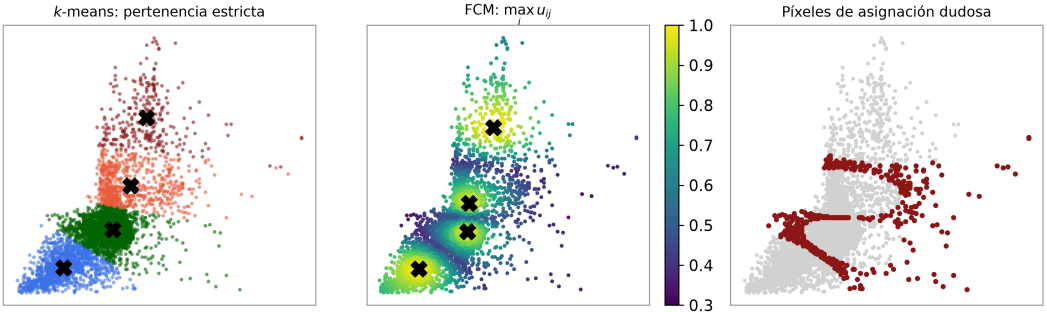
El centro de cada clase es un promedio ponderado de todos los datos, con pesos dados por la pertenencia elevada a m.

Algoritmo de fuzzy c-means

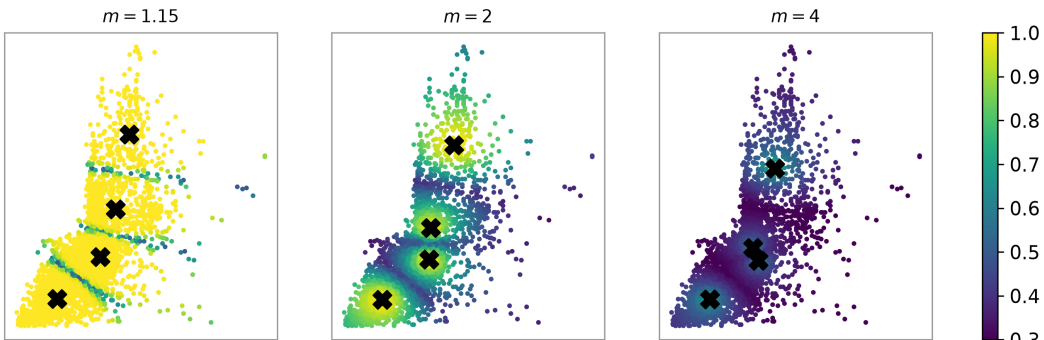
1. Generar C valores iniciales para los centros $\bar{V} = (\bar{\mathbf{v}}_1, \ldots, \bar{\mathbf{v}}_C)$.
2. Calcular la matriz de pertenencias óptima, $\bar{U} = \arg\min_U J_{\text{fcm}}(U, \bar{V})$.
3. Calcular los centros óptimos, $\bar{V} = \arg\min_V J_{\text{fcm}}(\bar{U}, V)$.
4. Verificar convergencia. Con $\hat{U}$ y $\hat{V}$ los valores de la iteración anterior, se detiene si $\max_{i,j} |\bar{u}_{ij} - \hat{u}_{ij}| < \varepsilon$, o si $\max_i \|\bar{\mathbf{v}}_i - \hat{\mathbf{v}}_i\| < \varepsilon$, o si el descenso ΔJ de la función objetivo es menor que ε. En caso contrario, volver al paso 2.

Conviene además fijar un número máximo de iteraciones.

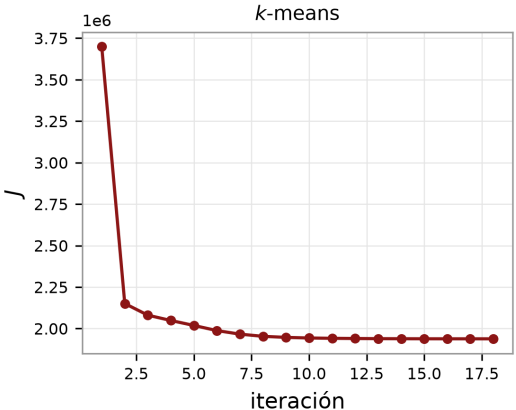
Pertenencia estricta frente a pertenencia difusa

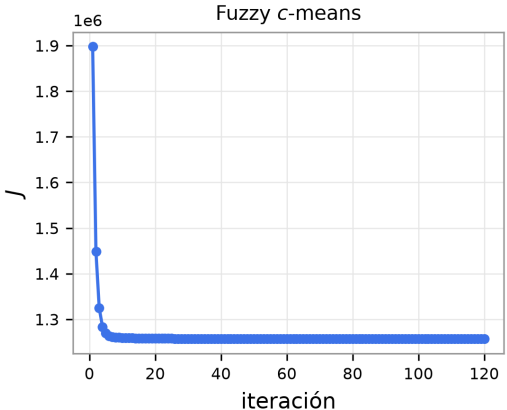


Exponente de difusividad

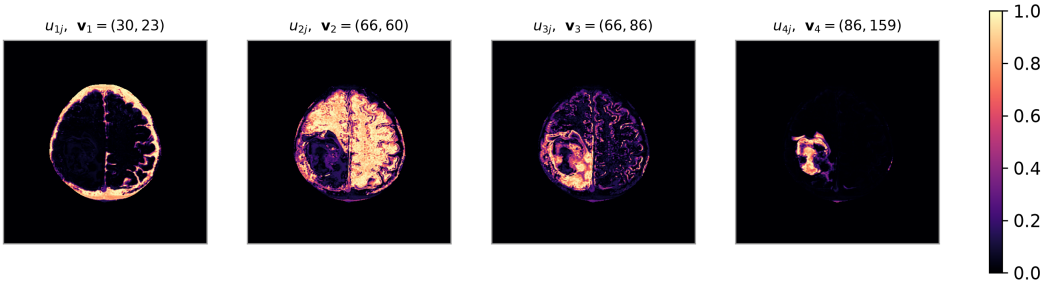


Convergencia



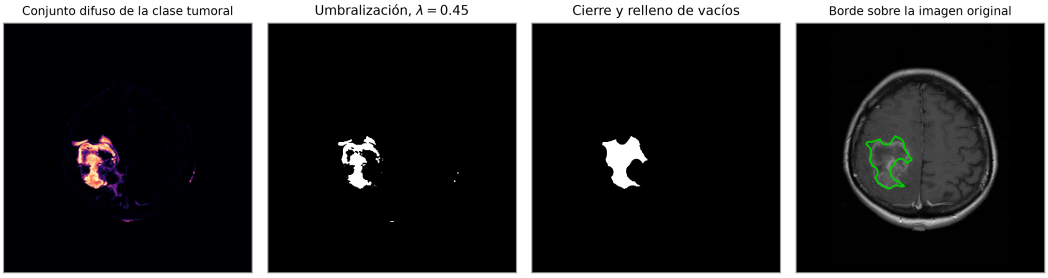


Mapas de pertenencia



Resultado de fuzzy c-means con $C = 4$ y $m = 2$, visto como cuatro imágenes de pertenencia.

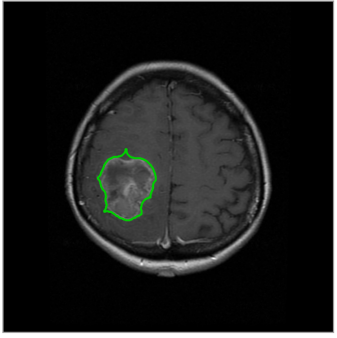
Postprocesamiento



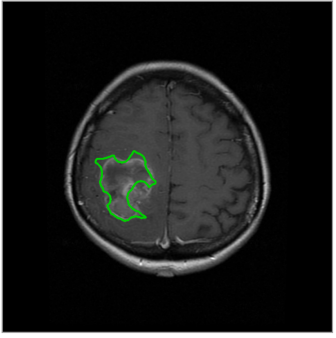
El conjunto difuso se convierte en un conjunto estricto umbralizando el mapa de pertenencia de la clase elegida: $f(x, y) = 1$ si $u_{ij} > \lambda$, y 0 en caso contrario. El símbolo λ es aquí el umbral de pertenencia y no el multiplicador de Lagrange.

Monoespectral frente a multiespectral

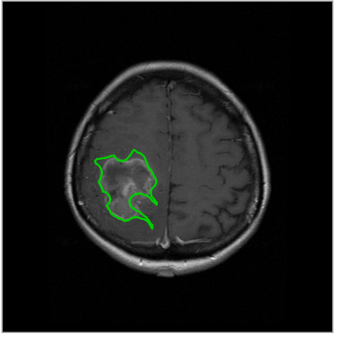
Monoespectral (T1 con contraste)



Biespectral (T1 con contraste, T2)



Multiespectral (tres modalidades)



Modelos de mezclas y algoritmo EM

Modelo mixto finito

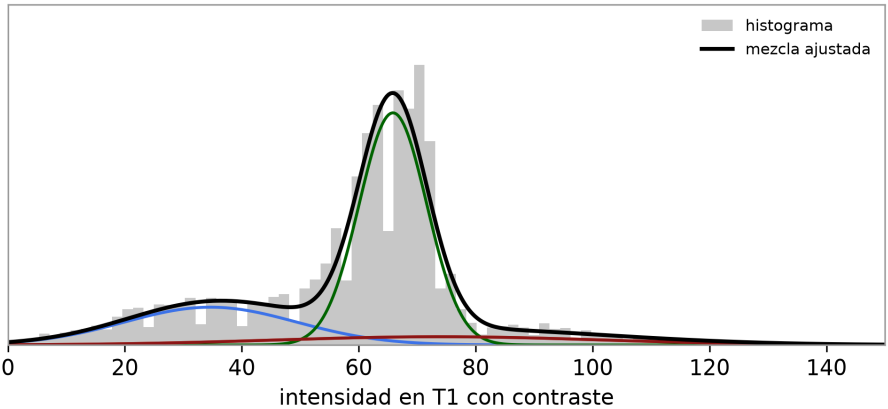
Una densidad multimodal y multivariada $f(\mathbf{x})$, con $\mathbf{x} \in \mathbb{R}^p$, se expresa como suma ponderada de C densidades condicionales de clase, con pesos iguales a las probabilidades a priori,

$$f(\mathbf{x}) = \sum_{i=1}^{C} w_i \, f_i(\mathbf{x} \mid \theta_i), \qquad \sum_{i=1}^{C} w_i = 1.$$

Con componentes gaussianas, $\theta_i = (\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$ y

$$f_i(\mathbf{x} \mid \theta_i) = N(\mathbf{x} \mid \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) = (2\pi)^{-p/2} \, |\boldsymbol{\Sigma}_i|^{-1/2} \exp\{-\tfrac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^\intercal \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i)\} \, .$$

Ajuste sobre el histograma



Algoritmo EM: paso de expectación

La pertenencia de cada dato a cada clase es una variable no observada. Con los parámetros actuales (w_i, θ_i) se calcula su esperanza, que es la probabilidad posterior de que la observación $\mathbf{x}_j$ pertenezca a la clase i,

$$\Pr(\theta_i \mid \mathbf{x}_j) = \hat{h}_{ij} = \frac{w_i \, f_i(\mathbf{x}_j \mid \theta_i)}{f(\mathbf{x}_j)} = \frac{w_i \, f_i(\mathbf{x}_j \mid \theta_i)}{\sum_{l=1}^{C} w_l \, f_l(\mathbf{x}_j \mid \theta_l)},$$

con $i = 1, \ldots, C$ y $j = 1, \ldots, N$.

Las posteriores de cada dato suman uno sobre las clases, como las pertenencias de fuzzy c-means, y son los pesos con los que el paso siguiente reestima los parámetros.

Algoritmo EM: paso de maximización

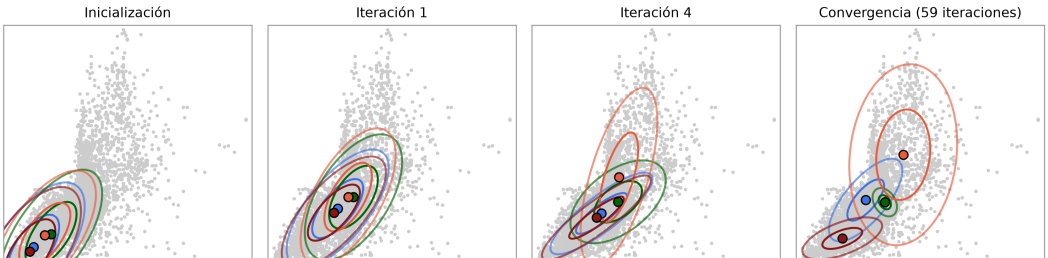
Dadas las posteriores, se actualizan los parámetros maximizando la verosimilitud esperada. Las probabilidades a priori son el promedio de las posteriores de cada clase y, para mezclas normales, las medias y covarianzas son promedios ponderados por ellas,

$$\hat{w}_i = \frac{1}{N}\sum_{j=1}^{N} \hat{h}_{ij}, \qquad \hat{\boldsymbol{\mu}}_i = \frac{\sum_{j=1}^{N} \hat{h}_{ij}\,\mathbf{x}_j}{\sum_{j=1}^{N} \hat{h}_{ij}}, \qquad \hat{\boldsymbol{\Sigma}}_i = \frac{\sum_{j=1}^{N} \hat{h}_{ij}\,(\mathbf{x}_j - \hat{\boldsymbol{\mu}}_i)(\mathbf{x}_j - \hat{\boldsymbol{\mu}}_i)^{\mathsf{T}}}{\sum_{j=1}^{N} \hat{h}_{ij}}.$$

Se itera hasta que el cambio relativo de los parámetros sea menor que una tolerancia o se alcance un número máximo de iteraciones.

Una vez ajustado el modelo, cada píxel se asigna a la clase que produce la mayor $\Pr(\theta_i \mid \mathbf{x}_j)$.

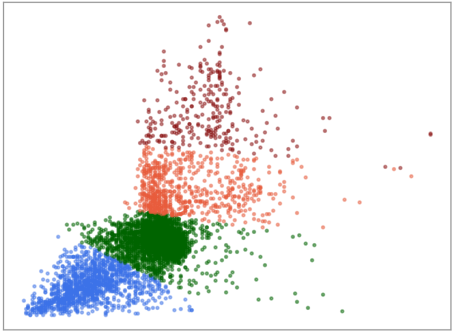
Iteraciones del algoritmo EM



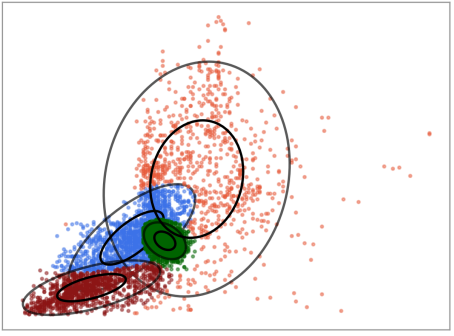
Las elipses corresponden a una y dos desviaciones estándar de cada componente.

Fronteras de decisión

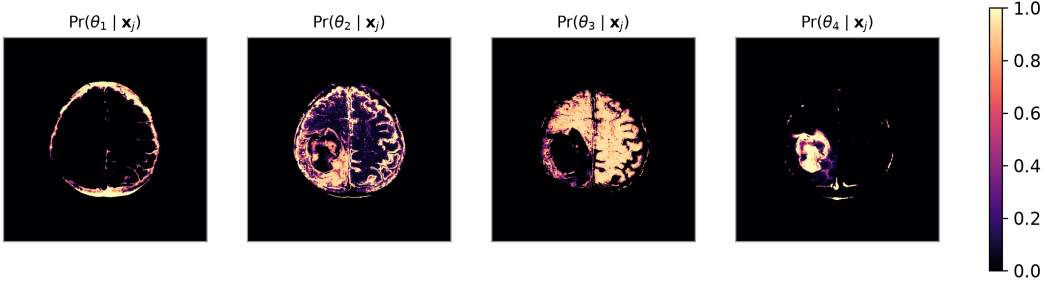
k-means: fronteras lineales equidistantes



Mezcla gaussiana: fronteras según covarianza



Probabilidades posteriores



Campos aleatorios de Markov

Sitios, etiquetas y espacio de soluciones

Una imagen S se representa como una red bidimensional rectangular de $m \times n$ píxeles, cuyos píxeles se reparten en K clases.

- El nivel de gris del píxel $s \in S$ se denota y_s, y el conjunto de píxeles es $\mathbf{y} = \{y_s \mid s \in S\}$.
- A cada píxel se le asigna una etiqueta del conjunto $L = \{1, \dots, K\}$.
- El conjunto de etiquetas de la imagen es $\mathbf{x} = \{x_s \mid x_s \in L,\ s \in S\}$, donde $x_s = \ell$ significa que el píxel s tiene la etiqueta ℓ.
- El espacio de soluciones $\Omega = \{1, \dots, K\}^{m \times n}$ posee $K^{m \times n}$ realizaciones posibles.

Dependencia local

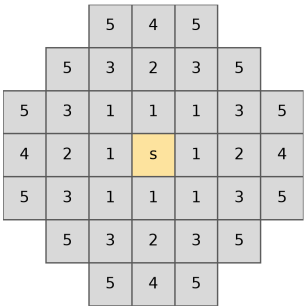
Los métodos suponen que el conjunto de etiquetas es una realización de un campo aleatorio X, y buscan una estimación $\hat{\mathbf{x}} \in \Omega$ del conjunto real desconocido $\mathbf{x}^*$.

La asignación de una etiqueta considera una dependencia estocástica entre las etiquetas de píxeles vecinos. Dicha dependencia se define a partir de un vecindario N_s que debe satisfacer

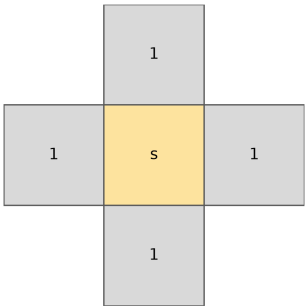
$$s \notin N_s, \qquad r \in N_s \iff s \in N_r.$$

Sistemas de vecindad

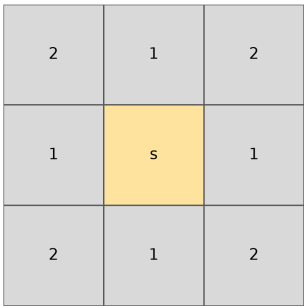
Órdenes 1 a 5



Primer orden (4 vecinos)

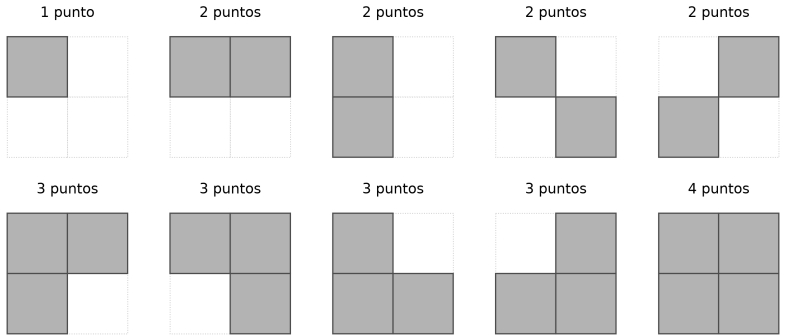


Segundo orden (8 vecinos)



Cliques

Un clique $c \in C$ es un subconjunto de una vecindad predefinida tal que, si dos píxeles s, r pertenecen a c, entonces $r \in N_s$. Con vecindad de segundo orden existen diez cliques distintos.



Definición del campo

Un campo aleatorio X es un campo aleatorio de Markov si

(i) $P(X = \mathbf{x}) > 0 \; \forall \, \mathbf{x} \in \Omega,$ (ii) $P(x_i \mid x_k, k \neq i) = P(x_i \mid x_k, k \in N_i).$

De la condición (ii) se deriva que la etiqueta de un píxel depende únicamente de las etiquetas de sus vecinos.

Por el teorema de Hammersley y Clifford, un campo que cumple (i) es de Markov respecto del sistema de vecindad si y sólo si $P(X)$ es una distribución de Gibbs sobre los cliques de ese sistema.

Distribución de Gibbs

$$P(X = \mathbf{x}) = \frac{1}{Z} \exp\{-\beta\, U(\mathbf{x})\}, \qquad Z = \sum_{\mathbf{x} \in \Omega} \exp\{-\beta\, U(\mathbf{x})\},$$

donde β es una constante positiva y Z un término de normalización. La función de energía de Gibbs se construye sumando un potencial sobre los cliques. Con cliques de dos puntos $c = \{s, r\}$ se obtiene el modelo de Potts,

$$U(\mathbf{x}) = \sum_{c \in C} V_c(\mathbf{x}), \qquad V_{\{s,r\}}(\mathbf{x}) = \begin{cases} -1, & x_s = x_r, \\ +1, & x_s \neq x_r. \end{cases}$$

Estimación máxima a posteriori

El campo de Markov es el modelo a priori de las etiquetas. Las intensidades se modelan dadas las etiquetas, con una gaussiana por clase, $y_s \mid x_s = \ell \sim N(\mu_\ell, \sigma_\ell^2)$, independientes entre píxeles. La estimación máxima a posteriori, $\hat{\mathbf{x}} = \arg\max_{\mathbf{x}} P(\mathbf{y} \mid \mathbf{x})\, P(\mathbf{x})$, equivale a minimizar la energía

$$E(\mathbf{x}) = \sum_{s \in S} \left[\frac{(y_s - \mu_{x_s})^2}{2\sigma_{x_s}^2} + \log \sigma_{x_s} \right] + \beta \sum_{\{s,r\} \in C} \mathbf{1}\{x_s \neq x_r\},$$

donde el primer término mide la fidelidad al dato y el segundo penaliza las parejas de vecinos con etiquetas distintas. El término de normalización Z no depende de $\mathbf{x}$ y desaparece.

Modo condicional iterado

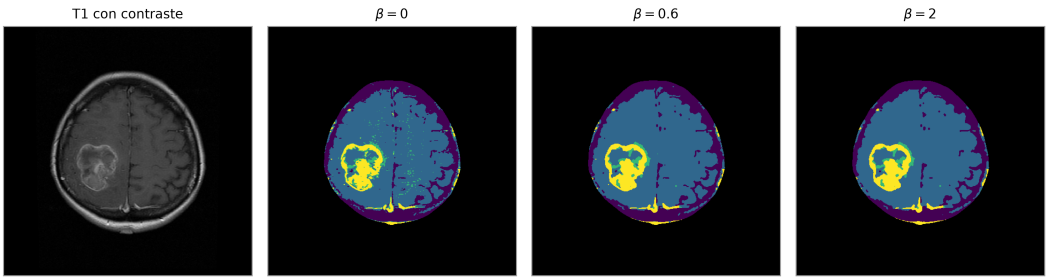
Minimizar $E(\mathbf{x})$ sobre las $K^{m\times n}$ configuraciones es inviable. El modo condicional iterado (ICM) lo hace de forma local: partiendo de la clasificación por máxima verosimilitud ($\beta = 0$), cada píxel toma la etiqueta que minimiza su propia energía con los vecinos fijos,

$$x_s \leftarrow \arg\min_{\ell} \left[\frac{(y_s - \mu_\ell)^2}{2\sigma_\ell^2} + \log \sigma_\ell + \beta\, n_s(\ell) \right],$$

con $n_s(\ell)$ el número de vecinos de s cuya etiqueta difiere de ℓ, y se recorre la imagen hasta que ninguna etiqueta cambie.

Cada actualización reduce E, de modo que el procedimiento converge en pocas pasadas, pero sólo a un mínimo local.

Efecto de la regularización espacial



Estimación por modo condicional iterado sobre la T1 con contraste, con las medias y desviaciones por clase tomadas de k-means y prior de Potts en vecindad de ocho.

Segmentación basada en regiones

Buscar las regiones directamente

Los métodos anteriores trabajan en el espacio de características y recuperan la coherencia espacial solo al final. Los métodos basados en regiones la imponen desde el comienzo.

Se busca una partición cuyas subregiones satisfagan un predicado de homogeneidad $P(R_i)$, definido según el problema. Por ejemplo, $P(R_i)$ es verdadero si todos los píxeles de R_i tienen aproximadamente el mismo nivel de gris, o si su desviación estándar no supera cierto valor.

Crecimiento de regiones

Se parte de un conjunto de puntos generadores g_i, con $i \in \{1, \dots, n\}$, y cada uno constituye una región inicial A_i. A cada región se agregan los vóxeles vecinos que cumplen un criterio de similitud predefinido.

Un vóxel x se incorpora a A_i si es 8-adyacente a algún vóxel ya perteneciente a la región y además

$$|f(x) - f(g_i)| < T,$$

con T el umbral seleccionado por el usuario.

Ejemplo numérico

Generadores g_1 y g_2

128	126	143	128	126	130	126	143	128	126
127	127	142	83	82	77	76	128	129	136
123	125	79	75	67	83	67	75	141	128
125	78	76	67	83	67	69	78	142	139
113	84	78	69	74	78	84	83	126	127
124	75	67	83	67	69	75	75	136	123
132	144	63	68	63	77	78	125	128	125
145	123	145	137	82	78	79	73	139	113
143	125	126	142	143	128	126	130	126	129
132	113	128	131	132	130	126	143	128	126

Paso 1

128	126	143	128	126	130	126	143	128	126
127	127	142	83	82	77	76	128	129	136
123	125	79	75	67	83	67	75	141	128
125	78	76	67	83	67	69	78	142	139
113	84	78	69	74	78	84	83	126	127
124	75	67	83	67	69	75	75	136	123
132	144	63	68	63	77	78	125	128	125
145	123	145	137	82	78	79	73	139	113
143	125	126	142	143	128	126	130	126	129
132	113	128	131	132	130	126	143	128	126

Paso 2

128	126	143	128	126	130	126	143	128	126
127	127	142	83	82	77	76	128	129	136
123	125	79	75	67	83	67	75	141	128
125	78	76	67	83	67	69	78	142	139
113	84	78	69	74	78	84	83	126	127
124	75	67	83	67	69	75	75	136	123
132	144	63	68	63	77	78	125	128	125
145	123	145	137	82	78	79	73	139	113
143	125	126	142	143	128	126	130	126	129
132	113	128	131	132	130	126	143	128	126

Paso 3

128	126	143	128	126	130	126	143	128	126
127	127	142	83	82	77	76	128	129	136
123	125	79	75	67	83	67	75	141	128
125	78	76	67	83	67	69	78	142	139
113	84	78	69	74	78	84	83	126	127
124	75	67	83	67	69	75	75	136	123
132	144	63	68	63	77	78	125	128	125
145	123	145	137	82	78	79	73	139	113
143	125	126	142	143	128	126	130	126	129
132	113	128	131	132	130	126	143	128	126

Región final

128	126	143	128	126	130	126	143	128	126
127	127	142	83	82	77	76	128	129	136
123	125	79	75	67	83	67	75	141	128
125	78	76	67	83	67	69	78	142	139
113	84	78	69	74	78	84	83	126	127
124	75	67	83	67	69	75	75	136	123
132	144	63	68	63	77	78	125	128	125
145	123	145	137	82	78	79	73	139	113
143	125	126	142	143	128	126	130	126	129
132	113	128	131	132	130	126	143	128	126

Dos generadores, vecindad de ocho y umbral $T = 25$. En amarillo los generadores, en verde la región acumulada.

Efecto del umbral

$T = 5$ (15 píxeles)

128	126	143	128	126	130	126	143	128	126
127	127	142	83	82	77	76	128	129	136
123	125	79	75	67	83	67	75	141	128
125	78	76	67	83	67	69	78	142	139
113	84	78	69	74	78	84	83	126	127
124	75	67	83	67	69	75	75	136	123
132	144	63	68	63	77	78	125	128	125
145	123	145	137	82	78	79	73	139	113
143	125	126	142	143	128	126	130	126	129
132	113	128	131	132	130	126	143	128	126

$T = 15$ (39 píxeles)

128	126	143	128	126	130	126	143	128	126
127	127	142	83	82	77	76	128	129	136
123	125	79	75	67	83	67	75	141	128
125	78	76	67	83	67	69	78	142	139
113	84	78	69	74	78	84	83	126	127
124	75	67	83	67	69	75	75	136	123
132	144	63	68	63	77	78	125	128	125
145	123	145	137	82	78	79	73	139	113
143	125	126	142	143	128	126	130	126	129
132	113	128	131	132	130	126	143	128	126

$T = 25$ (40 píxeles)

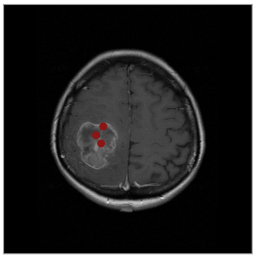
128	126	143	128	126	130	126	143	128	126
127	127	142	83	82	77	76	128	129	136
123	125	79	75	67	83	67	75	141	128
125	78	76	67	83	67	69	78	142	139
113	84	78	69	74	78	84	83	126	127
124	75	67	83	67	69	75	75	136	123
132	144	63	68	63	77	78	125	128	125
145	123	145	137	82	78	79	73	139	113
143	125	126	142	143	128	126	130	126	129
132	113	128	131	132	130	126	143	128	126

$T = 60$ (76 píxeles)

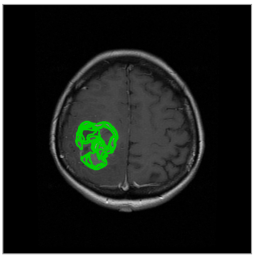
128	126	143	128	126	130	126	143	128	126
127	127	142	83	82	77	76	128	129	136
123	125	79	75	67	83	67	75	141	128
125	78	76	67	83	67	69	78	142	139
113	84	78	69	74	78	84	83	126	127
124	75	67	83	67	69	75	75	136	123
132	144	63	68	63	77	78	125	128	125
145	123	145	137	82	78	79	73	139	113
143	125	126	142	143	128	126	130	126	129
132	113	128	131	132	130	126	143	128	126

Crecimiento sobre la resonancia

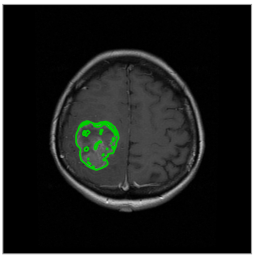
Puntos generadores



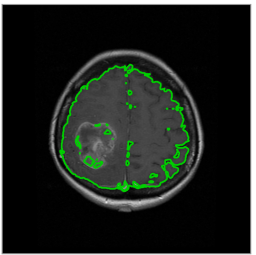
$T = 6$



$T = 12$

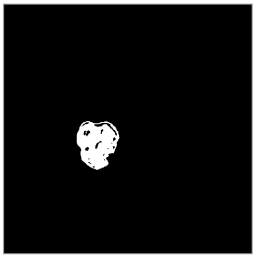


$T = 24$



Postprocesamiento

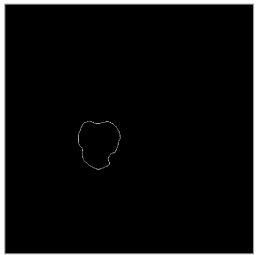
Región obtenida



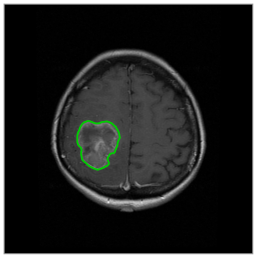
Cierre y relleno



Borde externo



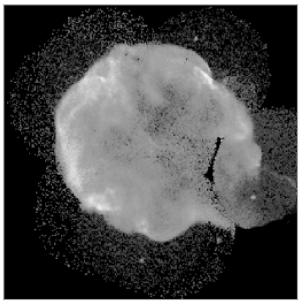
Superposición final



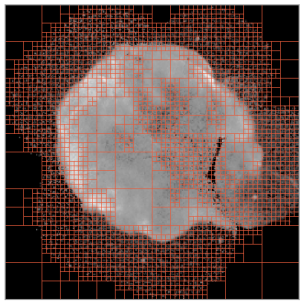
División y fusión

En lugar de crecer desde semillas, se parte de la imagen completa y se subdivide en cuadrantes mientras el predicado de homogeneidad no se cumpla; después se fusionan las regiones adyacentes cuya unión sí lo cumple.

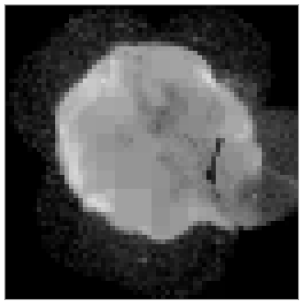
Radiografía del lazo del Cisne



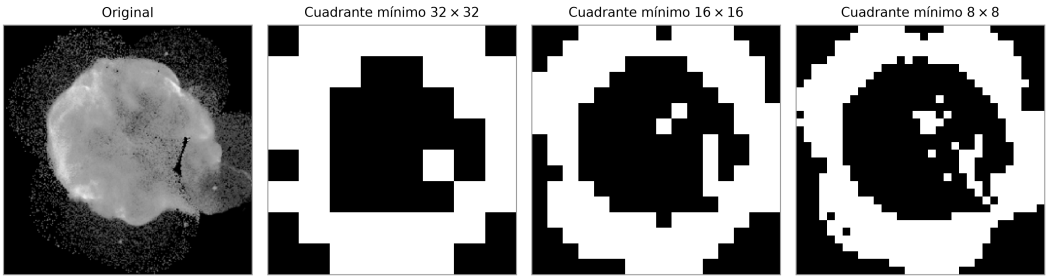
División hasta $\sigma \leq 8$ (2599 hojas)



Cada hoja con su intensidad media



Predicado y tamaño mínimo



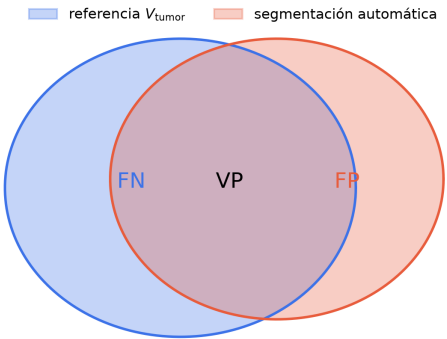
Aquí el predicado describe la región buscada y no su homogeneidad: $Q(R)$ es verdadero si $\sigma_R > 10$ y $0 < m_R < 125$, y un cuadrante se subdivide mientras Q sea falso. Se marcan los cuadrantes que lo satisfacen.

Evaluación de desempeño

Qué se mide

- **Exactitud**, comparando la segmentación con una referencia manual.
- **Reproducibilidad**, entendida como la desviación estándar de los índices de exactitud obtenidos en ensayos diferentes.
- **Tiempo de procesamiento** y **orden de complejidad**.
- **Interacción con el usuario**, es decir cuántas decisiones debe tomar el operador.

Métricas de solapamiento



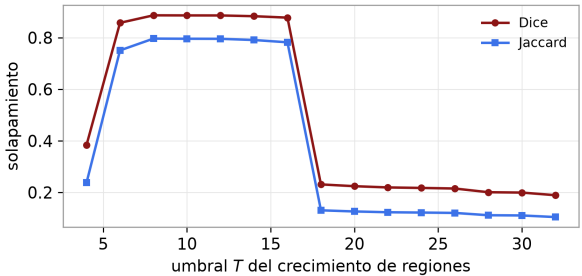
Con S la segmentación y R la referencia,

$$\text{Ex} = \frac{V_{\text{VP}}}{V_R}, \qquad \text{FP} = \frac{V_{\text{FP}}}{V_R}, \qquad \text{FN} = \frac{V_{\text{FN}}}{V_R}.$$

Índices simétricos de uso extendido,

$$\text{Dice} = \frac{2|S \cap R|}{|S| + |R|}, \quad \text{Jaccard} = \frac{|S \cap R|}{|S \cup R|}.$$

Sensibilidad al parámetro



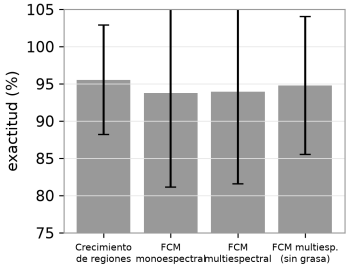
- Existe un intervalo de umbrales donde el solapamiento es alto y estable.
- Fuera de ese intervalo el índice cae de forma abrupta por fuga de la región.
- Reportar un único valor de Dice sin indicar cómo se eligió el parámetro dice poco sobre el método.

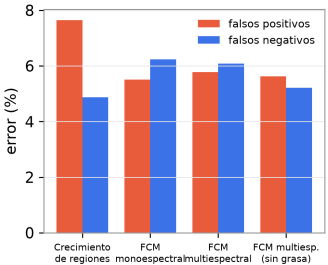
Estándar de referencia

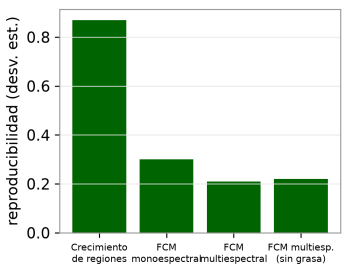
La referencia se obtiene por segmentación manual de un especialista, y se denomina estándar de oro.

- No está libre de error, ya que existe variabilidad entre observadores y del mismo observador en momentos distintos.
- En lesiones infiltrativas como el glioblastoma la frontera real es gradual, de modo que dos expertos pueden diferir de manera apreciable.
- Cuando se dispone de varias referencias conviene combinarlas, en lugar de tomar una sola como verdad.

Estudio comparativo







Resultados sobre la serie de glioblastomas. Exactitud, errores falsos positivos y falsos negativos, y reproducibilidad.

Interacción con el usuario

	Crecimiento de regiones	**Fuzzy c-means**
Inicialización	Parámetros del filtro, región de interés, tamaño y posición de los generadores	Parámetros del filtro, número de clases, exponente de difusividad, criterio de similitud, iteraciones máximas, región de interés
Intervención	Variación del umbral	Elección de la clase tumoral, variación del umbral
Evaluación	Segmentaciones parciales	Segmentaciones parciales