

Procesamiento de imágenes médicas

Redes neuronales feedforward

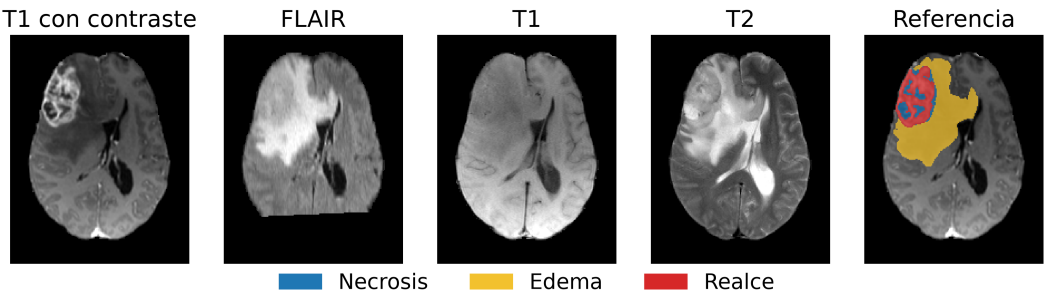
Segmentación y reconocimiento a partir de descriptores

Alejandro Veloz

Objetivos

- Describir píxeles y regiones con vectores de descriptores y normalizarlos.
- Explicar la neurona artificial, la red poco profunda y la red profunda como composiciones de funciones.
- Formular el entrenamiento como la minimización de la entropía cruzada por descenso de gradiente y retropropagación.
- Reconocer el sobreajuste, aplicar regularización y corregir el desbalance de clases.
- Segmentar un glioblastoma clasificando píxeles y reconocer lesiones clasificando regiones candidatas.

Caso de estudio



Base LUMIERE, 74 pacientes con glioblastoma, resonancia preoperatoria. Cuatro secuencias corregistradas a 1 mm y una segmentación de referencia en necrosis, edema y tumor realzante.

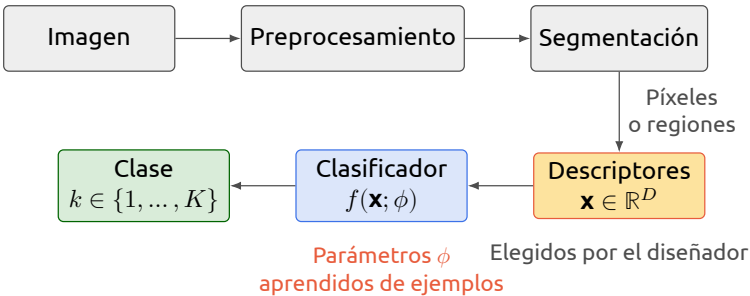
Partición por paciente

- Entrenamiento con 52 pacientes, para ajustar los parámetros.
- Validación con 8 pacientes, para elegir la arquitectura y los descriptores.
- Prueba con 14 pacientes, para el informe final.

Los píxeles de un mismo paciente son muy parecidos entre sí. Si se reparten píxeles en lugar de pacientes, la prueba mide memoria y no generalización.

Descriptores y clasificación

Sistema de reconocimiento



El diseñador elige los descriptores. El clasificador ajusta sus parámetros ϕ con ejemplos etiquetados.

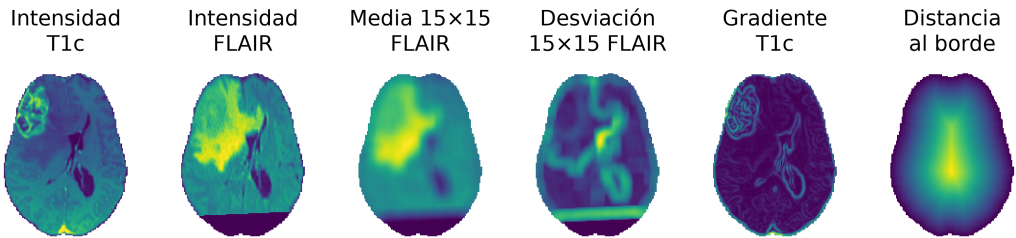
Descriptores de píxel

Cada píxel del cerebro se describe con 33 números.

- Las cuatro intensidades.
- Media y desviación estándar de cada secuencia en ventanas de 7, 15 y 31 píxeles.
- Magnitud del gradiente de cada secuencia.
- Distancia al borde del cerebro.

La media y la desviación en ventanas describen el contexto del píxel. El gradiente describe la presencia de bordes.

Ejemplo de descriptores de píxel



Seis de los 33 descriptores sobre el corte del caso de estudio. Cada mapa es una imagen y cada píxel recibe un vector con un valor de cada mapa.

Descriptores de región

Para una región R con área A y perímetro P:

$$\text{circularidad} = \frac{4\pi A}{P^2}, \qquad \text{solidez} = \frac{A}{A_c}, \qquad \text{extensión} = \frac{A}{A_b}.$$

A_c es el área de la envolvente convexa y A_b el área de la caja que contiene a R. La excentricidad es la de la elipse con los mismos momentos de segundo orden que R.

A estos descriptores de forma se agregan descriptores de intensidad, como la media y la desviación de cada secuencia dentro de R.

Vector de características y normalización

Cada ejemplo n se representa con un vector $\mathbf{x}_n \in \mathbb{R}^D$, con D descriptores.

Los descriptores tienen escalas distintas. Antes de clasificar se normaliza cada componente d:

$$\tilde{x}_{nd} = \frac{x_{nd} - \mu_d}{\sigma_d}.$$

μ_d y σ_d son la media y la desviación estándar del descriptor d en el conjunto de entrenamiento.

Las mismas μ_d y σ_d se aplican a validación y prueba.

Clasificación

Un clasificador asigna a cada $\mathbf{x}$ una clase $k \in \{1, \dots, K\}$. Los clasificadores de esta clase estiman la probabilidad de cada clase y eligen la mayor:

$$\hat{k}(\mathbf{x}) = \arg\max_{k} \; p(k \mid \mathbf{x}).$$

$p(k \mid \mathbf{x})$ es la probabilidad de la clase k dado el vector de descriptores $\mathbf{x}$, y $\hat{k}$ la clase asignada.

La regla divide el espacio de descriptores en regiones de decisión. Sus límites son las fronteras de decisión.

Clasificador lineal

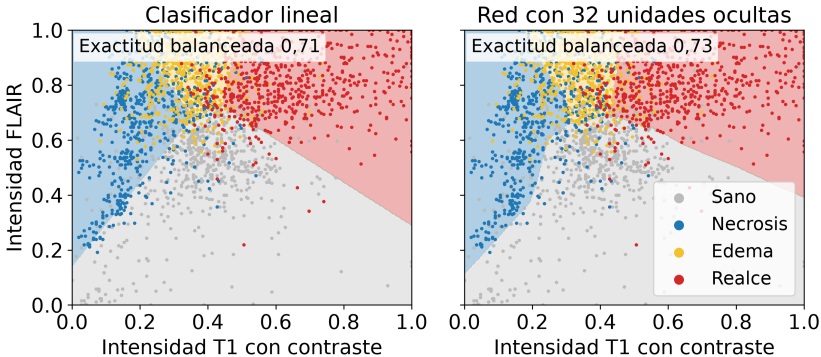
Un clasificador lineal calcula una puntuación por clase,

$$y_k = \beta_k + \boldsymbol{\omega}_k^\top \mathbf{x}, \qquad k = 1, \dots, K,$$

con $\boldsymbol{\omega}_k \in \mathbb{R}^D$ el vector de pesos y β_k el sesgo de la clase k.

- La clase asignada es la de mayor puntuación.
- La frontera entre dos clases cumple $y_k = y_j$, que es un hiperplano.
- Con dos descriptores, las fronteras son rectas.

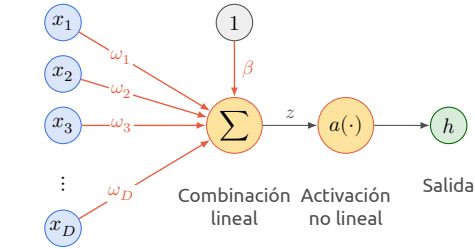
Fronteras de decisión en dos dimensiones



Sólo intensidades de T1 con contraste y FLAIR. Exactitud balanceada en entrenamiento 0,71 con el clasificador lineal y 0,73 con la red.

Redes feedforward

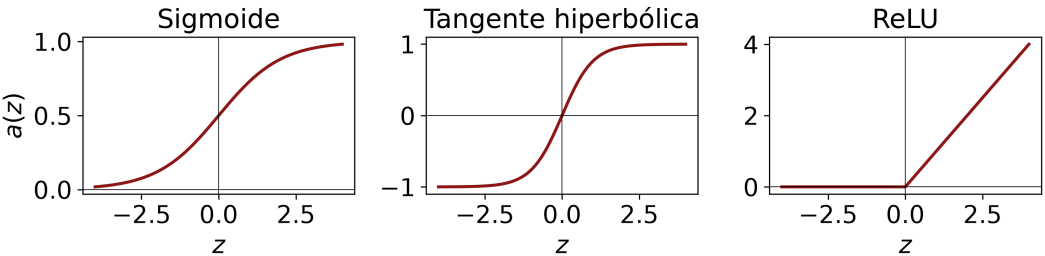
La neurona artificial



$$h = a\left(\beta + \sum_{d=1}^{D} \omega_d \, x_d\right)$$

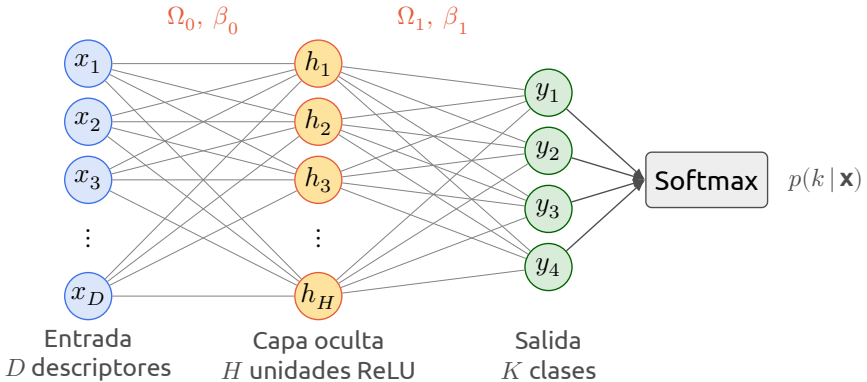
x_d son los descriptores, ω_d los pesos, β el sesgo, $a(\cdot)$ la función de activación y h la salida de la neurona.

Funciones de activación



La activación más usada es la unidad lineal rectificada,
$\text{ReLU}(z) = \max(0, z)$.

Red poco profunda



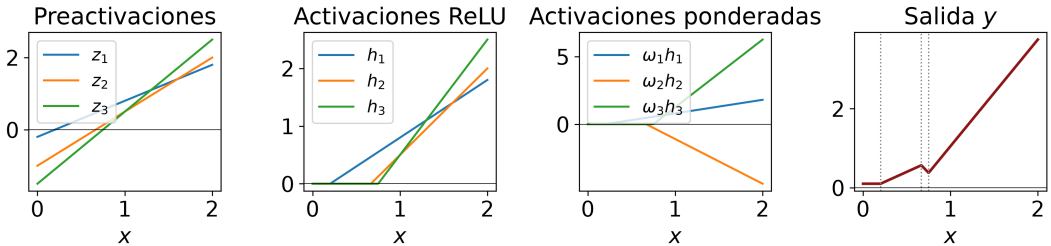
Red poco profunda en forma matricial

$$\mathbf{h} = \text{ReLU}(\boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x}), \qquad \mathbf{y} = \boldsymbol{\beta}_1 + \boldsymbol{\Omega}_1 \mathbf{h}.$$

$\mathbf{x} \in \mathbb{R}^D$ es la entrada, $\mathbf{h} \in \mathbb{R}^H$ las activaciones ocultas y $\mathbf{y} \in \mathbb{R}^K$ las salidas. $\boldsymbol{\Omega}_0$ es una matriz de $H \times D$ y $\boldsymbol{\Omega}_1$ de $K \times H$. $\boldsymbol{\beta}_0 \in \mathbb{R}^H$ y $\boldsymbol{\beta}_1 \in \mathbb{R}^K$ son los sesgos. La ReLU se aplica a cada componente.

Todos los parámetros forman el vector $\boldsymbol{\phi} = \{\boldsymbol{\beta}_0, \boldsymbol{\Omega}_0, \boldsymbol{\beta}_1, \boldsymbol{\Omega}_1\}$.

Funciones lineales por partes



Red con una entrada, tres unidades ReLU y una salida. Cada unidad aporta un quiebre donde su preactivación z_h cruza cero.

Aproximación universal

Una red poco profunda con suficientes unidades ocultas aproxima cualquier función continua sobre un dominio acotado, con el error que se desee.

- El teorema asegura que la red existe, pero no dice cuántas unidades necesita.
- Tampoco dice cómo encontrar sus parámetros.
- Tampoco asegura que la red ajustada generalice a datos nuevos.

Salida softmax

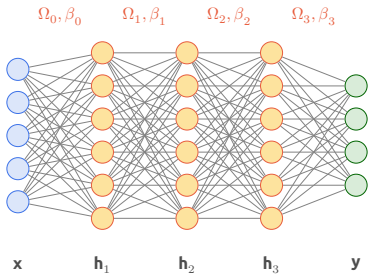
Las salidas y_k son números reales. La función softmax las convierte en probabilidades:

$$p(k \mid \mathbf{x}) = \frac{\exp(y_k)}{\sum_{j=1}^{K} \exp(y_j)}.$$

y_k es la salida de la red para la clase k y K el número de clases.

- Cada $p(k \mid \mathbf{x})$ queda entre 0 y 1, y las K suman 1.
- El orden de las salidas se conserva.

Redes profundas



$$\mathbf{h}_1 = \text{ReLU}(\boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x}), \quad \mathbf{h}_{l+1} = \text{ReLU}(\boldsymbol{\beta}_l + \boldsymbol{\Omega}_l \mathbf{h}_l), \quad \mathbf{y} = \boldsymbol{\beta}_L + \boldsymbol{\Omega}_L \mathbf{h}_L.$$

$\mathbf{h}_l$ son las activaciones de la capa oculta l, con $l = 1, \ldots, L$, y $\boldsymbol{\Omega}_l$, $\boldsymbol{\beta}_l$ sus pesos y sesgos.

Número de parámetros

Una capa que pasa de n a m unidades tiene $m\,n$ pesos y m sesgos.

Red de la clase, con 33 descriptores, dos capas ocultas de 64 y 4 clases:

$$(33 \cdot 64 + 64) + (64 \cdot 64 + 64) + (64 \cdot 4 + 4) = 6596.$$

El conjunto de entrenamiento tiene 40.000 píxeles por clase, muchos más ejemplos que parámetros.

Entrenamiento

Función de pérdida

Se buscan los parámetros que hacen más probables las etiquetas de entrenamiento. Tomando menos el logaritmo de la verosimilitud se obtiene la entropía cruzada:

$$L(\boldsymbol{\phi}) = -\frac{1}{N}\sum_{n=1}^{N} \log p(k_n \,|\, \mathbf{x}_n; \boldsymbol{\phi}).$$

N es el número de ejemplos, $\mathbf{x}_n$ los descriptores del ejemplo n, k_n su clase de referencia y $p(k_n \,|\, \mathbf{x}_n; \boldsymbol{\phi})$ la probabilidad que la red con parámetros $\boldsymbol{\phi}$ asigna a esa clase.

La pérdida es cero si la red asigna probabilidad 1 a cada clase correcta.

Descenso de gradiente

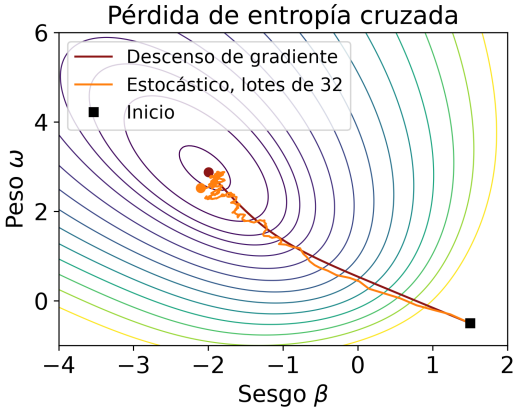
La pérdida se minimiza moviendo los parámetros en contra del gradiente:

$$\boldsymbol{\phi} \leftarrow \boldsymbol{\phi} - \alpha \frac{\partial L}{\partial \boldsymbol{\phi}}.$$

α es la tasa de aprendizaje y $\partial L / \partial \boldsymbol{\phi}$ el vector de derivadas de la pérdida respecto de cada parámetro.

- Una tasa pequeña avanza lento.
- Una tasa grande oscila o diverge.
- La pérdida de una red no es convexa y tiene mínimos locales y puntos silla.

Ejemplo de descenso de gradiente



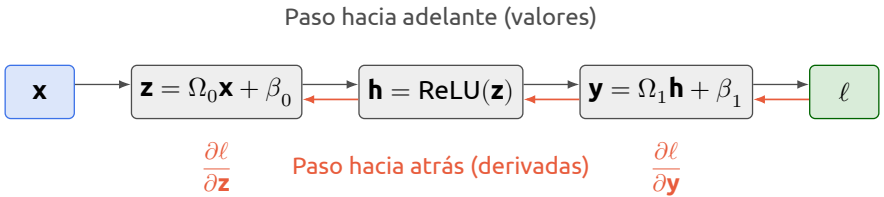
- Modelo $p = \sigma(\beta + \omega x)$, con x la intensidad en T1 con contraste y p la probabilidad de realce.
- El descenso de gradiente sigue la pendiente con todos los datos.
- El estocástico usa 32 píxeles por paso y avanza con ruido.

Descenso de gradiente estocástico

- En cada paso el gradiente se calcula con un minilote de B ejemplos elegidos al azar.
- Una época es una pasada completa por el conjunto de entrenamiento.
- El ruido del minilote ayuda a salir de puntos silla.

El optimizador Adam ajusta una tasa por parámetro con medias móviles del gradiente y de su cuadrado. Es la elección por omisión y la que usa la clase, con $\alpha = 10^{-3}$ y $B = 256$.

Retropropagación



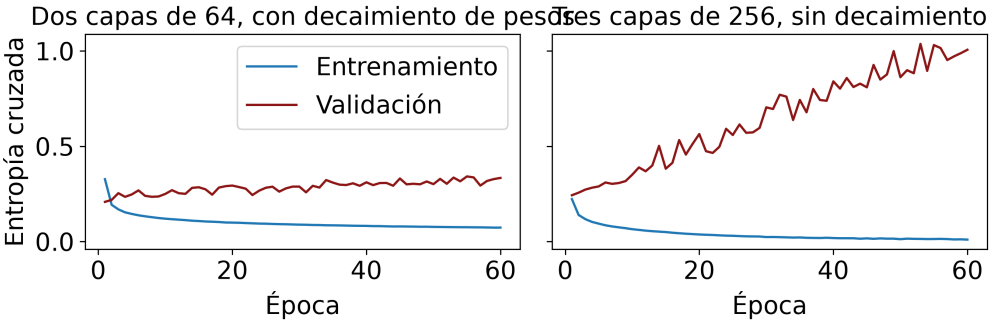
$$\frac{\partial \ell}{\partial \mathbf{\Omega}_1} = \frac{\partial \ell}{\partial \mathbf{y}}\,\mathbf{h}^\top, \quad \frac{\partial \ell}{\partial \mathbf{z}} = \mathbf{1}[\mathbf{z} > 0] \odot \left(\mathbf{\Omega}_1^\top \frac{\partial \ell}{\partial \mathbf{y}}\right), \quad \frac{\partial \ell}{\partial \mathbf{\Omega}_0} = \frac{\partial \ell}{\partial \mathbf{z}}\,\mathbf{x}^\top.$$

ℓ es la pérdida de un ejemplo, $\mathbf{z}$ la preactivación oculta, $\mathbf{1}[\mathbf{z} > 0]$ vale 1 en las componentes positivas y $\odot$ es el producto componente a componente. Con softmax y entropía cruzada, $\partial \ell / \partial y_k = p(k \mid \mathbf{x}) - \mathbf{1}[k = k_n]$.

Detalles prácticos

- **Inicialización.** Pesos aleatorios con varianza $2/n$ en una capa de n entradas.
- **Normalización de la entrada.** Media cero y varianza uno por descriptor.
- **Semilla.** Fijarla permite reproducir cada cifra.
- **Validación.** Elegir arquitectura y descriptores sin mirar la prueba.

Curvas de aprendizaje



La pérdida de entrenamiento baja en cada época. La de validación sube desde 0,21 hasta 0,33 en la red de dos capas, y llega a 1,01 en la red grande sin decaimiento de pesos.

Sobreajuste y regularización

Decaimiento de pesos, que penaliza pesos grandes:

$$L_\lambda(\boldsymbol{\phi}) = L(\boldsymbol{\phi}) + \lambda \sum_j \phi_j^2.$$

λ controla la fuerza de la penalización y ϕ_j recorre todos los pesos. En la clase, $\lambda = 10^{-4}$.

- **Detención temprana.** Guardar los parámetros con menor pérdida de validación.
- **Dropout.** Apagar al azar una fracción de unidades en cada paso de entrenamiento.
- **Más datos.** Más pacientes, o aumento de datos con transformaciones que conservan la etiqueta.

Desbalance de clases

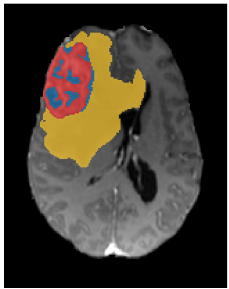
En entrenamiento, el 87,7,% de los píxeles de cerebro es tejido sano, el 7,1,% edema, el 2,6,% necrosis y el 2,6,% realce.

- Se entrena con el mismo número de píxeles por clase.
- La red estima entonces $p_b(k \mid \mathbf{x})$, la probabilidad con clases equiprobables.
- Por el teorema de Bayes, la probabilidad con las proporciones reales π_k cumple

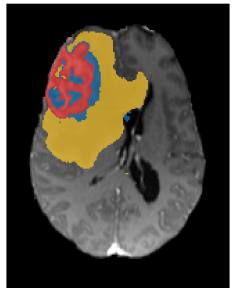
$$p(k \mid \mathbf{x}) \propto p_b(k \mid \mathbf{x})\ \pi_k .$$

Efecto de la corrección

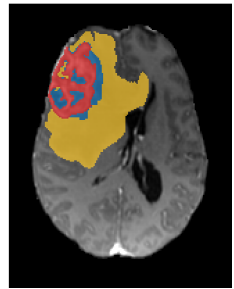
Referencia



Sin corrección



Con corrección



Dice medio en prueba del tumor completo, 0,87 sin corrección y 0,92 con corrección.
Tumor realzante, 0,86 y 0,88.

Segmentación por clasificación de píxeles

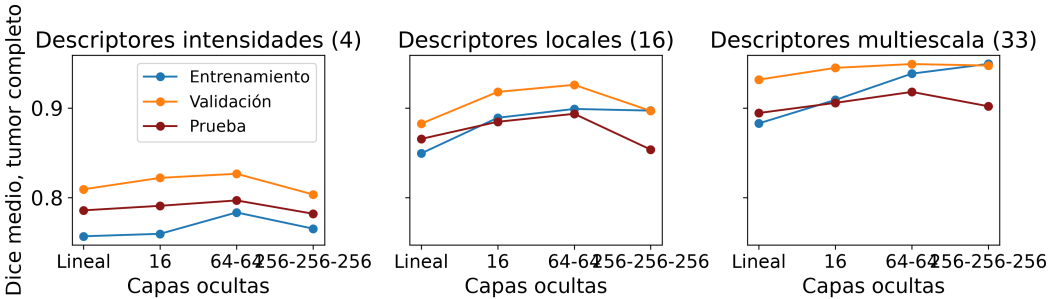
Planteamiento

- Cada píxel del cerebro es un ejemplo con descriptores $\mathbf{x}$ y una de cuatro clases.
- La segmentación es la clase asignada a cada píxel.
- Se evalúan tres regiones, tumor completo (tres clases), núcleo tumoral (necrosis y realce) y tumor realzante.

$$\text{Dice}(S, G) = \frac{2\,|S \cap G|}{|S| + |G|}$$

S es el conjunto de píxeles segmentados, G el de la referencia y $|\cdot|$ el número de píxeles. Se informa el Dice medio por paciente.

Capacidad del modelo y descriptores



Dice medio del tumor completo para cuatro modelos y tres conjuntos de descriptores. La red de tres capas de 256 se entrena sin decaimiento de pesos.

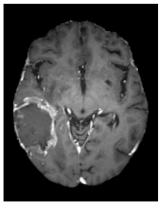
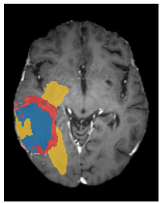
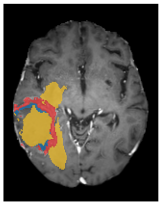
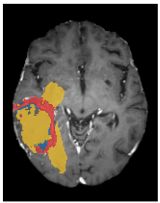
Resultados en validación y prueba

		Validación			Prueba		
Descriptores	Modelo	Completo	Núcleo	Realce	Completo	Núcleo	Realce
Intensidades	Lineal	0,81	0,68	0,78	0,79	0,62	0,76
Intensidades	64-64	0,83	0,72	0,81	0,80	0,62	0,74
Locales	Lineal	0,88	0,80	0,83	0,87	0,75	0,82
Locales	64-64	0,93	0,85	0,87	0,89	0,79	0,83
Multiescala	Lineal	0,93	0,86	0,89	0,89	0,79	0,87
Multiescala	16	0,94	0,90	0,91	0,91	0,83	0,88
Multiescala	64-64	0,95	0,89	0,90	0,92	0,81	0,88
Multiescala	256-256-256	0,95	0,88	0,90	0,90	0,81	0,87

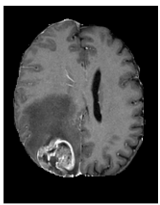
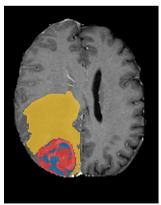
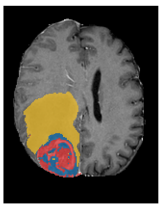
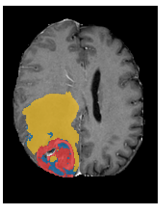
Dice medio por paciente. Con descriptores multiescala, la red 64-64 está entre las mejores en validación y en prueba, con una ventaja pequeña sobre el modelo lineal.

Segmentación de pacientes de prueba

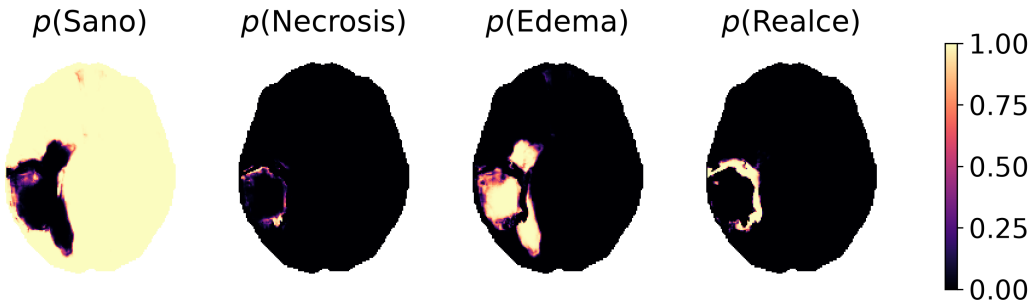
T1 con contraste | Referencia | Lineal | Red 64-64

T1 con contraste | Referencia | Lineal | Red 64-64

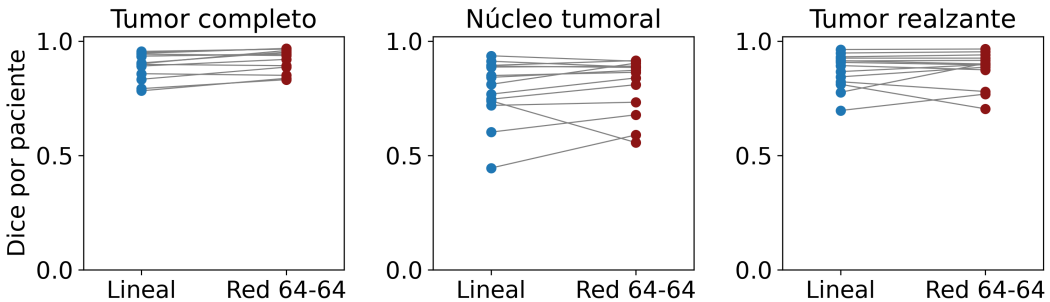





Mapas de probabilidad



Probabilidades corregidas por las proporciones de clase en el primer paciente de prueba.

Dice por paciente



Cada línea une los dos modelos en un paciente de prueba. La red supera al modelo lineal en el tumor completo en 11 de 14 pacientes.

Postprocesamiento

Se conserva la componente conexa mayor del tumor completo y se rellenan sus huecos.

	Completo	Núcleo	Realce
Red 64-64	0,92	0,81	0,88
Red 64-64 con postprocesamiento	0,92	0,81	0,88

El postprocesamiento morfológico introduce lo que el clasificador de píxeles ignora, que la lesión es una sola región.

Límites de los descriptores fijos

- La red sólo ve lo que los descriptores le entregan.
- Los descriptores de contexto suben el Dice más que cualquier cambio de arquitectura.
- Ningún descriptor de la lista describe la forma del anillo ni la posición relativa de los tejidos.

Una red que aprenda los descriptores desde los píxeles resuelve esta limitación. Ese es el papel de las redes convolucionales.

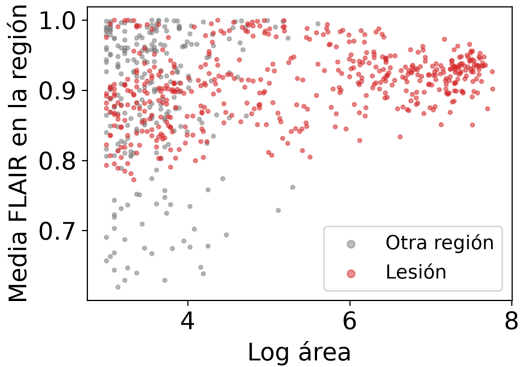
Reconocimiento de regiones candidatas

Detección en dos etapas

1. **Candidatas.** Componentes conexas de píxeles con FLAIR mayor que la media del cerebro más 1,5 desviaciones, de 20 píxeles o más.
2. **Decisión.** Una red clasifica cada candidata como lesión u otra región a partir de 12 descriptores de región.

Una candidata es lesión si al menos la mitad de sus píxeles pertenece al tumor completo de la referencia. Hay 759 candidatas de entrenamiento, 506 de ellas lesión.

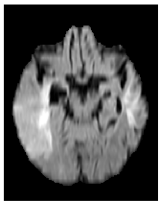
Descriptores de las candidatas



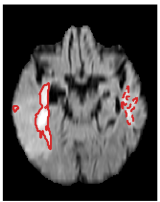
Candidatas de entrenamiento en el plano de dos de sus doce descriptores.

Resultado del reconocimiento

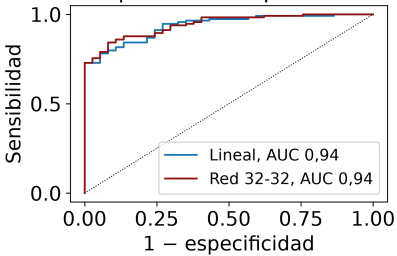
FLAIR



Decisión de la red sobre las candidatas



Curva ROC en pacientes de prueba



151 candidatas de prueba. Área bajo la curva ROC 0,94 con el modelo lineal y 0,94 con la red de dos capas de 32. Con umbral 0,5 la red tiene sensibilidad 96,% y especificidad 59,%. En el corte, rojo es lesión y cian otra región según la red; la línea discontinua marca un error.

Cuaderno de la clase

Todas las figuras y cifras de esta clase salen del cuaderno

`notebooks/09-redes-feedforward.ipynb`

El cuaderno calcula los descriptores, entrena cada red con PyTorch, evalúa por paciente y escribe las cifras que cita la clase. Corre en CPU en unos cuatro minutos.

Requisitos: `numpy`, `scipy`, `scikit-image`, `scikit-learn`, `matplotlib` y `torch`.

Siglas

Adam	Estimación adaptativa de momentos (*adaptive moment estimation*)
AUC	Área bajo la curva (*area under the curve*)
FLAIR	Recuperación de inversión con atenuación de fluido
MLP	Perceptrón multicapa (*multilayer perceptron*)
MNI	Instituto Neurológico de Montreal, espacio del atlas
ReLU	Unidad lineal rectificada (*rectified linear unit*)
ROC	Característica operativa del receptor

Referencias

- Prince, S. J. D. *Understanding Deep Learning.* MIT Press, 2023. Capítulos 3 a 9.
- Gonzalez, R. C. y Woods, R. E. *Digital Image Processing*, 4.ª ed. Pearson, 2018. Capítulos 11 y 12.
- Goodfellow, I., Bengio, Y. y Courville, A. *Deep Learning.* MIT Press, 2016. Capítulos 6 a 8.
- Cybenko, G. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems* 2, 303–314, 1989.
- He, K., Zhang, X., Ren, S. y Sun, J. Delving deep into rectifiers. *ICCV*, 2015.
- Kingma, D. P. y Ba, J. Adam: a method for stochastic optimization. *ICLR*, 2015.
- Saerens, M., Latinne, P. y Decaestecker, C. Adjusting the outputs of a classifier to new a priori probabilities. *Neural Computation* 14, 21–41, 2002.
- Suter, Y. et al. The LUMIERE dataset: longitudinal glioblastoma MRI with expert RANO evaluation. *Scientific Data* 9, 768, 2022.