

Procesamiento de imágenes médicas

# Crecimiento de regiones con un criterio aprendido

## Un ejemplo de segmentación con redes feedforward

Alejandro Veloz

# Objetivos

- Formular el crecimiento de regiones como una secuencia de decisiones sobre los píxeles de la frontera.
- Diseñar descriptores que dependan del píxel candidato y de la región ya construida.
- Generar datos de entrenamiento con un oráculo y corregir el desajuste de estados con DAgger.
- Comparar el criterio aprendido con el criterio clásico en pacientes nuevos.

# Crecimiento de regiones clásico

Se parte de una semilla $s$ y se agregan en cada paso los píxeles 8-adyacentes a la región que cumplen

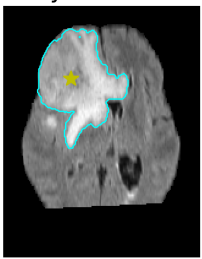
$$\big|f(x) - f(s)\big| < T.$$

$f$ es la intensidad FLAIR, $x$ el píxel candidato y $T$ el umbral.

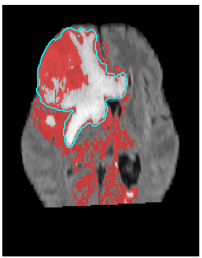
- El umbral se elige a mano o con datos.
- El criterio mira una sola secuencia.
- El criterio no usa lo que ya se sabe de la región.

# Fuga del criterio clásico

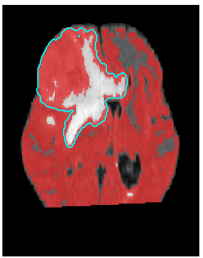
FLAIR, referencia y semilla



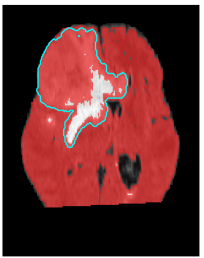
$T = 0{,}100$
Dice 0,43



$T = 0{,}175$
Dice 0,33



$T = 0{,}250$
Dice 0,36



Corte de prueba. Contorno cian, referencia. Estrella, semilla. En rojo, la región con tres umbrales alrededor del elegido en entrenamiento.

# Criterio aprendido

Se reemplaza la comparación con $T$ por una probabilidad estimada por una red:

$$p(x \in G \mid \boldsymbol{\psi}(x, R_t)) = g_{\boldsymbol{\theta}}(\boldsymbol{\psi}(x, R_t)).$$

$G$ es el objeto que se quiere segmentar, $R_t$ la región en el paso $t$, $\boldsymbol{\psi}(x, R_t)$ los descriptores del candidato $x$ dada la región y $g_{\boldsymbol{\theta}}$ una red feedforward con parámetros $\boldsymbol{\theta}$.

- Los descriptores usan las cuatro secuencias.
- Los descriptores comparan el candidato con la región actual.
- Los parámetros se ajustan con segmentaciones de referencia.

# Formulación del problema

- El objetivo $G$ es la componente conexa mayor del tumor completo.
- La semilla $s$ es el píxel de $G$ más alejado de su borde.
- La frontera $\mathcal{F}_t$ son los píxeles del cerebro 8-adyacentes a $R_t$ que no están en $R_t$.

$$R_0 = \{s\}, \qquad R_{t+1} = R_t \cup \{x \in \mathcal{F}_t : g_{\boldsymbol{\theta}}(\boldsymbol{\psi}(x, R_t)) > 0{,}5\}.$$

El proceso termina en el primer paso en que ningún candidato de $\mathcal{F}_t$ supera 0,5.

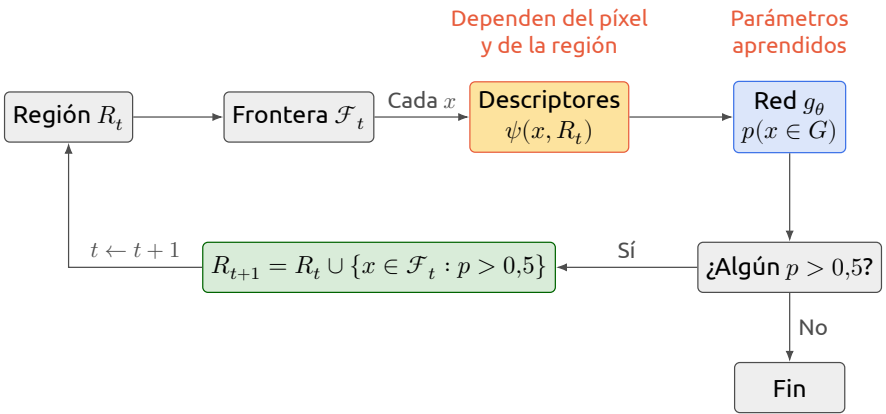
# Descriptores del candidato

$\boldsymbol{\psi}(x, R_t)$ tiene 17 componentes:

- Intensidad $f_c(x)$ de cada secuencia $c$.
- Diferencia normalizada con la región, $(f_c(x) - \mu_c)/\sigma_c$.
- La misma diferencia con la media de $3 \times 3$ alrededor de $x$.
- Magnitud del gradiente de cada secuencia en $x$.
- Fracción de los ocho vecinos de $x$ que ya están en $R_t$.

$\mu_c$ y $\sigma_c$ son la media y la desviación estándar de la secuencia $c$ dentro de $R_t$.

# Ciclo de crecimiento



# Problema de aprendizaje

Cada candidato visitado da un par $(\boldsymbol{\psi}_n, y_n)$, con $y_n = 1$ si el píxel pertenece al tumor completo y $y_n = 0$ si no. Se minimiza la entropía cruzada binaria:

$$L(\boldsymbol{\theta}) = -\frac{1}{N}\sum_{n=1}^{N}\Big[y_n \log p_n + (1-y_n)\log(1-p_n)\Big].$$

$p_n = g_{\boldsymbol{\theta}}(\boldsymbol{\psi}_n)$ es la probabilidad que da la red y $N$ el número de pares.

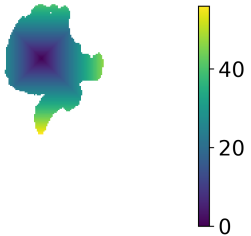
La red tiene dos capas ocultas de 32 unidades ReLU y una salida sigmoide.

# Estados generados por un oráculo

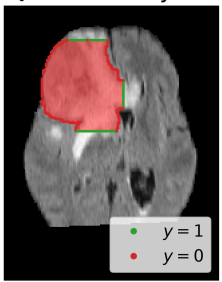
Objetivo *G* y semilla



Distancia geodésica $\delta$




Región $R_t$ con $t = 33$ y su frontera



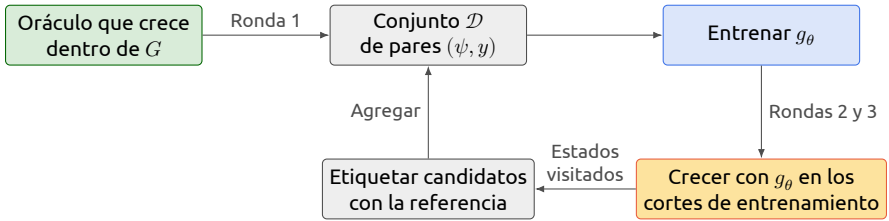

$\delta(x)$ es el número de pasos de vecindad 8 desde $s$ hasta $x$ sin salir de $G$. El oráculo usa $R_t = \{x \in G : \delta(x) \leq t\}$ con $t = 0, 2, 4, \ldots$ En verde, candidatos con $y = 1$. En rojo, con $y = 0$.

# Desajuste de estados

- La red se entrena con regiones perfectas, contenidas en $G$.
- Al crecer sola, la red comete errores y visita regiones con píxeles ajenos.
- Un píxel ajeno cambia $\mu_c$ y $\sigma_c$, y la red llega a estados que no vio.
- Los errores se acumulan paso a paso.

La distribución de estados en prueba difiere de la de entrenamiento.

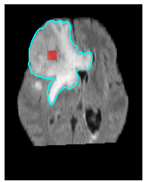
# DAgger



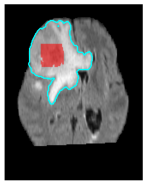

En cada ronda la red crece sobre los cortes de entrenamiento, los candidatos que visita se etiquetan con la referencia y se agregan al conjunto. Se hacen dos rondas además de la del oráculo.

# Evolución del crecimiento

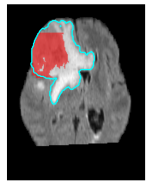
Clásico, paso 4



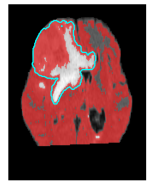
Clásico, paso 12



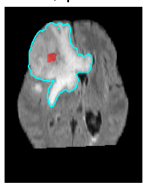
Clásico, paso 25



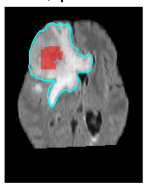
Clásico, final, 191 pasos
Dice 0,33



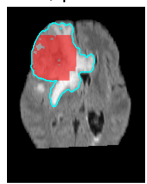
Red, paso 4



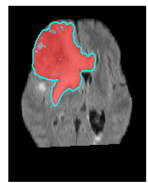
Red, paso 12



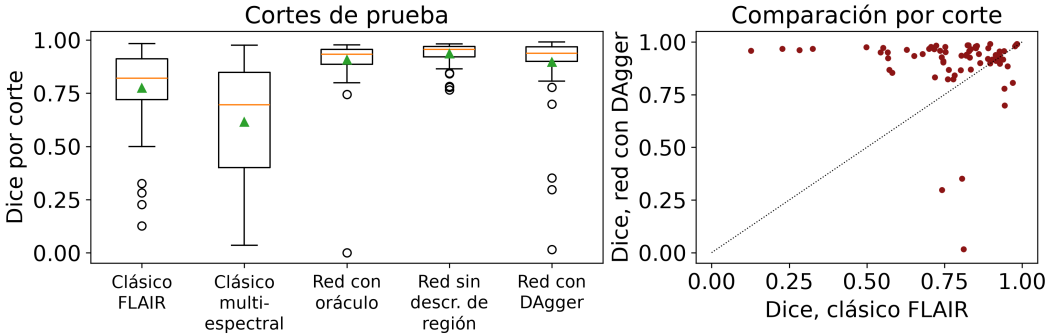
Red, paso 25



Red, final, 58 pasos
Dice 0,97



# Resultados en pacientes de prueba




Dice por corte en 70 cortes de 14 pacientes de prueba. La red con DAgger supera al clásico FLAIR en 57 cortes.

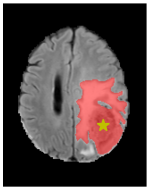
# Tabla de resultados

| Método | Media | Mediana | Dice $< 0{,}5$ |
|---|---|---|---|
| Clásico FLAIR | 0,78 | 0,82 | 5 |
| Clásico multiespectral | 0,62 | 0,70 | 28 |
| Red con oráculo | 0,91 | 0,93 | 1 |
| Red sin descriptores de región | 0,94 | 0,96 | 0 |
| Red con DAgger | 0,90 | 0,94 | 3 |

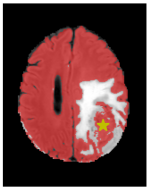
Dice por corte de prueba. La última columna cuenta los cortes con Dice menor que 0,5. La red sin descriptores de región se entrena igual, con oráculo y DAgger, sin los ocho descriptores relativos a $R_t$.

# Casos de prueba

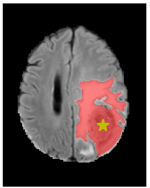
Referencia



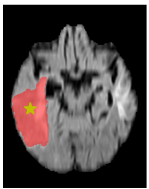
Clásico FLAIR
Dice 0,13



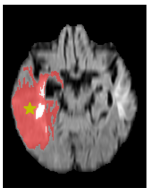
Red con DAgger
Dice 0,96



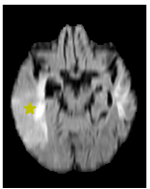
Referencia



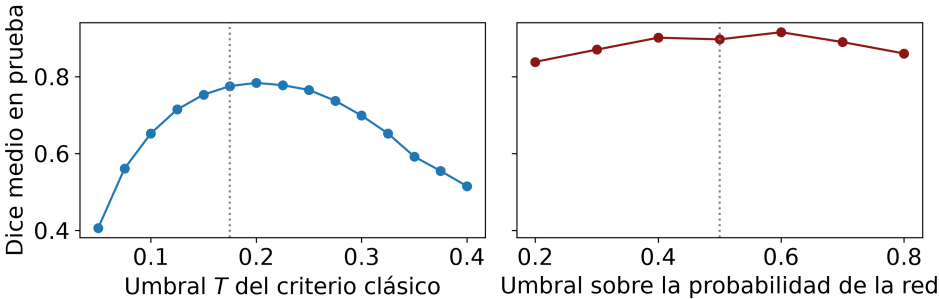
Clásico FLAIR
Dice 0,81



Red con DAgger
Dice 0,02



# Umbral de decisión




Dice medio en prueba frente al umbral. Con la red, el Dice va de 0,84 con umbral 0,2 a 0,86 con umbral 0,8.

# Sensibilidad a la semilla

Cinco semillas al azar en la mitad interior de $G$, en cada corte de prueba.

- Desviación estándar mediana del Dice entre semillas, criterio clásico, 0,080.
- Desviación estándar mediana del Dice entre semillas, red con DAgger, 0,003.

El criterio clásico compara con $f(s)$, de modo que la semilla fija la intensidad de referencia. La red compara con la región, que pronto deja de depender de la semilla.

# Alcances del ejemplo

- El ejemplo es bidimensional. En volúmenes la frontera tiene vecindad 26 y el mismo esquema funciona.
- La referencia es automática, de modo que se mide acuerdo con otro método.
- Los descriptores son fijos. Una red convolucional sobre un parche alrededor del candidato los aprendería.
- La semilla sigue siendo una decisión del usuario.

# Cuaderno de la clase

Todas las figuras y cifras de esta clase salen del cuaderno

`notebooks/09b-crecimiento-aprendido.ipynb`

El cuaderno implementa el crecimiento clásico, los descriptores, el oráculo, el entrenamiento con PyTorch, DAgger y la evaluación por corte.

Requisitos: `numpy`, `scipy`, `matplotlib` y `torch`.

# Siglas

| | |
|---|---|
| DAgger | Agregación de conjuntos de datos (*dataset aggregation*) |
| FLAIR | Recuperación de inversión con atenuación de fluido |
| ReLU | Unidad lineal rectificada (*rectified linear unit*) |

# Referencias


- Adams, R. y Bischof, L. Seeded region growing. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 16, 641–647, 1994.
- Gonzalez, R. C. y Woods, R. E. *Digital Image Processing*, 4.ª ed. Pearson, 2018. Capítulo 10.
- Prince, S. J. D. *Understanding Deep Learning.* MIT Press, 2023. Capítulos 3 a 9.
- Ross, S., Gordon, G. y Bagnell, D. A reduction of imitation learning and structured prediction to no-regret online learning. *AISTATS*, 2011.
- Suter, Y. et al. The LUMIERE dataset: longitudinal glioblastoma MRI with expert RANO evaluation. *Scientific Data* 9, 768, 2022.