

Procesamiento de imágenes médicas

Redes convolucionales

Clasificación de imágenes

Alejandro Veloz

Objetivos

- Explicar por qué una red densa es inadecuada para recibir una imagen completa.
- Describir una capa convolucional con sus canales, relleno, paso y campo receptivo.
- Calcular la forma de los mapas de características y el número de parámetros de una red convolucional.
- Distinguir equivariancia e invariancia a la traslación.
- Entrenar una red convolucional para clasificar parches de resonancia y comparar con redes densas.
- Usar un clasificador de parches para segmentar por ventana deslizante.

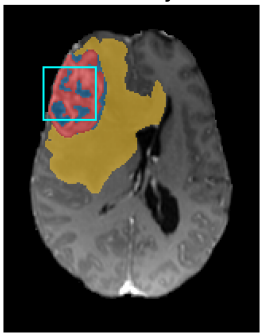
Un clasificador de imágenes recibe una imagen y entrega una clase. Hay dos maneras de construirlo.

- Calcular descriptores diseñados a mano (intensidades, medias locales, gradientes, forma) y entrenar un clasificador sobre ellos.
- Entregar la imagen completa a una red que aprende sus propios descriptores.

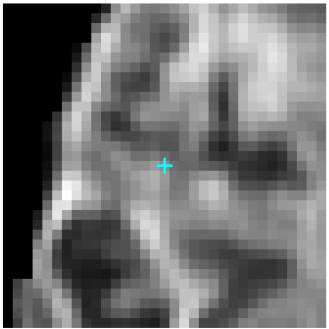
Las redes convolucionales siguen la segunda vía. Sus descriptores son filtros aprendidos a partir de ejemplos, organizados en capas.

Caso de estudio

T1 con contraste y referencia



Parche de 33 × 33, clase Realce



Base LUMIERE, 74 pacientes con glioblastoma, cuatro secuencias (T1 con contraste o T1c, FLAIR, T1 y T2). Cada parche de 33×33 píxeles con cuatro canales recibe la clase de su píxel central.

Partición y muestras

- Los pacientes se reparten en entrenamiento (52), validación (8) y prueba (14). Ningún paciente aporta parches a dos conjuntos.
- Se muestrean 6000 parches por clase en entrenamiento, 1000 en validación y 2000 en prueba.
- Con las cuatro clases igual de representadas, la exactitud sobre la muestra es la exactitud balanceada.
- En el cerebro completo el 87,75 % de los píxeles es sano.

Redes densas e imágenes

Una imagen como vector

Una red densa recibe un vector. Para entregarle un parche hay que aplanarlo:

$$4 \times 33 \times 33 = 4356 \text{ valores de entrada.}$$

- Con capas ocultas de 128 y 64 unidades, la red tiene 566.212 parámetros.
- La primera capa aporta casi todos, un peso por cada par entrada y unidad oculta.
- Una imagen de 512×512 con una capa de 1000 unidades necesitaría más de 262 millones de pesos.

Estructura de las imágenes

Al aplanar, la red densa trata cada píxel como una variable sin posición.

- Los píxeles vecinos están correlacionados y forman bordes, texturas y regiones.
- Un mismo detalle, como el borde del anillo de realce, aparece en distintas posiciones.
- Una red densa debe aprender ese detalle por separado en cada posición.

Una capa convolucional incorpora dos restricciones, conexiones locales y pesos compartidos entre posiciones.

La convolución como capa

Convolución discreta en dos dimensiones

Un kernel w de $(2a+1) \times (2a+1)$ coeficientes recorre la imagen f:

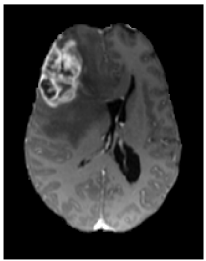
$$g(x,y) = \sum_{s=-a}^{a} \sum_{t=-a}^{a} w(s,t)\, f(x+s,\, y+t) + b.$$

g es el mapa de salida, (x, y) la posición, (s, t) el desplazamiento dentro del kernel y b un sesgo.

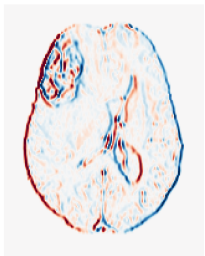
- Es el filtrado espacial lineal de siempre. En rigor es una correlación, porque el kernel no se gira.
- En una red, los coeficientes $w(s, t)$ y el sesgo b se aprenden.

Filtros diseñados

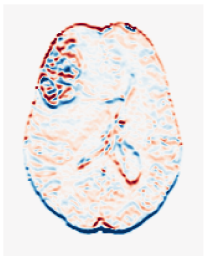
T1 con contraste



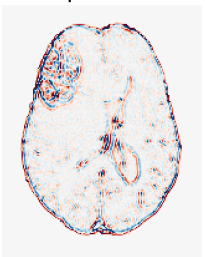
Sobel horizontal



Sobel vertical

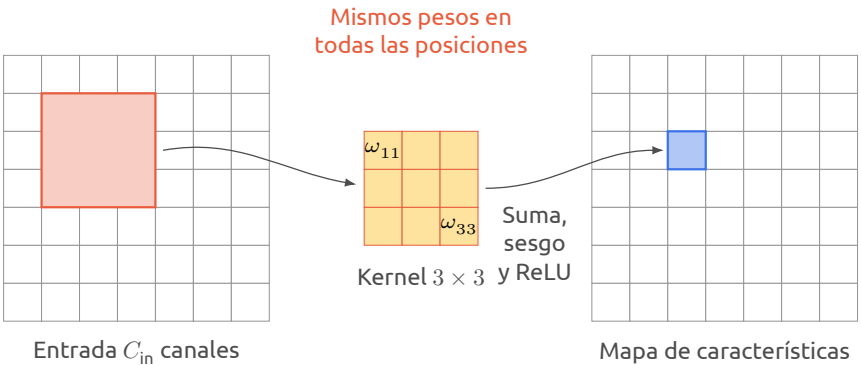


Laplaciano



Una capa convolucional con los kernels de Sobel y el laplaciano reproduce el filtrado espacial. La diferencia máxima con `scipy.ndimage.correlate` es menor que 10^{-6}.

Capa convolucional



Canales de entrada y de salida

Una capa con C_{in} canales de entrada y C_{out} kernels de $k \times k$ produce C_{out} mapas:

$$g_j(x, y) = b_j + \sum_{c=1}^{C_{\text{in}}} \sum_{s,t} w_{j,c}(s, t)\, f_c(x + s,\, y + t).$$

f_c es el canal c de la entrada, $w_{j,c}$ la rebanada c del kernel j y b_j su sesgo, con $j = 1, \ldots, C_{\text{out}}$.

- Parámetros de la capa: $C_{\text{out}}\,(C_{\text{in}}\,k^2 + 1)$.
- Primera capa del caso, $16\,(4 \cdot 9 + 1) = 592$ parámetros.

Relleno y paso

Para una entrada de $N \times N$, un kernel de $k \times k$, relleno P y paso S, la salida mide

$$N' = \left\lfloor \frac{N + 2P - k}{S} \right\rfloor + 1.$$

P es el número de filas y columnas de ceros que se agregan en cada borde. S es el salto entre posiciones consecutivas del kernel.

- Con $k = 3$, $P = 1$ y $S = 1$ la salida conserva el tamaño, $N' = N$.
- Con $S = 2$ la salida tiene la mitad de filas y de columnas.

Pooling

El pooling resume cada ventana de un mapa en un solo valor.

- Max pooling de 2×2 con paso 2 conserva el máximo de cada ventana y reduce cada dimensión a la mitad.
- Pooling promedio usa la media de la ventana.
- Pooling promedio global reduce cada mapa completo a un número.

El pooling no tiene parámetros. Reduce el cómputo de las capas siguientes y hace que pequeños desplazamientos cambien poco la salida.

Campo receptivo

El campo receptivo de una unidad es la región de la entrada que influye en su valor.

- Una convolución de 3×3 sobre la entrada ve 3×3 píxeles.
- Dos convoluciones de 3×3 seguidas ven 5×5.
- Cada pooling de paso 2 duplica el crecimiento de las capas siguientes.

En la red del caso, la última convolución tiene un campo receptivo de 38×38 píxeles, mayor que el parche de 33.

Equivariancia e invariancia

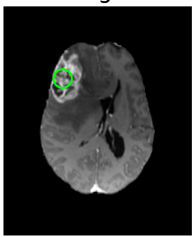
Sea T una traslación de la imagen f y F una operación de la red.

- F es **equivariante** si $F(Tf) = TF(f)$. Al desplazar la entrada, la salida se desplaza igual.
- F es **invariante** si $F(Tf) = F(f)$. Al desplazar la entrada, la salida no cambia.

La convolución es equivariante a la traslación. El pooling y el promedio global acercan la salida a la invariancia.

Ejemplo de equivariancia

Imagen



Mapa de la imagen

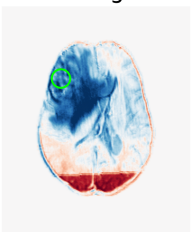
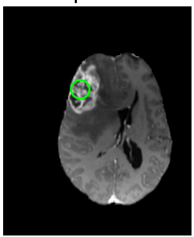
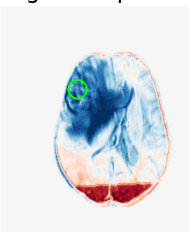


Imagen desplazada



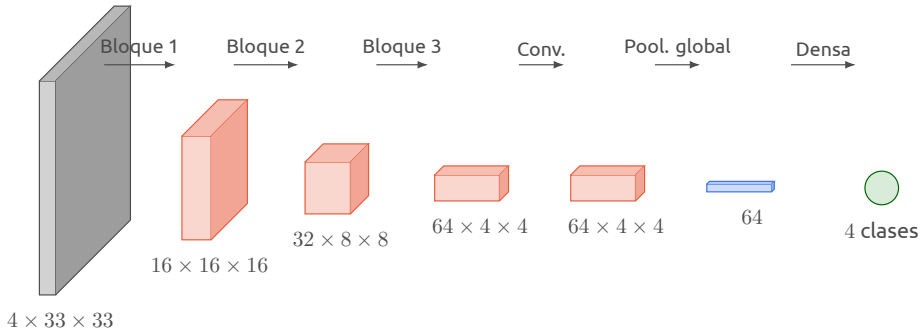
Mapa de la imagen desplazada



Un kernel aleatorio de 5×5 con cuatro canales. La imagen se desplaza 12 filas y 20 columnas. Al deshacer el desplazamiento del segundo mapa, la diferencia máxima con el primero es menor que 10^{-6}.

Una red para clasificar parches

Arquitectura de la red



Cada bloque: convolución 3×3, normalización por lotes, ReLU y max pooling 2×2.
Pooling global: promedio de cada mapa. Salida: softmax sobre 4 clases.

Normalización por lotes

Para cada canal, dentro de un lote de ejemplos,

$$\hat{z} = \frac{z - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \qquad z' = \gamma\,\hat{z} + \delta.$$

z es la salida de la convolución, μ_B y σ_B^2 su media y su varianza en el lote, ϵ una constante pequeña, y γ y δ parámetros aprendidos.

- Mantiene las activaciones en una escala estable durante el entrenamiento.
- En la evaluación usa medias y varianzas acumuladas, no las del lote.

Número de parámetros

Modelo	Entrada	Parámetros
Red densa sobre píxeles	4356	566.212
Red densa sobre descriptores	33	12.868
Red convolucional	$4 \times 33 \times 33$	61.140

- Las dos redes densas tienen capas ocultas de 128 y 64 unidades.
- La red convolucional recibe el mismo parche que la densa sobre píxeles con nueve veces menos parámetros.

Salida y función de pérdida

La capa final entrega puntuaciones $y_1, \ldots, y_K$ que la función softmax convierte en probabilidades:

$$p(k \mid \mathbf{x}) = \frac{e^{y_k}}{\sum_{j=1}^{K} e^{y_j}}, \qquad L = -\frac{1}{I} \sum_{i=1}^{I} \log p(k_i \mid \mathbf{x}_i).$$

$\mathbf{x}$ es el parche, $K = 4$ el número de clases, I el número de parches de entrenamiento y k_i la clase del parche $\mathbf{x}_i$. L es la entropía cruzada.

Entrenamiento

- Optimizador Adam con tasa de aprendizaje 10^{-3} y decaimiento de pesos 10^{-4}.
- Lotes de 128 parches y 15 épocas.
- La exactitud de validación se mide después de cada época.
- Las cuatro redes del caso se entrenan con los mismos parches y la misma semilla.

Aumento de datos

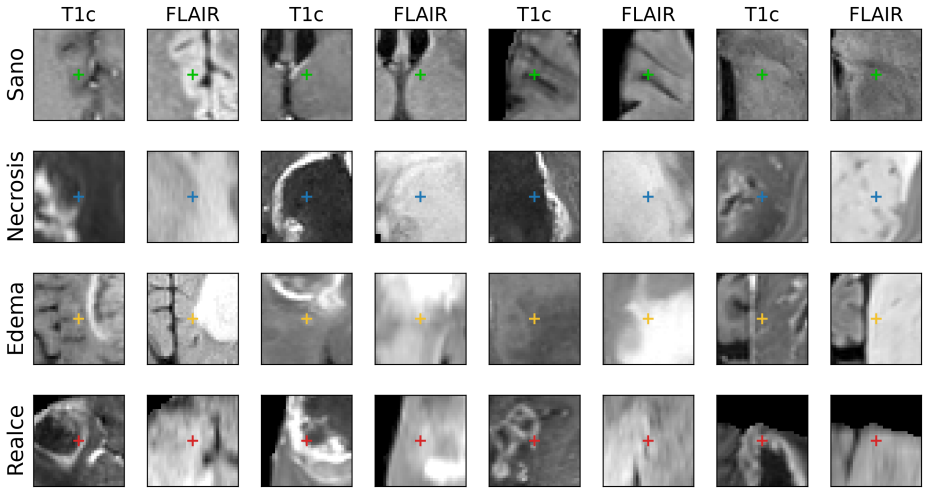
Cada parche se transforma al azar en cada lote, sin cambiar su clase.

- Volteo horizontal con probabilidad 0,5.
- Rotación de 0, 90, 180 o 270 grados.
- Las ocho combinaciones forman el grupo de simetrías del cuadrado.

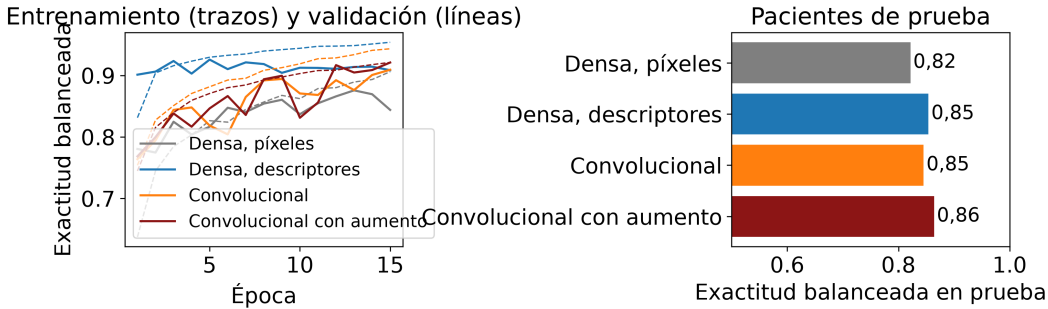
La red ve cada parche en varias orientaciones y aprende que la orientación no determina la clase.

Resultados sobre parches

Ejemplos de parches



Comparación de los cuatro modelos



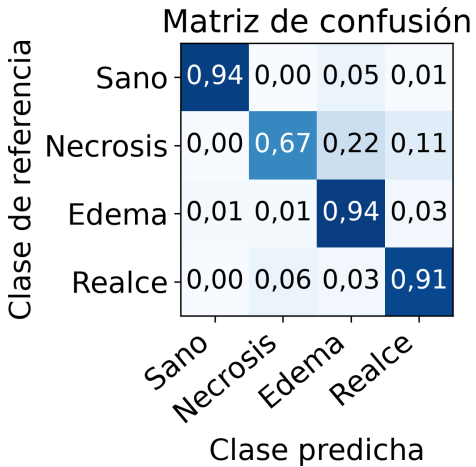
Exactitud balanceada en prueba. Densa sobre píxeles 0,82, densa sobre descriptores 0,85, convolucional 0,85, convolucional con aumento 0,86.

Exactitud por clase

Modelo	Sano	Necrosis	Edema	Realce
Densa, píxeles	0,96	0,63	0,75	0,94
Densa, descriptores	0,96	0,64	0,87	0,94
Convolucional	0,96	0,66	0,92	0,85
Convolucional con aumento	0,94	0,67	0,94	0,91

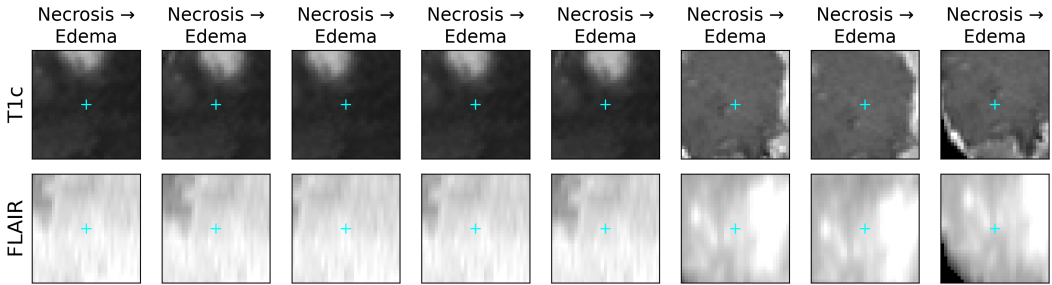
Fracción de parches de prueba de cada clase que el modelo clasifica correctamente.

Matriz de confusión



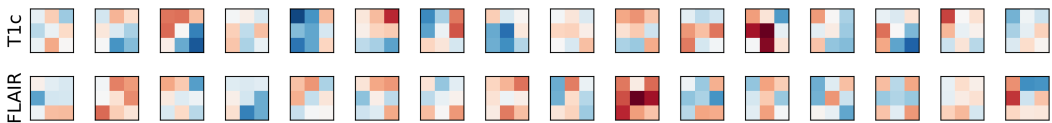
- Red convolucional con aumento, parches de prueba.
- Cada fila suma 1.
- La confusión mayor es necrosis predicha como edema, 0,22.

Errores con mayor confianza



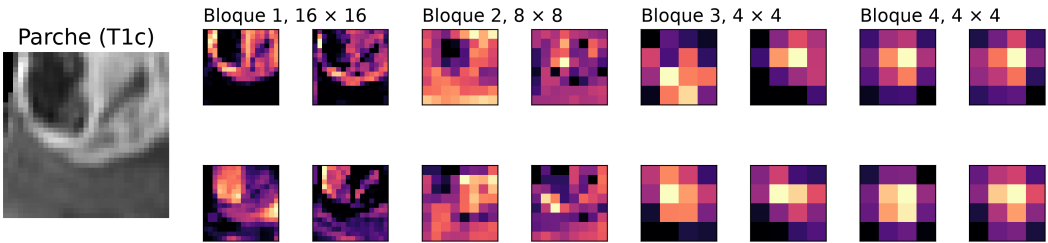
Los ocho parches de prueba mal clasificados con mayor probabilidad asignada, con su clase de referencia y la predicha. La cruz marca el píxel central.

Filtros aprendidos



Los 16 kernels de 3×3 de la primera capa, rebanadas de T1 con contraste (arriba) y de FLAIR (abajo). Rojo positivo, azul negativo.

Mapas de características



Parche de realce de prueba y los cuatro mapas de mayor activación media de cada bloque.

Mapas de saliencia

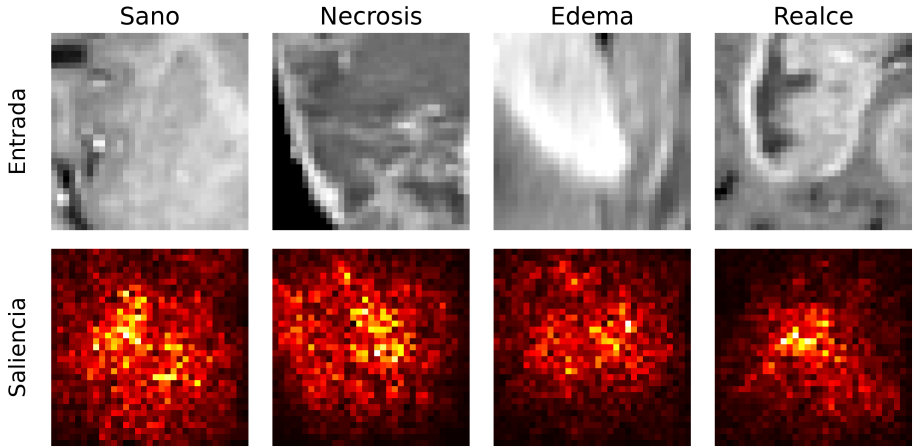
La saliencia de cada píxel de entrada mide cuánto cambia la puntuación de la clase predicha $\hat{k}$ al cambiar ese píxel:

$$s(u, v) = \sum_{c=1}^{4} \left| \frac{\partial y_{\hat{k}}}{\partial x_c(u, v)} \right|.$$

$x_c(u, v)$ es el píxel (u, v) del canal c del parche e $y_{\hat{k}}$ la puntuación de la clase $\hat{k}$ antes de softmax.

- Se calcula por retropropagación hasta la entrada, con los pesos fijos.
- Indica qué píxeles del parche usa la red para decidir.

Ejemplo de saliencia



Arquitecturas clásicas

LeNet y AlexNet

- **LeNet** (1998) reconoce dígitos manuscritos de 32×32 con dos capas convolucionales, dos de submuestreo y capas densas.
- **AlexNet** (2012) clasifica fotografías de 224×224 en mil clases de ImageNet con cinco capas convolucionales y tres densas.
- AlexNet popularizó ReLU, dropout y aumento de datos, y se entrenó en GPU.

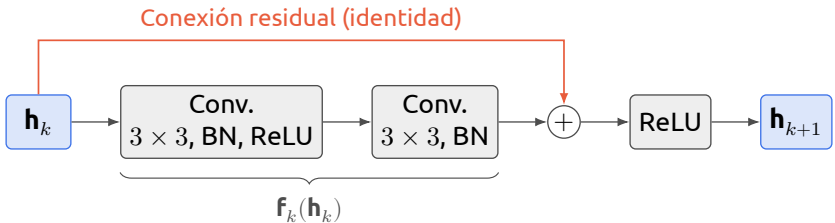
La red del caso de estudio tiene la misma organización que LeNet.

VGG

- Usa sólo convoluciones de 3×3, apiladas en bloques, y max pooling de 2×2.
- Dos convoluciones de 3×3 tienen el campo receptivo de una de 5×5 con menos parámetros, $2 \cdot 9\, C^2$ frente a $25\, C^2$.
- Las versiones de 16 y 19 capas tienen unos 140 millones de parámetros, la mayoría en las capas densas finales.

C es el número de canales de entrada y de salida de cada convolución.

Bloque residual



$$\mathbf{h}_{k+1} = \text{ReLU}(\mathbf{h}_k + \mathbf{f}_k(\mathbf{h}_k))$$

$\mathbf{h}_k$ son los mapas a la entrada del bloque k y $\mathbf{f}_k$ las dos convoluciones con sus normalizaciones.

ResNet

- Sin conexiones residuales, una red de 56 capas obtiene más error de entrenamiento que una de 20. El problema es de optimización, no de sobreajuste.
- Con bloques residuales se entrenan redes de 50, 101 y 152 capas.
- ResNet ganó ImageNet en 2015 y sus variantes son la base habitual de los clasificadores de imágenes médicas.

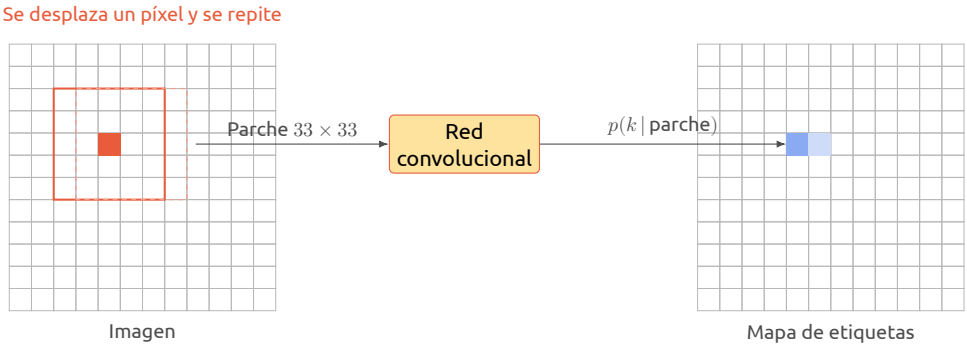
Aprendizaje por transferencia

Una red entrenada con millones de fotografías ya tiene filtros útiles para bordes, texturas y formas.

- Se reemplaza la capa final por una con las clases del problema nuevo.
- Se entrena sólo la capa nueva, o toda la red con una tasa de aprendizaje pequeña (fine-tuning).
- Es la práctica habitual cuando hay pocos cientos o miles de imágenes médicas etiquetadas.

De la clasificación a la segmentación

Ventana deslizante



Cada píxel del cerebro recibe la clase de su parche centrado. El segmentador es el clasificador aplicado en todas las posiciones.

Corrección por probabilidades a priori

La red se entrenó con clases balanceadas y estima $p_b(k \mid \mathbf{x})$. Por el teorema de Bayes,

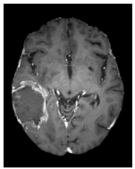
$$p(k \mid \mathbf{x}) \propto p_b(k \mid \mathbf{x})\, \pi_k .$$

π_k es la proporción de la clase k entre los píxeles de cerebro de los pacientes de entrenamiento y $\mathbf{x}$ el parche.

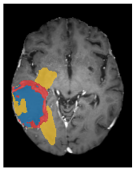
- Sin corrección la red marca como tumor una parte del cerebro sano.
- Con la corrección se elige la clase de mayor $p_b(k \mid \mathbf{x})\, \pi_k$.

Segmentación de pacientes de prueba

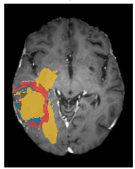
T1 con contraste



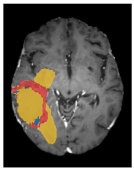
Referencia



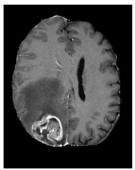
Densa, descriptores



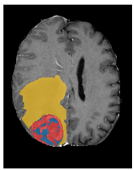
Convolucional



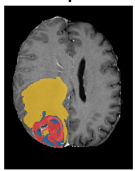
T1 con contraste



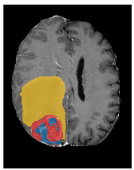
Referencia



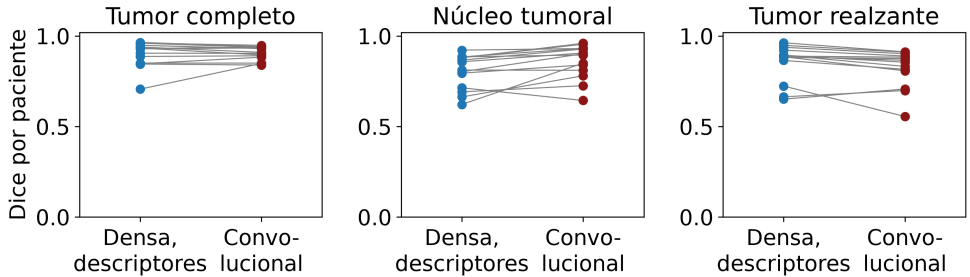
Densa, descriptores



Convolucional



Dice por paciente



Dice $= 2|A \cap B|/(|A| + |B|)$, con A la región predicha y B la de referencia. Mediana de la red convolucional frente a la densa sobre descriptores, tumor completo 0,91 y 0,93, núcleo 0,90 y 0,83, realce 0,86 y 0,89.

Redes totalmente convolucionales

- Una red sin capas densas acepta imágenes de cualquier tamaño y entrega un mapa en lugar de un número.
- Una sola pasada calcula la salida de todas las posiciones y comparte los cálculos entre parches vecinos.
- El pooling reduce la resolución. Para recuperar un mapa del tamaño de la imagen se agregan capas que aumentan la resolución, como la convolución transpuesta.

U-Net

- Una rama de codificación reduce la resolución y aumenta los canales, como la red del caso.
- Una rama de decodificación recupera la resolución con convoluciones transpuestas.
- Conexiones de salto llevan los mapas de cada nivel de la codificación al nivel correspondiente de la decodificación, para recuperar los bordes finos.
- Se entrena con imágenes completas y mapas de etiquetas completos.

Cuaderno de la clase

Todos los resultados de esta clase, con el código de cada experimento, están en el cuaderno

`notebooks/10-cnn-clasificacion.ipynb`

El cuaderno extrae los parches, implementa los cuatro clasificadores en PyTorch, los entrena, dibuja filtros, mapas y saliencias, y segmenta los pacientes de prueba por ventana deslizante. Los datos están en `notebooks/datos/lumiere_cortes.npz`.

Requisitos: `numpy`, `scipy`, `scikit-learn`, `matplotlib` y `torch`.

Siglas

Sigla	Significado
BN	Normalización por lotes (batch normalization)
FCN	Red totalmente convolucional (fully convolutional network)
FLAIR	Recuperación de inversión atenuada por fluidos
GPU	Unidad de procesamiento gráfico
ReLU	Unidad lineal rectificada
ResNet	Red residual
T1c	T1 con contraste de gadolinio
VGG	Visual Geometry Group (Universidad de Oxford)

Referencias

- Prince, S. J. D. *Understanding Deep Learning*. MIT Press, 2023. Capítulos 10 y 11.
- LeCun, Y., Bottou, L., Bengio, Y. y Haffner, P. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 1998.
- Krizhevsky, A., Sutskever, I. y Hinton, G. E. ImageNet classification with deep convolutional neural networks. *NeurIPS*, 2012.
- Simonyan, K. y Zisserman, A. Very deep convolutional networks for large-scale image recognition. *ICLR*, 2015.
- He, K., Zhang, X., Ren, S. y Sun, J. Deep residual learning for image recognition. *CVPR*, 2016.
- Ioffe, S. y Szegedy, C. Batch normalization. *ICML*, 2015.
- Ronneberger, O., Fischer, P. y Brox, T. U-Net. *MICCAI*, 2015.
- Simonyan, K., Vedaldi, A. y Zisserman, A. Deep inside convolutional networks, saliency maps. *ICLR Workshop*, 2014.
- Suter, Y. et al. The LUMIERE dataset. *Scientific Data* 9, 768, 2022.