

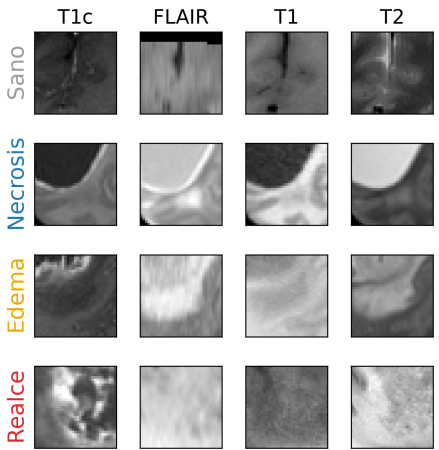
Embeddings de imágenes médicas

Alejandro Veloz

Objetivos

- Definir un embedding como la salida de un codificador y distinguirlo de la codificación one-hot.
- Obtener un embedding desde un clasificador convolucional y visualizarlo en el plano.
- Formular pérdidas contrastivas y entrenar un codificador sin etiquetas.
- Alinear dos grupos de secuencias en un espacio común.
- Aplicar embeddings a la búsqueda por contenido, al aprendizaje con pocas etiquetas y a la detección de anomalías.

Caso de estudio



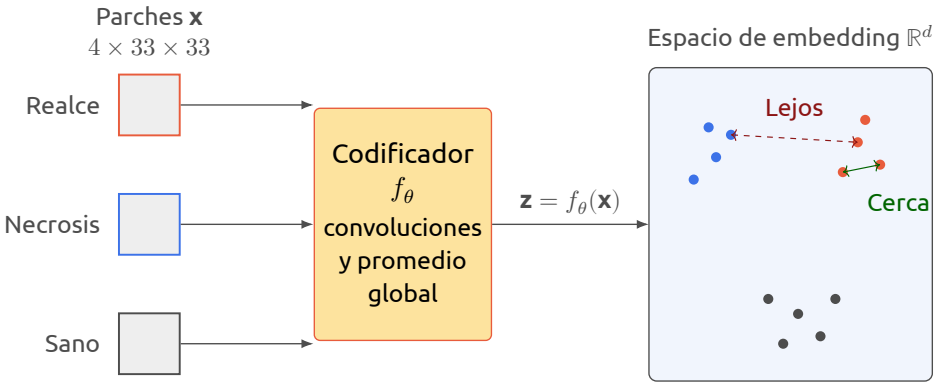
- Base LUMIERE, glioblastoma preoperatorio, cuatro secuencias corregistradas a 1 mm.
- Parches de 33×33 píxeles con las cuatro secuencias.
- Etiqueta del parche, la del píxel central (sano, necrosis, edema o realce).
- 24.000 parches de 52 pacientes para entrenar y 8000 de otros 14 para probar, con las cuatro clases balanceadas.

Representaciones vectoriales

Del descriptor al embedding

- Un vector de descriptores hechos a mano ya es una representación de la imagen en $\mathbb{R}^d$.
- Sus componentes las elige el diseñador y no cambian con la tarea.
- Un embedding es un vector calculado por una red $f_{\boldsymbol{\theta}}$ cuyos parámetros $\boldsymbol{\theta}$ se ajustan con datos.
- La propiedad buscada es geométrica. Dos imágenes parecidas deben tener vectores cercanos.

Codificador y espacio de embedding



$\mathbf{x}$ es el parche, $f_{\boldsymbol{\theta}}$ el codificador con parámetros $\boldsymbol{\theta}$ y $\mathbf{z} \in \mathbb{R}^d$ su embedding.

Similitud coseno y distancia euclidiana

Para dos embeddings $\mathbf{z}$ y $\mathbf{z}'$,

$$d(\mathbf{z}, \mathbf{z}') = \|\mathbf{z} - \mathbf{z}'\|_2, \qquad \cos(\mathbf{z}, \mathbf{z}') = \frac{\mathbf{z}^\top \mathbf{z}'}{\|\mathbf{z}\|_2 \, \|\mathbf{z}'\|_2}.$$

d es la distancia euclidiana y cos la similitud coseno, que vale 1 para vectores con la misma dirección.

Si ambos vectores tienen norma uno, $d(\mathbf{z}, \mathbf{z}')^2 = 2\,(1 - \cos(\mathbf{z}, \mathbf{z}'))$, y las dos medidas ordenan igual a los vecinos.

Variables categóricas y codificación one-hot

Una variable categórica, como el equipo de resonancia con n valores posibles, se representa con el vector one-hot

$$\mathbf{e}_i = (0, \dots, 0, 1, 0, \dots, 0) \in \{0, 1\}^n.$$

$\mathbf{e}_i$ tiene un 1 en la posición i del valor observado y ceros en las demás.

- Todo par de valores distintos queda a la misma distancia, $\sqrt{2}$.
- La dimensión crece con el número de valores.

Capa de embedding

Una capa de embedding es una matriz entrenable $\mathbf{E} \in \mathbb{R}^{n \times d}$. El valor i se representa con la fila i,

$$\mathbf{z}_i = \mathbf{E}^\top \mathbf{e}_i \in \mathbb{R}^d.$$

n es el número de valores de la variable, d la dimensión del embedding y $\mathbf{e}_i$ el vector one-hot.

- La matriz se ajusta por retropropagación junto con el resto de la red.
- Valores que cumplen papeles parecidos en la tarea terminan con filas parecidas.

Hipótesis distribucional y word2vec

- Las palabras que aparecen en contextos parecidos tienen significados parecidos.
- Word2vec entrena una capa de embedding para predecir las palabras vecinas de cada palabra en un texto.
- Las palabras con contextos parecidos reciben gradientes parecidos y quedan cerca.
- La misma idea se aplicó después a códigos clínicos, genes y pacientes.

Embeddings desde un clasificador

Codificador convolucional

- Tres bloques de convolución 3×3, normalización por lotes, ReLU (unidad lineal rectificada) y reducción máxima.
- Una cuarta convolución y un promedio global sobre la posición.
- Salida $\mathbf{z} = f_{\boldsymbol{\theta}}(\mathbf{x}) \in \mathbb{R}^{64}$ para cada parche, con 60.880 parámetros.
- El mismo codificador se entrena de tres maneras, con etiquetas, con vistas aumentadas y con pares de secuencias.

Embedding de la penúltima capa

El clasificador agrega una capa lineal sobre el embedding,

$$p(k \mid \mathbf{x}) = \text{softmax}_k(\mathbf{W}\, f_{\boldsymbol{\theta}}(\mathbf{x}) + \mathbf{b})\,.$$

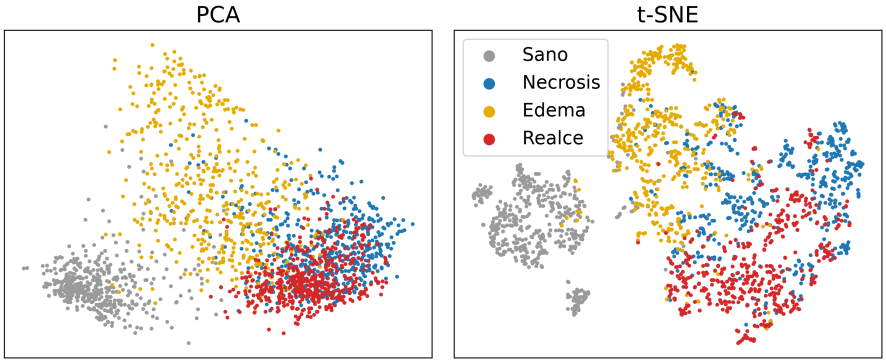
k es la clase, $\mathbf{W} \in \mathbb{R}^{4\times 64}$ y $\mathbf{b} \in \mathbb{R}^4$ los parámetros de la capa lineal.

- Se entrena con entropía cruzada, volteos y rotaciones del parche.
- Exactitud balanceada en los pacientes de prueba, 0,86.
- Como la última capa es lineal, el entrenamiento empuja a que las clases sean separables con hiperplanos en $\mathbb{R}^{64}$.

Proyección a dos dimensiones

- PCA (análisis de componentes principales) proyecta sobre las dos direcciones de mayor varianza. Conserva distancias grandes y es lineal.
- t-SNE (inserción estocástica de vecinos con distribución t) conserva en el plano los vecinos cercanos del espacio original. No es lineal.
- Ambas sirven para mirar un embedding, no para medir con él.

Embedding supervisado en el plano



2000 parches de prueba proyectados con PCA (análisis de componentes principales) y con t-SNE (inserción estocástica de vecinos con distribución t), coloreados por la clase de referencia.

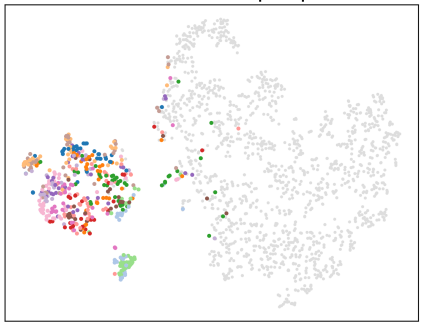
Precauciones con t-SNE

t-SNE es la inserción estocástica de vecinos con distribución t.

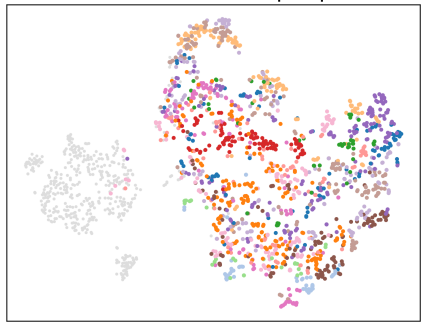
- El tamaño de un grupo en el plano no indica su dispersión en el espacio original.
- La distancia entre grupos lejanos no tiene interpretación.
- El resultado cambia con la perplejidad y con la semilla.
- Un grupo aparente puede aparecer incluso en datos sin estructura.

Información del paciente en el embedding

Parches sanos, color por paciente



Parches de lesión, color por paciente

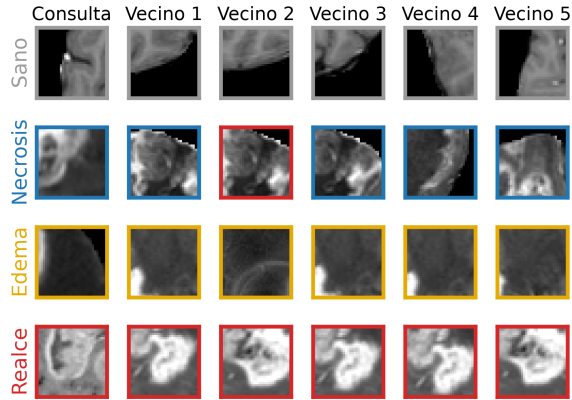


Con cinco vecinos en el embedding, el paciente de un parche sano se acierta en un 52,9 % de los casos; con píxeles crudos, en un 36,5 %; el azar da 7,1 %.

Búsqueda por contenido

- Una base de imágenes se guarda como una base de embeddings.
- Para una imagen de consulta se buscan los k embeddings más cercanos por similitud coseno.
- La precisión en k es la fracción de los k vecinos con la misma clase que la consulta.
- La búsqueda no exige reentrenar al agregar imágenes nuevas.

Ejemplo de búsqueda por contenido



T1 con contraste de cuatro consultas de prueba y sus cinco vecinos de entrenamiento; el borde indica la clase. Precisión en 5, 83,8 % con el embedding y 54,1 % con píxeles.

Aprendizaje contrastivo

Aprender sin etiquetas

- Etiquetar imágenes médicas exige tiempo de especialistas.
- Las imágenes sin etiqueta abundan en los archivos de los hospitales.
- El aprendizaje autosupervisado construye la señal de entrenamiento a partir de los datos mismos.
- El aprendizaje contrastivo usa una regla, dos versiones de una misma imagen deben tener embeddings cercanos y versiones de imágenes distintas, lejanos.

Pérdida contrastiva por pares

Para un par de imágenes con embeddings $\mathbf{z}, \mathbf{z}'$ y distancia $d = \|\mathbf{z} - \mathbf{z}'\|_2$,

$$\ell = y\, d^2 + (1 - y)\, \max(0,\, m - d)^2.$$

$y = 1$ si el par es de la misma clase y $y = 0$ si no; $m > 0$ es el margen.

- Los pares positivos se acercan.
- Los pares negativos se alejan hasta quedar a distancia m.

Pérdida de triplete

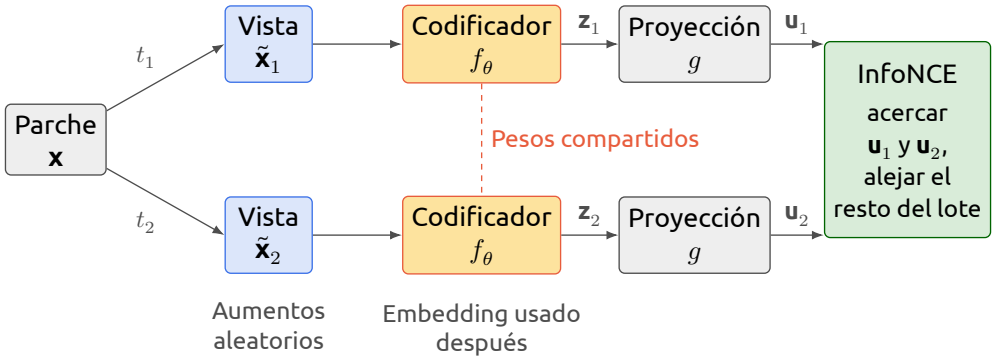
Para un ancla $\mathbf{z}_a$, un positivo $\mathbf{z}_p$ y un negativo $\mathbf{z}_n$,

$$\ell = \max\bigl(0,\ \|\mathbf{z}_a - \mathbf{z}_p\|_2^2 - \|\mathbf{z}_a - \mathbf{z}_n\|_2^2 + m\bigr)\,.$$

El positivo comparte clase con el ancla, el negativo no, y m es el margen.

- La pérdida pide que el positivo esté más cerca que el negativo por al menos m.
- Los tripletes fáciles dan pérdida cero; el entrenamiento depende de elegir negativos difíciles.

Esquema de SimCLR



SimCLR es un marco simple de aprendizaje contrastivo de representaciones. t_1 y t_2 son aumentos aleatorios, g una cabeza de proyección y $\mathbf{u}_1$, $\mathbf{u}_2$ sus salidas.

Aumentos para parches de resonancia

- Volteo horizontal y rotación en múltiplos de 90 grados.
- Cambio de brillo y contraste independiente en cada secuencia.
- Ruido gaussiano y desplazamiento de hasta tres píxeles.

Cada aumento define lo que el embedding debe ignorar. La orientación del parche y el contraste del equipo no deben cambiar la representación del tejido.

Pérdida InfoNCE

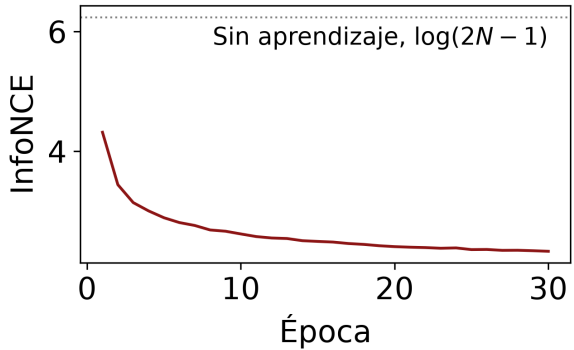
Para un lote de N parches hay $2N$ vistas. Para la vista i con par positivo j,

$$\ell_i = -\log \frac{\exp(\cos(\mathbf{u}_i, \mathbf{u}_j)/\tau)}{\sum_{k \neq i} \exp(\cos(\mathbf{u}_i, \mathbf{u}_k)/\tau)}.$$

$\mathbf{u}_i$ es la proyección de la vista i, la suma recorre las otras $2N - 1$ vistas y $\tau > 0$ es la temperatura; aquí $N = 256$ y $\tau = 0{,}2$.

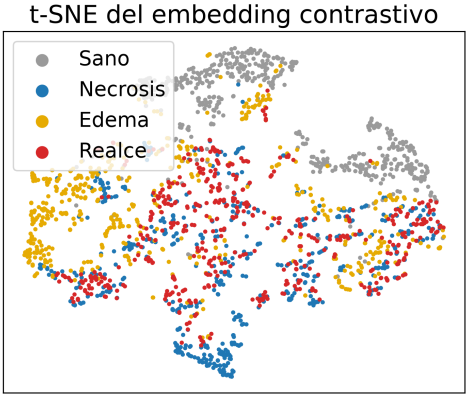
InfoNCE (estimación contrastiva por ruido con criterio de información) es una entropía cruzada que pide reconocer el par positivo entre $2N - 1$ candidatos.

Entrenamiento contrastivo



30 épocas sin etiquetas. La pérdida baja de 4,32 a 2,33; sin aprendizaje valdría 6,24.

Embedding contrastivo en el plano



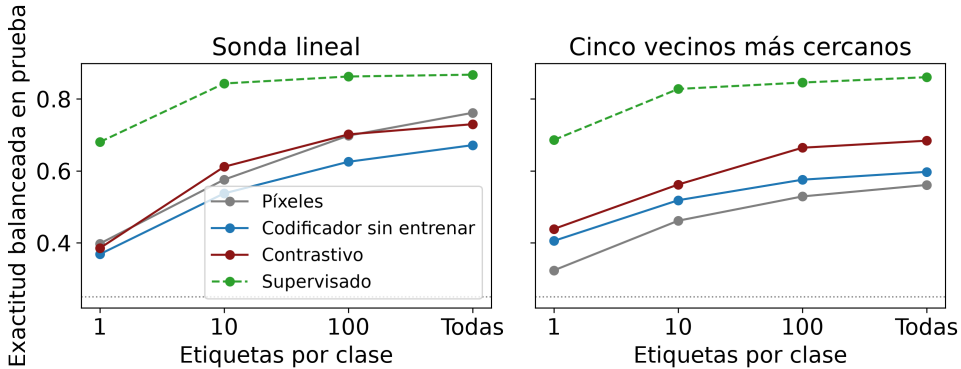
Los colores se agregan después; el codificador no vio ninguna etiqueta. Precisión en 5 de la búsqueda, 65,4 %.

Aprendizaje con pocas etiquetas

Protocolo de evaluación

- El codificador queda fijo y se usa su embedding como entrada.
- Con n parches etiquetados por clase se entrena una sonda lineal (regresión logística) o se clasifica por los cinco vecinos más cercanos.
- $n \in \{1, 10, 100\}$ y todas las etiquetas; con 1 y 10 se promedian 10 sorteos.
- Se comparan píxeles crudos, codificador sin entrenar, contrastivo y supervisado.

Exactitud según el número de etiquetas



Exactitud balanceada en los pacientes de prueba; la línea punteada horizontal es el azar.

Lectura de los resultados

Sonda lineal	1	10	100	Todas
Píxeles	0,40	0,58	0,70	0,76
Codificador sin entrenar	0,37	0,54	0,63	0,67
Contrastivo	0,39	0,61	0,70	0,73
Supervisado	0,68	0,84	0,86	0,87

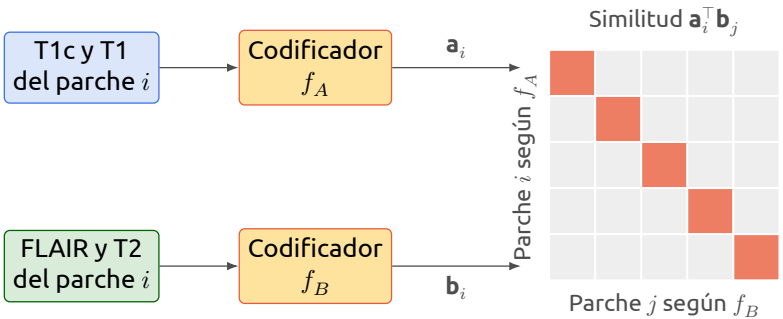
- Con 10 etiquetas por clase, el embedding contrastivo supera a los píxeles por 0,61 frente a 0,58.
- Con todas las etiquetas los píxeles quedan arriba, 0,76 frente a 0,73, y el supervisado sigue sobre ambos.

Alineación entre modalidades

Espacio común para dos modalidades

- CLIP (preentrenamiento contrastivo de lenguaje e imagen) entrena un codificador de imágenes y uno de texto con pares imagen y descripción.
- Cada imagen queda cerca de su descripción y lejos de las demás.
- La misma idea vale para dos grupos de secuencias de resonancia de un mismo parche.
- Aquí f_A recibe T1 con contraste y T1, y f_B recibe FLAIR y T2.

Esquema de la alineación



Diagonal pareja correcta, similitud alta

Fuera de la diagonal parches distintos, similitud baja

$\mathbf{a}_i$ y $\mathbf{b}_i$ son los embeddings normalizados del parche i según cada codificador.

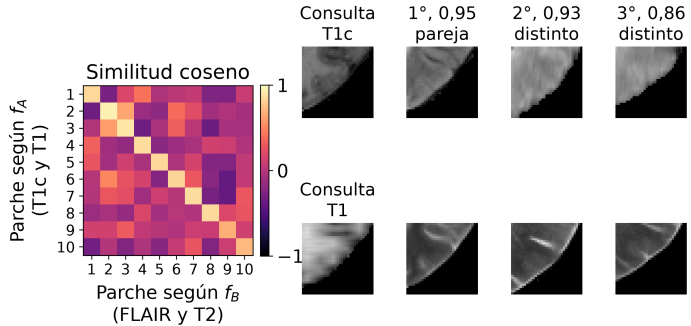
Pérdida contrastiva simétrica

$$\ell = -\frac{1}{2N}\sum_{i=1}^{N}\left[\log\frac{e^{\mathbf{a}_i^\top \mathbf{b}_i/\tau}}{\sum_j e^{\mathbf{a}_i^\top \mathbf{b}_j/\tau}} + \log\frac{e^{\mathbf{a}_i^\top \mathbf{b}_i/\tau}}{\sum_j e^{\mathbf{a}_j^\top \mathbf{b}_i/\tau}}\right]$$

$N = 256$ es el tamaño del lote, $\mathbf{a}_i$ y $\mathbf{b}_i$ los embeddings normalizados del parche i y $\tau = 0{,}1$ la temperatura.

- El primer término busca la pareja de $\mathbf{a}_i$ entre las $\mathbf{b}_j$.
- El segundo busca la pareja de $\mathbf{b}_i$ entre las $\mathbf{a}_j$.

Recuperación entre secuencias



Candidatos: arriba FLAIR, abajo T2

Entre 1000 parches de prueba, la pareja correcta queda primera en un 56,5 % de los casos y entre las cinco primeras en un 82,1 % (0,1 % y 0,5 % antes de entrenar; azar 0,1 % y 0,5 %).

Modelos de imagen y texto en medicina

- Variantes de CLIP (preentrenamiento contrastivo de lenguaje e imagen) entrenadas con radiografías e informes, y con figuras y leyendas de artículos biomédicos.
- Permiten clasificar sin ejemplos etiquetados, describiendo cada clase con una frase.
- Heredan los sesgos de sus datos, como el idioma, las modalidades y los centros representados.

Detección de anomalías

Anomalía como distancia a lo normal

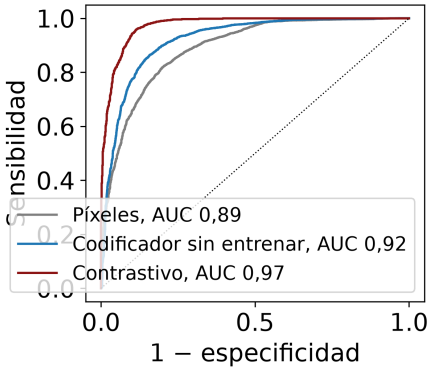
Con una referencia de embeddings de tejido sano $\{\mathbf{r}_1, \dots, \mathbf{r}_R\}$, el puntaje de un parche es

$$s(\mathbf{x}) = \frac{1}{k} \sum_{j=1}^{k} \| f_{\boldsymbol{\theta}}(\mathbf{x}) - \mathbf{r}_{(j)} \|_2 .$$

$\mathbf{r}_{(j)}$ es el j-ésimo vecino más cercano del embedding del parche en la referencia y $k = 5$.

- La referencia son 7050 parches de 47 cortes sin lesión de pacientes de entrenamiento.
- No se usa ninguna etiqueta de tumor.

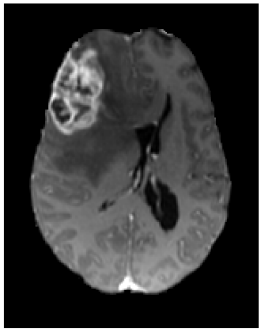
Desempeño de la detección



Parches de prueba con lesión frente a sanos. Área bajo la curva ROC (característica operativa del receptor), AUC en la leyenda, 0,89 con píxeles, 0,92 con el codificador sin entrenar y 0,97 con el contrastivo.

Mapa de anomalía

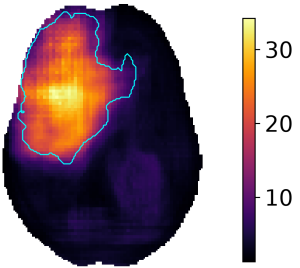
T1 con contraste



FLAIR y tumor de referencia



Puntaje de anomalía



Puntaje del embedding contrastivo calculado cada dos píxeles sobre un corte de prueba; el contorno marca el tumor de referencia.

Uso responsable de embeddings

Propiedades de un buen embedding

- Agrupa lo que la tarea considera igual e ignora lo que considera irrelevante.
- Sirve para tareas distintas de la que lo entrenó, con un clasificador simple encima.
- Es estable ante cambios de equipo, protocolo y paciente.
- Su dimensión es pequeña frente a la de la imagen.

Precauciones

- **Atajos.** Si una clase proviene de un solo centro, el embedding puede separar centros en lugar de tejidos.
- **Fuga de información.** Los parches de un mismo paciente no deben repartirse entre entrenamiento y prueba.
- **Proyecciones.** Un gráfico de t-SNE (inserción estocástica de vecinos) no demuestra separabilidad.
- **Privacidad.** Un embedding puede permitir reidentificar a un paciente.

Cuaderno de la clase

Todos los ejemplos de esta clase, con el código y las figuras, están en el cuaderno

`notebooks/11-embeddings.ipynb`

El cuaderno define el codificador, entrena las versiones supervisada, contrastiva y multimodal, y calcula la búsqueda por contenido, la evaluación con pocas etiquetas y la detección de anomalías. Los datos están en `notebooks/datos/lumiere_cortes.npz`.

Requisitos: `numpy`, `scipy`, `scikit-learn`, `matplotlib` y `torch`.

Siglas

AUC	Área bajo la curva ROC
CLIP	Preentrenamiento contrastivo de lenguaje e imagen
InfoNCE	Estimación contrastiva por ruido con criterio de información
PCA	Análisis de componentes principales
ReLU	Unidad lineal rectificada
ROC	Característica operativa del receptor
SimCLR	Marco simple para aprendizaje contrastivo de representaciones
t-SNE	Inserción estocástica de vecinos con distribución t

Referencias

- Suter, Y. y colaboradores. The LUMIERE dataset: longitudinal glioblastoma MRI with expert RANO evaluation. *Scientific Data*, 2022.
- Mikolov, T. y colaboradores. Distributed representations of words and phrases and their compositionality. *NeurIPS*, 2013.
- Hadsell, R., Chopra, S. y LeCun, Y. Dimensionality reduction by learning an invariant mapping. *CVPR*, 2006.
- Schroff, F., Kalenichenko, D. y Philbin, J. FaceNet: a unified embedding for face recognition and clustering. *CVPR*, 2015.
- van den Oord, A., Li, Y. y Vinyals, O. Representation learning with contrastive predictive coding. *arXiv:1807.03748*, 2018.
- Chen, T., Kornblith, S., Norouzi, M. y Hinton, G. A simple framework for contrastive learning of visual representations. *ICML*, 2020.
- Radford, A. y colaboradores. Learning transferable visual models from natural language supervision. *ICML*, 2021.
- van der Maaten, L. y Hinton, G. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 2008.