

Radiomics

Características cuantitativas de imágenes médicas

Alejandro Veloz

Objetivos

- Describir el flujo de un estudio radiómico desde la adquisición hasta la validación.
- Calcular características de forma, de primer orden y de textura a partir de una región segmentada.
- Analizar el efecto de la discretización, la segmentación y el equipo sobre las características.
- Construir y validar un modelo de predicción sin fuga de información.
- Interpretar el resultado de un modelo radiómico con una prueba de permutación.

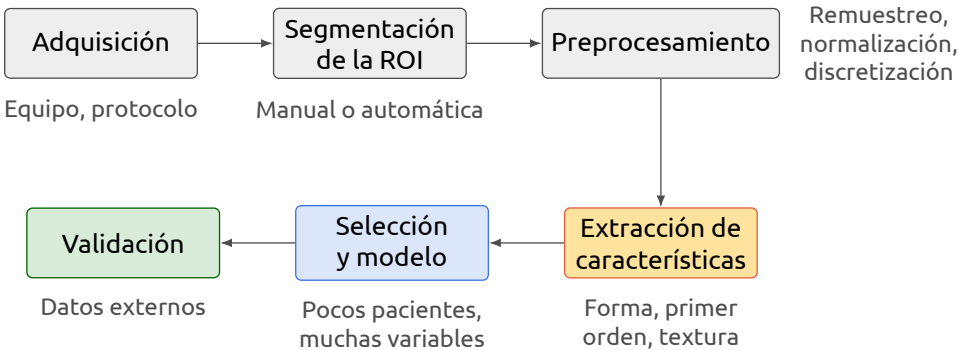
Radiomics y su flujo de trabajo

Definición

Radiomics es la extracción de un gran número de características cuantitativas de imágenes médicas y su análisis para apoyar decisiones clínicas.

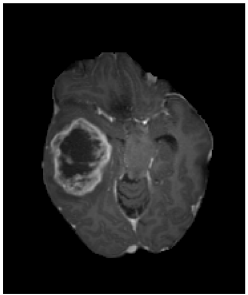
- Cada región de interés se describe con cientos de números.
- Las características se relacionan con un diagnóstico, un pronóstico o una respuesta al tratamiento.
- Se supone que la imagen contiene información del tejido que el ojo no cuantifica.

Flujo de un estudio radiómico



Caso de estudio

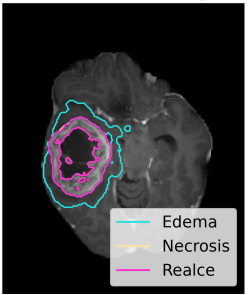
T1 con contraste



FLAIR



Compartimentos de DeepBraTumIA



Base LUMIERE, glioblastoma, estudio preoperatorio. Segmentación automática en realce, necrosis y edema. 107 características de PyRadiomics por secuencia y compartimento, publicadas con la base.

Variables clínicas

- **Metilación del promotor de MGMT.** Predice la respuesta a la temozolomida. Se determina en la biopsia. Hay 29 pacientes metilados y 34 no metilados.
- **Supervivencia.** Conocida en 69 pacientes, con mediana de 74 semanas. Se predice si supera la mediana.

Una predicción no invasiva de la metilación sería útil antes de la cirugía.

Verificación de las etiquetas

- En la segmentación de DeepBraTumIA, la etiqueta 1 es realce, la 2 necrosis y la 3 edema.
- El archivo de características publicado nombra realce a la etiqueta 2 y necrosis a la 1.
- El número de vóxeles de cada fila coincide con el volumen de necrosis y de realce intercambiados.

Antes de modelar, cada etiqueta se verifica contra una fuente independiente.

Características radiómicas

Familias de características

Familia	Número	Describe
Forma	14	Tamaño y geometría de la región
Primer orden	18	Histograma de intensidades
GLCM	24	Pares de vóxeles vecinos
GLRLM	16	Corridas de un mismo nivel
GLSZM	16	Zonas conexas de un mismo nivel
GLDM	14	Dependencia con la vecindad
NGTDM	5	Diferencia con el promedio vecino

Las cinco últimas familias son características de textura.

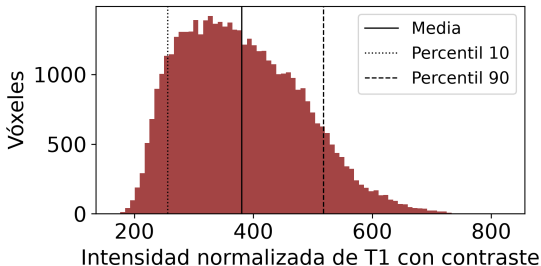
Características de forma

$$\text{Esfericidad} = \frac{\sqrt[3]{36\pi V^2}}{A}, \quad \text{Elongación} = \sqrt{\lambda_2/\lambda_1}, \quad \text{Planitud} = \sqrt{\lambda_3/\lambda_1}.$$

V es el volumen y A el área de la superficie triangulada de la región. $\lambda_1 \geq \lambda_2 \geq \lambda_3$ son los valores propios de la covarianza de las coordenadas de los vóxeles.

- La esfericidad vale 1 para una esfera y baja para formas irregulares.
- La superficie se obtiene con el algoritmo marching cubes.

Características de primer orden



$$\bar{x} = \frac{1}{N} \sum_{n=1}^{N} x_n$$

$$H = -\sum_{g=1}^{N_g} p_g \log_2 p_g$$

x_n es la intensidad del vóxel n de la región, N el número de vóxeles, p_g la fracción de vóxeles en el nivel discretizado g y N_g el número de niveles.

También percentiles, varianza, asimetría, curtosis y energía.

Normalización y discretización

En resonancia la intensidad no tiene unidades físicas. PyRadiomics normaliza toda la imagen y discretiza la región:

$$\tilde{x} = 100\,\frac{x-\mu}{\sigma}, \qquad g = \left\lfloor \frac{\tilde{x}}{w} \right\rfloor - \left\lfloor \frac{\min \tilde{x}}{w} \right\rfloor + 1.$$

μ y σ son la media y la desviación de toda la imagen, w el ancho de intervalo, min $\tilde{x}$ el mínimo en la región y g el nivel de gris entero.

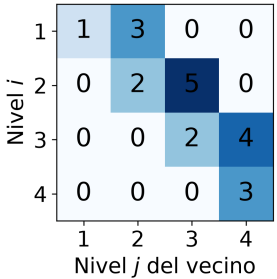
- Ancho fijo, $w = 5$ en la base. La región del ejemplo tiene 91 niveles en la mediana de los pacientes.
- Número fijo de intervalos, la alternativa más usada.

Matriz de coocurrencia

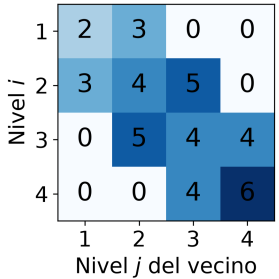
Imagen discretizada



Pares horizontales (i, j)



Matriz simétrica



$P(i, j)$ cuenta los pares de vóxeles vecinos en una dirección con niveles i y j. La imagen de 5×5 tiene 20 pares horizontales. Se suma la transpuesta para no distinguir el orden y se divide por el total.

Características de la matriz de coocurrencia

$$\text{Contraste} = \sum_{i,j} (i-j)^2 \, p(i,j), \qquad \text{Correlación} = \frac{\sum_{i,j} i\, j\, p(i,j) - \mu^2}{\sigma^2},$$

$$\text{Entropía conjunta} = -\sum_{i,j} p(i,j) \log_2 p(i,j).$$

$p(i,j)$ es la matriz de coocurrencia normalizada y μ, σ la media y la desviación de su distribución marginal.

- El contraste crece con las diferencias entre vecinos.
- La correlación mide la dependencia lineal entre el nivel de un vóxel y el de su vecino.

Otras matrices de textura

- **GLRLM.** Cuenta corridas de vóxeles consecutivos con el mismo nivel, por nivel y longitud.
- **GLSZM.** Cuenta zonas conexas con el mismo nivel, por nivel y tamaño. No depende de la dirección.
- **GLDM.** Cuenta cuántos vecinos de cada vóxel tienen un nivel parecido.
- **NGTDM.** Acumula la diferencia entre cada nivel y el promedio de su vecindad.

Filtros y estandarización

- Las características se repiten sobre imágenes filtradas, por ejemplo con laplaciano de gaussiana a varias escalas o con ondículas.
- Con filtros, una región produce más de mil características.
- Las definiciones y los pasos de preprocesamiento están estandarizados por la iniciativa IBSI.

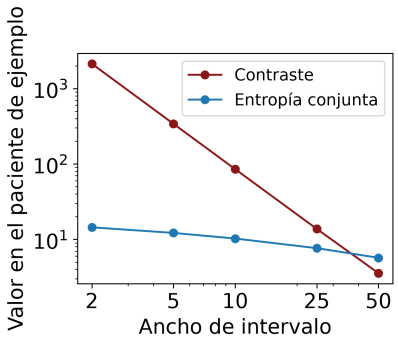
Implementación propia frente a PyRadiomics

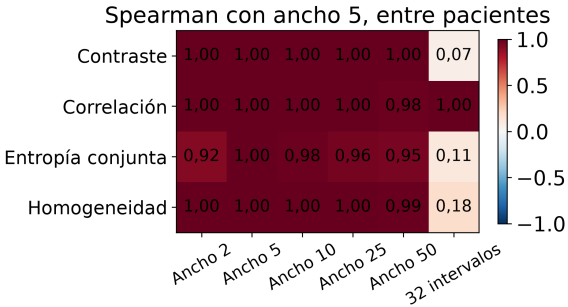
Característica	Implementación propia	PyRadiomics
Media	380,6	380,6
Entropía	6,294	6,294
Contraste GLCM	340,2	340,2
Correlación GLCM	0,567	0,567
Entropía conjunta GLCM	12,2	12,2
Volumen en vóxeles	45.957	45.957
Esfericidad	0,303	0,304

Tumor realzante del paciente de ejemplo en T1 con contraste. Las de primer orden y GLCM difieren en menos de 10^{-4} relativo. Las de malla difieren hasta 0,3,% por la variante de marching cubes.

Robustez de las características

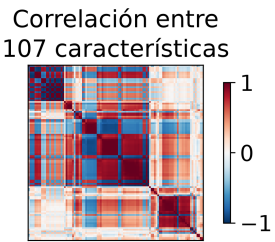
Efecto de la discretización

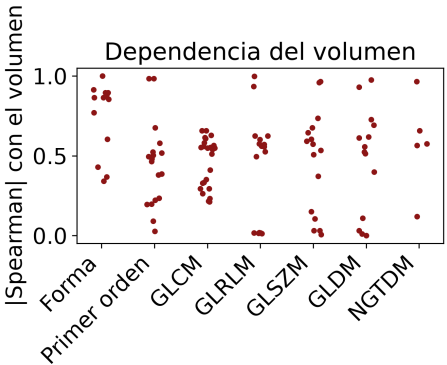




Izquierda, valor en el paciente de ejemplo según el ancho de intervalo. Derecha, correlación de Spearman entre pacientes con el ancho 5 y con cada alternativa. Con 32 intervalos fijos, el contraste conserva sólo 0,07 de correlación.

Redundancia





El 87,% de las características tiene correlación mayor que 0,9 con alguna otra. El 19,% tiene correlación mayor que 0,7 con el volumen.

Coeficiente de correlación intraclase

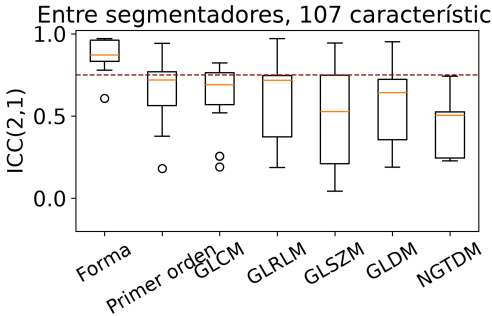
Una característica medida dos veces en n pacientes es reproducible si la variación entre pacientes domina a la variación entre mediciones:

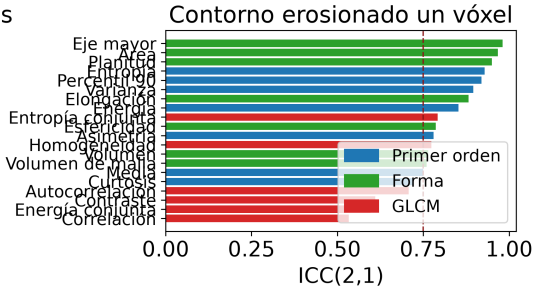
$$\text{ICC}(2,1) = \frac{MS_R - MS_E}{MS_R + (k-1)\,MS_E + \frac{k}{n}(MS_C - MS_E)}.$$

MS_R es la media de cuadrados entre pacientes, MS_C entre mediciones, MS_E la residual y $k = 2$ el número de mediciones.

Un ICC mayor que 0,75 se considera buena reproducibilidad.

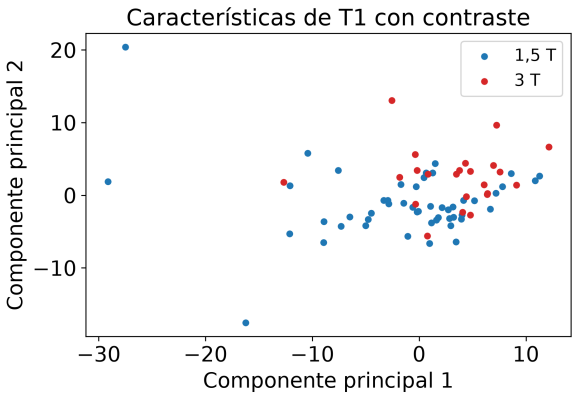
Reproducibilidad frente a la segmentación





Izquierda, DeepBraTumIA frente a HD-GLIO-AUTO en 73 estudios. Sólo el 36,% tiene ICC mayor que 0,75. Derecha, contorno erosionado un vóxel, que conserva el 58,% del volumen; 14 de 20 características superan 0,75.

Efecto del equipo



- 50 pacientes con T1 con contraste en 1,5 T y 23 en 3 T.
- Las características del realce predicen el campo magnético con área bajo la curva 0,80.
- Un modelo clínico puede aprender el equipo en lugar del tejido.

Armonización

- Protocolos de adquisición iguales en todos los centros, cuando es posible.
- Preprocesamiento común, con remuestreo, normalización de intensidades y discretización fijados de antemano.
- Corrección estadística del efecto del centro sobre las características, por ejemplo con ComBat.
- Selección de características reproducibles medidas en datos de repetición o con perturbaciones.

Modelos y validación

Muchas características y pocos pacientes

- Metilación de MGMT, 63 pacientes y 1284 características.
- Con más variables que pacientes, siempre existe una combinación que separa los datos de entrenamiento.
- Hacen falta selección de características, regularización y una validación honesta.

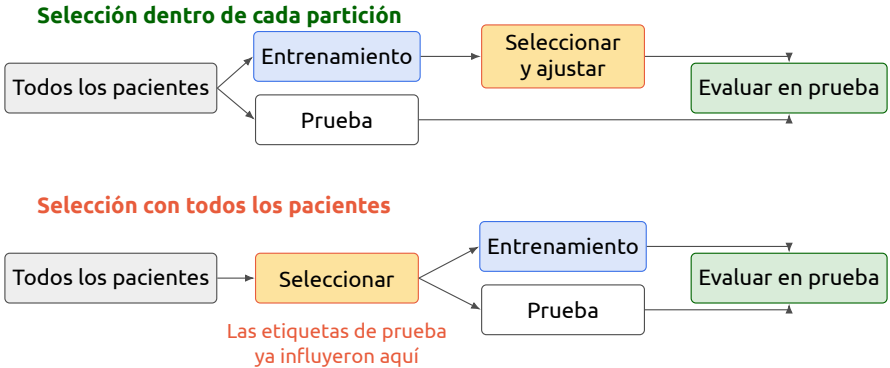
El modelo de la clase es una regresión logística con penalización ℓ_2 sobre las 10 características con mayor estadístico F.

Validación cruzada y área bajo la curva

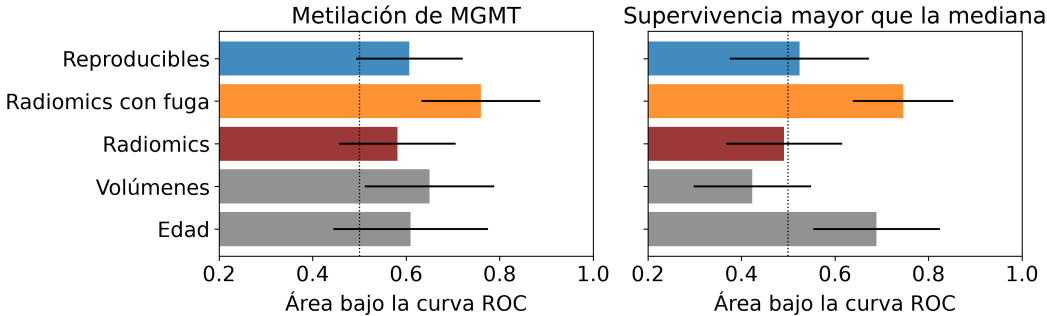
- Validación cruzada de 5 particiones, repetida 20 veces con particiones distintas.
- El área bajo la curva ROC es la probabilidad de que un paciente positivo al azar reciba mayor puntaje que uno negativo al azar.
- Vale 0,5 para un modelo al azar y 1 para uno perfecto.

Se informa la media y la desviación estándar entre las 100 particiones de prueba.

Fuga de información

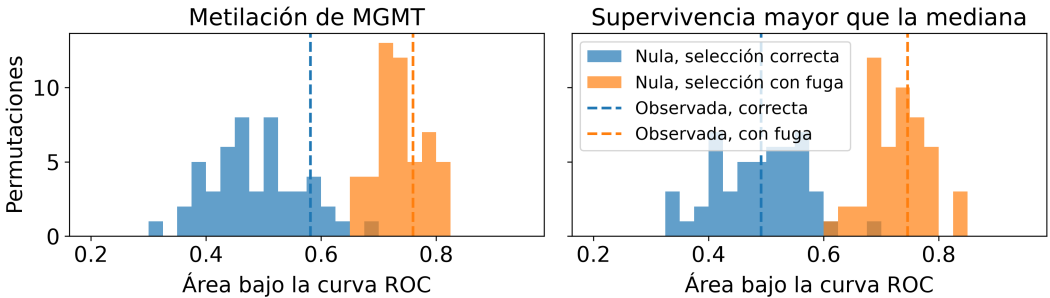


Resultados de predicción



MGMT, radiomics 0,58 con selección correcta y 0,76 con fuga. Supervivencia, radiomics 0,49, edad sola 0,69. Barras, desviación estándar entre particiones.

Prueba de permutación



50 permutaciones de las etiquetas por procedimiento. Con fuga, la mediana nula es 0,73 en MGMT y 0,73 en supervivencia. El valor p de la fuga es 0,35 y 0,41.

Calidad de un estudio radiómico

- Protocolo de adquisición y preprocesamiento descritos y fijados de antemano.
- Reproducibilidad de las características evaluada con repetición o perturbaciones.
- Validación con pacientes de otro centro o de otro período.
- Comparación con un modelo de variables clínicas simples.
- Código y datos disponibles.

Características diseñadas y aprendidas

- Las características radiómicas son descriptores diseñados, con definición matemática explícita.
- Una red convolucional aprende sus propios descriptores, que suelen ser más predictivos y menos interpretables.
- Los dos enfoques comparten los mismos problemas de equipo, segmentación, tamaño muestral y fuga.

Cuaderno de la clase

Todas las figuras y cifras de esta clase salen del cuaderno

`notebooks/12-radiomics.ipynb`

El cuaderno implementa las características de forma, primer orden y GLCM, las compara con PyRadiomics, calcula los ICC, entrena los modelos con validación repetida y construye las distribuciones nulas.

Requisitos: `numpy`, `scipy`, `pandas`, `scikit-image`, `scikit-learn` y `matplotlib`.

Siglas

AUC	Área bajo la curva (*area under the curve*)
GLCM	Matriz de coocurrencia de niveles de gris
GLDM	Matriz de dependencia de niveles de gris
GLRLM	Matriz de longitudes de corrida de niveles de gris
GLSZM	Matriz de tamaños de zona de niveles de gris
IBSI	Iniciativa de estandarización de biomarcadores de imagen
ICC	Coeficiente de correlación intraclase
MGMT	O6-metilguanina-ADN metiltransferasa
NGTDM	Matriz de diferencias de tonos de la vecindad
ROC	Característica operativa del receptor
TRIPOD	Guía de reporte de modelos de predicción

Referencias

- Gillies, R. J., Kinahan, P. E. y Hricak, H. Radiomics: images are more than pictures, they are data. *Radiology* 278, 563–577, 2016.
- Haralick, R. M., Shanmugam, K. y Dinstein, I. Textural features for image classification. *IEEE Trans. Systems, Man, and Cybernetics* 3, 610–621, 1973.
- Hegi, M. E. et al. MGMT gene silencing and benefit from temozolomide in glioblastoma. *New England Journal of Medicine* 352, 997–1003, 2005.
- Johnson, W. E., Li, C. y Rabinovic, A. Adjusting batch effects in microarray expression data using empirical Bayes methods. *Biostatistics* 8, 118–127, 2007.
- Koo, T. K. y Li, M. Y. A guideline of selecting and reporting intraclass correlation coefficients. *Journal of Chiropractic Medicine* 15, 155–163, 2016.
- Lambin, P. et al. Radiomics: the bridge between medical imaging and personalized medicine. *Nature Reviews Clinical Oncology* 14, 749–762, 2017.
- Suter, Y. et al. The LUMIERE dataset. *Scientific Data* 9, 768, 2022.
- van Griethuysen, J. J. M. et al. Computational radiomics system to decode the radiographic phenotype. *Cancer Research* 77, e104–e107, 2017.
- Zwanenburg, A. et al. The image biomarker standardization initiative. *Radiology* 295, 328–338, 2020.