

Métodos de Clustering basados en K-Means

- 1 Aprendizaje No-Supervisado
- 2 Clustering basado en representantes
- 3 Algoritmo Kernel K-Means
- 4 Clustering Spectral

Aprendizaje No-Supervisado

- Existen muchas bases de datos no etiquetadas
 - Muchos registros → dificultad para etiquetado manual
 - Subjetividad en etiquetado humano es otro problema
 - Costo de tener expertxs etiquetando es alto
- No-Supervisado significa que no hay “**Instructor**” en forma de etiquetas de clase para cada observación o registro


El problema de Clustering

El objetivo de la tarea de Clustering consiste en agrupar objetos similares y separarlos de aquellos “disimiles”


Enfoque empleado exitosamente en diversos dominios tales como:

- Genómica
- Imágenes médicas
- Sistemas recomendadores
- Segmentación de mercado

Ejemplo 1: Identificación de ROI




(a)




(b)

Ejemplo 2: Segmentación de clientes



Ejemplo 3: Grupos en red de enfermedades



<https://studentwork.prattsi.org/infovis/visualization/networks-human-disease/>

Métodos de Clustering

- Sin etiquetas, es necesario hacer algunos supuestos para definir qué propiedades son deseables en un grupo y cuando dos objetos serán considerados como similares
- Existen dos tipos de métodos de Clustering: Particionales y Jerárquicos.
- En este Curso haremos un mayor incapié en los particionales

Clustering basado en representantes

- Dado un conjunto de datos con n puntos en un espacio d -dimensional, $\mathcal{D} = \{\mathbf{x}_j\}_{j=1}^n$
- Dado también $k \in \mathbb{Z}$, el número de grupos a encontrar en $\mathcal{D}$
- El **objetivo** de la tarea es particionar $\mathcal{D}$ en k grupos o *clusters*, representados como $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$
- Luego, para cada cluster C_i existe un punto representativo μ_i
 - Comúnmente se le denomina centroide y corresponde a

$$\mu_i = \frac{1}{|C_i|} \sum_{\mathbf{x}_j \in C_i} \mathbf{x}_j$$

Método de Fuerza bruta

Una posible solución a este problema consiste en

- ① Generar todas las posibles particiones de n puntos en k grupos, $\binom{n}{k}$
- ② Para cada una, evaluar alguna puntuación que favorezca *ciertas propiedades*
 - Podría usarse

$$SSE(\mathcal{C}) = \sum_{i=1}^k \sum_{\mathbf{x}_j \in C_i} \|\mathbf{x}_j - \mu_i\|^2$$

- ③ Reportar aquella partición con la mejor puntuación, es decir

$$\mathcal{C}^* = \underset{\mathcal{C}}{\operatorname{argmin}} SSE(\mathcal{C})$$

Problema $\mathcal{O}(k^n/k!)$ posibles soluciones ...

Algoritmo K-Means

- K-Means utiliza una estrategia *Greedy* e iterativa para encontrar $\mathcal{C}^*$
 - 1 Inicializa los centroides al azar, generando k puntos en $\mathbb{R}^d$
 - 2 Comienza a iterar y en cada iteración realiza dos pasos: Asignación a un grupo y actualización de centroides
 - 3 Cada punto es asignado al grupo asociado al centroide más cercano.
 - 4 Se actualizan los centroides, calculando nuevamente las medias sobre los puntos asignados en el paso anterior.
 - 5 Al alcanzarse una cierta cantidad de iteraciones, no haber cambios en las asignaciones o bien, no encontrarse cambios significativos, el método termina.

K-MEANS ($\mathbf{D}, k, \epsilon$):

```
1  $t = 0$ 
2 Randomly initialize  $k$  centroids:  $\mu_1^t, \mu_2^t, \dots, \mu_k^t \in \mathbb{R}^d$ 
3 repeat
4    $t \leftarrow t + 1$ 
5    $C_j \leftarrow \emptyset$  for all  $j = 1, \dots, k$ 
   // Cluster Assignment Step
6   foreach  $\mathbf{x}_j \in \mathbf{D}$  do
7      $j^* \leftarrow \operatorname{argmin}_i \left\{ \|\mathbf{x}_j - \mu_i^t\|^2 \right\}$  // Assign  $\mathbf{x}_j$  to closest centroid
8      $C_{j^*} \leftarrow C_{j^*} \cup \{\mathbf{x}_j\}$ 
   // Centroid Update Step
9   foreach  $i = 1$  to  $k$  do
10     $\mu_i^t \leftarrow \frac{1}{|C_i|} \sum_{\mathbf{x}_j \in C_i} \mathbf{x}_j$ 
11 until  $\sum_{i=1}^k \|\mu_i^t - \mu_i^{t-1}\|^2 \leq \epsilon$ 
```

Algoritmo Kernel K-Means

- K-means realiza una separación en el espacio original de características de los datos
- El uso del *Kernel Trick* puede ayudar a construir grupos usando transformaciones no-lineales de este espacio

- Se mapea cada $\mathbf{x}_j \in \mathcal{C}$ mediante $\phi(\mathbf{x}_j)$
- Una función de kernel $\mathbf{K}$ es aplicada sobre cada par de puntos,
 $\mathbf{K}(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$
- Se aplica K-Means en este nuevo espacio
- La nueva función objetivo en el espacio de características es:

$$\min_{\mathcal{C}} SSE(\mathcal{C}) = \sum_{i=1}^k \sum_{\mathbf{x}_j \in C_i} \|\phi(\mathbf{x}_j) - \mu_i^\phi\|^2$$

$$\min_{\mathcal{C}} SSE(\mathcal{C}) = \sum_{j=1}^n \mathbf{K}(\mathbf{x}_j, \mathbf{x}_j) - \sum_{i=1}^k \frac{1}{|C_i|} \sum_{\mathbf{x}_p \in C_i} \sum_{\mathbf{x}_q \in C_i} \mathbf{K}(\mathbf{x}_p, \mathbf{x}_q)$$

KERNEL-KMEANS($\mathbf{K}, k, \epsilon$):

```
1  $t \leftarrow 0$ 
2  $\mathcal{C}^t \leftarrow \{C_1^t, \dots, C_k^t\}$  // Randomly partition points into  $k$  clusters
3 repeat
4    $t \leftarrow t + 1$ 
5   foreach  $C_i \in \mathcal{C}^{t-1}$  do // Squared norm of cluster means
6      $\text{sqnorm}_i \leftarrow \frac{1}{n_i^2} \sum_{\mathbf{x}_a \in C_i} \sum_{\mathbf{x}_b \in C_i} K(\mathbf{x}_a, \mathbf{x}_b)$ 
7   foreach  $\mathbf{x}_j \in \mathbf{D}$  do // Average kernel value for  $\mathbf{x}_j$  and  $C_i$ 
8     foreach  $C_i \in \mathcal{C}^{t-1}$  do
9        $\text{avg}_{ji} \leftarrow \frac{1}{n_i} \sum_{\mathbf{x}_a \in C_i} K(\mathbf{x}_a, \mathbf{x}_j)$ 
10    // Find closest cluster for each point
11    foreach  $\mathbf{x}_j \in \mathbf{D}$  do
12      foreach  $C_i \in \mathcal{C}^{t-1}$  do
13         $d(\mathbf{x}_j, C_i) \leftarrow \text{sqnorm}_i - 2 \cdot \text{avg}_{ji}$ 
14         $j^* \leftarrow \arg \min_i \{d(\mathbf{x}_j, C_i)\}$ 
15         $C_{j^*}^t \leftarrow C_{j^*}^t \cup \{\mathbf{x}_j\}$  // Cluster reassignment
16   $\mathcal{C}^t \leftarrow \{C_1^t, \dots, C_k^t\}$ 
17 until  $1 - \frac{1}{n} \sum_{i=1}^k |C_i^t \cap C_i^{t-1}| \leq \epsilon$ 
```

Vista general del método

- ① Pre-procesamiento: Construir una representación de grafo (matriz)
- ② Descomposición:
 - Calcular los valores y vectores propios de la matriz
 - Mapear cada punto en $\mathcal{D}$ a una representación vectorial basado en uno o más vectores propios
- ③ Agrupar
 - Asignar todos los puntos a 2 o más grupos, usando la nueva representación vectorial

Particionamiento espectral de un grafo



- Dado un grafo $G = (V, E)$, con $V = \{1, 2, \dots, n\}$ y $E : V \times V \rightarrow \{0, 1\}$
- A : Matriz de adyacencia de un grafo no dirigido que codifica los vecindarios de cada nodo en G
 - $A_{ij} = 1$ cuando existe conexión entre instancias i y j . 0 en otro caso.
 - Simétrica
 - Tiene n valores propios
 - Vectores propios reales y ortogonales
- D : Matriz de grados
 - $D = [d_{ii}]$, donde d_{ii} es el grado del nodo i
 - Es diagonal

Laplaciano

- $L = D - A$: Matriz Laplaciano
- Todos sus valores propios son ≥ 0
- $xLx = \sum_{ij} L_{ij}x_ix_j \geq 0$ para todo x
- Multiplicidad del primer valor propio es igual al número de componentes conectados
- Si vértices i y j están conectados en el grafo, en algún vector propio asociado al primer valor propio las componentes i y j serán 1


Clustering

- El segundo valor propio es clave
- El vector propio de este segundo valor será usado para encontrar los grupos
- **Obj.** Minimizar la cantidad de arcos de una partición a otra.
- Este vector es real, no tiene etiquetas $\{-1, +1\}$
 - Puede usarse la función signo



¿Cómo generar más de 2 clusters?

- Tomar los k vectores propios asociados a los valores propios más pequeños
- Esta matriz de $n \times k$ es entregada a otro método (e.g. K-Means)



- **Adyacencia**

$$\begin{bmatrix} 0 & 1 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 1 & 0 \end{bmatrix}$$

- **Grado**

$$\begin{bmatrix} 3 & 0 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 \end{bmatrix}$$

Las otras matrices ...

- $L = D - A$

- **Laplaciano**

$$\begin{bmatrix} 3 & -1 & -1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 \\ -1 & -1 & 3 & 0 & -1 & 0 \\ -1 & 0 & 0 & 3 & -1 & -1 \\ 0 & 0 & -1 & -1 & 3 & -1 \\ 0 & 0 & 0 & -1 & -1 & 2 \end{bmatrix}$$

- **Valores propios**

$$\begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 4 & 0 \\ 0 & 0 & 0 & 0 & 0 & 5 \end{bmatrix}$$

- **Vectores propios**

$$\begin{bmatrix} -0.408 & 0.289 & 0 & -0.577 & -0.408 & 0.5 \\ -0.408 & 0.577 & 0.5 & 0.289 & 0.408 & 0 \\ -0.408 & 0.289 & -0.5 & 0.289 & -0.408 & -0.5 \\ -0.408 & -0.289 & 0 & -0.577 & 0.408 & -0.5 \\ -0.408 & -0.289 & -0.5 & 0.289 & 0.408 & 0.5 \\ -0.408 & -0.577 & 0.5 & 0.289 & -0.408 & 0 \end{bmatrix}$$

Datos proyectados sobre los vectores propios

$$\begin{pmatrix} -0.408 & 0.289 & 0 & -0.577 & -0.408 & 0.5 \\ -0.408 & 0.577 & 0.5 & 0.289 & 0.408 & 0 \\ -0.408 & 0.289 & -0.5 & 0.289 & -0.408 & -0.5 \\ -0.408 & -0.289 & 0 & -0.577 & 0.408 & -0.5 \\ -0.408 & -0.289 & -0.5 & 0.289 & 0.408 & 0.5 \\ -0.408 & -0.577 & 0.5 & 0.289 & -0.408 & 0 \end{pmatrix}$$

