



Magíster en Estadística, PUCV

Regresión lineal: del ajuste a la regularización

Alejandro Veloz

El problema fundamental

Dado un conjunto de entrenamiento $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^I$, encontrar una función f que


1. ajuste bien los datos observados, y
2. generalice a datos que no hemos visto.

Los dos objetivos están en **tensión**. Casi todo lo que veremos hoy es una manera de administrar esa tensión.

La historia en tres preguntas

1. ¿Cuándo mínimos cuadrados funciona? - el régimen sano.
2. ¿Cuándo no funciona? - tres fallas, una sola enfermedad.
3. ¿Cómo se arregla? - con regularización.

El caso típico: un regresor



$I = 25$ observaciones, modelo $f[x, \phi] = \phi_0 + \phi_1 x$. Mínimos cuadrados minimiza la suma de **residuos** al cuadrado (segmentos grises). b) Reajustando sobre 100 datasets nuevos: las estimaciones casi no se mueven.

Mínimos cuadrados: forma general

Con D regresores $\mathbf{z}[x] = [1, z_1[x], \dots, z_D[x]]^\top$, el modelo es

$$f[x, \phi] = \phi^\top \mathbf{z}[x], \quad L[\phi] = \sum_{i=1}^I (f[x_i, \phi] - y_i)^2 = \|\mathbf{Z}\phi - \mathbf{y}\|^2$$

$$\hat{\phi} = \underset{\phi}{\operatorname{argmin}} L[\phi] = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}$$

Mínimo global, en una sola resolución lineal - siempre que $\mathbf{Z}^\top \mathbf{Z}$ sea invertible.

¿De dónde sale la pérdida cuadrática?


Hasta aquí *elegimos* minimizar cuadrados. También podemos **derivarlo**, modelando el ruido.

Supongamos que la observación es la salida del modelo más ruido gaussiano:

$$p(y \mid x, \phi, \sigma^2) = \text{Norm}[y \mid f[x, \phi], \sigma^2]$$

El modelo ya no predice un número - predice una **distribución** sobre y : su media es $f[x, \phi]$ y su ancho es la incertidumbre σ .

El modelo de ruido gaussiano



La curva cian es la **media** de y en cada x ; las campanas rojas son la predicción de verdad: una **distribución** $\text{Pr}(y | x_0)$ en cada posición. La banda gris ($\pm 2\hat{\sigma}$) es donde el modelo afirma que debería caer $\sim 95\%$ de las observaciones.

La función de verosimilitud



Para I observaciones independientes, la probabilidad de los datos es el producto:

$$p(\mathbf{y} \mid \mathbf{x}, \boldsymbol{\phi}, \sigma^2) = \prod_{i=1}^I \text{Norm}[y_i \mid f[x_i, \boldsymbol{\phi}], \sigma^2]$$

Leída como **función de $\boldsymbol{\phi}$** con los datos fijos, esta es la **función de verosimilitud**.

Nota: no es una densidad sobre $\boldsymbol{\phi}$ - no integra uno. Solo **ordena** los valores de los parámetros según qué tan bien explican los datos.

Dos lecturas de la misma expresión



- a) Con ϕ fijo, variando y : una **densidad** - no negativa, integra 1.
- b) Con los datos fijos, variando ϕ : la **verosimilitud** - sus contornos sobre (ϕ_0, ϕ_1) .
El máximo (estrella) es **exactamente la solución de mínimos cuadrados**. No integra 1: solo **ordena** los parámetros.

Máxima verosimilitud = mínimos cuadrados

Maximizamos el logaritmo - convierte el producto en suma y no mueve el máximo:

$$\ln p(\mathbf{y} \mid \mathbf{x}, \boldsymbol{\phi}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^I (f[x_i, \boldsymbol{\phi}] - y_i)^2 - \frac{I}{2} \ln(2\pi\sigma^2)$$

El segundo término no depende de $\boldsymbol{\phi}$, y $1/2\sigma^2$ es una constante positiva. Entonces:

$$\operatorname{argmax}_{\boldsymbol{\phi}} \ln p(\mathbf{y} \mid \mathbf{x}, \boldsymbol{\phi}, \sigma^2) = \operatorname{argmin}_{\boldsymbol{\phi}} \sum_{i=1}^I (f[x_i, \boldsymbol{\phi}] - y_i)^2$$

Mínimos cuadrados es máxima verosimilitud bajo ruido gaussiano. Y la varianza del ruido se determina de la expresión: $\hat{\sigma}^2 = \frac{1}{I} \sum_i (f[x_i, \hat{\boldsymbol{\phi}}] - y_i)^2$.

Una receta, muchas pérdidas

elegir $p(y \mid x, \phi) \longrightarrow$ pérdida $= -\ln p \longrightarrow$ minimizar

Supuesto sobre el ruido	$-\ln p$	Se conoce como
gaussiano (colas livianas)	$\sum_i (f[x_i, \phi] - y_i)^2$	pérdida cuadrática (OLS)
Laplace (colas pesadas, outliers)	$\sum_i f[x_i, \phi] - y_i $	pérdida absoluta (robusta)

La elección de una función de pérdida corresponde a nuestro supuesto sobre el ruido. Y la misma receta, con un prior sobre ϕ , va a producir la regularización.

El régimen sano: mínimos cuadrados funciona

Cuando (i) las observaciones son muchas comparadas con los parámetros ($I \gg D$) y (ii) los regresores están **bien condicionados** (ninguno casi redundante con otro):

- ▶ $\hat{\phi}$ es **insesgado**: en promedio sobre datasets, acierta a los parámetros verdaderos.
- ▶ Su varianza es pequeña - el panel (b) estable de la primera figura.
- ▶ **Teorema de Gauss–Markov**: entre todos los estimadores lineales insesgados, mínimos cuadrados tiene la **menor varianza**.

En este régimen, la regularización es innecesaria - solo podría agregar sesgo.

¿Cuándo necesita regularización la regresión lineal?

Tres maneras de salir del régimen sano:

Falla 1

Regresores correlacionados
dos columnas de Z llevan casi la misma información

Falla 2



Bases flexibles
polinomios, splines... la capacidad crece, los datos no

Falla 3

Demasiados parámetros
 $D + 1$ se acerca a I : el ajuste interpola los datos

Son causas del mismo fenómeno.

Falla 1: regresores correlacionados



Modelo verdadero $y = z_1 + z_2 + \varepsilon$, pero $z_2 \approx z_1$ (correlación 0,995). Los datos solo restringen la **suma** $\phi_1 + \phi_2$; la diferencia queda casi libre $\rightarrow$ las estimaciones MCO (gris) se dispersan a lo largo de $\phi_1 + \phi_2 = 2$. **Ridge** (cian, adelante de la cura) las fija cerca de la verdad.

Falla 2: bases flexibles

Para ajustar datos curvos expandimos los regresores con **funciones base**:

$$f[x, \phi] = \phi_0 + \sum_{j=1}^D \phi_j z_j[x], \quad z_j[x] = \text{polinomio de grado } j$$


Sigue siendo **lineal en ϕ** - misma solución cerrada.

Capacidad del modelo = número de funciones base D .

Nota: en un dominio acotado, los polinomios de grado alto **se parecen cada vez más entre sí** - las columnas vecinas de $\mathbf{Z}$ se vuelven casi redundantes.

La falla 2 es la falla 1 disfrazada.

Falla 2: de subajuste a sobreajuste



$I = 15$ muestras ruidosas de una función cuasi-sinusoidal. El grado 1 no puede representarla (**subajuste**). El grado 4 captura la estructura. El grado 14 pasa cerca de todos los puntos pero oscila entre ellos (**sobreajuste**).

El sobreajuste visto en los coeficientes

Coeficientes ajustados (base monomial $1, x, x^2, \dots$) sobre los mismos $I = 15$ datos:

	$D = 1$	$D = 4$	$D = 14$
$\hat{\phi}_0$	0,91	0,13	3,68
$\hat{\phi}_1$	-1,70	7,09	-762,31
$\hat{\phi}_2$		-13,54	30 689,53
$\hat{\phi}_3$		-9,49	-560 842,61
$\hat{\phi}_4$		16,35	5 867 159,80
$\vdots$			$\vdots$
$\hat{\phi}_{14}$			42 064 369,30

El sobreajuste se manifiesta como coeficientes enormes de signo alternado, que se cancelan entre sí para enhebrar la curva por cada punto.

Falla 3: tantos parámetros como observaciones

Falla 2 al límite: $D + 1 = I$.

- ▶ Z se vuelve **cuadrada** - el ajuste pasa por **todos** los puntos de entrenamiento.
- ▶ Error de entrenamiento: 0. Valor predictivo de ese número: también ≈ 0 .
- ▶ Los coeficientes necesarios para contorsionarse por cada punto ruidoso son **enormes** - como en la tabla anterior.

¿Y más allá? Para $D + 1 > I$ el sistema queda indeterminado: **infinitas** soluciones ajustan los datos perfectamente. ¿Cuál elegir?

Una sola enfermedad: $\mathbf{Z}^\top \mathbf{Z}$ mal condicionada

Las tres fallas son el mismo evento matemático:


- ▶ **Regresores correlacionados:** dos columnas de $\mathbf{Z}$ casi paralelas.
- ▶ **Bases flexibles:** muchas columnas casi redundantes.
- ▶ $D + 1 \rightarrow I$: tantas direcciones que fijar como ecuaciones disponibles.

En todos los casos, algunas direcciones del espacio de parámetros quedan apenas restringidas por los datos: $\mathbf{Z}^\top \mathbf{Z}$ se vuelve casi singular, y la estimación en esas direcciones la decide el ruido.

El resultado no es sesgo - es **varianza**: estimaciones de alto valor e inestables.

Para hacer esto preciso (y medible), necesitamos el lenguaje de la **generalización**.

Medir el daño: un experimento controlado



Para **medir** la generalización
construimos un mundo donde
conocemos la verdad:


$$y = \mu[x] + \varepsilon, \quad \varepsilon \sim \text{Norm}[0, \sigma^2]$$

Para cada x hay una distribución
 $\Pr(y \mid x)$ con media

$$\mu[x] = \mathbb{E}_y[y[x]]$$

y ruido $\sigma^2 = \mathbb{E}_y[(\mu[x] - y[x])^2]$.
Entrenamiento: $\mathcal{D} = \{x_i, y_i\}_{i=1}^I$,
más un conjunto de **test** separado del
mismo proceso.

Error de entrenamiento vs. error de test




El error de entrenamiento **decrece monótonamente** con la capacidad - cero en grado 14 (interpolación).

El de test primero baja, luego **sube**: el modelo deja de aprender estructura y empieza a ajustar ruido.

Ni el mejor modelo puede vencer el **piso de ruido σ^2** : el error irreducible.

La brecha entre las curvas es la **brecha de generalización**.

Fuentes de error: ruido, sesgo y varianza



- a) **Ruido**: hasta la función verdadera deja error residual en datos de test.
- b) **Sesgo**: un modelo de grado 2 no puede representar la función verdadera, ni con los mejores parámetros posibles.
- c) **Varianza**: con $I = 15$ puntos ruidosos, cada dataset da un ajuste de grado 6 distinto (gris: ± 2 desv. est. de los ajustes).

Formulación matemática del error de test

Pérdida cuadrática entre la predicción $f[x, \phi]$ y la observación $y[x]$:

$$\begin{aligned} L[x] &= (f[x, \phi] - y[x])^2 \\ &= ((f[x, \phi] - \mu[x]) + (\mu[x] - y[x]))^2 \\ &= (f[x, \phi] - \mu[x])^2 + 2(f[x, \phi] - \mu[x])(\mu[x] - y[x]) \\ &\quad + (\mu[x] - y[x])^2 \end{aligned}$$

Sumamos y restamos la media verdadera $\mu[x]$, y expandimos el cuadrado.

Esperanza sobre el ruido de test

Tomando la esperanza sobre el ruido de observación y :

$$\begin{aligned}\mathbb{E}_y[L[x]] &= (f[x, \phi] - \mu[x])^2 + 2(f[x, \phi] - \mu[x])(\underbrace{\mu[x] - \mathbb{E}_y[y[x]]}_{\mu[x]}) \\ &\quad + \mathbb{E}_y[(\mu[x] - y[x])^2] \\ &= (f[x, \phi] - \mu[x])^2 + 2(f[x, \phi] - \mu[x]) \cdot 0 + \mathbb{E}_y[(\mu[x] - y[x])^2] \\ &= (f[x, \phi] - \mu[x])^2 + \sigma^2 \rightarrow \text{ruido}\end{aligned}$$

El **primer término** se puede particionar aún más: en sesgo y varianza.

Los parámetros dependen del conjunto de entrenamiento

$\hat{\phi}$ se aprende de $\mathcal{D} = \{x_i, y_i\}$, así que es un **vector aleatorio**: otra muestra de entrenamiento da otros parámetros. En regresión lineal:

$$\hat{\phi}[\mathcal{D}] = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}, \quad \mathbf{y} \text{ es ruidoso} \Rightarrow \hat{\phi} \text{ es ruidoso.}$$

Modelo esperado sobre todos los conjuntos de entrenamiento posibles:

$$f_\mu[x] = \mathbb{E}_{\mathcal{D}} [f[x, \hat{\phi}[\mathcal{D}]]]$$

Sumando y restando $f_\mu[x]$ dentro de $(f[x, \hat{\phi}] - \mu[x])^2$ y tomando $\mathbb{E}_{\mathcal{D}}$, se separa en dos términos (el cruzado se anula de nuevo).

Descomposición sesgo-varianza

Combinando todos los términos:

$$\mathbb{E}_{\mathcal{D}} [\mathbb{E}_y[L[x]]] = \underbrace{\mathbb{E}_{\mathcal{D}} \left[\left(f[x, \hat{\phi}[\mathcal{D}]] - f_{\mu}[x] \right)^2 \right]}_{\text{varianza}} + \underbrace{\left(f_{\mu}[x] - \mu[x] \right)^2}_{\text{sesgo}^2} + \underbrace{\sigma^2}_{\text{ruido}}$$

- ▶ **[reducible] Varianza:** dispersión del modelo ajustado entre conjuntos de entrenamiento.
- ▶ **[reducible] Sesgo:** brecha sistemática entre el ajuste promedio y la verdad.
- ▶ **[irreducible] Ruido:** aleatoriedad inherente del mapeo entrada-salida.

La varianza en forma cerrada

Si la familia del modelo contiene la verdad, $\hat{\phi}$ es insesgado y


$$\text{Cov}[\hat{\phi}] = \sigma^2 (\mathbf{Z}^\top \mathbf{Z})^{-1} \Rightarrow \text{var}[f[x, \hat{\phi}]] = \sigma^2 \mathbf{z}[x]^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}[x]$$

Promediando la varianza sobre las entradas de entrenamiento:

$$\frac{1}{I} \sum_{i=1}^I \text{var}[f[x_i, \hat{\phi}]] = \frac{\sigma^2}{I} \text{tr}[\mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top] = \sigma^2 \frac{D+1}{I}$$


La varianza crece **linealmente con la capacidad D** y decrece como **$1/I$ con los datos** - y explota cuando $(\mathbf{Z}^\top \mathbf{Z})^{-1}$ explota: **nuestras tres fallas, cuantificadas.**

Reducir la varianza: más datos



Modelo de grado 6 ajustado a 150 conjuntos de entrenamiento independientes de cada tamaño. La banda gris (± 2 desv. est. de los ajustes) se encoge al crecer I - exactamente la predicción $\sigma^2(D + 1)/I$.

Más datos también curan el sobreajuste



El mismo modelo de grado 14. Con $I = 15$ interpola y oscila; con $I = 100$ es un ajuste perfectamente razonable. El sobreajuste no es una propiedad del modelo: es una propiedad del modelo *en relación con* la cantidad de datos.

Reducir el sesgo: más capacidad... con un precio

El sesgo se reduce haciendo el modelo **más flexible** (mayor grado D): una base polinomial suficientemente rica aproxima cualquier función continua.


Pero acabamos de calcular el efecto secundario:

$$\text{varianza promedio} = \sigma^2 \frac{D + 1}{I}$$

Con datos fijos, aumentar la capacidad aumenta la varianza.

⇒ aumentar la capacidad **no** necesariamente reduce el error de test: el **compromiso sesgo-varianza**.

El compromiso sesgo-varianza



Sesgo² y varianza calculados ajustando 400 conjuntos de entrenamiento independientes ($I = 15$) por grado, comparando contra la $\mu[x]$ conocida.

El sesgo **cae** con la capacidad; la varianza **sube** (linealmente, como predijimos).

El error de test esperado total:

$$\text{sesgo}^2 + \text{varianza} + \sigma^2$$

se minimiza en una **capacidad intermedia**.

Elegir la capacidad sin conocer la verdad

En la práctica no podemos ver el sesgo ni la varianza por separado. En su lugar, **apartamos datos**:

Entrenar: ajustar cada candidato ($D = 0, 1, 2, \dots$) con el conjunto de entrenamiento.

Validar: evaluar en el conjunto de validación.

Seleccionar: quedarse con el mejor **desempeño de validación**.

Test: evaluar el modelo final una sola vez.

Nunca usar el test para seleccionar.

Con pocos datos, **validación cruzada de k pliegues**:

- ▶ partir los datos en k pliegues,
- ▶ entrenar con $k - 1$, validar con el restante,
- ▶ rotar, y promediar los k errores de validación.


Validación cruzada, visualmente

pliegue 1	valida	entrena	entrena	entrena	entrena
pliegue 2	entrena	valida	entrena	entrena	entrena
pliegue 3	entrena	entrena	valida	entrena	entrena
pliegue 4	entrena	entrena	entrena	valida	entrena
pliegue 5	entrena	entrena	entrena	entrena	valida

$$\text{CV}[\lambda] = \frac{1}{I} \sum_{i=1}^I \left(y_i - \mathbf{f}^{-\kappa(i)}[x_i; \lambda] \right)^2$$

$\mathbf{f}^{-\kappa(i)}$: el modelo entrenado **sin el pliegue $\kappa(i)$** que contiene a la observación i . Cada dato valida exactamente una vez, y **nunca valida al modelo que lo vio**.

Validación cruzada: elegir el grado



Error de validación cruzada (5 pliegues) para grados 0-18 ($I = 30$).

La curva de CV reproduce la forma de U del error de test (inobservable), y elige un grado sensato - usando solo datos de entrenamiento.

Hasta aquí, la capacidad es nuestra única "perilla": un entero, D .

La regularización nos dará una "perilla" continua.

Regularización

Mantener el modelo flexible, pero **penalizar** las configuraciones de parámetros que los datos apenas restringen:

$$\hat{\phi} = \underset{\phi}{\operatorname{argmin}} \left[\underbrace{\|\mathbf{Z}\phi - \mathbf{y}\|^2}_{\text{ajustar los datos}} + \underbrace{\lambda g[\phi]}_{\text{mantenerse razonable}} \right]$$

$g[\phi]$ es grande para parámetros poco preferidos; $\lambda \geq 0$ negocia ajuste contra preferencia.

- ▶ $\lambda = 0$: de vuelta a mínimos cuadrados.
- ▶ $\lambda \rightarrow \infty$: gana la preferencia; los datos se ignoran.
- ▶ Entre medio: una **perilla continua de capacidad efectiva**.

Penalización L2 = regresión ridge

La elección más común penaliza la norma cuadrada de los pesos:

$$\hat{\phi} = \underset{\phi}{\operatorname{argmin}} \left[\|\mathbf{Z}\phi - \mathbf{y}\|^2 + \lambda \sum_{j \geq 1} \phi_j^2 \right]$$

(el intercepto ϕ_0 usualmente no se penaliza).

$$\hat{\phi}_{\text{ridge}} = (\mathbf{Z}^\top \mathbf{Z} + \lambda \mathbf{I})^{-1} \mathbf{Z}^\top \mathbf{y}$$

Regresión ridge / regularización de Tikhonov - el ancestro del “weight decay” de las redes neuronales.

$\mathbf{Z}^\top \mathbf{Z} + \lambda \mathbf{I}$ es siempre invertible.

Qué hace ridge, modo a modo


Con la SVD $\mathbf{Z} = \mathbf{U}\mathbf{S}\mathbf{V}^\top$ (valores singulares $s_1 \geq s_2 \geq \dots$):

$$\text{MCO: } \hat{\phi} = \sum_i \frac{1}{s_i} \mathbf{v}_i (\mathbf{u}_i^\top \mathbf{y}) \quad \text{ridge: } \hat{\phi}_{\text{ridge}} = \sum_i \frac{s_i}{s_i^2 + \lambda} \mathbf{v}_i (\mathbf{u}_i^\top \mathbf{y})$$

- Direcciones con s_i grande (bien determinadas por los datos): casi intactas.
- Direcciones con s_i chico (mal determinadas, dominadas por ruido): fuertemente encogidas hacia cero.


Ridge filtra el modelo según cuánta evidencia aportan los datos para cada dirección. Entra un poco de sesgo, sale mucha varianza.

Ajustes ridge al crecer λ



Modelo de grado 14, $I = 15$ - el desastre interpolante de las fallas 2/3. λ chico: aún sobreajusta. λ intermedio: suave y cerca de la verdad. λ grande: la penalización aplasta a los datos (subajuste).

Elegir λ : validación cruzada



Error de validación cruzada (5 pliegues) para el modelo ridge de grado 14, en función de λ .

Poca regularización $\rightarrow$ domina la varianza (meseta izquierda: el ajuste interpolante).

Demasiada $\rightarrow$ domina el sesgo (subida derecha).

λ^* en el mínimo - **sin tocar jamás el test.**

¿De dónde sale la penalización? El prior

Ya sabemos que mínimos cuadrados = máxima verosimilitud. Agregando un **prior** $\Pr(\phi)$, el criterio **máximo a posteriori (MAP)**:

$$\hat{\phi} = \underset{\phi}{\operatorname{argmax}} \left[\Pr(\phi) \prod_{i=1}^I \Pr(y_i \mid x_i, \phi) \right] \quad \lambda g[\phi] = -\ln \Pr(\phi)$$

Prior gaussiano

$$\phi_j \sim \text{Norm}[0, \sigma_{\phi}^2]:$$

Prior de Laplace


$$\Pr(\phi_j) \propto e^{-|\phi_j|/b}:$$

$$\Rightarrow \text{ridge, con } \lambda = \frac{\sigma^2}{\sigma_{\phi}^2}$$

$\Rightarrow$ lasso (penalización L1)

λ es el cociente entre lo que **creemos** (σ_{ϕ}^2) y lo que **observamos** (σ^2).

Ridge encoge, lasso selecciona



Trayectorias de los coeficientes de un modelo de grado 10 al crecer λ . Ridge encoge todos los coeficientes **suavemente hacia** cero; lasso los lleva **exactamente a** cero uno por uno - selección automática de regresores.

Regularizadores “disfrazados”

Las penalizaciones explícitas no son la única manera de romper el empate entre soluciones.

Cualquier factor que sesgue el ajuste hacia un subconjunto de las soluciones con pérdida similar actúa como **regularizador**, lo hayamos incorporado en el costo o no.

Vienen cuatro disfraces, cada uno **demostrablemente equivalente** (en regresión lineal) a algo que ya vimos:

1. el **optimizador** mismo (descenso de gradiente),
2. **parar temprano** (early stopping),
3. **promediar modelos** (bagging),
4. **agregar ruido a los datos** (aumento).

El optimizador - descenso de gradiente

Nada impide entrenar la regresión lineal con descenso de gradiente:

$$\phi_{t+1} = \phi_t - \alpha \mathbf{Z}^\top (\mathbf{Z} \phi_t - \mathbf{y}), \quad \phi_0 = \mathbf{0}$$

En la base de la SVD, cada modo evoluciona **independientemente**:

$$\mathbf{v}_i^\top \phi_t = \frac{1 - (1 - \alpha s_i^2)^t}{s_i} (\mathbf{u}_i^\top \mathbf{y})$$

- ▶ s_i **grande**: converge rápido - se aprende primero.
- ▶ s_i **chico** (dominado por ruido): converge lento - se aprende al final.

GD inicializado en $\mathbf{0}$ nunca sale del espacio fila de $\mathbf{Z} \rightarrow$ en el régimen sobre-parametrizado converge exactamente a la **solución de norma mínima**.

Early stopping $\approx$ ridge



Comparemos el factor de encogimiento de cada modo:

$$\text{GD en el paso } t : 1 - (1 - \alpha s_i^2)^t \qquad \text{ridge : } \frac{s_i^2}{s_i^2 + \lambda}$$

Ambos conservan los modos de s_i grande y suprimen los de s_i chico.


Detener el descenso de gradiente en la iteración t actúa como ridge
con $\lambda \approx \frac{1}{\alpha t}$: **entrenar más tiempo = regularizar menos.**

Early stopping



GD sobre el modelo de grado 14. a) El error de entrenamiento decrece monótonamente; el de test tiene un mínimo. b) A lo largo de la trayectoria el ajuste primero captura la estructura gruesa, luego sobreajusta - el mejor modelo aparece **a mitad del entrenamiento**, no al converger.

Promediar modelos - bagging



Modelo de grado 9, $I = 15$. Re-muestrear el entrenamiento con reemplazo (bootstrap) 20 veces, ajustar cada réplica, y **promediar las predicciones**. Los ajustes individuales (gris) varían salvajemente - su promedio (cian) es más suave: **promediar ataca directamente el término de varianza**.


Ruido en las entradas = ridge (exactamente)

Perturbamos cada entrada con $\varepsilon \sim \text{Norm}[0, \sigma_x^2]$ en cada iteración, para la regresión lineal simple $f[x, \phi] = \phi_0 + \phi_1 x$. Escribiendo el residuo $r_i = \phi_0 + \phi_1 x_i - y_i$:

$$\begin{aligned}\mathbb{E}_\varepsilon \left[(r_i + \phi_1 \varepsilon)^2 \right] &= r_i^2 + 2 \phi_1 r_i \underbrace{\mathbb{E}_\varepsilon[\varepsilon]}_0 + \phi_1^2 \underbrace{\mathbb{E}_\varepsilon[\varepsilon^2]}_{\sigma_x^2} \\ &= r_i^2 + \sigma_x^2 \phi_1^2\end{aligned}$$

Pérdida esperada = pérdida original + $\sigma_x^2 \sum_{j \geq 1} \phi_j^2 \rightarrow$ **aumentar los datos con ruido en la entrada es regularización L2** con $\lambda = \sigma_x^2$.

Ruido en las entradas




Modelo de grado 14 entrenado con 200 copias ruidosas de cada entrada. Más ruido en la entrada $\rightarrow$ ajuste más suave, exactamente como subir λ en ridge.

Los cuatro disfraces, desenmascarados

Disfraz	Equivale a	Mecanismo
descenso de gradiente desde 0 parar temprano en t bagging ruido en las entradas	solución de norma mínima ridge con $\lambda \approx 1/(\alpha t)$ — (ataca la varianza directo) exactamente ridge, $\lambda = \sigma_x^2$	modos aprendidos por evidencia modos lentos nunca aprendidos promediar cancela el ruido función más suave
L2 explícita (ridge)	MAP, prior gaussiano	encoge modos ruidosos
L1 explícita (lasso)	MAP, prior de Laplace	sparsity / selección

En deep learning las mismas ideas reaparecen como weight decay, early stopping, ensembles, dropout y aumentación - allá como heurísticas, acá como **teoremas**.

Epílogo: ¿y si interpolamos de todos modos?



De vuelta a la falla 3. Regresión lineal sobre p features aleatorias de Fourier $z_j[x] = \cos(\omega_j x + b_j)$, $I = 20$. Para $p > I$, entre las infinitas soluciones interpolantes tomamos la de **norma mínima**:

$$\hat{\phi} = Z^+ y$$

El error de test hace un pico en el **umbral de interpolación** $p = I \dots$ y luego **vuelve a bajar**: **doble descenso**.

¿Por qué ocurre el segundo descenso?


En $p = I$: $\mathbf{Z}$ es cuadrada y casi singular $\rightarrow$ la **única** solución interpolante tiene norma enorme $\rightarrow$ oscilaciones grandes. (La falla 3 en su peor versión - nuestra fórmula de varianza divergiendo.)

Para $p > I$: agregar features le da a la solución de norma mínima **más espacio para ser suave**: puede interpolar con coeficientes cada vez más chicos.

$$\hat{\phi} = \underset{\phi}{\operatorname{argmin}} \|\phi\|^2 \quad \text{sujeto a} \quad \mathbf{Z}\phi = \mathbf{y}$$

La pseudo-inversa es **el disfraz 1 desde el principio**: regularización implícita por norma mínima. El "régimen moderno" funciona porque está silenciosamente regularizado.

Al regularizar el pico desaparece



El mismo experimento, agregando **ridge** con λ ajustado por tamaño de modelo.

El pico del doble descenso **desaparece**: la curva óptimamente regularizada es monótona y al menos igual de buena **en todas partes**.

El doble descenso es una propiedad de la **interpolación sin regularizar** - no una ley de la naturaleza (Nakkiran et al., 2020).

Reglas prácticas

1. **Separar antes de mirar.** Apartar un test y tóquenlo una sola vez.
2. **Estandarizar las entradas** cuando el método no es invariante a escala (ridge, lasso, cualquier penalización).
3. **Preprocezar dentro del pliegue**, nunca antes de partir los datos.
4. **Eligir la pérdida según el problema** (el ruido que creen tener), no por conveniencia.
5. **Comparar contra una línea base** - la media de y , o un modelo de un solo regresor.
6. **Reportar variabilidad**, no un solo número: errores estándar de CV, particiones repetidas.

- ▶ Régimen sano ($I \gg D$, regresores bien condicionados): MCO es óptimo - **no se necesita regularización** (Gauss–Markov).
- ▶ Mínimos cuadrados = máxima verosimilitud con ruido gaussiano; **la pérdida viene del modelo de ruido**, no del gusto.
- ▶ Tres fallas - colinealidad, bases flexibles, $D + 1 \rightarrow I$ - son una enfermedad: **direcciones apenas restringidas por los datos**, donde decide el ruido. El síntoma es **varianza** (y coeficientes que explotan).
- ▶ Error de test = sesgo² + varianza + ruido; en regresión lineal, varianza promedio = $\sigma^2(D + 1)/I$.
- ▶ Capacidad y λ se eligen con validación / validación cruzada - **nunca con el test**.
- ▶ **Ridge** $(\mathbf{Z}^\top \mathbf{Z} + \lambda \mathbf{I})^{-1}$ cura la enfermedad en su origen; visión MAP: la penalización es un prior.
- ▶ Los regularizadores se disfrazan: GD (norma mínima), parar temprano ($\lambda \approx 1/\alpha t$), bagging, ruido en entradas ($\lambda = \sigma_x^2$) - todos demostrables aquí.
- ▶ El **doble descenso** existe en regresión lineal, y el ridge óptimo **lo elimina**.

¿Por qué lasso no se resuelve como ridge?



Ridge tiene forma cerrada porque su costo es **diferenciable en todas partes**. El de lasso no:

$$\|\mathbf{Z}\boldsymbol{\phi} - \mathbf{y}\|^2 + \lambda \sum_{j \geq 1} |\phi_j|$$

$|\phi_j|$ tiene una **esquina en $\phi_j = 0$** - exactamente donde queremos que caigan los coeficientes.

- ▶ No hay fórmula cerrada para el óptimo.
- ▶ El gradiente no existe en 0: descenso de gradiente puro **oscila** alrededor de cero y nunca produce ceros exactos.

El problema en 1D: soft-thresholding



- a) El costo 1D $\frac{1}{2}(\phi - a)^2 + \lambda|\phi|$: si $|a| \leq \lambda$, la esquina gana y el mínimo cae **exactamente en cero**.
- b) La solución como función de a : el operador **soft-thresholding** $\text{soft}[a, \lambda] = \text{sign}[a] \max(|a| - \lambda, 0)$, con su **zona muerta** $[-\lambda, \lambda]$ (gris).

Lasso por descenso de gradiente “proximal” (ISTA)


Alternar dos pasos - **gradiente sobre la parte suave**, **soft-thresholding sobre la penalización**:

$$\tilde{\phi} = \phi_t - \alpha \mathbf{Z}^\top (\mathbf{Z} \phi_t - \mathbf{y}) \qquad \phi_{t+1, j} = \text{soft}[\tilde{\phi}_j, \alpha \lambda]$$

Un paso normal de descenso de gradiente, seguido de: **empujar cada coeficiente hacia cero en $\alpha \lambda$; si cruza el cero, dejarlo en cero.**

Alternativa: **descenso por coordenadas** - optimizar un coeficiente a la vez, con los demás fijos; cada subproblema es exactamente el caso 1D. Es lo que usan `sklearn` y `glmnet`.

ISTA



Modelo de grado 10, λ moderado. Cada curva es un coeficiente a lo largo de las iteraciones: varios mueren **exactamente en cero** (uno baja, y el umbral lo captura); los demás convergen a su valor lasso.