



Magíster en Estadística, PUCV

Lógica difusa e inferencia Mamdani

Alejandro Veloz

Programa

1. Vaguedad frente a azar.
2. Conjuntos difusos y funciones de pertenencia.
3. Operaciones: t-normas, t-conormas y complementos.
4. Variables lingüísticas: del número a la etiqueta.
5. Implicación difusa y modus ponens generalizado.
6. Bases de reglas con varias entradas.
7. El mecanismo de inferencia Mamdani.

Vaguedad, no azar

Dos incertidumbres distintas

Azar. “La probabilidad de que el paciente tenga fiebre mañana es 0,3.”

El evento está bien definido. Lo que no sabemos es si ocurrirá. Al observarlo, la incertidumbre desaparece.

Dos incertidumbres distintas

Azar. “La probabilidad de que el paciente tenga fiebre mañana es 0,3.”

El evento está bien definido. Lo que no sabemos es si ocurrirá. Al observarlo, la incertidumbre desaparece.

Vaguedad. “El paciente tiene fiebre *moderada*.”

Aquí no hay nada que observar que resuelva la duda. Medimos 37,8°C y la pregunta sigue abierta, porque el predicado *moderada* no tiene una frontera nítida.

Dos incertidumbres distintas

Azar. “La probabilidad de que el paciente tenga fiebre mañana es 0,3.”



El evento está bien definido. Lo que no sabemos es si ocurrirá. Al observarlo, la incertidumbre desaparece.

Vaguedad. “El paciente tiene fiebre *moderada*.”

Aquí no hay nada que observar que resuelva la duda. Medimos $37,8^{\circ}\text{C}$ y la pregunta sigue abierta, porque el predicado *moderada* no tiene una frontera nítida.

La probabilidad mide qué tan seguros estamos de una proposición nítida.
El grado de pertenencia mide qué tan bien encaja un objeto en una categoría borrosa.

El costo de un umbral



Dos pacientes con 37,9°C y 38,1°C reciben decisiones opuestas del modelo nítido, y prácticamente la misma del modelo difuso.

Conjunto nítido y conjunto difuso

Sea X el universo de discurso. Un conjunto **nítido** $A \subseteq X$ queda descrito por su función indicadora:

$$\mathbb{1}_A : X \rightarrow \{0, 1\}, \quad \mathbb{1}_A(x) = \begin{cases} 1 & x \in A \\ 0 & x \notin A \end{cases}$$

Conjunto nítido y conjunto difuso

Sea X el universo de discurso. Un conjunto **nítido** $A \subseteq X$ queda descrito por su función indicadora:

$$\mathbb{1}_A : X \rightarrow \{0, 1\}, \quad \mathbb{1}_A(x) = \begin{cases} 1 & x \in A \\ 0 & x \notin A \end{cases}$$

Un conjunto **difuso** A en X (Zadeh, 1965) reemplaza el codominio por el intervalo unitario:

$$\mu_A : X \rightarrow [0, 1], \quad A = \{(x, \mu_A(x)) : x \in X\}$$

Conjunto nítido y conjunto difuso

Sea X el universo de discurso. Un conjunto **nítido** $A \subseteq X$ queda descrito por su función indicadora:

$$\mathbb{1}_A : X \rightarrow \{0, 1\}, \quad \mathbb{1}_A(x) = \begin{cases} 1 & x \in A \\ 0 & x \notin A \end{cases}$$

Un conjunto **difuso** A en X (Zadeh, 1965) reemplaza el codominio por el intervalo unitario:


$$\mu_A : X \rightarrow [0, 1], \quad A = \{(x, \mu_A(x)) : x \in X\}$$

Un conjunto difuso es su función de pertenencia. No hay un conjunto por un lado y una función por otro. La pregunta “¿pertenece x a A ?” se sustituye por “¿en qué grado pertenece?”.


Conjuntos difusos

Funciones de pertenencia usuales


triangular $\mu_A(x; a, b, c)$




trapezoidal $\mu_A(x; a, b, c, d)$



gaussiana $\mu_A(x; a, b)$



singleton $\mu_A(x; a)$



Funciones de pertenencia usuales

Triangular

$$\mu_A(x) = \max \left(0, \min \left(\frac{x-a}{b-a}, \frac{c-x}{c-b} \right) \right)$$

Gaussiana

$$\mu_A(x) = \exp \left(-\frac{(x-a)^2}{b^2} \right)$$

Trapezoidal

$$\mu_A(x) = \max \left(0, \min \left(\frac{x-a}{b-a}, 1, \frac{d-x}{d-c} \right) \right)$$

Singleton

$$\mu_A(x) = \begin{cases} 1 & x = a \\ 0 & \text{en otro caso} \end{cases}$$

Funciones de pertenencia usuales

Triangular

$$\mu_A(x) = \max \left(0, \min \left(\frac{x-a}{b-a}, \frac{c-x}{c-b} \right) \right)$$

Gaussiana

$$\mu_A(x) = \exp \left(-\frac{(x-a)^2}{b^2} \right)$$

Trapezoidal

$$\mu_A(x) = \max \left(0, \min \left(\frac{x-a}{b-a}, 1, \frac{d-x}{d-c} \right) \right)$$


Singleton

$$\mu_A(x) = \begin{cases} 1 & x = a \\ 0 & \text{en otro caso} \end{cases}$$

La singleton parece inútil, pero es la interfaz entre el mundo numérico y el difuso: un sensor entrega $x = x'$, y ese número entra al sistema como el conjunto difuso

$$\mu_{\bar{x}}(x) = \mathbb{1}[x = x'].$$

Propiedades de un conjunto difuso



Operaciones

El problema de extender $\cap$, $\cup$ y $\complement$

En conjuntos nítidos, las operaciones se definen sobre proposiciones verdaderas o falsas:

$$\mathbb{1}_{A \cap B} = \min(\mathbb{1}_A, \mathbb{1}_B), \quad \mathbb{1}_{A \cup B} = \max(\mathbb{1}_A, \mathbb{1}_B), \quad \mathbb{1}_{\complement A} = 1 - \mathbb{1}_A$$

El problema de extender $\cap$, $\cup$ y $\complement$

En conjuntos nítidos, las operaciones se definen sobre proposiciones verdaderas o falsas:

$$\mathbb{1}_{A \cap B} = \min(\mathbb{1}_A, \mathbb{1}_B), \quad \mathbb{1}_{A \cup B} = \max(\mathbb{1}_A, \mathbb{1}_B), \quad \mathbb{1}_{\complement A} = 1 - \mathbb{1}_A$$

Con grados en $[0, 1]$ hay **infinitas** extensiones que coinciden con éstas en $\{0, 1\}$. En vez de elegir una, se axiomatizan las familias admisibles:

conjunción y	intersección	t-norma $T : [0, 1]^2 \rightarrow [0, 1]$
disyunción o	unión	t-conorma $S : [0, 1]^2 \rightarrow [0, 1]$
negación no	complemento	complemento $c : [0, 1] \rightarrow [0, 1]$

Intersección: t-norma

Una **t-norma** $T : [0, 1] \times [0, 1] \rightarrow [0, 1]$ representa la conjunción y. Para $x, x', y, y', z \in [0, 1]$ debe cumplir:

Simetría	$T(x, y) = T(y, x)$
Asociatividad	$T(x, T(y, z)) = T(T(x, y), z)$
Monotonía	$T(x, y) \leq T(x', y')$ si $x \leq x'$ y $y \leq y'$
Elemento neutro	$T(x, 1) = x$

Intersección: t-norma

Una **t-norma** $T : [0, 1] \times [0, 1] \rightarrow [0, 1]$ representa la conjunción y. Para $x, x', y, y', z \in [0, 1]$ debe cumplir:


Simetría	$T(x, y) = T(y, x)$
Asociatividad	$T(x, T(y, z)) = T(T(x, y), z)$
Monotonía	$T(x, y) \leq T(x', y')$ si $x \leq x'$ y $y \leq y'$
Elemento neutro	$T(x, 1) = x$

Las dos consecuencias que se usan todo el tiempo:

$$T(x, 0) = 0 \quad \text{y} \quad T(x, y) \leq \min(x, y)$$

El mínimo es la mayor de todas las t-normas.

Intersección: ejemplo



Con $\mu_{A_1}(2,1) = 0,9$ y $\mu_{A_2}(2,1) = 0,1$: $T_{\min} = \min(0,9, 0,1) = 0,1$ y $T_{\text{prod}} = 0,9 \cdot 0,1 = 0,09$.

T-normas de uso frecuente

mínimo	$\text{MIN}(x, y) = \min(x, y)$
Łukasiewicz	$\text{LAND}(x, y) = \max(x + y - 1, 0)$
probabilística	$\text{PAND}(x, y) = xy$
débil	$\text{WEAK}(x, y) = \begin{cases} \min(x, y) & \text{si } \max(x, y) = 1 \\ 0 & \text{en otro caso} \end{cases}$
Hamacher	$\text{HAND}_{\gamma}(x, y) = \frac{xy}{\gamma + (1-\gamma)(x+y-xy)}, \quad \gamma \geq 0$
Dubois y Prade	$\text{DAND}_{\alpha}(x, y) = \frac{xy}{\max(x, y, \alpha)}, \quad \alpha \in [0, 1]$
Yager	$\text{YAND}_p(x, y) = 1 - \min\left(1, [(1-x)^p + (1-y)^p]^{1/p}\right), \quad p > 0$

T-normas de uso frecuente

mínimo	$\text{MIN}(x, y) = \min(x, y)$
Łukasiewicz	$\text{LAND}(x, y) = \max(x + y - 1, 0)$
probabilística	$\text{PAND}(x, y) = xy$
débil	$\text{WEAK}(x, y) = \begin{cases} \min(x, y) & \text{si } \max(x, y) = 1 \\ 0 & \text{en otro caso} \end{cases}$
Hamacher	$\text{HAND}_{\gamma}(x, y) = \frac{xy}{\gamma + (1-\gamma)(x+y-xy)}, \quad \gamma \geq 0$
Dubois y Prade	$\text{DAND}_{\alpha}(x, y) = \frac{xy}{\max(x, y, \alpha)}, \quad \alpha \in [0, 1]$
Yager	$\text{YAND}_p(x, y) = 1 - \min\left(1, [(1-x)^p + (1-y)^p]^{1/p}\right), \quad p > 0$

$$\text{WEAK} \leq \text{LAND} \leq \text{PAND} \leq \text{MIN}$$

Unión: t-conorma

Una **t-conorma** $S : [0, 1] \times [0, 1] \rightarrow [0, 1]$ representa la disyunción σ :

Simetría	$S(x, y) = S(y, x)$
Asociatividad	$S(x, S(y, z)) = S(S(x, y), z)$
Monotonía	$S(x, y) \leq S(x', y')$ si $x \leq x'$ y $y \leq y'$
Elemento neutro	$S(x, 0) = x$

Unión: t-conorma

Una **t-conorma** $S : [0, 1] \times [0, 1] \rightarrow [0, 1]$ representa la disyunción σ :

Simetría	$S(x, y) = S(y, x)$
Asociatividad	$S(x, S(y, z)) = S(S(x, y), z)$
Monotonía	$S(x, y) \leq S(x', y')$ si $x \leq x'$ y $y \leq y'$
Elemento neutro	$S(x, 0) = x$

Mismos axiomas, con el neutro en 0 en vez de en 1. Se sigue que $S(x, y) \geq \max(x, y)$: **el máximo es la menor de todas las t-conormas.**

Unión: t-conorma


Una **t-conorma** $S : [0, 1] \times [0, 1] \rightarrow [0, 1]$ representa la disyunción σ :

Simetría	$S(x, y) = S(y, x)$
Asociatividad	$S(x, S(y, z)) = S(S(x, y), z)$
Monotonía	$S(x, y) \leq S(x', y')$ si $x \leq x'$ y $y \leq y'$
Elemento neutro	$S(x, 0) = x$

Mismos axiomas, con el neutro en 0 en vez de en 1. Se sigue que $S(x, y) \geq \max(x, y)$: **el máximo es la menor de todas las t-conormas.**

Dualidad de De Morgan: si c es un complemento involutivo,
 $S(x, y) = c(T(c(x), c(y)))$.

Unión: ejemplo



Con $\mu_{A_1}(2,1) = 0,9$ y $\mu_{A_2}(2,1) = 0,1$: $S_{\max} = 0,9$ y
 $S_{\text{prob}} = 0,9 + 0,1 - 0,09 = 0,91$.

T-conormas de uso frecuente


máximo	$\text{MAX}(x, y) = \max(x, y)$
Łukasiewicz	$\text{LOR}(x, y) = \min(x + y, 1)$
probabilística	$\text{POR}(x, y) = x + y - xy$
fuerte	$\text{STRONG}(x, y) = \begin{cases} \max(x, y) & \text{si } \min(x, y) = 0 \\ 1 & \text{en otro caso} \end{cases}$
Hamacher	$\text{HOR}_\gamma(x, y) = \frac{x+y-(2-\gamma)xy}{1-(1-\gamma)xy}, \quad \gamma \geq 0$
Yager	$\text{YOR}_p(x, y) = \min(1, \sqrt[p]{x^p + y^p}), \quad p > 0$

T-conormas de uso frecuente

máximo	$\text{MAX}(x, y) = \max(x, y)$
Łukasiewicz	$\text{LOR}(x, y) = \min(x + y, 1)$
probabilística	$\text{POR}(x, y) = x + y - xy$
fuerte	$\text{STRONG}(x, y) = \begin{cases} \max(x, y) & \text{si } \min(x, y) = 0 \\ 1 & \text{en otro caso} \end{cases}$
Hamacher	$\text{HOR}_\gamma(x, y) = \frac{x+y-(2-\gamma)xy}{1-(1-\gamma)xy}, \quad \gamma \geq 0$
Yager	$\text{YOR}_p(x, y) = \min(1, \sqrt[p]{x^p + y^p}), \quad p > 0$

$$\text{MAX} \leq \text{POR} \leq \text{LOR} \leq \text{STRONG}$$

Superficies de los operadores



Las dos primeras son t-normas: solo se oscurecen en la esquina $(1, 1)$. Las dos últimas son t-conormas y hacen lo contrario. El mínimo tiene un pliegue en la diagonal.

Complemento

Un **complemento difuso** es una función $c : [0, 1] \rightarrow [0, 1]$ que asigna a cada grado $\mu_A(x)$ el grado $c(\mu_A(x))$ con el que x pertenece a $\bar{C}A$.

Condiciones de borde	$c(0) = 1$ y $c(1) = 0$
----------------------	-------------------------

Monotonía	$c(x) \geq c(y)$ si $x \leq y$
-----------	--------------------------------

Deseables además la continuidad y la **involución**, $c(c(x)) = x$.

Complemento

Un **complemento difuso** es una función $c : [0, 1] \rightarrow [0, 1]$ que asigna a cada grado $\mu_A(x)$ el grado $c(\mu_A(x))$ con el que x pertenece a $\complement A$.

Condiciones de borde	$c(0) = 1$ y $c(1) = 0$
Monotonía	$c(x) \geq c(y)$ si $x \leq y$

Deseables además la continuidad y la **involución**, $c(c(x)) = x$.

El estándar es $c(x) = 1 - x$. Las familias paramétricas más usadas:

$$c_\lambda(x) = \frac{1-x}{1+\lambda x} \quad (\lambda > -1) \qquad c_w(x) = (1-x^w)^{1/w} \quad (w > 0)$$

Complemento

Un **complemento difuso** es una función $c : [0, 1] \rightarrow [0, 1]$ que asigna a cada grado $\mu_A(x)$ el grado $c(\mu_A(x))$ con el que x pertenece a $\complement A$.

Condiciones de borde	$c(0) = 1$ y $c(1) = 0$
Monotonía	$c(x) \geq c(y)$ si $x \leq y$

Deseables además la continuidad y la **involución**, $c(c(x)) = x$.

El estándar es $c(x) = 1 - x$. Las familias paramétricas más usadas:

$$c_\lambda(x) = \frac{1-x}{1+\lambda x} \quad (\lambda > -1) \qquad c_w(x) = (1-x^w)^{1/w} \quad (w > 0)$$

En general $A \cap \complement A \neq \emptyset$. La ley del tercero excluido no se cumple.

Variables lingüísticas

Del número a la etiqueta

Una **variable lingüística** es una tupla $(x, \mathcal{T}(x), X)$:

- x es el nombre de la variable (*suciedad, edad, presión*);
- X es el universo de discurso donde toma valores numéricos;
- $\mathcal{T}(x) = \{A^{(1)}, \dots, A^{(n)}\}$ es su conjunto de **términos lingüísticos**, cada uno un conjunto difuso sobre X .

Del número a la etiqueta

Una **variable lingüística** es una tupla $(x, \mathcal{T}(x), X)$:

- x es el nombre de la variable (*suciedad, edad, presión*);
- X es el universo de discurso donde toma valores numéricos;
- $\mathcal{T}(x) = \{A^{(1)}, \dots, A^{(n)}\}$ es su conjunto de **términos lingüísticos**, cada uno un conjunto difuso sobre X .

$$\text{suciedad} \in \{\text{baja, media, alta}\}, \quad X = [0, 50]$$

Del número a la etiqueta


Una **variable lingüística** es una tupla $(x, \mathcal{T}(x), X)$:

- x es el nombre de la variable (*suciedad, edad, presión*);
- X es el universo de discurso donde toma valores numéricos;
- $\mathcal{T}(x) = \{A^{(1)}, \dots, A^{(n)}\}$ es su conjunto de **términos lingüísticos**, cada uno un conjunto difuso sobre X .

$$\text{suciedad} \in \{\text{baja, media, alta}\}, \quad X = [0, 50]$$

Es el mecanismo que permite escribir el modelo en el mismo lenguaje en que el experto enuncia su conocimiento, y el que hace que el modelo resultante sea legible por alguien que no lo programó.

Granulación del universo



Términos gaussianos equiespaciados con anchura $b = \Delta / (2\sqrt{\ln 2})$, de modo que dos términos vecinos se cruzan exactamente en 0,5.

Implicación y modus ponens

Modus ponens clásico

premisa

si p entonces q

hecho

p

consecuencia

q

Modus ponens clásico

premisa	si p entonces q
hecho	p
consecuencia	q

Es una regla **todo o nada**. Requiere que el hecho coincida *exactamente* con el antecedente.

Modus ponens clásico

premisa	si p entonces q
hecho	p
consecuencia	q

Es una regla **todo o nada**. Requiere que el hecho coincida *exactamente* con el antecedente.

Si la regla dice *si el tomate está rojo entonces está maduro*, y el hecho es *el tomate está bastante rojo*, la lógica clásica no concluye nada.

Modus ponens clásico

premisa	si p entonces q
hecho	p
consecuencia	q

Es una regla **todo o nada**. Requiere que el hecho coincida *exactamente* con el antecedente.

Si la regla dice *si el tomate está rojo entonces está maduro*, y el hecho es *el tomate está bastante rojo*, la lógica clásica no concluye nada.

El **modus ponens generalizado** levanta exactamente esa restricción:

permite que el hecho se parezca al antecedente, y devuelve una conclusión que se parece al consecuente en la misma medida.

Implicación difusa

Una **implicación difusa** es una función $I : [0, 1] \times [0, 1] \rightarrow [0, 1]$ que asigna un valor de verdad a la proposición condicional *si p entonces q* .

Con $p = "x \text{ es } A"$ y $q = "y \text{ es } B"$, la regla es una **relación difusa** sobre $X \times Y$:

$$\mu_{A \rightarrow B}(x, y) = I(\mu_A(x), \mu_B(y))$$

Implicación difusa

Una **implicación difusa** es una función $I : [0, 1] \times [0, 1] \rightarrow [0, 1]$ que asigna un valor de verdad a la proposición condicional *si p entonces q* .

Con $p = "x \text{ es } A"$ y $q = "y \text{ es } B"$, la regla es una **relación difusa** sobre $X \times Y$:

$$\mu_{A \rightarrow B}(x, y) = I(\mu_A(x), \mu_B(y))$$

S-implicaciones. Del formalismo booleano $p \rightarrow q \equiv \neg p \vee q$:
 $I(a, b) = S(c(a), b)$. Ejemplos: Kleene-Dienes, Łukasiewicz.

Implicación difusa

Una **implicación difusa** es una función $I : [0, 1] \times [0, 1] \rightarrow [0, 1]$ que asigna un valor de verdad a la proposición condicional *si p entonces q* .

Con $p = "x \text{ es } A"$ y $q = "y \text{ es } B"$, la regla es una **relación difusa** sobre $X \times Y$:

$$\mu_{A \rightarrow B}(x, y) = I(\mu_A(x), \mu_B(y))$$

S-implicaciones. Del formalismo booleano $p \rightarrow q \equiv \neg p \vee q$:
 $I(a, b) = S(c(a), b)$. Ejemplos: Kleene-Dienes, Łukasiewicz.

Implicaciones de t-norma. $I(a, b) = T(a, b)$. Ejemplos: **Mamdani** (min) y **Larsen** (producto).

Implicación difusa

Una **implicación difusa** es una función $I : [0, 1] \times [0, 1] \rightarrow [0, 1]$ que asigna un valor de verdad a la proposición condicional *si p entonces q*.

Con $p = "x \text{ es } A"$ y $q = "y \text{ es } B"$, la regla es una **relación difusa** sobre $X \times Y$:

$$\mu_{A \rightarrow B}(x, y) = I(\mu_A(x), \mu_B(y))$$

S-implicaciones. Del formalismo booleano $p \rightarrow q \equiv \neg p \vee q$:
 $I(a, b) = S(c(a), b)$. Ejemplos: Kleene-Dienes, Łukasiewicz.

Implicaciones de t-norma. $I(a, b) = T(a, b)$. Ejemplos: **Mamdani** (min) y **Larsen** (producto).

Las de t-norma no cumplen las propiedades de la implicación material, pero son las que se usan en control.

Operadores de implicación

Zadeh	$I(x, y) = \max(1 - x, \min(x, y))$
Łukasiewicz	$I(x, y) = \min(1, 1 - x + y)$
Mamdani	$I(x, y) = \min(x, y)$
Larsen	$I(x, y) = xy$
Kleene-Dienes	$I(x, y) = \max(1 - x, y)$
Kleene-Dienes-Łukasiewicz	$I(x, y) = 1 - x + xy$
Gödel	$I(x, y) = \begin{cases} 1 & \text{si } x \leq y \\ y & \text{en otro caso} \end{cases}$
Gaines	$I(x, y) = \begin{cases} 1 & \text{si } x \leq y \\ y/x & \text{en otro caso} \end{cases}$
Yager	$I(x, y) = y^x$

Modus ponens generalizado

premisa

si x es A entonces y es B

hecho

x es A'

consecuencia

y es B'

A y A' viven en el mismo universo pero **no** son necesariamente iguales;
lo mismo B y B' .

Modus ponens generalizado

premisa	si x es A entonces y es B
hecho	x es A'
consecuencia	y es B'

A y A' viven en el mismo universo pero **no** son necesariamente iguales; lo mismo B y B' .

B' se obtiene componiendo el hecho con la relación de la regla,
 $B' = A' \circ (A \rightarrow B)$:

$$\mu_{B'}(y) = \sup_{x \in X} T\left\{\mu_{A'}(x), \mu_{A \rightarrow B}(x, y)\right\}, \quad y \in Y$$

Modus ponens generalizado

premisa	si x es A entonces y es B
hecho	x es A'
consecuencia	y es B'


A y A' viven en el mismo universo pero **no** son necesariamente iguales; lo mismo B y B' .

B' se obtiene componiendo el hecho con la relación de la regla,
 $B' = A' \circ (A \rightarrow B)$:

$$\mu_{B'}(y) = \sup_{x \in X} T\left\{\mu_{A'}(x), \mu_{A \rightarrow B}(x, y)\right\}, \quad y \in Y$$

Es la **regla de inferencia composicional** de Zadeh. Con $A' = A$ y una implicación adecuada se recupera $B' = B$, es decir, el modus ponens clásico.

Inferencia con un hecho difuso



La mayor compatibilidad entre A' y A vale 0,81, y ese es el techo de B' .

El caso que usa Mamdani: hecho nítido

En un sistema real la entrada es un **número**, no un conjunto difuso. Se representa por un singleton, $\mu_{\bar{x}}(x) = \mathbb{1}[x = x']$.

El caso que usa Mamdani: hecho nítido

En un sistema real la entrada es un **número**, no un conjunto difuso. Se representa por un singleton, $\mu_{\bar{x}}(x) = \mathbb{1}[x = x']$.

Usando $T(a, 1) = a$ y $T(a, 0) = 0$, el supremo colapsa a un único término:

$$\begin{aligned}\mu_{B'}(y) &= \sup_{x \in X} T\{\mu_{\bar{x}}(x), \mu_{A \rightarrow B}(x, y)\} \\ &= \mu_{A \rightarrow B}(x', y) = \text{I}(\underbrace{\mu_A(x')}_{\alpha}, \mu_B(y))\end{aligned}$$

El caso que usa Mamdani: hecho nítido

En un sistema real la entrada es un **número**, no un conjunto difuso. Se representa por un singleton, $\mu_{\bar{x}}(x) = \mathbb{1}[x = x']$.


Usando $T(a, 1) = a$ y $T(a, 0) = 0$, el supremo colapsa a un único término:

$$\begin{aligned}\mu_{B'}(y) &= \sup_{x \in X} T\{\mu_{\bar{x}}(x), \mu_{A \rightarrow B}(x, y)\} \\ &= \mu_{A \rightarrow B}(x', y) = \text{I}(\underbrace{\mu_A(x')}_{\alpha}, \mu_B(y))\end{aligned}$$

Con la implicación de Mamdani, $\mu_{B'}(y) = \min(\alpha, \mu_B(y))$:

la conclusión es el consecuente recortado a la altura α , el **nivel de activación** de la regla.

Inferencia con un hecho nítido



El supremo se reduce a la columna $x = x'$ de la relación, que es el consecuente recortado a $\alpha = \mu_A(x') = 0,60$.

Bases de reglas

Reglas con varias entradas

Sean $x_1 \in X_1, \dots, x_d \in X_d$ las entradas lingüísticas e $y \in Y$ la salida, con términos $\mathcal{T}(x_j) = \{A_j^{(1)}, \dots\}$ y $\mathcal{T}(y) = \{B_1, \dots, B_n\}$.

$\mathcal{R}_1$	si x_1 es $A_1^{(1)}$ y ... y x_d es $A_d^{(1)}$ entonces y es B_1
$\vdots$	$\vdots$
$\mathcal{R}_n$	si x_1 es $A_1^{(n)}$ y ... y x_d es $A_d^{(n)}$ entonces y es B_n

Reglas con varias entradas

Sean $x_1 \in X_1, \dots, x_d \in X_d$ las entradas lingüísticas e $y \in Y$ la salida, con términos $\mathcal{T}(x_j) = \{A_j^{(1)}, \dots\}$ y $\mathcal{T}(y) = \{B_1, \dots, B_n\}$.

$\mathcal{R}_1$	si x_1 es $A_1^{(1)}$ y ... y x_d es $A_d^{(1)}$ entonces y es B_1
$\vdots$	$\vdots$
$\mathcal{R}_n$	si x_1 es $A_1^{(n)}$ y ... y x_d es $A_d^{(n)}$ entonces y es B_n
hecho	$x_1 = x'_1$ y ... y $x_d = x'_d$

Reglas con varias entradas

Sean $x_1 \in X_1, \dots, x_d \in X_d$ las entradas lingüísticas e $y \in Y$ la salida, con términos $\mathcal{T}(x_j) = \{A_j^{(1)}, \dots\}$ y $\mathcal{T}(y) = \{B_1, \dots, B_n\}$.

$\mathcal{R}_1$	si x_1 es $A_1^{(1)}$ y ... y x_d es $A_d^{(1)}$ entonces y es B_1
$\vdots$	$\vdots$
$\mathcal{R}_n$	si x_1 es $A_1^{(n)}$ y ... y x_d es $A_d^{(n)}$ entonces y es B_n
hecho	$x_1 = x'_1$ y ... y $x_d = x'_d$
consecuencia	y es B , y de ahí $\hat{y}$

Reglas con varias entradas

Sean $x_1 \in X_1, \dots, x_d \in X_d$ las entradas lingüísticas e $y \in Y$ la salida, con términos $\mathcal{T}(x_j) = \{A_j^{(1)}, \dots\}$ y $\mathcal{T}(y) = \{B_1, \dots, B_n\}$.

$\mathcal{R}_1$	si x_1 es $A_1^{(1)}$ y ... y x_d es $A_d^{(1)}$ entonces y es B_1
$\vdots$	$\vdots$
$\mathcal{R}_n$	si x_1 es $A_1^{(n)}$ y ... y x_d es $A_d^{(n)}$ entonces y es B_n
hecho	$x_1 = x'_1$ y ... y $x_d = x'_d$
consecuencia	y es B , y de ahí $\hat{y}$

La relación de la regla i combina las premisas con una t-norma y las aplica al consecuente:

$$R_i(x_1, \dots, x_d, y) = I\left(\underbrace{\min_j \mu_{A_j^{(i)}}(x_j)}_{\text{t-norma de las premisas}}, \mu_{B_i}(y)\right)$$

La base de reglas de la lavadora

Entradas: **suciedad** (0 a 50) y **masa de ropa** (0 a 9 kg). Salidas: **velocidad de centrifugado** (1000 a 2000 rpm) y **tiempo de secado** (0 a 3 h).

	suciedad	masa	rpm	tiempo
$\mathcal{R}_1$	baja	baja	bajas	corto
$\mathcal{R}_2$	media	media	medias	medio
$\mathcal{R}_3$	alta	alta	altas	largo
$\mathcal{R}_4$	alta	baja	altas	medio
$\mathcal{R}_5$	baja	alta	medias	largo

Inferencia Mamdani

Inferencia Mamdani

- Un conjunto difuso es su función de pertenencia, $\mu_A : X \rightarrow [0, 1]$. Modela vaguedad, no azar.

Inferencia Mamdani

- Un conjunto difuso *es* su función de pertenencia, $\mu_A : X \rightarrow [0, 1]$. Modela vaguedad, no azar.
- Las operaciones se axiomatizan: **t-normas** para *y*, **t-conormas** para *o*, complementos para *no*. Cotas: $T \leq \min$ y $S \geq \max$.

Inferencia Mamdani

- Un conjunto difuso es su función de pertenencia, $\mu_A : X \rightarrow [0, 1]$. Modela vaguedad, no azar.
- Las operaciones se axiomatizan: **t-normas** para y , **t-conormas** para o , complementos para no . Cotas: $T \leq \min$ y $S \geq \max$.
- Una regla es una **relación difusa** sobre $X \times Y$; el **GMP** la compone con el hecho, $\mu_{B'}(y) = \sup_x T\{\mu_{A'}(x), \mu_{A \rightarrow B}(x, y)\}$.

Inferencia Mamdani

- Un conjunto difuso es su función de pertenencia, $\mu_A : X \rightarrow [0, 1]$. Modela vaguedad, no azar.
- Las operaciones se axiomatizan: **t-normas** para y , **t-conormas** para o , complementos para no . Cotas: $T \leq \min$ y $S \geq \max$.
- Una regla es una **relación difusa** sobre $X \times Y$; el **GMP** la compone con el hecho, $\mu_{B'}(y) = \sup_x T\{\mu_{A'}(x), \mu_{A \rightarrow B}(x, y)\}$.
- Con entrada nítida, el supremo colapsa y todo se reduce a $\mu_{B'}(y) = \min(\alpha, \mu_B(y))$.

Inferencia Mamdani

- Un conjunto difuso *es* su función de pertenencia, $\mu_A : X \rightarrow [0, 1]$. Modela vaguedad, no azar.
- Las operaciones se axiomatizan: **t-normas** para *y*, **t-conormas** para *o*, complementos para *no*. Cotas: $T \leq \min$ y $S \geq \max$.
- Una regla es una **relación difusa** sobre $X \times Y$; el **GMP** la compone con el hecho, $\mu_{B'}(y) = \sup_x T\{\mu_{A'}(x), \mu_{A \rightarrow B}(x, y)\}$.
- Con entrada nítida, el supremo colapsa y todo se reduce a $\mu_{B'}(y) = \min(\alpha, \mu_B(y))$.
- **Mamdani** son cinco pasos: fusificar, activar (t-norma), implicar (recortar), agregar (t-conorma) y defusificar (centroide).

Inferencia Mamdani

- (i) **Fusificación.** Evaluar cada entrada nítida en las MF de las premisas, $\mu_j^{(i)}(x'_j)$.

Inferencia Mamdani

- (i) **Fusificación.** Evaluar cada entrada nítida en las MF de las premisas, $\mu_j^{(i)}(x'_j)$.
- (ii) **Activación.** Combinar las premisas de cada regla con la t-norma:

$$\alpha_i = \min (\mu_1^{(i)}(x'_1), \dots, \mu_d^{(i)}(x'_d))$$

Inferencia Mamdani

- (i) **Fusificación.** Evaluar cada entrada nítida en las MF de las premisas, $\mu_j^{(i)}(x'_j)$.
- (ii) **Activación.** Combinar las premisas de cada regla con la t-norma:

$$\alpha_i = \min (\mu_1^{(i)}(x'_1), \dots, \mu_d^{(i)}(x'_d))$$

- (iii) **Implicación.** Recortar el consecuente de cada regla a su nivel de activación:

$$\mu_{B'_i}(y) = I(\alpha_i, \mu_{B_i}(y)) = \min (\alpha_i, \mu_{B_i}(y))$$

Inferencia Mamdani

- (i) **Fusificación.** Evaluar cada entrada nítida en las MF de las premisas, $\mu_j^{(i)}(x'_j)$.
- (ii) **Activación.** Combinar las premisas de cada regla con la t-norma:

$$\alpha_i = \min(\mu_1^{(i)}(x'_1), \dots, \mu_d^{(i)}(x'_d))$$

- (iii) **Implicación.** Recortar el consecuente de cada regla a su nivel de activación:

$$\mu_{B'_i}(y) = I(\alpha_i, \mu_{B_i}(y)) = \min(\alpha_i, \mu_{B_i}(y))$$

- (iv) **Agregación.** Unir las conclusiones de todas las reglas con la t-conorma:

$$\mu_B(y) = \text{Agg}(\mu_{B'_1}(y), \dots, \mu_{B'_n}(y)) = \max_i \mu_{B'_i}(y)$$

Inferencia Mamdani

- (i) **Fusificación.** Evaluar cada entrada nítida en las MF de las premisas, $\mu_j^{(i)}(x'_j)$.
- (ii) **Activación.** Combinar las premisas de cada regla con la t-norma:

$$\alpha_i = \min(\mu_1^{(i)}(x'_1), \dots, \mu_d^{(i)}(x'_d))$$

- (iii) **Implicación.** Recortar el consecuente de cada regla a su nivel de activación:

$$\mu_{B'_i}(y) = I(\alpha_i, \mu_{B_i}(y)) = \min(\alpha_i, \mu_{B_i}(y))$$


- (iv) **Agregación.** Unir las conclusiones de todas las reglas con la t-conorma:

$$\mu_B(y) = \text{Agg}(\mu_{B'_1}(y), \dots, \mu_{B'_n}(y)) = \max_i \mu_{B'_i}(y)$$

- (v) **Desfusificación.** Reducir B a un número, por ejemplo el centro de gravedad:


$$\hat{y} = \frac{\int_Y y \mu_B(y) dy}{\int_Y \mu_B(y) dy}$$

Inferencia Mamdani (ejemplo)




Una fila por regla; en rojo el dato, en naranja el consecuente recortado a α_i .

Agregación y desfusificación



Centroide $\hat{y} = \int y\mu_B / \int \mu_B$; bisector, que parte el área en dos; y los tres estadísticos del núcleo.

Superficie de control



Cinco reglas escritas en castellano generan una superficie continua y no lineal, con mesetas alrededor de cada regla. El punto marca el caso de ejemplo.

Mamdani versus TSK

	Mamdani	Takagi-Sugeno-Kang
consecuente	conjunto difuso B_i	función $f_i(x_1, \dots, x_d)$
salida	$\hat{y}$ por defusificación	$\hat{y} = \frac{\sum_i \alpha_i f_i(\mathbf{x})}{\sum_i \alpha_i}$
costo	integral sobre Y	promedio ponderado
interpretabilidad	alta, todo es lingüístico	media, el consecuente es numérico
ajuste con datos	difícil	directo (mínimos cuadrados / ANFIS)

Mamdani versus TSK

	Mamdani	Takagi-Sugeno-Kang
consecuente	conjunto difuso B_i	función $f_i(x_1, \dots, x_d)$
salida	$\hat{y}$ por defusificación	$\hat{y} = \frac{\sum_i \alpha_i f_i(\mathbf{x})}{\sum_i \alpha_i}$
costo	integral sobre Y	promedio ponderado
interpretabilidad	alta, todo es lingüístico	media, el consecuente es numérico
ajuste con datos	difícil	directo (mínimos cuadrados / ANFIS)

Mamdani cuando el conocimiento viene del experto y hay que poder auditarlo.

TSK cuando el modelo se ajusta con datos y el costo importa.

Referencias

- L. A. Zadeh. *Fuzzy sets*. Information and Control, 8(3):338–353, 1965.
- L. A. Zadeh. *Outline of a new approach to the analysis of complex systems and decision processes*. IEEE Trans. Systems, Man and Cybernetics, 3(1):28–44, 1973.
- E. H. Mamdani, S. Assilian. *An experiment in linguistic synthesis with a fuzzy logic controller*. Int. J. Man-Machine Studies, 7(1):1–13, 1975.
- G. J. Klir, B. Yuan. *Fuzzy Sets and Fuzzy Logic: Theory and Applications*. Prentice Hall, 1995. — capítulos 1 a 3 y 11.
- J.-S. R. Jang, C.-T. Sun, E. Mizutani. *Neuro-Fuzzy and Soft Computing*. Prentice Hall, 1997. — capítulos 2 a 4.
- W. Pedrycz, F. Gomide. *Fuzzy Systems Engineering*. Wiley, 2007.