

Paradigmas de aprendizaje

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos



El problema de aprendizaje

Datos $(X, Y) \sim P$ sobre $\mathcal{X} \times \mathcal{Y}$, una clase de hipótesis $\mathcal{H}$ y una pérdida $L(y, f(x))$.

$$R(f) = \mathbb{E}_P[L(Y, f(X))] = \int L(y, f(x)) dP(x, y) \quad \text{riesgo esperado}$$

El problema de aprendizaje

Datos $(X, Y) \sim P$ sobre $\mathcal{X} \times \mathcal{Y}$, una clase de hipótesis $\mathcal{H}$ y una pérdida $L(y, f(x))$.

$$R(f) = \mathbb{E}_P[L(Y, f(X))] = \int L(y, f(x)) dP(x, y) \quad \text{riesgo esperado}$$

El objetivo ideal: $f^* = \arg \min_{f \in \mathcal{H}} R(f)$, el mejor predictor **en promedio sobre todos los casos que existirán**.

El problema de aprendizaje

Datos $(X, Y) \sim P$ sobre $\mathcal{X} \times \mathcal{Y}$, una clase de hipótesis $\mathcal{H}$ y una pérdida $L(y, f(x))$.

$$R(f) = \mathbb{E}_P[L(Y, f(X))] = \int L(y, f(x)) dP(x, y) \quad \text{riesgo esperado}$$

El objetivo ideal: $f^* = \arg \min_{f \in \mathcal{H}} R(f)$, el mejor predictor **en promedio sobre todos los casos que existirán**.

P es **desconocida**. $R(f)$ es una integral contra una distribución no podemos evaluar ni una vez, para ningún f . Minimizar el riesgo, directamente, **no se puede**.

El problema de aprendizaje


	Pérdida	$L(y, f(x))$	$f^*(x)$ poblacional
Regresión	cuadrática	$(y - f(x))^2$	la media $\mathbb{E}[Y \mid X=x]$
	absoluta	$ y - f(x) $	la mediana de $Y \mid X=x$
Clasificación	0-1	$\mathbb{1}\{y \neq f(x)\}$	la moda : $\arg \max_y P(y \mid x)$
	log-loss	$-\log \hat{p}(y \mid x)$	la propia $P(y \mid x)$

El problema de aprendizaje

	Pérdida	$L(y, f(x))$	$f^*(x)$ poblacional
Regresión	cuadrática	$(y - f(x))^2$	la media $\mathbb{E}[Y \mid X=x]$
	absoluta	$ y - f(x) $	la mediana de $Y \mid X=x$
Clasificación	0-1	$\mathbb{1}\{y \neq f(x)\}$	la moda : $\arg \max_y P(y \mid x)$
	log-loss	$-\log \hat{p}(y \mid x)$	la propia $P(y \mid x)$

Mismos datos, distinta pérdida, distinto óptimo: la cuadrática persigue la media (sensible a colas), la absoluta la mediana (robusta), la 0-1 la clase más probable. Elegir L **es formular el problema**.

El problema de aprendizaje



En color se muestra la densidad de $P(x, y)$ que mapea todos los casos posibles y su frecuencia.

$R(f)$ promedia el error sobre ese mapeo completo; $\hat{R}_S(f)$, solo sobre los n puntos que cayeron en la muestra.

Minimización del riesgo empírico

Lo único observable es la muestra $S = \{(x_i, y_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} P,$

$$\hat{f} = \arg \min_{f \in \mathcal{H}} \hat{R}_S(f) + \lambda \Omega(f), \quad \hat{R}_S(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$$

[se sustituye la integral por el promedio muestral]

Minimización del riesgo empírico

Lo único observable es la muestra $S = \{(x_i, y_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} P$,

$$\hat{f} = \arg \min_{f \in \mathcal{H}} \hat{R}_S(f) + \lambda \Omega(f), \quad \hat{R}_S(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$$

[se sustituye la integral por el promedio muestral]

- Para cada f **fijo**: $\hat{R}_S(f) \rightarrow R(f)$ (ley de los grandes números).
- $\hat{f}$ se elige **mirando** S . En $\hat{f}$, el riesgo empírico es optimista.

Minimización del riesgo empírico

Lo único observable es la muestra $S = \{(x_i, y_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} P,$


$$\hat{f} = \arg \min_{f \in \mathcal{H}} \hat{R}_S(f) + \lambda \Omega(f), \quad \hat{R}_S(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$$

[se sustituye la integral por el promedio muestral]

- Para cada f **fijo**: $\hat{R}_S(f) \rightarrow R(f)$ (ley de los grandes números).
- $\hat{f}$ se elige **mirando** S . En $\hat{f}$, el riesgo empírico es optimista.

Evaluar en un f fijo vs. en el f que ganó la competencia sobre S : esa diferencia es el **problema de generalización**.

El problema de generalización



Minimizar $\hat{R}_S$ a secas premia memorizar la muestra.
Para generalizar, se controla la **brecha** $R(\hat{f}) - \hat{R}_S(\hat{f})$.

Cuándo funciona ERM

Sea R^* el riesgo de Bayes y $f_{\mathcal{H}} = \arg \min_{f \in \mathcal{H}} R(f)$ el mejor de la clase:

$$R(\hat{f}) - R^* = \overset{\text{error de estimación}}{(R(\hat{f}) - R(f_{\mathcal{H}}))} + \overset{\text{error de aproximación}}{(R(f_{\mathcal{H}}) - R^*)}$$

Cuándo funciona ERM

Sea R^* el riesgo de Bayes y $f_{\mathcal{H}} = \arg \min_{f \in \mathcal{H}} R(f)$ el mejor de la clase:

$$R(\hat{f}) - R^* = \overset{\text{error de estimación}}{(R(\hat{f}) - R(f_{\mathcal{H}}))} + \overset{\text{error de aproximación}}{(R(f_{\mathcal{H}}) - R^*)}$$

Como $\hat{f}$ depende de S , se necesita convergencia **uniforme** sobre $\mathcal{H}$:

$$R(\hat{f}) - \hat{R}_S(\hat{f}) \leq \sup_{f \in \mathcal{H}} |R(f) - \hat{R}_S(f)| \lesssim \sqrt{\frac{\text{capacidad}(\mathcal{H})}{n}}$$

Cuándo funciona ERM

Sea R^* el riesgo de Bayes y $f_{\mathcal{H}} = \arg \min_{f \in \mathcal{H}} R(f)$ el mejor de la clase:

$$R(\hat{f}) - R^* = \overset{\text{error de estimación}}{(R(\hat{f}) - R(f_{\mathcal{H}}))} + \overset{\text{error de aproximación}}{(R(f_{\mathcal{H}}) - R^*)}$$


Como $\hat{f}$ depende de S , se necesita convergencia **uniforme** sobre $\mathcal{H}$:

$$R(\hat{f}) - \hat{R}_S(\hat{f}) \leq \sup_{f \in \mathcal{H}} |R(f) - \hat{R}_S(f)| \lesssim \sqrt{\frac{\text{capacidad}(\mathcal{H})}{n}}$$

$\mathcal{H}$ grande aproxima bien pero estima mal; $\mathcal{H}$ pequeño, al revés. La regularización $\lambda \Omega(f)$ recorre ese continuo.

La capacidad: dimensión VC

$d_{VC}(\mathcal{H})$: el mayor n tal que algunos n puntos admiten **los 2^n etiquetados**.




los 2^3 etiquetados se separan ✓: $d_{VC}(\text{rectas}) = 3$ 4 en XOR: ninguna recta lo logra ✗



La capacidad: dimensión VC

$d_{VC}(\mathcal{H})$: el mayor n tal que algunos n puntos admiten **los 2^n etiquetados**.



los 2^3 etiquetados se separan ✓: $d_{VC}(\text{rectas}) = 3$ 4 en XOR: ninguna recta lo logra ✗

$$R(f) \leq \hat{R}_S(f) + \sqrt{\frac{8 d_{VC} \left(\ln \frac{2n}{d_{VC}} + 1 \right) + 8 \ln \frac{4}{\delta}}{n}} \quad \text{prob.} \geq 1 - \delta$$

La capacidad: dimensión VC

$d_{VC}(\mathcal{H})$: el mayor n tal que algunos n puntos admiten **los 2^n etiquetados**.



los 2^3 etiquetados se separan ✓: $d_{VC}(\text{rectas}) = 3$ 4 en XOR: ninguna recta lo logra ✗

$$R(f) \leq \hat{R}_S(f) + \sqrt{\frac{8 d_{VC} \left(\ln \frac{2n}{d_{VC}} + 1 \right) + 8 \ln \frac{4}{\delta}}{n}} \quad \text{prob.} \geq 1 - \delta$$

La brecha escala como $\sqrt{d_{VC}/n}$; aprender exige $n \gtrsim d_{VC}$.

Varios paradigmas de aprendizaje

El marco general es $\rightarrow$ muestra i.i.d. de P , minimizar $\hat{R}_S(f) + \lambda \Omega(f)$, garantías vía n y capacidad.

Varios paradigmas de aprendizaje


El marco general es $\rightarrow$ muestra i.i.d. de P , minimizar $\hat{R}_S(f) + \lambda \Omega(f)$, garantías vía n y capacidad.

Casi todos los paradigmas modernos nacen de estresar ese marco: **cambiar qué es Y , qué es P , o quién tiene los datos.**

Varios paradigmas de aprendizaje

El marco general es $\rightarrow$ muestra i.i.d. de P , minimizar $\hat{R}_S(f) + \lambda \Omega(f)$, garantías vía n y capacidad.

Casi todos los paradigmas modernos nacen de estresar ese marco: **cambiar qué es Y , qué es P , o quién tiene los datos.**




Factorizaciones de la distribución conjunta

X (entrada observada), Y (salida observada), Z (variable latente).


Factorizaciones de la distribución conjunta

X (entrada observada), Y (salida observada), Z (variable latente).



Factorizaciones de la distribución conjunta

X (entrada observada), Y (salida observada), Z (variable latente).



Cada paradigma decide **qué variables considera y qué factor de la conjunta se modela.**

Taxonomía por tipo de supervisión

Paradigma	Datos	Objetivo
Supervisado	(x_i, y_i)	$\hat{f} : \mathcal{X} \rightarrow \mathcal{Y}$
No supervisado	(x_i)	Estructura de $P(x)$
Semi-supervisado	$(x_i, y_i) + (x_j)$	$\hat{f}$ con pocas etiquetas
Auto-supervisado	(x_i)	y construido desde x
Refuerzo	(s_t, a_t, r_t)	Política π


Taxonomía por tipo de supervisión

Paradigma	Datos	Objetivo
Supervisado	(x_i, y_i)	$\hat{f} : \mathcal{X} \rightarrow \mathcal{Y}$
No supervisado	(x_i)	Estructura de $P(x)$
Semi-supervisado	$(x_i, y_i) + (x_j)$	$\hat{f}$ con pocas etiquetas
Auto-supervisado	(x_i)	y construido desde x
Refuerzo	(s_t, a_t, r_t)	Política π


El enfoque auto-supervisado hizo posible a los modelos de lenguaje:
inventar la etiqueta a partir del propio dato.

Discriminativo vs generativo

generativo: modelar cómo se ve cada clase





...y Bayes entrega el clasificador: una sigmoide



$$P(y=1 \mid x) = \sigma\left(\log \frac{\pi f_1(x)}{(1-\pi) f_0(x)}\right)$$

igual $\Sigma \Rightarrow$ logit lineal: la **logística**


Discriminativo vs generativo



$$P(y=1 | x) = \sigma\left(\log \frac{\pi f_1(x)}{(1-\pi) f_0(x)}\right) \quad \text{igual } \Sigma \Rightarrow \text{logit lineal: la } \mathbf{logística}$$

El **discriminativo** modela $p(y | x)$: menos supuestos, mejor con n grande.
El **generativo** modela $p(x, y)$: simula, trata datos faltantes, usa datos sin etiqueta, pagando con supuestos sobre $p(x | y)$.

Supervisado vs no supervisado



El clustering encuentra *una* partición.

Que coincida con una etiqueta (por ejemplo, enfermo/no enfermo) es una hipótesis, no un resultado esperable.

El supuesto i.i.d.

Supuesto i.i.d.

Los datos de entrenamiento y los datos de despliegue son muestras **independientes e idénticamente distribuidas** de la **misma** distribución P .

El supuesto i.i.d.

Supuesto i.i.d.

Los datos de entrenamiento y los datos de despliegue son muestras **independientes e idénticamente distribuidas** de la **misma** distribución P .

Sin este supuesto, minimizar $\hat{R}(f)$ no dice nada sobre $R(f)$ (es falso casi siempre):

El supuesto i.i.d.

Supuesto i.i.d.

Los datos de entrenamiento y los datos de despliegue son muestras **independientes e idénticamente distribuidas** de la **misma** distribución P .

Sin este supuesto, minimizar $\hat{R}(f)$ no dice nada sobre $R(f)$ (es falso casi siempre):

- Se entrena en un hospital y se usa en otro.
- Se entrena con datos de 2023 y se usa en 2026.
- Se entrena con quienes *aceptaron* participar.

Tres tipos de dataset shift

Tipo	Qué cambia	Qué se mantiene
Covariate shift	$P_{tr}(x) \neq P_{te}(x)$	$P_{tr}(y x) = P_{te}(y x)$
Prior prob. shift	$P_{tr}(y) \neq P_{te}(y)$	$P_{tr}(x y) = P_{te}(x y)$
Concept shift	$P_{tr}(y x) \neq P_{te}(y x)$	$P_{tr}(x) = P_{te}(x)$

Tres tipos de dataset shift



Tipo	Qué cambia	Qué se mantiene
Covariate shift	$P_{tr}(x) \neq P_{te}(x)$	$P_{tr}(y x) = P_{te}(y x)$
Prior prob. shift	$P_{tr}(y) \neq P_{te}(y)$	$P_{tr}(x y) = P_{te}(x y)$
Concept shift	$P_{tr}(y x) \neq P_{te}(y x)$	$P_{tr}(x) = P_{te}(x)$

Cambia *quién* entra al modelo. Ej.: entreno con fotos de pasaporte, uso con selfies.

Cambia la *prevalencia*. Ej.: entreno en pandemia, despliego después.

Cambia la *regla*. Ej.: spam - el adversario se adapta. El más difícil de detectar.

Covariate shift



El modelo no empeoró: **lo estamos usando fuera de donde aprendió.** La validación cruzada no lo detecta.

Domain adaptation

Dominio **fuentes** $\mathcal{D}_S$ con etiquetas, dominio **objetivo** $\mathcal{D}_T$ sin ellas. Queremos minimizar el riesgo en $\mathcal{D}_T$.

Domain adaptation

Dominio **fuentes** $\mathcal{D}_S$ con etiquetas, dominio **objetivo** $\mathcal{D}_T$ sin ellas. Queremos minimizar el riesgo en $\mathcal{D}_T$.

- **Reponderación:** pesar cada ejemplo por $w(x) = P_T(x)/P_S(x)$.
- **Alineación:** aprender ϕ con $P_S(\phi(x)) \approx P_T(\phi(x))$ - CORAL, DANN, MMD.
- **Auto-entrenamiento:** pseudo-etiquetar el objetivo y refinar.

Domain adaptation

Dominio **fuentes** $\mathcal{D}_S$ con etiquetas, dominio **objetivo** $\mathcal{D}_T$ sin ellas. Queremos minimizar el riesgo en $\mathcal{D}_T$.

- **Reponderación:** pesar cada ejemplo por $w(x) = P_T(x)/P_S(x)$.
- **Alineación:** aprender ϕ con $P_S(\phi(x)) \approx P_T(\phi(x))$ - CORAL, DANN, MMD.
- **Auto-entrenamiento:** pseudo-etiquetar el objetivo y refinar.

Adaptation conoce el dominio objetivo. **Generalization** no: entrena con varios dominios y espera generalizar a uno nuevo.

Reponderación por importancia

```
#  $w(x) = P_T(x)/P_S(x)$  estimado con un clasificador fuente-vs-objetivo
dom = np.r_[np.zeros(xtr.size), np.ones(xte.size)]          # 0 = fuente, 1 = objetivo
p   = LogisticRegression().fit(np.r_[xtr, xte][:, None], dom).predict_proba(xtr[:, None])[:, 1]
w   = np.clip(p / (1 - p), 0, 20)                          # razón de densidades

sin_w = LinearRegression().fit(P(xtr, 1), ytr)              # modelo mal especificado
con_w = LinearRegression().fit(P(xtr, 1), ytr, sample_weight=w)

print(f"MSE despliegue, sin reponderar : {np.mean((sin_w.predict(P(xte, 1)) - yte)**2):.2f}")
print(f"MSE despliegue, reponderando   : {np.mean((con_w.predict(P(xte, 1)) - yte)**2):.2f}")
```

MSE despliegue, sin reponderar : 1.41

MSE despliegue, reponderando : 0.29

Reponderación por importancia

```
#  $w(x) = P_T(x)/P_S(x)$  estimado con un clasificador fuente-vs-objetivo
dom = np.r_[np.zeros(xtr.size), np.ones(xte.size)]          # 0 = fuente, 1 = objetivo
p    = LogisticRegression().fit(np.r_[xtr, xte][:, None], dom).predict_proba(xtr[:, None])[:, 1]
w    = np.clip(p / (1 - p), 0, 20)                          # razón de densidades

sin_w = LinearRegression().fit(P(xtr, 1), ytr)               # modelo mal especificado
con_w = LinearRegression().fit(P(xtr, 1), ytr, sample_weight=w)

print(f"MSE despliegue, sin reponderar : {np.mean((sin_w.predict(P(xte, 1)) - yte)**2):.2f}")
print(f"MSE despliegue, reponderando   : {np.mean((con_w.predict(P(xte, 1)) - yte)**2):.2f}")
```

MSE despliegue, sin reponderar : 1.41

MSE despliegue, reponderando : 0.29

Un solo modelo, dos usos: si *puede* distinguir los dominios hay shift (test), y sus probabilidades son los pesos (remedio). Requiere **solapamiento**.

Transfer learning

Tarea **fuelle** con muchos datos, tarea **objetivo** con pocos: se transporta la **representación** ϕ , incluso entre tareas distintas.

Transfer learning

Tarea **fuelle** con muchos datos, tarea **objetivo** con pocos: se transporta la **representación** ϕ , incluso entre tareas distintas.

- **Features fijas:** congelar ϕ pre-entrenada, ajustar un modelo simple encima.
- **Fine-tuning:** seguir optimizando ϕ (o una parte) con los datos objetivo.
- **Pre-entrenamiento auto-supervisado:** así nacen los *foundation models*.


Transfer learning

Tarea **fuelle** con muchos datos, tarea **objetivo** con pocos: se transporta la **representación** ϕ , incluso entre tareas distintas.


- **Features fijas:** congelar ϕ pre-entrenada, ajustar un modelo simple encima.
- **Fine-tuning:** seguir optimizando ϕ (o una parte) con los datos objetivo.
- **Pre-entrenamiento auto-supervisado:** así nacen los *foundation models*.

No cambia el objetivo, cambia el **punto de partida**: el sesgo inductivo heredado reduce el error de estimación con n chico. Riesgo: *negative transfer*.

Federated learning



Federated learning



Los datos **nunca** salen de la institución. Viajan solo actualizaciones del modelo. Es el paradigma natural cuando los datos son sensibles, están fragmentados, o su traslado es ilegal.

FedAvg

Entrada: K clientes, fracción C , épocas locales E , tasa η .

Inicializar w_0

para cada ronda $t = 1, 2, \dots$ **hacer**

$S_t \leftarrow$ subconjunto aleatorio de $\max(C \cdot K, 1)$ clientes

para cada cliente $k \in S_t$ *en paralelo* **hacer**

$w_{t+1}^k \leftarrow E$ épocas de SGD sobre los datos locales, partiendo de w_t

$$w_{t+1} \leftarrow \sum_{k \in S_t} \frac{n_k}{n} w_{t+1}^k$$

promedio ponderado por tamaño

FedAvg

Entrada: K clientes, fracción C , épocas locales E , tasa η .

Inicializar w_0

para cada ronda $t = 1, 2, \dots$ **hacer**

$S_t \leftarrow$ subconjunto aleatorio de $\max(C \cdot K, 1)$ clientes

para cada cliente $k \in S_t$ *en paralelo* **hacer**

$w_{t+1}^k \leftarrow E$ épocas de SGD sobre los datos locales, partiendo de w_t

$w_{t+1} \leftarrow \sum_{k \in S_t} \frac{n_k}{n} w_{t+1}^k$ promedio ponderado por tamaño

McMahan et al. (2017). Con $E = 1$ y $C = 1$ se reduce a SGD distribuido clásico.

Federated learning: dificultades

Datos no-IID

Otra población, otros equipos, otra prevalencia. El promedio puede ser peor que cualquier modelo local.

Comunicación

El cuello de botella es la red, no el cómputo.
Se optimizan rondas, no épocas.

Heterogeneidad de sistemas

Clientes que se caen, hardware distinto, disponibilidad variable.

Privacidad incompleta

Los gradientes filtran información: hay ataques que reconstruyen ejemplos desde Δw .

Federated learning: dificultades

Datos no-IID

Otra población, otros equipos, otra prevalencia. El promedio puede ser peor que cualquier modelo local.

Comunicación

El cuello de botella es la red, no el cómputo.
Se optimizan rondas, no épocas.

Heterogeneidad de sistemas


Clientes que se caen, hardware distinto, disponibilidad variable.

Privacidad incompleta

Los gradientes filtran información: hay ataques que reconstruyen ejemplos desde Δw .

Federated learning **no es** privacidad. Hay que sumarle una agregación segura y privacidad diferencial.


El efecto no-IID



Mismo algoritmo, misma cantidad de datos: lo único que cambia es *cómo están repartidos*.
Y más rondas de comunicación no lo arreglan.

Aprendizaje continuo

Los datos llegan como una **secuencia** de distribuciones $P_1, P_2, \dots$: aprender la tarea nueva **sin olvidar** las anteriores y sin re-entrenar desde cero.



Olvido catastrófico: al optimizar sobre B, los parámetros abandonan la solución de A.

Remedios: *replay*, regularización hacia parámetros importantes (EWC), módulos por tarea.

Otras variantes del mismo problema

Aprendizaje activo

Etiquetar cuesta (horas de experto). El modelo *elige* qué x etiquetar para aprender más por etiqueta. La muestra deja de ser pasiva: la sesga el propio algoritmo.

Aprendizaje online

No hay "entrenar y luego desplegar": los datos llegan de a uno y se decide antes de ver el siguiente. La garantía ya no es el riesgo sino el *regret* acumulado.

Meta-learning

La unidad de muestreo es la *tarea*, no el ejemplo: entrenar sobre muchas tareas para adaptarse a una nueva con pocos datos (*few-shot*).

Supervisión débil

Etiquetas imperfectas pero baratas: reglas, heurísticas, votación de fuentes ruidosas. Se observa una versión corrupta $\tilde{Y}$ en vez de Y .

Otras variantes del mismo problema

Aprendizaje activo

Etiquetar cuesta (horas de experto). El modelo *elige* qué x etiquetar para aprender más por etiqueta. La muestra deja de ser pasiva: la sesga el propio algoritmo.

Aprendizaje online

No hay "entrenar y luego desplegar": los datos llegan de a uno y se decide antes de ver el siguiente. La garantía ya no es el riesgo sino el *regret* acumulado.

Meta-learning

La unidad de muestreo es la *tarea*, no el ejemplo: entrenar sobre muchas tareas para adaptarse a una nueva con pocos datos (*few-shot*).

Supervisión débil

Etiquetas imperfectas pero baratas: reglas, heurísticas, votación de fuentes ruidosas. Se observa una versión corrupta $\tilde{Y}$ en vez de Y .

Datos faltantes

Supervisión débil corrompe Y ; acá llega incompleto x : se observa (x_{obs}, m) , con m la máscara. El remedio válido depende del **mecanismo** (Rubin, 1976):

Mecanismo	De qué depende la falta	Remedio válido
MCAR	de nada: $P(m \mid x) = P(m)$	borrar filas (desperdicia datos)
MAR	solo de lo observado: $P(m \mid x_{\text{obs}})$	imputación, verosimilitud
MNAR	de lo que falta	nada, sin supuestos extra

Datos faltantes

Supervisión débil corrompe Y ; acá llega incompleto x : se observa (x_{obs}, m) , con m la máscara. El remedio válido depende del **mecanismo** (Rubin, 1976):

Mecanismo	De qué depende la falta	Remedio válido
MCAR	de nada: $P(m \mid x) = P(m)$	borrar filas (desperdicia datos)
MAR	solo de lo observado: $P(m \mid x_{\text{obs}})$	imputación, verosimilitud
MNAR	de lo que falta	nada, sin supuestos extra

El mecanismo **no es verificable con los datos observados**.

Paradigmas

Paradigma	Qué supuesto rompe	Pregunta que responde
Supervisado clásico	ninguno (i.i.d.)	¿Predigo bien aquí?
Transfer learning	misma tarea	¿Reuso lo aprendido?
Domain adaptation	misma $P(x)$	¿Funciona allá?
Domain generalization	conocer el destino	¿Funciona donde sea?
Federated learning	datos centralizados	¿Aprendo sin ver los datos?
Aprendizaje continuo	distribución estacionaria	¿Aprendo sin olvidar?
Aprendizaje activo	muestreo pasivo	¿Qué etiqueta compro?
Aprendizaje online	lote fijo antes de actuar	¿Decido sobre la marcha?
Meta-learning	una sola tarea	¿Aprendo a aprender?
Datos faltantes	observar x completo	¿Aprendo con x incompleto?
Inferencia causal	observación pasiva	¿Qué pasa si intervengo?

Paradigmas

Paradigma	Qué supuesto rompe	Pregunta que responde
Supervisado clásico	ninguno (i.i.d.)	¿Predigo bien aquí?
Transfer learning	misma tarea	¿Reuso lo aprendido?
Domain adaptation	misma $P(x)$	¿Funciona allá?
Domain generalization	conocer el destino	¿Funciona donde sea?
Federated learning	datos centralizados	¿Aprendo sin ver los datos?
Aprendizaje continuo	distribución estacionaria	¿Aprendo sin olvidar?
Aprendizaje activo	muestreo pasivo	¿Qué etiqueta compro?
Aprendizaje online	lote fijo antes de actuar	¿Decido sobre la marcha?
Meta-learning	una sola tarea	¿Aprendo a aprender?
Datos faltantes	observar x completo	¿Aprendo con x incompleto?
Inferencia causal	observación pasiva	¿Qué pasa si intervengo?

La última fila es un salto cualitativo (cambia la *pregunta*, no el algoritmo.)

De predecir a intervenir

Los desafíos vistos hasta aquí comparten una forma: aprender de una muestra de una P y responder sobre otra - corrida (shift), incompleta (faltantes), repartida (federated), cambiante (continual).

De predecir a intervenir

Los desafíos vistos hasta aquí comparten una forma: aprender de una muestra de una P y responder sobre otra - corrida (shift), incompleta (faltantes), repartida (federated), cambiante (continual).

La pregunta causal pide algo más: la distribución de un mundo que **los datos no visitaron** - el que existiría si *nosotros* fijáramos el tratamiento. No es P_{tr} ni P_{te} : es una P que la propia decisión **crearía**.

De predecir a intervenir

Los desafíos vistos hasta aquí comparten una forma: aprender de una muestra de una P y responder sobre otra - corrida (shift), incompleta (faltantes), repartida (federated), cambiante (continual).

La pregunta causal pide algo más: la distribución de un mundo que **los datos no visitaron** - el que existiría si *nosotros* fijáramos el tratamiento. No es P_{tr} ni P_{te} : es una P que la propia decisión **crearía**.

Intervenir es un **shift** provocado, y evaluarlo choca con el **dato faltante** definitivo (falta lo que la decisión descartó).

Inferencia causal

Asma y neumonía

Un modelo de mortalidad en neumonía aprendió esta regla:

tener asma $\Rightarrow$ menor riesgo de morir

Asma y neumonía

Un modelo de mortalidad en neumonía aprendió esta regla:

tener asma $\Rightarrow$ menor riesgo de morir

- **Estadísticamente correcta:** en esos datos, los asmáticos morían menos.
- **Clínicamente absurda:** el asma agrava la neumonía.

Asma y neumonía

Un modelo de mortalidad en neumonía aprendió esta regla:

tener asma $\Rightarrow$ menor riesgo de morir

- **Estadísticamente correcta:** en esos datos, los asmáticos morían menos.
- **Clínicamente absurda:** el asma agrava la neumonía.

Los asmáticos iban directo a UCI. El modelo aprendió el efecto **del protocolo**, no el de la enfermedad. Usarlo para decidir altas habría matado gente.

Caruana et al. (2015), KDD.

La escalera de la causalidad

3. Contrafactuales - *¿qué habría pasado si...?*

$P(y_x | x', y')$ - imaginación, retrospectiva, atribución

2. Intervención - *¿qué pasa si hago...?*

$P(y | do(x))$ - experimentos, A/B tests, políticas

1. Asociación - *¿qué me dice X sobre Y ?*

$P(y | x)$ - aquí vive todo el ML supervisado

La escalera de la causalidad

3. Contrafactuales - *¿qué habría pasado si...?*

$P(y_x | x', y')$ - imaginación, retrospectiva, atribución

2. Intervención - *¿qué pasa si hago...?*

$P(y | do(x))$ - experimentos, A/B tests, políticas

1. Asociación - *¿qué me dice X sobre Y ?*

$P(y | x)$ - aquí vive todo el ML supervisado

Ningún volumen de datos del peldaño 1 responde una pregunta del peldaño 2 sin supuestos adicionales.

Condicionar no es intervenir

$$P(Y \mid X = x)$$

Filtro los datos: me quedo con quienes ya tenían $X = x$.

Los que tienen $X = x$ pueden diferir en todo lo demás.

$$P(Y \mid do(X = x))$$

Cambio el mundo: fijo $X = x$ para todos, borrando las causas de X .

Todo lo demás se mantiene como estaba.

Condicionar no es intervenir

$$P(Y \mid X = x)$$

Filtro los datos: me quedo con quienes ya tenían $X = x$.

Los que tienen $X = x$ pueden diferir en todo lo demás.

$$P(Y \mid do(X = x))$$

Cambio el mundo: fijo $X = x$ para todos, borrando las causas de X .

Todo lo demás se mantiene como estaba.

El barómetro y la tormenta: $P(\text{tormenta} \mid \text{barómetro bajo})$ es alta y útil para predecir. $P(\text{tormenta} \mid do(\text{barómetro bajo}))$ es la probabilidad basal - mover la aguja con el dedo no cambia el clima.

La variable aleatoria contrafactual

Cada unidad carga **dos** variables aleatorias, fijadas *antes* del tratamiento X :

$(Y_i(0), Y_i(1))$ qué le pasaría a i sin y con tratamiento


La variable aleatoria contrafactual

Cada unidad carga **dos** variables aleatorias, fijadas *antes* del tratamiento X :

$(Y_i(0), Y_i(1))$ qué le pasaría a i sin y con tratamiento


El efecto compara **dos mundos de la misma población**, $\mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$; la asociación, dos subpoblaciones, $\mathbb{E}[Y \mid X=1] - \mathbb{E}[Y \mid X=0]$.
Coinciden solo si $(Y(0), Y(1)) \perp\!\!\!\perp X$ (aleatorización).

La consistencia: un conmutador entre mundos




[Letra chica] Tratamiento con **versión única** y **sin interferencia** entre unidades (SUTVA).

Factual y contrafactual




Los dos mundos potenciales como función de la covariable (edad): existen **antes** del tratamiento.

Factual y contrafactual



Llegan los datos: cada unidad se revela en **un** mundo - y los tratados no se parecen a los controles.

Factual y contrafactual



Los círculos huecos son los contrafactuales: la mitad de la tabla que **nunca** se observa.

El contrafactual como dato faltante

i	z_i (edad, sexo)	X_i	$Y_i(1)$	$Y_i(0)$	$\tau_i = Y_i(1) - Y_i(0)$
1	45, M	1	7.1	?	?
2	62, F	0	?	4.9	?
3	31, F	1	8.3	?	?
4	58, M	0	?	5.5	?
5	40, F	1	6.0	?	?

observado



contrafactual (faltante)



Cada fila revela **una** celda; la otra es el **contrafactual**. Por eso τ_i nunca es observable.

El contrafactual como dato faltante

i	z_i (edad, sexo)	X_i	$Y_i(1)$	$Y_i(0)$	$\tau_i = Y_i(1) - Y_i(0)$
1	45, M	1	7.1	?	?
2	62, F	0	?	4.9	?
3	31, F	1	8.3	?	?
4	58, M	0	?	5.5	?
5	40, F	1	6.0	?	?

observado



contrafactual (faltante)



Cada fila revela **una** celda; la otra es el **contrafactual**. Por eso τ_i nunca es observable.

La tabla de datos faltantes definitiva: falta el 50 % y el **mecanismo de falta es la asignación** ($m = X$).

Aleatorizar: repartir los mundos con una moneda

Si una moneda asigna el tratamiento,
 $(Y(0), Y(1)) \perp\!\!\!\perp X$, y en dos pasos:

$$\begin{aligned}\mathbb{E}[Y \mid X=1] &= \mathbb{E}[Y(1) \mid X=1] && \text{consistencia} \\ &= \mathbb{E}[Y(1)] && \text{independencia}\end{aligned}$$

la asociación **es** el efecto: el RCT vuelve la
tabla **MCAR** por diseño.


Aleatorizar: repartir los mundos con una moneda

Si una moneda asigna el tratamiento,
 $(Y(0), Y(1)) \perp\!\!\!\perp X$, y en dos pasos:


$$\begin{aligned}\mathbb{E}[Y \mid X=1] &= \mathbb{E}[Y(1) \mid X=1] && \text{consistencia} \\ &= \mathbb{E}[Y(1)] && \text{independencia}\end{aligned}$$

la asociación **es** el efecto: el RCT vuelve la
tabla **MCAR** por diseño.

Límites: caro, lento, a veces imposible o
inmoral. Por eso lo que sigue: causalidad
observacional.




Confusor, mediador, collider




Confusor

ajustar por Z
corrige



Mediador


ajustar **bloquea**
parte del efecto



Collider


ajustar **crea**
asociación falsa

Confusor, mediador, collider




Confusor

ajustar por Z
corrige



Mediador

ajustar **bloquea**
parte del efecto



Collider

ajustar **crea**
asociación falsa

“Controlar por todas las variables disponibles” es *incorrecto*.
Qué ajustar depende del grafo.

Confusión en datos

```
n = 30_000
Z = rng.normal(0, 1, n) # gravedad basal (confusor)
X = (rng.random(n) < 1/(1+np.exp(-1.5*Z))).astype(int) # los graves se tratan más
Y = 2.5*Z - 1.0*X + rng.normal(0, 1, n) # efecto VERDADERO = -1.0

b = np.clip(np.digitize(Z, np.quantile(Z, np.linspace(0,1,21)))) - 1, 0, 19) # 20 estratos
ef = [Y[(b==j)&(X==1)].mean() - Y[(b==j)&(X==0)].mean() for j in range(20)]
pe = [np.mean(b==j) for j in range(20)]


print(f"diferencia cruda : {Y[X==1].mean()-Y[X==0].mean():+.2f} <-- signo equivocado")
print(f"ajustado por el confusor: {np.nansum(np.array(ef)*np.array(pe)):+.2f} (verdadero: -1.00)")
```

diferencia cruda : +1.65 <-- signo equivocado

ajustado por el confusor: -0.95 (verdadero: -1.00)

La estimación cruda dice que el tratamiento daña. Más datos no lo arreglan.

La paradoja de Simpson



Los mismos datos sostienen conclusiones opuestas.

Modelo desplegado = intervención

Todo modelo desplegado es una intervención.

Modelo desplegado = intervención

Todo modelo desplegado es una intervención.

- Si el modelo solo **describe**, basta el peldaño 1.
- Apenas alguien **actúa**, la distribución cambia: peldaño 2.

Modelo desplegado = intervención

Todo modelo desplegado es una intervención.

- Si el modelo solo **describe**, basta el peldaño 1.
- Apenas alguien **actúa**, la distribución cambia: peldaño 2.

Corolario: un modelo desplegado **invalida los datos con que fue entrenado**. Los recomendadores aprenden de logs que ellos generaron; los modelos de crédito solo ven a quienes aprobaron. Eso es *feedback loop*, y es un problema causal.