

Tipos de datos y su representación

Análisis exploratorio de datos

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos



Objetivos

- Distinguir el tipo lógico de una variable de su tipo físico de almacenamiento.
- Formalizar las escalas de medida mediante sus grupos de transformaciones admisibles, y derivar de ahí qué estadísticos resultan admisibles.
- Construir representaciones vectoriales para datos categóricos, ordinales, cíclicos, textuales, de imagen y de grafo.
- Relacionar cada representación con la disimilitud que induce sobre las observaciones.
- Reconocer las codificaciones que dependen de la respuesta y las condiciones bajo las cuales su uso es válido.

El punto de partida

Un archivo de datos clínicos. Cada columna es de naturaleza distinta.

id	edad	sexo	severidad	diagnóstico	ingreso	vef
1041	63	F	moderado	J44	2025-03-11	2,10
1042	47	M	leve	J45	2025-03-11	3,45
1043	71	F	grave	J44	2025-03-12	1,28
1044	55	M	leve	I50	2025-03-14	<i>faltante</i>

El punto de partida

Un archivo de datos clínicos. Cada columna es de naturaleza distinta.


id	edad	sexo	severidad	diagnóstico	ingreso	vef
1041	63	F	moderado	J44	2025-03-11	2,10
1042	47	M	leve	J45	2025-03-11	3,45
1043	71	F	grave	J44	2025-03-12	1,28
1044	55	M	leve	I50	2025-03-14	<i>faltante</i>

La tabla no determina por sí sola tres decisiones.

- Qué estadísticos de resumen admite cada columna.
- Cómo se cuantifica la distancia entre dos pacientes.
- Cómo se representa la celda sin registrar.


Qué necesita un algoritmo

Ningún método de aprendizaje lee la tabla anterior. Todos operan sobre dos objetos.



Qué necesita un algoritmo

Ningún método de aprendizaje lee la tabla anterior. Todos operan sobre dos objetos.



Toda la información semántica del problema entra por ϕ . Si ϕ codifica que “leve” y “grave” tienen la misma distancia que “leve” y “moderado”, ningún algoritmo posterior podrá corregirlo.

La unidad de análisis

La **unidad de análisis** es el tipo de entidad que representa cada fila, por ejemplo el paciente, la consulta o la medición. Cada fila es una **observación**, es decir una instancia concreta de ese tipo.

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n, \quad \mathbf{x}_i \in \mathcal{X}_1 \times \cdots \times \mathcal{X}_p$$

La unidad de análisis

La **unidad de análisis** es el tipo de entidad que representa cada fila, por ejemplo el paciente, la consulta o la medición. Cada fila es una **observación**, es decir una instancia concreta de ese tipo.

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n, \quad \mathbf{x}_i \in \mathcal{X}_1 \times \cdots \times \mathcal{X}_p$$

El producto cartesiano $\mathcal{X}_1 \times \cdots \times \mathcal{X}_p$ hace explícito que cada columna vive en su **propio espacio**. La matriz de diseño $X \in \mathbb{R}^{n \times p}$ aparece solo después de elegir una inmersión

$$\phi_j : \mathcal{X}_j \longrightarrow \mathbb{R}^{d_j}, \quad \phi(\mathbf{x}) = (\phi_1(x_1), \dots, \phi_p(x_p)) \in \mathbb{R}^d, \quad d = \sum_j d_j$$

La unidad de análisis

La **unidad de análisis** es el tipo de entidad que representa cada fila, por ejemplo el paciente, la consulta o la medición. Cada fila es una **observación**, es decir una instancia concreta de ese tipo.

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n, \quad \mathbf{x}_i \in \mathcal{X}_1 \times \cdots \times \mathcal{X}_p$$

El producto cartesiano $\mathcal{X}_1 \times \cdots \times \mathcal{X}_p$ hace explícito que cada columna vive en su **propio espacio**. La matriz de diseño $X \in \mathbb{R}^{n \times p}$ aparece solo después de elegir una inmersión

$$\phi_j : \mathcal{X}_j \longrightarrow \mathbb{R}^{d_j}, \quad \phi(\mathbf{x}) = (\phi_1(x_1), \dots, \phi_p(x_p)) \in \mathbb{R}^d, \quad d = \sum_j d_j$$

La elección de cada ϕ_j es una decisión de modelado.

Estructura tabular ordenada

Tres condiciones definen una tabla en forma **ordenada**.

1. Cada variable ocupa exactamente una columna.
2. Cada observación ocupa exactamente una fila.
3. Cada tabla recoge una sola unidad de análisis, es decir un solo tipo de entidad.

Estructura tabular ordenada

Tres condiciones definen una tabla en forma **ordenada**.

1. Cada variable ocupa exactamente una columna.
2. Cada observación ocupa exactamente una fila.
3. Cada tabla recoge una sola unidad de análisis, es decir un solo tipo de entidad.

```
largo = ancho.unpivot(index="paciente", variable_name="visita", value_name="vef")
```

forma ancha		
paciente	vef_v1	vef_v2
1	3.1	3.4
2	2.4	2.2

→

forma larga		
paciente	visita	vef
1	vef_v1	3.1
2	vef_v1	2.4
1	vef_v2	3.4
2	vef_v2	2.2

Estructura tabular ordenada

Tres condiciones definen una tabla en forma **ordenada**.

1. Cada variable ocupa exactamente una columna.
2. Cada observación ocupa exactamente una fila.
3. Cada tabla recoge una sola unidad de análisis, es decir un solo tipo de entidad.

```
largo = ancho.unpivot(index="paciente", variable_name="visita", value_name="vef")
```

forma ancha		
paciente	vef_v1	vef_v2
1	3.1	3.4
2	2.4	2.2

→

forma larga		
paciente	visita	vef
1	vef_v1	3.1
2	vef_v1	2.4
1	vef_v2	3.4
2	vef_v2	2.2

La forma larga expone la dependencia entre mediciones de un mismo sujeto, que la ancha oculta en los nombres de columna.

Antes de formalizar: cuatro preguntas

Dada una columna, cuatro preguntas determinan qué se puede hacer con ella.

Pregunta	diagnóstico J44, J45, I50	severidad leve, mod., grave	temperatura °C	vef litros
¿Se puede decir que dos valores son iguales?	sí	sí	sí	sí
¿Se puede decir que uno es mayor que otro?	no	sí	sí	sí
¿Tiene sentido restar dos valores?	no	no	sí	sí
¿Tiene sentido dividir dos valores?	no	no	no	sí
Escala	nominal	ordinal	intervalo	razón

Antes de formalizar: cuatro preguntas

Dada una columna, cuatro preguntas determinan qué se puede hacer con ella.

Pregunta	diagnóstico J44, J45, I50	severidad leve, mod., grave	temperatura °C	vef litros
¿Se puede decir que dos valores son iguales?	sí	sí	sí	sí
¿Se puede decir que uno es mayor que otro?	no	sí	sí	sí
¿Tiene sentido restar dos valores?	no	no	sí	sí
¿Tiene sentido dividir dos valores?	no	no	no	sí
Escala	nominal	ordinal	intervalo	razón

“20°C es el doble de calor que 10°C” es una afirmación falsa, porque el cero de la escala Celsius es convencional. En kelvin, que sí tiene cero absoluto, el cociente sí tiene sentido. La diferencia no está en el termómetro sino en dónde se puso el cero.

Escalas de medida

Una escala queda caracterizada por el **grupo de transformaciones** $\mathcal{G}$ que preservan la información medida. Un enunciado es **admisibile** si su valor de verdad es invariante bajo todo $g \in \mathcal{G}$.

Escala	Preserva	Transformaciones $\mathcal{G}$	Ejemplo
Nominal	igualdad =	renombrar las etiquetas	diagnóstico
Ordinal	orden $\leq$	g monótona creciente	escala Likert
Intervalo	diferencias $x_i - x_j$	$g(x) = ax + b, a > 0$	temperatura en °C
Razón	cocientes x_i / x_j	$g(x) = ax, a > 0$	masa, concentración
Absoluta	el valor mismo	$g = \text{id}$	conteo, probabilidad

Escalas de medida

Una escala queda caracterizada por el **grupo de transformaciones** $\mathcal{G}$ que preservan la información medida. Un enunciado es **admisibile** si su valor de verdad es invariante bajo todo $g \in \mathcal{G}$.

Escala	Preserva	Transformaciones $\mathcal{G}$	Ejemplo
Nominal	igualdad =	renombrar las etiquetas	diagnóstico
Ordinal	orden $\leq$	g monótona creciente	escala Likert
Intervalo	diferencias $x_i - x_j$	$g(x) = ax + b, a > 0$	temperatura en °C
Razón	cocientes x_i / x_j	$g(x) = ax, a > 0$	masa, concentración
Absoluta	el valor mismo	$g = \text{id}$	conteo, probabilidad

Los grupos están anidados, $\mathcal{G}_{\text{abs}} \subset \mathcal{G}_{\text{razón}} \subset \mathcal{G}_{\text{int}} \subset \mathcal{G}_{\text{ord}} \subset \mathcal{G}_{\text{nom}}$. A menor grupo, más enunciados admisibles.

Estadísticos admisibles

Con $g(x) = ax + b$ se tiene $\overline{g(x)} = a\bar{x} + b$, de modo que la comparación $\bar{x}_A > \bar{x}_B$ sobrevive para todo $a > 0$. La media es admisible en escala de intervalo.

Estadísticos admisibles

Con $g(x) = ax + b$ se tiene $\overline{g(x)} = a\bar{x} + b$, de modo que la comparación $\bar{x}_A > \bar{x}_B$ sobrevive para todo $a > 0$. La media es admisible en escala de intervalo.

	Moda <i>más frecuente</i>	Mediana $\hat{Q}(0,5)$	Media $\frac{1}{n} \sum_i x_i$	Media geom. $(\prod_i x_i)^{1/n}$	Coef. variación $\hat{\sigma} / \bar{x}$
Nominal	✓	—	—	—	—
Ordinal	✓	✓	—	—	—
Intervalo	✓	✓	✓	—	—
Razón	✓	✓	✓	✓	✓

Estadísticos admisibles


Con $g(x) = ax + b$ se tiene $\overline{g(x)} = a\bar{x} + b$, de modo que la comparación $\bar{x}_A > \bar{x}_B$ sobrevive para todo $a > 0$. La media es admisible en escala de intervalo.

	Moda <i>más frecuente</i>	Mediana $\hat{Q}(0,5)$	Media $\frac{1}{n} \sum_i x_i$	Media geom. $(\prod_i x_i)^{1/n}$	Coef. variación $\hat{\sigma} / \bar{x}$
Nominal	✓	—	—	—	—
Ordinal	✓	✓	—	—	—
Intervalo	✓	✓	✓	—	—
Razón	✓	✓	✓	✓	✓

El coeficiente de variación expresa la dispersión como fracción de la media. No es admisible en escala de intervalo, porque supone que el cero de la escala no es convencional.


Coeficiente de variación bajo cambio de escala

Dos grupos de mediciones de temperatura, expresadas en las dos escalas habituales.



Coeficiente de variación bajo cambio de escala

Dos grupos de mediciones de temperatura, expresadas en las dos escalas habituales.



En grados Celsius el grupo B tiene mayor coeficiente de variación que el A; en grados Fahrenheit la relación se invierte. Los datos son los mismos y la conversión es una transformación admisible en escala de intervalo, luego el enunciado “B es más variable que A” no es admisible. El coeficiente de variación exige escala de razón.

Continuas: el soporte determina la transformación

La escala de medida no agota la descripción. El **soporte** de la variable restringe las transformaciones razonables.

Soporte	Transformación	Justificación
$(0, \infty)$	$\log x$	simetriza el error multiplicativo
$[0, \infty)$	$\log(x + c), \sqrt{x}, \text{Yeo-Johnson}^\dagger$	admite el cero
$(0, 1)$	$\text{logit}(x) = \log \frac{x}{1-x}$	lleva el intervalo a $\mathbb{R}$
$\mathbb{N}_0$	$\sqrt{x}, \text{Anscombe } 2\sqrt{x + 3/8}$	estabiliza la varianza de Poisson
proporciones que suman uno	razón log-centrada (CLR)	elimina la restricción de suma
círculo S^1	$(\cos \theta, \sin \theta)$	respeta la periodicidad

[†] familia de potencias con exponente estimado de los datos.

Continuas: el soporte determina la transformación


La escala de medida no agota la descripción. El **soporte** de la variable restringe las transformaciones razonables.

Soporte	Transformación	Justificación
$(0, \infty)$	$\log x$	simetriza el error multiplicativo
$[0, \infty)$	$\log(x + c), \sqrt{x}, \text{Yeo-Johnson}^\dagger$	admite el cero
$(0, 1)$	$\text{logit}(x) = \log \frac{x}{1-x}$	lleva el intervalo a $\mathbb{R}$
$\mathbb{N}_0$	$\sqrt{x}, \text{Anscombe } 2\sqrt{x + 3/8}$	estabiliza la varianza de Poisson
proporciones que suman uno	razón log-centrada (CLR)	elimina la restricción de suma
círculo S^1	$(\cos \theta, \sin \theta)$	respeto la periodicidad

[†] familia de potencias con exponente estimado de los datos.

La familia que estabiliza la varianza se obtiene de $\text{Var}(X) = V(\mu)$ resolviendo $h(\mu) = \int V(\mu)^{-1/2} d\mu$. Para Poisson, $V(\mu) = \mu$ entrega $h(\mu) = 2\sqrt{\mu}$.

Continuas: efecto de la transformación



La asimetría $\hat{\gamma}_1$ del título mide cuán desbalanceadas están las dos colas; vale cero si la distribución es simétrica. Con $n = 40$ la media muestral de la variable original todavía conserva asimetría apreciable, mientras que en escala logarítmica la aproximación normal ya es adecuada. La transformación no cambia los datos, cambia la velocidad de convergencia de los procedimientos que los usan.

Categóricas nominales: codificación indicadora

Para $x \in \{c_1, \dots, c_K\}$ la codificación **one-hot** define $\phi(x) = (\mathbb{1}\{x = c_1\}, \dots, \mathbb{1}\{x = c_K\})^\top \in \{0, 1\}^K$.

Categóricas nominales: codificación indicadora

Para $x \in \{c_1, \dots, c_K\}$ la codificación **one-hot** define $\phi(x) = (\mathbb{1}\{x = c_1\}, \dots, \mathbb{1}\{x = c_K\})^\top \in \{0, 1\}^K$.

Esta codificación es la única compatible con la escala nominal, porque la distancia euclídea que induce es invariante a permutaciones de las etiquetas,

$$\|\phi(c_k) - \phi(c_l)\|_2 = \sqrt{2} \mathbb{1}\{k \neq l\}.$$

Catógoricas nominales: codificación indicadora

Para $x \in \{c_1, \dots, c_K\}$ la codificación **one-hot** define $\phi(x) = (\mathbb{1}\{x = c_1\}, \dots, \mathbb{1}\{x = c_K\})^\top \in \{0, 1\}^K$.

Esta codificación es la única compatible con la escala nominal, porque la distancia euclídea que induce es invariante a permutaciones de las etiquetas,

$$\|\phi(c_k) - \phi(c_l)\|_2 = \sqrt{2} \mathbb{1}\{k \neq l\}.$$

Sin embargo, la matriz resultante es **singular** al incluir intercepto, ya que $\sum_{k=1}^K \phi_k(x) = 1$ para todo x . La columna de unos pertenece al espacio generado por las K columnas indicadoras.

Catóricas nominales: codificación indicadora

Para $x \in \{c_1, \dots, c_K\}$ la codificación **one-hot** define $\phi(x) = (\mathbb{1}\{x = c_1\}, \dots, \mathbb{1}\{x = c_K\})^\top \in \{0, 1\}^K$.

Esta codificación es la única compatible con la escala nominal, porque la distancia euclídea que induce es invariante a permutaciones de las etiquetas,

$$\|\phi(c_k) - \phi(c_l)\|_2 = \sqrt{2} \mathbb{1}\{k \neq l\}.$$

Sin embargo, la matriz resultante es **singular** al incluir intercepto, ya que $\sum_{k=1}^K \phi_k(x) = 1$ para todo x . La columna de unos pertenece al espacio generado por las K columnas indicadoras.

Se elimina una categoría de referencia y quedan $K - 1$ columnas, la codificación *dummy*.

Codificación indicadora y distancias inducidas

one-hot: $\phi(c_k) = e_k$

J44	1	0	0
J45	0	1	0
I50	0	0	1
	e_1	e_2	e_3


distancias con one-hot

J44	0.00	1.41	1.41
J45	1.41	0.00	1.41
I50	1.41	1.41	0.00
	J44	J45	I50

distancias con código entero 0, 1, 2

J44	0.00	1.00	2.00
J45	1.00	0.00	1.00
I50	2.00	1.00	0.00
	J44	J45	I50

Codificación indicadora y distancias inducidas



Con one-hot las tres categorías quedan equidistantes, como corresponde a la escala nominal. Con el código entero, J44 e I50 quedan al doble de distancia que J44 y J45, afirmación que los datos no contienen y que introduce el orden alfabético de las etiquetas.

Categóricas de alta cardinalidad

Con K grande la codificación indicadora produce una matriz dispersa, con columnas de soporte reducido.

Estrategia	Definición	Riesgo principal
Agrupación	fusionar categorías con $n_k < n_0$	pérdida de resolución
Codificación por objetivo	$\hat{\theta}_k = \mathbb{E}[Y \mid x = c_k]$ suavizado	fuga de información
Truco del hash	$\phi(x) = e_{h(x) \bmod m}$	colisiones no controladas
Incrustación aprendida	$\phi(x) = W^\top e_x$, W entrenada	requiere n grande

Categóricas de alta cardinalidad

Con K grande la codificación indicadora produce una matriz dispersa, con columnas de soporte reducido.

Estrategia	Definición	Riesgo principal
Agrupación	fusionar categorías con $n_k < n_0$	pérdida de resolución
Codificación por objetivo	$\hat{\theta}_k = \mathbb{E}[Y \mid x = c_k]$ suavizado	fuga de información
Truco del hash	$\phi(x) = e_{h(x) \bmod m}$	colisiones no controladas
Incrustación aprendida	$\phi(x) = W^\top e_x$, W entrenada	requiere n grande

El suavizado empírico de Bayes contrae la media de la categoría hacia la media global,

$$\hat{\theta}_k = \frac{n_k \bar{y}_k + m \bar{y}}{n_k + m}.$$

Categóricas de alta cardinalidad

Con K grande la codificación indicadora produce una matriz dispersa, con columnas de soporte reducido.

Estrategia	Definición	Riesgo principal
Agrupación	fusionar categorías con $n_k < n_0$	pérdida de resolución
Codificación por objetivo	$\hat{\theta}_k = \mathbb{E}[Y \mid x = c_k]$ suavizado	fuga de información
Truco del hash	$\phi(x) = e_{h(x) \bmod m}$	colisiones no controladas
Incrustación aprendida	$\phi(x) = W^\top e_x$, W entrenada	requiere n grande


El suavizado empírico de Bayes contrae la media de la categoría hacia la media global,

$$\hat{\theta}_k = \frac{n_k \bar{y}_k + m \bar{y}}{n_k + m}.$$

$\hat{\theta}_k$ depende de Y . Estimarlos con todas las observaciones sesga hacia abajo el error de validación. Debe estimarse dentro de cada pliegue de la validación cruzada.


Categóricas de alta cardinalidad (contracción)

Ciento diez categorías con distinto número de observaciones. En rojo, la media cruda de cada una; en azul, la contraída hacia la media global.



Categóricas de alta cardinalidad (contracción)

Ciento diez categorías con distinto número de observaciones. En rojo, la media cruda de cada una; en azul, la contraída hacia la media global.



Con pocas observaciones la media cruda es ruido puro y la contracción la devuelve casi a la media global. Con muchas, ambas coinciden. El parámetro m fija dónde está el punto de equilibrio, aquí en veinte observaciones.

Categóricas ordinales

La codificación entera $\phi(c_k) = k$ conserva el orden y **añade** información no medida, porque impone $\phi(c_2) - \phi(c_1) = \phi(c_3) - \phi(c_2) = 1$. Esa igualdad no es invariante bajo transformaciones monótonas, luego no es admisible en escala ordinal.

Categorías ordinales

La codificación entera $\phi(c_k) = k$ conserva el orden y **añade** información no medida, porque impone $\phi(c_2) - \phi(c_1) = \phi(c_3) - \phi(c_2) = 1$. Esa igualdad no es invariante bajo transformaciones monótonas, luego no es admisible en escala ordinal.

Codificación	Supuesto	Uso apropiado
Entera $\phi(c_k) = k$	espaciado uniforme	árboles, tamaño muestral pequeño
One-hot	ninguno, pierde el orden	K pequeño, n grande
Acumulativa $\mathbb{1}\{x \geq c_k\}$	efectos monótonos	modelos lineales
Puntajes óptimos	estimados de los datos	análisis de correspondencias

Categorías ordinales

La codificación entera $\phi(c_k) = k$ conserva el orden y **añade** información no medida, porque impone $\phi(c_2) - \phi(c_1) = \phi(c_3) - \phi(c_2) = 1$. Esa igualdad no es invariante bajo transformaciones monótonas, luego no es admisible en escala ordinal.

Codificación	Supuesto	Uso apropiado
Entera $\phi(c_k) = k$	espaciado uniforme	árboles, tamaño muestral pequeño
One-hot	ninguno, pierde el orden	K pequeño, n grande
Acumulativa $\mathbb{1}\{x \geq c_k\}$	efectos monótonos	modelos lineales
Puntajes óptimos	estimados de los datos	análisis de correspondencias

Los indicadores acumulativos $\mathbb{1}\{x \geq c_k\}$, $k = 2, \dots, K$, conservan el orden sin imponer espaciado. Sus coeficientes son los incrementos entre niveles consecutivos.

Categóricas ordinales: las tres codificaciones

Seis pacientes con severidad registrada en cuatro niveles, escritos como columnas de números.

entera

p1	1
p2	3
p3	0
p4	2
p5	1
p6	3
	ϕ

one-hot

p1	0	1	0	0
p2	0	0	0	1
p3	1	0	0	0
p4	0	0	1	0
p5	0	1	0	0
p6	0	0	0	1
	ning.	leve	mod.	grave

acumulativa

p1	1	0	0
p2	1	1	1
p3	0	0	0
p4	1	1	0
p5	1	0	0
p6	1	1	1
	$\geq$ leve	$\geq$ mod.	grave

Categóricas ordinales: las tres codificaciones

Seis pacientes con severidad registrada en cuatro niveles, escritos como columnas de números.



entera	
p1	1
p2	3
p3	0
p4	2
p5	1
p6	3
ϕ	

one-hot				
p1	0	1	0	0
p2	0	0	0	1
p3	1	0	0	0
p4	0	0	1	0
p5	0	1	0	0
p6	0	0	0	1
	ning.	leve	mod.	grave

acumulativa			
p1	1	0	0
p2	1	1	1
p3	0	0	0
p4	1	1	0
p5	1	0	0
p6	1	1	1
	$\geq$ leve	$\geq$ mod.	grave

La entera gasta una columna y afirma que los cuatro niveles están igualmente espaciados. La one-hot gasta cuatro y descarta el orden. La acumulativa gasta tres, conserva el orden y no impone espaciado, porque cada columna responde una pregunta de sí o no.




Categóricas ordinales: consecuencia empírica



Los datos fueron generados con efecto casi nulo entre los tres primeros niveles y un salto grande en el último. La codificación entera reparte ese salto de manera uniforme y sesga la predicción en los cuatro niveles.




Variables cíclicas

Para un ángulo o una hora, la codificación entera introduce una discontinuidad artificial en el punto de reinicio.



Variables cíclicas

Para un ángulo o una hora, la codificación entera introduce una discontinuidad artificial en el punto de reinicio.



La inmersión $\phi(\theta) = (\cos \theta, \sin \theta)$ satisface $\|\phi(\theta_1) - \phi(\theta_2)\|_2 = 2|\sin \frac{\theta_1 - \theta_2}{2}|$, que es función únicamente de la diferencia angular. Es el análogo de la codificación indicadora para el grupo de rotaciones.

Series de tiempo

Una serie es una función $t \mapsto y_t$ sobre un índice ordenado. Sus filas **no son intercambiables**.

$$\mathbb{E}[y_t] = \mu, \quad \text{Cov}(y_t, y_{t+h}) = \gamma(h) \quad (\text{estacionariedad débil})$$

Series de tiempo

Una serie es una función $t \mapsto y_t$ sobre un índice ordenado. Sus filas **no son intercambiables**.

$$\mathbb{E}[y_t] = \mu, \quad \text{Cov}(y_t, y_{t+h}) = \gamma(h) \quad (\text{estacionariedad débil})$$

La representación supervisada se obtiene por **ventanas deslizantes**,

$$\mathbf{x}_t = (y_{t-1}, \dots, y_{t-L})^\top, \quad \text{objetivo } y_t,$$

lo que reduce el problema a una tabla al costo de fijar el rezago L .

Series de tiempo

Una serie es una función $t \mapsto y_t$ sobre un índice ordenado. Sus filas **no son intercambiables**.

$$\mathbb{E}[y_t] = \mu, \quad \text{Cov}(y_t, y_{t+h}) = \gamma(h) \quad (\text{estacionariedad débil})$$

La representación supervisada se obtiene por **ventanas deslizantes**,

$$\mathbf{x}_t = (y_{t-1}, \dots, y_{t-L})^\top, \quad \text{objetivo } y_t,$$

lo que reduce el problema a una tabla al costo de fijar el rezago L .

El muestreo aleatorio de filas para validación es inválido, porque las ventanas comparten valores de y . La partición debe respetar el orden temporal.

Texto: la bolsa de palabras

Se fija un **vocabulario** V , que es la lista de términos que se van a contar, y se descartan los artículos, las preposiciones y demás palabras sin contenido. Cada documento pasa a ser un vector con una coordenada por término.

$\text{tf}(v, d)$ = número de veces que el término v aparece en el documento d

Texto: la bolsa de palabras

Se fija un **vocabulario** V , que es la lista de términos que se van a contar, y se descartan los artículos, las preposiciones y demás palabras sin contenido. Cada documento pasa a ser un vector con una coordenada por término.

$\text{tf}(v, d) =$ número de veces que el término v aparece en el documento d

Para el documento d_1 , “paciente con tos y disnea, sibilancias en la espiración”,

v	paciente	tos	disnea	sibilancias	espiración	control	presión	arterial
$\text{tf}(v, d_1)$	1	1	1	1	1	0	0	0

Texto: la bolsa de palabras

Se fija un **vocabulario** V , que es la lista de términos que se van a contar, y se descartan los artículos, las preposiciones y demás palabras sin contenido. Cada documento pasa a ser un vector con una coordenada por término.

$\text{tf}(v, d) =$ número de veces que el término v aparece en el documento d

Para el documento d_1 , “paciente con tos y disnea, sibilancias en la espiración”,

v	paciente	tos	disnea	sibilancias	espiración	control	presión	arterial
$\text{tf}(v, d_1)$	1	1	1	1	1	0	0	0

El vector $\phi(d_1) = (\text{tf}(v_1, d_1), \dots, \text{tf}(v_{|V|}, d_1))$ vive en $\mathbb{N}_0^{|V|}$. Con un vocabulario real de decenas de miles de términos, casi todas sus coordenadas son cero.

Texto: TF-IDF

En el corpus de cuatro notas clínicas, el término “paciente” aparece en las cuatro. Contarlo no ayuda a distinguirlas.

Texto: TF-IDF

En el corpus de cuatro notas clínicas, el término “paciente” aparece en las cuatro. Contarlo no ayuda a distinguirlas.

Sea $df(v)$ el **número de documentos que contienen** v , de un total de N . La frecuencia inversa de documento penaliza los términos ubicuos,

$$idf(v) = \log \frac{N}{df(v)}, \quad w_{v,d} = tf(v,d) \cdot idf(v).$$

Texto: TF-IDF

En el corpus de cuatro notas clínicas, el término “paciente” aparece en las cuatro. Contarlo no ayuda a distinguirlas.

Sea $df(v)$ el **número de documentos que contienen** v , de un total de N . La frecuencia inversa de documento penaliza los términos ubicuos,

$$idf(v) = \log \frac{N}{df(v)},$$

$$w_{v,d} = tf(v, d) \cdot idf(v).$$

v	$tf(v, d_1)$	$df(v)$	$idf(v) = \log(4/df)$	w_{v,d_1}
paciente	1	4	$\log 1 = 0,00$	0,00
tos	1	2	$\log 2 = 0,69$	0,69
disnea	1	2	$\log 2 = 0,69$	0,69
espiración	1	1	$\log 4 = 1,39$	1,39
control	0	2	$\log 2 = 0,69$	0,00


Un término presente en todos los documentos recibe peso cero.

Uno presente en uno solo recibe el peso máximo.


El conteo mide presencia, TF-IDF mide **capacidad de distinguir**.

Texto: de documentos a vectores

Normalizando $\hat{w}_d = w_{\cdot,d} / \|w_{\cdot,d}\|_2$, la similitud es el **coseno** del ángulo entre ambos vectores, $\text{sim}(d_1, d_2) = \langle \hat{w}_{d_1}, \hat{w}_{d_2} \rangle$. Se normaliza porque la norma crece con la longitud del documento, que es formato y no contenido.




similitud coseno TF-IDF




Texto: de documentos a vectores

Normalizando $\hat{w}_d = w_{.,d} / \|w_{.,d}\|_2$, la similitud es el **coseno** del ángulo entre ambos vectores, $\text{sim}(d_1, d_2) = \langle \hat{w}_{d_1}, \hat{w}_{d_2} \rangle$. Se normaliza porque la norma crece con la longitud del documento, que es formato y no contenido.



similitud coseno TF-IDF



d_1 y d_2 son notas respiratorias, d_3 y d_4 cardiovasculares. La similitud recupera esa agrupación sin que nadie la haya declarado. La columna "paciente" tiene un uno en las cuatro filas y no contribuye a ninguna similitud, porque su peso IDF es cero.

Texto: representación distribuida

Las incrustaciones densas asignan $\phi(v) \in \mathbb{R}^d$ con $d \ll |V|$, estimadas de modo que términos con contextos similares reciban vectores próximos.

	Bolsa de palabras	TF-IDF	Incrustación
Dimensión	$ V \sim 10^4\text{--}10^6$	igual	$10^2\text{--}10^3$
Densidad	dispersa	dispersa	densa
Orden de palabras	no	no	según el modelo
Sinonimia	no capturada	no capturada	capturada
Interpretabilidad	directa	directa	nula por coordenada
Requiere corpus externo	no	no	habitualmente

Texto: representación distribuida

Las incrustaciones densas asignan $\phi(v) \in \mathbb{R}^d$ con $d \ll |V|$, estimadas de modo que términos con contextos similares reciban vectores próximos.

	Bolsa de palabras	TF-IDF	Incrustación
Dimensión	$ V \sim 10^4\text{--}10^6$	igual	$10^2\text{--}10^3$
Densidad	dispersa	dispersa	densa
Orden de palabras	no	no	según el modelo
Sinonimia	no capturada	no capturada	capturada
Interpretabilidad	directa	directa	nula por coordenada
Requiere corpus externo	no	no	habitualmente

Para el análisis exploratorio la representación por conteos es preferible, porque cada coordenada tiene nombre. Las incrustaciones se justifican cuando el objetivo es predictivo.


Imágenes

Una imagen es un tensor $I \in \mathbb{R}^{H \times W \times C}$. El aplanamiento $\text{vec}(I) \in \mathbb{R}^{HWC}$ apila los píxeles en un vector, sin perder ningún dato.


Imágenes

Una imagen es un tensor $I \in \mathbb{R}^{H \times W \times C}$. El aplanamiento $\text{vec}(I) \in \mathbb{R}^{HWC}$ apila los píxeles en un vector, sin perder ningún dato.


original



el mismo, desplazado
 $d = 28.1$




un dibujo distinto
 $d = 26.2$



Imágenes

Una imagen es un tensor $I \in \mathbb{R}^{H \times W \times C}$. El aplanamiento $\text{vec}(I) \in \mathbb{R}^{HWC}$ apila los píxeles en un vector, sin perder ningún dato.




Los trazos son delgados, de modo que al desplazarse casi no coinciden con los originales y la distancia se acerca a su **máximo posible**, $\sqrt{2k}$ con k píxeles encendidos. El mismo gato movido queda **más lejos** que una casa.


Grafos: el objeto y su matriz

Un grafo $G = (V, E)$ con $|V| = m$ nodos se describe por la **matriz de adyacencia** $A \in \{0, 1\}^{m \times m}$, donde $A_{uv} = 1$ si existe arista entre u y v .

grafo G : 9 nodos, 16 aristas




matriz de adyacencia $\mathbf{A}$




Grafos: el objeto y su matriz

Un grafo $G = (V, E)$ con $|V| = m$ nodos se describe por la **matriz de adyacencia** $A \in \{0, 1\}^{m \times m}$, donde $A_{uv} = 1$ si existe arista entre u y v .

grafo G : 9 nodos, 16 aristas



matriz de adyacencia A






Cada nodo puede además llevar atributos propios, reunidos en $H \in \mathbb{R}^{m \times q}$.
En una red de contactos, A dice quién se relaciona con quién y H dice la edad y el diagnóstico de cada persona.

Grafos: el problema de la numeración

Los nodos no vienen numerados. Renumerarlos cambia A sin cambiar el grafo.




mismo grafo, otra numeración



Grafos: el problema de la numeración


Los nodos no vienen numerados. Renumerarlos cambia A sin cambiar el grafo.

mismo grafo, otra numeración




Las dos matrices son distintas y describen el mismo objeto. Por lo tanto $\text{vec}(A)$ no está bien definido como representación. Una representación admisible debe ser una función **invariante bajo permutaciones** de los nodos, es decir, entregar el mismo valor sea cual sea la numeración.


Grafos: representaciones invariantes




vector de Fiedler: separa las dos comunidades



Grafos: representaciones invariantes



vector de Fiedler: separa las dos comunidades



Representación invariante	Construcción
---------------------------	--------------

Estadísticos de resumen	grado medio, densidad, coeficiente de agrupamiento, diámetro
Espectro laplaciano	valores propios de $\mathbf{L} = \mathbf{D} - \mathbf{A}$
Recuento de subgrafos	frecuencia de triángulos, estrellas, ciclos
Núcleos de grafo	Weisfeiler–Lehman, recorridos aleatorios
Incrustaciones aprendidas	agregación simétrica sobre el vecindario

Representaciones (resumen)

Tipo	Espacio $\mathcal{X}$	Representación ϕ	Disimilitud
Continua	$\mathbb{R}$ o subconjunto	identidad o transformación de soporte	$ x_1 - x_2 $
Conteo	$\mathbb{N}_0$	$\sqrt{x}, \log(1 + x)$	euclídea
Nominal	$\{c_1, \dots, c_K\}$	one-hot	Hamming, χ^2
Ordinal	orden total	acumulativa	orden, Kendall
Cíclica	S^1	$(\cos \theta, \sin \theta)$	angular
Composicional	Δ^{K-1}	razón log-centrada	Aitchison
Conjunto binario	$\{0, 1\}^K$	indicadores	Jaccard
Texto	secuencias	TF-IDF o incrustación	coseno
Imagen	$\mathbb{R}^{H \times W \times C}$	características convolucionales	euclídea en el espacio latente
Serie temporal	$\mathbb{R}^T$	ventanas, coeficientes espectrales	deformación temporal dinámica
Grafo	(V, E)	espectro, núcleo	núcleo de grafo
Mixta	producto	por columna	Gower

Representaciones (resumen)

Tipo	Espacio $\mathcal{X}$	Representación ϕ	Disimilitud
Continua	$\mathbb{R}$ o subconjunto	identidad o transformación de soporte	$ x_1 - x_2 $
Conteo	$\mathbb{N}_0$	$\sqrt{x}, \log(1 + x)$	euclídea
Nominal	$\{c_1, \dots, c_K\}$	one-hot	Hamming, χ^2
Ordinal	orden total	acumulativa	orden, Kendall
Cíclica	S^1	$(\cos \theta, \sin \theta)$	angular
Composicional	Δ^{K-1}	razón log-centrada	Aitchison
Conjunto binario	$\{0, 1\}^K$	indicadores	Jaccard
Texto	secuencias	TF-IDF o incrustación	coseno
Imagen	$\mathbb{R}^{H \times W \times C}$	características convolucionales	euclídea en el espacio latente
Serie temporal	$\mathbb{R}^T$	ventanas, coeficientes espectrales	deformación temporal dinámica
Grafo	(V, E)	espectro, núcleo	núcleo de grafo
Mixta	producto	por columna	Gower

La columna de disimilitud es la que consumen algoritmos de ML: agrupamiento, los vecinos más cercanos, métodos basados en kernels. Elegir la representación equivale a elegir la geometría del problema.

Disimilitud para datos mixtos

Una función d es una **métrica** si vale cero solo entre elementos iguales, es simétrica, y cumple la **desigualdad triangular** $d(x, z) \leq d(x, y) + d(y, z)$, es decir, pasar por un tercer punto nunca acorta el camino.

Disimilitud para datos mixtos

Una función d es una **métrica** si vale cero solo entre elementos iguales, es simétrica, y cumple la **desigualdad triangular** $d(x, z) \leq d(x, y) + d(y, z)$, es decir, pasar por un tercer punto nunca acorta el camino.

El coeficiente de **Gower** promedia disimilitudes por columna normalizadas a $[0, 1]$,

$$d_G(\mathbf{x}_i, \mathbf{x}_j) = \frac{\sum_{k=1}^p w_k \delta_{ijk} d_k(x_{ik}, x_{jk})}{\sum_{k=1}^p w_k \delta_{ijk}},$$

con $\delta_{ijk} = 1$ si ambas observaciones tienen la columna k registrada, y

$$d_k = \frac{|x_{ik} - x_{jk}|}{R_k} \text{ si es continua,} \quad d_k = \mathbb{1}\{x_{ik} \neq x_{jk}\} \text{ si es nominal.}$$

Disimilitud para datos mixtos

Una función d es una **métrica** si vale cero solo entre elementos iguales, es simétrica, y cumple la **desigualdad triangular** $d(x, z) \leq d(x, y) + d(y, z)$, es decir, pasar por un tercer punto nunca acorta el camino.

El coeficiente de **Gower** promedia disimilitudes por columna normalizadas a $[0, 1]$,

$$d_G(\mathbf{x}_i, \mathbf{x}_j) = \frac{\sum_{k=1}^p w_k \delta_{ijk} d_k(x_{ik}, x_{jk})}{\sum_{k=1}^p w_k \delta_{ijk}},$$

con $\delta_{ijk} = 1$ si ambas observaciones tienen la columna k registrada, y

$$d_k = \frac{|x_{ik} - x_{jk}|}{R_k} \text{ si es continua,} \quad d_k = \mathbb{1}\{x_{ik} \neq x_{jk}\} \text{ si es nominal.}$$

El rango R_k se estima de la muestra, así que debe calcularse en el pliegue de entrenamiento.

Datos faltantes como información

Tres situaciones distintas suelen compartir el mismo símbolo en el archivo.

1. **Ausencia estructural**, cuando la variable no aplica a la observación.
2. **Ausencia por no respuesta**, cuando la variable aplica y no fue registrada.
3. **Codificación centinela**, con el faltante almacenado como —99 o cadena vacía.

Datos faltantes como información

Tres situaciones distintas suelen compartir el mismo símbolo en el archivo.

1. **Ausencia estructural**, cuando la variable no aplica a la observación.
2. **Ausencia por no respuesta**, cuando la variable aplica y no fue registrada.
3. **Codificación centinela**, con el faltante almacenado como `—99` o cadena vacía.

```
df = pl.DataFrame({"edad": [34, -99, 51, None], "grupo": ["a", "b", "", None]})
lim = df.with_columns(
    # -99 y "" son centinelas, no valores
    pl.when(pl.col("edad") < 0).then(None).otherwise(pl.col("edad")).alias("edad"),
    pl.col("grupo").replace("", None),
)
print("nulos:", dict(zip(lim.columns, lim.null_count().row(0))))
```

```
nulos: {'edad': 2, 'grupo': 2}
```


Datos faltantes como información

Tres situaciones distintas suelen compartir el mismo símbolo en el archivo.

1. **Ausencia estructural**, cuando la variable no aplica a la observación.
2. **Ausencia por no respuesta**, cuando la variable aplica y no fue registrada.
3. **Codificación centinela**, con el faltante almacenado como -99 o cadena vacía.

```
df = pl.DataFrame({"edad": [34, -99, 51, None], "grupo": ["a", "b", "", None]})
lim = df.with_columns(                                     # -99 y "" son centinelas, no valores
    pl.when(pl.col("edad") < 0).then(None).otherwise(pl.col("edad")).alias("edad"),
    pl.col("grupo").replace("", None),
)
print("nulos:", dict(zip(lim.columns, lim.null_count().row(0))))
```

```
nulos: {'edad': 2, 'grupo': 2}
```

La ausencia puede ser informativa. El indicador $\mathbb{1}\{x_j \text{ faltante}\}$ como columna adicional permite usarla, si el mecanismo se mantiene en producción.

Tipo lógico y tipo físico

El tipo lógico corresponde a la escala de medida; el tipo físico, al formato de almacenamiento.

```
import polars as pl
df = pl.DataFrame({
    "id":      pl.Series([1, 2, 3], dtype=pl.UInt32),
    "sever":   pl.Series(["leve", "grave", "leve"],
                        dtype=pl.Enum(["leve", "moderado", "grave"])),
    "vef":     pl.Series([3.1, 2.4, 2.9], dtype=pl.Float32),
})
print(df.schema)
```

```
Schema({'id': UInt32, 'sever': Enum(categories=['leve', 'moderado', 'grave']), 'vef': Float32})
```

Tipo lógico y tipo físico

El tipo lógico corresponde a la escala de medida; el tipo físico, al formato de almacenamiento.

```
import polars as pl
df = pl.DataFrame({
    "id":      pl.Series([1, 2, 3], dtype=pl.UInt32),
    "sever":   pl.Series(["leve", "grave", "leve"],
                        dtype=pl.Enum(["leve", "moderado", "grave"])),
    "vef":     pl.Series([3.1, 2.4, 2.9], dtype=pl.Float32),
})
print(df.schema)
```

```
Schema({'id': UInt32, 'sever': Enum(categories=['leve', 'moderado', 'grave']), 'vef': Float32})
```

Enum de Polars y dictionary de Arrow almacenan los niveles junto a los datos, con lo que se detectan categorías no observadas en una partición y se preserva el orden declarado.

Tipo lógico y tipo físico

El tipo lógico corresponde a la escala de medida; el tipo físico, al formato de almacenamiento.

```
import polars as pl
df = pl.DataFrame({
    "id":      pl.Series([1, 2, 3], dtype=pl.UInt32),
    "sever":   pl.Series(["leve", "grave", "leve"],
                        dtype=pl.Enum(["leve", "moderado", "grave"])),
    "vef":     pl.Series([3.1, 2.4, 2.9], dtype=pl.Float32),
})
print(df.schema)
```

```
Schema({'id': UInt32, 'sever': Enum(categories=['leve', 'moderado', 'grave']), 'vef': Float32})
```

Enum de Polars y dictionary de Arrow almacenan los niveles junto a los datos, con lo que se detectan categorías no observadas en una partición y se preserva el orden declarado.

La lectura automática de un archivo delimitado infiere el tipo físico, nunca el lógico. Un código de diagnóstico almacenado como entero admitirá toda operación aritmética.

Las tres decisiones de la tabla inicial

Las tres decisiones planteadas al comienzo se resuelven con los criterios vistos.

Estadísticos admisibles. diagnóstico es nominal y solo admite la moda; severidad es ordinal y admite hasta la mediana. El promedio exige escala de intervalo.

Las tres decisiones de la tabla inicial

Las tres decisiones planteadas al comienzo se resuelven con los criterios vistos.

Estadísticos admisibles. diagnóstico es nominal y solo admite la moda; severidad es ordinal y admite hasta la mediana. El promedio exige escala de intervalo.

Distancia entre pacientes. La disimilitud de Gower sobre las cinco columnas:

disimilitud de Gower entre los cuatro pacientes

1041	0.00	0.76	0.24	0.71
1042	0.76	0.00	1.00	0.33
1043	0.24	1.00	0.00	0.92
1044	0.71	0.33	0.92	0.00
	1041	1042	1043	1044

Las tres decisiones de la tabla inicial

Las tres decisiones planteadas al comienzo se resuelven con los criterios vistos.

Estadísticos admisibles. diagnóstico es nominal y solo admite la moda; severidad es ordinal y admite hasta la mediana. El promedio exige escala de intervalo.

Distancia entre pacientes. La disimilitud de Gower sobre las cinco columnas:

disimilitud de Gower entre los cuatro pacientes

1041	0.00	0.76	0.24	0.71
1042	0.76	0.00	1.00	0.33
1043	0.24	1.00	0.00	0.92
1044	0.71	0.33	0.92	0.00
	1041	1042	1043	1044

Celda sin registrar. Se representa como nulo, con su indicador si la ausencia informa. Gower opera sin imputar, promediando solo las columnas presentes en ambos pacientes.

Referencias

- Stevens, S. S. (1946). On the theory of scales of measurement. *Science*, 103(2684), 677–680.
- Krantz, D., Luce, R. D., Suppes, P., Tversky, A. (1971). *Foundations of Measurement*, vol. 1. Academic Press.
- Velleman, P. F., Wilkinson, L. (1993). Nominal, ordinal, interval and ratio typologies are misleading. *The American Statistician*, 47(1), 65–72.
- Aitchison, J. (1986). *The Statistical Analysis of Compositional Data*. Chapman and Hall.
- Wickham, H. (2014). Tidy data. *Journal of Statistical Software*, 59(10).
- Micci-Barreca, D. (2001). A preprocessing scheme for high-cardinality categorical attributes. *SIGKDD Explorations*, 3(1), 27–32.
- Gower, J. C. (1971). A general coefficient of similarity and some of its properties. *Biometrics*, 27(4), 857–871.
- Bronstein, M. et al. (2021). Geometric deep learning: grids, groups, graphs, geodesics and gauges.