

Análisis exploratorio de datos

Conceptos, herramientas y métodos gráficos

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos




Objetivos

- Delimitar el análisis exploratorio frente al análisis confirmatorio y cuantificar el costo inferencial de explorar.
- Definir estimador, sesgo, varianza y error cuadrático medio, y descomposición del error.
- Interpretar la función de distribución empírica y su garantía uniforme de muestra finita.
- Comparar las reglas habituales para elegir el número de intervalos del histograma y sus supuestos sobre la densidad.
- Elegir métodos gráficos univariados y bivariados según la escala de medida de las variables.
- Distinguir las medidas de asociación que caracterizan la independencia de las que sólo detectan relación lineal o monótona.


Un caso: un biomarcador con asociación significativa

Un estudio con cien pacientes mide varios biomarcadores y evalúa cuál se asocia con la respuesta al tratamiento. El que presenta mayor asociación se muestra a continuación.



Un caso: un biomarcador con asociación significativa

Un estudio con cien pacientes mide varios biomarcadores y evalúa cuál se asocia con la respuesta al tratamiento. El que presenta mayor asociación se muestra a continuación.




La correlación $r \in [-1, 1]$ mide cuánto se acercan los puntos a una recta; aquí $r = 0,23$, asociación positiva moderada.

El valor p es la probabilidad de observar una asociación al menos así de grande **si en realidad no hubiera ninguna**. Como $p < 0,05$, el resultado se declararía significativo.


El costo inferencial de explorar

El biomarcador anterior es el de mayor correlación entre **cien variables de puro ruido**, **ninguna con relación real con la respuesta**. Cada histograma repite el experimento tres mil veces y anota en cada repetición la mayor correlación observada entre las k variables candidatas.



El costo inferencial de explorar

El biomarcador anterior es el de mayor correlación entre **cien variables de puro ruido, ninguna con relación real con la respuesta**. Cada histograma repite el experimento tres mil veces y anota en cada repetición la mayor correlación observada entre las k variables candidatas.



Con una variable, el histograma verde cruza la línea gris el 5 % de las veces, la tasa de falsos positivos aceptada. Con cien candidatas **la ganadora la cruza casi siempre**, y el hallazgo es un valor corriente de ese ruido. El valor p respondía por una variable fijada de antemano, no por la ganadora de cien.

El análisis exploratorio

Tukey (1977) distingue dos actividades con objetivos y garantías distintas.

	Exploratorio	Confirmatorio
Pregunta	Qué estructura hay	La hipótesis H_0 es sostenible
Hipótesis	Se genera de los datos	Fijada antes de ver los datos
Herramienta	Gráficos, resúmenes, residuos	Prueba, intervalo, valor p
Garantía formal	Ninguna	Control del error de tipo I
Riesgo	Sobreinterpretar ruido	No detectar estructura real


El análisis exploratorio

Tukey (1977) distingue dos actividades con objetivos y garantías distintas.

	Exploratorio	Confirmatorio
Pregunta	Qué estructura hay	La hipótesis H_0 es sostenible
Hipótesis	Se genera de los datos	Fijada antes de ver los datos
Herramienta	Gráficos, resúmenes, residuos	Prueba, intervalo, valor p
Garantía formal	Ninguna	Control del error de tipo I
Riesgo	Sobreinterpretar ruido	No detectar estructura real


La formulación de Tukey se resume en que es preferible una respuesta aproximada a la pregunta correcta que una respuesta exacta a la pregunta equivocada. El EDA determina cuál es la pregunta.

Alcance de los resúmenes numéricos



	$\bar{x}$	$\hat{\sigma}_x$	$\bar{y}$	$\hat{\sigma}_y$	r_{xy}
Los cuatro conjuntos	9,00	3,32	7,50	2,03	0,816

Alcance de los resúmenes numéricos



	$\bar{x}$	$\hat{\sigma}_x$	$\bar{y}$	$\hat{\sigma}_y$	r_{xy}
Los cuatro conjuntos	9,00	3,32	7,50	2,03	0,816

Los primeros dos momentos y la correlación coinciden en los cuatro conjuntos, y la recta de mínimos cuadrados es la misma. Sólo el tercero es apropiado para el modelo lineal. Los resúmenes numéricos son proyecciones de la distribución y una proyección admite muchas preimágenes.

Estimar una cantidad desconocida

Los resúmenes de Anscombe son proyecciones de la distribución. Antes de estimar la distribución completa debemos estudiar qué significa estimar bien.

Estimar una cantidad desconocida

Los resúmenes de Anscombe son proyecciones de la distribución. Antes de estimar la distribución completa debemos estudiar qué significa estimar bien.

Un **estimador** es cualquier función de los datos, $\hat{\theta}_n = g(X_1, \dots, X_n)$, construida para aproximar una cantidad desconocida θ . El parámetro θ es una constante; el estimador es aleatorio, porque depende de qué muestra se obtuvo.

Estimar una cantidad desconocida

Los resúmenes de Anscombe son proyecciones de la distribución. Antes de estimar la distribución completa debemos estudiar qué significa estimar bien.

Un **estimador** es cualquier función de los datos, $\hat{\theta}_n = g(X_1, \dots, X_n)$, construida para aproximar una cantidad desconocida θ . El parámetro θ es una constante; el estimador es aleatorio, porque depende de qué muestra se obtuvo.

$$\text{sesgo}(\hat{\theta}_n) = \mathbb{E}(\hat{\theta}_n) - \theta, \quad \text{Var}(\hat{\theta}_n) = \mathbb{E}[(\hat{\theta}_n - \mathbb{E}\hat{\theta}_n)^2].$$

Estimar una cantidad desconocida

Los resúmenes de Anscombe son proyecciones de la distribución. Antes de estimar la distribución completa debemos estudiar qué significa estimar bien.

Un **estimador** es cualquier función de los datos, $\hat{\theta}_n = g(X_1, \dots, X_n)$, construida para aproximar una cantidad desconocida θ . El parámetro θ es una constante; el estimador es aleatorio, porque depende de qué muestra se obtuvo.

$$\text{sesgo}(\hat{\theta}_n) = \mathbb{E}(\hat{\theta}_n) - \theta, \quad \text{Var}(\hat{\theta}_n) = \mathbb{E}[(\hat{\theta}_n - \mathbb{E}\hat{\theta}_n)^2].$$

El sesgo mide el desvío sistemático y la varianza la inestabilidad ante el cambio de muestra. El estimador es **consistente** si $\hat{\theta}_n \rightarrow \theta$ en probabilidad.

Estimar una cantidad desconocida

Los resúmenes de Anscombe son proyecciones de la distribución. Antes de estimar la distribución completa debemos estudiar qué significa estimar bien.

Un **estimador** es cualquier función de los datos, $\hat{\theta}_n = g(X_1, \dots, X_n)$, construida para aproximar una cantidad desconocida θ . El parámetro θ es una constante; el estimador es aleatorio, porque depende de qué muestra se obtuvo.

$$\text{sesgo}(\hat{\theta}_n) = \mathbb{E}(\hat{\theta}_n) - \theta, \quad \text{Var}(\hat{\theta}_n) = \mathbb{E}[(\hat{\theta}_n - \mathbb{E}\hat{\theta}_n)^2].$$

El sesgo mide el desvío sistemático y la varianza la inestabilidad ante el cambio de muestra. El estimador es **consistente** si $\hat{\theta}_n \rightarrow \theta$ en probabilidad.

La distribución empírica estima F , el histograma y el kernel estiman la densidad f , y $\bar{x}$, $\hat{\sigma}$ y $\hat{Q}(p)$ estiman sus contrapartes poblacionales.

Error cuadrático medio

El criterio que combina sesgo y varianza en un solo número es:

$$\text{ECM}(\hat{\theta}_n) = \mathbb{E}[(\hat{\theta}_n - \theta)^2].$$

Error cuadrático medio

El criterio que combina sesgo y varianza en un solo número es:

$$\text{ECM}(\hat{\theta}_n) = \mathbb{E}[(\hat{\theta}_n - \theta)^2].$$

Sumando y restando $\mathbb{E}(\hat{\theta}_n)$ dentro del cuadrado, el término cruzado se anula y queda:

$$\text{ECM}(\hat{\theta}_n) = \text{sesgo}^2(\hat{\theta}_n) + \text{Var}(\hat{\theta}_n).$$

Error cuadrático medio

El criterio que combina sesgo y varianza en un solo número es:

$$\text{ECM}(\hat{\theta}_n) = \mathbb{E}[(\hat{\theta}_n - \theta)^2].$$

Sumando y restando $\mathbb{E}(\hat{\theta}_n)$ dentro del cuadrado, el término cruzado se anula y queda:

$$\text{ECM}(\hat{\theta}_n) = \text{sesgo}^2(\hat{\theta}_n) + \text{Var}(\hat{\theta}_n).$$

No existe razón para exigir sesgo nulo. Un estimador insesgado con varianza grande es peor que uno levemente sesgado con varianza pequeña, y esa comparación es la que más adelante decidirá el ancho del histograma.

Error cuadrático medio

El criterio que combina sesgo y varianza en un solo número es:

$$\text{ECM}(\hat{\theta}_n) = \mathbb{E}[(\hat{\theta}_n - \theta)^2].$$

Sumando y restando $\mathbb{E}(\hat{\theta}_n)$ dentro del cuadrado, el término cruzado se anula y queda:

$$\text{ECM}(\hat{\theta}_n) = \text{sesgo}^2(\hat{\theta}_n) + \text{Var}(\hat{\theta}_n).$$

No existe razón para exigir sesgo nulo. Un estimador insesgado con varianza grande es peor que uno levemente sesgado con varianza pequeña, y esa comparación es la que más adelante decidirá el ancho del histograma.



Cuando lo estimado es una **curva** y no un número, el error se integra sobre todo el dominio:

$$\text{MISE} = \mathbb{E} \int (\hat{f}(x) - f(x))^2 dx = \int \text{sesgo}^2(x) dx + \int \text{Var}(x) dx,$$

identidad que resulta de aplicar la descomposición anterior en cada x e integrar.



Construcción de la distribución empírica

Con siete observaciones, $F_n(x)$ es la proporción de datos que no supera a x .



Construcción de la distribución empírica

Con siete observaciones, $F_n(x)$ es la proporción de datos que no supera a x .



La construcción es determinista dados los datos, no requiere fijar ningún parámetro y usa toda la información de la muestra.

El histograma, en cambio, exige fijar el ancho de los intervalos antes de poder dibujarse.

La función de distribución empírica

El objeto básico del EDA univariado es:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n 1\{X_i \leq x\},$$

escalonada, no decreciente, con saltos de tamaño $1/n$ en cada observación.

La función de distribución empírica

El objeto básico del EDA univariado es:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n 1\{X_i \leq x\},$$

escalonada, no decreciente, con saltos de tamaño $1/n$ en cada observación.

Para x fijo, $nF_n(x) \sim \text{Binomial}(n, F(x))$, luego $F_n(x)$ es insesgada y su varianza, $F(x)(1 - F(x))/n$, tiende a cero. El estimador es consistente.

La función de distribución empírica

El objeto básico del EDA univariado es:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n 1\{X_i \leq x\},$$


escalonada, no decreciente, con saltos de tamaño $1/n$ en cada observación.

Para x fijo, $nF_n(x) \sim \text{Binomial}(n, F(x))$, luego $F_n(x)$ es insesgada y su varianza, $F(x)(1 - F(x))/n$, tiende a cero. El estimador es consistente.


Glivenko–Cantelli. $\sup_x |F_n(x) - F(x)| \xrightarrow{\text{c.s.}} 0$. **DKW.** $\mathbb{P}(\sup_x |F_n - F| > \varepsilon) \leq 2e^{-2n\varepsilon^2}$.

Banda uniforme de nivel $1 - \alpha$ con $\varepsilon_n = \sqrt{\frac{1}{2n} \log \frac{2}{\alpha}}$, sin supuestos sobre F salvo continuidad.

La función de distribución empírica: banda uniforme



La función de distribución empírica: banda uniforme



El ancho de la banda decrece como $n^{-1/2}$ y no requiere elegir ningún parámetro de suavizado. Es la razón por la que el gráfico de F_n resulta preferible al histograma cuando el objetivo es comparar distribuciones.

Cuantiles

El cuantil de orden p se define por la inversa generalizada

$$Q(p) = F^{-1}(p) = \inf\{x : F(x) \geq p\}, \quad p \in (0, 1),$$

y su versión muestral reemplaza F por F_n , interpolando entre **estadísticos de orden** consecutivos, es decir, los datos ordenados $X_{(1)} \leq \dots \leq X_{(n)}$.

Cuantiles

El cuantil de orden p se define por la inversa generalizada

$$Q(p) = F^{-1}(p) = \inf\{x : F(x) \geq p\}, \quad p \in (0, 1),$$

y su versión muestral reemplaza F por F_n , interpolando entre **estadísticos de orden** consecutivos, es decir, los datos ordenados $X_{(1)} \leq \dots \leq X_{(n)}$.

Los **resúmenes de cinco números** $(X_{(1)}, \hat{Q}(0,25), \hat{Q}(0,5), \hat{Q}(0,75), X_{(n)})$ son la base del diagrama de caja.

Cuantiles

El cuantil de orden p se define por la inversa generalizada

$$Q(p) = F^{-1}(p) = \inf\{x : F(x) \geq p\}, \quad p \in (0, 1),$$

y su versión muestral reemplaza F por F_n , interpolando entre **estadísticos de orden** consecutivos, es decir, los datos ordenados $X_{(1)} \leq \dots \leq X_{(n)}$.

Los **resúmenes de cinco números** $(X_{(1)}, \hat{Q}(0,25), \hat{Q}(0,5), \hat{Q}(0,75), X_{(n)})$ son la base del diagrama de caja.

La inversa generalizada es necesaria porque F puede tener saltos y tramos planos, casos en que la inversa ordinaria no existe.

Localización, dispersión y robustez

El **punto de ruptura** es la fracción mínima de observaciones que, modificadas arbitrariamente, llevan al estimador a un valor arbitrario. La **eficiencia** compara su varianza con la del mejor estimador posible bajo normalidad.

Estimador	Definición	Punto de ruptura	Eficiencia normal
Media	$\frac{1}{n} \sum x_i$	0	100 %
Mediana	$\hat{Q}(0,5)$	50 %	64 %
Media recortada α	Promedio central	α	$\approx 99 \%$ si $\alpha = 0,05$
Desv. estándar	$\sqrt{\frac{1}{n-1} \sum (x_i - \bar{x})^2}$	0	100 %
IQR	$\hat{Q}(0,75) - \hat{Q}(0,25)$	25 %	37 %
MAD	$1,4826 \cdot \text{med} x_i - \text{med}(x) $	50 %	37 %


Localización, dispersión y robustez

El **punto de ruptura** es la fracción mínima de observaciones que, modificadas arbitrariamente, llevan al estimador a un valor arbitrario. La **eficiencia** compara su varianza con la del mejor estimador posible bajo normalidad.

Estimador	Definición	Punto de ruptura	Eficiencia normal
Media	$\frac{1}{n} \sum x_i$	0	100 %
Mediana	$\hat{Q}(0,5)$	50 %	64 %
Media recortada α	Promedio central	α	$\approx 99 \%$ si $\alpha = 0,05$
Desv. estándar	$\sqrt{\frac{1}{n-1} \sum (x_i - \bar{x})^2}$	0	100 %
IQR	$\hat{Q}(0,75) - \hat{Q}(0,25)$	25 %	37 %
MAD	$1,4826 \cdot \text{med} x_i - \text{med}(x) $	50 %	37 %

El factor $1,4826 = 1/\Phi^{-1}(0,75)$ hace que el MAD estime σ de manera consistente bajo normalidad. Sin ese factor el MAD subestima la desviación estándar en un 33 %.

Robustez: comportamiento bajo contaminación



Curva de sensibilidad, versión empírica de la función de influencia

Cada punto corresponde a una muestra distinta, formada por los mismos 200 datos limpios más una única observación de valor v , en el eje horizontal. Esa sola observación sobre $n = 201$ desplaza la media y la desviación estándar sin cota. La mediana, el IQR y el MAD permanecen constantes, porque el valor contaminado ya está fuera del rango central y su magnitud no interviene.

Forma: asimetría y curtosis

$$\hat{\gamma}_1 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^3}{\hat{\sigma}^3}, \quad \hat{\gamma}_2 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^4}{\hat{\sigma}^4} - 3$$

Ambos son adimensionales e invariantes bajo transformaciones afines, por lo tanto admisibles en escala de intervalo.

Forma: asimetría y curtosis

$$\hat{\gamma}_1 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^3}{\hat{\sigma}^3}, \quad \hat{\gamma}_2 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^4}{\hat{\sigma}^4} - 3$$

Ambos son adimensionales e invariantes bajo transformaciones afines, por lo tanto admisibles en escala de intervalo.

Valor	Interpretación	Consecuencia práctica
$\hat{\gamma}_1 > 0$	Cola derecha larga	La media supera a la mediana
$\hat{\gamma}_2 > 0$	Colas pesadas y pico agudo	Atípicos frecuentes, media ineficiente
$\hat{\gamma}_2 < 0$	Colas ligeras	Posible distribución acotada o bimodal

Forma: asimetría y curtosis

$$\hat{\gamma}_1 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^3}{\hat{\sigma}^3}, \quad \hat{\gamma}_2 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^4}{\hat{\sigma}^4} - 3$$


Ambos son adimensionales e invariantes bajo transformaciones afines, por lo tanto admisibles en escala de intervalo.

Valor	Interpretación	Consecuencia práctica
$\hat{\gamma}_1 > 0$	Cola derecha larga	La media supera a la mediana
$\hat{\gamma}_2 > 0$	Colas pesadas y pico agudo	Atípicos frecuentes, media ineficiente
$\hat{\gamma}_2 < 0$	Colas ligeras	Posible distribución acotada o bimodal

La curtosis muestral está acotada por $\hat{\gamma}_2 \leq n - 3 + 6/(n - 1)$, luego con n pequeño no detecta colas pesadas. Su varianza asintótica bajo normalidad es $24/n$.


Efecto del número de intervalos

El mismo conjunto de datos, cuatro histogramas. La conclusión cambia en cada uno.



Efecto del número de intervalos


El mismo conjunto de datos, cuatro histogramas. La conclusión cambia en cada uno.



Con $m = 4$ parece unimodal y asimétrica; con $m = 12$ y $m = 45$ aparecen dos modos; con $m = 400$ el gráfico es casi la lista de las observaciones.

Efecto del número de intervalos

El mismo conjunto de datos, cuatro histogramas. La conclusión cambia en cada uno.



Con $m = 4$ parece unimodal y asimétrica; con $m = 12$ y $m = 45$ aparecen dos modos; con $m = 400$ el gráfico es casi la lista de las observaciones.

Las cuatro provienen del mismo conjunto de datos. Las diapositivas siguientes derivan el criterio que fija m .

El histograma como estimador de densidad

Sobre una partición en intervalos $B_1, \dots, B_m$ de ancho h , con $\nu_j = \#\{i : x_i \in B_j\}$,

$$\hat{f}_h(x) = \frac{\nu_j}{nh} = \frac{\hat{p}_j}{h}, \quad x \in B_j, \quad \hat{p}_j = \nu_j/n.$$

El histograma como estimador de densidad

Sobre una partición en intervalos $B_1, \dots, B_m$ de ancho h , con $\nu_j = \#\{i : x_i \in B_j\}$,

$$\hat{f}_h(x) = \frac{\nu_j}{nh} = \frac{\hat{p}_j}{h}, \quad x \in B_j, \quad \hat{p}_j = \nu_j/n.$$

Es una densidad válida, dado que $\hat{f}_h \geq 0$ y $\int \hat{f}_h = \sum_j \hat{p}_j = 1$.

El histograma como estimador de densidad

Sobre una partición en intervalos $B_1, \dots, B_m$ de ancho h , con $\nu_j = \#\{i : x_i \in B_j\}$,

$$\hat{f}_h(x) = \frac{\nu_j}{nh} = \frac{\hat{p}_j}{h}, \quad x \in B_j, \quad \hat{p}_j = \nu_j/n.$$

Es una densidad válida, dado que $\hat{f}_h \geq 0$ y $\int \hat{f}_h = \sum_j \hat{p}_j = 1$.

El criterio de calidad es el $\text{MISE}(h)$ ya definido, aplicado a $\hat{f}_h$.

El histograma como estimador de densidad

Sobre una partición en intervalos $B_1, \dots, B_m$ de ancho h , con $\nu_j = \#\{i : x_i \in B_j\}$,

$$\hat{f}_h(x) = \frac{\nu_j}{nh} = \frac{\hat{p}_j}{h}, \quad x \in B_j, \quad \hat{p}_j = \nu_j/n.$$

Es una densidad válida, dado que $\hat{f}_h \geq 0$ y $\int \hat{f}_h = \sum_j \hat{p}_j = 1$.

El criterio de calidad es el $\text{MISE}(h)$ ya definido, aplicado a $\hat{f}_h$.

El ancho h es el único parámetro libre y controla el sesgo y la varianza en direcciones opuestas. Elegirlo por inspección visual equivale a elegir el resultado.

Sesgo y varianza del histograma

Sea $x \in B_j$ con centro c_j y f continuamente diferenciable. A primer orden,

$$\text{sesgo}(x) \approx f'(c_j) (c_j - x), \quad \text{Var}(\hat{f}_h(x)) \approx \frac{f(x)}{nh}.$$

Sesgo y varianza del histograma

Sea $x \in B_j$ con centro c_j y f continuamente diferenciable. A primer orden,

$$\text{sesgo}(x) \approx f'(c_j) (c_j - x), \quad \text{Var}(\hat{f}_h(x)) \approx \frac{f(x)}{nh}.$$

El sesgo es $O(h)$ y la varianza es $O(1/nh)$, de modo que ambos se controlan en direcciones opuestas. Integrando sobre cada intervalo y sumando, con $R(f') = \int f'(x)^2 dx$,

$$\text{AMISE}(h) = \frac{h^2}{12} R(f') + \frac{1}{nh}.$$

Ancho óptimo y tasa de convergencia

Derivando $AMISE(h) = \frac{h^2}{12}R(f') + \frac{1}{nh}$ respecto de h e igualando a cero,

$$\frac{h}{6}R(f') - \frac{1}{nh^2} = 0 \quad \Rightarrow$$

$$h^* = \left(\frac{6}{n R(f')} \right)^{1/3} \propto n^{-1/3}.$$

Ancho óptimo y tasa de convergencia

Derivando $AMISE(h) = \frac{h^2}{12}R(f') + \frac{1}{nh}$ respecto de h e igualando a cero,

$$\frac{h}{6}R(f') - \frac{1}{nh^2} = 0 \quad \Rightarrow \quad h^* = \left(\frac{6}{n R(f')} \right)^{1/3} \propto n^{-1/3}.$$

Sustituyendo,

$$AMISE(h^*) = \left(\frac{3}{4}\right)^{2/3} R(f')^{1/3} n^{-2/3} = O(n^{-2/3}).$$

Ancho óptimo y tasa de convergencia

Derivando $AMISE(h) = \frac{h^2}{12}R(f') + \frac{1}{nh}$ respecto de h e igualando a cero,

$$\frac{h}{6}R(f') - \frac{1}{nh^2} = 0 \quad \Rightarrow \quad h^* = \left(\frac{6}{n R(f')} \right)^{1/3} \propto n^{-1/3}.$$

Sustituyendo,

$$AMISE(h^*) = \left(\frac{3}{4}\right)^{2/3} R(f')^{1/3} n^{-2/3} = O(n^{-2/3}).$$

La tasa $n^{-2/3}$ es inferior a la de un estimador de kernel de segundo orden, que alcanza $n^{-4/5}$.

El precio lo paga la discontinuidad de la función escalonada.

Reglas para el ancho de intervalo

Todas se obtienen sustituyendo $R(f')$ por una estimación, o bien de argumentos ajenos al MISE.

Regla	Fórmula	Supuesto	Comportamiento
Sturges (1926)	$m = \lceil \log_2 n \rceil + 1$	Normal, n pequeño	$m = O(\log n)$, sobresuaviza
Rice	$m = \lceil 2n^{1/3} \rceil$	Ninguno	Tasa correcta, escala arbitraria
Scott (1979)	$h = 3,49 \hat{\sigma} n^{-1/3}$	f normal	Óptima si f es normal
Freedman–Diaconis (1981)	$h = 2 \widehat{\text{IQR}} n^{-1/3}$	Ninguno	Robusta a colas y atípicos
Doane (1976)	Sturges + $\log_2(1 + \hat{\gamma}_1 /\sigma_{\gamma_1})$	Corrige asimetría	Mejora a Sturges
Validación cruzada	$\arg \min_h \hat{J}(h)$	Ninguno	Estima el riesgo directamente

Reglas para el ancho de intervalo

Todas se obtienen sustituyendo $R(f')$ por una estimación, o bien de argumentos ajenos al MISE.


Regla	Fórmula	Supuesto	Comportamiento
Sturges (1926)	$m = \lceil \log_2 n \rceil + 1$	Normal, n pequeño	$m = O(\log n)$, sobresuaviza
Rice	$m = \lceil 2n^{1/3} \rceil$	Ninguno	Tasa correcta, escala arbitraria
Scott (1979)	$h = 3,49 \hat{\sigma} n^{-1/3}$	f normal	Óptima si f es normal
Freedman–Diaconis (1981)	$h = 2 \widehat{\text{IQR}} n^{-1/3}$	Ninguno	Robusta a colas y atípicos
Doane (1976)	Sturges + $\log_2(1 + \hat{\gamma}_1 /\sigma_{\gamma_1})$	Corrige asimetría	Mejora a Sturges
Validación cruzada	$\arg \min_h \hat{J}(h)$	Ninguno	Estima el riesgo directamente

Scott sustituye $R(f') = 1/(4\sqrt{\pi}\sigma^3)$, válido para la normal, en h^* , y obtiene $h^* = (24\sqrt{\pi})^{1/3} \sigma n^{-1/3} \approx 3,49 \sigma n^{-1/3}$.

Freedman–Diaconis reemplaza $\hat{\sigma}$ por $\widehat{\text{IQR}}/1,349$ y estrecha el intervalo, con lo que tolera colas pesadas.


Por qué la regla de Sturges es inadecuada

La regla fija $m = \lceil \log_2 n \rceil + 1$, luego $h \asymp \text{rango} / \log_2 n$. Como $h^* \propto n^{-1/3}$ y $1 / \log_2 n$ decrece mucho más lentamente, el ancho de Sturges es asintóticamente **demasiado grande** y el MISE no alcanza la tasa $n^{-2/3}$.




Por qué la regla de Sturges es inadecuada

La regla fija $m = \lceil \log_2 n \rceil + 1$, luego $h \asymp \text{rango} / \log_2 n$. Como $h^* \propto n^{-1/3}$ y $1 / \log_2 n$ decrece mucho más lentamente, el ancho de Sturges es asintóticamente **demasiado grande** y el MISE no alcanza la tasa $n^{-2/3}$.




Con $n = 10^6$, Sturges propone 21 intervalos y la tasa correcta exige del orden de 200. La regla sigue siendo el valor por omisión en varias herramientas.

Comparación de reglas sobre datos reales



Comparación de reglas sobre datos reales



Mezcla de dos normales con $n = 2000$. La curva continua es la densidad verdadera. Sturges oculta la bimodalidad; Freedman-Diaconis y Scott la hacen visible.

Elección del ancho por validación cruzada

Ninguna regla anterior mira la forma de f . El criterio que sí lo hace estima directamente el riesgo integrado:

$$\int (\hat{f}_h(x) - f(x))^2 dx = \int \hat{f}_h(x)^2 dx - 2 \int \hat{f}_h(x) f(x) dx + \int f(x)^2 dx,$$

y el tercero no depende de h , así que basta con los dos primeros.

Elección del ancho por validación cruzada

Ninguna regla anterior mira la forma de f . El criterio que sí lo hace estima directamente el riesgo integrado:

$$\int (\hat{f}_h(x) - f(x))^2 dx = \int \hat{f}_h(x)^2 dx - 2 \int \hat{f}_h(x) f(x) dx + \int f(x)^2 dx,$$

y el tercero no depende de h , así que basta con los dos primeros.

El estimador insesgado de dejar uno fuera (Rudemo 1982; Bowman 1984) es:

$$\hat{J}(h) = \frac{2}{(n-1)h} - \frac{n+1}{(n-1)h} \sum_{j=1}^m \hat{p}_j^2$$

y el ancho elegido es $\hat{h} = \arg \min_h \hat{J}(h)$.

Elección del ancho por validación cruzada

Ninguna regla anterior mira la forma de f . El criterio que sí lo hace estima directamente el riesgo integrado:

$$\int (\hat{f}_h(x) - f(x))^2 dx = \int \hat{f}_h(x)^2 dx - 2 \int \hat{f}_h(x) f(x) dx + \int f(x)^2 dx,$$

y el tercero no depende de h , así que basta con los dos primeros.



El estimador insesgado de dejar uno fuera (Rudemo 1982; Bowman 1984) es:

$$\hat{J}(h) = \frac{2}{(n-1)h} - \frac{n+1}{(n-1)h} \sum_{j=1}^m \hat{p}_j^2$$


y el ancho elegido es $\hat{h} = \arg \min_h \hat{J}(h)$.

El procedimiento no supone forma de f , sólo requiere que $\int f^2 dx$ sea finita. Es el criterio correcto cuando f es asimétrica o multimodal, situaciones en que las reglas basadas en $\hat{\sigma}$ fallan.

Validación cruzada: ejemplo



Validación cruzada: ejemplo



La curva de riesgo es plana cerca del mínimo, lo que indica que la elección exacta no es crítica dentro de un rango amplio. Lo que sí resulta crítico es no situarse en la zona de sobresuavizado, donde el sesgo domina.

Estimación de densidad por kernel

El estimador centra en cada observación una función de pesos suave K , el kernel, y con ello elimina la discontinuidad y la dependencia del origen:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right), \quad \int K = 1, \quad \int u K(u) du = 0.$$

Estimación de densidad por kernel

El estimador centra en cada observación una función de pesos suave K , el kernel, y con ello elimina la discontinuidad y la dependencia del origen:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right), \quad \int K = 1, \quad \int u K(u) du = 0.$$

Con un kernel de segundo orden,

$$\text{AMISE}(h) = \frac{h^4}{4} \mu_2(K)^2 R(f'') + \frac{R(K)}{nh},$$
$$h^* \propto n^{-1/5}, \quad \text{AMISE}(h^*) = O(n^{-4/5}).$$

Estimación de densidad por kernel

El estimador centra en cada observación una función de pesos suave K , el kernel, y con ello elimina la discontinuidad y la dependencia del origen:


$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right), \quad \int K = 1, \quad \int u K(u) du = 0.$$

Con un kernel de segundo orden,


$$\text{AMISE}(h) = \frac{h^4}{4} \mu_2(K)^2 R(f'') + \frac{R(K)}{nh},$$
$$h^* \propto n^{-1/5}, \quad \text{AMISE}(h^*) = O(n^{-4/5}).$$

La eficiencia relativa entre kernels admisibles es inferior al 7 %, mientras que duplicar el ancho modifica la estimación de manera sustantiva.

Kernel: efecto del ancho



Kernel: efecto del ancho



La misma muestra de $n = 400$ con tres anchos. La línea discontinua es la densidad verdadera. Un ancho pequeño produce modos espurios; uno grande fusiona los modos reales.

Diagrama de caja

La construcción de Tukey usa la caja $[\hat{Q}_1, \hat{Q}_3]$, la mediana, y dos segmentos que se extienden **hasta la observación más extrema** dentro de los límites internos:

$$[\hat{Q}_1 - 1,5 \widehat{IQR}, \hat{Q}_3 + 1,5 \widehat{IQR}].$$

Diagrama de caja

La construcción de Tukey usa la caja $[\hat{Q}_1, \hat{Q}_3]$, la mediana, y dos segmentos que se extienden **hasta la observación más extrema** dentro de los límites internos:

$$[\hat{Q}_1 - 1,5 \widehat{IQR}, \hat{Q}_3 + 1,5 \widehat{IQR}].$$

Bajo normalidad, $\hat{Q}_{1,3} = \mp 0,6745\sigma$ e $\widehat{IQR} = 1,349\sigma$, luego esos límites quedan en $\pm 2,698\sigma$ y la proporción esperada de puntos marcados es:

$$2 \Phi(-2,698) = 0,0070.$$

Diagrama de caja

La construcción de Tukey usa la caja $[\hat{Q}_1, \hat{Q}_3]$, la mediana, y dos segmentos que se extienden **hasta la observación más extrema** dentro de los límites internos:




$$[\hat{Q}_1 - 1,5 \widehat{IQR}, \hat{Q}_3 + 1,5 \widehat{IQR}].$$

Bajo normalidad, $\hat{Q}_{1,3} = \mp 0,6745\sigma$ e $\widehat{IQR} = 1,349\sigma$, luego esos límites quedan en $\pm 2,698\sigma$ y la proporción esperada de puntos marcados es:


$$2 \Phi(-2,698) = 0,0070.$$

Con $n = 1000$ observaciones normales se esperan siete puntos marcados. Marcado no significa erróneo. El factor 1,5 es una convención calibrada sobre la normal, no un criterio de detección de errores.

Los límites del diagrama de caja



Los límites del diagrama de caja



Los cuatro grupos tienen mediana y cuartiles casi idénticos y el diagrama de caja no los distingue. El diagrama de caja resume cinco números, y cinco números no identifican una distribución.

Diagrama cuantil–cuantil

El gráfico cuantil–cuantil, conocido en la literatura como **Q–Q plot**, enfrenta los cuantiles muestrales con los cuantiles teóricos,

$$\left(\Phi^{-1} \left(\frac{i - 0,5}{n} \right), X_{(i)} \right), \quad i = 1, \dots, n.$$

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, los puntos se alinean sobre la recta de pendiente σ e intercepto μ .





Diagrama cuantil–cuantil

El gráfico cuantil–cuantil, conocido en la literatura como **Q–Q plot**, enfrenta los cuantiles muestrales con los cuantiles teóricos,


$$\left(\Phi^{-1} \left(\frac{i - 0,5}{n} \right), X_{(i)} \right), \quad i = 1, \dots, n.$$

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, los puntos se alinean sobre la recta de pendiente σ e intercepto μ .




Curvatura convexa indica asimetría a la derecha; forma de S indica colas pesadas en ambos extremos; escalones indican multimodalidad o discretización.

Análisis bivariado: sobreploteo



Análisis bivariado: sobreploteo




Con n grande el diagrama de dispersión satura y deja de codificar densidad.

El hexbin y la densidad bidimensional son histogramas en dos dimensiones, de modo que la elección del número de celdas hereda toda la discusión anterior sobre sesgo y varianza.


Medidas de asociación

Medida	Qué es	Detecta	Nulo implica indep.
Pearson r	Covarianza estandarizada	Asociación lineal	Sólo si (X, Y) es normal
Spearman ρ	Pearson sobre los rangos	Asociación monótona	No
Kendall τ	Proporción de pares concordantes	Concordancia	No
Información mutua	$\iint p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$	Dependencia general	Sí
Corr. de distancias	Correlación entre matrices de distancias	Dependencia general	Sí


lineal
 $r = 0.89$, $\rho = 0.90$
 $dCor = 0.88$




cuadrática
 $r = -0.07$, $\rho = -0.07$
 $dCor = 0.50$



monótona no lineal
 $r = 0.80$, $\rho = 0.89$
 $dCor = 0.84$




circular
 $r = 0.00$, $\rho = -0.00$
 $dCor = 0.19$




Medidas de asociación

Medida	Qué es	Detecta	Nulo implica indep.
Pearson r	Covarianza estandarizada	Asociación lineal	Sólo si (X, Y) es normal
Spearman ρ	Pearson sobre los rangos	Asociación monótona	No
Kendall τ	Proporción de pares concordantes	Concordancia	No
Información mutua	$\iint p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$	Dependencia general	Sí
Corr. de distancias	Correlación entre matrices de distancias	Dependencia general	Sí


lineal
 $r = 0.89$, $\rho = 0.90$
 $dCor = 0.88$




cuadrática
 $r = -0.07$, $\rho = -0.07$
 $dCor = 0.50$



monótona no lineal
 $r = 0.80$, $\rho = 0.89$
 $dCor = 0.84$



circular
 $r = 0.00$, $\rho = -0.00$
 $dCor = 0.19$



En los casos segundo y cuarto la dependencia es determinista y $r \approx 0$. La correlación de distancias se anula si y sólo si las variables son independientes.

Asociación entre variables categóricas

Con conteos n_{ij} y esperados bajo independencia $e_{ij} = n_{i.}n_{.j}/n$:



$$\chi^2 = \sum_{i,j} (n_{ij} - e_{ij})^2 / e_{ij}, \quad V = \sqrt{\chi^2 / (n \min(r - 1, c - 1))}.$$

Asociación entre variables categóricas




Con conteos n_{ij} y esperados bajo independencia $e_{ij} = n_{i.}n_{.j}/n$:

$$\chi^2 = \sum_{i,j} (n_{ij} - e_{ij})^2 / e_{ij}, \quad V = \sqrt{\chi^2 / (n \min(r - 1, c - 1))}.$$


El χ^2 crece con n ; la V de Cramér lo normaliza a $[0, 1]$. Los **residuos de Pearson** $(n_{ij} - e_{ij}) / \sqrt{e_{ij}}$ del panel derecho localizan la asociación y su signo.



Comparación de distribuciones entre grupos




Comparación de distribuciones entre grupos




Los tres grupos tienen media y mediana cero. Difieren en dispersión y en número de modos, información que el diagrama de caja no transmite.

Con n moderado el gráfico de los puntos es preferible a los resúmenes numéricos.


La paradoja de Simpson en el EDA



por estrato: pendiente $\approx +0,55$ en los cuatro



La paradoja de Simpson en el EDA






La asociación agregada y la asociación dentro de cada estrato tienen signos opuestos. Ningún criterio interno a los datos decide cuál corresponde usar. **La decisión requiere conocimiento del mecanismo que generó los estratos.**

Valores atípicos en varias dimensiones

Una observación puede ser ordinaria en cada coordenada y atípica en el conjunto. Bajo $X \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$:

$$d^2(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \sim \chi_p^2,$$

lo que entrega el umbral $d^2 > \chi_{p, 1-\alpha}^2$.






Valores atípicos en varias dimensiones

Una observación puede ser ordinaria en cada coordenada y atípica en el conjunto. Bajo $X \sim \mathcal{N}_p(\mu, \Sigma)$:

$$d^2(\mathbf{x}) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \sim \chi_p^2,$$

lo que entrega el umbral $d^2 > \chi_{p, 1-\alpha}^2$.



La clásica usa todos los puntos y su elipse se ensancha hasta cubrirlos, el **enmascaramiento**; el MCD estima Σ sólo con la mitad más concentrada y los deja fuera.

Datos faltantes: patrón y mecanismo



Sea $R_{ij} = 1\{x_{ij} \text{ observado}\}$. Rubin (1976) clasifica el mecanismo por la dependencia de R respecto de los datos.

Mecanismo	Condición	Consecuencia
MCAR	$P(R \mid X_{\text{obs}}, X_{\text{fal}}) = P(R)$	El caso completo es insesgado
MAR	$P(R \mid X_{\text{obs}}, X_{\text{fal}}) = P(R \mid X_{\text{obs}})$	Imputación basada en lo observado es válida
MNAR	Depende de X_{fal}	Se requiere modelar el mecanismo

Datos faltantes: patrón y mecanismo

Sea $R_{ij} = 1\{x_{ij} \text{ observado}\}$. Rubin (1976) clasifica el mecanismo por la dependencia de R respecto de los datos.

Mecanismo	Condición	Consecuencia
MCAR	$P(R \mid X_{\text{obs}}, X_{\text{fal}}) = P(R)$	El caso completo es insesgado
MAR	$P(R \mid X_{\text{obs}}, X_{\text{fal}}) = P(R \mid X_{\text{obs}})$	Imputación basada en lo observado es válida
MNAR	Depende de X_{fal}	Se requiere modelar el mecanismo



Protocolo de análisis exploratorio

1. **Estructura.** Dimensiones, esquema declarado, unidad de análisis, claves duplicadas.
2. **Validez.** Rangos admisibles, unidades, fechas imposibles, códigos centinela.
3. **Faltantes.** Proporción por columna, patrón conjunto, hipótesis sobre el mecanismo.
4. **Univariado.** Distribución empírica, cuantiles, forma, valores extremos.
5. **Bivariado.** Asociación con la respuesta y entre predictores, con la medida que corresponda a la escala.
6. **Estratos.** Repetir los pasos 4 y 5 dentro de los grupos relevantes.
7. **Registro.** Documentar cada decisión tomada y su justificación.

Protocolo de análisis exploratorio

1. **Estructura.** Dimensiones, esquema declarado, unidad de análisis, claves duplicadas.
2. **Validez.** Rangos admisibles, unidades, fechas imposibles, códigos centinela.
3. **Faltantes.** Proporción por columna, patrón conjunto, hipótesis sobre el mecanismo.
4. **Univariado.** Distribución empírica, cuantiles, forma, valores extremos.
5. **Bivariado.** Asociación con la respuesta y entre predictores, con la medida que corresponda a la escala.
6. **Estratos.** Repetir los pasos 4 y 5 dentro de los grupos relevantes.
7. **Registro.** Documentar cada decisión tomada y su justificación.

El paso 7 condiciona a los demás. Sin el registro de las decisiones tomadas durante la exploración, la validez del análisis confirmatorio posterior no puede evaluarse.

El caso inicial, con los criterios de la clase

El biomarcador presentado al comienzo admite ahora un diagnóstico completo.

1. El valor p correspondía a una variable fijada de antemano, mientras que la variable fue seleccionada entre cien a partir de los datos. La inferencia nominal no es aplicable.
2. El procedimiento válido consiste en declarar la hipótesis con anterioridad, o bien reservar una muestra confirmatoria que no se examina durante la exploración.

El caso inicial, con los criterios de la clase

El biomarcador presentado al comienzo admite ahora un diagnóstico completo.

1. El valor p correspondía a una variable fijada de antemano, mientras que la variable fue seleccionada entre cien a partir de los datos. La inferencia nominal no es aplicable.
2. El procedimiento válido consiste en declarar la hipótesis con anterioridad, o bien reservar una muestra confirmatoria que no se examina durante la exploración.

La exploración es necesaria y cada decisión tomada a partir de los datos reduce la validez de la inferencia posterior sobre esos mismos datos. El registro de decisiones, paso 7 del protocolo, es lo que permite evaluar esa reducción.

Referencias

- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- Anscombe, F. J. (1973). Graphs in statistical analysis. *The American Statistician*, 27(1), 17–21.
- Massart, P. (1990). The tight constant in the Dvoretzky–Kiefer–Wolfowitz inequality. *Annals of Probability*, 18(3), 1269–1283.
- Scott, D. W. (1979). On optimal and data-based histograms. *Biometrika*, 66(3), 605–610.
- Freedman, D., Diaconis, P. (1981). On the histogram as a density estimator: L_2 theory. *Z. Wahrscheinlichkeitstheorie*, 57, 453–476.
- Rudemo, M. (1982). Empirical choice of histograms and kernel density estimators. *Scandinavian Journal of Statistics*, 9(2), 65–78.
- Wasserman, L. (2006). *All of Nonparametric Statistics*, cap. 6. Springer.
- Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581–592.
- Rousseeuw, P. J., Van Driessen, K. (1999). A fast algorithm for the minimum covariance determinant estimator. *Technometrics*, 41(3), 212–223.
- Székely, G., Rizzo, M., Bakirov, N. (2007). Measuring and testing dependence by correlation of distances. *Annals of Statistics*, 35(6), 2769–2794.
- Hofmann, H., Wickham, H., Kafadar, K. (2017). Letter-value plots. *Journal of Computational and Graphical Statistics*, 26(3), 469–477.