

Visualización de datos y preprocesamiento

Datos multivariados, datos dependientes y
construcción de características

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos




Objetivos

- Formular la visualización como una asignación de variables a canales perceptuales, ordenados por su precisión.
- Seleccionar métodos gráficos para datos multivariados y con dependencia temporal, espacial o jerárquica.
- Aplicar la regla de estimación en entrenamiento a todo paso que estime parámetros.
- Depurar, integrar e imputar de modo que el resultado sea función determinista de los datos crudos.
- Estimar una regresión lineal por mínimos cuadrados y justificar la penalización con la descomposición del error.
- Derivar el análisis de componentes principales desde sus tres formulaciones equivalentes.
- Construir la representación de UMAP y delimitar qué se lee en un mapa de vecindad.
- Distinguir la linealidad en los parámetros de la linealidad en las variables.


Un caso: Los sellos del transbordador Challenger

El análisis previo al lanzamiento del 28 de enero de 1986 evaluó si la temperatura comprometía los sellos de los cohetes aceleradores. La evidencia considerada fueron los vuelos que habían presentado incidentes en los sellos.




Un caso: Los sellos del transbordador Challenger

El análisis previo al lanzamiento del 28 de enero de 1986 evaluó si la temperatura comprometía los sellos de los cohetes aceleradores. La evidencia considerada fueron los vuelos que habían presentado incidentes en los sellos.




Sobre estos datos no se aprecia relación entre la temperatura de lanzamiento y el número de sellos dañados.

Los veintitrés vuelos



Los veintitrés vuelos



Los dieciséis vuelos sin incidentes ocurrieron todos con temperaturas altas, y son los que establecen el contraste. Al excluirllos, la asociación deja de ser visible. La curva gris es una regresión logística ajustada a los veintitrés vuelos.

El lanzamiento se realizó a $-0,6^{\circ}\text{C}$, valor situado fuera del rango de toda la experiencia previa, cuyo mínimo fue $11,7^{\circ}\text{C}$.

Visualización de datos

Gramática de gráficos

Un gráfico queda especificado por una composición de capas independientes.

Capa	Contenido	Decisión
Datos	Tabla ordenada	Unidad de análisis
Estética	x , y , color, tamaño, forma, transparencia	Qué variable a qué canal
Geometría	Punto, línea, barra, área, contorno	Qué marca representa una fila
Escala	Lineal, logarítmica, discreta, temporal	Cómo se mapea el rango
Coordenada	Cartesiana, polar, geográfica	Sistema de referencia
Faceta	Partición en paneles	Qué se compara en paralelo

Gramática de gráficos

Un gráfico queda especificado por una composición de capas independientes.

Capa	Contenido	Decisión
Datos	Tabla ordenada	Unidad de análisis
Estética	x , y , color, tamaño, forma, transparencia	Qué variable a qué canal
Geometría	Punto, línea, barra, área, contorno	Qué marca representa una fila
Escala	Lineal, logarítmica, discreta, temporal	Cómo se mapea el rango
Coordenada	Cartesiana, polar, geográfica	Sistema de referencia
Faceta	Partición en paneles	Qué se compara en paralelo

La **estética** es una función $a_k : \mathcal{X}_j \rightarrow \mathcal{C}_k$ que asigna la variable j al canal k , y debe preservar la estructura de la escala de medida.

Gramática de gráficos

Un gráfico queda especificado por una composición de capas independientes.

Capa	Contenido	Decisión
Datos	Tabla ordenada	Unidad de análisis
Estética	x , y , color, tamaño, forma, transparencia	Qué variable a qué canal
Geometría	Punto, línea, barra, área, contorno	Qué marca representa una fila
Escala	Lineal, logarítmica, discreta, temporal	Cómo se mapea el rango
Coordenada	Cartesiana, polar, geográfica	Sistema de referencia
Faceta	Partición en paneles	Qué se compara en paralelo


La **estética** es una función $a_k : \mathcal{X}_j \rightarrow \mathcal{C}_k$ que asigna la variable j al canal k , y debe preservar la estructura de la escala de medida.

Una variable nominal asignada a un canal ordenado, como la posición o la intensidad, induce un orden que los datos no contienen.

Una variable continua asignada a un canal nominal, como la forma, descarta la información métrica.


Jerarquía de precisión perceptual

Cleveland y McGill (1984) midieron el error relativo con que un observador estima magnitudes según el canal empleado.



Jerarquía de precisión perceptual



Cleveland y McGill (1984) midieron el error relativo con que un observador estima magnitudes según el canal empleado.



La variable que porta la conclusión principal debe asignarse al canal de posición común. El uso de área para codificar magnitud introduce además el error de que el lector juzga radios y no áreas.




La jerarquía en un ejemplo

Las mismas cinco magnitudes, que suman cien, codificadas en tres canales distintos.



La jerarquía en un ejemplo




Las mismas cinco magnitudes, que suman cien, codificadas en tres canales distintos.



Ordenar las cinco cantidades resulta inmediato sólo en el tercer panel. La diferencia entre A y C, de 2,5 puntos, se lee directamente sobre el eje común y es casi invisible en los otros dos. En el panel del área la superficie sí es proporcional al valor, pero el lector juzga el radio, que crece como la raíz, y por eso percibe diferencias menores que las reales.




Escalas lineal y logarítmica

La escala logarítmica corresponde a $x \mapsto \log x$ y convierte razones en diferencias. Es la escala correcta cuando el mecanismo es multiplicativo o cuando el rango abarca varios órdenes de magnitud.




Escalas lineal y logarítmica

La escala logarítmica corresponde a $x \mapsto \log x$ y convierte razones en diferencias. Es la escala correcta cuando el mecanismo es multiplicativo o cuando el rango abarca varios órdenes de magnitud.




En escala logarítmica la pendiente es la tasa de crecimiento relativo y las distancias verticales iguales representan razones iguales. El eje debe rotularse con los valores originales, no con sus logaritmos.

Color




Color



Escala del dato	Paleta	Criterio
Continua sin cero de referencia	Secuencial	Luminancia monótona
Continua con cero significativo	Divergente	Simétrica respecto del punto neutro
Nominal	Cualitativa	Tonos distinguibles, sin orden de luminancia

Color




Escala del dato	Paleta	Criterio
Continua sin cero de referencia	Secuencial	Luminancia monótona
Continua con cero significativo	Divergente	Simétrica respecto del punto neutro
Nominal	Cualitativa	Tonos distinguibles, sin orden de luminancia

La paleta jet no tiene luminancia monótona y produce bordes que el dato no contiene.

Cerca del 4 % de la población presenta alguna deficiencia en la percepción del rojo y el verde, de modo que una codificación que dependa de ese contraste resulta inaccesible para parte de la audiencia.


El color en un mapa estadístico

Un contraste del modelo lineal general produce un estadístico t con signo, donde el cero separa la activación de la desactivación. El dato tiene punto neutro, de modo que la paleta debe ser divergente y con límites simétricos.



El color en un mapa estadístico

Un contraste del modelo lineal general produce un estadístico t con signo, donde el cero separa la activación de la desactivación. El dato tiene punto neutro, de modo que la paleta debe ser divergente y con límites simétricos.



La paleta jet añade anillos que el mapa no contiene, porque su luminancia no es monótona. La divergente sitúa el tono neutro en cero y los límites simétricos aseguran que un mismo tono represente la misma magnitud en ambos signos. El tercer panel expone el límite de la paleta divergente, ya que en luminancia los dos signos se confunden.

Datos multivariados: El problema

Con p variables y sólo dos canales espaciales, toda visualización de datos multivariados adopta una de cuatro estrategias.

Estrategia	Método	Costo
Mostrar todos los pares	Matriz de dispersión, mapa de calor	$O(p^2)$ paneles
Añadir canales no espaciales	Color, tamaño, forma, faceta	Satura pasadas 4 o 5 variables
Proyectar a dimensión baja	PCA, MDS, t -SNE, UMAP	Pérdida controlada o no controlada
Redefinir los ejes	Coordenadas paralelas, curvas de Andrews	Depende del orden de los ejes


Datos multivariados: El problema

Con p variables y sólo dos canales espaciales, toda visualización de datos multivariados adopta una de cuatro estrategias.


Estrategia	Método	Costo
Mostrar todos los pares	Matriz de dispersión, mapa de calor	$O(p^2)$ paneles
Añadir canales no espaciales	Color, tamaño, forma, faceta	Satura pasadas 4 o 5 variables
Proyectar a dimensión baja	PCA, MDS, t -SNE, UMAP	Pérdida controlada o no controlada
Redefinir los ejes	Coordenadas paralelas, curvas de Andrews	Depende del orden de los ejes

Ninguna estrategia domina a las otras. La matriz de dispersión conserva toda la información bivariada y ninguna estructura de orden superior. La proyección puede revelar estructura conjunta y no permite recuperar las variables originales.

Matriz de dispersión





Matriz de dispersión




La matriz muestra las $\binom{p}{2}$ proyecciones sobre pares de ejes originales. Con $p = 4$ son seis paneles; con $p = 30$ serían 435, de modo que el método no escala.

Coordenadas paralelas






Coordenadas paralelas




Las coordenadas paralelas muestran las p variables simultáneamente. Sólo son visibles las relaciones entre ejes **adyacentes**, de modo que el gráfico depende del orden elegido. Con p ejes existen $p!/2$ órdenes y ninguno muestra todos los pares.

Mapa de calor con reordenamiento

Orden arbitrario de las columnas Orden por agrupamiento jerárquico





Mapa de calor con reordenamiento




La matriz es la misma en ambos paneles. El reordenamiento por agrupamiento jerárquico revela la estructura de bloques, que en el orden original resulta invisible. El orden de filas y columnas es una decisión de visualización (no un dato).

Proyección lineal: Biplot de componentes principales



Proyección lineal: Biplot de componentes principales




En el biplot la flecha de la variable k tiene coordenadas $v_{kj} \sqrt{\lambda_j}$, que sobre datos estandarizados son la correlación entre esa variable y la componente j . El ángulo entre dos flechas aproxima la correlación entre las variables y su longitud, la varianza representada en el plano. La lectura es válida sólo si las dos primeras componentes explican una fracción alta de la varianza.

Proyecciones no lineales


PCA




MDS métrico




Isomap $k = 10$



t -SNE



Proyecciones no lineales



Datos generados sobre un *manifold* bidimensional enrollado en $\mathbb{R}^3$. El color codifica la posición a lo largo del *manifold*. Sólo Isomap y *t*-SNE recuperan el orden intrínseco; las proyecciones lineales superponen zonas distantes del *manifold*.

Lectura de una proyección no lineal




La disposición del plano ya no corresponde a ninguna combinación de las variables originales, de modo que no toda lectura del gráfico es legítima.

Lectura de una proyección no lineal


La disposición del plano ya no corresponde a ninguna combinación de las variables originales, de modo que no toda lectura del gráfico es legítima.

Admite lectura	No admite lectura
Qué puntos quedaron juntos, es decir, la vecindad de cada observación.	La distancia entre dos grupos alejados en el plano.
La existencia de grupos separados, si se confirma en el espacio original.	El tamaño y la densidad aparente de cada nube.
La continuidad de una trayectoria dentro de una nube.	El significado de los ejes horizontal y vertical.
	El número de grupos, que depende de los parámetros.

Datos dependientes: Series de tiempo




Datos dependientes: Series de tiempo




$\rho(h) = \gamma(h)/\gamma(0)$ mide la asociación entre y_t e y_{t+h} sin descontar los rezagos intermedios. La autocorrelación parcial descuenta esos rezagos y por eso identifica el orden de un proceso autorregresivo. La estacionalidad aparece como picos en múltiplos del período.

Descomposición y estacionalidad



Descomposición y estacionalidad



La descomposición STL estima tendencia y estacionalidad con regresión local iterada y admite estacionalidad variable en el tiempo. La versión robusta reduce la influencia de valores extremos sobre las dos componentes. El gráfico de subseries expone la forma estacional que el gráfico de la serie oculta.

Otras estructuras de dependencia

Estructura	Objeto de dependencia	Gráfico	Riesgo
Temporal	Autocovarianza $\gamma(h)$	Línea, ACF, subseries	Partición aleatoria inválida
Espacial	Semivariograma $\gamma(h)$	Coropleta, variograma	Unidad de área modificable
Jerárquica	Correlación intraclase ρ_I	Espagueti, caja por grupo	n efectivo menor que n
Longitudinal	Matriz por sujeto	Espagueti, perfiles medios	Confusión entre y dentro de sujeto
Reticular	Adyacencia A	Diagrama de nodos, matriz	Disposición arbitraria

Otras estructuras de dependencia

Estructura	Objeto de dependencia	Gráfico	Riesgo
Temporal	Autocovarianza $\gamma(h)$	Línea, ACF, subseries	Partición aleatoria inválida
Espacial	Semivariograma $\gamma(h)$	Coropleta, variograma	Unidad de área modificable
Jerárquica	Correlación intraclase ρ_I	Espaguete, caja por grupo	n efectivo menor que n
Longitudinal	Matriz por sujeto	Espaguete, perfiles medios	Confusión entre y dentro de sujeto
Reticular	Adyacencia A	Diagrama de nodos, matriz	Disposición arbitraria

La correlación intraclase ρ_I es la fracción de la varianza total que se explica por diferencias entre grupos, de modo que mide cuánto se parecen entre sí dos observaciones del mismo grupo. El tamaño muestral efectivo es $n_{\text{ef}} = n / (1 + (m - 1)\rho_I)$ con grupos de tamaño m . Con $m = 10$ y $\rho_I = 0,3$, mil observaciones equivalen a doscientas setenta independientes.

Preprocesamiento

El flujo de preprocesamiento

Todo paso que **estima un parámetro a partir de los datos** es parte del modelo.

Paso	Parámetro estimado	Debe ajustarse en
Estandarización	$\hat{\mu}, \hat{\sigma}$	Entrenamiento
Imputación por mediana	$\hat{Q}(0,5)$	Entrenamiento
Codificación por objetivo	$\hat{\theta}_k = \mathbb{E}[Y \mid c_k]$	Entrenamiento
Selección de variables	Subconjunto S	Entrenamiento
PCA	Base V_k	Entrenamiento
Discretización	Puntos de corte	Entrenamiento


El flujo de preprocesamiento

Todo paso que **estima un parámetro a partir de los datos** es parte del modelo.


Paso	Parámetro estimado	Debe ajustarse en
Estandarización	$\hat{\mu}, \hat{\sigma}$	Entrenamiento
Imputación por mediana	$\hat{Q}(0, 5)$	Entrenamiento
Codificación por objetivo	$\hat{\theta}_k = \mathbb{E}[Y \mid c_k]$	Entrenamiento
Selección de variables	Subconjunto S	Entrenamiento
PCA	Base V_k	Entrenamiento
Discretización	Puntos de corte	Entrenamiento

Si cualquiera de estos parámetros se estima con la muestra completa antes de particionar, la estimación del error de generalización queda sesgada hacia abajo. **El fenómeno se denomina fuga de información.**

Fuga de información: Magnitud del efecto



Fuga de información: Magnitud del efecto



Las etiquetas son independientes de las 3000 variables por construcción, de modo que la exactitud correcta es 0,5. Seleccionar las veinte variables más asociadas antes de particionar produce una estimación muy superior a la real.

Construcción del flujo

```
num = Pipeline([("imp", SimpleImputer(strategy="median", add_indicator=True)),
                ("esc", StandardScaler())])
cat = Pipeline([("imp", SimpleImputer(strategy="most_frequent")),
                ("cod", OneHotEncoder(handle_unknown="infrequent_if_exist",
                                      min_frequency=0.01))])

prep = ColumnTransformer([("num", num, cols_num), ("cat", cat, cols_cat)],
                        remainder="drop")
modelo = Pipeline([("prep", prep), ("clf", LogisticRegression(max_iter=2000))])
```

Construcción del flujo

```
num = Pipeline([("imp", SimpleImputer(strategy="median", add_indicator=True)),
                ("esc", StandardScaler())])
cat = Pipeline([("imp", SimpleImputer(strategy="most_frequent")),
                ("cod", OneHotEncoder(handle_unknown="infrequent_if_exist",
                                     min_frequency=0.01))])

prep = ColumnTransformer([("num", num, cols_num), ("cat", cat, cols_cat)],
                        remainder="drop")
modelo = Pipeline([("prep", prep), ("clf", LogisticRegression(max_iter=2000))])
```

Pipeline garantiza que fit se ejecuta sólo sobre el pliegue de entrenamiento y que transform se aplica al de validación con los parámetros ya estimados.

Depuración

Problema	Detección	Corrección
Duplicados exactos	Clave repetida	Eliminar, dejando registro del número
Duplicados aproximados	Similitud de cadenas, bloqueo	Resolución de entidades
Violación de dominio	Rango, catálogo, expresión regular	Marcar como faltante
Inconsistencia entre columnas	Regla lógica declarada	Marcar el registro completo
Unidad mezclada	Multimodalidad en la marginal	Convertir con factor conocido
Código centinela	Valor extremo repetido	Convertir a nulo
Fecha imposible	Orden temporal, calendario	Marcar o corregir con fuente
Codificación de texto	Caracteres no válidos	Normalizar a NFC

Depuración


Problema	Detección	Corrección
Duplicados exactos	Clave repetida	Eliminar, dejando registro del número
Duplicados aproximados	Similitud de cadenas, bloqueo	Resolución de entidades
Violación de dominio	Rango, catálogo, expresión regular	Marcar como faltante
Inconsistencia entre columnas	Regla lógica declarada	Marcar el registro completo
Unidad mezclada	Multimodalidad en la marginal	Convertir con factor conocido
Código centinela	Valor extremo repetido	Convertir a nulo
Fecha imposible	Orden temporal, calendario	Marcar o corregir con fuente
Codificación de texto	Caracteres no válidos	Normalizar a NFC

Toda corrección es una operación registrada sobre los datos originales, nunca una edición manual del archivo.

El conjunto depurado debe ser función determinista del conjunto crudo.


Depuración: Dos unidades o dos poblaciones

Dos columnas de peso, ambas bimodales. Una mezcla kilogramos con libras; la otra registra adultos y niños. El histograma no las distingue.



Depuración: Dos unidades o dos poblaciones


Dos columnas de peso, ambas bimodales. Una mezcla kilogramos con libras; la otra registra adultos y niños. El histograma no las distingue.



Ambas son bimodales. La primera requiere corrección y la segunda no, y el histograma no permite distinguirlas.


El cociente entre los modos

En escala logarítmica la separación entre modos es el logaritmo de su cociente. Ese cociente se estima ajustando una mezcla de dos normales, y su incertidumbre por **bootstrap**, remuestreando con reemplazo y repitiendo la estimación en cada réplica.



El cociente entre los modos

En escala logarítmica la separación entre modos es el logaritmo de su cociente. Ese cociente se estima ajustando una mezcla de dos normales, y su incertidumbre por **bootstrap**, remuestreando con reemplazo y repitiendo la estimación en cada réplica.



El intervalo de la columna A contiene el factor kilogramo a libra; el de la columna B no contiene ningún factor tabulado. Coincidir con una conversión conocida es lo que permite dividir. Sin esa coincidencia, lo correcto es marcar la columna y consultar la fuente, nunca dividir por el cociente estimado.

Depuración declarativa

```
import polars as pl

REGLAS = [
    (pl.col("edad").is_between(0, 120), "edad fuera de dominio"),
    (pl.col("vef") > 0, "espirometría no positiva"),
    (pl.col("fecha_alta") >= pl.col("fecha_ingreso"), "alta anterior al ingreso"),
]

df = df.with_columns([
    pl.when(cond).then(pl.lit(0)).otherwise(pl.lit(1)).alias(f"viola_{i}")
    for i, (cond, _) in enumerate(REGLAS)
])

informe = df.select(pl.col("^viola_.*$").sum()) # cuántos registros viola cada regla
limpio = df.filter(pl.sum_horizontal(pl.col("^viola_.*$")) == 0)
```

Depuración declarativa

```
import polars as pl

REGLAS = [
    (pl.col("edad").is_between(0, 120),          "edad fuera de dominio"),
    (pl.col("vef") > 0,                          "espirometría no positiva"),
    (pl.col("fecha_alta") >= pl.col("fecha_ingreso"), "alta anterior al ingreso"),
]

df = df.with_columns([
    pl.when(cond).then(pl.lit(0)).otherwise(pl.lit(1)).alias(f"viola_{i}")
    for i, (cond, _) in enumerate(REGLAS)
])

informe = df.select(pl.col("^viola_.*$").sum())      # cuántos registros viola cada regla
limpio  = df.filter(pl.sum_horizontal(pl.col("^viola_.*$")) == 0)
```

Las reglas se declaran una vez y producen dos salidas, el informe de violaciones y el conjunto depurado.

Integración

1. **Cambio de granularidad.** Una unión uno a muchos multiplica filas y rompe la independencia.
2. **Conflicto de esquema.** Dos fuentes usan la misma etiqueta con distinto significado o unidad.
3. **Fuga temporal.** La tabla incorporada contiene información posterior a la predicción.

Integración

1. **Cambio de granularidad.** Una unión uno a muchos multiplica filas y rompe la independencia.
2. **Conflicto de esquema.** Dos fuentes usan la misma etiqueta con distinto significado o unidad.
3. **Fuga temporal.** La tabla incorporada contiene información posterior a la predicción.

```
unido = eventos.join_asof(                # une con el último valor disponible
    mediciones.sort("t"),                  # ANTES del instante del evento
    left_on="t_evento", right_on="t", by="paciente", strategy="backward",
)
```

Integración

1. **Cambio de granularidad.** Una unión uno a muchos multiplica filas y rompe la independencia.
2. **Conflicto de esquema.** Dos fuentes usan la misma etiqueta con distinto significado o unidad.
3. **Fuga temporal.** La tabla incorporada contiene información posterior a la predicción.

```
unido = eventos.join_asof(                # une con el último valor disponible
    mediciones.sort("t"),                 # ANTES del instante del evento
    left_on="t_evento", right_on="t", by="paciente", strategy="backward",
)
```

La unión por proximidad temporal hacia atrás incorpora una serie sin usar el futuro; la unión ordinaria por identificador sí lo usa.

Imputación: Qué hace la media

Sea x con m valores faltantes de n bajo MCAR. La imputación por la media observada $\bar{x}_{\text{obs}}$ entrega:

$$\hat{\sigma}_{\text{imp}}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i^{\text{imp}} - \bar{x})^2 = \frac{n-m-1}{n-1} \hat{\sigma}_{\text{obs}}^2,$$

dado que las m observaciones imputadas contribuyen con desviación nula.

Imputación: Qué hace la media

Sea x con m valores faltantes de n bajo MCAR. La imputación por la media observada $\bar{x}_{\text{obs}}$ entrega:

$$\hat{\sigma}_{\text{imp}}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i^{\text{imp}} - \bar{x})^2 = \frac{n-m-1}{n-1} \hat{\sigma}_{\text{obs}}^2,$$

dado que las m observaciones imputadas contribuyen con desviación nula.

Con un 30 % de faltantes, la varianza estimada se reduce cerca de un 30 % y toda inferencia posterior resulta anticonservadora.

Imputación: Qué hace la media

Sea x con m valores faltantes de n bajo MCAR. La imputación por la media observada $\bar{x}_{\text{obs}}$ entrega:

$$\hat{\sigma}_{\text{imp}}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i^{\text{imp}} - \bar{x})^2 = \frac{n-m-1}{n-1} \hat{\sigma}_{\text{obs}}^2,$$


dado que las m observaciones imputadas contribuyen con desviación nula.

Con un 30 % de faltantes, la varianza estimada se reduce cerca de un 30 % y toda inferencia posterior resulta anticonservadora.


La imputación por la media preserva la media y sesga la varianza, la covarianza y la forma de la distribución. Es admisible sólo cuando la proporción de faltantes es despreciable, situación en la que cualquier método sirve.

Imputación: Comparación


Valores reales, $r = 0.85$




Media, $r = 0.48$




KNN, $k = 5$, $r = 0.85$



Iterativa (MICE), $r = 0.88$



Imputación: Comparación



Mecanismo MAR con 37 % de faltantes en la segunda variable. En verde los valores reales que se ocultan, en granate los imputados. La imputación por la media colapsa los faltantes sobre una recta horizontal y reduce la correlación.

Imputación múltiple y reglas de Rubin

La imputación simple trata los valores imputados como si fueran observados y subestima la incertidumbre. La imputación múltiple genera M conjuntos completos, ajusta el modelo en cada uno y combina.

$$\bar{Q} = \frac{1}{M} \sum_{m=1}^M \hat{Q}_m, \quad \bar{U} = \frac{1}{M} \sum_{m=1}^M \hat{U}_m, \quad B = \frac{1}{M-1} \sum_{m=1}^M (\hat{Q}_m - \bar{Q})^2$$

Imputación múltiple y reglas de Rubin

La imputación simple trata los valores imputados como si fueran observados y subestima la incertidumbre. La imputación múltiple genera M conjuntos completos, ajusta el modelo en cada uno y combina.

$$\bar{Q} = \frac{1}{M} \sum_{m=1}^M \hat{Q}_m, \quad \bar{U} = \frac{1}{M} \sum_{m=1}^M \hat{U}_m, \quad B = \frac{1}{M-1} \sum_{m=1}^M (\hat{Q}_m - \bar{Q})^2$$

$$T = \bar{U} + \left(1 + \frac{1}{M}\right) B$$

Imputación múltiple y reglas de Rubin

La imputación simple trata los valores imputados como si fueran observados y subestima la incertidumbre. La imputación múltiple genera M conjuntos completos, ajusta el modelo en cada uno y combina.

$$\bar{Q} = \frac{1}{M} \sum_{m=1}^M \hat{Q}_m, \quad \bar{U} = \frac{1}{M} \sum_{m=1}^M \hat{U}_m, \quad B = \frac{1}{M-1} \sum_{m=1}^M (\hat{Q}_m - \bar{Q})^2$$

$$T = \bar{U} + \left(1 + \frac{1}{M}\right) B$$

$\bar{U}$ es la varianza dentro de cada imputación y B la varianza entre imputaciones, que cuantifica la incertidumbre por no haber observado el dato. La imputación simple corresponde a $B = 0$.

Reducción de datos

Técnica	Reduce	Garantía	Uso
Muestreo aleatorio simple	Filas	Insesgado, error $O(n^{-1/2})$	Exploración
Muestreo estratificado	Filas	Varianza menor a igual n	Clases desbalanceadas
Muestreo con reserva	Filas	Una pasada, flujo continuo	Datos en línea
Agregación	Filas	Exacta si la consulta es aditiva	Tableros, informes
Cuantización	Precisión	Error acotado por el paso	Almacenamiento

Reducción de datos

Técnica	Reduce	Garantía	Uso
Muestreo aleatorio simple	Filas	Inssegado, error $O(n^{-1/2})$	Exploración
Muestreo estratificado	Filas	Varianza menor a igual n	Clases desbalanceadas
Muestreo con reserva	Filas	Una pasada, flujo continuo	Datos en línea
Agregación	Filas	Exacta si la consulta es aditiva	Tableros, informes
Cuantización	Precisión	Error acotado por el paso	Almacenamiento

La agregación previa es la reducción que más información descarta, porque elimina la variabilidad interna de los grupos y, según la paradoja de Simpson, puede invertir el signo de la asociación observada.

Regresión lineal: El modelo y sus parámetros

Todo lo que sigue en la presentación opera sobre un modelo de regresión, de modo que revisaremos qué es y qué se estima en él.

Regresión lineal: El modelo y sus parámetros

Todo lo que sigue en la presentación opera sobre un modelo de regresión, de modo que revisaremos qué es y qué se estima en él.

Con p predictores y una respuesta y , el modelo lineal postula:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \mathbb{E}(\varepsilon_i) = 0,$$

o en forma matricial $y = X\beta + \varepsilon$ con $X \in \mathbb{R}^{n \times (p+1)}$.

Regresión lineal: El modelo y sus parámetros

Todo lo que sigue en la presentación opera sobre un modelo de regresión, de modo que revisaremos qué es y qué se estima en él.

Con p predictores y una respuesta y , el modelo lineal postula:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \mathbb{E}(\varepsilon_i) = 0,$$

o en forma matricial $y = X\beta + \varepsilon$ con $X \in \mathbb{R}^{n \times (p+1)}$.

Lineal se refiere a los **parámetros**, no a las variables. El modelo $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$ es lineal, y $y = \beta_0 e^{\beta_1 x} + \varepsilon$ no lo es. Las bases de expansión, más adelante en esta unidad, retoman esta distinción.

Regresión lineal: El modelo y sus parámetros

Todo lo que sigue en la presentación opera sobre un modelo de regresión, de modo que revisaremos qué es y qué se estima en él.

Con p predictores y una respuesta y , el modelo lineal postula:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \mathbb{E}(\varepsilon_i) = 0,$$

o en forma matricial $y = X\beta + \varepsilon$ con $X \in \mathbb{R}^{n \times (p+1)}$.

Lineal se refiere a los **parámetros**, no a las variables. El modelo $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$ es lineal, y $y = \beta_0 e^{\beta_1 x} + \varepsilon$ no lo es. Las bases de expansión, más adelante en esta unidad, retoman esta distinción.

Los parámetros β son desconocidos y se estiman a partir de los datos. En el vocabulario de la unidad 2, $\hat{\beta}$ es un estimador, tiene sesgo y varianza, y su ECM se descompone en esos dos términos.

Estimación por mínimos cuadrados

El criterio elige el β que minimiza la suma de cuadrados de los residuos:

$$\hat{\beta} = \arg \min_{\beta} \|y - X\beta\|_2^2.$$

Estimación por mínimos cuadrados

El criterio elige el β que minimiza la suma de cuadrados de los residuos:

$$\hat{\beta} = \arg \min_{\beta} \|y - X\beta\|_2^2.$$

Derivando e igualando a cero se obtienen las **ecuaciones normales** y su solución:

$$X^T(y - X\hat{\beta}) = 0 \quad \implies \quad \hat{\beta} = (X^T X)^{-1} X^T y,$$

válida cuando $X^T X$ es invertible, es decir, cuando las columnas son linealmente independientes y $n > p$.

Estimación por mínimos cuadrados

El criterio elige el β que minimiza la suma de cuadrados de los residuos:

$$\hat{\beta} = \arg \min_{\beta} \|y - X\beta\|_2^2.$$

Derivando e igualando a cero se obtienen las **ecuaciones normales** y su solución:

$$X^T(y - X\hat{\beta}) = 0 \quad \implies \quad \hat{\beta} = (X^T X)^{-1} X^T y,$$

válida cuando $X^T X$ es invertible, es decir, cuando las columnas son linealmente independientes y $n > p$.

La primera ecuación dice que el residuo es ortogonal a toda columna de X , de modo que $\hat{y}$ es la **proyección ortogonal** de y sobre el espacio generado por los predictores.

Estimación por mínimos cuadrados

El criterio elige el β que minimiza la suma de cuadrados de los residuos:

$$\hat{\beta} = \arg \min_{\beta} \|y - X\beta\|_2^2.$$

Derivando e igualando a cero se obtienen las **ecuaciones normales** y su solución:

$$X^T(y - X\hat{\beta}) = 0 \quad \implies \quad \hat{\beta} = (X^T X)^{-1} X^T y,$$

válida cuando $X^T X$ es invertible, es decir, cuando las columnas son linealmente independientes y $n > p$.

La primera ecuación dice que el residuo es ortogonal a toda columna de X , de modo que $\hat{y}$ es la **proyección ortogonal** de y sobre el espacio generado por los predictores.

Bajo el modelo, $\hat{\beta}$ es insesgado y $\text{Var}(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$.

Por qué penalizar

Cuando las columnas de X son casi colineales, $X^T X$ está mal condicionada y la varianza $\sigma^2 (X^T X)^{-1}$ se dispara. El estimador sigue siendo insesgado y deja de ser útil.

Por qué penalizar

Cuando las columnas de X son casi colineales, $X^T X$ está mal condicionada y la varianza $\sigma^2 (X^T X)^{-1}$ se dispara. El estimador sigue siendo insesgado y deja de ser útil.

La penalización añade un término que restringe la magnitud de los coeficientes:

$$\hat{\beta}_\lambda = \arg \min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \Omega(\beta), \quad \Omega = \|\cdot\|_2^2 \text{ o } \|\cdot\|_1.$$

Por qué penalizar

Cuando las columnas de X son casi colineales, $X^T X$ está mal condicionada y la varianza $\sigma^2 (X^T X)^{-1}$ se dispara. El estimador sigue siendo insesgado y deja de ser útil.

La penalización añade un término que restringe la magnitud de los coeficientes:

$$\hat{\beta}_\lambda = \arg \min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \Omega(\beta), \quad \Omega = \|\cdot\|_2^2 \text{ o } \|\cdot\|_1.$$

El estimador resultante es **sesgado por construcción**, y se justifica con la descomposición sesgo-varianza. El sesgo introducido es pequeño frente a la reducción de varianza que produce, de modo que el ECM baja.

Por qué penalizar

Cuando las columnas de X son casi colineales, $X^T X$ está mal condicionada y la varianza $\sigma^2 (X^T X)^{-1}$ se dispara. El estimador sigue siendo insesgado y deja de ser útil.

La penalización añade un término que restringe la magnitud de los coeficientes:

$$\hat{\beta}_\lambda = \arg \min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \Omega(\beta), \quad \Omega = \|\cdot\|_2^2 \text{ o } \|\cdot\|_1.$$

El estimador resultante es **sesgado por construcción**, y se justifica con la descomposición sesgo-varianza. El sesgo introducido es pequeño frente a la reducción de varianza que produce, de modo que el ECM baja.

El parámetro λ se estima por validación cruzada, luego es un parámetro estimado a partir de los datos y queda sujeto a la regla del flujo.

Transformaciones de escala

Transformación	Definición	Apropiada cuando
Estandarización	$(x - \hat{\mu}) / \hat{\sigma}$	Distribución aproximadamente simétrica
Mínimo-máximo	$(x - x_{\min}) / (x_{\max} - x_{\min})$	Rango conocido y acotado
Robusta	$(x - \hat{Q}_2) / \widehat{IQR}$	Presencia de valores extremos
Cuantil	$\Phi^{-1}(F_n(x))$	Forma arbitraria, n grande
Yeo-Johnson	Familia potencia con λ estimado	Asimetría, admite valores negativos
Norma unitaria	$\mathbf{x} / \ \mathbf{x}\ _2$	La dirección importa y la magnitud no

Transformaciones de escala



Transformación	Definición	Apropiada cuando
Estandarización	$(x - \hat{\mu})/\hat{\sigma}$	Distribución aproximadamente simétrica
Mínimo-máximo	$(x - x_{\min})/(x_{\max} - x_{\min})$	Rango conocido y acotado
Robusta	$(x - \hat{Q}_2)/\widehat{IQR}$	Presencia de valores extremos
Cuantil	$\Phi^{-1}(F_n(x))$	Forma arbitraria, n grande
Yeo-Johnson	Familia potencia con λ estimado	Asimetría, admite valores negativos
Norma unitaria	$\mathbf{x}/\ \mathbf{x}\ _2$	La dirección importa y la magnitud no

La familia de Yeo-Johnson generaliza a Box-Cox admitiendo $x \leq 0$:


$$\psi_{\lambda}(x) = \begin{cases} ((x+1)^{\lambda} - 1)/\lambda, & \lambda \neq 0, x \geq 0, \\ \log(x+1), & \lambda = 0, x \geq 0, \end{cases}$$

con λ estimado por máxima verosimilitud bajo normalidad de $\psi_{\lambda}(X)$.

Efecto de la escala sobre el modelo



Efecto de la escala sobre el modelo



Los métodos basados en distancia y los penalizados por norma no son invariantes a la escala de las columnas. Los árboles y sus combinaciones sí lo son, porque sólo usan el orden dentro de cada variable.

Extracción y selección de características

	Selección	Extracción
Salida	Subconjunto $S \subseteq \{1, \dots, p\}$	$z = g(\mathbf{x}) \in \mathbb{R}^k$
Interpretabilidad	Conserva el significado original	Coordenadas nuevas
Costo de medición	Se reduce, no se miden las descartadas	No se reduce
Uso típico	Selección de biomarcadores	Compresión, descorrelación

Extracción y selección de características

	Selección	Extracción
Salida	Subconjunto $S \subseteq \{1, \dots, p\}$	$z = g(\mathbf{x}) \in \mathbb{R}^k$
Interpretabilidad	Conserva el significado original	Coordenadas nuevas
Costo de medición	Se reduce, no se miden las descartadas	No se reduce
Uso típico	Selección de biomarcadores	Compresión, descorrelación

Familia	Criterio	Costo	Limitación
Filtro	Asociación marginal con Y	$O(p)$	Ignora interacciones
Envoltura	Desempeño del modelo	$O(p^2)$ o mayor	Riesgo de sobreajuste
Embebida	Penalización dentro del ajuste	Costo del ajuste	Depende del modelo

Extracción y selección de características

	Selección	Extracción
Salida	Subconjunto $S \subseteq \{1, \dots, p\}$	$z = g(\mathbf{x}) \in \mathbb{R}^k$
Interpretabilidad	Conserva el significado original	Coordenadas nuevas
Costo de medición	Se reduce, no se miden las descartadas	No se reduce
Uso típico	Selección de biomarcadores	Compresión, descorrelación

Familia	Criterio	Costo	Limitación
Filtro	Asociación marginal con Y	$O(p)$	Ignora interacciones
Envoltura	Desempeño del modelo	$O(p^2)$ o mayor	Riesgo de sobreajuste
Embebida	Penalización dentro del ajuste	Costo del ajuste	Depende del modelo

Un filtro marginal descarta variables cuyo efecto sólo aparece en combinación. Con $y = x_1 \oplus x_2$, ambas variables tienen asociación marginal nula con y y son conjuntamente determinantes.

Selección embebida: Por qué la penalización ℓ_1 anula coeficientes

El estimador Lasso resuelve $\min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1$.

Selección embebida: Por qué la penalización ℓ_1 anula coeficientes

El estimador Lasso resuelve $\min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1$.

La función $|\beta_j|$ no es diferenciable en cero, donde no hay una derivada sino un rango de pendientes admisibles. La condición de optimalidad queda:

$$\frac{1}{n} \mathbf{x}_j^T (y - X\hat{\beta}) = \lambda s_j,$$
$$s_j = \text{sgn}(\hat{\beta}_j) \text{ si } \hat{\beta}_j \neq 0, \quad s_j \in [-1, 1] \text{ si } \hat{\beta}_j = 0.$$

Selección embebida: Por qué la penalización ℓ_1 anula coeficientes

El estimador Lasso resuelve $\min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1$.


La función $|\beta_j|$ no es diferenciable en cero, donde no hay una derivada sino un rango de pendientes admisibles. La condición de optimalidad queda:

$$\frac{1}{n} \mathbf{x}_j^\top (y - X\hat{\beta}) = \lambda s_j,$$


$$s_j = \text{sgn}(\hat{\beta}_j) \text{ si } \hat{\beta}_j \neq 0, \quad s_j \in [-1, 1] \text{ si } \hat{\beta}_j = 0.$$

Ese intervalo permite anular $\hat{\beta}_j$ y produce ceros exactos.

Geometría de la penalización




Geometría de la penalización




En azul los contornos de la suma de cuadrados y en granate la región admisible. El contacto con la bola ℓ_1 ocurre en un vértice, donde una coordenada es exactamente cero. La bola ℓ_2 es lisa y el contacto se produce en un punto de coordenadas genéricas.

Estabilidad de la selección



Estabilidad de la selección




Entre dos variables casi colineales el Lasso elige una de manera esencialmente arbitraria y la elección cambia con la muestra. La frecuencia de selección sobre remuestreos es una medida de estabilidad que un único ajuste no entrega.


PCA: La idea

Dos variables correlacionadas ocupan una franja alargada. Casi toda la información está en la dirección larga de esa franja.


1. Datos originales



2. Centrar y hallar direcciones propias




3. Proyectar sobre $\mathbf{v}_1$



PCA: La idea

Dos variables correlacionadas ocupan una franja alargada. Casi toda la información está en la dirección larga de esa franja.



Los segmentos naranjos son lo que se descarta al quedarse con una sola coordenada. PCA elige la dirección $\mathbf{v}_1$ que los hace, en promedio, lo más cortos posible. Esa dirección coincide con la de máxima varianza.

PCA: Cálculo

1. **Centrar.** $\tilde{x}_i = x_i - \bar{x}$. Sin centrar, la primera componente apunta al centroide y no describe variabilidad.
2. **Covarianza.** $S = \frac{1}{n-1} \tilde{X}^T \tilde{X} \in \mathbb{R}^{p \times p}$, simétrica y con valores propios reales y no negativos.
3. **Diagonalizar.** $S = V \Lambda V^T$ con $\lambda_1 \geq \dots \geq \lambda_p \geq 0$ y V ortogonal.
4. **Proyectar.** $z_i = V_k^T \tilde{x}_i \in \mathbb{R}^k$, quedándose con las k primeras columnas.

PCA: Cálculo

Cada λ_j es la **varianza de los datos a lo largo de** v_j , y como la traza se conserva bajo cambio de base ortogonal:

$$\sum_{j=1}^p \lambda_j = \text{tr}(S) = \sum_{j=1}^p \hat{\sigma}_j^2 \quad \Rightarrow \quad \text{proporción explicada por } v_j = \frac{\lambda_j}{\sum_l \lambda_l}.$$

PCA: Cálculo

Cada λ_j es la **varianza de los datos a lo largo de** v_j , y como la traza se conserva bajo cambio de base ortogonal:

$$\sum_{j=1}^p \lambda_j = \text{tr}(S) = \sum_{j=1}^p \hat{\sigma}_j^2 \quad \Rightarrow \quad \text{proporción explicada por } v_j = \frac{\lambda_j}{\sum_l \lambda_l}.$$

En la práctica no se forma S . Se calcula la descomposición en valores singulares $\tilde{X} = U\Sigma V^T$, que entrega los mismos V con $\lambda_j = \sigma_j^2 / (n - 1)$ y es numéricamente estable.

PCA: Ejemplo

```
Xc = P2 - P2.mean(axis=0)          # 1. centrar
S  = np.cov(Xc, rowvar=False)      # 2. covarianza 2x2
lam, V = np.linalg.eigh(S)         # 3. diagonalizar
lam, V = lam[::-1], V[:, ::-1]     #   de mayor a menor
Z  = Xc @ V[:, :1]                 # 4. proyectar sobre v1

print("var(Z) =", round(float(Z.var(ddof=1)), 3),
      "   lambda_1 =", round(float(lam[0]), 3))
print("tr(S)  =", round(float(np.trace(S)), 3),
      "   suma de autovalores =", round(float(lam.sum()), 3))
print("proporcion explicada por v1 =", round(float(lam[0]/lam.sum()), 3))
```

```
var(Z) = 1.597   lambda_1 = 1.597
tr(S)  = 1.855   suma de autovalores = 1.855
proporcion explicada por v1 = 0.861
```

PCA: Ejemplo

```
Xc = P2 - P2.mean(axis=0)          # 1. centrar
S  = np.cov(Xc, rowvar=False)      # 2. covarianza 2x2
lam, V = np.linalg.eigh(S)         # 3. diagonalizar
lam, V = lam[::-1], V[:, ::-1]     #   de mayor a menor
Z  = Xc @ V[:, :1]                 # 4. proyectar sobre v1

print("var(Z) =", round(float(Z.var(ddof=1)), 3),
      "   lambda_1 =", round(float(lam[0]), 3))
print("tr(S)  =", round(float(np.trace(S)), 3),
      "   suma de autovalores =", round(float(lam.sum()), 3))
print("proporcion explicada por v1 =", round(float(lam[0]/lam.sum()), 3))
```

```
var(Z) = 1.597    lambda_1 = 1.597
tr(S)  = 1.855    suma de autovalores = 1.855
proporcion explicada por v1 = 0.861
```

La varianza de la proyección coincide con el primer valor propio y la suma de valores propios reproduce la traza.

Ambas identidades comprueban que la implementación es correcta.

PCA: Tres formulaciones equivalentes

Formulación	Problema
Máxima varianza	$\max_{\ v\ =1} v^T S v$, sucesivamente ortogonal
Mínimo error de reconstrucción	$\min_{V_k} \sum_i \ x_i - V_k V_k^T x_i\ _2^2$
Aproximación de rango bajo	$\min_{\text{rango}(B) \leq k} \ X - B\ _F$

PCA: Tres formulaciones equivalentes

Formulación	Problema
Máxima varianza	$\max_{\ v\ =1} v^T S v$, sucesivamente ortogonal
Mínimo error de reconstrucción	$\min_{V_k} \sum_i \ x_i - V_k V_k^T x_i\ _2^2$
Aproximación de rango bajo	$\min_{\text{rango}(B) \leq k} \ X - B\ _F$

Eckart-Young-Mirsky. Si $X = U \Sigma V^T$, el minimizador es $X_k = U_k \Sigma_k V_k^T$ y el error vale $\|X - X_k\|_F^2 = \sum_{j>k} \sigma_j^2$. Las tres formulaciones tienen la misma solución.


PCA: Tres formulaciones equivalentes

Formulación	Problema
Máxima varianza	$\max_{\ v\ =1} v^T S v$, sucesivamente ortogonal
Mínimo error de reconstrucción	$\min_{V_k} \sum_i \ x_i - V_k V_k^T x_i\ _2^2$
Aproximación de rango bajo	$\min_{\text{rango}(B) \leq k} \ X - B\ _F$


Eckart-Young-Mirsky. Si $X = U \Sigma V^T$, el minimizador es $X_k = U_k \Sigma_k V_k^T$ y el error vale $\|X - X_k\|_F^2 = \sum_{j>k} \sigma_j^2$. Las tres formulaciones tienen la misma solución.

Maximizar varianza y minimizar error de reconstrucción son el mismo problema porque la varianza total se reparte entre lo retenido y lo descartado.

PCA: Qué significa retener k componentes





PCA: Qué significa retener k componentes




Dígitos manuscritos de 8×8 , es decir $p = 64$. Con $k = 12$ componentes se retiene el 78 % de la varianza y el dígito ya es reconocible. Retener k componentes equivale a describir cada observación con k números en lugar de 64.

PCA: Escala de las columnas





PCA: Escala de las columnas




Sin estandarizar, la primera componente es prácticamente la variable de mayor varianza numérica, con independencia de su relevancia.

PCA sobre la matriz de correlación, es decir con estandarización previa, es el procedimiento por omisión salvo que todas las columnas compartan unidad y esa unidad sea significativa.

Elección del número de componentes



Elección del número de componentes



El umbral de varianza acumulada es arbitrario.

El análisis paralelo compara el espectro observado con el esperado bajo independencia y retiene las componentes que lo superan, criterio que recupera la dimensión latente verdadera en este ejemplo.

Proyecciones aleatorias

Cuando p es muy grande, existe una alternativa a PCA que no requiere estimar S .

Proyecciones aleatorias

Cuando p es muy grande, existe una alternativa a PCA que no requiere estimar S .

Lema de Johnson–Lindenstrauss. Para todo $0 < \varepsilon < 1$ y todo conjunto de n puntos en $\mathbb{R}^p$, existe una aplicación lineal $f : \mathbb{R}^p \rightarrow \mathbb{R}^k$ con $k = O(\varepsilon^{-2} \log n)$ tal que:

$$(1 - \varepsilon) \|x_i - x_j\|_2^2 \leq \|f(x_i) - f(x_j)\|_2^2 \leq (1 + \varepsilon) \|x_i - x_j\|_2^2$$

para todo par i, j .

Proyecciones aleatorias

Cuando p es muy grande, existe una alternativa a PCA que no requiere estimar S .



Lema de Johnson–Lindenstrauss. Para todo $0 < \varepsilon < 1$ y todo conjunto de n puntos en $\mathbb{R}^p$, existe una aplicación lineal $f : \mathbb{R}^p \rightarrow \mathbb{R}^k$ con $k = O(\varepsilon^{-2} \log n)$ tal que:

$$(1 - \varepsilon)\|\mathbf{x}_i - \mathbf{x}_j\|_2^2 \leq \|f(\mathbf{x}_i) - f(\mathbf{x}_j)\|_2^2 \leq (1 + \varepsilon)\|\mathbf{x}_i - \mathbf{x}_j\|_2^2$$


para todo par i, j .

La dimensión de llegada depende de $\log n$ y **no depende de p** . Con $n = 10^6$ y $\varepsilon = 0,1$ la cota entrega k del orden de algunos miles, sea $p = 10^4$ o $p = 10^7$.

La maldición de la dimensión




La maldición de la dimensión




Bajo independencia entre coordenadas, $\|\mathbf{x}\|_2$ se concentra en $\sqrt{p}$ con desviación $O(1)$, de modo que el contraste relativo entre el vecino más cercano y el más lejano tiende a cero.

El concepto de vecindad pierde contenido y, por consiguiente, los métodos basados en distancia.

Una proyección lineal no siempre es suficiente



Una proyección lineal no siempre es suficiente



PCA busca la mejor **combinación lineal** de las variables.


La estructura de este conjunto es radial y ninguna combinación lineal la captura.

Los métodos no lineales construyen coordenadas como la del tercer panel.


UMAP: Construcción

UMAP no proyecta. Construye un **grafo de vecindad** en el espacio original y luego busca una disposición en el plano que reproduzca ese grafo.

1. Grafo de los k vecinos



2. Peso difuso por punto




3. Disposición en $\mathbb{R}^2$ del grafo



UMAP: Construcción

UMAP no proyecta. Construye un **grafo de vecindad** en el espacio original y luego busca una disposición en el plano que reproduzca ese grafo.



El radio ρ_i es la distancia al vecino más próximo y σ_i se ajusta para que los pesos de cada punto sumen $\log_2 k$. Así, un punto en zona rara considera “cercaños” a vecinos más lejanos que un punto en zona densa.

Esa normalización local es lo que permite tratar densidades heterogéneas.

UMAP: Función objetivo

Sea w_{ij} el peso del grafo en el espacio original y q_{ij} el peso análogo entre las posiciones y_i, y_j del plano:

$$q_{ij} = (1 + a\|y_i - y_j\|_2^{2b})^{-1}.$$

UMAP: Función objetivo

Sea w_{ij} el peso del grafo en el espacio original y q_{ij} el peso análogo entre las posiciones y_i, y_j del plano:

$$q_{ij} = (1 + a\|y_i - y_j\|_2^{2b})^{-1}.$$

Las posiciones $\{y_i\}$ se obtienen minimizando la entropía cruzada entre ambos grafos:

$$\mathcal{L} = \sum_{i < j} \left[w_{ij} \log \frac{w_{ij}}{q_{ij}} + (1 - w_{ij}) \log \frac{1 - w_{ij}}{1 - q_{ij}} \right].$$

UMAP: Función objetivo

Sea w_{ij} el peso del grafo en el espacio original y q_{ij} el peso análogo entre las posiciones y_i, y_j del plano:

$$q_{ij} = (1 + a\|y_i - y_j\|_2^{2b})^{-1}.$$


Las posiciones $\{y_i\}$ se obtienen minimizando la entropía cruzada entre ambos grafos:

$$\mathcal{L} = \sum_{i < j} \left[w_{ij} \log \frac{w_{ij}}{q_{ij}} + (1 - w_{ij}) \log \frac{1 - w_{ij}}{1 - q_{ij}} \right].$$


El término **azul atrae** a los pares vecinos en el original; el **granate repele** a los que no lo son. t -SNE minimiza la divergencia de Kullback–Leibler, que sólo contiene el primer término, y por eso conserva menos estructura global que UMAP.

UMAP: Ejemplo


n_neighbors = 5, min_dist = 0.0




n_neighbors = 15, min_dist = 0.0




n_neighbors = 50, min_dist = 0.0




n_neighbors = 5, min_dist = 0.5




n_neighbors = 15, min_dist = 0.5



n_neighbors = 50, min_dist = 0.5



UMAP: Ejemplo



Parámetro	Controla	Valor bajo / alto
$n_neighbors$	Tamaño del vecindario	Estructura local fragmentada / estructura global
$\min_dist$	Separación mínima en el plano	Grupos compactos / distribución dispersa

Qué se puede leer en un mapa de UMAP o t -SNE

Aspecto del gráfico	PCA, MDS métrico	t -SNE, UMAP
Distancia entre puntos vecinos	Interpretable	Aproximadamente interpretable
Distancia entre grupos lejanos	Interpretable	no interpretable
Tamaño y densidad de los grupos	Interpretable	no interpretable
Número de grupos	Interpretable	Depende de los parámetros
Ejes	Combinación lineal explícita	Sin significado
Reproducibilidad	Determinista	Depende de la semilla
Aplicable a datos nuevos	Sí	UMAP sí, t -SNE no

Qué se puede leer en un mapa de UMAP o t -SNE

Aspecto del gráfico	PCA, MDS métrico	t -SNE, UMAP
Distancia entre puntos vecinos	Interpretable	Aproximadamente interpretable
Distancia entre grupos lejanos	Interpretable	no interpretable
Tamaño y densidad de los grupos	Interpretable	no interpretable
Número de grupos	Interpretable	Depende de los parámetros
Ejes	Combinación lineal explícita	Sin significado
Reproducibilidad	Determinista	Depende de la semilla
Aplicable a datos nuevos	Sí	UMAP sí, t -SNE no

Un mapa de UMAP no permite afirmar que dos grupos separados en pantalla son más distintos entre sí que dos grupos contiguos, ni a comparar el tamaño de las nubes.

Para esas preguntas corresponde volver al espacio original y medir.

Reducción no lineal de la dimensión

Método	Preserva	Aplicable a datos nuevos	Costo
PCA	Varianza global, distancias euclídeas	Sí, proyección lineal	$O(n p \min(n, p))$
PCA de kernel	Distancias en el espacio de kernel	Sí	$O(n^3)$
MDS métrico	Todas las distancias	No directamente	$O(n^3)$
Isomap	Distancias geodésicas sobre el grafo	No directamente	$O(n^3)$
LLE	Reconstrucciones locales lineales	No directamente	$O(n^2 k)$
t -SNE	Vecindades locales	No	$O(n \log n)$
UMAP	Vecindades locales y algo de estructura global	Sí, con extensión	$O(n^{1,14})$
Autocodificador	Lo que la pérdida especifique	Sí	Entrenamiento

Reducción no lineal de la dimensión

Método	Preserva	Aplicable a datos nuevos	Costo
PCA	Varianza global, distancias euclídeas	Sí, proyección lineal	$O(n p \min(n, p))$
PCA de kernel	Distancias en el espacio de kernel	Sí	$O(n^3)$
MDS métrico	Todas las distancias	No directamente	$O(n^3)$
Isomap	Distancias geodésicas sobre el grafo	No directamente	$O(n^3)$
LLE	Reconstrucciones locales lineales	No directamente	$O(n^2 k)$
t -SNE	Vecindades locales	No	$O(n \log n)$
UMAP	Vecindades locales y algo de estructura global	Sí, con extensión	$O(n^{1,14})$
Autocodificador	Lo que la pérdida especifique	Sí	Entrenamiento

La columna de aplicabilidad a datos nuevos determina si el método sirve dentro de un flujo de predicción.

Los métodos sin esa propiedad son instrumentos de exploración y no pueden formar parte de un Pipeline evaluado por validación cruzada.

Efectos lineales y no lineales

Un modelo es **lineal en los parámetros** si $f(\mathbf{x}) = \sum_j \beta_j \phi_j(\mathbf{x})$, cualquiera sea la forma de las funciones base ϕ_j .

Efectos lineales y no lineales

Un modelo es **lineal en los parámetros** si $f(\mathbf{x}) = \sum_j \beta_j \phi_j(\mathbf{x})$, cualquiera sea la forma de las funciones base ϕ_j .

Base	Forma	Comportamiento
Polinomial	$1, x, x^2, \dots, x^d$	Global, oscila en los extremos
Constante por tramos	$\mathbb{1}\{x \in I_k\}$	Discontinua, requiere cortes
Spline cúbico	Tramos cúbicos con dos derivadas continuas	Local y suave
Spline natural	Cúbico, lineal fuera de los nodos extremos	Controla las colas
Kernel gaussiano	$\exp(-\ x - c_k\ ^2 / 2h^2)$	Local, ancho h
Interacción	$x_j x_k, \phi_j \cdot \phi_k$	Efecto conjunto




Efectos lineales y no lineales

Un modelo es **lineal en los parámetros** si $f(\mathbf{x}) = \sum_j \beta_j \phi_j(\mathbf{x})$, cualquiera sea la forma de las funciones base ϕ_j .


Base	Forma	Comportamiento
Polinomial	$1, x, x^2, \dots, x^d$	Global, oscila en los extremos
Constante por tramos	$\mathbb{1}\{x \in I_k\}$	Discontinua, requiere cortes
Spline cúbico	Tramos cúbicos con dos derivadas continuas	Local y suave
Spline natural	Cúbico, lineal fuera de los nodos extremos	Controla las colas
Kernel gaussiano	$\exp(-\ x - c_k\ ^2 / 2h^2)$	Local, ancho h
Interacción	$x_j x_k, \phi_j \cdot \phi_k$	Efecto conjunto

La regresión sobre una base sigue siendo un problema de mínimos cuadrados lineales. La no linealidad reside en ϕ , no en el procedimiento de estimación, de modo que toda la teoría lineal continúa siendo aplicable.

Bases de expansión



Bases de expansión



Línea discontinua es la función verdadera; continua es el ajuste. El polinomio de grado alto oscila en los extremos, fenómeno de Runge. El spline concentra la flexibilidad donde hay nodos y se comporta de manera estable en todo el rango.

Kernels y modelos aditivos

Si el algoritmo depende de los datos sólo por productos internos, sustituirlos por un kernel $K(\mathbf{x}_i, \mathbf{x}_j)$ define implícitamente una base de dimensión posiblemente infinita.

$$K(\mathbf{x}, \mathbf{x}') = \langle \varphi(\mathbf{x}), \varphi(\mathbf{x}') \rangle_{\mathcal{H}}, \quad K \text{ simétrica y semidefinida positiva.}$$

Kernels y modelos aditivos

Si el algoritmo depende de los datos sólo por productos internos, sustituirlos por un kernel $K(\mathbf{x}_i, \mathbf{x}_j)$ define implícitamente una base de dimensión posiblemente infinita.

$$K(\mathbf{x}, \mathbf{x}') = \langle \varphi(\mathbf{x}), \varphi(\mathbf{x}') \rangle_{\mathcal{H}}, \quad K \text{ simétrica y semidefinida positiva.}$$

El teorema del representante garantiza que la solución del problema regularizado tiene la forma $\hat{f}(\mathbf{x}) = \sum_{i=1}^n \alpha_i K(\mathbf{x}_i, \mathbf{x})$, de modo que el problema es de dimensión n y no de la dimensión de $\mathcal{H}$.

Kernels y modelos aditivos

Si el algoritmo depende de los datos sólo por productos internos, sustituirlos por un kernel $K(\mathbf{x}_i, \mathbf{x}_j)$ define implícitamente una base de dimensión posiblemente infinita.

$$K(\mathbf{x}, \mathbf{x}') = \langle \varphi(\mathbf{x}), \varphi(\mathbf{x}') \rangle_{\mathcal{H}}, \quad K \text{ simétrica y semidefinida positiva.}$$

El teorema del representante garantiza que la solución del problema regularizado tiene la forma $\hat{f}(\mathbf{x}) = \sum_{i=1}^n \alpha_i K(\mathbf{x}_i, \mathbf{x})$, de modo que el problema es de dimensión n y no de la dimensión de $\mathcal{H}$.

Los **modelos aditivos generalizados** ofrecen la alternativa interpretable:

$$g(\mathbb{E}[Y \mid \mathbf{x}]) = \beta_0 + \sum_{j=1}^p f_j(x_j),$$

con cada f_j estimada por splines penalizados. Se recupera el efecto de cada variable por separado y se pierden las interacciones no declaradas.

Errores frecuentes

Error	Síntoma	Corrección
Escalar antes de particionar	Error de validación optimista	Todo dentro del Pipeline
Imputar con la media	Varianza y correlación reducidas	Imputación iterativa o múltiple
Codificar por objetivo sin pliegues	Desempeño no reproducible	Estimar dentro del pliegue
Partición aleatoria en series	Error de validación optimista	Partición por bloques temporales
Balancear antes de particionar	Duplicados entre conjuntos	Remuestrear sólo el entrenamiento
PCA sin estandarizar	La variable de mayor escala domina	Estandarizar salvo unidades comunes
Elegir k mirando el desempeño final	Estimación sesgada	Validación cruzada anidada [†]
Interpretar t -SNE cuantitativamente	Conclusiones sobre distancias	Volver al espacio original

[†] un bucle interno de validación elige los hiperparámetros y uno externo estima el error, de modo que los datos que eligen no son los que evalúan.

Volviendo al caso inicial de la clase

El análisis previo al lanzamiento admite un diagnóstico en tres puntos, uno por cada bloque visto hoy.

1. **Visualización.** El gráfico pertinente incorporaba los veintitrés vuelos con la temperatura asignada al canal de posición, que es el de mayor precisión perceptual.
2. **Preprocesamiento.** El filtrado de filas es una operación de preparación de datos y determina qué puede observar el análisis. La exigencia de registrar cada decisión alcanza también a los filtros.
3. **Extrapolación.** La temperatura pronosticada quedaba fuera del rango de los datos disponibles, condición bajo la cual ningún modelo ajustado sobre ellos tiene soporte.

Volviendo al caso inicial de la clase

El análisis previo al lanzamiento admite un diagnóstico en tres puntos, uno por cada bloque visto hoy.

1. **Visualización.** El gráfico pertinente incorporaba los veintitrés vuelos con la temperatura asignada al canal de posición, que es el de mayor precisión perceptual.
2. **Preprocesamiento.** El filtrado de filas es una operación de preparación de datos y determina qué puede observar el análisis. La exigencia de registrar cada decisión alcanza también a los filtros.
3. **Extrapolación.** La temperatura pronosticada quedaba fuera del rango de los datos disponibles, condición bajo la cual ningún modelo ajustado sobre ellos tiene soporte.

Las dos reglas para recordar: La variable que porta la conclusión se asigna al canal perceptual más preciso, y todo paso que estima parámetros a partir de los datos pertenece al modelo y se ajusta únicamente en entrenamiento.

Referencias

- Wilkinson, L. (2005). *The Grammar of Graphics*, 2.^a ed. Springer.
- Cleveland, W. S., McGill, R. (1984). Graphical perception. *Journal of the American Statistical Association*, 79(387), 531–554.
- Inselberg, A. (1985). The plane with parallel coordinates. *The Visual Computer*, 1(2), 69–91.
- Cleveland, R. B. et al. (1990). STL: a seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1), 3–73.
- van der Maaten, L., Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9, 2579–2605.
- Wattenberg, M., Viégas, F., Johnson, I. (2016). How to use t-SNE effectively. *Distill*.
- McInnes, L., Healy, J., Melville, J. (2018). UMAP: uniform manifold approximation and projection. arXiv:1802.03426.
- Rubin, D. B. (1987). *Multiple Imputation for Nonresponse in Surveys*. Wiley.
- van Buuren, S., Groothuis-Oudshoorn, K. (2011). mice: multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3).

Referencias (continuación)

- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *JRSS B*, 58(1), 267–288.
- Meinshausen, N., Bühlmann, P. (2010). Stability selection. *JRSS B*, 72(4), 417–473.
- Eckart, C., Young, G. (1936). The approximation of one matrix by another of lower rank. *Psychometrika*, 1(3), 211–218.
- Horn, J. L. (1965). A rationale and test for the number of factors in factor analysis. *Psychometrika*, 30(2), 179–185.
- Johnson, W. B., Lindenstrauss, J. (1984). Extensions of Lipschitz mappings into a Hilbert space. *Contemporary Mathematics*, 26, 189–206.
- Beyer, K. et al. (1999). When is nearest neighbor meaningful? *ICDT*, 217–235.
- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*, 2.^a ed. Springer.
- Kaufman, S., Rosset, S., Perlich, C. (2012). Leakage in data mining. *ACM TKDD*, 6(4).