

Regresión y regularización I

Unidad 5. Generalización, descomposición
sesgo–varianza y validación cruzada

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos



Objetivos

- Formular la predicción como minimización del riesgo esperado y distinguirla de la min. del riesgo empírico.
- Derivar la descomposición del error de test en ruido, sesgo y varianza, y enunciar supuestos.
- Calcular en forma cerrada la varianza de una regresión lineal, dentro y fuera de la muestra, y leer en ella el precio de cada parámetro y el umbral de interpolación.
- Cuantificar optimismo del error de entrenamiento y relacionarlo con los criterios de verosim. penalizada.
- Estimar el error de generalización con datos apartados, validación cruzada y bootstrap, y elegir la capacidad de un modelo sin conocer la verdad.

Caso de ejemplo

Dos grupos ajustan un modelo lineal para predecir una variable clínica continua a partir de $n = 40$ pacientes. El primero usa las 30 variables disponibles. El segundo usa las tres que la literatura previa señala como relevantes.

Modelo	Variables	ECM de entrenamiento	R^2 de entrenamiento
A	30	0,16	0,96
B	3	0,98	0,73

El primer grupo concluye que su modelo explica el 96 por ciento de la variabilidad y lo propone para uso clínico. El segundo grupo reconoce que el suyo explica bastante menos.

Caso de ejemplo

Se dispone después de 4 000 pacientes nuevos del mismo proceso, no usados en el ajuste.

Modelo	Variables	ECM de entrenamiento	ECM en pacientes nuevos	Varianza del ruido
A	30	0,16	4,80	1
B	3	0,98	1,54	1

El modelo que explica más en entrenamiento se equivoca varias veces más en pacientes nuevos. El error de entrenamiento del modelo A está por debajo de la varianza del ruido, cosa que ningún modelo puede lograr sobre datos nuevos.

Preguntas: Qué cantidad hay que medir, por qué el modelo A la mide mal, y cómo se obtiene con 30 variables un modelo mejor que ambos.

La generalización

Del riesgo empírico al riesgo esperado

El aprendizaje supervisado busca minimizar el riesgo esperado,

$$R(f) = \mathbb{E}_P[L(Y, f(X))],$$

que no es calculable porque P es desconocida, y su sustituto observable, el riesgo empírico sobre la muestra $S = \{(x_i, y_i)\}_{i=1}^n$:

$$\hat{R}_S(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i)).$$

Para una f fija, $\hat{R}_S(f) \rightarrow R(f)$ por la ley de los grandes números. El estimador $\hat{f} = \arg \min_{f \in \mathcal{H}} \hat{R}_S(f)$ se elige mirando S , y en él el riesgo empírico es optimista.

La cantidad que interesa es $R(\hat{f})$. La tabla del caso reporta $\hat{R}_S(\hat{f})$ para dos clases $\mathcal{H}$ distintas, y la columna de pacientes nuevos es una estimación de $R(\hat{f})$ con cuatro mil observaciones frescas.

La pérdida cuadrática y el riesgo de Bayes

Con pérdida cuadrática, el riesgo se descompone punto a punto. Sea $\mu[x] = \mathbb{E}[Y \mid X = x]$ la media condicional y $\sigma^2[x] = \text{Var}(Y \mid X = x)$. Para cualquier f :

$$\mathbb{E}[(Y - f(X))^2 \mid X = x] = (f(x) - \mu[x])^2 + \sigma^2[x].$$

El primer sumando es no negativo y se anula sólo si $f(x) = \mu[x]$. El riesgo de Bayes es:

$$R^* = R(\mu) = \mathbb{E}[\sigma^2[X]],$$

que con ruido homocedástico vale σ^2 .

Ningún modelo, por flexible que sea, tiene riesgo esperado menor que σ^2 . Un error de entrenamiento por debajo de σ^2 , como el del modelo A, no es evidencia de calidad sino de que el modelo ajustó ruido.

Error de aproximación y error de estimación

El exceso de riesgo de $\hat{f}$ sobre el riesgo de Bayes se separa en dos partes,


$$R(\hat{f}) - R^* = \underbrace{(R(\hat{f}) - R(f_{\mathcal{H}}))}_{\text{error de estimación}} + \underbrace{(R(f_{\mathcal{H}}) - R^*)}_{\text{error de aproximación}}, \quad f_{\mathcal{H}} = \arg \min_{f \in \mathcal{H}} R(f),$$

y la primera se acota en el peor caso por $\sqrt{d_{VC}/n}$, salvo constantes.

	Teoría general	Regresión lineal
Error de aproximación	Existe, no se calcula	Sesgo al cuadrado, en forma cerrada
Error de estimación	Cota uniforme $\sqrt{d_{VC}/n}$	Varianza exacta, $\sigma^2(p+1)/n$ en la muestra
Garantía	Peor caso, con probabilidad $1 - \delta$	Caso promedio, en esperanza
Ritmo en n	$n^{-1/2}$	n^{-1}

Aprender exige n grande frente a la capacidad, y la capacidad se paga en error de estimación.

Datos con verdad conocida




Los datos se generan mediante el modelo $y = \mu[x] + \varepsilon$ con $\varepsilon \sim N(0, \sigma^2)$ y $\sigma = 0,15$.

Conocer μ permite medir por separado cada componente del error (imposible sobre datos reales).

Los modelos candidatos son polinomios de grado d , es decir, regresiones lineales sobre la base $z[x] = (1, x, \dots, x^d)$.


Subajuste y sobreajuste



El grado 1 no puede representar la función, ni con los mejores parámetros posibles. El grado 4 recupera la estructura. El grado 14 tiene 15 parámetros para 15 observaciones, pasa por todas y oscila entre ellas. Su error de entrenamiento es cero, y es el peor de los tres modelos.

El error de entrenamiento no distingue el segundo panel del tercero, y de hecho prefiere el tercero. Hace falta otra medida.

Error de entrenamiento y error de test



Promedio sobre 300 muestras de entrenamiento de tamaño 15, con el error de test medido sobre 200 observaciones nuevas. El error de entrenamiento decrece con la capacidad hasta cero. El de test baja, alcanza un mínimo y vuelve a subir, y en ningún grado baja de σ^2 .

La distancia entre las curvas es la brecha de generalización.

La descomposición sesgo–varianza

(Prince 2023, sección 8.2)

Notación

Objeto	Notación
Media condicional y ruido	$\mu[x] = \mathbb{E}_y[y[x]], \quad \sigma^2 = \mathbb{E}_y[(\mu[x] - y[x])^2]$
Modelo con parámetros	$f[x, \beta] = \beta^\top z[x]$
Conjunto de entrenamiento	$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$
Parámetros estimados	$\hat{\beta}[\mathcal{D}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$
Modelo promedio	$f_\mu[x] = \mathbb{E}_{\mathcal{D}}[f[x, \hat{\beta}[\mathcal{D}]]]$
Número de parámetros	$p + 1$

La notación $y[x]$ señala que se considera la respuesta en una posición x dada, donde es una variable aleatoria con media $\mu[x]$.

Hay dos fuentes de aleatoriedad, el ruido de la observación de test, sobre el que promedia $\mathbb{E}_y$, y el conjunto de entrenamiento, sobre el que promedia $\mathbb{E}_{\mathcal{D}}$.

Formulación del error de test

En un punto x , la pérdida cuadrática entre la predicción y la observación es:

$$\begin{aligned} L[x] &= (f[x, \beta] - y[x])^2 \\ &= ((f[x, \beta] - \mu[x]) + (\mu[x] - y[x]))^2 \\ &= (f[x, \beta] - \mu[x])^2 + 2(f[x, \beta] - \mu[x])(\mu[x] - y[x]) + (\mu[x] - y[x])^2. \end{aligned}$$

En la segunda línea se sumó y restó la media verdadera $\mu[x]$, y en la tercera se expandió el cuadrado.

No se asume modelo lineal, ni ruido gaussiano.

Esperanza sobre el ruido de test

La observación $y[x]$ es aleatoria, de modo que la pérdida lo es. Su esperanza sobre el ruido, con el modelo fijo, es:

$$\begin{aligned}\mathbb{E}_y[L[x]] &= (f[x, \beta] - \mu[x])^2 + 2(f[x, \beta] - \mu[x])(\mu[x] - \mathbb{E}_y[y[x]]) + \mathbb{E}_y[(\mu[x] - y[x])^2] \\ &= (f[x, \beta] - \mu[x])^2 + \sigma^2.\end{aligned}$$

El término cruzado se anula porque el ruido tiene media cero. El error esperado en un punto es la distancia al cuadrado entre el modelo y la verdad, más un piso σ^2 que no depende del modelo.

El primer sumando todavía depende de qué muestra se usó para ajustar, a través de β . Falta promediar sobre ella.

Los parámetros dependen de la muestra

Los parámetros se estiman a partir de $\mathcal{D}$, luego son un vector aleatorio cuya distribución la induce el proceso que generó la muestra. En regresión lineal esa dependencia es:

$$\hat{\beta}[\mathcal{D}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}, \quad \mathbf{y} = \boldsymbol{\mu} + \boldsymbol{\varepsilon},$$

y la aleatoriedad de $\boldsymbol{\varepsilon}$ pasa a $\hat{\beta}$ filtrada por $(\mathbf{X}^\top \mathbf{X})^{-1}$.

Otra muestra habría dado otros parámetros y otra función ajustada.

El modelo promedio sobre todas las muestras posibles es:

$$f_\mu[x] = \mathbb{E}_{\mathcal{D}} [f[x, \hat{\beta}[\mathcal{D}]]].$$

Sobre el término $(f[x, \hat{\beta}[\mathcal{D}]] - \mu[x])^2$ se repite la jugada anterior, ahora sumando y restando $f_\mu[x]$.

Esperanza sobre el conjunto de entrenamiento

$$\begin{aligned}(\mathbf{f}[x, \hat{\beta}[\mathcal{D}]] - \mu[x])^2 &= \left((\mathbf{f}[x, \hat{\beta}[\mathcal{D}]] - \mathbf{f}_\mu[x]) + (\mathbf{f}_\mu[x] - \mu[x]) \right)^2 \\&= (\mathbf{f}[x, \hat{\beta}[\mathcal{D}]] - \mathbf{f}_\mu[x])^2 + 2(\mathbf{f}[x, \hat{\beta}[\mathcal{D}]] - \mathbf{f}_\mu[x])(\mathbf{f}_\mu[x] - \mu[x]) \\&\quad + (\mathbf{f}_\mu[x] - \mu[x])^2.\end{aligned}$$

Al tomar $\mathbb{E}_{\mathcal{D}}$ lo único aleatorio es $\mathbf{f}[x, \hat{\beta}[\mathcal{D}]]$, de modo que el factor $\mathbf{f}_\mu[x] - \mu[x]$ sale de la esperanza y el término cruzado se anula por la definición de $\mathbf{f}_\mu$:

$$2(\mathbf{f}_\mu[x] - \mu[x]) \mathbb{E}_{\mathcal{D}} [\mathbf{f}[x, \hat{\beta}[\mathcal{D}]] - \mathbf{f}_\mu[x]] = 2(\mathbf{f}_\mu[x] - \mu[x])(\mathbf{f}_\mu[x] - \mathbf{f}_\mu[x]) = 0.$$

El último término no depende de $\mathcal{D}$, luego:

$$\mathbb{E}_{\mathcal{D}} \left[(\mathbf{f}[x, \hat{\beta}[\mathcal{D}]] - \mu[x])^2 \right] = \mathbb{E}_{\mathcal{D}} \left[(\mathbf{f}[x, \hat{\beta}[\mathcal{D}]] - \mathbf{f}_\mu[x])^2 \right] + (\mathbf{f}_\mu[x] - \mu[x])^2.$$

Descomposición sesgo–varianza

Combinando las dos esperanzas:


Descomposición del error de test esperado

$$\mathbb{E}_{\mathcal{D}} \left[\mathbb{E}_y [L[x]] \right] = \underbrace{\mathbb{E}_{\mathcal{D}} \left[\left(f[x, \hat{\beta}[\mathcal{D}]] - f_{\mu}[x] \right)^2 \right]}_{\text{varianza}} + \underbrace{\left(f_{\mu}[x] - \mu[x] \right)^2}_{\text{sesgo}^2} + \underbrace{\sigma^2}_{\text{ruido}}.$$

Término		Reducible?	
Varianza	Dispersión del ajuste entre muestras	Sí	Más datos, menos capacidad, regularización
Sesgo ²	Desvío sistemático del ajuste promedio	Sí	Más capacidad, mejor base
Ruido	Aleatoriedad del mapeo entrada–salida	No	

Las palancas que reducen un término reducible tienden a aumentar el otro (compromiso sesgo–varianza).

Las tres fuentes de error



Izquierda, aunque el modelo fuera exactamente μ , los datos nuevos caen en la banda y no sobre la curva.

Centro, el mejor polinomio de grado 2 que existe, ajustado a la verdad, deja la brecha sombreada.

Derecha, 150 ajustes de grado 6 a 150 muestras de 15 puntos, con la banda de dos desviaciones de esos ajustes y uno de ellos en azul.

La regresión lineal permite calcular el sesgo

Condicionando en las entradas de entrenamiento, con $y = \boldsymbol{\mu} + \boldsymbol{\varepsilon}$ y $\mathbb{E}[\boldsymbol{\varepsilon}] = 0$,

$$\mathbb{E}_{\mathcal{D}}[\hat{\boldsymbol{\beta}}] = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\mu}, \quad f_{\boldsymbol{\mu}}[x] = z[x]^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\mu}.$$

El modelo promedio es la proyección de la verdad sobre el espacio generado por la base, evaluada en x (panel central de la figura anterior).

Si la verdad pertenece al espacio del modelo, es decir, si $\boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta}^*$ para algún $\boldsymbol{\beta}^*$, entonces $\mathbb{E}_{\mathcal{D}}[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta}^*$ y el sesgo es cero en todo x . La condición es que el modelo esté bien especificado.

El sesgo de un modelo de grado d no depende de n . Con datos infinitos, el grado 2 del panel central sigue equivocándose.

La regresión lineal permite calcular la varianza

Con $\text{Cov}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}$, se obtiene $\text{Cov}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$, luego:

$$\text{Var} (f[x, \hat{\boldsymbol{\beta}}]) = \sigma^2 \mathbf{z}[x]^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{z}[x].$$

Promediada sobre las entradas de entrenamiento aparece la traza de la matriz sombrero $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$, que es una proyección de rango $p + 1$:

$$\frac{1}{n} \sum_{i=1}^n \text{Var} (f[x_i, \hat{\boldsymbol{\beta}}]) = \frac{\sigma^2}{n} \text{tr}(\mathbf{H}) = \sigma^2 \frac{p + 1}{n}.$$

La varianza crece linealmente con el número de parámetros y decrece como $1/n$ con los datos. Cada parámetro adicional cuesta exactamente σ^2/n de varianza promedio, aporte información o no.

El promedio no depende de la base ni del condicionamiento. El condicionamiento decide dónde se concentra la varianza, a través de $\mathbf{z}[x]^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{z}[x]$, que entre los puntos de entrenamiento puede ser enorme.

El optimismo del error de entrenamiento

El error de entrenamiento, $\text{err} = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2$, es optimista respecto del error en observaciones nuevas tomadas en las mismas entradas, $\text{Err}_{\text{in}} = \frac{1}{n} \sum_i \mathbb{E}_{y^{\text{nuevo}}} [(y_i^{\text{nuevo}} - \hat{y}_i)^2]$.

Para cualquier ajuste lineal $\hat{y} = Hy$, la diferencia esperada tiene forma cerrada,

$$\mathbb{E}[\text{Err}_{\text{in}}] - \mathbb{E}[\text{err}] = \frac{2}{n} \sum_{i=1}^n \text{Cov}(\hat{y}_i, y_i) = \frac{2\sigma^2}{n} \text{tr}(H) = 2\sigma^2 \frac{p+1}{n}.$$

El error de entrenamiento subestima el error verdadero en exactamente dos veces la varianza promedio. Corregirlo da el C_p de Mallows, $\text{err} + 2\hat{\sigma}^2(p+1)/n$, que bajo ruido gaussiano coincide con el AIC (salvo constantes).

Para el modelo A, con $\hat{\sigma}^2 \approx 1$, la corrección vale $2 \times 31/40 \approx 1,55$, mayor que el propio error reportado.

La varianza fuera de la muestra


El promedio $\sigma^2(p+1)/n$ está tomado sobre las entradas de entrenamiento. Un paciente nuevo tiene entradas nuevas. Con p variables centradas de distribución gaussiana, tanto en entrenamiento como en test, y modelo bien especificado, el exceso de riesgo esperado fuera de la muestra es:

$$\mathbb{E}[R(\hat{\beta})] - \sigma^2 = \sigma^2 \mathbb{E}[x^\top (X^\top X)^{-1} x] = \sigma^2 \frac{p}{n - p - 1}, \quad n > p + 1.$$

Observaciones por parámetro	Dentro de la muestra, p/n	Fuera de la muestra, $p/(n - p - 1)$
$n = 10p$	$0,10 \sigma^2$	$\approx 0,11 \sigma^2$
$n = 2p$	$0,50 \sigma^2$	$\approx 1,0 \sigma^2$
$n = 40, p = 30$ (el ejemplo)	$0,75 \sigma^2$	$3,33 \sigma^2$
$n = p + 1$	$\approx \sigma^2$	∞


El error del modelo A en pacientes nuevos era predecible antes de verlos. La fórmula diverge cuando p se acerca a n , y ese polo es el umbral de interpolación.

Verificación numérica



Puntos, promedio sobre 300 réplicas con diseño gaussiano y modelo bien especificado. Curvas, las dos fórmulas. Dentro de la muestra la varianza crece linealmente. Fuera de ella se dispara al acercarse p a n . En $p = 30$ la fórmula predice un exceso de $3,33 \sigma^2$ sobre el ruido, que es el orden del error del modelo A.

Reducción de la varianza con más datos



El mismo modelo de grado 6, ajustado a 150 muestras de cada tamaño. La banda de dos desviaciones de los ajustes se encoge como predice $\sigma^2(p+1)/n$, y con $n = 100$ los ajustes son casi indistinguibles. La curva azul, el modelo promedio, no cambia con n , porque el sesgo no depende de los datos.

Más datos es la primera palanca contra la varianza y casi nunca hace daño. Su límite es que los datos cuestan.


Reducción del sesgo con más capacidad

El sesgo proviene de que la clase de modelos no contiene a μ . Se reduce ampliando la clase, y una base polinomial suficientemente rica aproxima cualquier función continua en un intervalo cerrado.

El precio es la varianza. Con datos fijos, la varianza promedio es $\sigma^2(p + 1)/n$, de modo que cada función base agregada cuesta σ^2/n , y fuera de la muestra bastante más al acercarse p a n .

Como una fuerza baja y la otra sube, la suma tiene un mínimo en una capacidad intermedia. Aumentar la capacidad sólo conviene mientras el sesgo eliminado supere la varianza añadida. Ése es el compromiso sesgo–varianza.

El compromiso sesgo–varianza



Cada término se calcula ajustando 400 muestras de tamaño 15 por grado y comparando con la μ conocida sobre una grilla. El sesgo cae con la capacidad y la varianza sube. Sobre las entradas de entrenamiento la varianza es exactamente $\sigma^2(p + 1)/n$, y sobre la grilla, entre los puntos, es mayor y crece más rápido. La suma tiene la forma de U del error de test, que deja de ser un misterio.

La figura sólo puede dibujarse porque se conoce μ y se pueden remuestrear conjuntos de entrenamiento. Sobre datos reales no se dispone de ninguna de las dos cosas.

Estimar el error de generalización

Estimación del error con datos apartados

Queda elegir la capacidad sin conocer μ , es decir, elegir entre los candidatos (por ahora los polinomios de cada grado). El sustituto práctico de remuestrear la realidad es reservar observaciones que el ajuste no vio.

Conjunto	Para qué	Cuántas veces se usa
Entrenamiento	Estimar los parámetros de cada candidato	Una vez por candidato
Validación	Comparar candidatos y elegir la capacidad o λ	Tantas como candidatos
Test	Estimar el error del modelo elegido	Una sola vez, al final

Si el test se usa para elegir, la estimación final hereda el optimismo de la selección, porque se eligió lo que casualmente funcionó allí. Elegir mirando los datos consume grados de libertad.

Con pocos datos, reservar una fracción fija desperdicia. La validación cruzada reutiliza cada observación para entrenar y para validar.


Validación cruzada de k pliegues (folds)

pliegue 1	valida	entrena	entrena	entrena	entrena
pliegue 2	entrena	valida	entrena	entrena	entrena
pliegue 3	entrena	entrena	valida	entrena	entrena
pliegue 4	entrena	entrena	entrena	valida	entrena
pliegue 5	entrena	entrena	entrena	entrena	valida

$$CV = \frac{1}{n} \sum_{i=1}^n \left(y_i - \hat{f}^{-\kappa(i)}[x_i] \right)^2, \quad \hat{f}^{-\kappa(i)} \text{ ajustado sin el pliegue } \kappa(i) \text{ que contiene a } i.$$

Cada observación valida exactamente una vez, contra un modelo ajustado con $n(k-1)/k$ datos. Con $k = n$ se obtiene dejar uno fuera (asintóticamente equivalente al AIC). Los valores usuales son $k = 5$ y $k = 10$.

Validación cruzada para elegir el grado



Cinco pliegues sobre $n = 30$, repetidos 25 veces. La curva reproduce la forma de U del error de test sin haber usado la verdad ni datos de test, y elige un grado razonable. A la derecha el error explota cuando el grado se acerca al tamaño de los pliegues de entrenamiento, que es el umbral de interpolación visto desde dentro de la muestra.

El grado es una perilla entera. La regularización va a dar una perilla continua sobre el mismo eje.

Tres estimadores del error de predicción

Estimador	Construcción	Sesgo	Costo
Datos apartados	Ajustar con una parte, evaluar en la otra	Pesimista, usa menos datos	Un ajuste
Validación cruzada	Rotar k pliegues, promediar	Levemente pesimista	k ajustes
Bootstrap	Ajustar en remuestras, evaluar en las no sorteadas	Pesimista, corregido por el 0,632	B ajustes
Corrección analítica	$\text{err} + 2\hat{\sigma}^2 \text{tr}(\mathbf{H})/n$	Insesgado con modelo correcto	Ninguno

Las tres primeras filas estiman el error sobre entradas nuevas y no requieren que el modelo sea correcto. La cuarta es la corrección por el optimismo, que con ruido gaussiano es el AIC.

Cuando el objetivo es predecir, las estimaciones por remuestreo son preferibles, porque no dependen de que la verosimilitud esté bien especificada. Cuando los ajustes son caros, la corrección analítica es la única viable.

La regla de un error estándar y la validación anidada

La curva de validación cruzada es plana cerca de su mínimo y cada punto lleva error de muestreo. Elegir el mínimo exacto es una decisión ruidosa.

La regla de un error estándar toma el modelo más simple cuyo error de validación esté a menos de un error estándar del mínimo. Se cede una diferencia estadísticamente indistinguible y se gana un modelo más estable.

Dos reglas:

- Todo preprocesamiento que estime algo, incluida la estandarización, se ajusta dentro del pliegue de entrenamiento. Hacerlo antes de partir filtra los datos de validación al ajuste.
- El error de validación cruzada en el λ elegido es optimista, porque λ se eligió mirándolo. Una estimación honesta del desempeño final exige un ciclo externo, que es la validación anidada.

Referencias

- Prince, S. J. D. (2023). *Understanding Deep Learning*, capítulos 8 y 9. MIT Press.
- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*, 2.^a ed., capítulos 2, 3 y 7. Springer.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*, capítulos 1 y 3. Springer.
- Wasserman, L. (2004). *All of Statistics*, capítulos 6, 8 y 13. Springer.
- Vapnik, V. N. (1998). *Statistical Learning Theory*. Wiley.