

Regresión y regularización II

Unidad 5. Gauss–Markov, regresión ridge,
regularizadores encubiertos y doble descenso

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos



Objetivos

- Justificar la regularización con Gauss–Markov y la descomposición sesgo–varianza. Calcular el sesgo y la varianza de ridge en cada dirección.
- Interpretar ridge como estimador de máximo a posteriori y calcular sus grados de libertad efectivos.
- Elegir el parámetro de penalización por validación cruzada y reconocer cuándo ridge no conviene.
- Reconocer la regularización implícita en la parada temprana, el ruido en las entradas y el promedio de modelos.
- Explicar el doble descenso y el efecto de la regularización sobre él.

El caso

Se quiere predecir una variable clínica continua a partir de 30 variables medidas en $n = 40$ pacientes. Los datos son simulados y la verdad es conocida.

- La respuesta depende sólo de cuatro de las 30 variables. Sus coeficientes son 1,2, $-0,9$, 0,7 y 0,4.
- El ruido tiene varianza $\sigma^2 = 1$.

Dos grupos ajustan un modelo lineal por mínimos cuadrados.

- El modelo A usa las 30 variables.
- El modelo B usa las tres variables que la literatura señala como relevantes. Son las de mayor efecto. La cuarta variable tiene un efecto pequeño y no está en esa lista.

Los resultados del caso

La tabla muestra el error cuadrático medio de cada modelo en los 40 pacientes de entrenamiento y en 4 000 pacientes nuevos.

Modelo	Variables	ECM de entrenamiento	ECM en pacientes nuevos	Varianza del ruido
A	30	0,16	4,80	1
B	3	0,98	1,54	1

El modelo A tiene el menor error de entrenamiento y el mayor error en pacientes nuevos. Cada variable inútil le suma varianza. El modelo B omite una variable verdadera y predice mejor. ¿Cómo se obtiene con las 30 variables un modelo mejor que A y B?

Regularización

Gauss–Markov y su límite

Teorema de Gauss–Markov



Si $y = X\beta + \epsilon$ con $\mathbb{E}[\epsilon] = 0$ y $\text{Cov}(\epsilon) = \sigma^2 I$, el estimador de mínimos cuadrados tiene la menor varianza entre todos los estimadores lineales e insesgados de β .

El teorema sólo compara estimadores insesgados. No dice nada sobre los estimadores sesgados. El error es el sesgo al cuadrado más la varianza. Si un sesgo pequeño reduce mucho la varianza, el error total baja.

Con muchas observaciones por parámetro y regresores bien condicionados, la varianza ya es pequeña. En ese caso, regularizar sólo añade sesgo.

Los métodos de esta sección son estimadores sesgados. Tienen menor error cuadrático medio que mínimos cuadrados cuando faltan observaciones o los regresores están mal condicionados.

Límites de mínimos cuadrados



Los regresores correlacionados, las bases flexibles y p cercano a n causan el mismo problema. Los datos casi no restringen alguna dirección de los parámetros. La matriz $X^T X$ queda casi singular y el ruido fija el ajuste en esa dirección. En la figura, los datos fijan $\beta_1 + \beta_2$ y dejan libre $\beta_1 - \beta_2$. La nube gris está centrada en el valor verdadero, así que el problema es de varianza.

Regularización como problema de optimización

El aprendizaje se plantea como $\hat{f} = \arg \min_f \hat{R}_S(f) + \lambda \Omega(f)$. En regresión lineal,

$$\hat{\beta}_\lambda = \arg \min_{\beta} \underbrace{\|y - X\beta\|^2}_{\text{ajustar los datos}} + \lambda \underbrace{\Omega(\beta)}_{\text{preferencia}}, \quad \lambda \geq 0.$$

En las direcciones que los datos apenas restringen, el primer término no distingue entre soluciones. El segundo término elige según una preferencia explícita y no según el ruido.

- Con $\lambda = 0$ se recupera mínimos cuadrados.
- Con $\lambda \rightarrow \infty$ domina la preferencia y el ajuste ignora los datos.
- Entre ambos, λ cambia la capacidad de forma continua. El grado de un polinomio la cambia a saltos.

Desde aquí, las columnas de X están estandarizadas, la respuesta está centrada y el intercepto no se penaliza.

Regresión ridge

Con $\Omega(\beta) = \|\beta\|_2^2 = \sum_j \beta_j^2$, el objetivo es cuadrático y el mínimo tiene forma cerrada,

$$\hat{\beta}_\lambda = (X^T X + \lambda I)^{-1} X^T y.$$

Los valores propios de $X^T X$ son no negativos. Sumar λI los aumenta todos en λ . Para $\lambda > 0$ la matriz siempre es invertible, incluso con $p > n$. El problema es estrictamente convexo y tiene solución única.

Ridge resuelve a la vez la colinealidad, las bases redundantes y el caso $p \geq n$. La matriz casi singular recibe λ en su diagonal y deja de serlo.

El método se llama regresión ridge en estadística, regularización de Tikhonov en problemas inversos y decaimiento de pesos en redes neuronales.

Ridge dirección por dirección

Con la descomposición en valores singulares $X = USV^T$, $s_1 \geq s_2 \geq \dots \geq s_p \geq 0$,

$$\hat{\beta}_{\text{MCO}} = \sum_{j=1}^p \frac{1}{s_j} v_j (u_j^T y), \quad \hat{\beta}_{\lambda} = \sum_{j=1}^p \frac{s_j}{s_j^2 + \lambda} v_j (u_j^T y).$$

Las v_j son direcciones ortogonales del espacio de parámetros. El valor s_j mide cuánto cambian las predicciones al mover β en la dirección v_j . Así mide cuánto informan los datos sobre esa combinación de coeficientes.

Mínimos cuadrados multiplica cada dirección por $1/s_j$. Si s_j es pequeño, ese factor amplifica mucho el ruido. Ridge multiplica además por el factor $c_j(\lambda) = s_j^2 / (s_j^2 + \lambda) \in (0, 1]$, cercano a uno donde $s_j^2 \gg \lambda$ y cercano a cero donde $s_j^2 \ll \lambda$.

Ridge encoge más las direcciones donde los datos informan menos. Las v_j son las componentes principales de X . Ridge es una versión continua de la regresión sobre las primeras k componentes.

Sesgo y varianza de ridge en forma cerrada

En las coordenadas $\theta_j = \mathbf{v}_j^\top \boldsymbol{\beta}$, el estimador $\hat{\theta}_j^{\text{MCO}} = \mathbf{u}_j^\top \mathbf{y} / s_j$ es insesgado y tiene varianza σ^2 / s_j^2 . Ridge da $\hat{\theta}_{j,\lambda} = c_j(\lambda) \hat{\theta}_j^{\text{MCO}}$, con sesgo $-\lambda \theta_j / (s_j^2 + \lambda)$ y varianza $\sigma^2 s_j^2 / (s_j^2 + \lambda)^2$. Sumando sobre las coordenadas,


$$\text{ECM}(\lambda) = \|\mathbb{E}[\hat{\boldsymbol{\beta}}_\lambda] - \boldsymbol{\beta}\|^2 + \text{tr Cov}(\hat{\boldsymbol{\beta}}_\lambda) = \sum_{j=1}^p \frac{\lambda^2 \theta_j^2 + \sigma^2 s_j^2}{(s_j^2 + \lambda)^2}.$$

Teorema de Hoerl–Kennard (1970)

$$\left. \frac{d}{d\lambda} \text{ECM}(\lambda) \right|_{\lambda=0} = -2\sigma^2 \sum_{j=1}^p \frac{1}{s_j^4} < 0. \text{ Para cualquier matriz de diseño existe un } \lambda > 0 \text{ con } \text{ECM}(\hat{\boldsymbol{\beta}}_\lambda) < \text{ECM}(\hat{\boldsymbol{\beta}}_{\text{MCO}}).$$


Cerca de $\lambda = 0$ la varianza cae rápido, sobre todo en las direcciones peor determinadas. El sesgo al cuadrado crece sólo a segundo orden.

Curva del error en λ para el caso



Se usa la matriz de diseño del caso, $n = 40$ y $p = 30$, con los coeficientes verdaderos. Las curvas salen de las fórmulas cerradas. Los puntos son simulaciones con ruido nuevo. El sesgo crece con λ y la varianza cae. La suma tiene un mínimo lejos de cero. Ahí el error es una fracción del de mínimos cuadrados.



Ajustes ridge al crecer λ



Se simulan 15 observaciones de $y = \mu(x) + \varepsilon$, con $\mu(x) = \sin 2\pi x + 0,25 \cos 6\pi x$ y ruido de desviación estándar 0,15. Se ajusta un polinomio de grado 14, que con $\lambda = 0$ interpola los datos. Con λ pequeño sigue sobreajustando. Con λ intermedio la curva es suave y cercana a la verdadera. Con λ grande la curva queda demasiado simple.

Con un solo modelo, λ cubre de forma continua desde varianza pura hasta sesgo puro.

Grados de libertad efectivos



$$df(\lambda) = \text{tr}(H_\lambda) = \text{tr} \left[X(X^\top X + \lambda I)^{-1} X^\top \right] = \sum_{j=1}^p \frac{s_j^2}{s_j^2 + \lambda}.$$

Ridge con 30 variables no usa 30 parámetros. Usa $df(\lambda)$, un número fraccionario que decrece de p a cero. El optimismo del error de entrenamiento vale $2\sigma^2 df(\lambda)/n$, y $df(\lambda)$ ocupa el lugar de k en el AIC.

Ridge como estimador de máximo a posteriori

Con ruido gaussiano, mínimos cuadrados es máxima verosimilitud. Se agrega una a priori normal. Con

$$y \mid \boldsymbol{\beta} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I}), \quad \boldsymbol{\beta} \sim N(0, \tau^2\mathbf{I}),$$


la moda de la distribución a posteriori maximiza $\log p(y \mid \boldsymbol{\beta}) + \log p(\boldsymbol{\beta})$, es decir, minimiza

$$\frac{1}{2\sigma^2}\|y - \mathbf{X}\boldsymbol{\beta}\|^2 + \frac{1}{2\tau^2}\|\boldsymbol{\beta}\|^2 \quad \Longleftrightarrow \quad \hat{\boldsymbol{\beta}}_\lambda \text{ con } \lambda = \frac{\sigma^2}{\tau^2}.$$

El parámetro de penalización es el cociente entre la varianza del ruido y la varianza a priori. Con más ruido, ridge regulariza más. Con una a priori muy ancha, ridge vuelve a mínimos cuadrados.

Otra forma de la a priori da otra penalización. Con $\beta_j \sim \text{Laplace}(0, b)$ el término es $\|\boldsymbol{\beta}\|_1/b$, la penalización del lasso.

Elección de λ por validación cruzada en el caso



Se usan cinco pliegues sobre los 40 pacientes. A la izquierda domina la varianza y el error se acerca al de mínimos cuadrados. A la derecha domina el sesgo. La regla de un error estándar elige el λ mayor cuyo error queda dentro de la banda del mínimo. Ese es el modelo más regularizado que los datos no distinguen del mejor. La curva no usa a los pacientes nuevos.

Regularizadores encubiertos

Descenso de gradiente sobre mínimos cuadrados

La regresión lineal también se puede ajustar por descenso de gradiente, partiendo de cero,

$$\beta_{t+1} = \beta_t - \alpha X^\top (X\beta_t - y), \quad \beta_0 = 0.$$


En las coordenadas de la descomposición en valores singulares, cada dirección avanza por separado,

$$v_j^\top \beta_t = \frac{1 - (1 - \alpha s_j^2)^t}{s_j} (u_j^\top y), \quad 0 < \alpha < 2/s_1^2.$$

Las direcciones con s_j grande convergen rápido y se aprenden primero. Las de s_j pequeño tienen mucho ruido, convergen despacio y se aprenden al final. Antes de converger, el ajuste favorece las direcciones con s_j grande.

Desde cero, la iteración nunca sale del espacio fila de X . Con $p > n$ converge a la solución interpolante de norma mínima, que es única.

Parada temprana



Cada método conserva la dirección j con el factor

$$\text{descenso de gradiente en el paso } t : 1 - (1 - \alpha s_j^2)^t, \quad \text{ridge} : \frac{s_j^2}{s_j^2 + \lambda},$$

Ambos factores valen cerca de uno donde s_j es grande y cerca de cero donde es pequeño. Detener en la iteración t equivale a ridge con $\lambda \approx 1/(\alpha t)$.

El número de iteraciones es un hiperparámetro de regularización. Convergencia del todo equivale a $\lambda \rightarrow 0$, es decir, a mínimos cuadrados con toda su varianza. El mejor modelo aparece a mitad del entrenamiento.

Ruido en las entradas

Se toma la regresión simple $f[x, \beta] = \beta_0 + \beta_1 x$. En cada iteración, se suma a cada entrada un ruido $\varepsilon \sim N(0, \sigma_x^2)$. Con el residuo $r_i = \beta_0 + \beta_1 x_i - y_i$,


$$\mathbb{E}_\varepsilon[(r_i + \beta_1 \varepsilon)^2] = r_i^2 + 2\beta_1 r_i \underbrace{\mathbb{E}_\varepsilon[\varepsilon]}_0 + \beta_1^2 \underbrace{\mathbb{E}_\varepsilon[\varepsilon^2]}_{\sigma_x^2} = r_i^2 + \sigma_x^2 \beta_1^2.$$

La pérdida esperada es la pérdida original más $\sigma_x^2 \sum_{j \geq 1} \beta_j^2$. Por lo tanto, agregar ruido a las entradas es exactamente regularización ridge con $\lambda = \sigma_x^2$.

Un modelo que tolera cambios pequeños en la entrada necesita pendientes pequeñas. Ridge penaliza justamente las pendientes grandes.

Con bases no lineales, el ruido pasa por las funciones base y la equivalencia deja de ser exacta. El efecto cualitativo se mantiene. La aumentación de datos en aprendizaje profundo usa esta misma idea.

Promediar modelos



Se remuestrea el entrenamiento con reemplazo, se ajusta cada réplica y se promedian las predicciones. El procedimiento se llama bagging. Cada ajuste oscila de forma distinta y el promedio es más suave. Promediar reduce la varianza y no cambia el sesgo.

Si los M errores fueran independientes, la varianza se dividiría por M . Los errores están correlacionados porque comparten datos. Por eso la reducción real es menor, aunque existe. Los bosques aleatorios y los ensambles usan este principio.

Formas de regularización

Mecanismo	Equivale a	Por qué
Penalización ℓ_2	Máximo a posteriori con a priori gaussiana	Encoge las direcciones con poca evidencia
Penalización ℓ_1	Máximo a posteriori con a priori de Laplace	Umbral suave, anula coeficientes
Parar temprano en t	Ridge con $\lambda \approx 1/(\alpha t)$	Las direcciones lentas no se aprenden
Ruido en las entradas	Ridge con $\lambda = \sigma_x^2$, exactamente	Penaliza las pendientes
Promediar remuestras	Reducción directa de la varianza	Las oscilaciones se cancelan
Descenso de gradiente desde cero	Solución de norma mínima	Nunca sale del espacio fila de X

La regularización expresa una preferencia entre soluciones con pérdida similar. Esa preferencia puede estar en el costo, en la a priori, en el número de iteraciones, en los datos o en el optimizador.

En aprendizaje profundo, estas filas se llaman decaimiento de pesos, parada temprana, aumentación, ensambles y regularización implícita. En redes profundas se apoyan en evidencia empírica. En regresión lineal se demuestran en una o dos líneas.

Interpolación y doble descenso

Más parámetros que datos

Con $p > n$ el sistema $X\beta = y$ tiene infinitas soluciones exactas. Todas tienen error de entrenamiento cero. Los datos no prefieren ninguna, así que la elección necesita otro criterio.


La elección más simple es la de norma mínima,

$$\hat{\beta} = \arg \min_{\beta} \|\beta\|^2 \quad \text{sujeto a} \quad X\beta = y, \quad \hat{\beta} = X^+ y = \lim_{\lambda \rightarrow 0^+} (X^T X + \lambda I)^{-1} X^T y,$$

que entrega la pseudoinversa y encuentra el descenso de gradiente desde cero. Es también el límite de ridge cuando la penalización desaparece.

Hay una paradoja abierta. Una red con dimensión de Vapnik y Chervonenkis enorme generaliza bien. El doble descenso estudia esta paradoja en regresión lineal, donde todo se puede calcular.

Doble descenso



Regresión lineal sobre p funciones base aleatorias $z_j[x] = \cos(\omega_j x + b_j)$, con $n = 20$ y la solución de norma mínima para $p > n$. A la izquierda de $p = n$ está la U clásica. En $p = n$ hay un pico. A la derecha el error vuelve a bajar y termina bajo el mínimo clásico. Belkin y colaboradores llamaron doble descenso a esta curva en 2019.

Origen del pico y del segundo descenso


El pico corresponde al polo de la varianza fuera de la muestra de mínimos cuadrados, $\sigma^2 p / (n - p - 1)$. En $p = n$ la matriz X es cuadrada y casi singular. La única solución interpolante tiene norma enorme y oscila entre los datos.

Para $p > n$ hay más funciones base que restricciones. La solución de norma mínima reparte el ajuste entre ellas con coeficientes cada vez más pequeños. La capacidad nominal sube, pero la complejidad efectiva del estimador baja.

Elegir la norma mínima es la última fila de la tabla de regularización implícita. Por eso el caso sobreparametrizado no contradice la teoría clásica. El optimizador regulariza el ajuste sin una penalización explícita.

Con diseño gaussiano isotrópico y $\gamma = p/n$, la teoría asintótica da un riesgo de $\sigma^2 \gamma / (1 - \gamma)$ para $\gamma < 1$ y de $\|\beta\|^2 (1 - 1/\gamma) + \sigma^2 / (\gamma - 1)$ para $\gamma > 1$. Ambos riesgos tienen un polo en $\gamma = 1$.

Doble descenso con ridge óptimo



Es el mismo experimento con ridge, con el λ óptimo para cada tamaño de modelo. El pico desaparece. La curva regularizada es monótona y al menos igual de buena en todo el rango. El doble descenso aparece sólo al interpolar sin regularizar. Nakkiran y colaboradores lo establecieron en 2020.

La sección partió preguntando cuándo la regresión lineal necesita regularización. Incluso el doble descenso, un fenómeno reciente, se corrige con ridge, un método de 1970.

Errores frecuentes

Error	Corrección
Reportar el error o el R^2 de entrenamiento como desempeño	Datos apartados o validación cruzada
Usar el conjunto de test para elegir el modelo o λ	Validación, y el test una sola vez al final
Estandarizar o seleccionar variables antes de partir los datos	Todo el preprocesamiento dentro del pliegue
Reportar el error de validación cruzada en el λ elegido	Validación anidada
Penalizar el intercepto o variables en escalas distintas	Centrar la respuesta y estandarizar las columnas
Interpretar coeficientes de variables correlacionadas como efectos	La descomposición mide predicción, no causalidad
Regularizar en el régimen sano	Gauss–Markov, sólo se añade sesgo
Creer que más datos corrigen el sesgo	Más datos reducen la varianza, el sesgo lo corrige la clase
Elegir el mínimo exacto de una curva de validación ruidosa	Regla de un error estándar

Cierre del caso

Modelo	Variables	ECM de entrenamiento	Predicción de la teoría	ECM, pacientes nuevos
A, mínimos cuadrados	30	0,16	$1 + 30/9 = 4,33$	4,80
B, mínimos cuadrados	3	0,98	$1 + 3/36 + 0,4^2 = 1,24$	1,54
Ridge, λ por validación cruzada	30	0,26	$\text{df}(\lambda) = 23,4$	2,04

Dentro de la muestra, el modelo A sumó σ^2/n de error por cada una de sus 26 variables inútiles. Fuera de la muestra, el exceso es $\sigma^2 p/(n - p - 1)$ y crece porque p está cerca de n . El modelo B tuvo un sesgo pequeño por la variable que omitió. Ridge con las 30 variables reduce el error de A a menos de la mitad, pero no alcanza al modelo B. El modelo verdadero tiene cuatro efectos entre treinta variables. La a priori gaussiana de ridge supone muchos coeficientes moderados y no se ajusta a este caso.

Ninguna conclusión sale del R^2 de entrenamiento. Todas salen de la descomposición del error y de estimar el error de generalización con los datos disponibles.

Referencias

- Prince, S. J. D. (2023). *Understanding Deep Learning*, capítulos 8 y 9. MIT Press.
- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*, 2.^a ed., capítulos 2, 3 y 7. Springer.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*, capítulos 1 y 3. Springer.
- Wasserman, L. (2004). *All of Statistics*, capítulos 6, 8 y 13. Springer.
- Hoerl, A. E., Kennard, R. W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.
- Efron, B. (1986). How biased is the apparent error rate of a prediction rule? *Journal of the American Statistical Association*, 81(394), 461–470.
- Efron, B., Tibshirani, R. (1997). Improvements on cross-validation: the .632+ bootstrap method. *Journal of the American Statistical Association*, 92(438), 548–560.
- Stone, M. (1977). An asymptotic equivalence of choice of model by cross-validation and Akaike's criterion. *Journal of the Royal Statistical Society B*, 39(1), 44–47.

Referencias (continuación)

- Bishop, C. M. (1995). Training with noise is equivalent to Tikhonov regularization. *Neural Computation*, 7(1), 108–116.
- Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*, sección 7.8. MIT Press.
- Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2), 123–140.
- Belkin, M., Hsu, D., Ma, S., Mandal, S. (2019). Reconciling modern machine-learning practice and the classical bias–variance trade-off. *PNAS*, 116(32), 15849–15854.
- Hastie, T., Montanari, A., Rosset, S., Tibshirani, R. J. (2022). Surprises in high-dimensional ridgeless least squares interpolation. *Annals of Statistics*, 50(2), 949–986.
- Bartlett, P. L., Long, P. M., Lugosi, G., Tsigler, A. (2020). Benign overfitting in linear regression. *PNAS*, 117(48), 30063–30070.
- Nakkiran, P., Venkat, P., Kakade, S., Ma, T. (2021). Optimal regularization can mitigate double descent. *ICLR 2021*.
- Vapnik, V. N. (1998). *Statistical Learning Theory*. Wiley.