

Regresión y regularización III

Unidad 5. El lasso, sus variantes y sus aplicaciones

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos



Objetivos

- Formular el lasso como la versión convexa de la selección del mejor subconjunto y resolverlo coordenada a coordenada.
- Calcular los grados de libertad del lasso y relacionarlos con el optimismo del error de entrenamiento.
- Enunciar el error del lasso con p variables, $s \log p/n$ en lugar de p/n , y la condición para que elija las variables correctas.
- Seleccionar variables con control de falsos positivos, y distinguir la selección de la inferencia.
- Elegir entre elastic net, lasso relajado, lasso adaptativo, group lasso y fused lasso según la estructura esperada de los coeficientes.
- Tratar variables categóricas sin que la selección dependa de la categoría de referencia.
- Reconstruir una señal o una imagen con menos proyecciones que incógnitas.
- Usar el lasso para estimar grafos de dependencia, causalidad de Granger, efectos de tratamiento y ecuaciones diferenciales, y saber qué no garantiza cada uso.

El caso

Se quiere predecir una variable clínica continua con $n = 40$ pacientes y 30 variables. Los datos son simulados y la verdad es conocida.

- La respuesta depende sólo de cuatro variables, con coeficientes 1,2, $-0,9$, 0,7 y 0,4. Las otras 26 tienen coeficiente cero.
- El ruido tiene varianza $\sigma^2 = 1$.

El caso

Se quiere predecir una variable clínica continua con $n = 40$ pacientes y 30 variables. Los datos son simulados y la verdad es conocida.

- La respuesta depende sólo de cuatro variables, con coeficientes 1,2, $-0,9$, 0,7 y 0,4. Las otras 26 tienen coeficiente cero.
- El ruido tiene varianza $\sigma^2 = 1$.

Se comparan tres modelos, cada uno evaluado con el error cuadrático medio (ECM) en 4 000 pacientes nuevos.

- **Modelo A.** Mínimos cuadrados con las 30 variables.
- **Modelo B.** Mínimos cuadrados con las tres variables que la literatura señala como relevantes. Son las de mayor efecto. La cuarta no está en la lista.
- **Ridge.** Las 30 variables, con la penalización elegida por validación cruzada.

Tres modelos en el caso

Modelo	Variables	ECM de entrenamiento	ECM, pacientes nuevos
A, mínimos cuadrados	30	0,16	4,80
B, las tres de la literatura	3	0,98	1,54
Ridge, λ por validación cruzada	30	0,26	2,04

Tres modelos en el caso

Modelo	Variables	ECM de entrenamiento	ECM, pacientes nuevos
A, mínimos cuadrados	30	0,16	4,80
B, las tres de la literatura	3	0,98	1,54
Ridge, λ por validación cruzada	30	0,26	2,04

Ridge usa las 30 variables con coeficientes moderados. El modelo verdadero usa 4 con coeficientes grandes y deja 26 en cero.

Tres modelos en el caso

Modelo	Variables	ECM de entrenamiento	ECM, pacientes nuevos
A, mínimos cuadrados	30	0,16	4,80
B, las tres de la literatura	3	0,98	1,54
Ridge, λ por validación cruzada	30	0,26	2,04

Ridge usa las 30 variables con coeficientes moderados. El modelo verdadero usa 4 con coeficientes grandes y deja 26 en cero.

Si un oráculo indica las cuatro, el error esperado de mínimos cuadrados sobre ellas es

$$\sigma^2 \left(1 + \frac{s}{n - s - 1} \right) = 1 + \frac{4}{35} \approx 1,11.$$

Tres modelos en el caso

Modelo	Variables	ECM de entrenamiento	ECM, pacientes nuevos
A, mínimos cuadrados	30	0,16	4,80
B, las tres de la literatura	3	0,98	1,54
Ridge, λ por validación cruzada	30	0,26	2,04

Ridge usa las 30 variables con coeficientes moderados. El modelo verdadero usa 4 con coeficientes grandes y deja 26 en cero.

Si un oráculo indica las cuatro, el error esperado de mínimos cuadrados sobre ellas es

$$\sigma^2 \left(1 + \frac{s}{n - s - 1} \right) = 1 + \frac{4}{35} \approx 1,11.$$

¿Cuánto de esa ventaja se recupera sin el oráculo?

La hipótesis de dispersión

Un vector $\beta \in \mathbb{R}^p$ es s -disperso si tiene a lo más s componentes no nulas, con $s \ll p$.

La hipótesis de dispersión

Un vector $\beta \in \mathbb{R}^p$ es s -disperso si tiene a lo más s componentes no nulas, con $s \ll p$.

Ridge es el estimador de máximo a posteriori con a priori gaussiana. Esa a priori espera muchos coeficientes moderados y pone poca masa cerca de cero. La a priori de Laplace, $p(\beta_j) \propto e^{-|\beta_j|/b}$, tiene un pico en cero y colas pesadas. Su estimador de máximo a posteriori es el lasso.

La hipótesis de dispersión

Un vector $\beta \in \mathbb{R}^p$ es s -disperso si tiene a lo más s componentes no nulas, con $s \ll p$.

Ridge es el estimador de máximo a posteriori con a priori gaussiana. Esa a priori espera muchos coeficientes moderados y pone poca masa cerca de cero. La a priori de Laplace, $p(\beta_j) \propto e^{-|\beta_j|/b}$, tiene un pico en cero y colas pesadas. Su estimador de máximo a posteriori es el lasso.

Estructura esperada	Penalización	Métodos
Pocos coeficientes no nulos	$\ \beta\ _1$	Lasso, relajado, adaptativo
Grupos correlacionados que entran juntos	$\ \beta\ _1 + \ \beta\ _2^2$	Elastic net
Pocas variables, cada una con varias columnas	$\sum_g \ \beta_g\ _2$	Group lasso, variables categóricas
Pocos cambios entre coeficientes vecinos	$\sum_i \beta_{i+1} - \beta_i $	Fused lasso, tomografía

La hipótesis de dispersión

Un vector $\beta \in \mathbb{R}^p$ es s -disperso si tiene a lo más s componentes no nulas, con $s \ll p$.

Ridge es el estimador de máximo a posteriori con a priori gaussiana. Esa a priori espera muchos coeficientes moderados y pone poca masa cerca de cero. La a priori de Laplace, $p(\beta_j) \propto e^{-|\beta_j|/b}$, tiene un pico en cero y colas pesadas. Su estimador de máximo a posteriori es el lasso.

Estructura esperada	Penalización	Métodos
Pocos coeficientes no nulos	$\ \beta\ _1$	Lasso, relajado, adaptativo
Grupos correlacionados que entran juntos	$\ \beta\ _1 + \ \beta\ _2^2$	Elastic net
Pocas variables, cada una con varias columnas	$\sum_g \ \beta_g\ _2$	Group lasso, variables categóricas
Pocos cambios entre coeficientes vecinos	$\sum_i \beta_{i+1} - \beta_i $	Fused lasso, tomografía

La penalización se elige según la estructura esperada de los coeficientes.

El estimador lasso

Del mejor subconjunto a la norma ℓ_1

La selección del mejor subconjunto resuelve

$$\min_{\beta} \frac{1}{2} \|y - X\beta\|^2 \quad \text{sujeto a} \quad \|\beta\|_0 = \#\{j : \beta_j \neq 0\} \leq s,$$

y debe examinar $\binom{p}{s}$ subconjuntos. Con $p = 30$ y $s = 4$ son 27 405 ajustes. Con $p = 1\,000$ y $s = 10$ son unos $2,6 \times 10^{23}$. El problema es NP-difícil.

Del mejor subconjunto a la norma ℓ_1

La selección del mejor subconjunto resuelve

$$\min_{\beta} \frac{1}{2} \|y - X\beta\|^2 \quad \text{sujeto a} \quad \|\beta\|_0 = \#\{j : \beta_j \neq 0\} \leq s,$$

y debe examinar $\binom{p}{s}$ subconjuntos. Con $p = 30$ y $s = 4$ son 27 405 ajustes. Con $p = 1\,000$ y $s = 10$ son unos $2,6 \times 10^{23}$. El problema es NP-difícil.

La familia $\|\beta\|_q^q = \sum_j |\beta_j|^q$ va desde la cuenta de no nulos, $q \rightarrow 0$, hasta ridge, $q = 2$. El lasso usa $q = 1$,

$$\hat{\beta}_\lambda = \arg \min_{\beta} \frac{1}{2} \|y - X\beta\|^2 + \lambda \|\beta\|_1.$$

Del mejor subconjunto a la norma ℓ_1

La selección del mejor subconjunto resuelve

$$\min_{\beta} \frac{1}{2} \|y - X\beta\|^2 \quad \text{sujeto a} \quad \|\beta\|_0 = \#\{j : \beta_j \neq 0\} \leq s,$$




y debe examinar $\binom{p}{s}$ subconjuntos. Con $p = 30$ y $s = 4$ son 27 405 ajustes. Con $p = 1\,000$ y $s = 10$ son unos $2,6 \times 10^{23}$. El problema es NP-difícil.

La familia $\|\beta\|_q^q = \sum_j |\beta_j|^q$ va desde la cuenta de no nulos, $q \rightarrow 0$, hasta ridge, $q = 2$. El lasso usa $q = 1$,




$$\hat{\beta}_\lambda = \arg \min_{\beta} \frac{1}{2} \|y - X\beta\|^2 + \lambda \|\beta\|_1.$$

Con $q < 1$ la bola no es convexa y el problema tiene mínimos locales. Con $q > 1$ la bola es lisa y no produce ceros. Con $q = 1$ la bola es convexa y además tiene vértices sobre los ejes.

Las bolas ℓ_q



Las bolas ℓ_q



La cruz marca la solución de mínimos cuadrados, rodeada por contornos de la suma de cuadrados. La región admisible está en granate. Con la bola ℓ_2 el contacto cae en un punto sin ceros. Con la bola ℓ_1 cae en un vértice, donde $\beta_2 = 0$. Con $q = 1/2$ también cae en un vértice, pero la región no es convexa y la búsqueda puede quedar atrapada.

Condiciones de optimalidad y $\lambda_{\text{máx}}$

Por la condición de subgradiente, $\hat{\beta}$ es solución si y sólo si

$$\mathbf{x}_j^T(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda s_j, \quad s_j = \text{sgn}(\hat{\beta}_j) \text{ si } \hat{\beta}_j \neq 0, \quad s_j \in [-1, 1] \text{ si } \hat{\beta}_j = 0.$$

Condiciones de optimalidad y $\lambda_{\text{máx}}$

Por la condición de subgradiente, $\hat{\beta}$ es solución si y sólo si

$$\mathbf{x}_j^T(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda s_j, \quad s_j = \text{sgn}(\hat{\beta}_j) \text{ si } \hat{\beta}_j \neq 0, \quad s_j \in [-1, 1] \text{ si } \hat{\beta}_j = 0.$$

Tiene dos consecuencias.

- **Las variables activas empatan.** Todas tienen la misma correlación absoluta con el residuo, $|\mathbf{x}_j^T \mathbf{r}| = \lambda$. Las inactivas tienen una menor. El algoritmo LARS usa esta regla.
- **Existe un λ por encima del cual todo es cero.** $\hat{\beta} = 0$ cumple la condición si y sólo si $|\mathbf{x}_j^T \mathbf{y}| \leq \lambda$ para todo j , es decir,

$$\lambda \geq \lambda_{\text{máx}} = \max_j |\mathbf{x}_j^T \mathbf{y}|.$$

Condiciones de optimalidad y $\lambda_{\text{máx}}$

Por la condición de subgradiente, $\hat{\beta}$ es solución si y sólo si

$$\mathbf{x}_j^T(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda s_j, \quad s_j = \text{sgn}(\hat{\beta}_j) \text{ si } \hat{\beta}_j \neq 0, \quad s_j \in [-1, 1] \text{ si } \hat{\beta}_j = 0.$$

Tiene dos consecuencias.

- **Las variables activas empatan.** Todas tienen la misma correlación absoluta con el residuo, $|\mathbf{x}_j^T \mathbf{r}| = \lambda$. Las inactivas tienen una menor. El algoritmo LARS usa esta regla.
- **Existe un λ por encima del cual todo es cero.** $\hat{\beta} = 0$ cumple la condición si y sólo si $|\mathbf{x}_j^T \mathbf{y}| \leq \lambda$ para todo j , es decir,

$$\lambda \geq \lambda_{\text{máx}} = \max_j |\mathbf{x}_j^T \mathbf{y}|.$$

La trayectoria se calcula desde $\lambda_{\text{máx}}$ hacia abajo. En el caso, $\lambda_{\text{máx}} = 43,7$.

Umbral duro, ridge y umbral suave

Si las columnas son ortonormales, $X^T X = I$, el problema se separa en p problemas escalares en $a_j = x_j^T y = \hat{\beta}_j^{\text{MCO}}$.

Estimador	$\hat{\beta}_j$	Regla
Mejor subconjunto de tamaño M	$a_j \cdot \mathbb{1}(a_j \geq a_{(M)})$	Umbral duro, discontinuo
Ridge	$a_j / (1 + \lambda)$	Encogimiento proporcional, nunca cero
Lasso	$\text{sgn}(a_j) (a_j - \lambda)_+$	Umbral suave, continuo y con ceros

Umbral duro, ridge y umbral suave

Si las columnas son ortonormales, $X^T X = I$, el problema se separa en p problemas escalares en $a_j = \mathbf{x}_j^T \mathbf{y} = \hat{\beta}_j^{\text{MCO}}$.

Estimador	$\hat{\beta}_j$	Regla
Mejor subconjunto de tamaño M	$a_j \cdot \mathbb{1}(a_j \geq a_{(M)})$	Umbral duro, discontinuo
Ridge	$a_j / (1 + \lambda)$	Encogimiento proporcional, nunca cero
Lasso	$\text{sgn}(a_j) (a_j - \lambda)_+$	Umbral suave, continuo y con ceros

La fila del lasso se obtiene de $\min_{\beta} \frac{1}{2}(a - \beta)^2 + \lambda|\beta|$ por casos. Si $\beta > 0$, $\beta = a - \lambda$, admisible sólo si $a > \lambda$. Si $\beta < 0$, $\beta = a + \lambda$, admisible sólo si $a < -\lambda$. Si $|a| \leq \lambda$, la condición de subgradiente se cumple en $\beta = 0$.

Umbral duro, ridge y umbral suave



Si las columnas son ortonormales, $X^T X = I$, el problema se separa en p problemas escalares en $a_j = \mathbf{x}_j^T \mathbf{y} = \hat{\beta}_j^{\text{MCO}}$.

Estimador	$\hat{\beta}_j$	Regla
Mejor subconjunto de tamaño M	$a_j \cdot \mathbb{1}(a_j \geq a_{(M)})$	Umbral duro, discontinuo
Ridge	$a_j / (1 + \lambda)$	Encogimiento proporcional, nunca cero
Lasso	$\text{sgn}(a_j) (a_j - \lambda)_+$	Umbral suave, continuo y con ceros



La fila del lasso se obtiene de $\min_{\beta} \frac{1}{2}(a - \beta)^2 + \lambda|\beta|$ por casos. Si $\beta > 0$, $\beta = a - \lambda$, admisible sólo si $a > \lambda$. Si $\beta < 0$, $\beta = a + \lambda$, admisible sólo si $a < -\lambda$. Si $|a| \leq \lambda$, la condición de subgradiente se cumple en $\beta = 0$.

El umbral duro conserva o anula cada coeficiente. Ese salto hace inestable al mejor subconjunto. Ridge nunca anula. El lasso es la única regla de las tres continua y con ceros.

El operador de umbral suave



El operador de umbral suave



A la izquierda, si $|a| \leq \lambda$ el vértice de $|\beta|$ domina y el mínimo cae exactamente en cero. A la derecha, el lasso vale cero sobre la zona muerta $[-\lambda, \lambda]$. Fuera de ella sigue la diagonal, desplazado en λ . Ese desplazamiento también sesga los coeficientes grandes, que sí existen. Este sesgo acompaña a la continuidad, y el lasso relajado lo corrige.

Descenso por coordenadas

Sin columnas ortonormales no hay forma cerrada. Pero cada coordenada, con las demás fijas, es el mismo problema escalar. Con el residuo parcial $\mathbf{r}^{(j)} = \mathbf{y} - \sum_{k \neq j} \mathbf{x}_k \beta_k$,

$$\beta_j \leftarrow \frac{\text{sgn}(\mathbf{x}_j^\top \mathbf{r}^{(j)}) (|\mathbf{x}_j^\top \mathbf{r}^{(j)}| - \lambda)_+}{\|\mathbf{x}_j\|^2}.$$

Descenso por coordenadas

Sin columnas ortonormales no hay forma cerrada. Pero cada coordenada, con las demás fijas, es el mismo problema escalar. Con el residuo parcial $\mathbf{r}^{(j)} = \mathbf{y} - \sum_{k \neq j} \mathbf{x}_k \beta_k$,

$$\beta_j \leftarrow \frac{\text{sgn}(\mathbf{x}_j^\top \mathbf{r}^{(j)}) (|\mathbf{x}_j^\top \mathbf{r}^{(j)}| - \lambda)_+}{\|\mathbf{x}_j\|^2}.$$

El algoritmo recorre las coordenadas en ciclo hasta que ninguna cambia. Converge al óptimo global porque la parte no diferenciable, $\sum_j |\beta_j|$, es separable por coordenadas (Tseng, 2001). Con una penalización no separable puede atascarse.

Descenso por coordenadas


Sin columnas ortonormales no hay forma cerrada. Pero cada coordenada, con las demás fijas, es el mismo problema escalar. Con el residuo parcial $\mathbf{r}^{(j)} = \mathbf{y} - \sum_{k \neq j} \mathbf{x}_k \beta_k$,

$$\beta_j \leftarrow \frac{\text{sgn}(\mathbf{x}_j^T \mathbf{r}^{(j)}) (|\mathbf{x}_j^T \mathbf{r}^{(j)}| - \lambda)_+}{\|\mathbf{x}_j\|^2}.$$


El algoritmo recorre las coordenadas en ciclo hasta que ninguna cambia. Converge al óptimo global porque la parte no diferenciable, $\sum_j |\beta_j|$, es separable por coordenadas (Tseng, 2001). Con una penalización no separable puede atascarse.

Para una grilla de λ , se parte de $\lambda_{\text{máx}}$ y cada ajuste empieza en la solución del anterior. Las soluciones vecinas se parecen, así que cada ajuste converge en pocas pasadas. Así trabajan `glmnet` y `scikit-learn`.

Trayectorias sobre el caso



Trayectorias sobre el caso



Las 30 variables del caso, con los cuatro coeficientes verdaderos en granate. Ridge los encoge suavemente y ninguno llega a cero. En el lasso todos valen cero sobre $\lambda_{\text{máx}}$. Al bajar λ las variables entran de a una, con trayectorias lineales a trozos. Las cuatro verdaderas entran primero. Las nulas entran después con coeficientes pequeños.

Grados de libertad del lasso

El optimismo del error de entrenamiento es $\frac{2}{n} \sum_i \text{Cov}(\hat{y}_i, y_i)$ y los grados de libertad son $\text{df} = \sum_i \text{Cov}(\hat{y}_i, y_i) / \sigma^2$.

Teorema (Zou, Hastie y Tibshirani, 2007; Tibshirani y Taylor, 2012)


Para λ fijo y X en posición general, el número de coeficientes no nulos $|\mathcal{A}_\lambda|$ es un estimador insesgado de $\text{df}(\lambda)$.

Grados de libertad del lasso

El optimismo del error de entrenamiento es $\frac{2}{n} \sum_i \text{Cov}(\hat{y}_i, y_i)$ y los grados de libertad son $\text{df} = \sum_i \text{Cov}(\hat{y}_i, y_i) / \sigma^2$.


Teorema (Zou, Hastie y Tibshirani, 2007; Tibshirani y Taylor, 2012)

Para λ fijo y X en posición general, el número de coeficientes no nulos $|\mathcal{A}_\lambda|$ es un estimador insesgado de $\text{df}(\lambda)$.




Simulación con la matriz del caso y 300 réplicas del ruido. El C_p del lasso es $\text{err} + 2\hat{\sigma}^2 |\mathcal{A}_\lambda| / n$. La selección de variables no agrega grados de libertad, porque el encogimiento la compensa exactamente.

Elección de λ en el caso




Elección de λ en el caso




Cinco pliegues sobre los 40 pacientes. La curva del lasso queda bajo la de ridge en todo el rango útil, porque su a priori coincide con la verdad. La regla de un error estándar elige $\lambda_{1EE} \approx 5,5$. Con ese valor entran 10 variables, las cuatro verdaderas y seis nulas. En pacientes nuevos el error es 1,31, contra 2,04 de ridge y 1,54 del modelo B.

El sesgo del lasso y el lasso relajado



El umbral suave resta λ a todo coeficiente activo, y los efectos verdaderos quedan encogidos. El lasso relajado usa el lasso sólo para elegir el soporte y luego reajusta por mínimos cuadrados sobre él (Meinshausen, 2007).

El sesgo del lasso y el lasso relajado



El umbral suave resta λ a todo coeficiente activo, y los efectos verdaderos quedan encogidos. El lasso relajado usa el lasso sólo para elegir el soporte y luego reajusta por mínimos cuadrados sobre él (Meinshausen, 2007).

El reajuste recupera la magnitud de los efectos. También reajusta los falsos positivos, ahora sin encogimiento. Por eso el λ del relajado se elige por validación cruzada del procedimiento completo, con el reajuste. En el caso elige 9 variables y obtiene 1,49 en pacientes nuevos, peor que el lasso. Con muchos falsos positivos, el encogimiento mantenía pequeños sus coeficientes.

Cuándo funciona

Error de predicción del lasso

Teorema (Bickel, Ritov y Tsybakov, 2009; Hastie, Tibshirani y Wainwright, 2015, cap. 11)

Sea β s -disperso, $\|x_j\|^2 \leq n$, ruido $N(0, \sigma^2)$ y X con la condición de autovalor restringido de constante $\gamma > 0$. Con $\lambda = 2\sigma\sqrt{2n \log p} + n\delta$, con probabilidad al menos $1 - 2e^{-n\delta^2/2}$,

$$\frac{1}{n} \|X(\hat{\beta}_\lambda - \beta)\|^2 \leq \frac{C}{\gamma} \sigma^2 \frac{s \log p}{n}.$$

Error de predicción del lasso

Teorema (Bickel, Ritov y Tsybakov, 2009; Hastie, Tibshirani y Wainwright, 2015, cap. 11)

Sea β s -disperso, $\|x_j\|^2 \leq n$, ruido $N(0, \sigma^2)$ y X con la condición de autovalor restringido de constante $\gamma > 0$. Con $\lambda = 2\sigma\sqrt{2n \log p} + n\delta$, con probabilidad al menos $1 - 2e^{-n\delta^2/2}$,

$$\frac{1}{n} \|X(\hat{\beta}_\lambda - \beta)\|^2 \leq \frac{C}{\gamma} \sigma^2 \frac{s \log p}{n}.$$

Estimador	Exceso de riesgo	Qué paga
Mínimos cuadrados	$\sigma^2 p/(n - p - 1)$	Cada una de las p variables
Oráculo que conoce el soporte	$\sigma^2 s/(n - s - 1)$	Cada una de las s relevantes
Lasso	$\asymp \sigma^2 s \log p/n$	Las s relevantes, más $\log p$ por buscarlas

Error de predicción del lasso

Teorema (Bickel, Ritov y Tsybakov, 2009; Hastie, Tibshirani y Wainwright, 2015, cap. 11)


Sea β s -disperso, $\|x_j\|^2 \leq n$, ruido $N(0, \sigma^2)$ y X con la condición de autovalor restringido de constante $\gamma > 0$. Con $\lambda = 2\sigma\sqrt{2n \log p} + n\delta$, con probabilidad al menos $1 - 2e^{-n\delta^2/2}$,

$$\frac{1}{n} \|X(\hat{\beta}_\lambda - \beta)\|^2 \leq \frac{C}{\gamma} \sigma^2 \frac{s \log p}{n}.$$


Estimador	Exceso de riesgo	Qué paga
Mínimos cuadrados	$\sigma^2 p/(n - p - 1)$	Cada una de las p variables
Oráculo que conoce el soporte	$\sigma^2 s/(n - s - 1)$	Cada una de las s relevantes
Lasso	$\asymp \sigma^2 s \log p/n$	Las s relevantes, más $\log p$ por buscarlas

Al duplicar las candidatas, el error suma $\log 2$ por variable relevante. El lasso funciona con $p > n$, donde mínimos cuadrados no está definido.

Error de predicción en simulación



Error de predicción en simulación



$n = 100$, $s = 5$ coeficientes iguales a uno, diseño gaussiano, 30 réplicas por punto. El error de mínimos cuadrados sigue la fórmula $\sigma^2 p / (n - p - 1)$ y diverge cerca de $p = n$. El error del oráculo no depende de p . El del lasso, con $\lambda = \sigma \sqrt{2n \log p}$, crece como $\log p$. Sigue funcionando con $p = 1\ 200$, doce veces más variables que observaciones. Con pocas variables gana mínimos cuadrados, porque allí nada compensa el sesgo del lasso.

Condiciones para seleccionar bien

Un lasso que predice bien puede seleccionar mal. Para que algún λ recupere el soporte con los signos correctos, hacen falta dos condiciones (Zhao y Yu, 2006; Wainwright, 2009).

- **Irrepresentabilidad.** Las relevantes no deben explicar bien a las irrelevantes,

$$\|X_{S^c}^T X_S (X_S^T X_S)^{-1} \text{sgn}(\beta_S)\|_\infty < 1.$$

- **Señal mínima.** $\min_{j \in S} |\beta_j|$ debe superar el orden de $\sigma \sqrt{\log p/n}$.


Condiciones para seleccionar bien

Un lasso que predice bien puede seleccionar mal. Para que algún λ recupere el soporte con los signos correctos, hacen falta dos condiciones (Zhao y Yu, 2006; Wainwright, 2009).

- **Irrepresentabilidad.** Las relevantes no deben explicar bien a las irrelevantes,

$$\|X_{S^c}^T X_S (X_S^T X_S)^{-1} \text{sgn}(\beta_S)\|_{\infty} < 1.$$



- **Señal mínima.** $\min_{j \in S} |\beta_j|$ debe superar el orden de $\sigma \sqrt{\log p/n}$.



Con $\beta = (2, 3, 0)$ y $x_3 = \frac{2}{3}x_1 + \frac{2}{3}x_2 + \frac{1}{3}e$, la cantidad vale $4/3$. Incluso con $n = 1\,000$, el lasso no acierta el soporte en más de la mitad de las muestras.



Selección de variables

Un experimento con verdad conocida



Regla	Verdaderos positivos, de 6	Falsos positivos, de 44
$\lambda_{\min}$	5,9	13,8
λ_{1EE}	5,8	5,2

Un experimento con verdad conocida



Regla	Verdaderos positivos, de 6	Falsos positivos, de 44
$\lambda_{\min}$	5,9	13,8
λ_{1EE}	5,8	5,2

$n = 100, p = 50$, seis variables relevantes con efectos de 1,0 a 0,3, columnas con correlación $0,3^{|j-k|}$.

La validación cruzada elige λ para predecir. Para predecir conviene dejar entrar variables nulas con coeficientes pequeños. Con $\lambda_{\min}$ entran en promedio casi catorce falsos positivos. La regla de un error estándar los reduce a cinco sin perder verdaderos.

Selección por estabilidad

Meinshausen y Bühlmann (2010). Se ajusta el lasso en B submuestras de tamaño $n/2$. Para cada variable se registra la frecuencia $\hat{\pi}_j(\lambda)$ con que queda seleccionada. Se retienen las variables con $\max_{\lambda} \hat{\pi}_j(\lambda) \geq \pi$.

Cota del número de falsos positivos


Si q es el número medio de variables seleccionadas por submuestra y $\pi > 1/2$, bajo intercambiabilidad de las irrelevantes, $\mathbb{E}[V] \leq \frac{q^2}{(2\pi - 1)p}$.

Selección por estabilidad

Meinshausen y Bühlmann (2010). Se ajusta el lasso en B submuestras de tamaño $n/2$. Para cada variable se registra la frecuencia $\hat{\pi}_j(\lambda)$ con que queda seleccionada. Se retienen las variables con $\max_{\lambda} \hat{\pi}_j(\lambda) \geq \pi$.



Cota del número de falsos positivos

Si q es el número medio de variables seleccionadas por submuestra y $\pi > 1/2$, bajo intercambiabilidad de las irrelevantes, $\mathbb{E}[V] \leq \frac{q^2}{(2\pi - 1)p}$.




En una muestra del experimento, con $q \leq 8$ y $\pi = 0,6$, se retienen 4 variables, todas verdaderas. Las dos de efecto más débil quedan fuera. El método pierde sensibilidad y gana control de falsos positivos.

Inferencia después de la selección




Inferencia después de la selección



Ninguna variable tiene efecto. El lasso elige las tres primeras en entrar y cada una se contrasta en el ajuste por mínimos cuadrados. Con la misma muestra, el 43 por ciento de los contrastes da $p < 0,05$. Si se elige con una mitad y se contrasta con la otra, el 4,3 por ciento.

Inferencia después de la selección



Ninguna variable tiene efecto. El lasso elige las tres primeras en entrar y cada una se contrasta en el ajuste por mínimos cuadrados. Con la misma muestra, el 43 por ciento de los contrastes da $p < 0,05$. Si se elige con una mitad y se contrasta con la otra, el 4,3 por ciento.

Es el problema de los grados de libertad del investigador, automatizado. Las soluciones son partir la muestra, la inferencia selectiva que condiciona en el evento de selección (Lee y colaboradores, 2016), el lasso corregido por sesgo para intervalos en alta dimensión, y los *knockoffs*, que controlan la tasa de falsos descubrimientos (Barber y Candès, 2015).

Variantes

Elastic net


$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta}} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \lambda \left(\alpha \|\boldsymbol{\beta}\|_1 + \frac{1-\alpha}{2} \|\boldsymbol{\beta}\|_2^2 \right)$$

En el descenso por coordenadas sólo cambia el denominador, $\beta_j \leftarrow S_{\lambda\alpha}(\mathbf{x}_j^\top \mathbf{r}^{(j)}) / (\|\mathbf{x}_j\|^2 + \lambda(1-\alpha))$.

Elastic net

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2} \|y - X\beta\|^2 + \lambda \left(\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right)$$

En el descenso por coordenadas sólo cambia el denominador, $\beta_j \leftarrow S_{\lambda\alpha}(\mathbf{x}_j^T \mathbf{r}^{(j)}) / (\|\mathbf{x}_j\|^2 + \lambda(1 - \alpha))$.



Cinco variables relevantes con correlación 0,9, en granate. El lasso deja entrar a una o dos y mantiene a las otras en cero. El elastic net las hace entrar juntas. Zou y Hastie (2005) acotan la diferencia entre dos coeficientes por $\sqrt{2(1 - \rho)}$ dividido por el peso de la penalización cuadrática. Así, variables casi idénticas reciben coeficientes casi idénticos.

Lasso adaptativo

Zou (2006). El lasso adaptativo penaliza cada coeficiente con un peso inverso a una estimación preliminar,

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2} \|y - X\beta\|^2 + \lambda \sum_j w_j |\beta_j|, \quad w_j = \frac{1}{|\tilde{\beta}_j|^\gamma},$$

con $\tilde{\beta}$ de mínimos cuadrados o de ridge.

Lasso adaptativo

Zou (2006). El lasso adaptativo penaliza cada coeficiente con un peso inverso a una estimación preliminar,

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2} \|y - X\beta\|^2 + \lambda \sum_j w_j |\beta_j|, \quad w_j = \frac{1}{|\tilde{\beta}_j|^\gamma},$$

con $\tilde{\beta}$ de mínimos cuadrados o de ridge.

Los efectos grandes reciben poca penalización y quedan casi sin sesgo. Los pequeños reciben mucha y se anulan. Con $\tilde{\beta}$ consistente y λ bien elegido, el lasso adaptativo tiene la propiedad del oráculo. Selecciona el soporte correcto con probabilidad que tiende a uno. Estima los coeficientes activos con la distribución asintótica que tendrían si el soporte fuera conocido. Lo logra aunque falle la condición de irrepresentabilidad.

Lasso adaptativo

Zou (2006). El lasso adaptativo penaliza cada coeficiente con un peso inverso a una estimación preliminar,

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2} \|y - X\beta\|^2 + \lambda \sum_j w_j |\beta_j|, \quad w_j = \frac{1}{|\tilde{\beta}_j|^\gamma},$$

con $\tilde{\beta}$ de mínimos cuadrados o de ridge.

Los efectos grandes reciben poca penalización y quedan casi sin sesgo. Los pequeños reciben mucha y se anulan. Con $\tilde{\beta}$ consistente y λ bien elegido, el lasso adaptativo tiene la propiedad del oráculo. Selecciona el soporte correcto con probabilidad que tiende a uno. Estima los coeficientes activos con la distribución asintótica que tendrían si el soporte fuera conocido. Lo logra aunque falle la condición de irrepresentabilidad.

En el descenso por coordenadas sólo cambia el umbral, λw_j en lugar de λ . En el caso, con pesos de ridge, selecciona 12 variables y obtiene 1,45 en pacientes nuevos. Con $n = 40$ y $p = 30$ la estimación preliminar es mala, y los pesos heredan su ruido.

Group lasso

Yuan y Lin (2006). Las columnas se agrupan, $X\beta = \sum_g X_g \beta_g$. Se penaliza la norma euclídea de cada grupo, sin cuadrado,

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2} \left\| y - \sum_g X_g \beta_g \right\|^2 + \lambda \sum_g \sqrt{p_g} \|\beta_g\|_2.$$

Group lasso

Yuan y Lin (2006). Las columnas se agrupan, $X\beta = \sum_g X_g \beta_g$. Se penaliza la norma euclídea de cada grupo, sin cuadrado,

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2} \left\| y - \sum_g X_g \beta_g \right\|^2 + \lambda \sum_g \sqrt{p_g} \|\beta_g\|_2.$$

La norma $\|\beta_g\|_2$ tiene un vértice sólo en $\beta_g = 0$, donde su subgradiente es la bola unitaria. Con $X_g^T X_g = I$ y $z_g = X_g^T r^{(g)}$, la actualización por bloque es

$$\beta_g \leftarrow \left(1 - \frac{\lambda \sqrt{p_g}}{\|z_g\|_2} \right)_+ z_g.$$

Group lasso

Yuan y Lin (2006). Las columnas se agrupan, $X\beta = \sum_g X_g \beta_g$. Se penaliza la norma euclídea de cada grupo, sin cuadrado,



$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2} \left\| y - \sum_g X_g \beta_g \right\|^2 + \lambda \sum_g \sqrt{p_g} \|\beta_g\|_2.$$

La norma $\|\beta_g\|_2$ tiene un vértice sólo en $\beta_g = 0$, donde su subgradiente es la bola unitaria. Con $X_g^T X_g = I$ y $z_g = X_g^T r^{(g)}$, la actualización por bloque es



$$\beta_g \leftarrow \left(1 - \frac{\lambda \sqrt{p_g}}{\|z_g\|_2} \right)_+ z_g.$$

Si $\|z_g\|_2 \leq \lambda \sqrt{p_g}$, el grupo entero es cero. Si no, todas sus componentes son no nulas y se encogen en la misma proporción. Con grupos de tamaño uno se obtiene el lasso.

Umbral por coordenada y umbral por bloque



Umbral por coordenada y umbral por bloque



Un grupo de dos coeficientes. Cada flecha lleva z a su imagen. El lasso resta λ a cada coordenada por separado. Los puntos de las franjas van a los ejes y los del cuadrado central, al origen. El group lasso encoge el vector hacia el origen sin cambiar su dirección. Los puntos del disco central van al origen. Nunca deja unas componentes del grupo en cero y otras no. El group lasso disperso de Simon y colaboradores (2013) suma ambas penalizaciones. Así selecciona grupos y, dentro de ellos, componentes.

Fused lasso y variación total


Si los coeficientes tienen un orden, se espera que los vecinos sean iguales. El fused lasso penaliza las diferencias,

$$\min_{\beta} \frac{1}{2} \|y - \beta\|^2 + \lambda \sum_i |\beta_{i+1} - \beta_i|.$$

Fused lasso y variación total

Si los coeficientes tienen un orden, se espera que los vecinos sean iguales. El fused lasso penaliza las diferencias,

$$\min_{\beta} \frac{1}{2} \|y - \beta\|^2 + \lambda \sum_i |\beta_{i+1} - \beta_i|.$$




La solución es constante a trozos, porque las diferencias nulas son los vértices. Recupera los cinco cambios de nivel verdaderos. Se usa para detectar cambios en el número de copias de un gen (Tibshirani y Wang, 2008).

Fused lasso y variación total

Si los coeficientes tienen un orden, se espera que los vecinos sean iguales. El fused lasso penaliza las diferencias,

$$\min_{\beta} \frac{1}{2} \|y - \beta\|^2 + \lambda \sum_i |\beta_{i+1} - \beta_i|.$$



La solución es constante a trozos, porque las diferencias nulas son los vértices. Recupera los cinco cambios de nivel verdaderos. Se usa para detectar cambios en el número de copias de un gen (Tibshirani y Wang, 2008).

El lasso generalizado, $\lambda \|D\beta\|_1$, incluye todos estos casos. Con $D = I$ es el lasso. Con la matriz de diferencias es el fused lasso. Con el gradiente de una imagen es la variación total, que se usa en tomografía.

Variables categóricas

Codificación de un factor

Un factor F con niveles $1, \dots, K$ se codifica con $K - 1$ columnas indicadoras, respecto de un nivel de referencia r . En el modelo

$$y = \beta_0 + \sum_{k \neq r} \beta_k \mathbb{1}[F = k] + \dots$$

el coeficiente $\beta_k = \mu_k - \mu_r$ es la diferencia entre el nivel k y la referencia.

Codificación de un factor

Un factor F con niveles $1, \dots, K$ se codifica con $K - 1$ columnas indicadoras, respecto de un nivel de referencia r . En el modelo

$$y = \beta_0 + \sum_{k \neq r} \beta_k \mathbb{1}[F = k] + \dots$$

el coeficiente $\beta_k = \mu_k - \mu_r$ es la diferencia entre el nivel k y la referencia.

En mínimos cuadrados la elección de r no cambia el ajuste. Las $K - 1$ columnas generan el mismo espacio para cualquier r , y las predicciones no cambian.

Codificación de un factor

Un factor F con niveles $1, \dots, K$ se codifica con $K - 1$ columnas indicadoras, respecto de un nivel de referencia r . En el modelo

$$y = \beta_0 + \sum_{k \neq r} \beta_k \mathbb{1}[F = k] + \dots$$

el coeficiente $\beta_k = \mu_k - \mu_r$ es la diferencia entre el nivel k y la referencia.

En mínimos cuadrados la elección de r no cambia el ajuste. Las $K - 1$ columnas generan el mismo espacio para cualquier r , y las predicciones no cambian.


En el lasso la elección de r cambia el resultado. Un cero en β_k dice que el nivel k es igual a la referencia, y eso depende de cuál es la referencia. Además, la penalización actúa columna por columna. Puede conservar unos niveles y anular otros, y no responde si el factor tiene efecto.

Dependencia de la referencia



lasso sobre las dummies de F

referencia 1	ref.	0,0	-0,2	0,9	1,0
referencia 2	0,0	ref.	-0,2	0,9	1,0
referencia 3	0,0	0,0	ref.	1,0	1,1
referencia 4	-0,8	-0,9	-1,1	ref.	0,2
referencia 5	-0,9	-1,0	-1,1	0,0	ref.
	1	2	3	4	5

nivel de F



Dependencia de la referencia



$n = 200$, una variable continua relevante, cuatro irrelevantes, un factor F de cinco niveles con medias $(0, 0, 0, 1, 1)$ y un factor G sin efecto. A la izquierda, el lasso con cada referencia posible. Con referencia 1, declara distintos los niveles 4 y 5. Con referencia 4, declara distintos los niveles 1, 2 y 3. Ambos resultados describen el mismo ajuste, y ninguno dice si F tiene efecto. Además, el lasso deja entrar dos o tres indicadoras de G según la referencia. A la derecha, el group lasso con un grupo por variable. F entra entero y G queda fuera. La trayectoria de F es idéntica con referencia 1 y con referencia 4.

Group lasso e invariancia a la referencia

Si cada grupo se ortonormaliza, $X_g = Q_g R_g$ con $Q_g^T Q_g = I$, la penalización del grupo es $\|\boldsymbol{\theta}_g\| = \|Q_g \boldsymbol{\theta}_g\| = \|X_g \boldsymbol{\beta}_g\|$. Es la norma de la contribución del factor al ajuste.

Group lasso e invariancia a la referencia

Si cada grupo se ortonormaliza, $X_g = Q_g R_g$ con $Q_g^T Q_g = I$, la penalización del grupo es $\|\boldsymbol{\theta}_g\| = \|Q_g \boldsymbol{\theta}_g\| = \|X_g \boldsymbol{\beta}_g\|$. Es la norma de la contribución del factor al ajuste.

Las indicadoras centradas generan el mismo subespacio para cualquier referencia. El problema depende sólo de ese subespacio. Por eso el ajuste es el mismo para las K codificaciones. En la figura, las trayectorias con referencia 1 y 4 difieren en el orden de 10^{-15} .

Group lasso e invariancia a la referencia

Si cada grupo se ortonormaliza, $X_g = Q_g R_g$ con $Q_g^T Q_g = I$, la penalización del grupo es $\|\theta_g\| = \|Q_g \theta_g\| = \|X_g \beta_g\|$. Es la norma de la contribución del factor al ajuste.

Las indicadoras centradas generan el mismo subespacio para cualquier referencia. El problema depende sólo de ese subespacio. Por eso el ajuste es el mismo para las K codificaciones. En la figura, las trayectorias con referencia 1 y 4 difieren en el orden de 10^{-15} .

Situación	Tratamiento
Decidir si una variable categórica tiene efecto	Group lasso con grupos ortonormalizados
Niveles ordenados, como estadios o tramos	Fused lasso sobre niveles contiguos, que fusiona categorías
Niveles nominales que podrían fusionarse	Fusión de todos los pares, CAS-ANOVA (Bondell y Reich, 2009)
Interacciones entre variables	Lasso jerárquico, la interacción sólo si entran sus efectos principales
Escalas mixtas, continuas e indicadoras	Estandarizar las continuas y declarar qué se hizo con las indicadoras

Reconstrucción a partir de proyecciones

Menos ecuaciones que incógnitas

Se mide $y = Ax$ con $A \in \mathbb{R}^{m \times n}$ y $m < n$. Cada medición es una proyección de la señal. El sistema tiene infinitas soluciones.

Menos ecuaciones que incógnitas

Se mide $y = Ax$ con $A \in \mathbb{R}^{m \times n}$ y $m < n$. Cada medición es una proyección de la señal. El sistema tiene infinitas soluciones.

La solución de norma mínima, $\hat{x} = A^+y$, reparte la energía entre todas las componentes. Si x es dispersa, conviene otra solución, la búsqueda de base de Chen, Donoho y Saunders (1998),

$$\min_x \|x\|_1 \quad \text{sujeto a} \quad Ax = y,$$

que es un programa lineal. Si las mediciones tienen ruido, se usa el lasso.

Menos ecuaciones que incógnitas

Se mide $y = Ax$ con $A \in \mathbb{R}^{m \times n}$ y $m < n$. Cada medición es una proyección de la señal. El sistema tiene infinitas soluciones.

La solución de norma mínima, $\hat{x} = A^+y$, reparte la energía entre todas las componentes. Si x es dispersa, conviene otra solución, la búsqueda de base de Chen, Donoho y Saunders (1998),

$$\min_x \|x\|_1 \quad \text{sujeto a} \quad Ax = y,$$




que es un programa lineal. Si las mediciones tienen ruido, se usa el lasso.

Teorema (Candès, Romberg y Tao, 2006; Donoho, 2006)


Si A tiene entradas gaussianas independientes y $m \geq C s \log(n/s)$, con alta probabilidad la búsqueda de base recupera exactamente toda x s -dispersa.

El número de mediciones depende de s y sólo logarítmicamente del tamaño, n . Es el mismo $s \log p$ del lasso.

Proyecciones aleatorias de una señal dispersa




Proyecciones aleatorias de una señal dispersa




Una señal de longitud 256 con 10 componentes no nulas, medida con 64 proyecciones gaussianas. La solución de norma ℓ_2 mínima, A^+y , tiene error relativo 0,89 y no se parece a la señal. La de norma ℓ_1 mínima recupera la señal con error del orden de 10^{-14} , la precisión de la máquina.

La transición de fase



La transición de fase



$n = 100$, diez réplicas por celda. El eje horizontal muestra la fracción de mediciones. El vertical muestra la dispersión relativa al número de mediciones. En una franja angosta, la recuperación pasa de fallar casi siempre a acertar casi siempre. Donoho y Tanner (2009) calcularon la curva límite exacta. Es la misma para una clase muy amplia de matrices de medición. Debajo de la curva, pocas mediciones bastan.

El teorema del corte de Fourier

Una tomografía mide integrales de línea de la imagen f . La proyección en el ángulo θ es $P_\theta(t) = \int f(t \cos \theta - u \sin \theta, t \sin \theta + u \cos \theta) du$.

El teorema del corte de Fourier

Una tomografía mide integrales de línea de la imagen f . La proyección en el ángulo θ es $P_\theta(t) = \int f(t \cos \theta - u \sin \theta, t \sin \theta + u \cos \theta) du$.

Teorema del corte de Fourier

La transformada de Fourier unidimensional de P_θ es el corte de la transformada bidimensional de f a lo largo de la recta de ángulo θ que pasa por el origen,

$$\hat{P}_\theta(\omega) = \hat{f}(\omega \cos \theta, \omega \sin \theta).$$

El teorema del corte de Fourier

Una tomografía mide integrales de línea de la imagen f . La proyección en el ángulo θ es $P_\theta(t) = \int f(t \cos \theta - u \sin \theta, t \sin \theta + u \cos \theta) du$.

Teorema del corte de Fourier

La transformada de Fourier unidimensional de P_θ es el corte de la transformada bidimensional de f a lo largo de la recta de ángulo θ que pasa por el origen,

$$\hat{P}_\theta(\omega) = \hat{f}(\omega \cos \theta, \omega \sin \theta).$$

Con 22 proyecciones se miden 22 rectas radiales del espacio de frecuencias. El resto queda sin medir. La resonancia magnética mide directamente el espacio de frecuencias. Submuestrearlo acorta el examen.

El teorema del corte de Fourier

Una tomografía mide integrales de línea de la imagen f . La proyección en el ángulo θ es $P_\theta(t) = \int f(t \cos \theta - u \sin \theta, t \sin \theta + u \cos \theta) du$.

Teorema del corte de Fourier

La transformada de Fourier unidimensional de P_θ es el corte de la transformada bidimensional de f a lo largo de la recta de ángulo θ que pasa por el origen,

$$\hat{P}_\theta(\omega) = \hat{f}(\omega \cos \theta, \omega \sin \theta).$$

Con 22 proyecciones se miden 22 rectas radiales del espacio de frecuencias. El resto queda sin medir. La resonancia magnética mide directamente el espacio de frecuencias. Submuestrearlo acorta el examen.


Una imagen médica no es dispersa, pero su gradiente sí, porque es casi constante por regiones. Por eso se busca la imagen de menor variación total, $TV(\mathbf{x}) = \sum_i \|\nabla \mathbf{x}_i\|_2$, compatible con las frecuencias medidas. Es un group lasso sobre el gradiente.

Tomografía con pocas proyecciones


fantoma




22 rectas radiales



retroproyección filtrada




norma ℓ_2 mínima



variación total mínima




Tomografía con pocas proyecciones



Fantoma de Shepp y Logan de 128×128 y 22 proyecciones. La retroproyección filtrada, el método clásico, deja estrías, con error relativo 0,51. La norma ℓ_2 mínima rellena con ceros las frecuencias no medidas y produce artefactos de submuestreo, con error 0,26. La variación total mínima, resuelta con el algoritmo primal-dual de Chambolle y Pock, tiene error 0,016. Candès, Romberg y Tao (2006) hicieron este experimento.

Tomografía con pocas proyecciones



Fantoma de Shepp y Logan de 128×128 y 22 proyecciones. La retroproyección filtrada, el método clásico, deja estrías, con error relativo 0,51. La norma ℓ_2 mínima rellena con ceros las frecuencias no medidas y produce artefactos de submuestreo, con error 0,26. La variación total mínima, resuelta con el algoritmo primal-dual de Chambolle y Pock, tiene error 0,016. Candès, Romberg y Tao (2006) hicieron este experimento.

El compressed sensing está aprobado para uso clínico en resonancia magnética desde 2017. Acorta varias veces los exámenes (Lustig, Donoho y Pauly, 2007).

Estructura y causalidad

Selección de vecindarios

Sea $\mathbf{X} \sim N(0, \mathbf{\Sigma})$ con matriz de precisión $\mathbf{\Theta} = \mathbf{\Sigma}^{-1}$. La regresión de una variable sobre las demás es

$$\mathbb{E}[X_j \mid \mathbf{X}_{-j}] = \sum_{k \neq j} \beta_{jk} X_k, \quad \beta_{jk} = -\frac{\Theta_{jk}}{\Theta_{jj}}.$$

Selección de vecindarios

Sea $\mathbf{X} \sim N(0, \mathbf{\Sigma})$ con matriz de precisión $\mathbf{\Theta} = \mathbf{\Sigma}^{-1}$. La regresión de una variable sobre las demás es

$$\mathbb{E}[X_j \mid \mathbf{X}_{-j}] = \sum_{k \neq j} \beta_{jk} X_k, \quad \beta_{jk} = -\frac{\Theta_{jk}}{\Theta_{jj}}.$$

Por lo tanto $\beta_{jk} = 0$ si y sólo si $\Theta_{jk} = 0$, si y sólo si X_j y X_k son independientes condicionalmente al resto. Los ceros de las p regresiones definen el grafo de independencia condicional.

Selección de vecindarios

Sea $X \sim N(0, \Sigma)$ con matriz de precisión $\Theta = \Sigma^{-1}$. La regresión de una variable sobre las demás es



$$\mathbb{E}[X_j \mid X_{-j}] = \sum_{k \neq j} \beta_{jk} X_k, \quad \beta_{jk} = -\frac{\Theta_{jk}}{\Theta_{jj}}.$$

Por lo tanto $\beta_{jk} = 0$ si y sólo si $\Theta_{jk} = 0$, si y sólo si X_j y X_k son independientes condicionalmente al resto. Los ceros de las p regresiones definen el grafo de independencia condicional.


Meinshausen y Bühlmann (2006) ajustan un lasso por nodo y unen los vecindarios. Demuestran que así se recupera el grafo con p creciente con n . El lasso gráfico de Friedman, Hastie y Tibshirani (2008) estima Θ directamente,

$$\max_{\Theta \succ 0} \log \det \Theta - \text{tr}(S\Theta) - \lambda \|\Theta\|_1.$$

Un grafo de diez variables




Un grafo de diez variables




Diez variables gaussianas con una cadena y un nodo que conecta con tres, $n = 300$, un lasso por nodo con la regla de un error estándar. Se recuperan las diez aristas sin ninguna falsa. La correlación marginal no sirve aquí. En una cadena, todas las variables están correlacionadas con todas. Sólo la regresión sobre el resto distingue la conexión directa de la indirecta.

Grafo de vecindarios y colisionador




Grafo de independencia condicional




x e y son independientes y ambas causan z . Marginalmente no se relacionan, pero condicionadas en z sí. La regresión de x sobre (y, z) tiene coeficiente $-0,79$ en y . El grafo de independencia condicional une x con y , que no tienen relación causal.

Grafo de vecindarios y colisionador



Grafo de independencia condicional



x e y son independientes y ambas causan z . Marginalmente no se relacionan, pero condicionadas en z sí. La regresión de x sobre (y, z) tiene coeficiente $-0,79$ en y . El grafo de independencia condicional une x con y , que no tienen relación causal.


El lasso entrega el grafo moral del grafo causal, que agrega aristas entre causas de un efecto común. La matriz de covarianza no contiene la dirección, porque varios grafos causales producen la misma. Para orientar las aristas hay que detectar colisionadores con el algoritmo PC, conocer el orden causal (Shojaie y Michailidis, 2010), intervenir, o suponer algo sobre el ruido. NOTEARS (Zheng y colaboradores, 2018) plantea el aprendizaje del grafo causal como un lasso con una restricción de aciclicidad.

Causalidad de Granger con lasso

En series de tiempo el pasado ordena. En un modelo autorregresivo vectorial $\mathbf{x}_t = \mathbf{A}\mathbf{x}_{t-1} + \boldsymbol{\varepsilon}_t$, x_j causa en el sentido de Granger a x_i si $A_{ij} \neq 0$. Es decir, el pasado de x_j ayuda a predecir x_i aun con el pasado de las demás.

Causalidad de Granger con lasso


En series de tiempo el pasado ordena. En un modelo autorregresivo vectorial $\mathbf{x}_t = \mathbf{A}\mathbf{x}_{t-1} + \boldsymbol{\varepsilon}_t$, x_j causa en el sentido de Granger a x_i si $A_{ij} \neq 0$. Es decir, el pasado de x_j ayuda a predecir x_i aun con el pasado de las demás.



Seis series, $T = 300$, un lasso por fila. Se recuperan los ceros de $\mathbf{A}$. Con K series y L rezagos hay $K^2 L$ coeficientes, y la dispersión es indispensable.

Causalidad de Granger con lasso

En series de tiempo el pasado ordena. En un modelo autorregresivo vectorial $\mathbf{x}_t = \mathbf{A}\mathbf{x}_{t-1} + \boldsymbol{\varepsilon}_t$, x_j causa en el sentido de Granger a x_i si $A_{ij} \neq 0$. Es decir, el pasado de x_j ayuda a predecir x_i aun con el pasado de las demás.



Seis series, $T = 300$, un lasso por fila. Se recuperan los ceros de $\mathbf{A}$. Con K series y L rezagos hay $K^2 L$ coeficientes, y la dispersión es indispensable.

Esta causalidad sólo mide mejora en la predicción. Una serie no medida que influye en dos crea flechas. Un muestreo más lento que la dinámica, como en resonancia funcional, puede invertirlas.

Efecto de un tratamiento con muchos controles

El modelo es $y = \alpha d + \mathbf{x}^\top \boldsymbol{\theta}_y + e$, con tratamiento $d = \mathbf{x}^\top \boldsymbol{\theta}_d + v$. Se quiere estimar α controlando por los confusores entre p variables.

Efecto de un tratamiento con muchos controles


El modelo es $y = \alpha d + \mathbf{x}^\top \boldsymbol{\theta}_y + e$, con tratamiento $d = \mathbf{x}^\top \boldsymbol{\theta}_d + v$. Se quiere estimar α controlando por los confusores entre p variables.

La selección ingenua ajusta el lasso de y sobre $(d, \mathbf{x})$ sin penalizar d . Un confusor con efecto pequeño sobre y y grande sobre d se anula, porque d ya lo representa. Su efecto pasa a $\hat{\alpha}$. La doble selección de Belloni, Chernozhukov y Hansen (2014) une los soportes de dos lasso, y sobre $\mathbf{x}$ y d sobre $\mathbf{x}$. Luego estima α por mínimos cuadrados con la unión.

Efecto de un tratamiento con muchos controles

El modelo es $y = \alpha d + \mathbf{x}^\top \boldsymbol{\theta}_y + e$, con tratamiento $d = \mathbf{x}^\top \boldsymbol{\theta}_d + v$. Se quiere estimar α controlando por los confusores entre p variables.

La selección ingenua ajusta el lasso de y sobre $(d, \mathbf{x})$ sin penalizar d . Un confusor con efecto pequeño sobre y y grande sobre d se anula, porque d ya lo representa. Su efecto pasa a $\hat{\alpha}$. La doble selección de Belloni, Chernozhukov y Hansen (2014) une los soportes de dos lasso, y sobre $\mathbf{x}$ y d sobre $\mathbf{x}$. Luego estima α por mínimos cuadrados con la unión.



Estimador	Media de $\hat{\alpha}$	Sesgo	Desviación estándar
Selección ingenua	0,706	0,206	0,034
Doble selección	0,499	−0,001	0,074
Oráculo	0,499	−0,001	0,074


Otras aplicaciones

Descubrimiento de ecuaciones

SINDy (Brunton, Proctor y Kutz, 2016). Se observa $z(t)$ y se estiman las derivadas. Se regresa $\dot{z}$ sobre una biblioteca de funciones candidatas $\Theta(z) = [1, x, y, x^2, xy, \dots]$. Se espera que cada ecuación use pocas, $\dot{z} = \Theta(z)\Xi$ con Ξ disperso.

Descubrimiento de ecuaciones

SINDy (Brunton, Proctor y Kutz, 2016). Se observa $z(t)$ y se estiman las derivadas. Se regresa $\dot{z}$ sobre una biblioteca de funciones candidatas $\Theta(z) = [1, x, y, x^2, xy, \dots]$. Se espera que cada ecuación use pocas, $\dot{z} = \Theta(z)\Xi$ con Ξ disperso.



Datos con ruido del modelo de Lotka y Volterra, desde cuatro condiciones iniciales. Mínimos cuadrados da los diez términos distintos de cero. La regresión dispersa por umbral secuencial identifica

$$\dot{x} = 0,667 x - 1,335 xy, \quad \dot{y} = -0,999 y + 0,999 xy$$

frente a la verdad $\dot{x} = 0,667 x - 1,333 xy, \dot{y} = -y + xy$. Una sola órbita no basta, porque sobre una curva cerrada los términos de la biblioteca son colineales.

Resumen de aplicaciones

Problema	Qué es disperso	Penalización
Biomarcadores, $p \gg n$	Genes o variantes con efecto	Lasso, elastic net
Eventos neuronales, calcio y BOLD	Eventos bajo una convolución	Lasso con diseño de convolución
Clasificación	Coeficientes logísticos	ℓ_1 sobre la verosimilitud
Compleción de matrices, recomendación	Los valores singulares	Norma nuclear
Detección de atípicos	Desplazamiento por observación	ℓ_1 sobre los desplazamientos
Componentes interpretables	Las cargas	PCA disperso
Compresión de redes neuronales	Pesos o neuronas	ℓ_1 , group lasso
Resonancia y tomografía rápidas	Gradiente u ondículas	Variación total
Ecuaciones de un sistema dinámico	Términos de la biblioteca	Umbral secuencial
Estructura y conectividad	Aristas del grafo	Lasso por nodo, lasso gráfico

Resumen de aplicaciones

Problema	Qué es disperso	Penalización
Biomarcadores, $p \gg n$	Genes o variantes con efecto	Lasso, elastic net
Eventos neuronales, calcio y BOLD	Eventos bajo una convolución	Lasso con diseño de convolución
Clasificación	Coeficientes logísticos	ℓ_1 sobre la verosimilitud
Compleción de matrices, recomendación	Los valores singulares	Norma nuclear
Detección de atípicos	Desplazamiento por observación	ℓ_1 sobre los desplazamientos
Componentes interpretables	Las cargas	PCA disperso
Compresión de redes neuronales	Pesos o neuronas	ℓ_1 , group lasso
Resonancia y tomografía rápidas	Gradiente u ondículas	Variación total
Ecuaciones de un sistema dinámico	Términos de la biblioteca	Umbral secuencial
Estructura y conectividad	Aristas del grafo	Lasso por nodo, lasso gráfico

Todas usan la misma idea. Un problema subdeterminado o ruidoso se vuelve resoluble si se declara qué debe ser disperso. La zona muerta del umbral suave produce los ceros.

Cierre

Errores frecuentes

Error	Corrección
Penalizar variables en escalas distintas	Estandarizar dentro del pliegue
Usar $\lambda_{\min}$ para elegir variables	Regla de un error estándar o selección por estabilidad
Tomar una variable anulada como irrelevante	Verificar irrepresentabilidad, estabilidad y elastic net
Tomar los coeficientes del lasso como efectos	Están encogidos; reajuste o lasso adaptativo
Reportar valores p de las variables seleccionadas	Partición, inferencia selectiva, <i>knockoffs</i>
Penalizar por separado las indicadoras de un factor	Group lasso con grupos ortonormalizados
Elegir controles que predicen la respuesta para estimar un efecto	Doble selección
Tomar el grafo de vecindarios como causal	Colisionadores y equivalencia de Markov
Tomar la causalidad de Granger como causalidad	Confusores no medidos y frecuencia de muestreo
Usar la norma ℓ_2 mínima con una señal dispersa	Norma ℓ_1 o variación total

Resultado del caso

Modelo	Variables	ECM de entrenamiento	ECM, pacientes nuevos
A, mínimos cuadrados	30	0,16	4,80
B, las tres de la literatura	3	0,98	1,54
Ridge, $\lambda_{\min}$	30	0,26	2,04
Lasso, $\lambda_{1 \text{ EE}}$	10	0,57	1,31
Lasso relajado	9	0,40	1,49
Elastic net, $\alpha = 0,5$	21	0,25	1,78
Lasso adaptativo	12	0,41	1,45

Resultado del caso

Modelo	Variables	ECM de entrenamiento	ECM, pacientes nuevos
A, mínimos cuadrados	30	0,16	4,80
B, las tres de la literatura	3	0,98	1,54
Ridge, $\lambda_{\min}$	30	0,26	2,04
Lasso, $\lambda_{1 \text{ EE}}$	10	0,57	1,31
Lasso relajado	9	0,40	1,49
Elastic net, $\alpha = 0,5$	21	0,25	1,78
Lasso adaptativo	12	0,41	1,45

El lasso con la regla de un error estándar obtiene 1,31. Es el procedimiento más cercano al oráculo, 1,11.

Trabaja con las 30 variables, sin la lista de la literatura. Encuentra las cuatro verdaderas, incluida la de efecto 0,4 que el modelo B omitió.

Resultado del caso

Modelo	Variables	ECM de entrenamiento	ECM, pacientes nuevos
A, mínimos cuadrados	30	0,16	4,80
B, las tres de la literatura	3	0,98	1,54
Ridge, $\lambda_{\min}$	30	0,26	2,04
Lasso, $\lambda_{1\text{ EE}}$	10	0,57	1,31
Lasso relajado	9	0,40	1,49
Elastic net, $\alpha = 0,5$	21	0,25	1,78
Lasso adaptativo	12	0,41	1,45

El lasso con la regla de un error estándar obtiene 1,31. Es el procedimiento más cercano al oráculo, 1,11.

Trabaja con las 30 variables, sin la lista de la literatura. Encuentra las cuatro verdaderas, incluida la de efecto 0,4 que el modelo B omitió.

Con $n = 40$, las variantes no mejoran al lasso. El relajado reajusta falsos positivos. El adaptativo hereda el ruido de ridge. El elastic net admite 21 variables, sin grupos que lo justifiquen. Cada variante corrige un defecto específico y sólo conviene si ese defecto está presente.

Referencias

- Hastie, T., Tibshirani, R., Wainwright, M. (2015). *Statistical Learning with Sparsity: The Lasso and Generalizations*. CRC Press.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *JRSS B*, 58(1), 267–288.
- Zou, H., Hastie, T. (2005). Regularization and variable selection via the elastic net. *JRSS B*, 67(2), 301–320.
- Zou, H. (2006). The adaptive lasso and its oracle properties. *JASA*, 101(476), 1418–1429.
- Yuan, M., Lin, Y. (2006). Model selection and estimation in regression with grouped variables. *JRSS B*, 68(1), 49–67.
- Zou, H., Hastie, T., Tibshirani, R. (2007). On the degrees of freedom of the lasso. *Annals of Statistics*, 35(5), 2173–2192.
- Meinshausen, N. (2007). Relaxed lasso. *Computational Statistics & Data Analysis*, 52(1), 374–393.
- Zhao, P., Yu, B. (2006). On model selection consistency of lasso. *JMLR*, 7, 2541–2563.
- Bickel, P., Ritov, Y., Tsybakov, A. (2009). Simultaneous analysis of lasso and Dantzig selector. *Annals of Statistics*, 37(4), 1705–1732.
- Meinshausen, N., Bühlmann, P. (2010). Stability selection. *JRSS B*, 72(4), 417–473.
- Lee, J. D., Sun, D. L., Sun, Y., Taylor, J. E. (2016). Exact post-selection inference, with application to the lasso. *Annals of Statistics*, 44(3), 907–927.
- Barber, R. F., Candès, E. J. (2015). Controlling the false discovery rate via knockoffs. *Annals of Statistics*, 43(5), 2055–2085.

Referencias (continuación)

- Tibshirani, R., Saunders, M., Rosset, S., Zhu, J., Knight, K. (2005). Sparsity and smoothness via the fused lasso. *JRSS B*, 67(1), 91–108.
- Candès, E. J., Romberg, J., Tao, T. (2006). Robust uncertainty principles. *IEEE Transactions on Information Theory*, 52(2), 489–509.
- Donoho, D. L. (2006). Compressed sensing. *IEEE Transactions on Information Theory*, 52(4), 1289–1306.
- Donoho, D. L., Tanner, J. (2009). Observed universality of phase transitions in high-dimensional geometry. *Phil. Trans. R. Soc. A*, 367, 4273–4293.
- Lustig, M., Donoho, D., Pauly, J. M. (2007). Sparse MRI. *Magnetic Resonance in Medicine*, 58(6), 1182–1195.
- Chambolle, A., Pock, T. (2011). A first-order primal-dual algorithm for convex problems with applications to imaging. *J. Math. Imaging Vision*, 40, 120–145.
- Meinshausen, N., Bühlmann, P. (2006). High-dimensional graphs and variable selection with the lasso. *Annals of Statistics*, 34(3), 1436–1462.
- Friedman, J., Hastie, T., Tibshirani, R. (2008). Sparse inverse covariance estimation with the graphical lasso. *Biostatistics*, 9(3), 432–441.
- Zheng, X., Aragam, B., Ravikumar, P., Xing, E. P. (2018). DAGs with NO TEARS. *NeurIPS*.
- Belloni, A., Chernozhukov, V., Hansen, C. (2014). Inference on treatment effects after selection among high-dimensional controls. *Review of Economic Studies*, 81(2), 608–650.
- Bondell, H. D., Reich, B. J. (2009). Simultaneous factor selection and collapsing levels in ANOVA. *Biometrics*, 65(1), 169–177.
- Brunton, S. L., Proctor, J. L., Kutz, J. N. (2016). Discovering governing equations from data by sparse identification of nonlinear dynamical systems. *PNAS*, 113(15), 3932–3937.