

Regresión heterocedástica por máxima verosimilitud

Unidad 5. Predecir la media y la varianza punto a
punto

Alejandro Veloz


INF396 - Introducción a la Ciencia de Datos



Objetivos

- Escribir la log verosimilitud gaussiana con una varianza que depende de las entradas. Ver mínimos cuadrados como el caso de varianza constante.
- Modelar la media y el logaritmo de la varianza como dos regresiones lineales sobre bases de funciones.
- Derivar las condiciones de optimalidad. Obtener de ellas un algoritmo que alterna mínimos cuadrados ponderados y un paso de Fisher.
- Elegir la complejidad de la media y de la varianza por validación cruzada de la log verosimilitud.
- Construir intervalos de predicción con la varianza del ruido y la varianza de la media estimada. Medir su cobertura en datos nuevos.
- Reconocer los límites del método, como la verosimilitud no acotada, el sesgo de la varianza máximo verosímil y el supuesto gaussiano.

Ruido que cambia con x



Los datos siguen $y = \mu(x) + \sigma(x) \varepsilon$, con $\varepsilon \sim N(0, 1)$ y $\sigma(x) = 0,06 + 0,5 x^2$. La media es $\mu(x) = \sin 2\pi x + 0,25 \cos 6\pi x$. La desviación estándar crece casi diez veces en el dominio.

Mínimos cuadrados estima bien la media. Sin embargo, resume el ruido en una sola cifra $\hat{\sigma}^2$. Esa cifra sobrestima la varianza a la izquierda y la subestima a la derecha.

La verosimilitud gaussiana completa

Sean $y_i \mid x_i \sim N(\mu(x_i), \sigma^2(x_i))$ independientes. La log verosimilitud negativa es

$$\ell = \frac{1}{2} \sum_{i=1}^n \left[\log 2\pi + \log \sigma^2(x_i) + \frac{(y_i - \mu(x_i))^2}{\sigma^2(x_i)} \right].$$

Si $\sigma^2(x) = \sigma^2$ es constante, el segundo término no depende de μ . Entonces minimizar ℓ en μ equivale a minimizar $\sum_i (y_i - \mu(x_i))^2$.

Si σ^2 depende de x , aparecen dos efectos.

- Cada residuo pesa según la precisión $1/\sigma^2(x_i)$ de su observación.
- El término $\log \sigma^2(x_i)$ penaliza una varianza grande. El cociente penaliza una varianza cercana a cero. La varianza óptima en cada punto equilibra ambos términos.

El modelo heterocedástico

La media y el logaritmo de la varianza son dos regresiones lineales sobre bases de funciones,

$$\mu(x) = z(x)^\top \beta, \quad \log \sigma^2(x) = w(x)^\top \gamma.$$

Las bases son $z(x) = (T_0(u), \dots, T_d(u))$ y $w(x) = (T_0(u), \dots, T_q(u))$, polinomios de Chebyshev en $u = 2x - 1$.

- El logaritmo garantiza $\sigma^2(x) > 0$ sin restricciones sobre γ .
- Con $q = 0$ el modelo es homocedástico, con $\sigma^2 = e^{\gamma_0}$.
- Los efectos sobre la varianza son multiplicativos, $\sigma^2(x) = \prod_k e^{\gamma_k T_k(u)}$. Así suele variar la dispersión de una medición.
- El modelo tiene $(d + 1) + (q + 1)$ parámetros. Los grados d y q son dos hiperparámetros distintos.

La log verosimilitud negativa y sus derivadas

Con $s_i = w_i^\top \gamma$ y $r_i = y_i - z_i^\top \beta$,

$$\ell(\beta, \gamma) = \frac{1}{2} \sum_{i=1}^n [s_i + r_i^2 e^{-s_i}] + \text{cte.}$$

Las derivadas son

$$\frac{\partial \ell}{\partial \beta} = - \sum_{i=1}^n e^{-s_i} r_i z_i, \quad \frac{\partial \ell}{\partial \gamma} = \frac{1}{2} \sum_{i=1}^n (1 - r_i^2 e^{-s_i}) w_i.$$

La primera derivada se anula si los residuos ponderados por la precisión son ortogonales a la base de la media. La segunda se anula si los residuos estandarizados al cuadrado, $r_i^2 / \hat{\sigma}^2(x_i)$, valen uno en promedio en cada dirección de la base de la varianza.

Mínimos cuadrados ponderados con γ fijo

Si las varianzas $\sigma_i^2 = e^{s_i}$ son conocidas, la ecuación $\partial \ell / \partial \beta = 0$ es lineal en β ,

$$\hat{\beta} = (Z^\top \Sigma^{-1} Z)^{-1} Z^\top \Sigma^{-1} y, \quad \Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_n^2).$$

Es el estimador de mínimos cuadrados ponderados con pesos $1/\sigma_i^2$. Su varianza es

$$\text{Var}(\hat{\beta}) = (Z^\top \Sigma^{-1} Z)^{-1}.$$

Teorema de Aitken (1935). Si los errores no están correlacionados y tienen varianzas σ_i^2 , el estimador ponderado tiene la menor varianza entre los lineales insesgados. Mínimos cuadrados ordinarios es insesgado, pero no tiene varianza mínima.

Paso de Fisher para γ con β fijo

Con los residuos fijos, la segunda derivada de cada sumando respecto de s_i es $\frac{1}{2}r_i^2 e^{-s_i}$. Su esperanza vale $\frac{1}{2}$. Entonces la información de Fisher para γ es $\frac{1}{2}W^\top W$. El paso de Newton con esa matriz es



$$\gamma \leftarrow \gamma + (W^\top W)^{-1} W^\top (\tilde{r}^2 - 1), \quad \tilde{r}_i^2 = r_i^2 e^{-s_i}.$$

La corrección de γ es una regresión por mínimos cuadrados. La respuesta es $\tilde{r}^2 - 1$ y los regresores son la base de la varianza. Si la varianza predicha es correcta, $\tilde{r}^2 - 1$ tiene media cero en todo el dominio y la corrección se anula.


Algoritmo y convergencia

1. Ajustar $\hat{\beta}$ por mínimos cuadrados ordinarios y fijar $\gamma = (\log \overline{r^2}, 0, \dots, 0)$.
2. Calcular las precisiones $e^{-w_i^\top \gamma}$ y actualizar $\hat{\beta}$ por mínimos cuadrados ponderados.
3. Calcular los residuos y dar un paso de Fisher en γ .
4. Repetir 2 y 3 hasta que ℓ deje de bajar.

El algoritmo alternado alcanza la precisión de la máquina en 8 iteraciones. El descenso de gradiente sobre (β, γ) con $\alpha = 0,01$ necesita unas 4 600 para quedar a 10^{-6} del óptimo. Con $\alpha = 0,02$ el gradiente ya no desciende en forma monótona. Adam llega en unas 4 200 y luego oscila, porque su paso no decrece.



Elección de d y q por validación cruzada




El error cuadrático de validación no evalúa la varianza predicha. Por eso no puede elegir q . La log verosimilitud negativa en los pliegues evalúa la distribución completa. Es una regla de puntuación propia, cuyo valor esperado es mínimo en la distribución verdadera.

Con cinco pliegues, el mínimo está en $d = 10$ y $q = 1$. Ese modelo supera al mejor homocedástico por 0,43 nats por observación. Los grados $q > 1$ no mejoran.


Intervalos de predicción

Una observación nueva en x difiere de $\hat{\mu}(x)$ por el ruido y por el error al estimar la media.
Por eso,

$$\text{Var}(y - \hat{\mu}(x)) \approx \underbrace{\hat{\sigma}^2(x)}_{\text{ruido}} + \underbrace{z(x)^\top (Z^\top \hat{\Sigma}^{-1} Z)^{-1} z(x)}_{\text{estimación}}.$$





La desviación estándar estimada



Con $q = 1$, el modelo es $\log \hat{\sigma}^2(x) = \hat{\gamma}_0 + \hat{\gamma}_1(2x - 1)$, con $\hat{\gamma}_0 = -3,40$ y $\hat{\gamma}_1 = 2,42$. La desviación estándar estimada pasa de 0,05 en $x = 0$ a 0,61 en $x = 1$. Los valores verdaderos son 0,06 y 0,56.

La curva verdadera $\sigma(x) = 0,06 + 0,5 x^2$ no es log-lineal. Aun así, una recta en el logaritmo la aproxima bien. Los residuos absolutos individuales son muy dispersos, y el modelo de la varianza los promedia.


Calibración sobre datos nuevos



Modelo	Grados (d, q)	Log verosim. neg.	Cobertura 95 %	Cobertura $x < 0,2$	Cobertura $x > 0,8$
Varianza constante	(10, 0)	0,132	0,930	1,000	0,745
Varianza modelada	(10, 1)	-0,285	0,956	0,964	0,962

El intervalo homocedástico tiene una cobertura global de 0,93, cercana a la nominal. Esa cifra promedia una cobertura de 1 en la zona de poco ruido y de 0,75 en la de mucho ruido.

La media estimada



En 500 muestras de entrenamiento con $d = 10$, la ponderación reduce a la mitad o menos la varianza de $\hat{\mu}(x)$ donde el ruido es pequeño. Donde el ruido es grande, la varianza no cambia. Así lo predice el teorema de Aitken.

El error cuadrático integrado de la media cambia poco, de 0,0042 a 0,0041. Modelar la varianza mejora sobre todo la incertidumbre predicha. La media mejora sólo localmente.

Límites del método

- **Verosimilitud no acotada.** Si la media pasa exactamente por un dato y la varianza predicha puede hacerse pequeña en ese punto, $\ell \rightarrow -\infty$ y el máximo no existe. Esto no ocurre con bases rígidas y n grande. Con modelos flexibles, como una red, hay que limitar o regularizar el modelo de la varianza.
- **Sesgo de la varianza.** El estimador máximo verosímil de la varianza no descuenta los parámetros de la media. Con varianza constante, $\hat{\sigma}^2 = \text{RSS}/n$ subestima por el factor $(n - p)/n$. La máxima verosimilitud restringida (REML) corrige ese sesgo.
- **Supuesto gaussiano.** La cobertura del intervalo $\hat{\mu} \pm 1,96 \hat{\sigma}$ depende de las colas normales. Hay que revisar los residuos estandarizados $r_i / \hat{\sigma}(x_i)$. Si sus colas son pesadas, conviene usar una verosimilitud t o estimar cuantiles directamente.
- **Dos incertidumbres.** La varianza $\hat{\sigma}^2(x)$ describe el ruido. La varianza de $\hat{\mu}(x)$ describe el error de estimación. Un intervalo con sólo el ruido es demasiado estrecho donde hay pocos datos.

Implementación

```
def base(x, grado):
    # polinomios de Chebyshev en [0, 1]
    return np.polynomial.chebyshev.chebvander(2*x - 1, grado)

def ajusta(x, y, d, q, n_iter=100, tol=1e-10):
    Z, W = base(x, d), base(x, q)
    beta = np.linalg.lstsq(Z, y, rcond=None)[0] # mínimos cuadrados ordinarios
    gamma = np.zeros(q + 1); gamma[0] = np.log(np.mean((y - Z @ beta)**2))
    for _ in range(n_iter):
        prec = np.exp(-W @ gamma) # 1 / sigma^2(x_i)
        beta = np.linalg.solve(Z.T @ (prec[:, None]*Z), Z.T @ (prec*y))
        paso = np.linalg.solve(W.T @ W, W.T @ ((y - Z @ beta)**2*prec - 1))
        gamma += paso # paso de Fisher
        if np.max(np.abs(paso)) < tol: break
    return beta, gamma

def predice(x_nuevo, beta, gamma, d, q):
    return base(x_nuevo, d) @ beta, np.exp(base(x_nuevo, q) @ gamma) # media y varianza
```

Extensión con redes neuronales

Una red neuronal con dos salidas puede reemplazar las dos bases fijas,

$$\mu(x) = f_1[x, \phi], \quad \log \sigma^2(x) = f_2[x, \phi],$$

y minimizar exactamente la misma función,

$$\ell(\phi) = \frac{1}{2} \sum_{i=1}^n \left[f_2[x_i, \phi] + (y_i - f_1[x_i, \phi])^2 e^{-f_2[x_i, \phi]} \right].$$

La red tiene dos desventajas. No hay solución exacta por bloques, así que el entrenamiento depende del gradiente. Además, la flexibilidad de la red hace más probable la verosimilitud no acotada.

Como ventaja, la red aprende las bases desde los datos. Esto es útil cuando x tiene muchas dimensiones y no hay una base natural.

Referencias

- Aitken, A. C. (1935). On least squares and linear combination of observations. *Proceedings of the Royal Society of Edinburgh*, 55, 42–48.
- Harvey, A. C. (1976). Estimating regression models with multiplicative heteroscedasticity. *Econometrica*, 44(3), 461–465.
- Aitkin, M. (1987). Modelling variance heterogeneity in normal regression using GLIM. *Journal of the Royal Statistical Society C*, 36(3), 332–339.
- Smyth, G. K. (1989). Generalized linear models with varying dispersion. *Journal of the Royal Statistical Society B*, 51(1), 47–60.
- Nix, D. A., Weigend, A. S. (1994). Estimating the mean and variance of the target probability distribution. *Proceedings of the IEEE International Conference on Neural Networks*, 55–60.
- Gneiting, T., Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378.
- Prince, S. J. D. (2023). *Understanding Deep Learning*, sección 5.3. MIT Press.