

Regresión logística

Unidad 5. Clasificación por máxima verosimilitud,
regularización y selección de variables

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos



Objetivos

- Formular la clasificación como la estimación de una probabilidad condicional y derivar la regla de Bayes.
- Reconocer cuándo sirve y cuándo falla la regresión lineal sobre una respuesta binaria.
- Derivar la log verosimilitud logística, su gradiente y su hessiano, y escribir el método de Newton como mínimos cuadrados ponderados iterados.
- Calcular errores estándar y razones de chances, y reconocer la separación completa.
- Regularizar con L2, L1 y por grupos, y elegir la intensidad por validación cruzada.
- Evaluar un clasificador con la matriz de confusión, la curva ROC, la calibración y los costos de los errores.
- Extender el modelo a K clases con la función softmax.
- Seleccionar variables cuando se mezclan variables numéricas y categóricas.

Clasificación y probabilidad condicional

Sea $y \in \{0, 1\}$ la respuesta y $\mathbf{x} \in \mathbb{R}^p$ las entradas. Toda la información de $\mathbf{x}$ sobre y está en

$$p(\mathbf{x}) = \Pr(y = 1 \mid \mathbf{x}) = \mathbb{E}[y \mid \mathbf{x}].$$



Si los dos tipos de error cuestan lo mismo, la **regla de Bayes** minimiza la probabilidad de error,

$$\hat{y}(\mathbf{x}) = 1\{p(\mathbf{x}) > 1/2\},$$

y su error, $\mathbb{E}[\min(p(X), 1 - p(X))]$, se llama riesgo de Bayes y es el menor posible.

La tarea es estimar $p(\mathbf{x})$. La probabilidad estimada sirve para clasificar, mover el umbral si los errores cuestan distinto e informar la incertidumbre de cada predicción.

Regresión lineal sobre una respuesta binaria



Doscientos pacientes reciben dosis entre 0 y 8, con probabilidad de respuesta $\text{sig}(-4 + 1,2x)$. Como $\mathbb{E}[y | x] = p(x)$, la regresión lineal sobre $y \in \{0, 1\}$ estima la probabilidad y se llama **modelo de probabilidad lineal**. Su recta tiene pendiente 0,155 por unidad de dosis. En el 19 % del rango predice probabilidades fuera de $[0, 1]$ (zonas sombreadas).

El modelo de probabilidad lineal

La regresión lineal sobre una respuesta 0/1 tiene tres ventajas.

- Sus coeficientes son diferencias de probabilidad. Aquí la probabilidad sube 0,155 por unidad de dosis.
- Tiene solución cerrada y admite todos los métodos de la regresión lineal, incluidos ridge y lasso.
- Cuando las probabilidades están lejos de 0 y de 1, la sigmoide es casi recta y ambos modelos dan predicciones parecidas.

También tiene tres defectos.

- Predice probabilidades negativas o mayores que uno.
- Supone que cada variable tiene el mismo efecto sobre la probabilidad en todo el rango. Pero una probabilidad cercana a 1 ya no puede aumentar.
- Es heterocedástico, por lo que los errores estándar de mínimos cuadrados no son válidos.

El modelo logístico

Chances y logaritmo de las chances


Las **chances** (odds) de un evento con probabilidad p son $p/(1 - p)$. Van de 0 a ∞ . Su logaritmo es el **logit** y va de $-\infty$ a ∞ .

La regresión logística modela el logit como función lineal,

$$\log \frac{p(\mathbf{x})}{1 - p(\mathbf{x})} = \beta_0 + \boldsymbol{\beta}^\top \mathbf{x},$$

es decir,

$$p(\mathbf{x}) = \text{sig}(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x})}}.$$



β_1 fija la pendiente de la curva y β_0 fija su posición. La frontera $p(\mathbf{x}) = 1/2$ es el hiperplano $\beta_0 + \boldsymbol{\beta}^\top \mathbf{x} = 0$.

Interpretación de los coeficientes

Si x_j aumenta en una unidad y las demás variables quedan fijas, el logit aumenta en β_j . Las chances se multiplican por

$$\frac{\text{chances}(x_j + 1)}{\text{chances}(x_j)} = e^{\beta_j},$$

que es la **razón de chances** (odds ratio) de la variable j .

- Si $\beta_j > 0$ la probabilidad aumenta, si $\beta_j < 0$ disminuye, y si $\beta_j = 0$ la variable no tiene efecto dado el resto.
- El efecto sobre la probabilidad no es constante. Por la derivada de la sigmoide, $\partial p / \partial x_j = \beta_j p(1 - p)$. Es máximo en $p = 1/2$ y nulo en los extremos.
- Para probabilidades pequeñas, la razón de chances se aproxima al riesgo relativo.

Estimación por máxima verosimilitud

La verosimilitud de Bernoulli

Sea $p_i = \text{sig}(\mathbf{x}_i^\top \boldsymbol{\beta})$, con el intercepto en $\mathbf{x}_i = (1, x_{i1}, \dots, x_{ip})$. Cada respuesta tiene probabilidad $p_i^{y_i} (1 - p_i)^{1-y_i}$. Con observaciones independientes, la log verosimilitud negativa es

$$\begin{aligned}\ell(\boldsymbol{\beta}) &= - \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] \\ &= \sum_{i=1}^n \left[\log(1 + e^{z_i}) - y_i z_i \right], \quad z_i = \mathbf{x}_i^\top \boldsymbol{\beta}.\end{aligned}$$

- La primera forma es la **entropía cruzada binaria** entre las etiquetas y las probabilidades predichas.
- La segunda sale de $\log p_i = z_i - \log(1 + e^{z_i})$ y $\log(1 - p_i) = -\log(1 + e^{z_i})$. Es la que se programa, calculando $\log(1 + e^z)$ de forma estable.
- $2\ell(\hat{\boldsymbol{\beta}})$ es la **desviación** del modelo y es análoga a la suma de cuadrados residual.

El gradiente

La sigmoide cumple $\text{sig}'(z) = \text{sig}(z)(1 - \text{sig}(z))$. La derivada del sumando i es

$$\frac{\partial}{\partial \beta} \left[\log(1 + e^{z_i}) - y_i z_i \right] = (\text{sig}(z_i) - y_i) \mathbf{x}_i = (p_i - y_i) \mathbf{x}_i,$$

y en forma matricial, con X de $n \times (p + 1)$,

$$\nabla \ell(\beta) = X^\top (p - y).$$

La ecuación de verosimilitud $X^\top (y - \hat{p}) = 0$ tiene la forma de las ecuaciones normales, $X^\top (y - X\hat{\beta}) = 0$. En ambas, los residuos son ortogonales a las columnas de X . Como p no es lineal en β , no hay solución cerrada.

El hessiano y la convexidad

El hessiano es

$$\nabla^2 \ell(\beta) = \sum_{i=1}^n p_i(1 - p_i) \mathbf{x}_i \mathbf{x}_i^\top = \mathbf{X}^\top \mathbf{W} \mathbf{X}, \quad \mathbf{W} = \text{diag}(p_i(1 - p_i)).$$

Como los pesos son positivos, $\mathbf{v}^\top \mathbf{X}^\top \mathbf{W} \mathbf{X} \mathbf{v} = \sum_i p_i(1 - p_i)(\mathbf{x}_i^\top \mathbf{v})^2 \geq 0$ para todo $\mathbf{v}$. El hessiano es semidefinido positivo y la log verosimilitud negativa es **convexa**.

- No hay mínimos locales. Si existe un mínimo, es global.
- Si $\mathbf{X}$ tiene rango completo y el mínimo existe, es único.
- El peso $p_i(1 - p_i)$ es la varianza de y_i , como en el modelo de probabilidad lineal.

Newton–Raphson y mínimos cuadrados reponderados

El método de Newton minimiza en cada paso la aproximación cuadrática de ℓ ,



$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} - (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{p} - \mathbf{y}).$$

Reordenando,

$$\boldsymbol{\beta}^{(t+1)} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{z}, \quad \mathbf{z} = \mathbf{X} \boldsymbol{\beta}^{(t)} + \mathbf{W}^{-1} (\mathbf{y} - \mathbf{p}).$$

Cada paso es una regresión por **mínimos cuadrados ponderados** de la respuesta de trabajo $\mathbf{z}$ sobre $\mathbf{X}$, con pesos $p_i(1 - p_i)$. Como los pesos cambian en cada iteración, el algoritmo se llama mínimos cuadrados reponderados iterativamente (**IRLS**).

Convergencia



Se ajusta un modelo de cuatro variables a los datos de cáncer de mama de Wisconsin, desde $\beta = 0$. Newton llega a la precisión de máquina en unas ocho iteraciones. Su convergencia es cuadrática y duplica las cifras correctas por paso. El descenso de gradiente necesita cientos o miles de iteraciones según la tasa.

Los datos de cáncer de mama

Hay 569 tumores de mama con diagnóstico confirmado y 212 son malignos (Street, Wolberg y Mangasarian, 1993). Se miden diez características de los núcleos celulares en una imagen digital de la punción (radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal). Cada una se resume por su media, su error estándar y su peor valor, y hay 30 variables.

- La respuesta es $y = 1$ si el tumor es maligno.
- Una partición estratificada fija deja 369 tumores para ajustar y 200 para evaluar.
- Las variables se estandarizan con la media y la desviación estándar del entrenamiento.

El conjunto está en scikit-learn (`load_breast_cancer`).



Inferencia sobre los coeficientes

Para n grande, $\hat{\beta} \approx N(\beta, (X^\top \hat{W} X)^{-1})$. La covarianza es la inversa del hessiano en el óptimo (información de Fisher observada).

Variable	$\hat{\beta}_j$	EE	z	Razón de chances, IC 95 %
Intercepto	-0,68	0,28	-2,4	-
Radio medio	3,68	0,83	4,4	39,64 [7,78; 201,89]
Textura media	1,65	0,34	4,9	5,23 [2,70; 10,14]
Suavidad media	0,87	0,46	1,9	2,39 [0,96; 5,93]
Puntos cóncavos medios	2,97	0,78	3,8	19,41 [4,19; 89,81]

El modelo usa cuatro variables estandarizadas, elegidas antes de ver los datos. Si la textura media sube una desviación estándar y las otras tres quedan fijas, las chances de malignidad se multiplican por 5,2. Su intervalo de 95 % va de 2,7 a 10,1. La suavidad media no es significativa al 5 %.

Separación completa



Con las 30 variables, un hiperplano separa sin error los tumores malignos de los benignos del entrenamiento. Entonces $\ell(c\beta) \rightarrow 0$ al crecer c , y el **estimador de máxima verosimilitud no existe**. El descenso de gradiente reduce la pérdida sin fin y $\|\beta\|$ crece sin cota.

Consecuencias de la separación

Tras 10^5 iteraciones, $\|\hat{\beta}\| = 43$ y sigue creciendo. El error de entrenamiento es cero.

- La frontera clasifica bien en test, con 3 % de error y AUC 0,990.
- Las probabilidades están mal calibradas. La log verosimilitud negativa en test es 0,51 y la del modelo regularizado es 0,08. Los pocos errores ocurren con probabilidades casi 0 o 1.
- Los coeficientes y sus errores estándar crecen sin límite y no se pueden interpretar.

Hay dos remedios habituales.

1. **Regularizar.** La penalización garantiza un mínimo único y finito.
2. Usar la corrección de Firth (1993). Esta penalización usa la información de Fisher, reduce el sesgo de $\hat{\beta}$ y siempre da estimaciones finitas.

Regularización

Regresión logística penalizada

Como en la regresión lineal, se agrega una penalización a la log verosimilitud negativa media,

$$\hat{\beta} = \operatorname{argmin}_{\beta} \frac{1}{n} \ell(\beta) + \lambda P(\beta),$$

con el intercepto sin penalizar y las variables estandarizadas.

Penalización	$P(\beta)$	Efecto
Ridge (L2)	$\frac{1}{2} \sum_j \beta_j^2$	Encoge, siempre existe y es única
Lasso (L1)	$\sum_j \beta_j $	Encoge y anula, selecciona variables
Elastic net	$\alpha \sum_j \beta_j + \frac{1-\alpha}{2} \sum_j \beta_j^2$	Selecciona grupos de variables correlacionadas
Group lasso	$\sum_g \sqrt{p_g} \ \beta_g\ _2$	Selecciona o descarta bloques completos

Ridge es el máximo a posteriori con a priori normal, y el lasso lo es con a priori de Laplace.

Ridge y lasso logísticos

Ridge. La penalización suma $\lambda n \mathbf{I}$ al hessiano, salvo en el intercepto. El paso de Newton es

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} + (\mathbf{X}^\top \mathbf{W} \mathbf{X} + n \lambda \tilde{\mathbf{I}})^{-1} (\mathbf{X}^\top (\mathbf{y} - \mathbf{p}) - n \lambda \tilde{\mathbf{I}} \boldsymbol{\beta}^{(t)}),$$

y el mínimo existe aunque los datos estén separados.


Lasso. La penalización no es diferenciable. El gradiente proximal da un paso de gradiente sobre la parte suave y aplica el umbral suave,

$$\boldsymbol{\beta} \leftarrow S_{\lambda/L} \left(\boldsymbol{\beta} - \frac{1}{L} \nabla \frac{1}{n} \ell(\boldsymbol{\beta}) \right), \quad S_t(v) = \text{sign}(v) \max(|v| - t, 0),$$

con $L = \|\mathbf{X}\|_2^2 / 4n$ como cota de la curvatura. Con variables estandarizadas, todos los coeficientes son nulos para


$$\lambda \geq \lambda_{\max} = \max_j \frac{1}{n} |\mathbf{x}_j^\top (\mathbf{y} - \bar{y})|.$$

Camino de regularización



Se usan las 30 variables de cáncer de mama. Ridge encoge todos los coeficientes en forma continua y, con λ pequeño, los deja crecer hacia la solución separadora. El lasso los incorpora uno a uno. Entran primero los peores valores de los puntos cóncavos, del radio y de la textura.

Elección de λ por validación cruzada



La curva es la desviación media en diez pliegues, con su error estándar. El mínimo (línea punteada) usa 13 variables. La regla de un error estándar (línea discontinua) elige 9 variables. Su desviación no difiere estadísticamente de la del mínimo.

La desviación de validación evalúa las probabilidades. El error de clasificación es más ruidoso, porque sólo cambia cuando un caso cruza el umbral.

Evaluación de clasificadores

La matriz de confusión

Con un umbral c , el clasificador $\hat{y} = 1\{\hat{p}(\mathbf{x}) > c\}$ produce cuatro conteos en un conjunto de evaluación.

	Predicho positivo	Predicho negativo
Positivo	Verdaderos positivos (VP)	Falsos negativos (FN)
Negativo	Falsos positivos (FP)	Verdaderos negativos (VN)

- **Sensibilidad**, $VP/(VP + FN)$, es la fracción de positivos detectados.
- **Especificidad**, $VN/(VN + FP)$, es la fracción de negativos descartados.
- **Valor predictivo positivo**, $VP/(VP + FP)$, es la fracción de alarmas correctas. Depende de la prevalencia.
- **Exactitud**, $(VP + VN)/n$. Engaña con clases desbalanceadas, porque predecir siempre la clase mayoritaria ya la hace alta.

Curva ROC, calibración y reglas de puntuación

Curva ROC. Al variar el umbral c , el par $(1 - \text{especificidad}, \text{sensibilidad})$ recorre una curva. El área bajo ella, el **AUC**, es la probabilidad de que un positivo al azar reciba mayor puntaje que un negativo al azar (estadístico de Mann–Whitney). El AUC mide la capacidad de ordenar y no evalúa las probabilidades.


Calibración. Entre los casos con $\hat{p} \approx 0,8$, el 80 % debería ser positivo. Se revisa agrupando por probabilidad predicha y comparando con la frecuencia observada.

Reglas de puntuación propias. Evalúan las probabilidades y miden a la vez la calibración y la discriminación.

$$-\frac{1}{n} \sum_i [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] \quad (\text{log verosimilitud negativa media}),$$


$$\frac{1}{n} \sum_i (\hat{p}_i - y_i)^2 \quad (\text{puntaje de Brier}).$$

Evaluación en test



Modelo	Error	AUC	Log verosim. neg.	Brier
Sin regularizar (separación)	0,030	0,990	0,51	0,027
Ridge, $\lambda = 10^{-2}$	0,015	0,992	0,08	0,019
Lasso, λ_{1EE}	0,020	0,991	0,10	0,022
Cuatro variables	0,050	0,981	0,16	0,046

El umbral y el costo de los errores



Sea C_{FN} el costo de un falso negativo y C_{FP} el de un falso positivo. Con probabilidades calibradas, el umbral óptimo es $c^* = C_{FP} / (C_{FP} + C_{FN})$, que aquí vale $1/11$. En este test, el umbral teórico no reduce el costo. Con $c = 0,5$ la sensibilidad ya es $0,97$, y bajar a $1/11$ detecta un cáncer más y agrega 24 falsas alarmas. El umbral se elige con los costos y con datos de validación. La fórmula vale sólo con probabilidades calibradas.

Más de dos clases

Regresión softmax

Sea $y \in \{1, \dots, K\}$, con un vector de coeficientes β_k por clase. La función softmax da

$$\Pr(y = k \mid \mathbf{x}) = \frac{\exp(\mathbf{x}^\top \beta_k)}{\sum_{k'=1}^K \exp(\mathbf{x}^\top \beta_{k'})}.$$

- Sumar el mismo vector a todos los β_k no cambia las probabilidades. Para eliminar esta indeterminación, se fija una clase de referencia, $\beta_K = 0$, o se penaliza.
- Con $K = 2$ y $\beta_2 = 0$ se recupera la regresión logística, con $\beta = \beta_1$.
- El logaritmo del cociente de probabilidades de dos clases es lineal, $\log \frac{\Pr(y=k|\mathbf{x})}{\Pr(y=K|\mathbf{x})} = \mathbf{x}^\top \beta_k$. Las fronteras entre clases son hiperplanos.

Verosimilitud y gradiente multiclase

Sea Y la codificación one-hot ($n \times K$, un uno por fila en la columna de la clase) y P la matriz de probabilidades predichas. La log verosimilitud negativa es la **entropía cruzada multiclase**,


$$\ell(B) = - \sum_{i=1}^n \log P_{iy_i} = \sum_{i=1}^n \left[\log \sum_k e^{\mathbf{x}_i^\top \boldsymbol{\beta}_k} - \mathbf{x}_i^\top \boldsymbol{\beta}_{y_i} \right],$$

y su gradiente respecto de la matriz $B = [\boldsymbol{\beta}_1, \dots, \boldsymbol{\beta}_K]$ es

$$\nabla_B \ell = X^\top (P - Y).$$


El gradiente tiene la forma del caso binario. La función es convexa y su hessiano tiene bloques $X^\top W_{kk'} X$ con $W_{kk'} = \text{diag}(P_{ik}(\delta_{kk'} - P_{ik'}))$. Con pK grande, se minimiza con L-BFGS.

Dígitos manuscritos



Se ajusta una regresión softmax sobre los 64 píxeles de 1 000 dígitos de 8×8 , con L2 elegida por validación cruzada. Cada imagen muestra los pesos β_k de una clase. Más intensidad en un píxel rojo aumenta las chances de esa clase, y en uno azul las disminuye. El cero tiene pesos positivos en el anillo y negativos en el centro.

Evaluación con los dígitos



En 797 dígitos de test el error es 3,4 %, igual al error de scikit-learn con la misma penalización.

El modelo es lineal en los píxeles y tiene 650 parámetros.

Los errores más frecuentes son ochos predichos como nueves o como unos, y treses predichos como ochos.

Un caso con variables mixtas

Reingreso hospitalario a 30 días

Los datos son simulados y la verdad es conocida. Hay 600 pacientes egresados y el 36 % reingresa antes de 30 días. Las variables numéricas tienen correlaciones realistas (la hemoglobina con la creatinina, los fármacos con los días de hospitalización). Por eso hay variables sin efecto asociadas con variables con efecto.

Ocho de las 21 variables tienen efecto. Con la codificación de referencia, las 14 numéricas y los 7 factores ocupan 31 columnas.

El objetivo es predecir el reingreso de pacientes nuevos e identificar las variables asociadas con él. La mitad de las variables numéricas y tres de los siete factores no tienen efecto.

Las variables

Variable	Tipo	Niveles o unidad	Efecto verdadero
Edad	Numérica	Años	Sí
Creatinina	Numérica	mg/dL	Sí
Hemoglobina	Numérica	g/dL	No
Días	Numérica	Días de hospitalización	Sí
Fármacos	Numérica	Número al alta	Sí
Ingreso	Categórica	Electivo, Derivado, Urgencia	Sí
Servicio	Categórica	Medicina, Cardiología, Cirugía, Traumatología	Sí
Tabaquismo	Categórica	Nunca, Actual, Ex	Sí
Previsión	Categórica	Isapre, Fonasa A-B, Fonasa C-D	Sí
Sexo	Categórica	Mujer, Hombre	No
Región	Categórica	RM, Austral, Centro, Norte, Sur	No
Estado civil	Categórica	Casado, Separado, Soltero, Viudo	No
IMC, PAS, HbA1c, sodio, potasio, FC, colesterol, plaquetas, temperatura	Numérica	–	No

Variables categóricas en la regresión logística

Un factor con L niveles se representa con $L - 1$ columnas indicadoras, una por nivel distinto del de referencia. El coeficiente de cada columna es el logaritmo de la razón de chances de ese nivel frente a la referencia.

Ingreso	Urgencia	Derivado
Electivo (referencia)	0	0
Urgencia	1	0
Derivado	0	1

El lasso sobre las columnas tiene dos problemas para seleccionar factores.

- Puede retener sólo algunos niveles de un factor. Lo que interesa saber es si el factor completo tiene efecto.
- Las columnas retenidas dependen del nivel de referencia, y esa elección es arbitraria.

Group lasso


Las columnas se agrupan por variable, $\beta = (\beta_1, \dots, \beta_G)$, con un grupo por variable numérica y uno por factor.

El estimador es

$$\hat{\beta} = \operatorname{argmin}_{\beta} \frac{1}{n} \ell(\beta) + \lambda \sum_{g=1}^G \sqrt{p_g} \|\beta_g\|_2.$$

- La norma euclídea sin elevar al cuadrado no es diferenciable en $\beta_g = 0$. Por eso anula grupos completos, como el valor absoluto anula coeficientes.
- El group lasso actúa como ridge dentro de un grupo seleccionado. Todos los niveles del factor entran juntos.
- El factor $\sqrt{p_g}$ evita favorecer a los factores con más niveles.
- El paso proximal es un umbral suave por bloques, $\beta_g \leftarrow (1 - t\sqrt{p_g}/\|v_g\|)_+ v_g$.

Camino con variables mixtas



Las columnas de las ocho variables con efecto están en color y las demás en gris. El group lasso hace entrar juntas las columnas de cada factor. En ambos métodos, las variables con efecto entran antes que las demás. La excepción son algunas columnas de factores con efectos pequeños.

Nivel de referencia y lasso

Factor (columnas)	Lasso, ref. 1	Lasso, ref. 2	Group lasso, ref. 1	Group lasso, ref. 2
Ingreso (2)	1	1	2	2
Servicio (3)	2	1	3	3
Tabaquismo (2)	1	1	2	2
Previsión (2)	1	2	2	2
Sexo (1)	0	0	0	0
Región (4)	0	0	0	0
Estado civil (3)	0	0	0	0


Se cuentan las columnas retenidas de cada factor en λ_{1EE} , con dos elecciones de los niveles de referencia. El lasso retiene un número distinto de columnas de Servicio y de Previsión según la referencia, y casi nunca las retiene todas. El group lasso retiene o descarta cada factor completo y decide igual con ambas referencias.

Resultados de la selección

Estimador	Verdaderas	Falsas	AUC	Brier
Lasso logístico	8 de 8	2	0,740	0,1882
Group lasso logístico	8 de 8	3	0,736	0,1892
Lasso lineal (prob. lineal)	8 de 8	0	0,736	0,1899
Group lasso lineal (prob. lineal)	8 de 8	3	0,736	0,1899
Oráculo, máxima verosimilitud	8 de 8	0	0,753	0,1880
Todas, máxima verosimilitud	8 de 8	13	0,741	0,1952
Probabilidad verdadera	–	–	0,768	0,1789

Se usan diez pliegues y la regla de un error estándar. El AUC y el Brier se miden en 20 000 pacientes nuevos. Todos los estimadores recuperan las ocho variables con efecto. Todos salvo el lasso lineal retienen dos o tres sin efecto (frecuencia cardiaca, temperatura, IMC). El oráculo conoce las ocho variables y su AUC difiere del resto en 0,01 a 0,02. El modelo con las 21 variables sin penalizar tiene peor Brier que el lasso (0,195 frente a 0,188).

Estabilidad de la selección



Se mide la frecuencia con que se selecciona cada variable en 100 submuestras de 300 pacientes. Con los tres métodos, las ocho variables con efecto aparecen en más del 90 % de las submuestras. La frecuencia cardiaca y el IMC aparecen en la mitad o más. Los métodos difieren en los factores sin efecto. El lasso retiene alguna columna de Región en el 56 % de las submuestras y el group lasso sólo en el 23 %.

Regresión lineal frente a logística

En este caso, el lasso lineal sobre la respuesta 0/1 seleccionó las mismas ocho variables y menos variables sin efecto. Su AUC fue 0,736 y el del lasso logístico fue 0,740. Con probabilidades entre 0,1 y 0,7 la sigmoide es casi lineal, y por eso ambos modelos ordenan las variables de modo parecido.

Para seleccionar variables o estimar efectos promedio, la regresión lineal sobre 0/1 es un punto de partida aceptable, sobre todo con probabilidades moderadas. Sus coeficientes son diferencias de probabilidad.

Para predecir probabilidades, la logística es la opción correcta. Sus predicciones quedan en $[0, 1]$, su varianza es la de una Bernoulli y está calibrada por construcción en el entrenamiento. Con eventos raros o probabilidades cercanas a 0 o 1, los dos modelos difieren mucho.

Combinarlas significa seleccionar con el modelo lineal y luego ajustar una logística con las variables elegidas. Esto no mejora al lasso logístico, que selecciona con la misma verosimilitud que usa para predecir.

Implementación

```
import numpy as np
from sklearn.linear_model import LogisticRegression, LogisticRegressionCV

def irls(X, y, n_iter=50):                                # X con una columna de unos
    b = np.zeros(X.shape[1])
    for _ in range(n_iter):
        p = 1/(1 + np.exp(-X @ b)); w = p*(1 - p)
        b = b + np.linalg.solve(X.T @ (w[:, None]*X), X.T @ (y - p))    # paso de Newton
    return b

# scikit-learn: C = 1/(n*lambda); el intercepto no se penaliza
ridge = LogisticRegression(C=1.0)                        # L2
lasso = LogisticRegressionCV(Cs=30, penalty="l1", solver="saga", cv=10,
                             scoring="neg_log_loss", max_iter=10000)    # L1, lambda por VC
softmax = LogisticRegression(C=1.0)                      # con y de K clases ajusta el modelo multinomial
```

Errores frecuentes

- Usar la exactitud con clases desbalanceadas, o evaluar con el AUC un modelo cuyas probabilidades se van a usar.
- Elegir el umbral o λ con el conjunto de test.
- Interpretar un coeficiente enorme con un error estándar enorme, sin revisar si hay separación.
- Interpretar la razón de chances como riesgo relativo cuando el evento es frecuente.
- No estandarizar antes de penalizar. En ese caso la penalización depende de las unidades de medida.
- Seleccionar niveles sueltos de un factor con el lasso y olvidar que el resultado depende de la referencia.
- Reportar como estimaciones de los efectos los coeficientes del lasso, que están encogidos hacia cero. La inferencia debe corregir por la selección.

Referencias

- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*, 2.^a ed., secciones 4.4 y 18.4. Springer.
- Hastie, T., Tibshirani, R., Wainwright, M. (2015). *Statistical Learning with Sparsity*, capítulos 3 y 4. CRC Press.
- Agresti, A. (2013). *Categorical Data Analysis*, 3.^a ed., capítulos 4 a 7. Wiley.
- McCullagh, P., Nelder, J. A. (1989). *Generalized Linear Models*, 2.^a ed. Chapman and Hall.
- Firth, D. (1993). Bias reduction of maximum likelihood estimates. *Biometrika*, 80(1), 27–38.
- Meier, L., van de Geer, S., Bühlmann, P. (2008). The group lasso for logistic regression. *JRSS B*, 70(1), 53–71.
- Beck, A., Teboulle, M. (2009). A fast iterative shrinkage-thresholding algorithm for linear inverse problems. *SIAM Journal on Imaging Sciences*, 2(1), 183–202.
- Street, W. N., Wolberg, W. H., Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. *Proceedings of SPIE*, 1905, 861–870.