Regresión logística I

Unidad 5. El modelo, su estimación por máxima verosimilitud y la evaluación de un clasificador

Alejandro Veloz

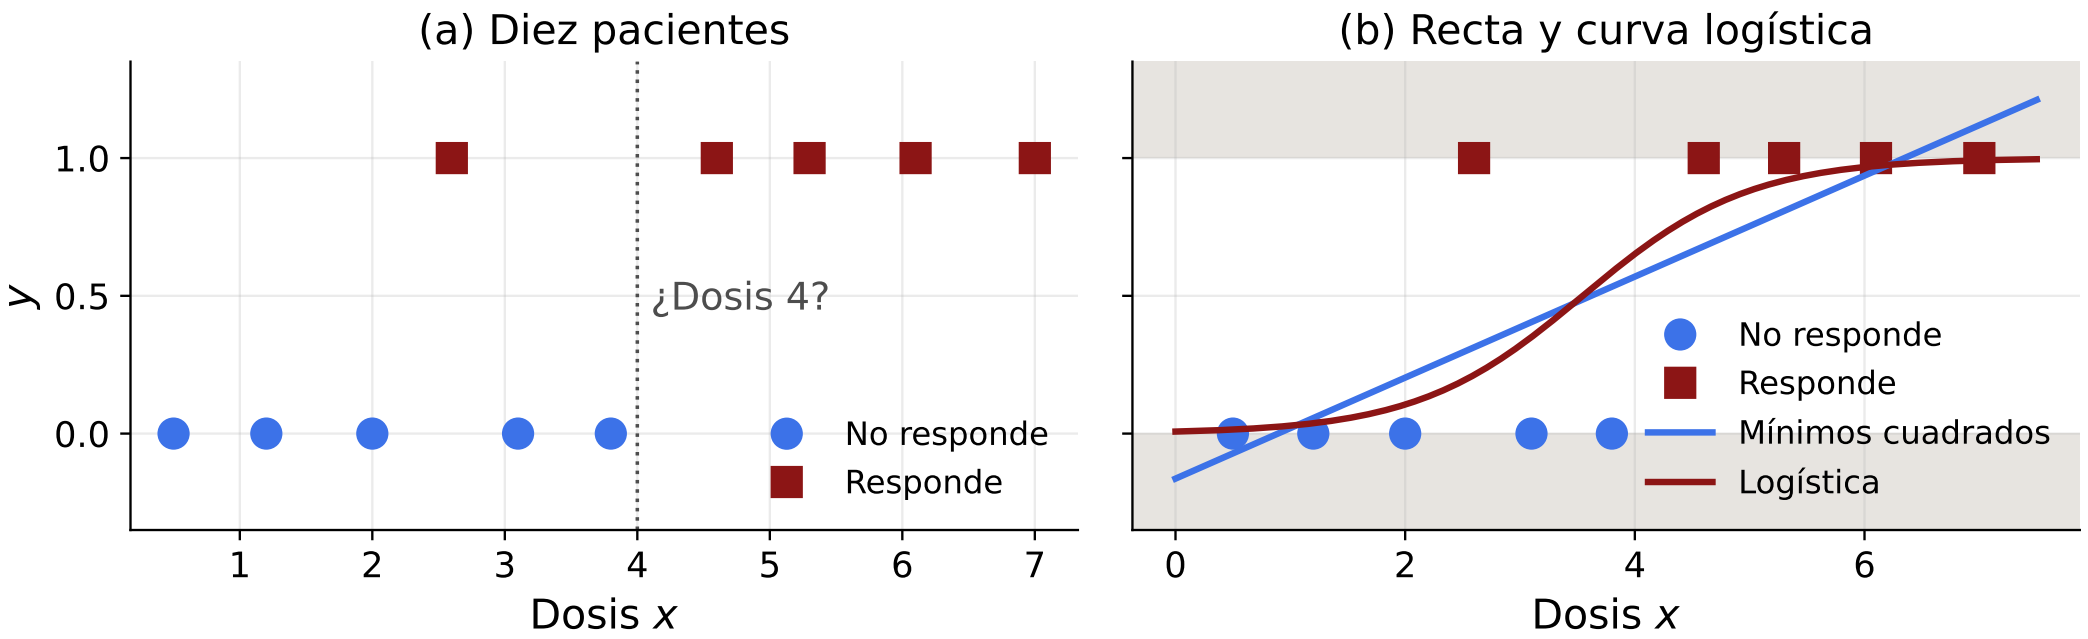
INF396 - Introducción a la Ciencia de Datos



Objetivos

- Formular la clasificación como la estimación de una probabilidad condicional y derivar la regla de Bayes.
- Reconocer cuándo sirve y cuándo falla la regresión lineal sobre una respuesta binaria.
- Construir el modelo logístico desde un puntaje lineal y leer sus coeficientes como razones de chances.
- Derivar la log verosimilitud logística, su gradiente y su hessiano, y escribir el método de Newton como mínimos cuadrados ponderados iterados.
- Calcular errores estándar y reconocer la separación completa.
- Evaluar un clasificador con la matriz de confusión, la curva ROC, la calibración y los costos de los errores.

Diez pacientes



Diez pacientes reciben una dosis x de un fármaco. Cinco responden ($y = 1$) y cinco no ($y = 0$). Buscamos la probabilidad de respuesta con dosis 4. La recta de mínimos cuadrados (b) da $0{,}57$ en $x = 4$, pero da $-0{,}16$ en $x = 0$ y $1{,}21$ en $x = 7{,}5$, que no son probabilidades. La curva logística queda entre 0 y 1 y da $0{,}65$ en $x = 4$.

Clasificación y probabilidad condicional

Sea $y \in \{0, 1\}$ la respuesta y $\mathrm{x} \in \mathbb{R}^p$ las entradas. Toda la información de x sobre y está en

$$p(\mathrm{x}) = \Pr(y = 1 \mid \mathrm{x}) = \mathbb{E}[y \mid \mathrm{x}].$$

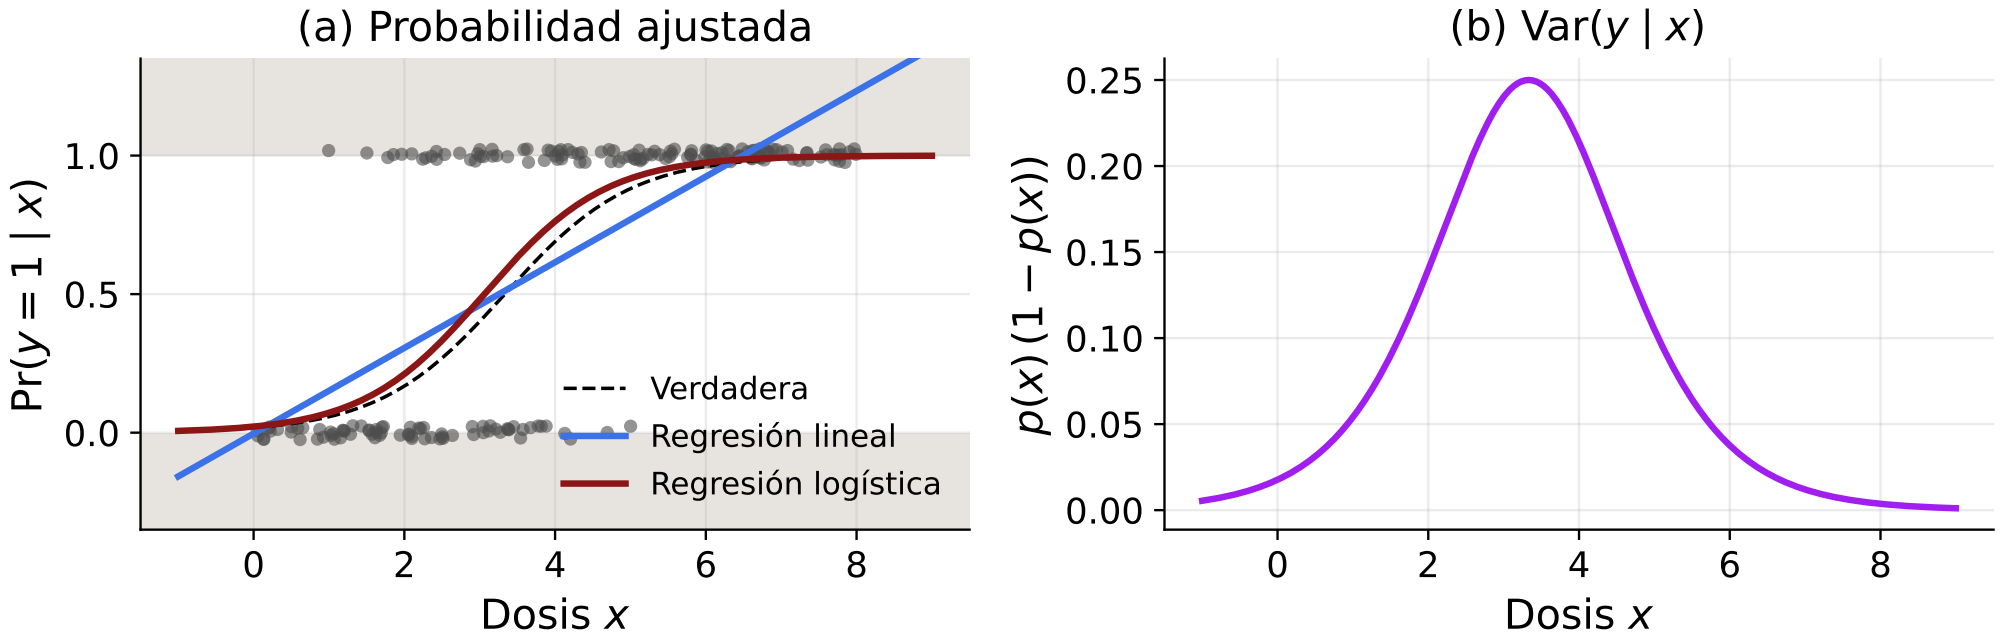
Si los dos tipos de error cuestan lo mismo, la **regla de Bayes** minimiza la probabilidad de error,

$$\hat{y}(\mathrm{x}) = 1\{p(\mathrm{x}) > 1/2\},$$

y su error, $\mathbb{E}[\min(p(\mathrm{X}), 1 - p(\mathrm{X}))]$, se llama riesgo de Bayes y es el menor posible.

La tarea es estimar $p(\mathrm{x})$. La probabilidad estimada sirve para clasificar, mover el umbral si los errores cuestan distinto e informar la incertidumbre de cada predicción.

Regresión lineal sobre una respuesta binaria



Doscientos pacientes reciben dosis entre 0 y 8, con probabilidad de respuesta sig$(-4 + 1{,}2x)$. Como $\mathbb{E}[y \mid x] = p(x)$, la regresión lineal sobre $y \in \{0, 1\}$ estima la probabilidad y se llama **modelo de probabilidad lineal**. Su recta tiene pendiente $0{,}155$ por unidad de dosis. En el $19\,\%$ del rango predice probabilidades fuera de $[0, 1]$ (zonas sombreadas).

El modelo de probabilidad lineal

La regresión lineal sobre una respuesta 0/1 tiene tres ventajas.

- Sus coeficientes son diferencias de probabilidad. Aquí la probabilidad sube $0{,}155$ por unidad de dosis.
- Tiene solución cerrada y admite todos los métodos de la regresión lineal, incluidos ridge y lasso.
- Cuando las probabilidades están lejos de 0 y de 1, la sigmoide es casi recta y ambos modelos dan predicciones parecidas.

También tiene tres defectos.

- Predice probabilidades negativas o mayores que uno.
- Supone que cada variable tiene el mismo efecto sobre la probabilidad en todo el rango. Pero una probabilidad cercana a 1 ya no puede aumentar.
- Es heterocedástico, por lo que los errores estándar de mínimos cuadrados no son válidos.

El modelo logístico

Del puntaje a la probabilidad

El modelo se construye en tres pasos.

1. Un **puntaje** lineal, $z = \beta_0 + \beta_1 x$, que puede tomar cualquier valor real.

2. La **sigmoide** convierte el puntaje en un número entre 0 y 1,

$$p = \text{sig}(z) = \frac{1}{1 + e^{-z}}.$$

3. La **decisión** es $\hat{y} = 1$ si $p > 1/2$, es decir, si $z > 0$.

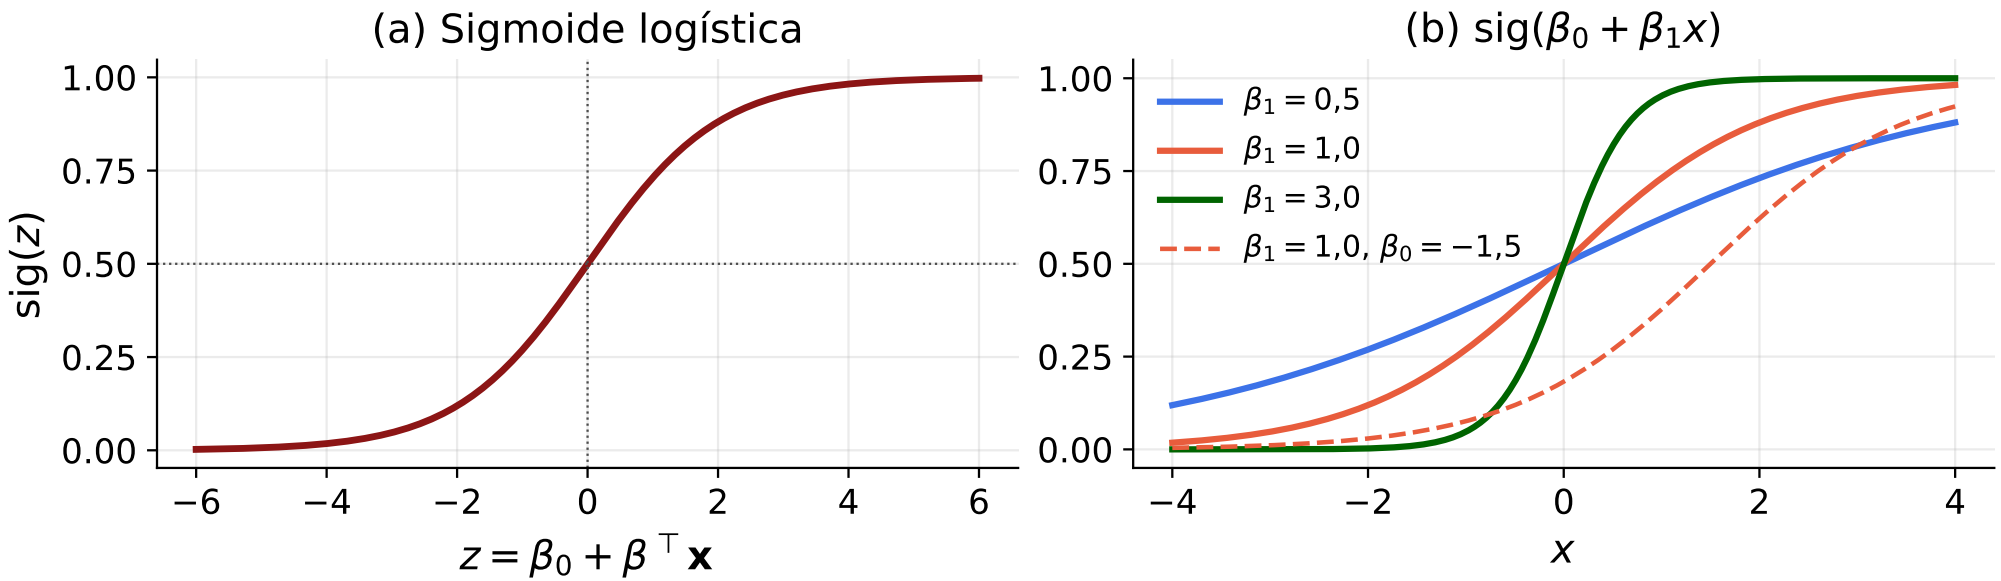
Un puntaje muy positivo da una probabilidad cercana a 1.

Un puntaje muy negativo da una probabilidad cercana a 0.

Un puntaje nulo da $1/2$.

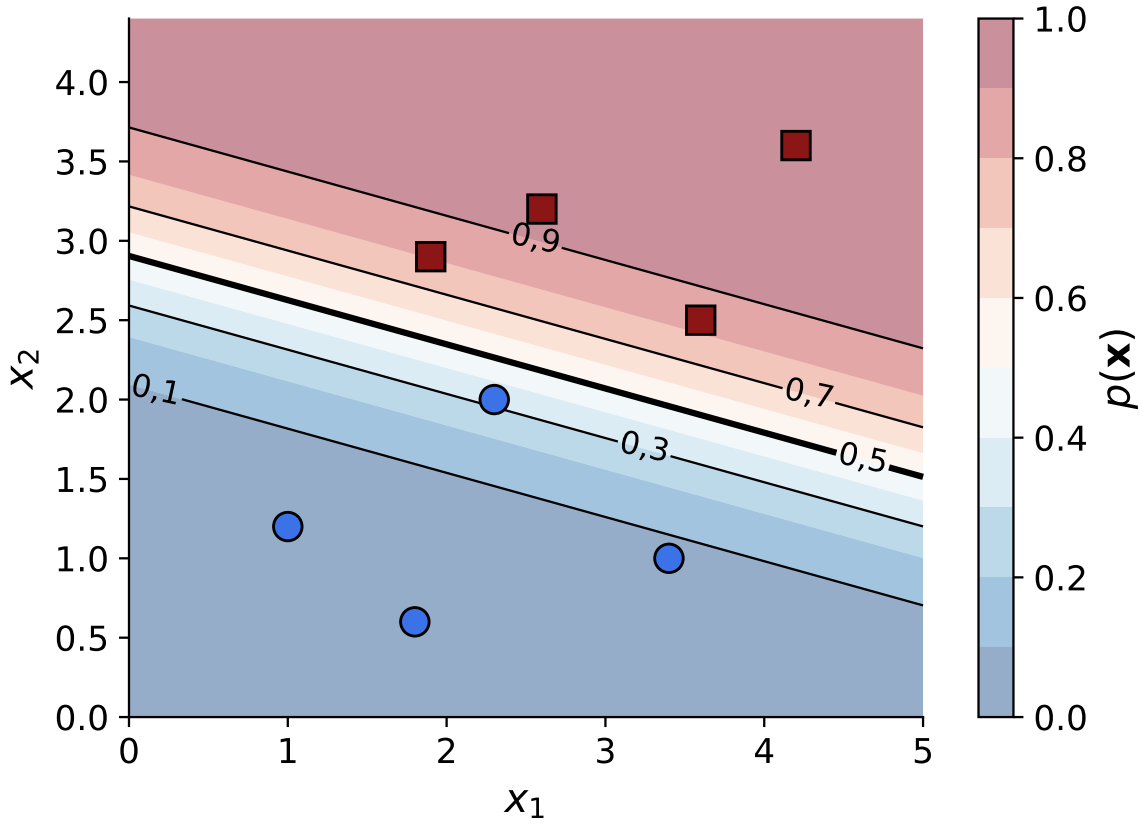
z	$p = \text{sig}(z)$
-4	$0{,}02$
-2	$0{,}12$
-1	$0{,}27$
0	$0{,}50$
1	$0{,}73$
2	$0{,}88$
4	$0{,}98$

La función sigmoide



En (a), la sigmoide pasa por $1/2$ en $z = 0$ y se aplana en los extremos. En (b), β_1 fija la pendiente de la curva y β_0 fija su posición. Con β_1 grande, la curva se parece a un escalón.

La probabilidad en el plano



Con dos variables el puntaje es

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2.$$

- La **frontera** $p = 1/2$ es la recta $z = 0$ (línea gruesa).
- Las curvas de nivel de p son rectas paralelas a la frontera.
- $z = \|\boldsymbol{\beta}\|\, d(\mathrm{x})$, con $d(\mathrm{x})$ la distancia con signo a la frontera.

La probabilidad crece con la distancia a la frontera y $\|\boldsymbol{\beta}\|$ fija la rapidez. Aquí $\|\boldsymbol{\beta}\| = 2{,}8$, y un punto a media unidad de la frontera tiene

$$p = \mathrm{sig}(1{,}4) = 0{,}80.$$

Chances con números

Dosis	Chances	p
0	$1/8$	$0{,}11$
1	$1/4$	$0{,}20$
2	$1/2$	$0{,}33$
3	1	$0{,}50$
4	2	$0{,}67$

Las **chances** (odds) de un evento con probabilidad p son $p/(1-p)$. Con $p = 0{,}8$ las chances son 4, es decir, 4 a 1.

Con $\beta_0 = \log(1/8) = -2{,}08$ y $\beta_1 = \log 2 = 0{,}69$, cada unidad de dosis duplica las chances (tabla).

El logaritmo de las chances es el **logit**. La regresión logística lo modela como función lineal,

$$\log \frac{p(\mathrm{x})}{1-p(\mathrm{x})} = \beta_0 + \boldsymbol{\beta}^\top \mathrm{x}.$$

Interpretación de los coeficientes

Si x_j aumenta en una unidad y las demás variables quedan fijas, el logit aumenta en β_j. Las chances se multiplican por

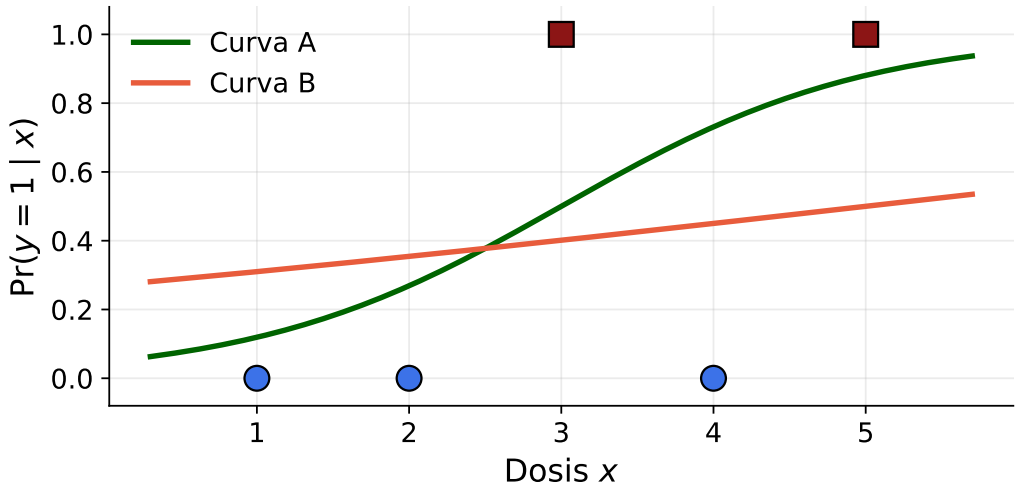
$$\frac{\text{chances}(x_j + 1)}{\text{chances}(x_j)} = e^{\beta_j},$$

que es la **razón de chances** (odds ratio) de la variable j.

- Si $\beta_j > 0$ la probabilidad aumenta, si $\beta_j < 0$ disminuye, y si $\beta_j = 0$ la variable no tiene efecto dado el resto.
- El efecto sobre la probabilidad no es constante. Por la derivada de la sigmoide, $\partial p / \partial x_j = \beta_j \, p(1-p)$. Es máximo en $p = 1/2$ y nulo en los extremos.
- Para probabilidades pequeñas, la razón de chances se aproxima al riesgo relativo.

Estimación por máxima verosimilitud

La verosimilitud con cinco pacientes



x	y	Curva A p	Curva A Prob. de y	Curva B p	Curva B Prob. de y
1	0	$0{,}12$	$0{,}88$	$0{,}31$	$0{,}69$
2	0	$0{,}27$	$0{,}73$	$0{,}35$	$0{,}65$
3	1	$0{,}50$	$0{,}50$	$0{,}40$	$0{,}40$
4	0	$0{,}73$	$0{,}27$	$0{,}45$	$0{,}55$
5	1	$0{,}88$	$0{,}88$	$0{,}50$	$0{,}50$
Producto		$0{,}076$		$0{,}049$	
$-\log$ **del producto**		$2{,}57$		$3{,}01$	

Cada curva asigna una probabilidad a la respuesta observada de cada paciente. Con pacientes independientes, la probabilidad del conjunto es el producto. La curva A da $0{,}076$ y la B da $0{,}049$, y por eso A explica mejor los datos. La **máxima verosimilitud** elige la curva con el mayor producto, aquí $\beta_0 = -3{,}89$ y $\beta_1 = 1{,}09$, con producto $0{,}089$.

La verosimilitud de Bernoulli

Sea $p_i = \text{sig}(\mathrm{x}_i^\top \boldsymbol{\beta})$, con el intercepto en $\mathrm{x}_i = (1, x_{i1}, \ldots, x_{ip})$. Cada respuesta tiene probabilidad $p_i^{y_i}(1-p_i)^{1-y_i}$. Con observaciones independientes, la log verosimilitud negativa es

$$\begin{aligned}\ell(\boldsymbol{\beta}) &= -\sum_{i=1}^{n}\Big[y_i \log p_i + (1-y_i)\log(1-p_i)\Big] \\ &= \sum_{i=1}^{n}\Big[\log\left(1+e^{z_i}\right) - y_i z_i\Big], \qquad z_i = \mathrm{x}_i^\top \boldsymbol{\beta}.\end{aligned}$$

- La primera forma es la **entropía cruzada binaria** entre las etiquetas y las probabilidades predichas.
- La segunda sale de $\log p_i = z_i - \log(1+e^{z_i})$ y $\log(1-p_i) = -\log(1+e^{z_i})$. Es la que se programa, calculando $\log(1+e^z)$ de forma estable.
- $2\ell(\hat{\boldsymbol{\beta}})$ es la **desviación** del modelo y es análoga a la suma de cuadrados residual.

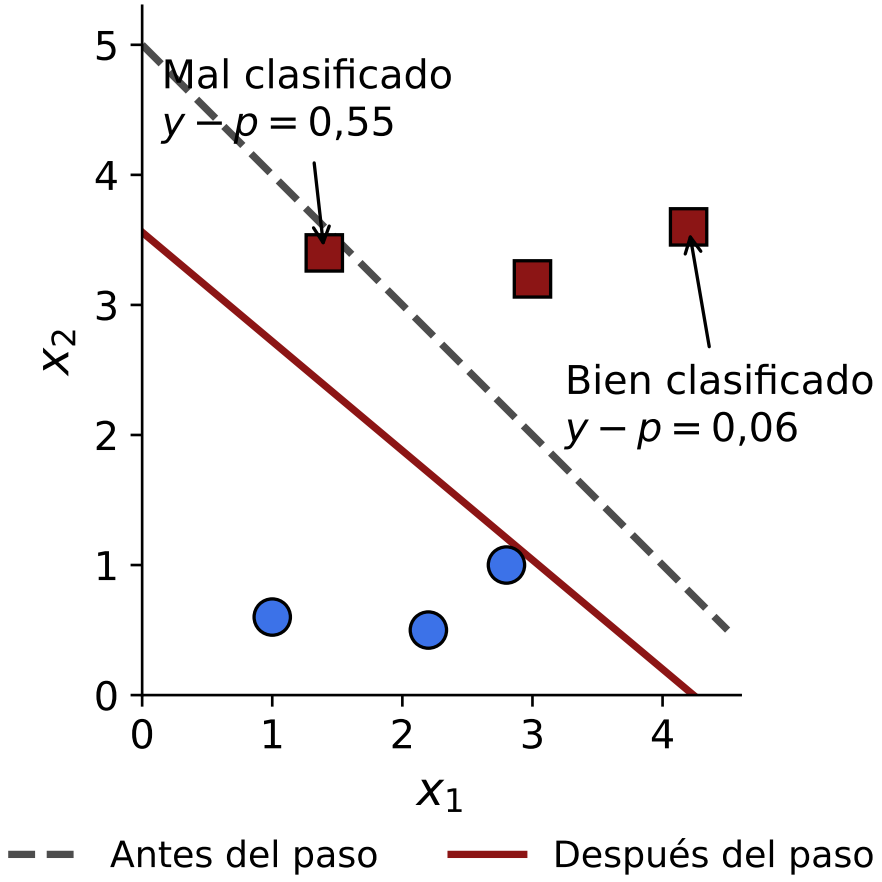
La derivada de la sigmoide

Derivando $\mathrm{sig}(z) = (1 + e^{-z})^{-1}$,

$$\begin{aligned}\mathrm{sig}'(z) &= \frac{e^{-z}}{(1+e^{-z})^2} = \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}} \\ &= \mathrm{sig}(z)\big(1 - \mathrm{sig}(z)\big).\end{aligned}$$

- La derivada se escribe con la propia sigmoide. Esa propiedad simplifica el gradiente.
- Es máxima en $z = 0$, donde vale $1/4$, y tiende a cero en los extremos.
- Un cambio en β mueve mucho la probabilidad de los puntos cercanos a la frontera y poco la de los puntos lejanos.

Cada punto tira de la frontera



El punto i aporta $(p_i - y_i)\,\mathrm{x}_i$ al gradiente de la log verosimilitud negativa. Un paso de descenso con ese punto es

$$\boldsymbol{\beta} \leftarrow \boldsymbol{\beta} + \eta\,(y_i - p_i)\,\mathrm{x}_i\,.$$

- El punto mal clasificado tiene $y = 1$ y $p = 0{,}45$. Tira con fuerza $0{,}55$ y la frontera gira hacia él.
- El punto bien clasificado tiene $y - p = 0{,}06$ y casi no la mueve.

El gradiente

La sigmoide cumple $\mathrm{sig}'(z) = \mathrm{sig}(z)(1 - \mathrm{sig}(z))$. La derivada del sumando i es

$$\frac{\partial}{\partial \boldsymbol{\beta}} \Big[\log(1 + e^{z_i}) - y_i z_i \Big] = \big(\mathrm{sig}(z_i) - y_i\big)\, \mathrm{x}_i = (p_i - y_i)\, \mathrm{x}_i,$$

y en forma matricial, con X de $n \times (p+1)$,

$$\nabla \ell(\boldsymbol{\beta}) = \mathrm{X}^\top (\mathrm{p} - \mathrm{y}).$$

La ecuación de verosimilitud $\mathrm{X}^\top(\mathrm{y} - \hat{\mathrm{p}}) = 0$ tiene la forma de las ecuaciones normales, $\mathrm{X}^\top(\mathrm{y} - \mathrm{X}\hat{\boldsymbol{\beta}}) = 0$. En ambas, los residuos son ortogonales a las columnas de X. Como p no es lineal en $\boldsymbol{\beta}$, no hay solución cerrada.

El hessiano y la convexidad

El hessiano es

$$\nabla^2 \ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} p_i(1-p_i)\,\mathrm{x}_i\mathrm{x}_i^\top = \mathrm{X}^\top \mathrm{W}\mathrm{X}, \qquad \mathrm{W} = \mathsf{diag}\left(p_i(1-p_i)\right).$$

Como los pesos son positivos, $\mathrm{v}^\top \mathrm{X}^\top \mathrm{W}\mathrm{X}\mathrm{v} = \sum_i p_i(1-p_i)(\mathrm{x}_i^\top \mathrm{v})^2 \geq 0$ para todo v. El hessiano es semidefinido positivo y la log verosimilitud negativa es **convexa**.

- No hay mínimos locales. Si existe un mínimo, es global.
- Si X tiene rango completo y el mínimo existe, es único.
- El peso $p_i(1-p_i)$ es la varianza de y_i, como en el modelo de probabilidad lineal.

Newton–Raphson y mínimos cuadrados reponderados

El método de Newton minimiza en cada paso la aproximación cuadrática de ℓ,

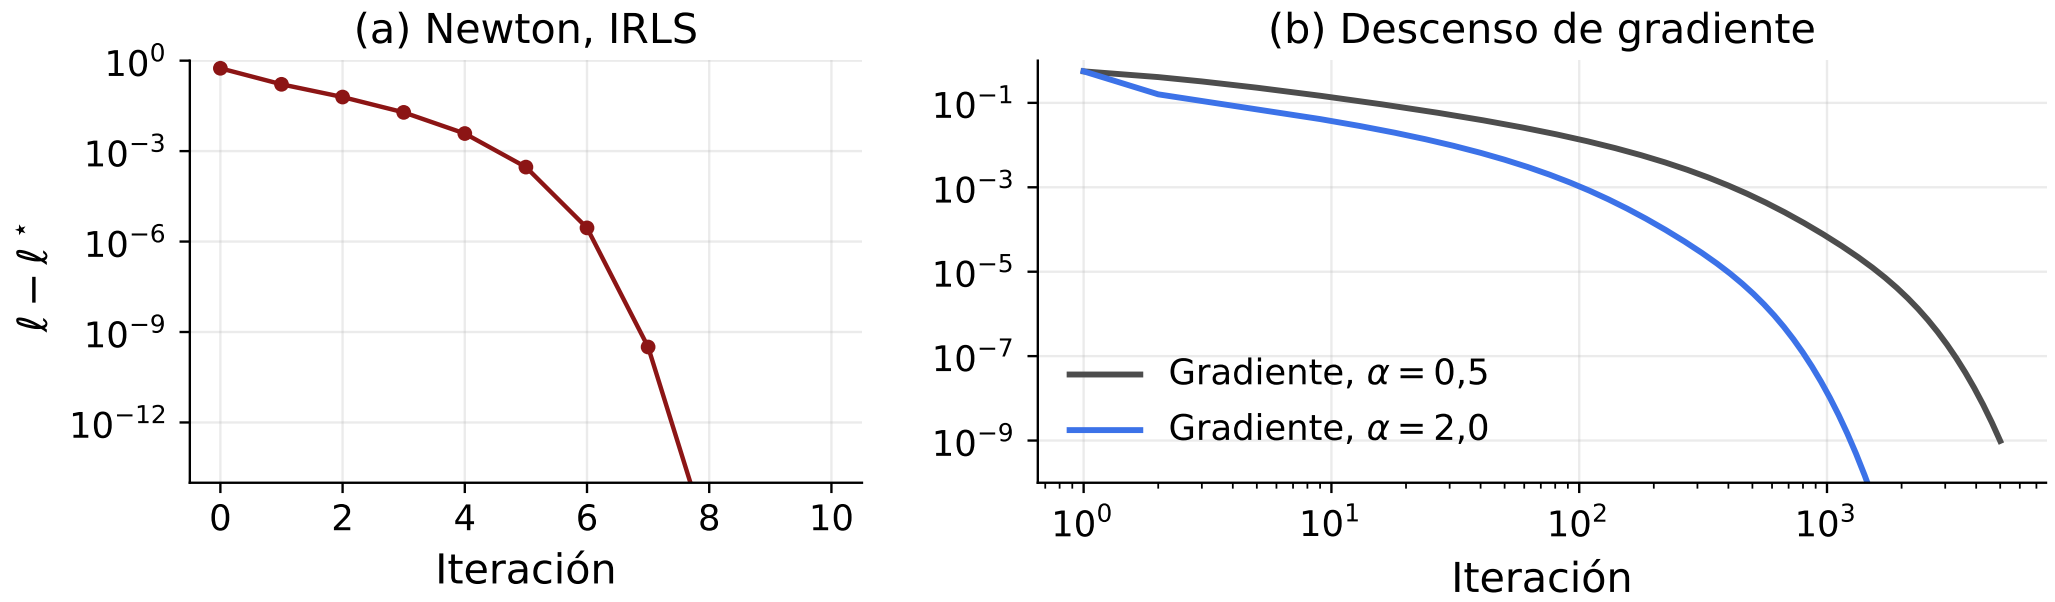
$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} - \left(\mathrm{X}^\top \mathrm{W} \mathrm{X}\right)^{-1} \mathrm{X}^\top (\mathrm{p} - \mathrm{y}).$$

Reordenando,

$$\boldsymbol{\beta}^{(t+1)} = \left(\mathrm{X}^\top \mathrm{W} \mathrm{X}\right)^{-1} \mathrm{X}^\top \mathrm{W} \mathrm{z}, \qquad \mathrm{z} = \mathrm{X}\boldsymbol{\beta}^{(t)} + \mathrm{W}^{-1}(\mathrm{y} - \mathrm{p}).$$

Cada paso es una regresión por **mínimos cuadrados ponderados** de la respuesta de trabajo z sobre X, con pesos $p_i(1 - p_i)$. Como los pesos cambian en cada iteración, el algoritmo se llama mínimos cuadrados reponderados iterativamente (**IRLS**).

Convergencia



Se ajusta un modelo de cuatro variables a los datos de cáncer de mama de Wisconsin, desde $\beta = 0$. Newton llega a la precisión de máquina en unas ocho iteraciones. Su convergencia es cuadrática y duplica las cifras correctas por paso. El descenso de gradiente necesita cientos o miles de iteraciones según la tasa.

Los datos de cáncer de mama

Hay 569 tumores de mama con diagnóstico confirmado y 212 son malignos (Street, Wolberg y Mangasarian, 1993). Se miden diez características de los núcleos celulares en una imagen digital de la punción (radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal). Cada una se resume por su media, su error estándar y su peor valor, y hay 30 variables.

- La respuesta es $y = 1$ si el tumor es maligno.
- Una partición estratificada fija deja 369 tumores para ajustar y 200 para evaluar.
- Las variables se estandarizan con la media y la desviación estándar del entrenamiento.

El conjunto está en scikit-learn (`load_breast_cancer`).

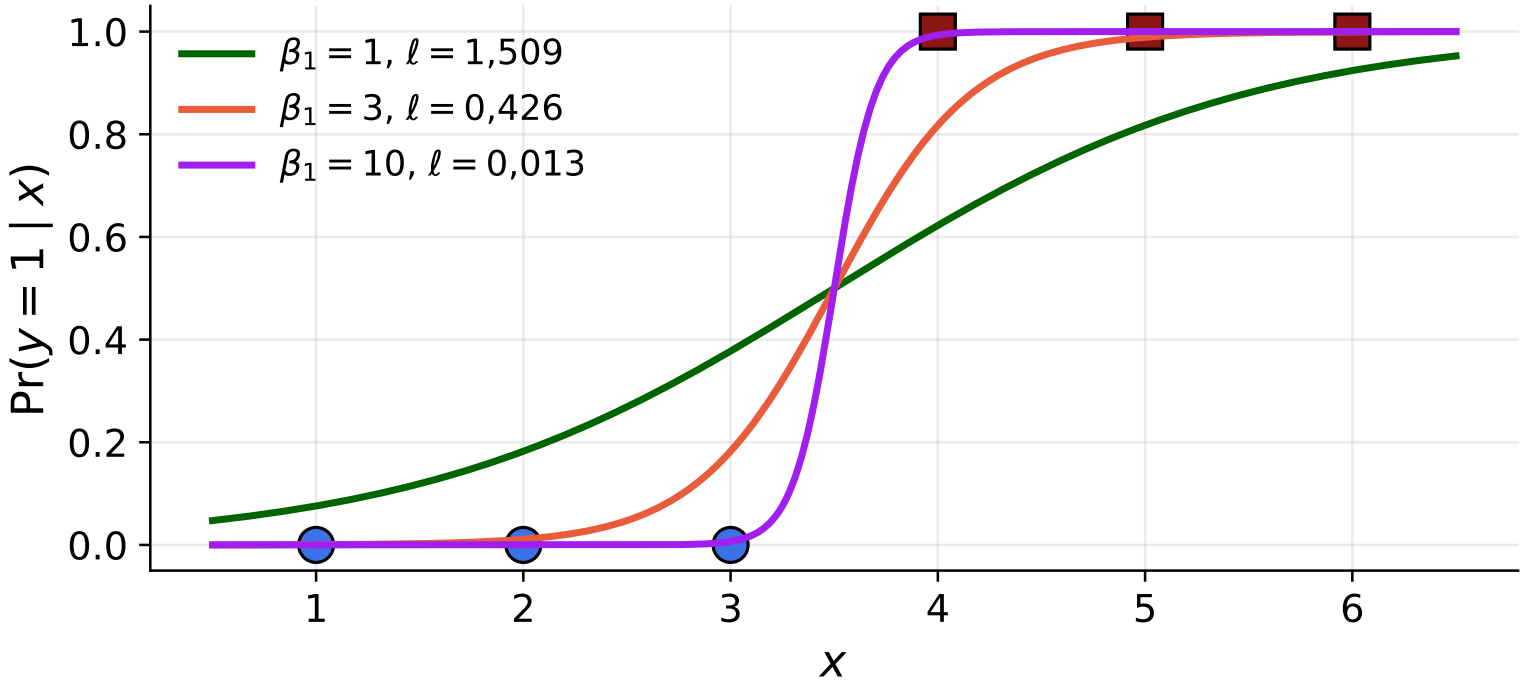
Inferencia sobre los coeficientes

Para n grande, $\hat{\boldsymbol{\beta}} \approx N\left(\boldsymbol{\beta}, (\mathbf{X}^\top \hat{\mathbf{W}} \mathbf{X})^{-1}\right)$. La covarianza es la inversa del hessiano en el óptimo (información de Fisher observada).

Variable	$\hat{\beta}_j$	**EE**	z	**Razón de chances, IC 95 %**
Intercepto	$-0{,}68$	$0{,}28$	$-2{,}4$	–
Radio medio	$3{,}68$	$0{,}83$	$4{,}4$	$39{,}64\,[7{,}78;\ 201{,}89]$
Textura media	$1{,}65$	$0{,}34$	$4{,}9$	$5{,}23\,[2{,}70;\ 10{,}14]$
Suavidad media	$0{,}87$	$0{,}46$	$1{,}9$	$2{,}39\,[0{,}96;\ 5{,}93]$
Puntos cóncavos medios	$2{,}97$	$0{,}78$	$3{,}8$	$19{,}41\,[4{,}19;\ 89{,}81]$

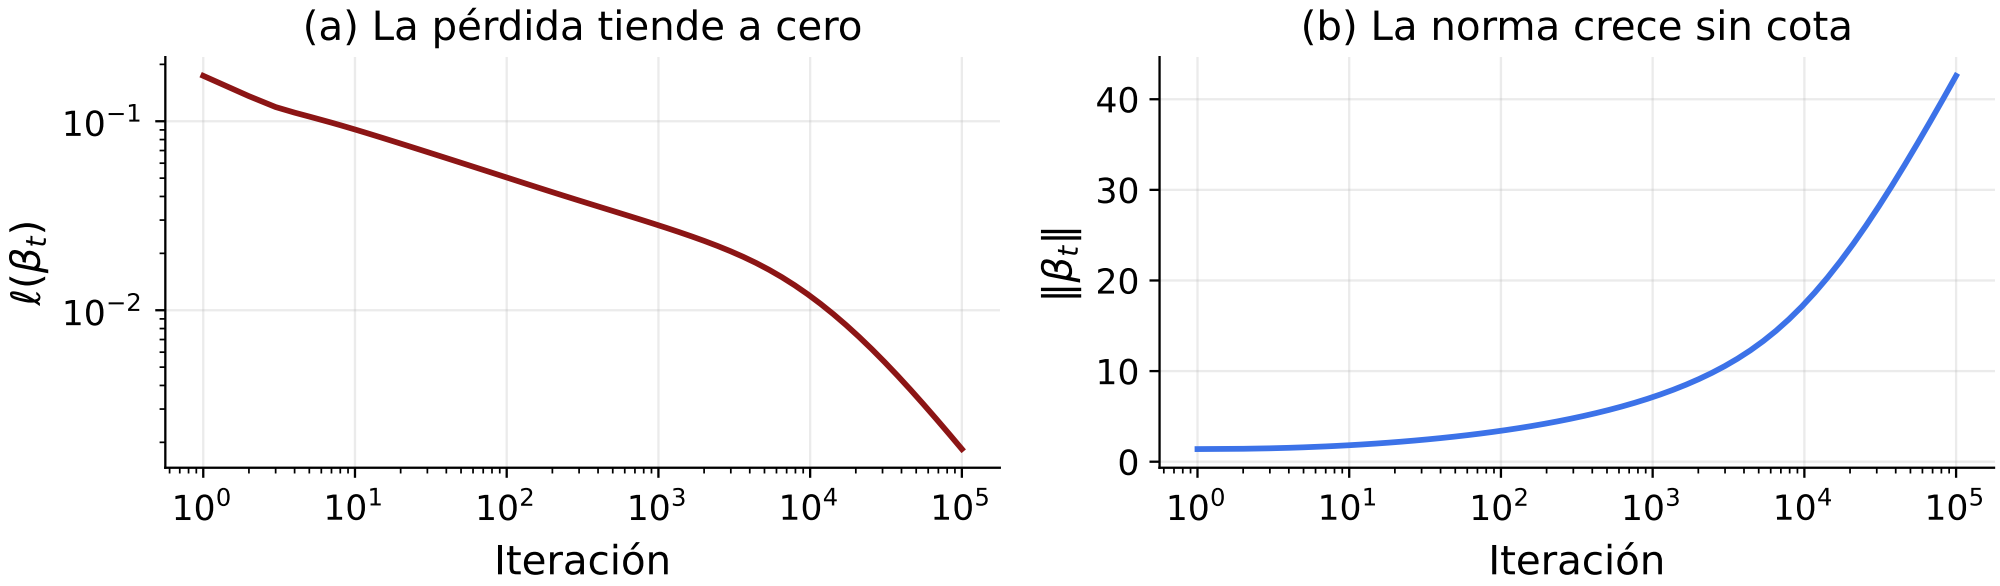
El modelo usa cuatro variables estandarizadas, elegidas antes de ver los datos. Si la textura media sube una desviación estándar y las otras tres quedan fijas, las chances de malignidad se multiplican por $5{,}2$. Su intervalo de 95 % va de $2{,}7$ a $10{,}1$. La suavidad media no es significativa al 5 %.

Separación en una dimensión



Los tres pacientes de la izquierda tienen $y = 0$ y los tres de la derecha $y = 1$. Una curva centrada en $3{,}5$ los clasifica a todos bien. Al empinarla, la log verosimilitud negativa ℓ baja de $1{,}51$ con $\beta_1 = 1$ a $0{,}43$ con $\beta_1 = 3$ y a $0{,}013$ con $\beta_1 = 10$. ℓ tiende a cero sin alcanzar un mínimo, y el estimador de máxima verosimilitud no existe.

Separación completa



Con las 30 variables, un hiperplano separa sin error los tumores malignos de los benignos del entrenamiento. Entonces $\ell(c\boldsymbol{\beta}) \to 0$ al crecer c, y el **estimador de máxima verosimilitud no existe**. El descenso de gradiente reduce la pérdida sin fin y $\|\boldsymbol{\beta}\|$ crece sin cota.

Consecuencias de la separación

Tras 10^5 iteraciones, $\|\hat{\beta}\| = 43$ y sigue creciendo. El error de entrenamiento es cero.

- La frontera clasifica bien en test, con 3 % de error y AUC $0{,}990$.
- Las probabilidades están mal calibradas. La log verosimilitud negativa en test es $0{,}51$, y la de un modelo con penalización ridge es $0{,}08$. Los pocos errores ocurren con probabilidades casi 0 o 1.
- Los coeficientes y sus errores estándar crecen sin límite y no se pueden interpretar.

Hay dos remedios habituales.

1. **Regularizar**. La penalización garantiza un mínimo único y finito.
2. Usar la corrección de Firth (1993). Esta penalización usa la información de Fisher, reduce el sesgo de $\hat{\beta}$ y siempre da estimaciones finitas.

Evaluación de clasificadores

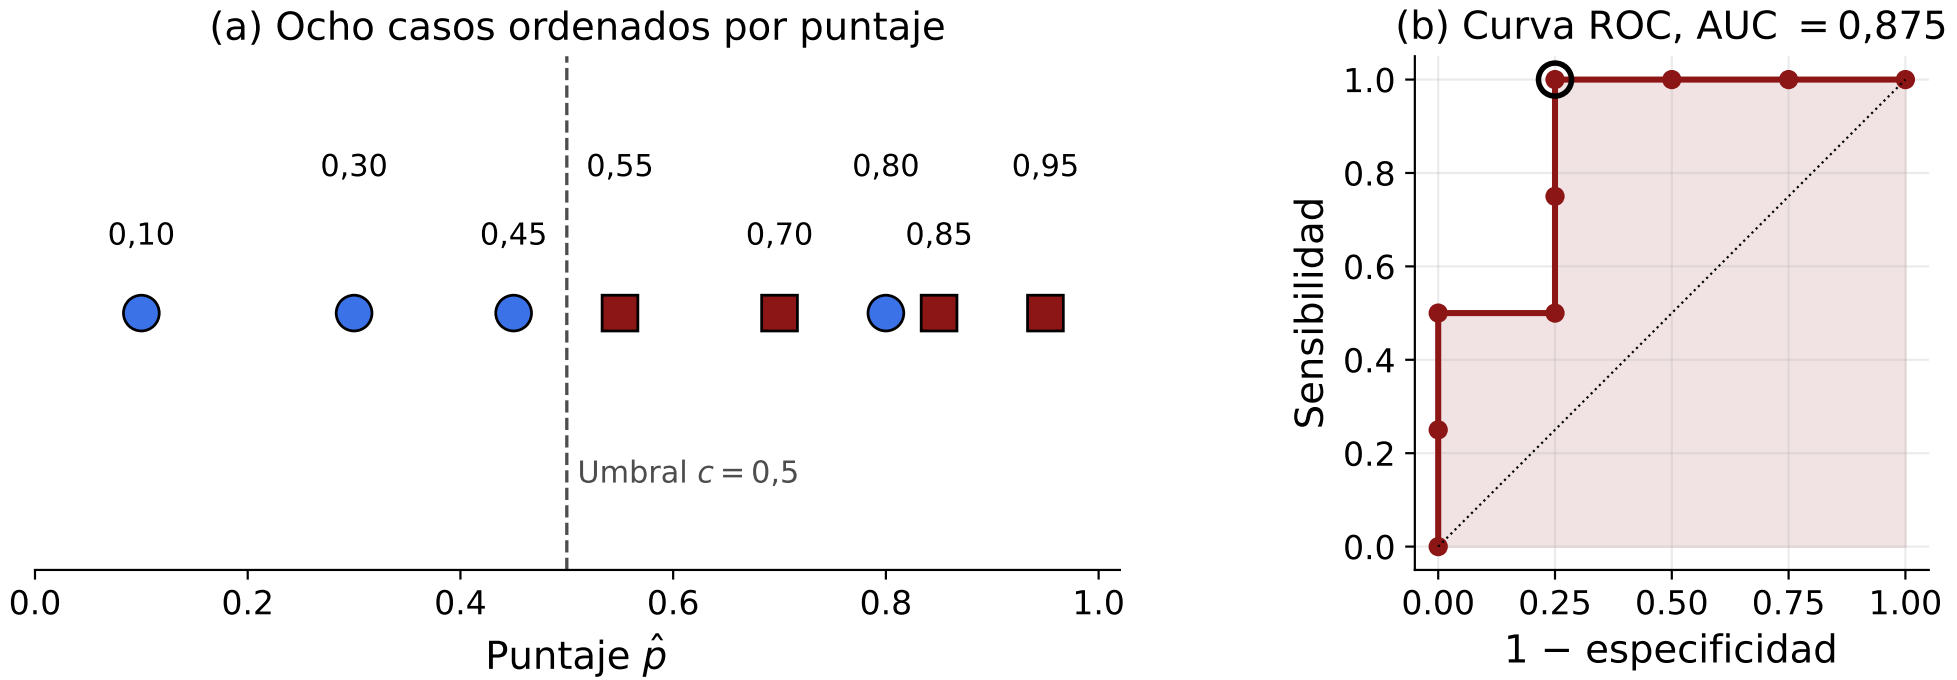
La matriz de confusión

Un clasificador decide $\hat{y} = 1\{\hat{p}(\mathrm{x}) > c\}$. Con $c = 0{,}5$ evalúa a 20 pacientes, 8 enfermos y 12 sanos.

	Predicho enfermo	**Predicho sano**
Enfermo	Verdaderos positivos, VP $= 6$	Falsos negativos, FN $= 2$
Sano	Falsos positivos, FP $= 3$	Verdaderos negativos, VN $= 9$

- **Sensibilidad**, VP/(VP + FN) $= 6/8 = 0{,}75$. Es la fracción de enfermos detectados.
- **Especificidad**, VN/(VN + FP) $= 9/12 = 0{,}75$. Es la fracción de sanos descartados.
- **Valor predictivo positivo**, VP/(VP + FP) $= 6/9 = 0{,}67$. Es la fracción de alarmas correctas y depende de la prevalencia.
- **Exactitud**, (VP + VN)/$n = 15/20 = 0{,}75$. Engaña con clases desbalanceadas. Si sólo el 1 % está enfermo, decir siempre sano da exactitud $0{,}99$.

Una curva ROC con ocho casos



Hay cuatro positivos (cuadrados) y cuatro negativos. Cada umbral da un punto (1 − especificidad, sensibilidad). Con $c = 0{,}5$ la sensibilidad es 1 y la especificidad $0{,}75$ (círculo). Al bajar el umbral de caso en caso, la curva sube con cada positivo y avanza a la derecha con cada negativo. En 14 de los 16 pares positivo–negativo el positivo tiene mayor puntaje, y el área bajo la curva es $14/16 = 0{,}875$.

Curva ROC, calibración y reglas de puntuación

Curva ROC. Al variar el umbral c, el par (1 − especificidad, sensibilidad) recorre una curva. El área bajo ella, el **AUC**, es la probabilidad de que un positivo al azar reciba mayor puntaje que un negativo al azar (estadístico de Mann–Whitney). El AUC mide la capacidad de ordenar y no evalúa las probabilidades.

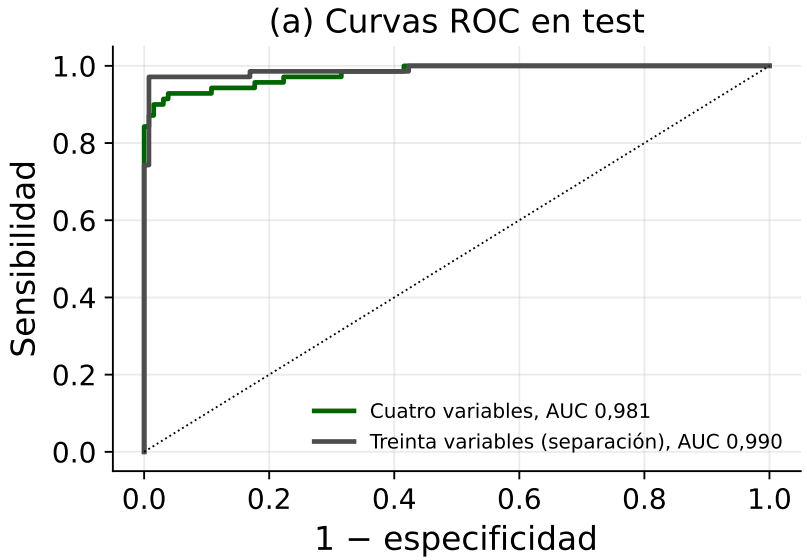
Calibración. Entre los casos con $\hat{p} \approx 0{,}8$, el $80\,\%$ debería ser positivo. Se revisa agrupando por probabilidad predicha y comparando con la frecuencia observada.

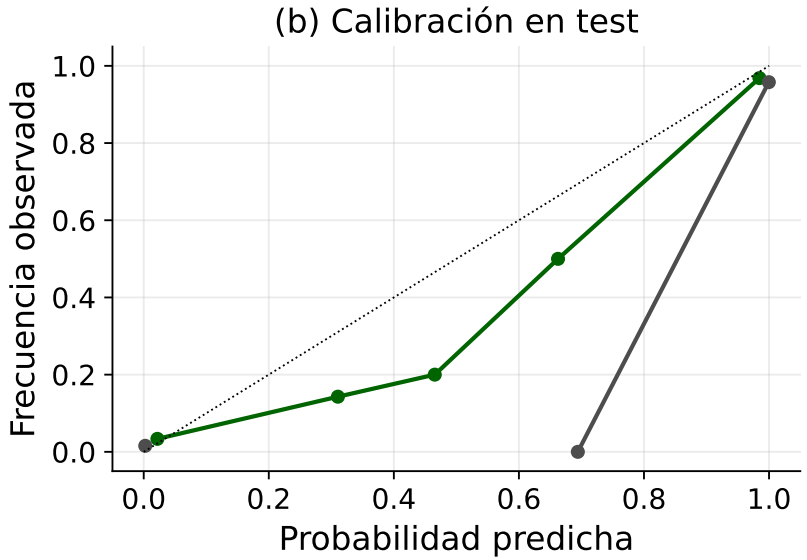
Reglas de puntuación propias. Evalúan las probabilidades y miden a la vez la calibración y la discriminación.

$$-\tfrac{1}{n}\textstyle\sum_i \left[y_i \log \hat{p}_i + (1-y_i)\log(1-\hat{p}_i)\right] \quad \text{(log verosimilitud negativa media)},$$

$$\tfrac{1}{n}\textstyle\sum_i (\hat{p}_i - y_i)^2 \quad \text{(puntaje de Brier)}.$$

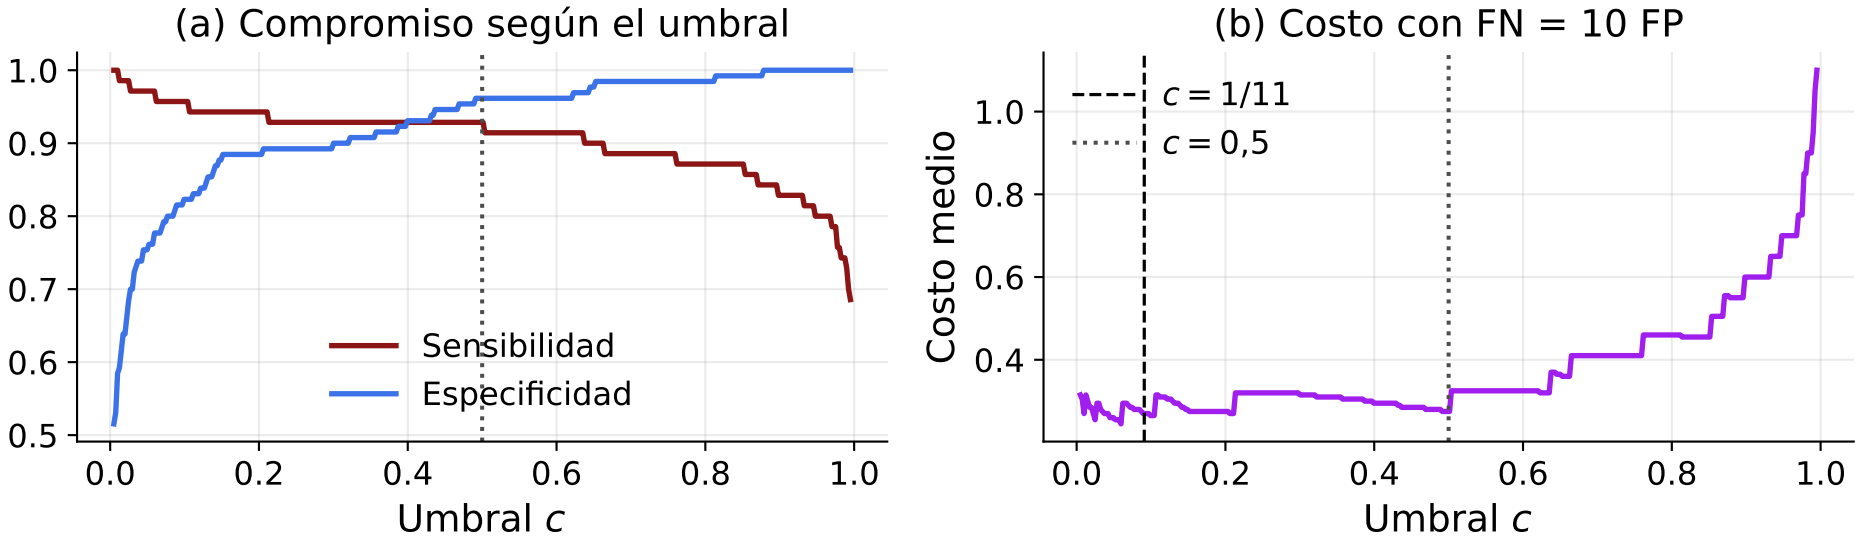
Evaluación en test





Modelo	Error	AUC	Log verosim. neg.	Brier
Cuatro variables	0,050	0,981	0,16	0,046
Treinta variables (separación)	0,030	0,990	0,51	0,027

El umbral y el costo de los errores



Sea C_{FN} el costo de un falso negativo y C_{FP} el de un falso positivo. Con probabilidades calibradas, el umbral óptimo es $c^\star = C_{\text{FP}}/(C_{\text{FP}} + C_{\text{FN}})$, que con $C_{\text{FN}} = 10\,C_{\text{FP}}$ vale $1/11$. Con el modelo de cuatro variables, bajar el umbral de $0{,}5$ a $1/11$ detecta dos cánceres más (67 de 70) y agrega 19 falsas alarmas. El costo medio baja de $0{,}275$ a $0{,}270$. El umbral se elige con los costos y con datos de validación.

Implementación

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score, log_loss, brier_score_loss, confusion_matrix

def irls(X, y, n_iter=50):                          # X con una columna de unos
    b = np.zeros(X.shape[1])
    for _ in range(n_iter):
        p = 1/(1 + np.exp(-X @ b)); w = p*(1 - p)
        b = b + np.linalg.solve(X.T @ (w[:, None]*X), X.T @ (y - p))   # paso de Newton
    return b

modelo = LogisticRegression(C=np.inf, max_iter=1000).fit(X, y)         # sin penalización
p = modelo.predict_proba(X_test)[:, 1]
roc_auc_score(y_test, p), log_loss(y_test, p), brier_score_loss(y_test, p)
confusion_matrix(y_test, p > 1/11)                  # umbral elegido por los costos
```

Errores frecuentes

- Usar la regresión lineal sobre una respuesta 0/1 para predecir probabilidades, que pueden salir de $[0, 1]$.
- Usar la exactitud con clases desbalanceadas, o evaluar con el AUC un modelo cuyas probabilidades se van a usar.
- Elegir el umbral con el conjunto de test.
- Interpretar un coeficiente enorme con un error estándar enorme, sin revisar si hay separación.
- Interpretar la razón de chances como riesgo relativo cuando el evento es frecuente.
- Interpretar un coeficiente sin recordar que el efecto sobre la probabilidad depende de p.

Referencias

- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*, 2.ª ed., sección 4.4. Springer.
- Agresti, A. (2013). *Categorical Data Analysis*, 3.ª ed., capítulos 4 a 6. Wiley.
- McCullagh, P., Nelder, J. A. (1989). *Generalized Linear Models*, 2.ª ed. Chapman and Hall.
- Serrano, L. G. (2021). *Grokking Machine Learning*, capítulos 6 y 7. Manning.
- Firth, D. (1993). Bias reduction of maximum likelihood estimates. *Biometrika*, 80(1), 27–38.
- Street, W. N., Wolberg, W. H., Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. *Proceedings of SPIE*, 1905, 861–870.