Regresión logística II

Unidad 5. Regularización, más de dos clases y selección con variables mixtas

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos



Objetivos

- Regularizar la regresión logística con L2, L1 y por grupos, y elegir la intensidad por validación cruzada.
- Comparar modelos regularizados por su capacidad de ordenar y por la calidad de sus probabilidades.
- Extender el modelo a K clases con la función softmax.
- Seleccionar variables cuando se mezclan variables numéricas y categóricas.
- Comparar la regresión lineal y la logística para seleccionar variables y para predecir probabilidades.

El modelo logístico

Con $y \in \{0, 1\}$ y entradas $\mathrm{x} \in \mathbb{R}^p$, la regresión logística modela la probabilidad como

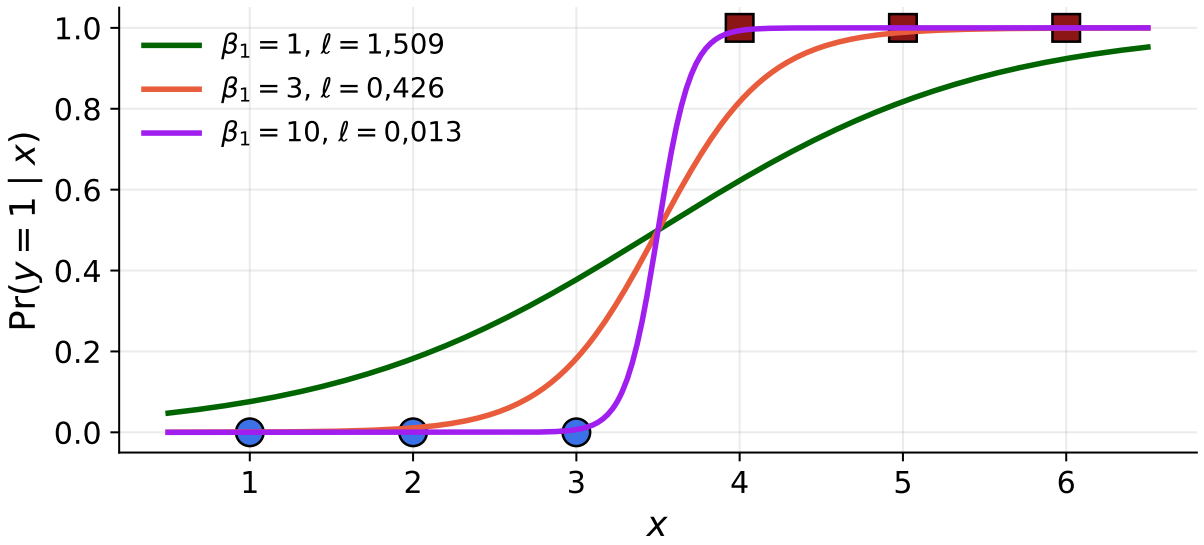
$$p(\mathrm{x}) = \Pr(y = 1 \mid \mathrm{x}) = \mathrm{sig}(\beta_0 + \boldsymbol{\beta}^\top \mathrm{x}) = \frac{1}{1 + e^{-(\beta_0 + \boldsymbol{\beta}^\top \mathrm{x})}}.$$

- La frontera $p(\mathrm{x}) = 1/2$ es el hiperplano $\beta_0 + \boldsymbol{\beta}^\top \mathrm{x} = 0$.
- e^{β_j} es la razón de chances de la variable j.
- Los coeficientes minimizan la log verosimilitud negativa, con $z_i = \mathrm{x}_i^\top \boldsymbol{\beta}$ e intercepto en x_i,

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \Big[\log\left(1 + e^{z_i}\right) - y_i z_i \Big], \qquad \nabla \ell = \mathrm{X}^\top(\mathrm{p} - \mathrm{y}), \qquad \nabla^2 \ell = \mathrm{X}^\top \mathrm{W} \mathrm{X},$$

  con $\mathrm{W} = \mathrm{diag}\left(p_i(1 - p_i)\right)$. La función es convexa y el método de Newton la minimiza en pocas iteraciones.

Separación y estimadores infinitos



Si un hiperplano separa sin error los unos de los ceros, la log verosimilitud negativa tiende a cero al empinar la curva. El mínimo no existe y $\|\boldsymbol{\beta}\| \to \infty$.

En la figura, ℓ baja de $1{,}51$ a $0{,}013$ al pasar de $\beta_1 = 1$ a $\beta_1 = 10$.

Con muchas variables y pocos datos, la separación es frecuente. Las probabilidades quedan cerca de 0 o 1 y los coeficientes no se pueden interpretar.

Los datos de cáncer de mama

Hay 569 tumores de mama con diagnóstico confirmado y 212 son malignos (Street, Wolberg y Mangasarian, 1993). Se miden diez características de los núcleos celulares en una imagen digital de la punción (radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal). Cada una se resume por su media, su error estándar y su peor valor, y hay 30 variables.

- La respuesta es $y = 1$ si el tumor es maligno.
- Una partición estratificada fija deja 369 tumores para ajustar y 200 para evaluar.
- Las variables se estandarizan con la media y la desviación estándar del entrenamiento.

El conjunto está en scikit-learn (`load_breast_cancer`).

Regularización

Regresión logística penalizada

Como en la regresión lineal, se agrega una penalización a la log verosimilitud negativa media,

$$\hat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta}}{\text{argmin}} \, \frac{1}{n}\ell(\boldsymbol{\beta}) + \lambda \, P(\boldsymbol{\beta}),$$

con el intercepto sin penalizar y las variables estandarizadas.

Penalización	$P(\boldsymbol{\beta})$	**Efecto**
Ridge (L2)	$\frac{1}{2}\sum_j \beta_j^2$	Encoge, siempre existe y es única
Lasso (L1)	$\sum_j \lvert\beta_j\rvert$	Encoge y anula, selecciona variables
Elastic net	$\alpha \sum_j \lvert\beta_j\rvert + \frac{1-\alpha}{2}\sum_j \beta_j^2$	Selecciona grupos de variables correlacionadas
Group lasso	$\sum_g \sqrt{p_g}\, \lVert\boldsymbol{\beta}_g\rVert_2$	Selecciona o descarta bloques completos

Ridge es el máximo a posteriori con a priori normal, y el lasso lo es con a priori de Laplace.

Ridge y lasso logísticos

Ridge. La penalización suma $\lambda n \mathrm{I}$ al hessiano, salvo en el intercepto. El paso de Newton es

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} + (\mathrm{X}^\top \mathrm{W} \mathrm{X} + n\lambda \tilde{\mathrm{I}})^{-1} (\mathrm{X}^\top (\mathrm{y} - \mathrm{p}) - n\lambda \tilde{\mathrm{I}} \boldsymbol{\beta}^{(t)}),$$

y el mínimo existe aunque los datos estén separados.

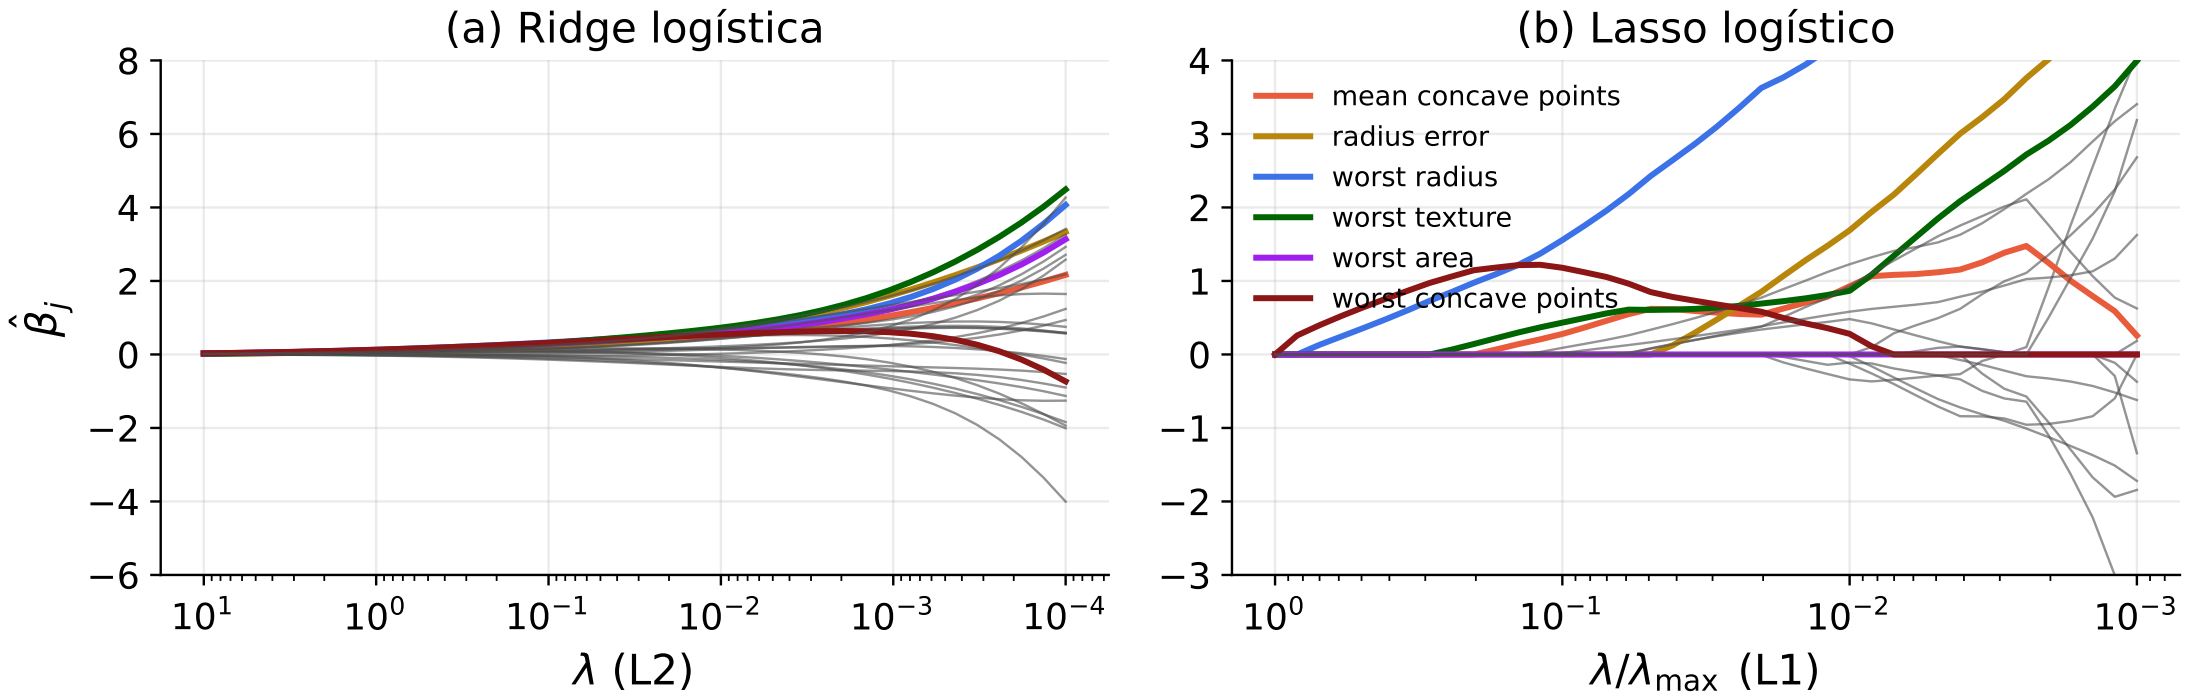
Lasso. La penalización no es diferenciable. El gradiente proximal da un paso de gradiente sobre la parte suave y aplica el umbral suave,

$$\boldsymbol{\beta} \leftarrow S_{\lambda/L}\Big(\boldsymbol{\beta} - \tfrac{1}{L} \nabla \tfrac{1}{n} \ell(\boldsymbol{\beta})\Big), \quad S_t(v) = \mathsf{sign}(v)\, \mathsf{máx}(|v| - t, 0),$$

con $L = \|\mathrm{X}\|_2^2 / 4n$ como cota de la curvatura. Con variables estandarizadas, todos los coeficientes son nulos para

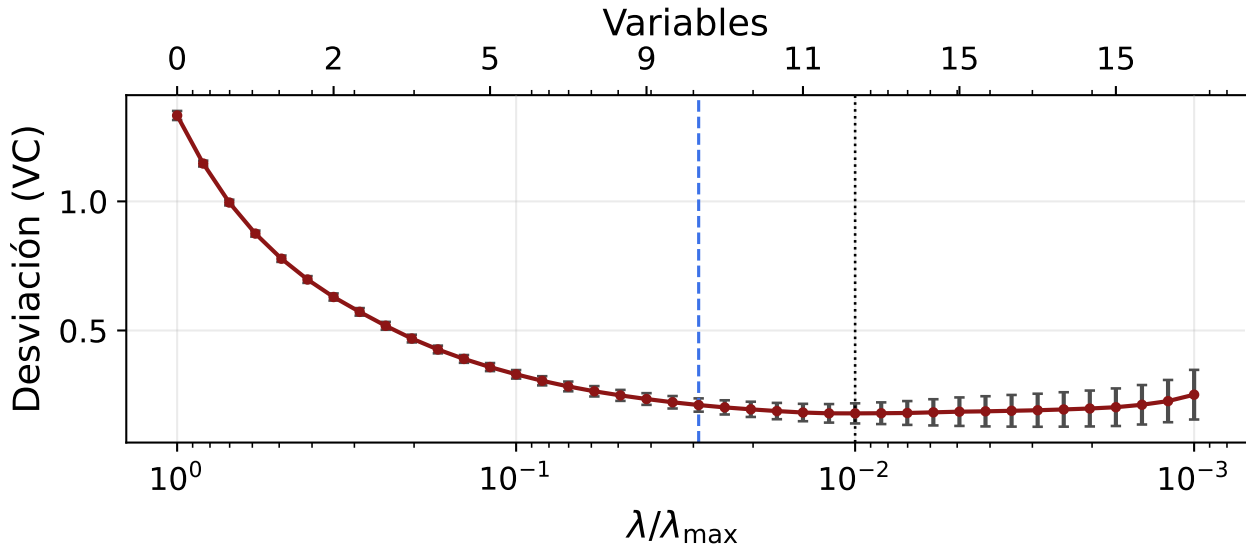
$$\lambda \geq \lambda_{\mathsf{máx}} = \max_j \tfrac{1}{n} \big| \mathrm{x}_j^\top (\mathrm{y} - \bar{y}) \big|.$$

Caminos de regularización



Se usan las 30 variables de cáncer de mama. Ridge encoge todos los coeficientes en forma continua y, con λ pequeño, los deja crecer hacia la solución separadora. El lasso los incorpora uno a uno. Entran primero los peores valores de los puntos cóncavos, del radio y de la textura.

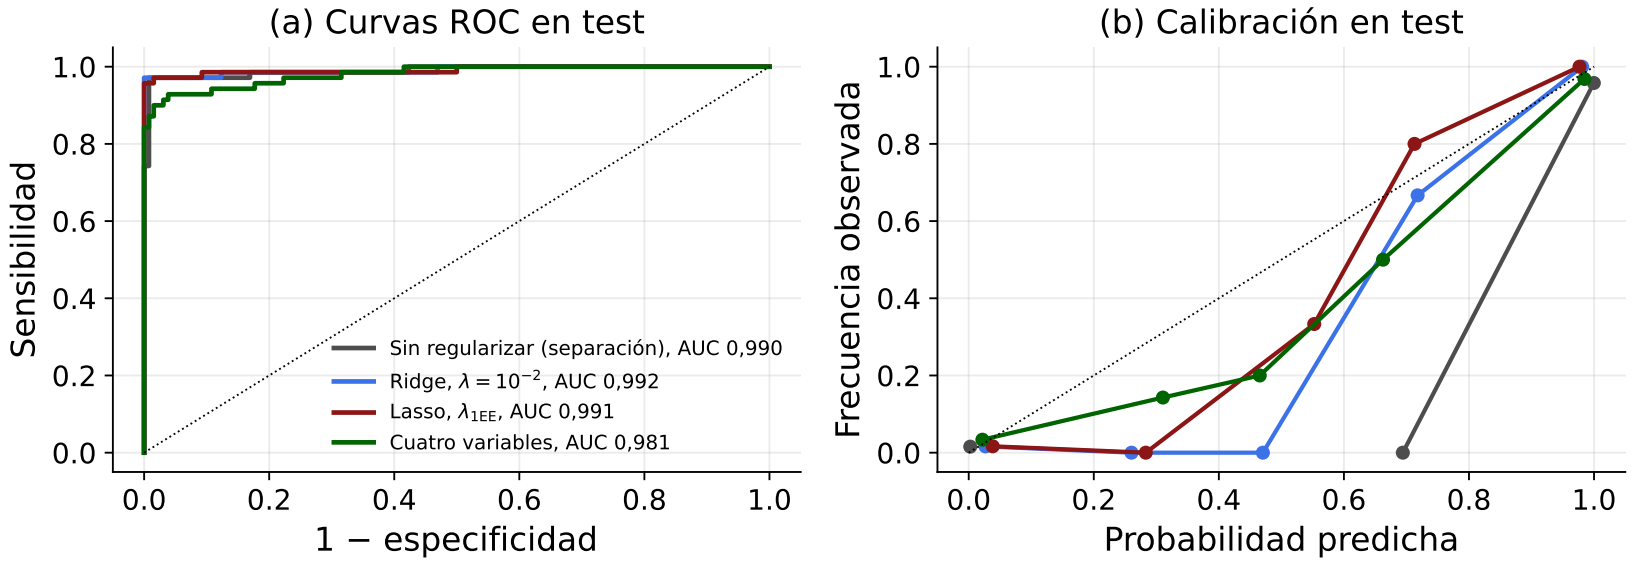
Elección de λ por validación cruzada



La curva es la desviación media en diez pliegues, con su error estándar. El mínimo (línea punteada) usa 13 variables. La regla de un error estándar (línea discontinua) elige 9 variables. Su desviación no difiere estadísticamente de la del mínimo.

La desviación de validación evalúa las probabilidades. El error de clasificación es más ruidoso, porque sólo cambia cuando un caso cruza el umbral.

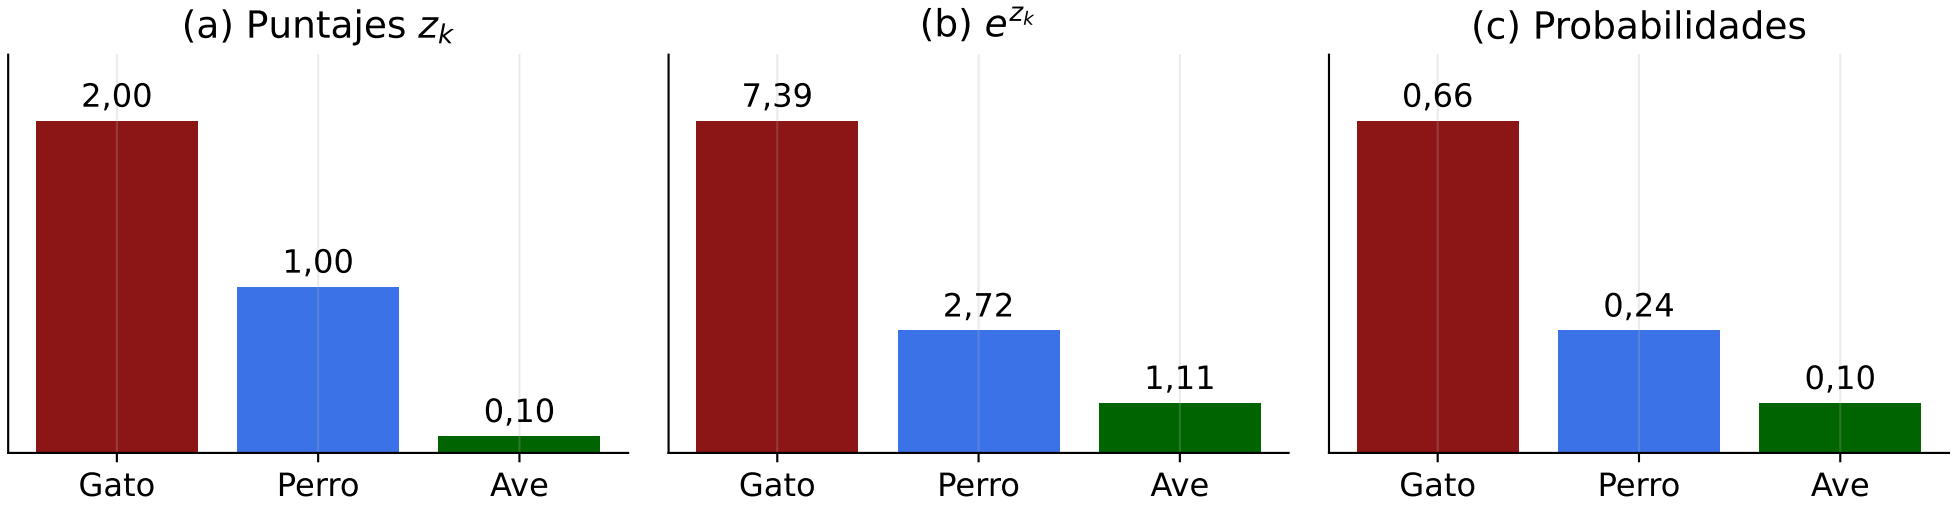
Evaluación de los modelos regularizados



Modelo	Error	AUC	Log verosim. neg.	Brier
Sin regularizar (separación)	0,030	0,990	0,51	0,027
Ridge, $\lambda = 10^{-2}$	0,015	0,992	0,08	0,019
Lasso, λ_{1EE}	0,020	0,991	0,10	0,022
Cuatro variables	0,050	0,981	0,16	0,046

Más de dos clases

Tres puntajes y tres probabilidades



Un clasificador de imágenes calcula un puntaje por clase, 2 para gato, 1 para perro y $0,1$ para ave. La función **softmax** exponencia cada puntaje, y así todos quedan positivos. Luego divide por la suma, $7,39 + 2,72 + 1,11 = 11,21$, y así suman uno. Las probabilidades son $0,66$, $0,24$ y $0,10$. Sumar la misma constante a los tres puntajes no cambia el resultado.

Regresión softmax

Sea $y \in \{1, \dots, K\}$, con un vector de coeficientes $\boldsymbol{\beta}_k$ por clase. La función softmax da

$$\Pr(y = k \mid \mathrm{x}) = \frac{\exp(\mathrm{x}^\top \boldsymbol{\beta}_k)}{\sum_{k'=1}^{K} \exp(\mathrm{x}^\top \boldsymbol{\beta}_{k'})}.$$

- Sumar el mismo vector a todos los $\boldsymbol{\beta}_k$ no cambia las probabilidades. Para eliminar esta indeterminación, se fija una clase de referencia, $\boldsymbol{\beta}_K = 0$, o se penaliza.
- Con $K = 2$ y $\boldsymbol{\beta}_2 = 0$ se recupera la regresión logística, con $\boldsymbol{\beta} = \boldsymbol{\beta}_1$.
- El logaritmo del cociente de probabilidades de dos clases es lineal, $\log \frac{\Pr(y=k|\mathrm{x})}{\Pr(y=K|\mathrm{x})} = \mathrm{x}^\top \boldsymbol{\beta}_k$. Las fronteras entre clases son hiperplanos.

Verosimilitud y gradiente multiclase

Sea Y la codificación one-hot ($n \times K$, un uno por fila en la columna de la clase) y P la matriz de probabilidades predichas. La log verosimilitud negativa es la **entropía cruzada multiclase**,

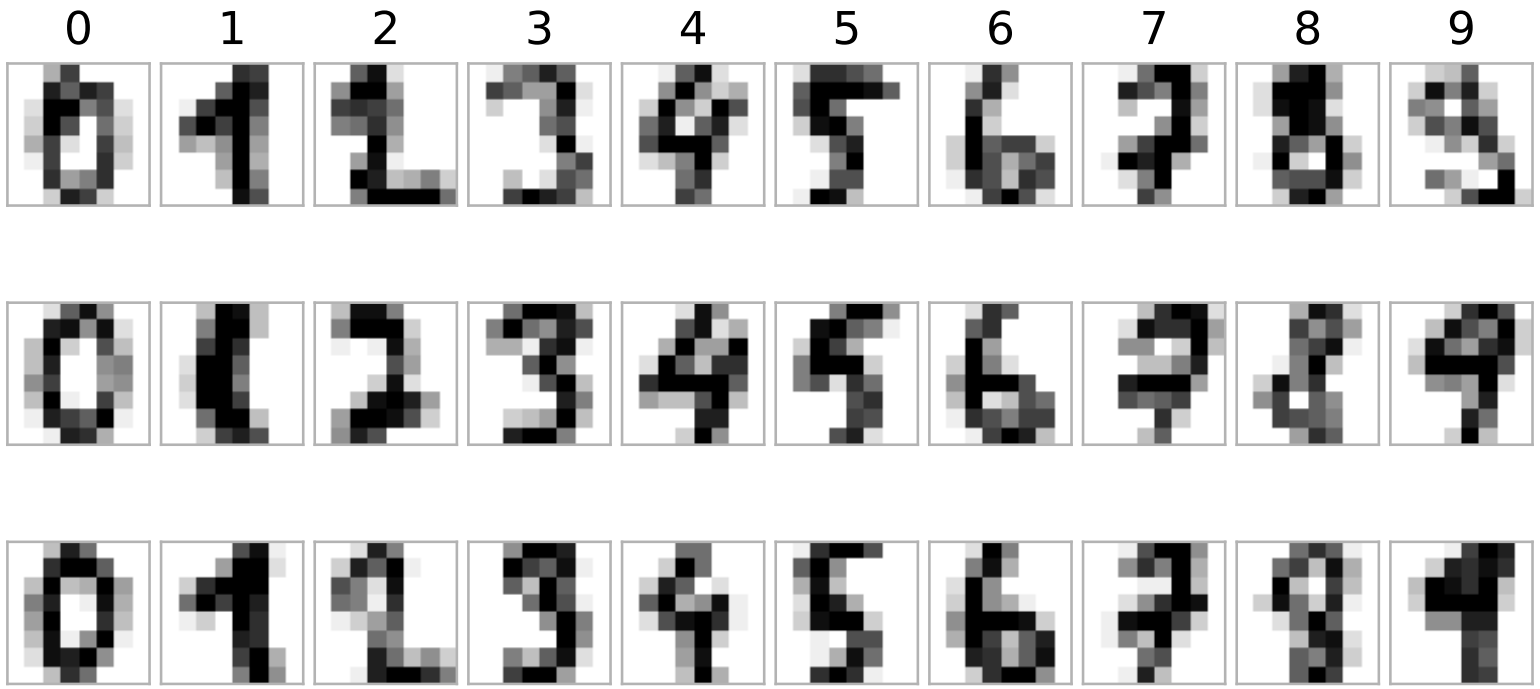
$$\ell(\mathrm{B}) = -\sum_{i=1}^{n} \log P_{i y_i} = \sum_{i=1}^{n} \left[\log \sum_{k} e^{\mathbf{x}_i^\top \boldsymbol{\beta}_k} - \mathbf{x}_i^\top \boldsymbol{\beta}_{y_i} \right],$$

y su gradiente respecto de la matriz $\mathrm{B} = [\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_K]$ es

$$\nabla_{\mathrm{B}} \ell = \mathrm{X}^\top (\mathrm{P} - \mathrm{Y}).$$

El gradiente tiene la forma del caso binario. La función es convexa y su hessiano tiene bloques $\mathrm{X}^\top \mathrm{W}_{kk'} \mathrm{X}$ con $\mathrm{W}_{kk'} = \operatorname{diag}\left(P_{ik}(\delta_{kk'} - P_{ik'})\right)$. Con pK grande, se minimiza con L-BFGS.

Dígitos manuscritos

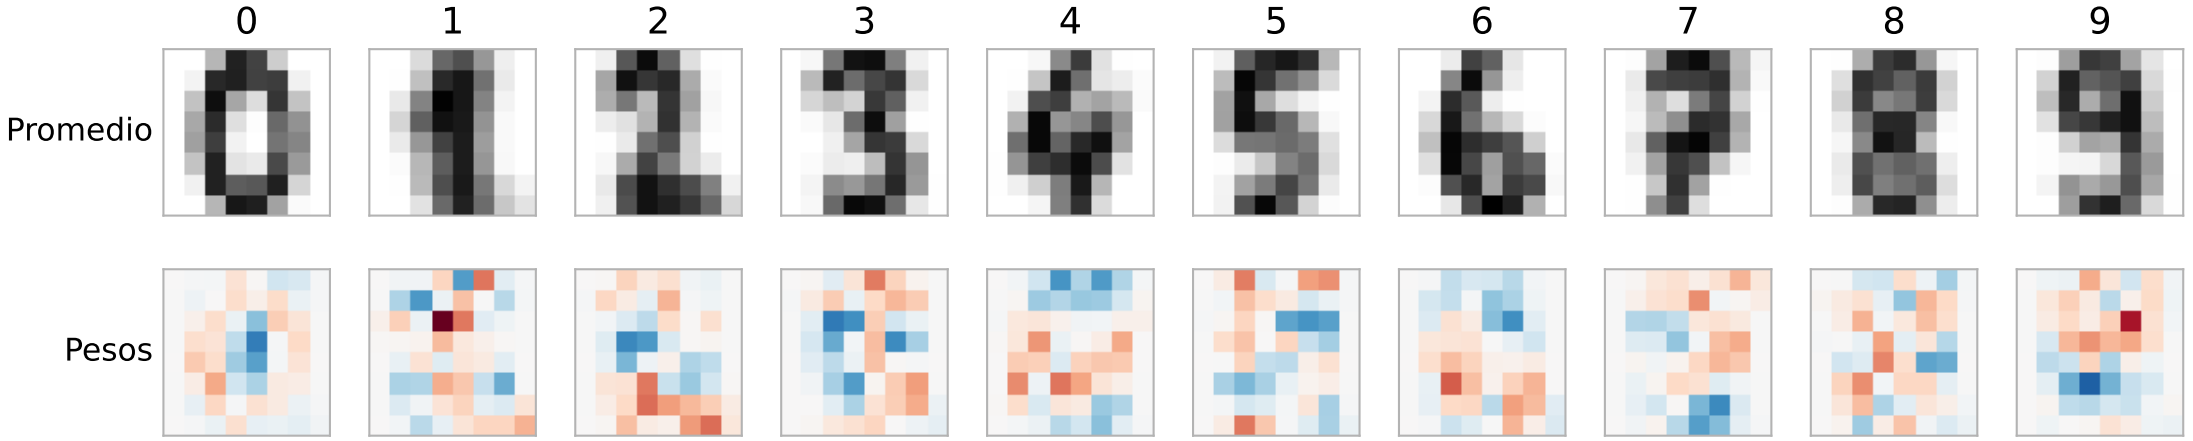


64 números

0	1	8	10	14	10	0	0
0	12	10	6	6	16	2	0
0	3	0	0	7	14	1	0
0	0	0	0	9	11	0	0
0	0	0	0	2	16	1	0
0	0	0	0	0	8	12	0
0	0	4	0	2	11	9	0
0	0	12	16	14	12	4	0

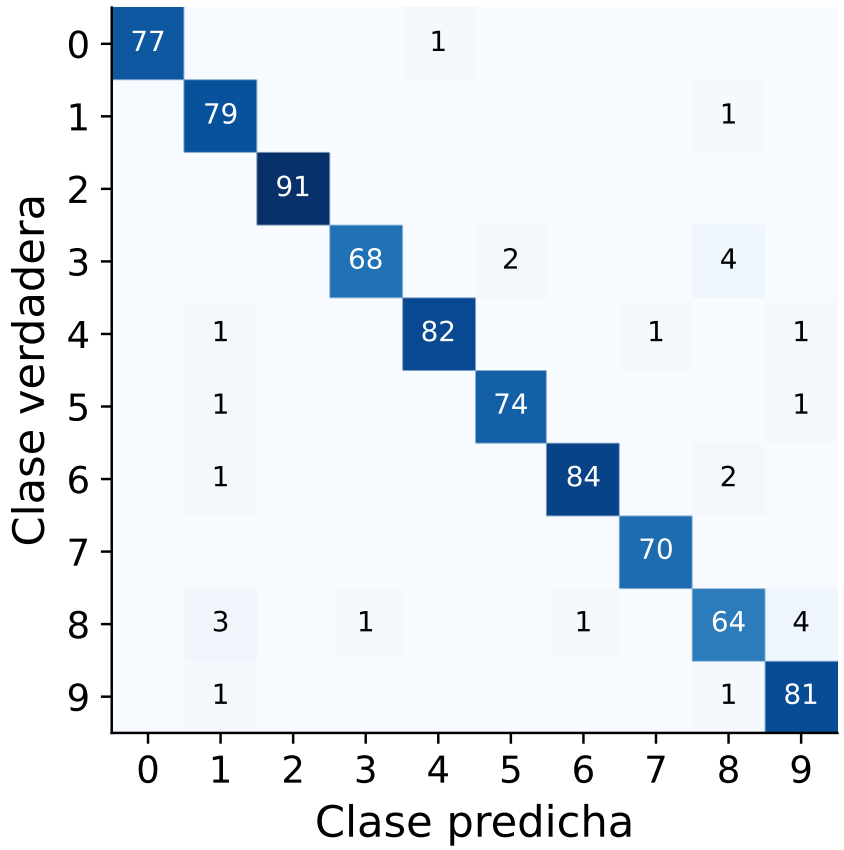
Hay $1\,797$ dígitos escritos a mano, digitalizados en imágenes de 8×8 píxeles con 17 niveles de gris. A la izquierda hay tres ejemplos de cada clase. Para el modelo, cada imagen es un vector de 64 números entre 0 y 16 (derecha). Se usan $1\,000$ imágenes para entrenar y 797 para evaluar.

Los pesos de cada clase



Se ajusta una regresión softmax sobre los 64 píxeles, con penalización L2 elegida por validación cruzada. La fila de arriba muestra el dígito promedio de cada clase. La de abajo muestra los pesos β_k de cada clase. Un píxel rojo aumenta las chances de la clase cuando tiene tinta, y uno azul las disminuye. Los pesos no copian el promedio. Marcan los píxeles que distinguen una clase de las demás. El cero tiene pesos negativos en el centro, donde los otros dígitos tienen tinta.

Evaluación con los dígitos



En 797 dígitos de test el error es $3{,}4\,\%$, igual al error de scikit-learn con la misma penalización.

El modelo es lineal en los píxeles y tiene 650 parámetros.

Los errores más frecuentes son ochos predichos como nueves o como unos, y treses predichos como ochos.

Un caso con variables mixtas

Reingreso hospitalario a 30 días

Los datos son simulados y la verdad es conocida. Hay 600 pacientes egresados y el 36 % reingresa antes de 30 días. Las variables numéricas tienen correlaciones realistas (la hemoglobina con la creatinina, los fármacos con los días de hospitalización). Por eso hay variables sin efecto asociadas con variables con efecto.

Ocho de las 21 variables tienen efecto. Con la codificación de referencia, las 14 numéricas y los 7 factores ocupan 31 columnas.

El objetivo es predecir el reingreso de pacientes nuevos e identificar las variables asociadas con él. La mitad de las variables numéricas y tres de los siete factores no tienen efecto.

Las variables

Variable	Tipo	Niveles o unidad	Efecto verdadero
Edad	Numérica	Años	Sí
Creatinina	Numérica	mg/dL	Sí
Hemoglobina	Numérica	g/dL	No
Días	Numérica	Días de hospitalización	Sí
Fármacos	Numérica	Número al alta	Sí
Ingreso	Categórica	Electivo, Derivado, Urgencia	Sí
Servicio	Categórica	Medicina, Cardiología, Cirugía, Traumatología	Sí
Tabaquismo	Categórica	Nunca, Actual, Ex	Sí
Previsión	Categórica	Isapre, Fonasa A-B, Fonasa C-D	Sí
Sexo	Categórica	Mujer, Hombre	No
Región	Categórica	RM, Austral, Centro, Norte, Sur	No
Estado civil	Categórica	Casado, Separado, Soltero, Viudo	No
IMC, PAS, HbA1c, sodio, potasio, FC, colesterol, plaquetas, temperatura	Numérica	–	No

Variables categóricas en la regresión logística

Un factor con L niveles se representa con $L - 1$ columnas indicadoras, una por nivel distinto del de referencia. El coeficiente de cada columna es el logaritmo de la razón de chances de ese nivel frente a la referencia.

Ingreso	**Urgencia**	**Derivado**
Electivo (referencia)	0	0
Urgencia	1	0
Derivado	0	1

El lasso sobre las columnas tiene dos problemas para seleccionar factores.

- Puede retener sólo algunos niveles de un factor. Lo que interesa saber es si el factor completo tiene efecto.
- Las columnas retenidas dependen del nivel de referencia, y esa elección es arbitraria.

Group lasso

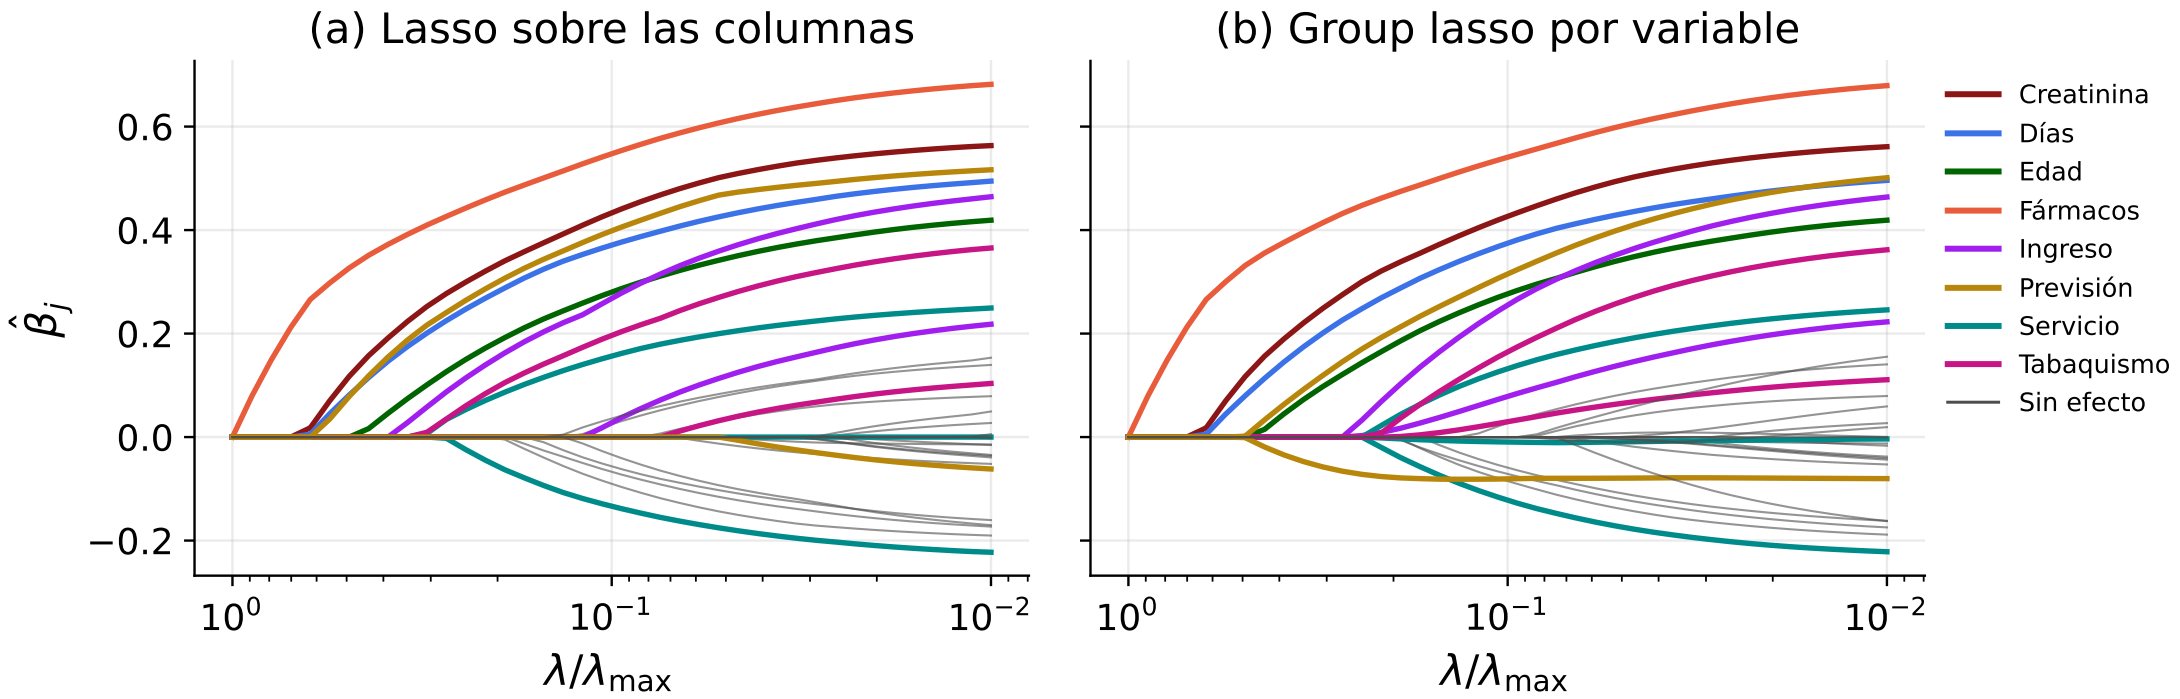
Las columnas se agrupan por variable, $\boldsymbol{\beta} = (\boldsymbol{\beta}_1, \dots, \boldsymbol{\beta}_G)$, con un grupo por variable numérica y uno por factor.

El estimador es

$$\hat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta}}{\operatorname{argmin}} \frac{1}{n}\ell(\boldsymbol{\beta}) + \lambda \sum_{g=1}^{G} \sqrt{p_g}\, \|\boldsymbol{\beta}_g\|_2 .$$

- La norma euclídea sin elevar al cuadrado no es diferenciable en $\boldsymbol{\beta}_g = 0$. Por eso anula grupos completos, como el valor absoluto anula coeficientes.
- El group lasso actúa como ridge dentro de un grupo seleccionado. Todos los niveles del factor entran juntos.
- El factor $\sqrt{p_g}$ evita favorecer a los factores con más niveles.
- El paso proximal es un umbral suave por bloques, $\boldsymbol{\beta}_g \leftarrow (1 - t\sqrt{p_g}/\|\mathrm{v}_g\|)_+ \mathrm{v}_g$.

Caminos con variables mixtas



Las columnas de las ocho variables con efecto están en color y las demás en gris. El group lasso hace entrar juntas las columnas de cada factor. En ambos métodos, las variables con efecto entran antes que las demás. La excepción son algunas columnas de factores con efectos pequeños.

Nivel de referencia y lasso

Factor (columnas)	Lasso, ref. 1	Lasso, ref. 2	Group lasso, ref. 1	Group lasso, ref. 2
Ingreso (2)	1	1	2	2
Servicio (3)	2	1	3	3
Tabaquismo (2)	1	1	2	2
Previsión (2)	1	2	2	2
Sexo (1)	0	0	0	0
Región (4)	0	0	0	0
Estado civil (3)	0	0	0	0

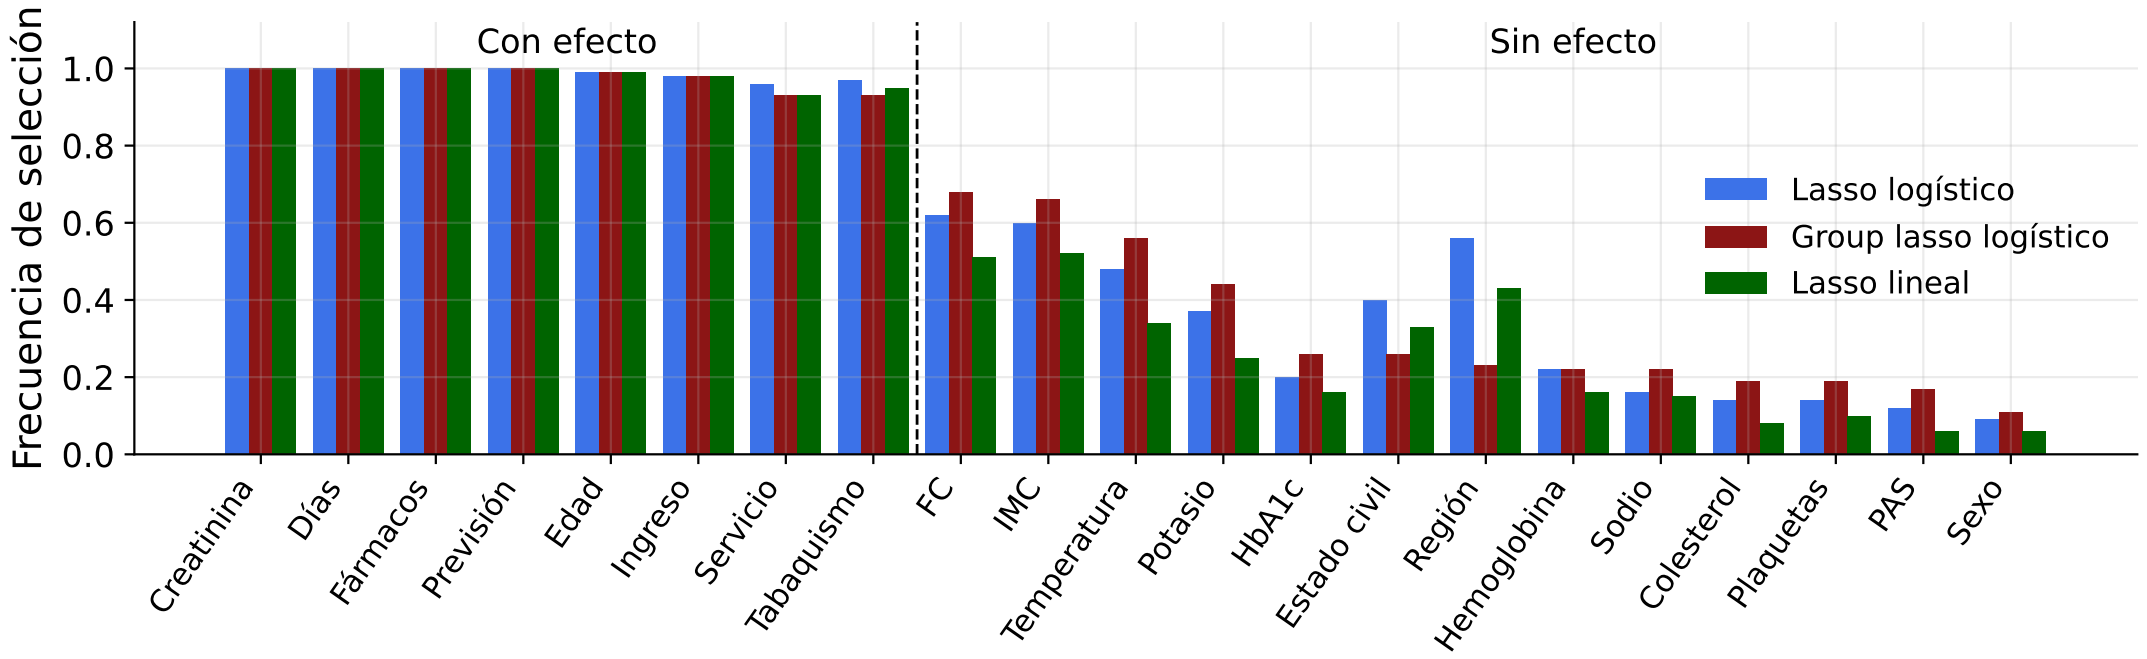
Se cuentan las columnas retenidas de cada factor en $\lambda_{1\text{EE}}$, con dos elecciones de los niveles de referencia. El lasso retiene un número distinto de columnas de Servicio y de Previsión según la referencia, y casi nunca las retiene todas. El group lasso retiene o descarta cada factor completo y decide igual con ambas referencias.

Resultados de la selección

Estimador	Verdaderas	Falsas	AUC	Brier
Lasso logístico	8 de 8	2	$0{,}740$	$0{,}1882$
Group lasso logístico	8 de 8	3	$0{,}736$	$0{,}1892$
Lasso lineal (prob. lineal)	8 de 8	0	$0{,}736$	$0{,}1899$
Group lasso lineal (prob. lineal)	8 de 8	3	$0{,}736$	$0{,}1899$
Oráculo, máxima verosimilitud	8 de 8	0	$0{,}753$	$0{,}1880$
Todas, máxima verosimilitud	8 de 8	13	$0{,}741$	$0{,}1952$
Probabilidad verdadera	–	–	$0{,}768$	$0{,}1789$

Se usan diez pliegues y la regla de un error estándar. El AUC y el Brier se miden en $20\,000$ pacientes nuevos. Todos los estimadores recuperan las ocho variables con efecto. Todos salvo el lasso lineal retienen dos o tres sin efecto (frecuencia cardiaca, temperatura, IMC). El oráculo conoce las ocho variables y su AUC difiere del resto en $0{,}01$ a $0{,}02$. El modelo con las 21 variables sin penalizar tiene peor Brier que el lasso ($0{,}195$ frente a $0{,}188$).

Estabilidad de la selección



Se mide la frecuencia con que se selecciona cada variable en 100 submuestras de 300 pacientes. Con los tres métodos, las ocho variables con efecto aparecen en más del 90 % de las submuestras. La frecuencia cardiaca y el IMC aparecen en la mitad o más. Los métodos difieren en los factores sin efecto. El lasso retiene alguna columna de Región en el 56 % de las submuestras y el group lasso sólo en el 23 %.

Regresión lineal frente a logística

En este caso, el lasso lineal sobre la respuesta 0/1 seleccionó las mismas ocho variables y menos variables sin efecto. Su AUC fue $0{,}736$ y el del lasso logístico fue $0{,}740$. Con probabilidades entre $0{,}1$ y $0{,}7$ la sigmoide es casi lineal, y por eso ambos modelos ordenan las variables de modo parecido.

Para seleccionar variables o estimar efectos promedio, la regresión lineal sobre 0/1 es un punto de partida aceptable, sobre todo con probabilidades moderadas. Sus coeficientes son diferencias de probabilidad.

Para predecir probabilidades, la logística es la opción correcta. Sus predicciones quedan en $[0,\,1]$, su varianza es la de una Bernoulli y está calibrada por construcción en el entrenamiento. Con eventos raros o probabilidades cercanas a 0 o 1, los dos modelos difieren mucho.

Combinarlas significa seleccionar con el modelo lineal y luego ajustar una logística con las variables elegidas. Esto no mejora al lasso logístico, que selecciona con la misma verosimilitud que usa para predecir.

Implementación

```
from sklearn.linear_model import LogisticRegression, LogisticRegressionCV


# scikit-learn: C = 1/(n*lambda); el intercepto no se penaliza
ridge = LogisticRegression(C=1.0)                                        # L2
lasso = LogisticRegressionCV(Cs=30, penalty="l1", solver="saga", cv=10,
                             scoring="neg_log_loss", max_iter=10000)     # L1, lambda por VC
red = LogisticRegression(penalty="elasticnet", l1_ratio=0.5, solver="saga", C=1.0)
softmax = LogisticRegression(C=1.0)          # con y de K clases ajusta el modelo multinomial
```

Errores frecuentes

- No estandarizar antes de penalizar. En ese caso la penalización depende de las unidades de medida.
- Elegir λ con el conjunto de test.
- Evaluar con el AUC un modelo cuyas probabilidades se van a usar. El AUC no ve la calibración.
- Seleccionar niveles sueltos de un factor con el lasso y olvidar que el resultado depende de la referencia.
- Reportar como estimaciones de los efectos los coeficientes del lasso, que están encogidos hacia cero. La inferencia debe corregir por la selección.
- Usar uno contra el resto y tratar sus puntajes como probabilidades, aunque no sumen uno.

Referencias

- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*, 2.ª ed., secciones 4.4 y 18.4. Springer.
- Hastie, T., Tibshirani, R., Wainwright, M. (2015). *Statistical Learning with Sparsity*, capítulos 3 y 4. CRC Press.
- Agresti, A. (2013). *Categorical Data Analysis*, 3.ª ed., capítulo 7. Wiley.
- Meier, L., van de Geer, S., Bühlmann, P. (2008). The group lasso for logistic regression. *JRSS B*, 70(1), 53–71.
- Beck, A., Teboulle, M. (2009). A fast iterative shrinkage-thresholding algorithm for linear inverse problems. *SIAM Journal on Imaging Sciences*, 2(1), 183–202.
- Serrano, L. G. (2021). *Grokking Machine Learning*, capítulo 6. Manning.
- Street, W. N., Wolberg, W. H., Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. *Proceedings of SPIE*, 1905, 861–870.