

Análisis discriminante

Unidad 5. Clasificación generativa con densidades normales: LDA, QDA y sus variantes

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos



Objetivos

- Distinguir el enfoque generativo, que modela las entradas de cada clase, del enfoque discriminativo de la regresión logística.
- Derivar desde la regla de Bayes la función discriminante cuadrática (QDA) y, con covarianzas iguales, la lineal (LDA).
- Estimar probabilidades a priori, medias y covarianzas, y aplicar el algoritmo a un ejemplo pequeño.
- Elegir entre LDA y QDA según el tamaño de la muestra, considerando el sesgo y la varianza.
- Comparar LDA y la regresión logística en eficiencia y robustez.
- Interpretar el discriminante de Fisher como proyección y usarlo para reducir la dimensión.
- Regularizar el discriminante cuando hay muchas variables y pocas observaciones.

Dos formas de estimar $\Pr(y = k \mid \mathbf{x})$

La regla de Bayes asigna $\mathbf{x}$ a la clase de mayor probabilidad a posteriori. Hay dos formas de estimarla.


Discriminativa. Modelar $\Pr(y = k \mid \mathbf{x})$ directamente, como la regresión logística. Este enfoque no supone nada sobre la distribución de las $\mathbf{x}$.

Generativa. Modelar las entradas de cada clase con una densidad $f_k(\mathbf{x})$ y una probabilidad a priori π_k . Luego aplicar el teorema de Bayes:

$$\Pr(y = k \mid \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x})}{\sum_{j=1}^K \pi_j f_j(\mathbf{x})}.$$

El denominador es igual para todas las clases. Por eso la regla de Bayes asigna $\mathbf{x}$ a la clase con mayor $\pi_k f_k(\mathbf{x})$.

La regla de Bayes en una dimensión



Dos clases normales con medias 0 y 2 y varianza uno. La frontera (línea discontinua) está donde $\pi_1 f_1(x) = \pi_2 f_2(x)$. El área gris es la probabilidad de error de Bayes. Con probabilidades a priori iguales, la frontera es el punto medio entre las medias. Si la clase 1 es más frecuente, la frontera se mueve hacia la clase 2. Así, un caso necesita más evidencia para quedar en esa clase.

Del supuesto normal a QDA y LDA

La función discriminante cuadrática

Si las entradas de la clase k siguen una normal multivariada $N(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$,

$$f_k(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}_k|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right).$$

El logaritmo de $\pi_k f_k(\mathbf{x})$, sin la constante común $-\frac{p}{2} \log 2\pi$, es

$$\delta_k(\mathbf{x}) = -\frac{1}{2} \log |\boldsymbol{\Sigma}_k| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) + \log \pi_k.$$

La regla de Bayes asigna $\mathbf{x}$ a la clase con mayor $\delta_k(\mathbf{x})$. Como δ_k es cuadrática en $\mathbf{x}$, las fronteras $\delta_k(\mathbf{x}) = \delta_j(\mathbf{x})$ son cuádricas (elipses, parábolas o hipérbolas en dos dimensiones).

Este es el **análisis discriminante cuadrático** (QDA).

La función discriminante lineal

Si todas las clases comparten la covarianza, $\Sigma_k = \Sigma$, el término $\log |\Sigma|$ es común y se elimina. Desarrollando la forma cuadrática,

$$(\mathbf{x} - \boldsymbol{\mu}_k)^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) = \mathbf{x}^\top \Sigma^{-1} \mathbf{x} - 2 \mathbf{x}^\top \Sigma^{-1} \boldsymbol{\mu}_k + \boldsymbol{\mu}_k^\top \Sigma^{-1} \boldsymbol{\mu}_k,$$

El primer término también es común a todas las clases.

Queda la **función discriminante lineal**,

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^\top \Sigma^{-1} \boldsymbol{\mu}_k + \log \pi_k,$$

lineal en $\mathbf{x}$. Este es el **análisis discriminante lineal** (LDA).

Entre dos clases, la frontera es el hiperplano

$$\mathbf{x}^\top \Sigma^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \frac{1}{2} (\boldsymbol{\mu}_1^\top \Sigma^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^\top \Sigma^{-1} \boldsymbol{\mu}_2) - \log \frac{\pi_1}{\pi_2}.$$

Estimación

Con n_k observaciones en la clase k y $n = \sum_k n_k$,

$$\hat{\pi}_k = \frac{n_k}{n}, \quad \hat{\boldsymbol{\mu}}_k = \frac{1}{n_k} \sum_{i: y_i=k} \mathbf{x}_i,$$

$$\hat{\boldsymbol{\Sigma}}_k = \frac{1}{n_k - 1} \sum_{i: y_i=k} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_k)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_k)^\top \quad (\text{QDA}),$$


$$\hat{\boldsymbol{\Sigma}} = \frac{1}{n - K} \sum_{k=1}^K \sum_{i: y_i=k} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_k)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_k)^\top \quad (\text{LDA, covarianza conjunta}).$$

Algoritmo. Estimar $\hat{\pi}_k$, $\hat{\boldsymbol{\mu}}_k$ y $\hat{\boldsymbol{\Sigma}}$ (o $\hat{\boldsymbol{\Sigma}}_k$). Para un $\mathbf{x}$ nuevo, calcular $\hat{\delta}_k(\mathbf{x})$ en cada clase. Asignar $\hat{y} = \operatorname{argmax}_k \hat{\delta}_k(\mathbf{x})$. La softmax de los $\hat{\delta}_k$ da las probabilidades a posteriori.

Ejemplo, control de calidad de chips

Curvatura	Diámetro	Control
2,95	6,63	Aprobado
2,53	7,79	Aprobado
3,57	5,65	Aprobado
3,16	5,47	Aprobado
2,58	4,46	Rechazado
2,16	6,22	Rechazado
3,27	3,52	Rechazado

Una fábrica quiere automatizar el control de calidad de un chip. Para ello usa su curvatura y su diámetro. Expertos evaluaron siete chips. Un chip nuevo tiene curvatura 2,81 y diámetro 5,46.



Ejemplo, el cálculo

Con $\hat{\pi}_1 = 4/7, \hat{\pi}_2 = 3/7$,

$$\hat{\mu}_1 = \begin{pmatrix} 3,05 \\ 6,39 \end{pmatrix}, \quad \hat{\mu}_2 = \begin{pmatrix} 2,67 \\ 4,73 \end{pmatrix}, \quad \hat{\Sigma} = \begin{pmatrix} 0,238 & -0,540 \\ -0,540 & 1,434 \end{pmatrix}.$$


Para el chip nuevo $\mathbf{x} = (2,81; 5,46)$,

$$\hat{\delta}_1(\mathbf{x}) = -4,36, \quad \hat{\delta}_2(\mathbf{x}) = -1,99,$$

y la probabilidad a posteriori de rechazo es $e^{-1,99} / (e^{-4,36} + e^{-1,99}) = 0,92$. El chip se **rechaza**.


El chip nuevo tiene un diámetro alto para un rechazado. Pero su curvatura es baja para su diámetro. En los aprobados, la curvatura y el diámetro tienen correlación negativa. La distancia de Mahalanobis considera esa correlación. Con siete observaciones, ninguna conclusión de este tipo es estable.

Fronteras de LDA y QDA



Hay ciento cincuenta observaciones por clase. Con covarianzas iguales (a), las fronteras estimadas están cerca de la de Bayes. Con covarianzas distintas (b), la frontera de Bayes es una hipérbola. QDA la aproxima, y LDA sólo puede trazar una recta.

Sesgo y varianza en LDA y QDA



Las covarianzas verdaderas son distintas y $p = 10$. LDA estima $p(p + 1)/2 = 55$ parámetros de covarianza. QDA estima K veces más, 110.

Con 40 o menos observaciones por clase, LDA tiene menor error, aunque su frontera esté mal especificada. Desde unas 70 por clase, QDA es mejor. Con 400, QDA queda a 0,6 puntos del error de Bayes.

LDA tiene más sesgo y menos varianza que QDA. Aquí la covarianza determina la capacidad.

LDA y regresión logística

Dos estimadores de la misma frontera

Con dos clases, el logaritmo de las chances según LDA es


$$\log \frac{\Pr(y = 1 \mid \mathbf{x})}{\Pr(y = 2 \mid \mathbf{x})} = \log \frac{\pi_1}{\pi_2} - \frac{1}{2}(\underbrace{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2}_{\boldsymbol{\beta}_0})^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) + \mathbf{x}^\top \boldsymbol{\Sigma}^{-1}(\underbrace{\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2}_{\boldsymbol{\beta}}),$$

Esta expresión tiene la forma del modelo logístico.

Ambos métodos ajustan $\boldsymbol{\beta}_0 + \boldsymbol{\beta}^\top \mathbf{x}$, pero de distinta manera:

- La regresión logística maximiza la verosimilitud **condicional** $\prod_i \Pr(y_i \mid \mathbf{x}_i)$. No supone nada sobre las $\mathbf{x}$.
- LDA maximiza la verosimilitud **conjunta** $\prod_i \Pr(y_i) f_{y_i}(\mathbf{x}_i)$ y supone normalidad con covarianza común. Calcula $\boldsymbol{\beta}$ con medias y covarianzas.


Eficiencia y robustez



La covarianza es común y $p = 5$. Con datos normales (a), LDA es algo mejor con pocos datos y ambos llegan al error de Bayes. Efron (1975) mostró que, bajo normalidad, la eficiencia relativa de la logística está entre un medio y dos tercios. La logística necesita entre un 50 % más y el doble de datos para la misma precisión. Con un 5 % de observaciones atípicas en una clase (b), LDA se aleja del error de Bayes (23,2 % frente a 21,8 % con 320 por clase). La logística casi no cambia (22,0 %).

El discriminante de Fisher

La dirección de Fisher




Fisher (1936) buscó la dirección w que maximiza la separación de las clases proyectadas dividida por su dispersión,

$$J(w) = \frac{(w^\top \hat{\mu}_1 - w^\top \hat{\mu}_2)^2}{w^\top S_W w}, \quad \text{con solución } w \propto S_W^{-1}(\hat{\mu}_1 - \hat{\mu}_2),$$

que es la dirección de LDA, sin suponer normalidad. La proyección sobre la diferencia de medias (b) da $J = 0,65$, y la de Fisher (c) da $J = 2,0$.

LDA como reducción de dimensión



Con K clases, las direcciones discriminantes son los vectores propios de $S_W^{-1}S_B$. La matriz S_B es la dispersión entre las medias de clase. Hay a lo sumo $K - 1$ direcciones. Las componentes principales (a) maximizan la varianza total y no usan las etiquetas. Las direcciones discriminantes (b) maximizan la separación de las clases. En los dígitos, aíslan el cero, el cuatro y el seis.

Muchas variables y pocas
observaciones


Discriminante regularizado

Con p grande, $\hat{\Sigma}$ tiene $p(p + 1)/2$ parámetros y se estima mal. Con $p \geq n - K$, la matriz es singular. Tres métodos encogen la covarianza.

- **Discriminante regularizado** (Friedman, 1989): $\hat{\Sigma}_k(\alpha) = \alpha \hat{\Sigma}_k + (1 - \alpha) \hat{\Sigma}$, entre QDA y LDA.
- **Encogimiento hacia la diagonal**: $\hat{\Sigma}(\gamma) = (1 - \gamma) \hat{\Sigma} + \gamma \frac{\text{tr} \hat{\Sigma}}{p} \mathbf{I}$, el análogo de ridge para covarianzas. Ledoit y Wolf (2004) dan un γ óptimo sin validación cruzada.
- **Bayesiano ingenuo gaussiano**: usa covarianzas diagonales. Supone variables independientes dentro de cada clase.

Los tres usan un modelo menos realista para estimar menos parámetros. Del mismo modo, ridge renuncia a la insesgadez de mínimos cuadrados.

Encogimiento hacia la diagonal



Hay dos clases en $p = 60$ y 40 observaciones por clase. Las variables vecinas están correlacionadas $(0,5^{|i-j|})$. La covarianza tiene 1 830 parámetros.

LDA sin encogimiento tiene 39 % de error, y el de Bayes es 20 %. Al encoger hacia la diagonal, el error baja de forma monótona hasta 24,5 % con $\gamma = 1$. Ese valor ignora todas las correlaciones. El bayesiano ingenuo logra 26 %.

Con pocos datos, estimar las correlaciones empeora la clasificación (Bickel y Levina, 2004).

Vinos y dígitos

Método	Vinos, error de VC	Dígitos, error de test
LDA	1,2 %	4,4 %
QDA	0,8 %	No estimable
Discriminante regularizado, $\alpha = 0,5, \gamma = 0,1$	0,7 %	0,8 %
Bayesiano ingenuo	2,8 %	11,9 %
Regresión logística (softmax)	2,0 %	3,4 %

Vinos (Forina et al.). Son 178 vinos de tres cultivares italianos con 13 variables químicas. Se usa validación cruzada de diez pliegues repetida cinco veces. Todos los métodos aciertan en más del 97 % de los casos. QDA y el discriminante regularizado son los mejores.

Dígitos. Son 1 000 imágenes de 8×8 píxeles para entrenar y 797 para evaluar. Hay unos 100 por clase. Las covarianzas de clase son singulares, y QDA no se puede estimar. El discriminante regularizado tiene 0,8 % de error. La regresión softmax tiene 3,4 %.

Implementación

```
import numpy as np
from sklearn.discriminant_analysis import (LinearDiscriminantAnalysis,
                                           QuadraticDiscriminantAnalysis)

def lda(X, y):                                # estimación
    clases = np.unique(y); n, K = len(y), len(clases)
    pis = np.array([np.mean(y == k) for k in clases])
    mus = np.array([X[y == k].mean(0) for k in clases])
    S = sum((X[y == k] - m).T @ (X[y == k] - m) for k, m in zip(clases, mus))/(n - K)
    return clases, pis, mus, np.linalg.inv(S)

def delta(x, pis, mus, Si):                  # funciones discriminantes lineales
    return x @ Si @ mus.T - 0.5*np.sum(mus @ Si * mus, 1) + np.log(pis)

lda_sk = LinearDiscriminantAnalysis(solver="lsqr", shrinkage="auto") # Ledoit-Wolf
qda_sk = QuadraticDiscriminantAnalysis(reg_param=0.1)

Z = LinearDiscriminantAnalysis(n_components=2).fit_transform(X, y) # proyección de Fisher
```

Errores frecuentes

- Creer que LDA exige clases linealmente separables. LDA supone normalidad con covarianza común y funciona con clases que se traslapan.
- Usar QDA con pocas observaciones por clase. Con $n_k \leq p$, las covarianzas son singulares.
- Aplicar LDA a variables categóricas codificadas como números. Para ellas, el supuesto normal no tiene sentido.
- Usar las probabilidades a priori de la muestra cuando difieren de las de la población donde se usará el clasificador. En ese caso, hay que reemplazar $\hat{\pi}_k$.
- Reducir la dimensión con componentes principales antes de clasificar, sin compararlas con las direcciones discriminantes. Estas direcciones sí usan las etiquetas.
- Interpretar los coeficientes de LDA como efectos causales o como razones de chances sin verificar la normalidad.

Referencias

- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*, 2.^a ed., secciones 4.3 y 4.4.5. Springer.
- James, G., Witten, D., Hastie, T., Tibshirani, R. (2021). *An Introduction to Statistical Learning*, 2.^a ed., sección 4.4. Springer.
- Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188.
- Efron, B. (1975). The efficiency of logistic regression compared to normal discriminant analysis. *JASA*, 70(352), 892–898.
- Friedman, J. H. (1989). Regularized discriminant analysis. *JASA*, 84(405), 165–175.
- Bickel, P. J., Levina, E. (2004). Some theory for Fisher's linear discriminant function, naive Bayes, and some alternatives when there are many more variables than observations. *Bernoulli*, 10(6), 989–1010.
- Ledoit, O., Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- Teknomo, K. (2015). *Discriminant Analysis Tutorial* (origen del ejemplo de los chips).