Análisis discriminante

Unidad 5. Clasificación generativa: del conteo al bayesiano ingenuo, LDA, QDA y sus variantes

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos



Objetivos

- Distinguir el enfoque generativo, que modela las entradas de cada clase, del enfoque discriminativo de la regresión logística.
- Aplicar la regla de Bayes con conteos y con el supuesto ingenuo de independencia.
- Interpretar la distancia de Mahalanobis y la forma de la frontera según la forma de cada clase.
- Derivar desde la regla de Bayes la función discriminante cuadrática (QDA) y, con covarianzas iguales, la lineal (LDA).
- Estimar probabilidades a priori, medias y covarianzas, y aplicar el algoritmo a un ejemplo pequeño.
- Elegir entre LDA y QDA según el tamaño de la muestra, y comparar LDA con la regresión logística.
- Interpretar el discriminante de Fisher como proyección y regularizar el discriminante con muchas variables.

Dos formas de estimar $\Pr(y = k \mid \mathrm{x})$

La regla de Bayes asigna x a la clase de mayor probabilidad a posteriori. Hay dos formas de estimarla.

Discriminativa. Modelar $\Pr(y = k \mid \mathrm{x})$ directamente, como la regresión logística. Este enfoque no supone nada sobre la distribución de las x.

Generativa. Modelar las entradas de cada clase con una densidad $f_k(\mathrm{x})$ y una probabilidad a priori π_k. Luego aplicar el teorema de Bayes:

$$\Pr(y = k \mid \mathrm{x}) = \frac{\pi_k f_k(\mathrm{x})}{\sum_{j=1}^{K} \pi_j f_j(\mathrm{x})}.$$

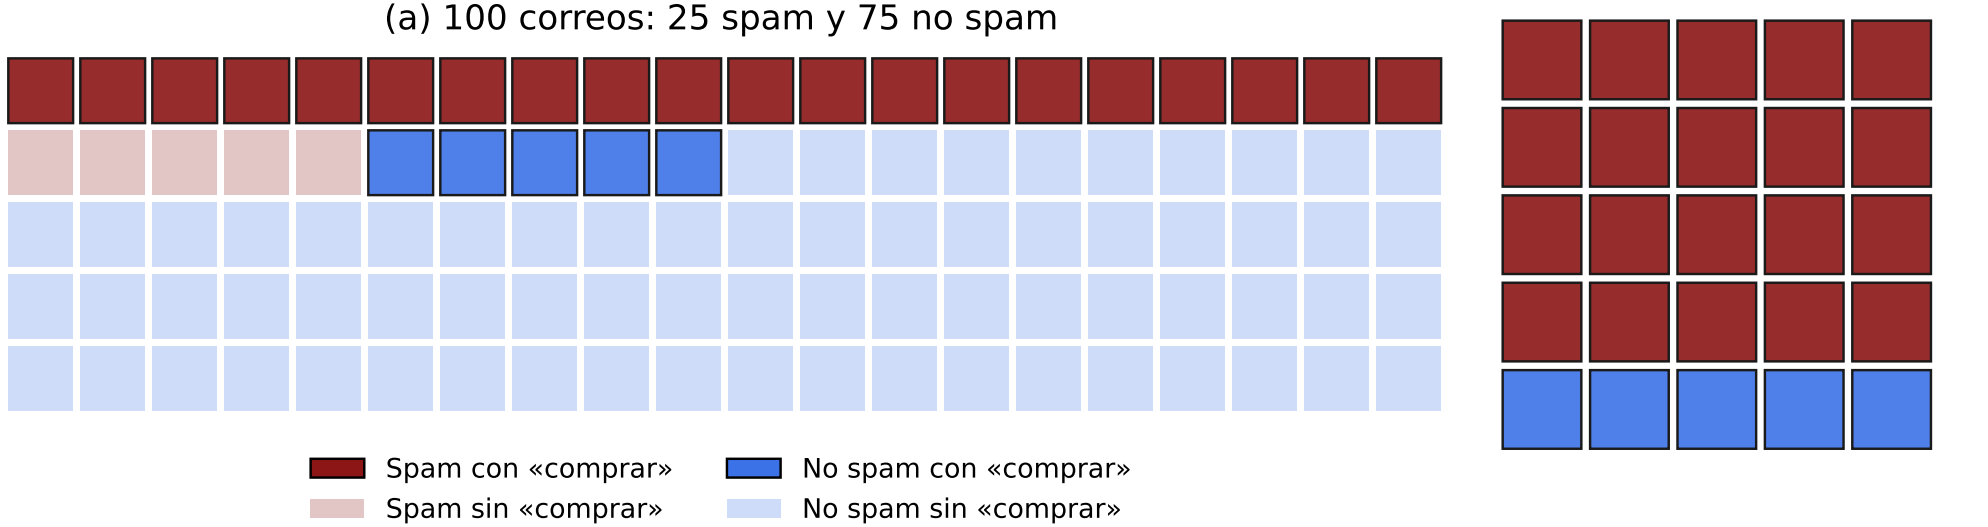
El denominador es igual para todas las clases. Por eso la regla de Bayes asigna x a la clase con mayor $\pi_k f_k(\mathrm{x})$.

El enfoque generativo con conteos

Un filtro de spam con cien correos

(a) 100 correos: 25 spam y 75 no spam

(b) Los 25 que dicen «comprar»



De 100 correos, 25 son spam. La palabra «comprar» aparece en 20 correos spam y en 5 correos que no son spam. Entre los 25 correos con «comprar» (b), 20 son spam. Un correo nuevo con esa palabra es spam con probabilidad $20/25 = 0{,}8$.

El mismo cálculo con el teorema de Bayes

Sea S el evento «es spam» y C el evento «contiene comprar». Por el teorema de Bayes,

$$\begin{aligned}\Pr(\mathrm{S} \mid \mathrm{C}) &= \frac{\Pr(\mathrm{C} \mid \mathrm{S}) \Pr(\mathrm{S})}{\Pr(\mathrm{C} \mid \mathrm{S}) \Pr(\mathrm{S}) + \Pr(\mathrm{C} \mid \text{no S}) \Pr(\text{no S})} \\ &= \frac{\frac{20}{25} \cdot \frac{25}{100}}{\frac{20}{25} \cdot \frac{25}{100} + \frac{5}{75} \cdot \frac{75}{100}} = \frac{0{,}20}{0{,}25} = 0{,}8.\end{aligned}$$

- $\Pr(\mathrm{S}) = 0{,}25$ es la probabilidad **a priori**, antes de leer el correo.
- $\Pr(\mathrm{C} \mid \mathrm{S}) = 0{,}8$ describe cómo se generan los correos spam. Es el modelo **generativo** de la clase.
- El numerador es la fracción de correos que son spam y dicen «comprar». El denominador es la fracción que dice «comprar».

Dos palabras y el supuesto ingenuo

La palabra «barato» aparece en 15 de los 25 correos spam y en 10 de los 75 restantes. Para un correo con «comprar» y «barato», contar los correos con ambas palabras deja muy pocos casos.

El **bayesiano ingenuo** supone que las palabras son independientes dentro de cada clase, y multiplica,

$$\begin{aligned} \text{Spam:} \quad & 0{,}25 \times \tfrac{20}{25} \times \tfrac{15}{25} = 0{,}12, \\ \text{No spam:} \quad & 0{,}75 \times \tfrac{5}{75} \times \tfrac{10}{75} = 0{,}0067. \end{aligned}$$

Normalizando, $\Pr(\text{spam} \mid \text{comprar, barato}) = 0{,}12/(0{,}12 + 0{,}0067) = 0{,}947.$

El supuesto es falso, porque las palabras de un correo dependen entre sí. Pero reduce el modelo a contar cada palabra por separado, y suele clasificar bien.

Con cinco mil correos

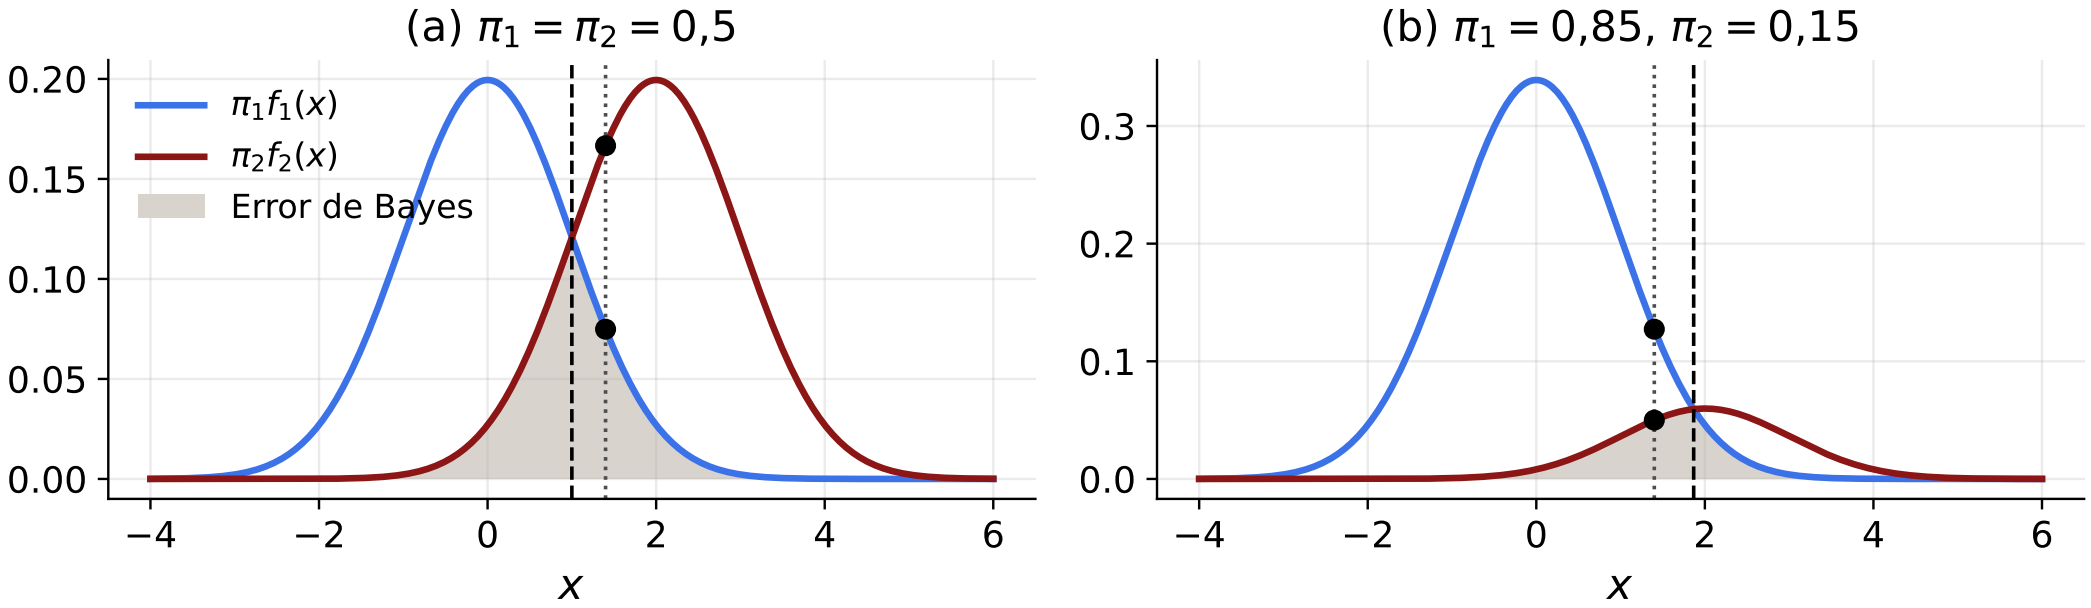
Palabra	**Spam**	**No spam**	$\Pr(\text{spam} \mid \text{palabra})$
`money`	214	75	$0{,}74$
`cheap`	34	13	$0{,}72$
`meeting`	7	642	$0{,}01$
`thanks`	33	1409	$0{,}02$

Hay $5\,728$ correos en inglés, el $24\,\%$ spam. Se entrena con $4\,582$ y se evalúa con $1\,146$. La tabla cuenta los correos de entrenamiento que contienen cada palabra. El clasificador multiplica las probabilidades de las palabras presentes, con suavizado de Laplace. Acierta en el $98{,}8\,\%$ de los correos de evaluación. Decir siempre «no spam» acierta en el $73{,}7\,\%$.

Un correo que sólo dice cheap `money` es spam con probabilidad $0{,}96$.

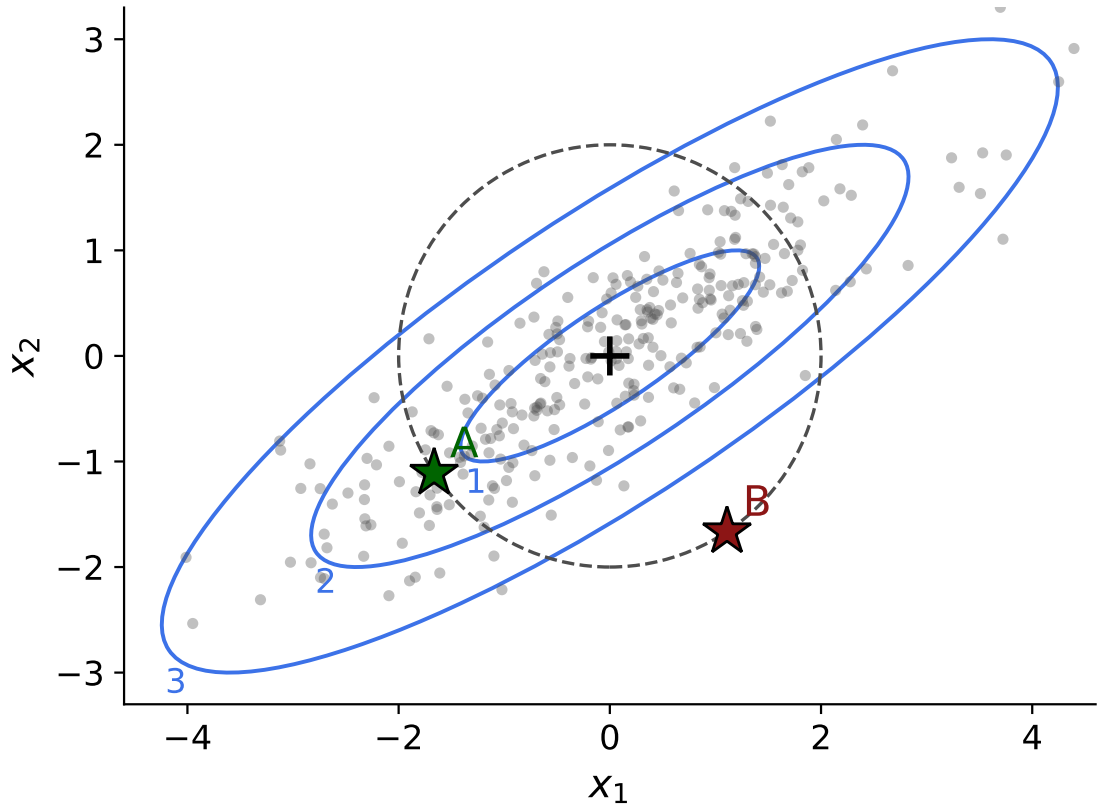
Del supuesto normal a QDA y LDA

La regla de Bayes en una dimensión



Con variables continuas, los conteos se reemplazan por densidades. Dos clases normales tienen medias 0 y 2 y varianza uno. La frontera (discontinua) está donde $\pi_1 f_1(x) = \pi_2 f_2(x)$, y el área gris es el error de Bayes. En $x = 1{,}4$ (punteada), (a) da alturas $0{,}075$ y $0{,}167$, y Pr(clase $2 \mid x$) $= 0{,}167/(0{,}075 + 0{,}167) = 0{,}69$. Con $\pi_1 = 0{,}85$ (b), las alturas son $0{,}127$ y $0{,}050$, y el punto pasa a la clase 1.

La distancia de Mahalanobis



Los puntos A y B están a distancia euclídea 2 del centro (círculo). A está en la dirección en que la nube se extiende y B en la dirección en que es angosta.

La **distancia de Mahalanobis** mide la distancia en unidades de la dispersión de la nube,

$$d_M(\mathrm{x}) = \sqrt{(\mathrm{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathrm{x} - \boldsymbol{\mu})}.$$

A está a $d_M = 1{,}20$ y B a $d_M = 4{,}47$. Las elipses son los puntos a $d_M = 1, 2, 3$. B es mucho más raro que A para esta nube.

La función discriminante cuadrática

Si las entradas de la clase k siguen una normal multivariada $N(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$,

$$f_k(\mathrm{x}) = \frac{1}{(2\pi)^{p/2}|\boldsymbol{\Sigma}_k|^{1/2}} \exp\left(-\tfrac{1}{2}(\mathrm{x}-\boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1}(\mathrm{x}-\boldsymbol{\mu}_k)\right).$$

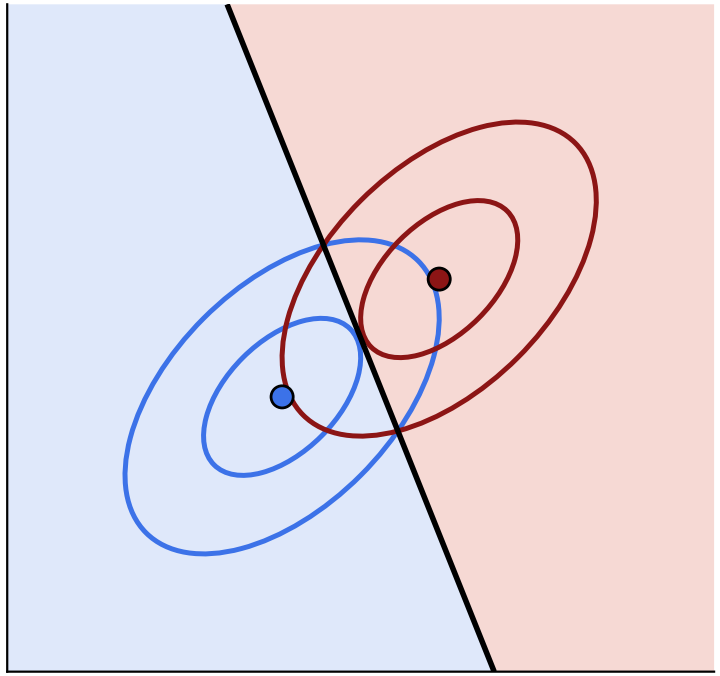
El logaritmo de $\pi_k f_k(\mathrm{x})$, sin la constante común $-\frac{p}{2}\log 2\pi$, es

$$\delta_k(\mathrm{x}) = -\tfrac{1}{2}\log|\boldsymbol{\Sigma}_k| - \tfrac{1}{2}(\mathrm{x}-\boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1}(\mathrm{x}-\boldsymbol{\mu}_k) + \log \pi_k\,.$$

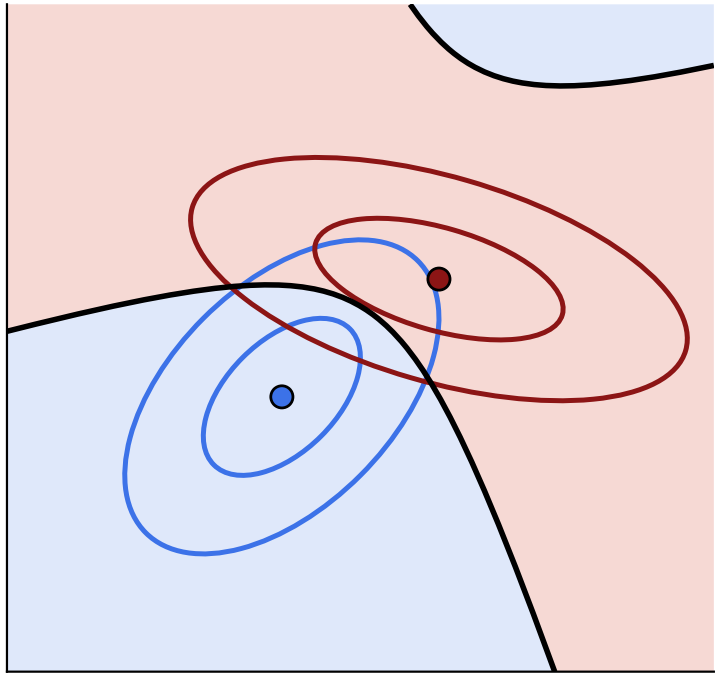
La regla de Bayes asigna x a la clase con mayor $\delta_k(\mathrm{x})$. Como δ_k es cuadrática en x, las fronteras $\delta_k(\mathrm{x}) = \delta_j(\mathrm{x})$ son cuádricas (elipses, parábolas o hipérbolas en dos dimensiones). Este es el **análisis discriminante cuadrático** (QDA).

La forma de las clases y la forma de la frontera

(a) Misma forma: recta



(b) Formas distintas: curva



Cada clase se dibuja con sus elipses de Mahalanobis. En (a) las dos clases tienen la misma covarianza. Los términos cuadráticos en x de δ_1 y δ_2 son iguales y se cancelan, y la frontera es una recta. En (b) las covarianzas son distintas y la frontera es una curva, que rodea a la clase más angosta.

La función discriminante lineal

Si todas las clases comparten la covarianza, $\boldsymbol{\Sigma}_k = \boldsymbol{\Sigma}$, el término $\log |\boldsymbol{\Sigma}|$ es común y se elimina. Desarrollando la forma cuadrática,

$$(\mathrm{x} - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}^{-1} (\mathrm{x} - \boldsymbol{\mu}_k) = \mathrm{x}^\top \boldsymbol{\Sigma}^{-1} \mathrm{x} - 2\, \mathrm{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \boldsymbol{\mu}_k^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k ,$$

El primer término también es común a todas las clases.

Queda la **función discriminante lineal**,

$$\delta_k(\mathrm{x}) = \mathrm{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k - \tfrac{1}{2} \boldsymbol{\mu}_k^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \log \pi_k ,$$

lineal en x. Este es el **análisis discriminante lineal** (LDA).

Entre dos clases, la frontera es el hiperplano

$$\mathrm{x}^\top \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \tfrac{1}{2} (\boldsymbol{\mu}_1^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_2) - \log \frac{\pi_1}{\pi_2} .$$

Estimación

Con n_k observaciones en la clase k y $n = \sum_k n_k$,

$$\hat{\pi}_k = \frac{n_k}{n}, \qquad \hat{\boldsymbol{\mu}}_k = \frac{1}{n_k} \sum_{i:\, y_i = k} \mathrm{x}_i,$$

$$\hat{\boldsymbol{\Sigma}}_k = \frac{1}{n_k - 1} \sum_{i:\, y_i = k} (\mathrm{x}_i - \hat{\boldsymbol{\mu}}_k)(\mathrm{x}_i - \hat{\boldsymbol{\mu}}_k)^\top \quad \text{(QDA)},$$

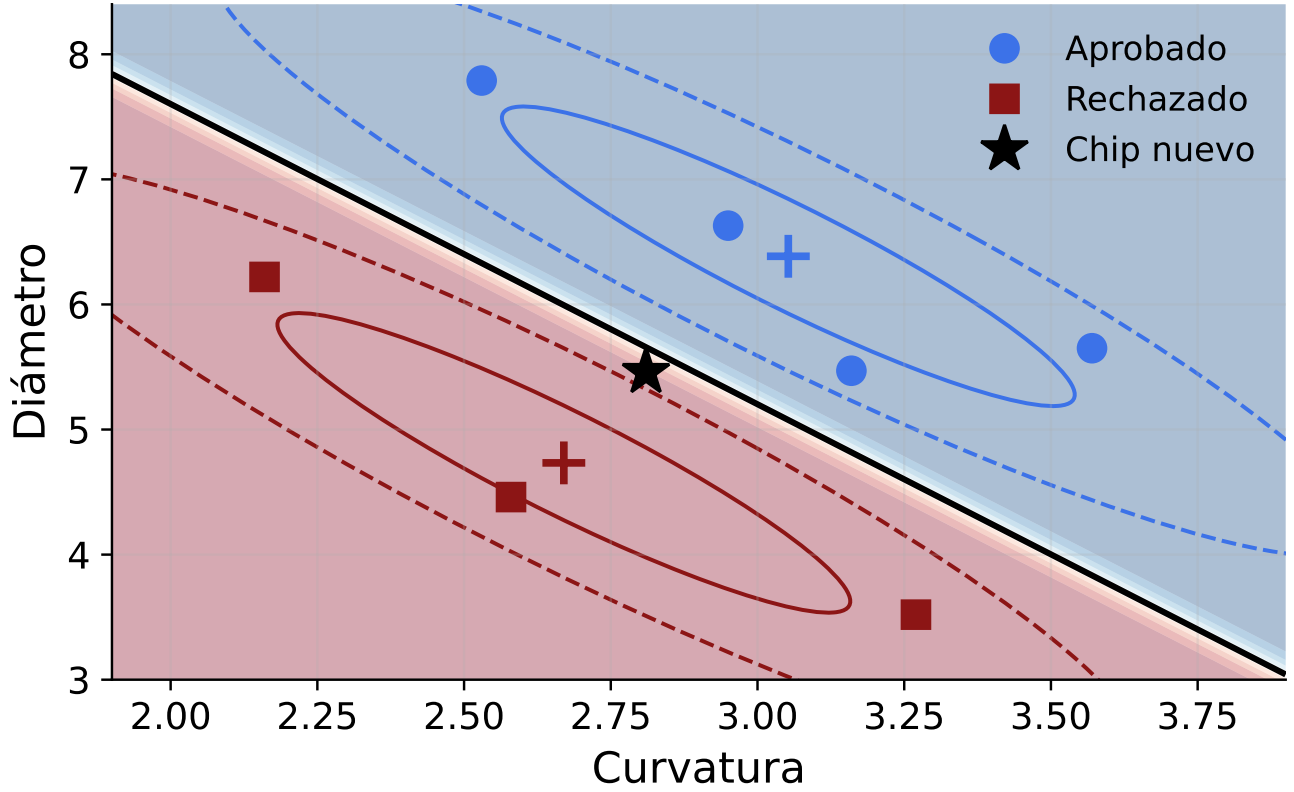
$$\hat{\boldsymbol{\Sigma}} = \frac{1}{n - K} \sum_{k=1}^{K} \sum_{i:\, y_i = k} (\mathrm{x}_i - \hat{\boldsymbol{\mu}}_k)(\mathrm{x}_i - \hat{\boldsymbol{\mu}}_k)^\top \quad \text{(LDA, covarianza conjunta)}.$$

Algoritmo. Estimar $\hat{\pi}_k$, $\hat{\boldsymbol{\mu}}_k$ y $\hat{\boldsymbol{\Sigma}}$ (o $\hat{\boldsymbol{\Sigma}}_k$). Para un x nuevo, calcular $\hat{\delta}_k(\mathrm{x})$ en cada clase. Asignar $\hat{y} = \operatorname{argmax}_k \hat{\delta}_k(\mathrm{x})$. La softmax de los $\hat{\delta}_k$ da las probabilidades a posteriori.

Ejemplo, control de calidad de chips

Curvatura	Diámetro	Control
$2{,}95$	$6{,}63$	Aprobado
$2{,}53$	$7{,}79$	Aprobado
$3{,}57$	$5{,}65$	Aprobado
$3{,}16$	$5{,}47$	Aprobado
$2{,}58$	$4{,}46$	Rechazado
$2{,}16$	$6{,}22$	Rechazado
$3{,}27$	$3{,}52$	Rechazado

Una fábrica quiere automatizar el control de calidad de un chip. Para ello usa su curvatura y su diámetro. Expertos evaluaron siete chips. Un chip nuevo tiene curvatura $2{,}81$ y diámetro $5{,}46$.



Ejemplo, el cálculo

Con $\hat{\pi}_1 = 4/7, \hat{\pi}_2 = 3/7$,

$$\hat{\boldsymbol{\mu}}_1 = \begin{pmatrix} 3{,}05 \\ 6{,}39 \end{pmatrix}, \qquad \hat{\boldsymbol{\mu}}_2 = \begin{pmatrix} 2{,}67 \\ 4{,}73 \end{pmatrix}, \qquad \hat{\boldsymbol{\Sigma}} = \begin{pmatrix} 0{,}238 & -0{,}540 \\ -0{,}540 & 1{,}434 \end{pmatrix}.$$

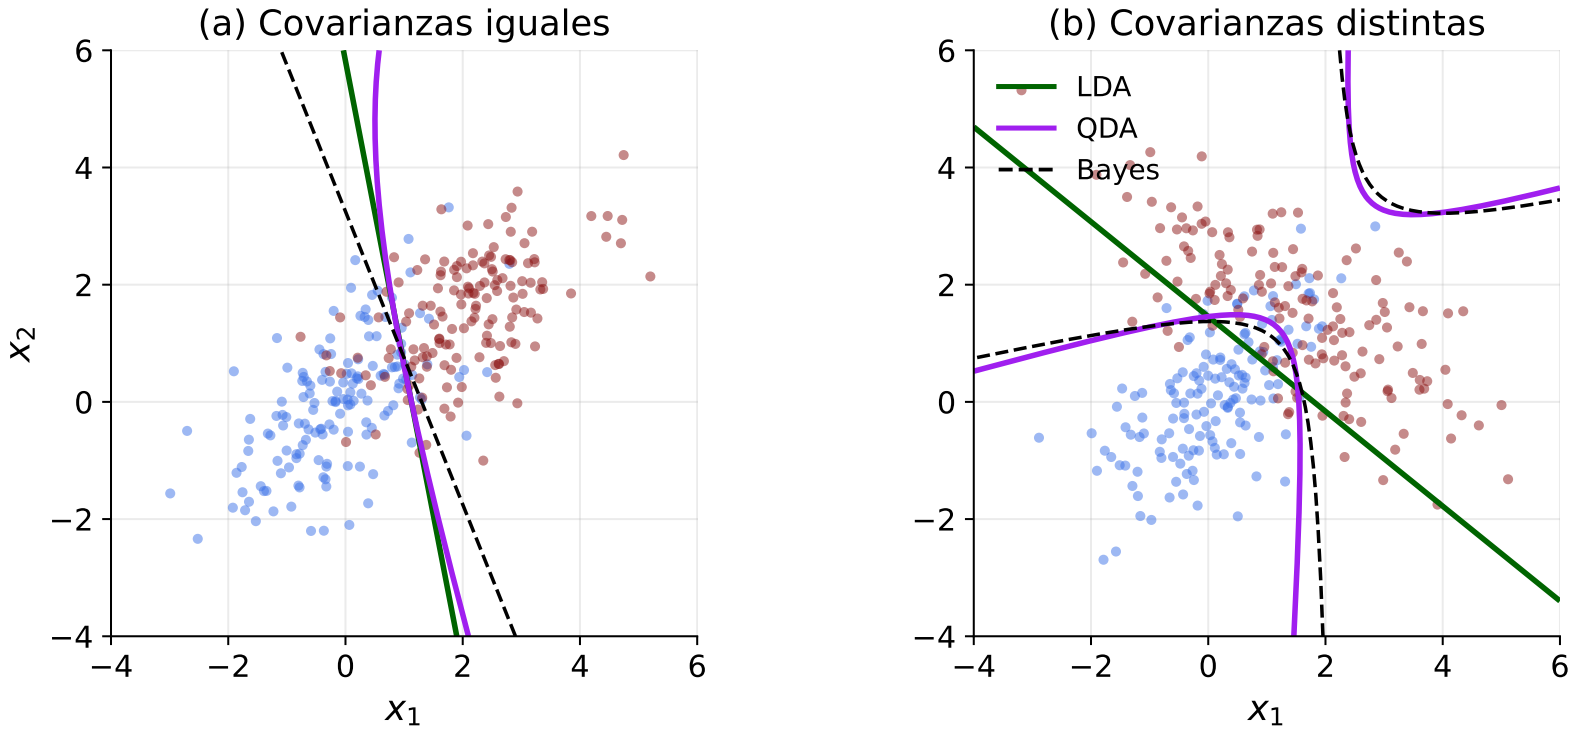
Para el chip nuevo $\mathrm{x} = (2{,}81;\ 5{,}46)$,

$$\hat{\delta}_1(\mathrm{x}) = -4{,}36, \qquad \hat{\delta}_2(\mathrm{x}) = -1{,}99,$$

y la probabilidad a posteriori de rechazo es $e^{-1{,}99}/(e^{-4{,}36} + e^{-1{,}99}) = 0{,}92$. El chip se **rechaza**.

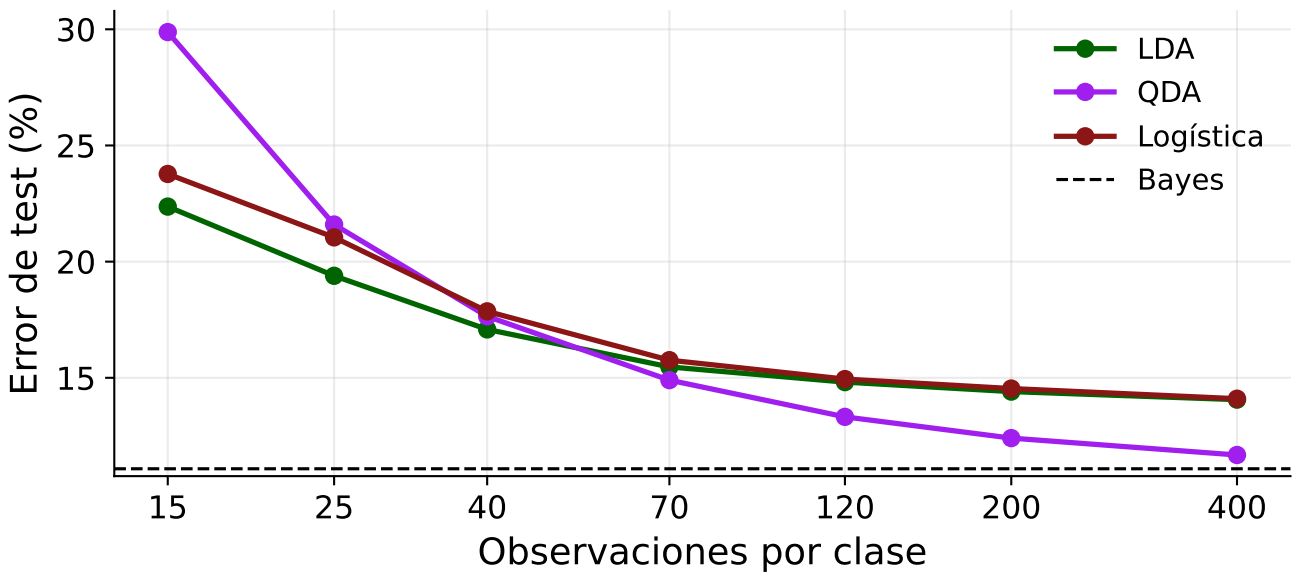
El chip nuevo tiene un diámetro alto para un rechazado. Pero su curvatura es baja para su diámetro. En los aprobados, la curvatura y el diámetro tienen correlación negativa. La distancia de Mahalanobis considera esa correlación. Con siete observaciones, ninguna conclusión de este tipo es estable.

Fronteras de LDA y QDA



Hay ciento cincuenta observaciones por clase. Con covarianzas iguales (a), las fronteras estimadas están cerca de la de Bayes. Con covarianzas distintas (b), la frontera de Bayes es una hipérbola. QDA la aproxima, y LDA sólo puede trazar una recta.

Sesgo y varianza en LDA y QDA



Las covarianzas verdaderas son distintas y $p = 10$. LDA estima $p(p+1)/2 = 55$ parámetros de covarianza. QDA estima K veces más, 110.

Con 40 o menos observaciones por clase, LDA tiene menor error, aunque su frontera esté mal especificada. Desde unas 70 por clase, QDA es mejor. Con 400, QDA queda a $0{,}6$ puntos del error de Bayes.

LDA tiene más sesgo y menos varianza que QDA. Aquí la covarianza determina la capacidad.

LDA y regresión logística

Dos estimadores de la misma frontera

Con dos clases, el logaritmo de las chances según LDA es

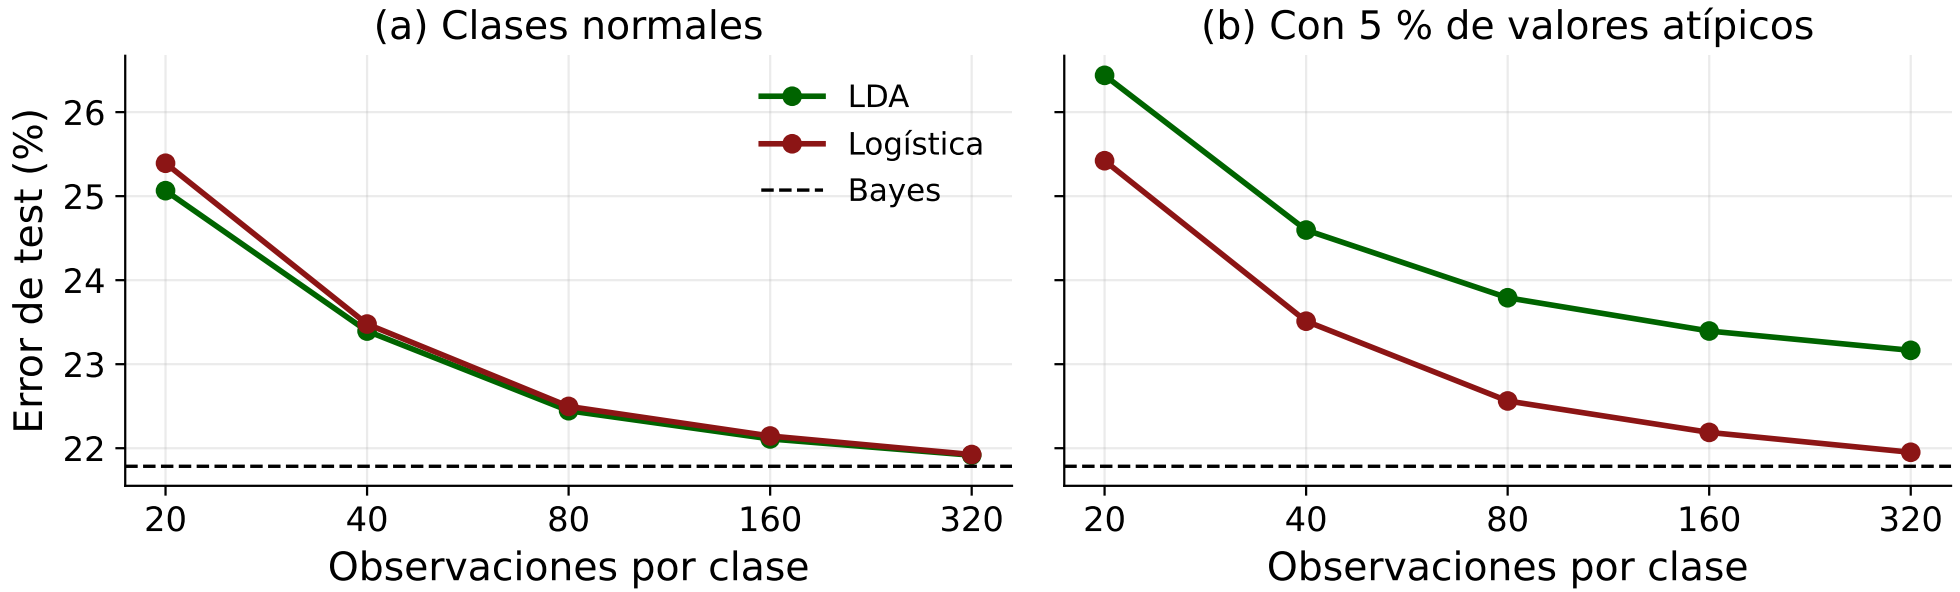
$$\log \frac{\Pr(y=1 \mid \mathrm{x})}{\Pr(y=2 \mid \mathrm{x})} = \log \frac{\pi_1}{\pi_2} - \underbrace{\tfrac{1}{2}(\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2)^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)}_{\beta_0} + \mathrm{x}^\top \boldsymbol{\Sigma}^{-1}(\underbrace{\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2}_{\boldsymbol{\beta}}),$$

Esta expresión tiene la forma del modelo logístico.

Ambos métodos ajustan $\beta_0 + \boldsymbol{\beta}^\top \mathrm{x}$, pero de distinta manera:

- La regresión logística maximiza la verosimilitud **condicional** $\prod_i \Pr(y_i \mid \mathrm{x}_i)$. No supone nada sobre las x.
- LDA maximiza la verosimilitud **conjunta** $\prod_i \Pr(y_i) f_{y_i}(\mathrm{x}_i)$ y supone normalidad con covarianza común. Calcula $\boldsymbol{\beta}$ con medias y covarianzas.

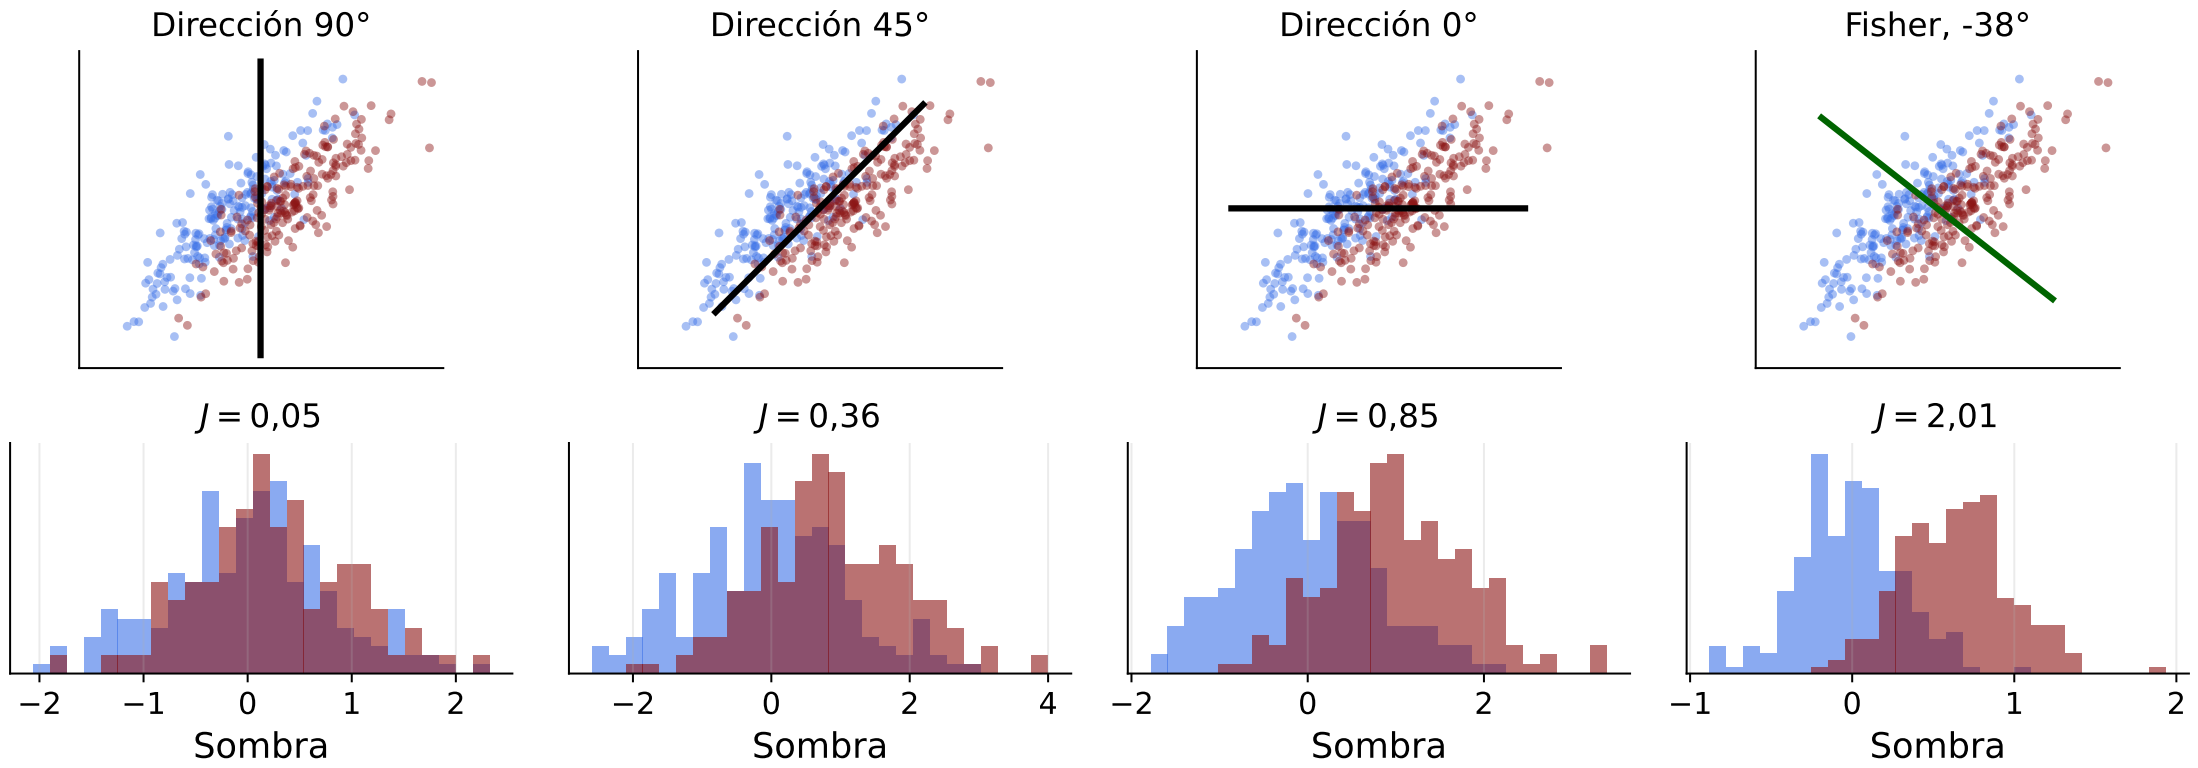
Eficiencia y robustez



La covarianza es común y $p = 5$. Con datos normales (a), LDA es algo mejor con pocos datos y ambos llegan al error de Bayes. Efron (1975) mostró que, bajo normalidad, la eficiencia relativa de la logística está entre un medio y dos tercios. La logística necesita entre un $50\,\%$ más y el doble de datos para la misma precisión. Con un $5\,\%$ de observaciones atípicas en una clase (b), LDA se aleja del error de Bayes ($23{,}2\,\%$ frente a $21{,}8\,\%$ con 320 por clase). La logística casi no cambia ($22{,}0\,\%$).

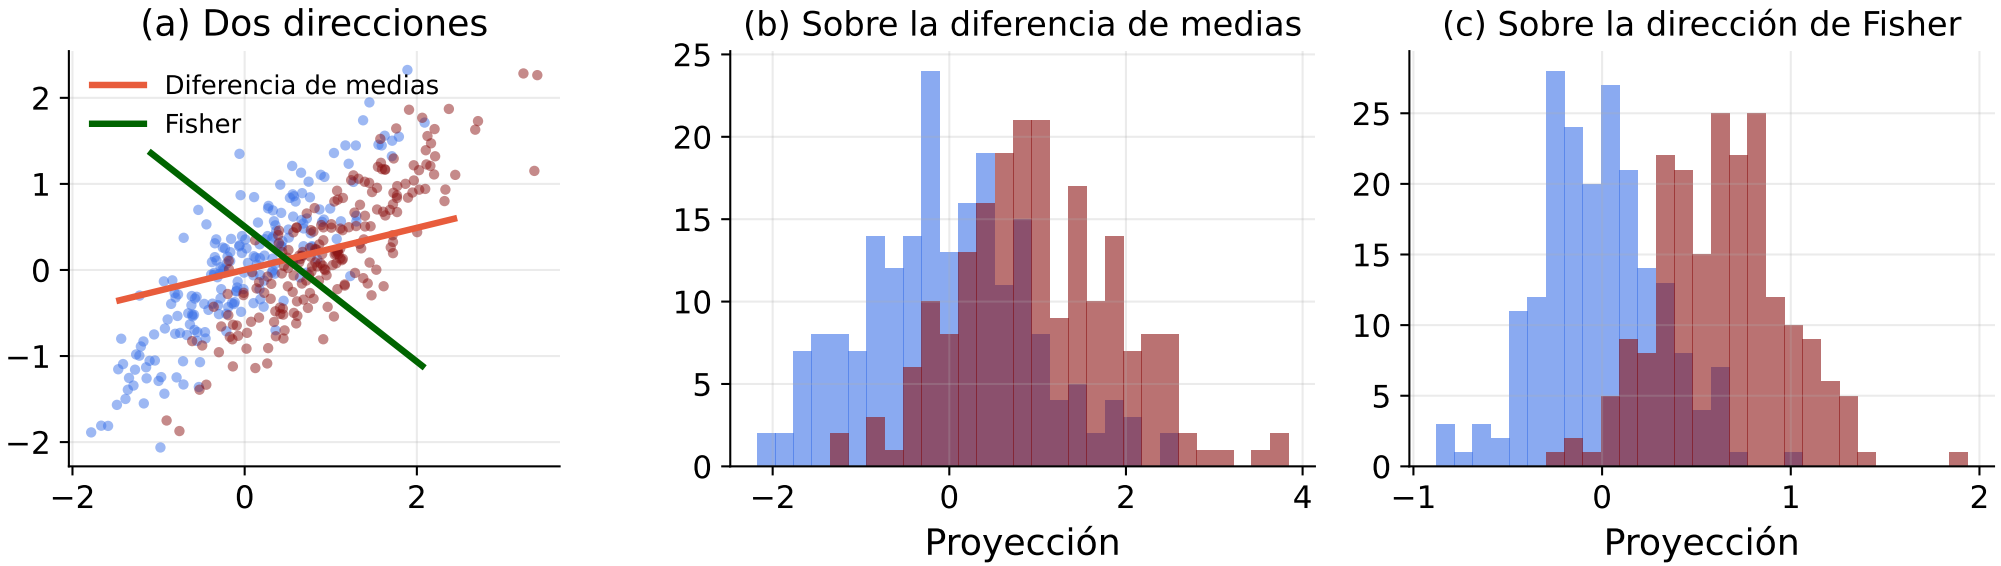
El discriminante de Fisher

Las sombras de los puntos



Al proyectar los puntos sobre una recta, cada uno deja una sombra. Las sombras de las dos clases se traslapan según la dirección. J es la separación de las medias de las sombras dividida por su dispersión. Vale $0{,}05$ en la dirección vertical, $0{,}85$ en la horizontal y $2{,}01$ en la dirección de Fisher.

La dirección de Fisher



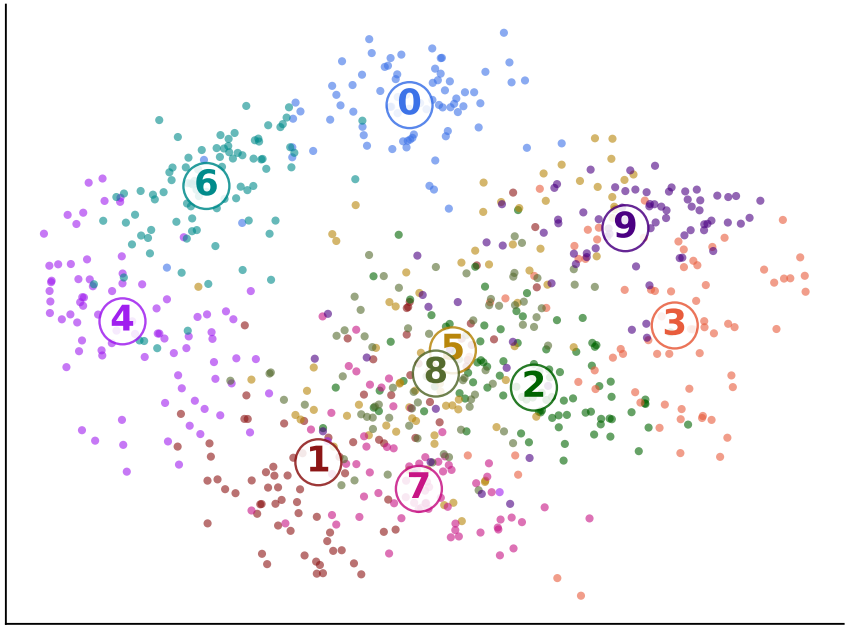
Fisher (1936) buscó la dirección w que maximiza la separación de las clases proyectadas dividida por su dispersión,

$$J(\mathrm{w}) = \frac{(\mathrm{w}^\top \hat{\boldsymbol{\mu}}_1 - \mathrm{w}^\top \hat{\boldsymbol{\mu}}_2)^2}{\mathrm{w}^\top \mathrm{S}_W \mathrm{w}}, \qquad \text{con solución } \mathrm{w} \propto \mathrm{S}_W^{-1}(\hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2),$$

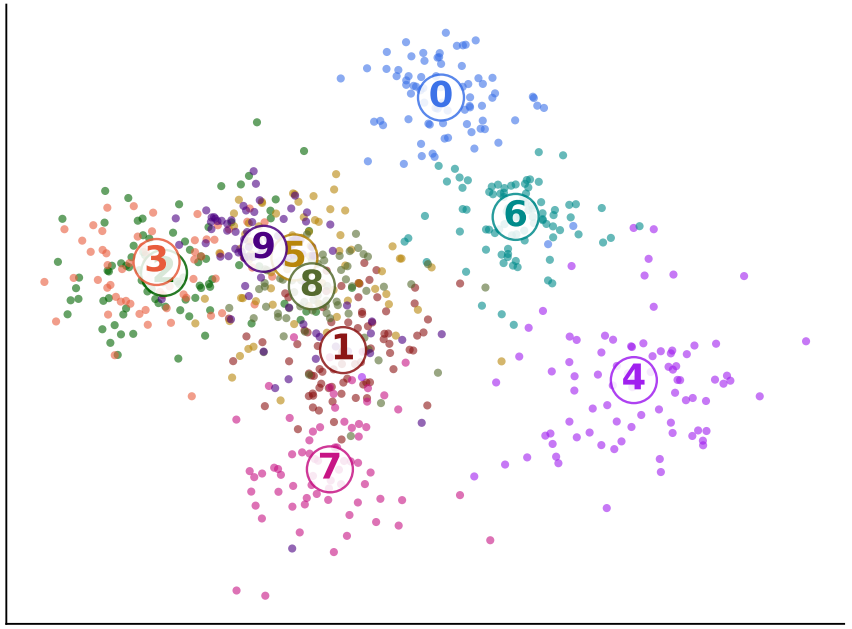
que es la dirección de LDA, sin suponer normalidad. La proyección sobre la diferencia de medias (b) da $J = 0{,}65$ y la de Fisher (c), $J = 2{,}01$.

LDA como reducción de dimensión

(a) Dos componentes principales



(b) Dos direcciones discriminantes



Con K clases, las direcciones discriminantes son los vectores propios de $\mathrm{S}_W^{-1}\mathrm{S}_B$. La matriz S_B es la dispersión entre las medias de clase. Hay a lo sumo $K - 1$ direcciones. Las componentes principales (a) maximizan la varianza total y no usan las etiquetas. Las direcciones discriminantes (b) maximizan la separación de las clases. En los dígitos, aíslan el cero, el cuatro y el seis.

Muchas variables y pocas observaciones

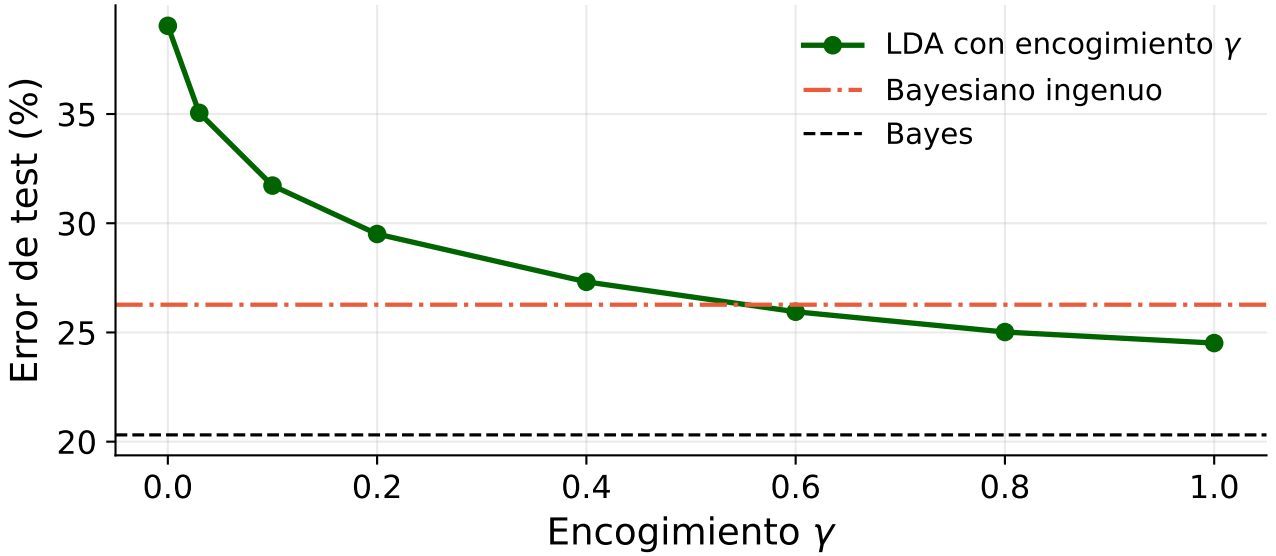
Discriminante regularizado

Con p grande, $\hat{\boldsymbol{\Sigma}}$ tiene $p(p+1)/2$ parámetros y se estima mal. Con $p \geq n - K$, la matriz es singular. Tres métodos encogen la covarianza.

- **Discriminante regularizado** (Friedman, 1989): $\hat{\boldsymbol{\Sigma}}_k(\alpha) = \alpha\hat{\boldsymbol{\Sigma}}_k + (1-\alpha)\hat{\boldsymbol{\Sigma}}$, entre QDA y LDA.
- **Encogimiento hacia la diagonal**: $\hat{\boldsymbol{\Sigma}}(\gamma) = (1-\gamma)\hat{\boldsymbol{\Sigma}} + \gamma \frac{\text{tr}\,\hat{\boldsymbol{\Sigma}}}{p}\mathbf{I}$, el análogo de ridge para covarianzas. Ledoit y Wolf (2004) dan un γ óptimo sin validación cruzada.
- **Bayesiano ingenuo gaussiano**: usa covarianzas diagonales. Supone variables independientes dentro de cada clase.

Los tres usan un modelo menos realista para estimar menos parámetros. Del mismo modo, ridge renuncia a la insesgadez de mínimos cuadrados.

Encogimiento hacia la diagonal



Hay dos clases en $p = 60$ y 40 observaciones por clase. Las variables vecinas están correlacionadas ($0{,}5^{|i-j|}$). La covarianza tiene $1\,830$ parámetros.

LDA sin encogimiento tiene 39 % de error, y el de Bayes es 20 %. Al encoger hacia la diagonal, el error baja de forma monótona hasta $24{,}5$ % con $\gamma = 1$. Ese valor ignora todas las correlaciones. El bayesiano ingenuo logra 26 %.

Con pocos datos, estimar las correlaciones empeora la clasificación (Bickel y Levina, 2004).

Vinos y dígitos

Método	Vinos, error de VC	Dígitos, error de test
LDA	$1{,}2\,\%$	$4{,}4\,\%$
QDA	$0{,}8\,\%$	No estimable
Discriminante regularizado, $\alpha = 0{,}5$, $\gamma = 0{,}1$	$0{,}7\,\%$	$0{,}8\,\%$
Bayesiano ingenuo	$2{,}8\,\%$	$11{,}9\,\%$
Regresión logística (softmax)	$2{,}0\,\%$	$3{,}4\,\%$

Vinos (Forina et al.). Son 178 vinos de tres cultivares italianos con 13 variables químicas. Se usa validación cruzada de diez pliegues repetida cinco veces. Todos los métodos aciertan en más del $97\,\%$ de los casos. QDA y el discriminante regularizado son los mejores.

Dígitos. Son $1\,000$ imágenes de 8×8 píxeles para entrenar y 797 para evaluar. Hay unos 100 por clase. Las covarianzas de clase son singulares, y QDA no se puede estimar. El discriminante regularizado tiene $0{,}8\,\%$ de error. La regresión softmax tiene $3{,}4\,\%$.

Implementación

```
import numpy as np
from sklearn.discriminant_analysis import (LinearDiscriminantAnalysis,
                                           QuadraticDiscriminantAnalysis)

def lda(X, y):                                  # estimación
    clases = np.unique(y); n, K = len(y), len(clases)
    pis = np.array([np.mean(y == k) for k in clases])
    mus = np.array([X[y == k].mean(0) for k in clases])
    S = sum((X[y == k] - m).T @ (X[y == k] - m) for k, m in zip(clases, mus))/(n - K)
    return clases, pis, mus, np.linalg.inv(S)
def delta(x, pis, mus, Si):                     # funciones discriminantes lineales
    return x @ Si @ mus.T - 0.5*np.sum(mus @ Si * mus, 1) + np.log(pis)
lda_sk = LinearDiscriminantAnalysis(solver="lsqr", shrinkage="auto")   # Ledoit-Wolf
qda_sk = QuadraticDiscriminantAnalysis(reg_param=0.1)
Z = LinearDiscriminantAnalysis(n_components=2).fit_transform(X, y)    # proyección de Fisher
```

Errores frecuentes

- Creer que LDA exige clases linealmente separables. LDA supone normalidad con covarianza común y funciona con clases que se traslapan.
- Usar QDA con pocas observaciones por clase. Con $n_k \leq p$, las covarianzas son singulares.
- Aplicar LDA a variables categóricas codificadas como números. Para ellas, el supuesto normal no tiene sentido.
- Usar las probabilidades a priori de la muestra cuando difieren de las de la población donde se usará el clasificador. En ese caso, hay que reemplazar $\hat{\pi}_k$.
- Reducir la dimensión con componentes principales sin compararlas con las direcciones discriminantes, que sí usan las etiquetas.
- Estimar en cero la probabilidad de una palabra ausente en una clase, sin suavizado de Laplace.
- Interpretar los coeficientes de LDA como efectos causales o como razones de chances sin verificar la normalidad.

Referencias

- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*, 2.ª ed., secciones 4.3 y 4.4.5. Springer.
- James, G., Witten, D., Hastie, T., Tibshirani, R. (2021). *An Introduction to Statistical Learning*, 2.ª ed., sección 4.4. Springer.
- Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188.
- Efron, B. (1975). The efficiency of logistic regression compared to normal discriminant analysis. *JASA*, 70(352), 892–898.
- Friedman, J. H. (1989). Regularized discriminant analysis. *JASA*, 84(405), 165–175.
- Bickel, P. J., Levina, E. (2004). Some theory for Fisher's linear discriminant function, naive Bayes, and some alternatives when there are many more variables than observations. *Bernoulli*, 10(6), 989–1010.
- Ledoit, O., Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- Serrano, L. G. (2021). *Grokking Machine Learning*, capítulo 8. Manning.
- Teknomo, K. (2015). *Discriminant Analysis Tutorial* (origen del ejemplo de los chips).