

Aprendizaje no supervisado

Unidad 6. Agrupamiento, mezclas, densidad,
validación y factorización de matrices

Alejandro Veloz

INF396 - Introducción a la Ciencia de Datos



Objetivos

- Formular el agrupamiento como un problema de optimización o de estimación sin etiquetas.
- Aplicar k-means y fuzzy c-means, y reconocer sus supuestos y sus límites.
- Derivar el algoritmo EM para una mezcla de gaussianas y elegir el número de componentes.
- Agregar regularización espacial con campos aleatorios de Markov para segmentar imágenes.
- Construir un dendrograma y aplicar el agrupamiento espectral a grupos no convexos.
- Encontrar grupos de forma arbitraria y ruido con DBSCAN, OPTICS y HDBSCAN.
- Evaluar un agrupamiento con medidas internas y externas, y elegir el número de grupos.
- Factorizar una matriz no negativa para encontrar partes y tópicos.

Contenido

1. El problema del agrupamiento
2. Métodos basados en representantes
3. Mezclas gaussianas y el algoritmo EM
4. Agrupamiento jerárquico y espectral
5. Métodos basados en densidad
6. Validación del agrupamiento
7. Factorización en matrices no negativas

Contenido

1. El problema del agrupamiento

2. Métodos basados en representantes

3. Mezclas gaussianas y el algoritmo EM

4. Agrupamiento jerárquico y espectral

5. Métodos basados en densidad

6. Validación del agrupamiento

7. Factorización en matrices no negativas

Aprender sin etiquetas

En el aprendizaje supervisado cada observación x_i tiene una respuesta y_i . En el aprendizaje no supervisado sólo hay entradas, $\{x_1, \dots, x_n\}$.

Los datos sin etiquetas son la mayoría.

- Etiquetar es caro, por ejemplo cuando requiere a un especialista.
- El etiquetado humano es subjetivo y varía entre personas.
- A veces no se sabe qué etiquetas buscar.

El objetivo es describir la estructura de los datos. Las tareas principales son las siguientes.

- **Agrupamiento.** Encontrar grupos de observaciones parecidas.
- **Estimación de densidad.** Describir cómo se distribuyen los datos.
- **Reducción de la dimensión y factorización.** Representar los datos con pocas variables o partes.


Ejemplos de agrupamiento

- **Imágenes médicas.** Separar los tejidos de una resonancia magnética según las intensidades de varias secuencias.
- **Clientes.** Formar segmentos de clientes con hábitos de compra parecidos.
- **Genómica.** Agrupar genes con niveles de expresión parecidos en distintas condiciones.
- **Texto.** Encontrar los temas de una colección de documentos.
- **Enfermedades.** Formar grupos de enfermedades que comparten genes o síntomas.


En todos los casos no existe una respuesta correcta conocida. La calidad del agrupamiento se juzga por su coherencia interna y por su utilidad en el problema.

¿Cuántos grupos hay?


(a) Grupos compactos




(b) Lunas



(c) Anillos



(d) Densidades distintas y ruido



Cuatro conjuntos de datos sin etiquetas. En (a) los grupos son compactos y separados. En (b) y (c) los grupos tienen formas curvas y uno rodea al otro. En (d) hay grupos con densidades distintas y puntos sueltos que no pertenecen a ninguno.

Cada método supone una forma de grupo. Un método que funciona bien en (a) puede fallar en (b), (c) o (d).

El problema del agrupamiento

Dados n puntos $\mathcal{D} = \{\mathbf{x}_i\}_{i=1}^n$ en $\mathbb{R}^p$ y un número K , se busca una partición $\mathcal{C} = \{C_1, \dots, C_K\}$ tal que

- los puntos de un mismo grupo sean parecidos, y
- los puntos de grupos distintos sean diferentes.

Para precisar “parecido” hace falta una medida de distancia o de similitud, por ejemplo la distancia euclídea

$$d(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2.$$

Las variables se estandarizan antes de calcular distancias. Si no, la variable con mayor escala domina la distancia y define los grupos.


Familias de métodos

Familia	Idea	Ejemplos
Representantes	Cada grupo tiene un centro	k-means, fuzzy c-means
Probabilísticos	Cada grupo es una distribución	Mezcla de gaussianas
Jerárquicos	Grupos anidados a distintas escalas	Enlace simple, completo, Ward
Grafos	Grupos poco conectados entre sí	Agrupamiento espectral
Densidad	Grupos como zonas densas	DBSCAN, OPTICS, HDBSCAN
Factorización	Datos como combinación de partes	NMF


Los métodos particionales asignan cada punto a un grupo. Los difusos y los probabilísticos asignan a cada punto un grado de pertenencia a cada grupo. Los de densidad pueden declarar que un punto es ruido.

El caso de la resonancia magnética


T1 con contraste




T1 FLAIR



T2 FLAIR





Región de análisis



Tres secuencias de resonancia magnética de un paciente con glioblastoma, co-registradas: T1 con contraste, T1 FLAIR y T2 FLAIR. Cada píxel tiene tres intensidades. El objetivo es separar el tumor del tejido sano sin una segmentación de referencia.

Cada píxel es un punto



Con una sola secuencia (izquierda) cada píxel es un número y el histograma muestra picos que se superponen. Con dos secuencias (derecha) cada píxel es un punto del plano. Los tejidos forman nubes que se separan mejor que en una dimensión. Agrupar los píxeles en ese espacio segmenta la imagen.

Contenido

1. El problema del agrupamiento

2. Métodos basados en representantes

3. Mezclas gaussianas y el algoritmo EM

4. Agrupamiento jerárquico y espectral

5. Métodos basados en densidad

6. Validación del agrupamiento

7. Factorización en matrices no negativas

Agrupar con representantes

Cada grupo C_k se resume en un punto representativo, su centroide,

$$\boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{\mathbf{x}_i \in C_k} \mathbf{x}_i.$$

La calidad de una partición se mide con la suma de cuadrados dentro de los grupos,

$$J(\mathcal{C}) = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2,$$

y se busca la partición que la minimiza.

Probar todas las particiones es imposible. El número de formas de repartir n puntos en K grupos crece como $K^n / K!$. Con $n = 100$ y $K = 3$ hay más de 10^{46} particiones. Hace falta un algoritmo que busque una buena solución sin recorrerlas todas.

El algoritmo k-means

El algoritmo de Lloyd alterna dos pasos hasta que la partición no cambia.


1. **Inicializar** K centroides, por ejemplo K puntos de los datos al azar.
2. **Asignar** cada punto al centroide más cercano,

$$c(i) = \operatorname{argmin}_k \|x_i - \mu_k\|^2.$$

3. **Actualizar** cada centroide como la media de los puntos asignados.
4. Repetir 2 y 3 hasta que las asignaciones no cambien.


Cada paso reduce J o la deja igual. La asignación minimiza J con los centroides fijos, y la media minimiza J con la partición fija. Como hay un número finito de particiones, el algoritmo termina. Pero puede terminar en un mínimo local.

k-means paso a paso



Seiscientos puntos en cuatro grupos. Los centroides iniciales (cruces negras) están mal ubicados, dos en cada uno de dos grupos. Las líneas muestran el camino de cada centroide. Después de 13 iteraciones los centroides llegan al centro de cada grupo y la partición deja de cambiar.

Dependencia de la inicialización



Nueve grupos en una rejilla. La mejor partición tiene $J = 1\,382$. Una mala inicialización deja dos centroides en un grupo y ninguno en otro, con $J = 2\,599$. Con centroides iniciales al azar, sólo el 40 % de 100 corridas llega al mejor valor. Con k-means++ llega el 88 %.

Inicialización k-means++


k-means++ (Arthur y Vassilvitskii, 2007) elige los centroides iniciales de forma escalonada.

1. Elegir el primer centroide al azar entre los datos.
2. Para cada punto, calcular $D(\mathbf{x}_i)$, la distancia al centroide ya elegido más cercano.
3. Elegir el siguiente centroide con probabilidad proporcional a $D(\mathbf{x}_i)^2$.
4. Repetir hasta tener K centroides.

Los puntos lejanos de los centroides ya elegidos tienen más probabilidad de ser elegidos. Así los centroides iniciales quedan repartidos entre los grupos.


En la práctica se corre k-means varias veces, con distintas semillas, y se conserva la partición con menor J .

Límites de k-means




k-means asigna cada punto al centroide más cercano. Las fronteras entre grupos son rectas, y los grupos que encuentra son convexos y de tamaño parecido. En (a) corta grupos alargados de forma transversal. En (b) y (c) no puede separar grupos curvos ni anidados. El índice de Rand ajustado con las etiquetas verdaderas es 0,58, 0,26 y 0,00.

k-means en la resonancia magnética



Los píxeles del cerebro en el espacio de T1 con contraste y T2 FLAIR, con $K = 4$. Los centroides se mueven hacia las zonas densas de cada tejido. El grupo de intensidades altas en ambas secuencias corresponde al tumor.

Segmentación con k-means



Cada píxel recibe la etiqueta de su grupo. El grupo con el centroide de mayor intensidad marca el tumor. El resultado incluye algunos píxeles sueltos fuera del tumor, porque k -means no usa la posición de los píxeles, sólo sus intensidades.

Pertenencia difusa

En k-means cada punto pertenece a un solo grupo. En los bordes entre tejidos esa decisión es arbitraria. **Fuzzy c-means** (Bezdek, 1981) asigna a cada punto un grado de pertenencia $u_{ik} \in [0, 1]$ a cada grupo, con $\sum_k u_{ik} = 1$.

La función objetivo es


$$J_m = \sum_{i=1}^n \sum_{k=1}^K u_{ik}^m \|x_i - v_k\|^2, \quad m > 1.$$

Minimizando con multiplicadores de Lagrange se obtienen dos actualizaciones,

$$v_k = \frac{\sum_i u_{ik}^m x_i}{\sum_i u_{ik}^m}, \quad u_{ik} = \left[\sum_{j=1}^K \left(\frac{\|x_i - v_k\|}{\|x_i - v_j\|} \right)^{2/(m-1)} \right]^{-1}.$$


El algoritmo alterna las dos actualizaciones hasta que las pertenencias dejan de cambiar.

El exponente m




El color indica la mayor pertenencia de cada punto. Con m cercano a 1 las pertenencias son casi 0 o 1, como en k-means. Con $m = 2$, el valor habitual, los puntos entre grupos tienen pertenencias intermedias. Con m grande todas las pertenencias se acercan a $1/K$.

Mapas de pertenencia en la resonancia



Una imagen por grupo, con la pertenencia u_{ik} de cada píxel. El grupo del tumor (derecha) tiene pertenencia alta en el centro de la lesión y valores intermedios en el borde. Un umbral sobre este mapa da la segmentación, y el valor del umbral controla cuánto del borde se incluye.

k-means frente a fuzzy c-means



Las particiones son parecidas. La diferencia está en los puntos entre grupos. Fuzzy c-means los marca con pertenencias bajas (derecha, en rojo), y esos puntos son los de asignación dudosa.

Kernel k-means

k-means separa con fronteras rectas. Para grupos no convexos se transforma cada punto con una función $\varphi(\mathbf{x})$ a un espacio donde los grupos sí se separen con rectas, y se aplica k-means allí.

La distancia al centroide en el espacio transformado sólo necesita productos internos,

$$\|\varphi(\mathbf{x}_i) - \boldsymbol{\mu}_k\|^2 = K(\mathbf{x}_i, \mathbf{x}_i) - \frac{2}{|C_k|} \sum_{j \in C_k} K(\mathbf{x}_i, \mathbf{x}_j) + \frac{1}{|C_k|^2} \sum_{j, l \in C_k} K(\mathbf{x}_j, \mathbf{x}_l),$$

con $K(\mathbf{x}, \mathbf{y}) = \varphi(\mathbf{x})^\top \varphi(\mathbf{y})$, por ejemplo el núcleo gaussiano $\exp(-\|\mathbf{x} - \mathbf{y}\|^2 / 2s^2)$.

No hace falta calcular φ , sólo la matriz $n \times n$ de valores del núcleo. Kernel k-means está muy relacionado con el agrupamiento espectral.

Contenido

1. El problema del agrupamiento
2. Métodos basados en representantes
- 3. Mezclas gaussianas y el algoritmo EM**
4. Agrupamiento jerárquico y espectral
5. Métodos basados en densidad
6. Validación del agrupamiento
7. Factorización en matrices no negativas

Mezcla finita de gaussianas

Un modelo probabilístico de grupos supone que cada punto viene de uno de K componentes normales, sin que se sepa de cuál,

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k N(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k), \quad \pi_k \geq 0, \quad \sum_k \pi_k = 1.$$

- π_k es la proporción de puntos del componente k .
- $\boldsymbol{\mu}_k$ y $\boldsymbol{\Sigma}_k$ son su media y su covarianza.
- La covarianza permite grupos elípticos de cualquier orientación.

Una variable latente $z_i \in \{1, \dots, K\}$ indica el componente de cada punto. Si se conociera, estimar los parámetros sería fácil. Agrupar es estimar z_i .

Log verosimilitud de la mezcla

Con n puntos independientes, la log verosimilitud es

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^n \log \left(\sum_{k=1}^K \pi_k N(\mathbf{x}_i \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right).$$

El logaritmo de una suma no se separa. Las derivadas de ℓ igualadas a cero no tienen solución cerrada, porque los parámetros de todos los componentes aparecen mezclados en cada término.

El algoritmo **EM** (esperanza y maximización; Dempster, Laird y Rubin, 1977) resuelve este problema alternando dos pasos fáciles.

Paso E: responsabilidades

Con los parámetros actuales, se calcula la probabilidad de que el punto i venga del componente k , por el teorema de Bayes,

$$\gamma_{ik} = \Pr(z_i = k \mid \mathbf{x}_i) = \frac{\pi_k N(\mathbf{x}_i \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j N(\mathbf{x}_i \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}.$$

γ_{ik} se llama **responsabilidad** del componente k sobre el punto i . Cada fila de la matriz $n \times K$ de responsabilidades suma uno.

Las responsabilidades son una pertenencia gradual, como en fuzzy c-means, pero con una interpretación de probabilidad.

Paso M: actualizar los parámetros

Con las responsabilidades fijas, cada componente se estima como un promedio ponderado.


Con $N_k = \sum_i \gamma_{ik}$,

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{i=1}^n \gamma_{ik} \mathbf{x}_i, \quad \boldsymbol{\Sigma}_k = \frac{1}{N_k} \sum_{i=1}^n \gamma_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^\top, \quad \pi_k = \frac{N_k}{n}.$$

Son las fórmulas de máxima verosimilitud de una normal, con cada punto contado con peso γ_{ik} .


Propiedad. Cada iteración de EM no disminuye la log verosimilitud. El algoritmo converge a un máximo local, que depende de la inicialización. Se detiene cuando el aumento de ℓ es menor que una tolerancia.

EM en una dimensión



Veinticinco datos en una dimensión, dos componentes. Se inicia con medias 3,6 y 1,8, la varianza total en ambos componentes y pesos iguales. Después de 41 iteraciones las medias son 0,96 y 4,40, las desviaciones estándar 0,54 y 1,19 y los pesos 0,42 y 0,58.

La log verosimilitud sube en cada iteración




La log verosimilitud del ejemplo sube de $-52,6$ a $-46,9$ y luego se estabiliza.

Al principio sube lentamente, porque los dos componentes parten casi iguales. Cuando se separan, el aumento se acelera.

EM suele converger rápido al comienzo y lento cerca del máximo.

Mezcla gaussiana frente a k-means



En grupos alargados, k-means (a) corta los grupos, con índice de Rand ajustado 0,58. La mezcla gaussiana (b) ajusta una elipse a cada grupo y recupera la partición verdadera, con índice 1,00. El criterio BIC (c) se minimiza en $K = 3$, el número verdadero de grupos.

k-means como caso límite de EM


Si todos los componentes tienen covarianza $\sigma^2 \mathbf{I}$ y pesos iguales, la responsabilidad es

$$\gamma_{ik} = \frac{\exp(-\|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 / 2\sigma^2)}{\sum_j \exp(-\|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2 / 2\sigma^2)}.$$

Cuando $\sigma^2 \rightarrow 0$, la responsabilidad vale 1 para el centroide más cercano y 0 para los demás. El paso E se convierte en la asignación de k-means y el paso M en el cálculo de las medias.


k-means es una mezcla gaussiana con covarianzas esféricas iguales y asignaciones estrictas. La mezcla agrega la forma de cada grupo, su proporción y una pertenencia con interpretación de probabilidad.

Mezcla sobre el histograma de la resonancia




Histograma de T1 con contraste dentro del cerebro y la mezcla de gaussianas ajustada por EM. Cada componente modela un tejido. Los componentes se superponen, y por eso un umbral fijo sobre una sola secuencia confunde tejidos.

EM en dos secuencias



Las elipses muestran la covarianza de cada componente en varias iteraciones. Los componentes cambian de forma y orientación hasta ajustarse a las nubes de cada tejido.

Probabilidades posteriores



Una imagen por componente, con la responsabilidad γ_{ik} de cada píxel. A diferencia de k-means, la mezcla da una probabilidad para cada tejido. Esa probabilidad permite medir la incertidumbre de la segmentación en los bordes.

Agregar información espacial

Los métodos anteriores clasifican cada píxel sólo por sus intensidades. Pero los píxeles vecinos suelen pertenecer al mismo tejido.

Un **campo aleatorio de Markov** modela esa dependencia. La etiqueta x_s de cada píxel s depende sólo de las etiquetas de sus vecinos N_s ,

$$\Pr(x_s \mid x_r, r \neq s) = \Pr(x_s \mid x_r, r \in N_s).$$

Con el modelo de Potts, la distribución a priori de las etiquetas penaliza los vecinos distintos,

$$\Pr(\mathbf{x}) \propto \exp \left(-\beta \sum_s \sum_{r \in N_s} 1\{x_s \neq x_r\} \right), \quad \beta \geq 0.$$

La segmentación final maximiza la probabilidad a posteriori, que combina la verosimilitud de la mezcla con esta distribución a priori.

Sistemas de vecindad

Órdenes 1 a 5

		5	4	5		
	5	3	2	3	5	
5	3	1	1	1	3	5
4	2	1	s	1	2	4
5	3	1	1	1	3	5
	5	3	2	3	5	
		5	4	5		

Primer orden (4 vecinos)


		1		
	1		s	1
		1		

Segundo orden (8 vecinos)

2	1	2
1		1
2	1	2

En la vecindad de primer orden cada píxel tiene 4 vecinos, arriba, abajo, izquierda y derecha. En la de segundo orden tiene 8, con las diagonales. El orden de la vecindad define qué píxeles influyen en la etiqueta de cada uno.

Efecto de la regularización espacial



Segmentación con la mezcla gaussiana y el modelo de Potts, resuelta con el algoritmo de modo condicional iterado (ICM). Con $\beta = 0$ cada píxel se clasifica solo, como en la mezcla. Al aumentar β desaparecen los píxeles aislados y las regiones se vuelven más compactas. Con β muy grande se pierden detalles finos.

Contenido

1. El problema del agrupamiento
2. Métodos basados en representantes
3. Mezclas gaussianas y el algoritmo EM
- 4. Agrupamiento jerárquico y espectral**
5. Métodos basados en densidad
6. Validación del agrupamiento
7. Factorización en matrices no negativas

Agrupamiento jerárquico aglomerativo


El agrupamiento jerárquico no fija el número de grupos. Construye una jerarquía de grupos anidados.

1. Empezar con cada punto como un grupo.
2. Unir los dos grupos más cercanos.
3. Repetir hasta tener un solo grupo.

La distancia entre dos grupos A y B se define con un **criterio de enlace**.


Enlace	Distancia entre grupos	Grupos que produce
Simple	$\min_{a \in A, b \in B} d(a, b)$	Alargados, en cadena
Completo	$\max_{a \in A, b \in B} d(a, b)$	Compactos, de diámetro parecido
Promedio	Promedio de $d(a, b)$	Intermedios
Ward	Aumento de la suma de cuadrados al unir	Compactos, como k-means

El dendrograma



El dendrograma muestra el orden de las uniones. La altura de cada unión es la distancia entre los grupos que se unen. Cortar el dendrograma a una altura (línea discontinua) da una partición. Aquí el corte da tres grupos, uno por cada nube de puntos.

Efecto del criterio de enlace



Las mismas lunas con cuatro criterios y dos grupos. El enlace simple sigue la forma curva de cada luna y recupera la partición verdadera. Los enlaces completo, promedio y de Ward prefieren grupos compactos y cortan las lunas.

El enlace simple tiene un costo. Un solo punto entre dos grupos basta para unirlos, por lo que es muy sensible al ruido.

Agrupamiento con grafos

Otra forma de definir grupos es con un grafo. Cada punto es un nodo y se unen los puntos cercanos, por ejemplo cada punto con sus 10 vecinos más cercanos.

- A es la matriz de adyacencia, con $A_{ij} = 1$ si i y j están unidos.
- D es la matriz diagonal de grados, $D_{ii} = \sum_j A_{ij}$.
- $L = D - A$ es el **laplaciano** del grafo.

Un buen agrupamiento corta pocas aristas entre grupos. Para cualquier vector f ,

$$f^\top L f = \frac{1}{2} \sum_{i,j} A_{ij} (f_i - f_j)^2.$$

Si f es casi constante dentro de cada grupo, $f^\top L f$ es pequeño.

Un ejemplo pequeño

Seis nodos en dos triángulos, $\{1, 2, 3\}$ y $\{4, 5, 6\}$,
unidos por la arista 3-4.

$$L = \begin{pmatrix} 2 & -1 & -1 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 \\ -1 & -1 & 3 & -1 & 0 & 0 \\ 0 & 0 & -1 & 3 & -1 & -1 \\ 0 & 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & -1 & -1 & 2 \end{pmatrix}$$

Valores propios de L:

0,00, 0,44, 3,00, 3,00, 3,00, 4,56

El primero es cero, con vector propio constante. El
segundo vector propio, el **vector de Fiedler**, es

$(0,46 \ 0,46 \ 0,26 \ -0,26 \ -0,46 \ -0,46)$

Su signo separa los dos triángulos.


El algoritmo espectral

1. Construir el grafo de vecinos y su laplaciano, en general normalizado,
 $L_{\text{sym}} = I - D^{-1/2} A D^{-1/2}$.
2. Calcular los K vectores propios de los K valores propios más pequeños.
3. Formar la matriz $n \times K$ con esos vectores y normalizar cada fila.
4. Aplicar k-means a las filas.

Cada punto se representa con K coordenadas espectrales. En esas coordenadas los grupos del grafo quedan separados y compactos, y k-means los encuentra.

El costo principal es calcular los vectores propios de una matriz $n \times n$, que es caro para n grande.

Agrupamiento espectral sobre los anillos



k-means (a) corta los anillos por la mitad. El grafo de 10 vecinos (b) une sólo puntos del mismo anillo. El agrupamiento espectral (c) recupera los dos anillos, con índice de Rand ajustado 1,00. Los dos primeros valores propios del laplaciano son casi cero (d), porque el grafo tiene dos partes casi desconectadas.

Contenido

1. El problema del agrupamiento
2. Métodos basados en representantes
3. Mezclas gaussianas y el algoritmo EM
4. Agrupamiento jerárquico y espectral
- 5. Métodos basados en densidad**
6. Validación del agrupamiento
7. Factorización en matrices no negativas

Grupos como zonas densas

Los métodos basados en densidad definen un grupo como una zona de alta densidad de puntos, separada de otras por zonas de baja densidad.

- No suponen una forma para los grupos.
- No piden el número de grupos.
- Declaran como **ruido** los puntos de zonas poco densas.

Dos preguntas definen cada método.

- ¿Cómo se estima la densidad alrededor de un punto?
- ¿Cuándo dos puntos densos pertenecen al mismo grupo?

DBSCAN


DBSCAN (Ester et al., 1996) usa dos parámetros, un radio ε y un número mínimo de puntos MinPts. La vecindad de un punto es $N_\varepsilon(x) = \{y : d(x, y) \leq \varepsilon\}$.

- Un punto es **núcleo** si su vecindad tiene al menos MinPts puntos.
- Un punto es **frontera** si no es núcleo pero está en la vecindad de un núcleo.
- Un punto es **ruído** si no es núcleo ni frontera.

Dos núcleos pertenecen al mismo grupo si están unidos por una cadena de núcleos, cada uno en la vecindad del anterior. Un grupo es un conjunto de núcleos conectados de esta forma, más sus puntos frontera.

Tipos de puntos

$\varepsilon = 0,5$, MinPts = 5




Los círculos tienen radio ε .

Los núcleos (azul) tienen al menos cinco puntos en su círculo.

El punto frontera (cuadrado naranja) tiene menos de cinco vecinos, pero está dentro del círculo de un núcleo.


Los puntos de ruido (cruces) no tienen un núcleo cerca.

Elegir ε y el resultado sobre las lunas



El gráfico de distancia al k -ésimo vecino (a), con k igual a MinPts, aquí 5, y los puntos ordenados, tiene un codo. Los puntos a la derecha del codo están en zonas poco densas. Se elige ε en el codo, aquí 0,12. Sobre las lunas con 40 puntos de ruido, k-means (b) corta las lunas. DBSCAN (c) encuentra las dos lunas y marca 29 puntos como ruido.

Densidades distintas



Dos grupos densos y cercanos, un grupo disperso y ruido. Ningún ϵ sirve. Con $\epsilon = 0,12$ el grupo disperso queda como ruido. Con $\epsilon = 0,4$ los dos grupos densos se unen. HDBSCAN y OPTICS encuentran los tres grupos.

OPTICS

OPTICS (Ankerst et al., 1999) evita fijar un solo ε . Ordena los puntos de modo que los puntos de un mismo grupo queden seguidos.

Para cada punto calcula la **distancia de alcanzabilidad**, la menor distancia con que se puede llegar a él desde los puntos ya ordenados. El **diagrama de alcanzabilidad** grafica esa distancia en el orden de OPTICS.

- Cada valle del diagrama es un grupo.
- La profundidad del valle indica la densidad del grupo.
- Los picos separan grupos o marcan ruido.

En el ejemplo de densidades distintas, el diagrama tiene dos valles profundos para los grupos densos y uno ancho y menos profundo para el grupo disperso.

HDBSCAN

HDBSCAN (Campello et al., 2013) aplica DBSCAN para todos los valores de ε a la vez y construye una jerarquía de grupos.

1. Calcula una distancia que tiene en cuenta la densidad de cada punto.
2. Construye el árbol de expansión mínima con esa distancia y la jerarquía de grupos.
3. Elige los grupos más estables, los que persisten en un rango amplio de densidades.

El parámetro principal es el tamaño mínimo de un grupo, más fácil de elegir que ε . Encuentra grupos de densidades distintas y marca el ruido.

En el ejemplo de densidades distintas, HDBSCAN encuentra los tres grupos y marca 83 puntos como ruido, con índice de Rand ajustado 0,90 sobre los puntos que no son ruido.

Ventajas y límites

Ventajas

- Encuentran grupos de forma arbitraria.
- No necesitan el número de grupos.
- Identifican el ruido.
- DBSCAN cuesta $O(n \log n)$ con un índice espacial.

Límites

- DBSCAN usa un solo umbral de densidad y falla con grupos de densidades distintas.
- En dimensión alta todas las distancias se parecen y la densidad pierde sentido.
- Los resultados dependen de la escala de las variables, que hay que estandarizar.

Contenido

1. El problema del agrupamiento
2. Métodos basados en representantes
3. Mezclas gaussianas y el algoritmo EM
4. Agrupamiento jerárquico y espectral
5. Métodos basados en densidad
- 6. Validación del agrupamiento**
7. Factorización en matrices no negativas


Tres preguntas de validación

Sin etiquetas no hay un error de test que medir. La validación responde tres preguntas.

1. **Tendencia.** ¿Tienen los datos grupos? Un método de agrupamiento entrega grupos aunque los datos sean uniformes.
2. **Validación interna.** ¿Qué tan compactos y separados son los grupos? Usa sólo los datos.
3. **Validación externa.** ¿Coinciden los grupos con una clasificación conocida? Usa etiquetas que no se usaron para agrupar.

La validación interna sirve también para elegir el número de grupos K .

Tendencia al agrupamiento con VAT



VAT (Bezdek y Hathaway, 2002) calcula la matriz de distancias entre todos los puntos y reordena filas y columnas para que los puntos cercanos queden juntos. Los grupos aparecen como bloques oscuros en la diagonal. Con grupos (b) se ven cuatro bloques. Con datos uniformes (d) no hay bloques claros.

Índices internos

Miden dos propiedades, la **cohesión** dentro de los grupos y la **separación** entre grupos.

- **Suma de cuadrados dentro de los grupos** (WCSS), $\sum_k \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$. Siempre baja al aumentar K . Se busca el codo de la curva.
- **Silueta**. Para cada punto, con $a(i)$ la distancia media a su grupo y $b(i)$ la menor distancia media a otro grupo,

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1].$$

Valores cercanos a 1 indican un punto bien asignado. Se maximiza la silueta media.

Otros índices internos

- **Calinski–Harabasz**, se maximiza. Con B la suma de cuadrados entre los centroides y la media global, ponderada por el tamaño de cada grupo, y W la suma de cuadrados dentro de los grupos,

$$\text{CH} = \frac{B/(K-1)}{W/(n-K)}.$$

- **Davies–Bouldin**, se minimiza. Con s_k la distancia media de los puntos del grupo k a su centroide,


$$\text{DB} = \frac{1}{K} \sum_{k=1}^K \max_{j \neq k} \frac{s_k + s_j}{\|\boldsymbol{\mu}_k - \boldsymbol{\mu}_j\|}.$$

- **Estadístico gap** (Tibshirani et al., 2001), se maximiza. Con W_K la suma de cuadrados dentro de los grupos,

$$\text{Gap}(K) = E^*[\log W_K] - \log W_K,$$

donde E^* es el promedio sobre conjuntos de datos uniformes en la misma región.


Elegir K



k-means sobre los cuatro grupos compactos, con K entre 1 y 8. El codo de WCSS, el máximo de la silueta, el mínimo de Davies–Bouldin y el máximo del estadístico gap coinciden en $K = 4$, el número verdadero de grupos. El índice de Calinski–Harabasz también se maximiza en $K = 4$.

Con datos reales los índices pueden no coincidir. Conviene revisar varios y usar el conocimiento del problema.

Gráfico de silueta



Cada barra horizontal es un punto, ordenado dentro de su grupo. La línea discontinua es la silueta media. Con $K = 4$ todos los grupos tienen siluetas altas y parecidas. Con $K = 6$ dos grupos verdaderos quedan partidos, y sus partes tienen siluetas bajas.

Índices externos

Cuando existen etiquetas verdaderas, se compara la partición con ellas. Las etiquetas de los grupos son arbitrarias, así que los índices comparan pares de puntos.

Para cada par de puntos se cuenta si están juntos en la partición y en las etiquetas.

- **Índice de Rand.** Fracción de pares en que ambas coinciden, juntos en las dos o separados en las dos.
- **Índice de Rand ajustado (ARI).** Corrige el índice de Rand por el valor esperado al azar. Vale 1 para una partición idéntica y 0 en promedio para una partición al azar.
- **Pureza.** Cada grupo se etiqueta con su clase más frecuente y se cuenta la fracción de puntos bien etiquetados. Crece con el número de grupos y llega a 1 si cada punto es un grupo.


En segmentación de imágenes se usa el coeficiente de Dice entre la región segmentada S y la de referencia R , $2|S \cap R|/(|S| + |R|)$.

Comparación de métodos

Método	Grupos compactos	Grupos alargados	Lunas	Anillos
k-means	0,91	0,58	0,26	0,00
Mezcla gaussiana	0,91	1,00	0,51	0,00
Ward	0,91	0,55	0,17	0,01
Enlace simple	0,00	0,56	1,00	1,00
Espectral	0,91	0,99	1,00	1,00
HDBSCAN	0,70	0,88	0,99	1,00

Índice de Rand ajustado con las etiquetas verdaderas, en negrita el mejor de cada conjunto. Ningún método es el mejor en todos los casos. Los métodos de representantes funcionan bien con grupos compactos. La mezcla gaussiana es la mejor con grupos alargados. El enlace simple, el espectral y HDBSCAN recuperan las formas curvas. El espectral es el más estable en los cuatro conjuntos.

Métricas de solapamiento en segmentación



Con la región de referencia R y la región segmentada S , los píxeles se dividen en verdaderos positivos (VP), falsos positivos (FP) y falsos negativos (FN).

$$\text{Dice} = \frac{2 \text{ VP}}{2 \text{ VP} + \text{FP} + \text{FN}},$$

$$\text{Jaccard} = \frac{\text{VP}}{\text{VP} + \text{FP} + \text{FN}}.$$

Ambos valen 1 si las regiones coinciden y 0 si no se tocan. No usan los verdaderos negativos, que en una imagen son casi todos los píxeles.

Contenido

1. El problema del agrupamiento
2. Métodos basados en representantes
3. Mezclas gaussianas y el algoritmo EM
4. Agrupamiento jerárquico y espectral
5. Métodos basados en densidad
6. Validación del agrupamiento
- 7. Factorización en matrices no negativas**

Agrupar como factorizar una matriz

Los datos forman una matriz X de $n \times p$, una fila por observación. Una aproximación de rango bajo es

$$X \approx WH, \quad W \in \mathbb{R}^{n \times K}, \quad H \in \mathbb{R}^{K \times p}, \quad K \ll \min(n, p).$$

- Las K filas de H son vectores base, en el espacio de las variables.
- Cada fila de W da los pesos con que una observación combina esos vectores base.

k-means es un caso de esta factorización. H contiene los K centroides y cada fila de W tiene un solo 1, en el grupo de la observación. Permitir pesos graduales da agrupamientos blandos.

Factorización en matrices no negativas

Si X tiene sólo valores no negativos, como intensidades de imagen o conteos de palabras, la **NMF** (Lee y Seung, 1999) busca

$$\min_{W, H} \|X - WH\|_F^2 \quad \text{con} \quad W \geq 0, \quad H \geq 0.$$

Las actualizaciones multiplicativas alternan entre las dos matrices,

$$H_{kj} \leftarrow H_{kj} \frac{(W^\top X)_{kj}}{(W^\top W H)_{kj}}, \quad W_{ik} \leftarrow W_{ik} \frac{(X H^\top)_{ik}}{(W H H^\top)_{ik}}.$$

Si las matrices iniciales son positivas, las actualizaciones las mantienen positivas. El error no aumenta en ninguna iteración. Como en k-means, el resultado es un mínimo local que depende de la inicialización.


No negatividad y representación por partes

En la NMF cada observación es una **suma** de vectores base con pesos no negativos. No hay restas, así que ningún vector base puede cancelar a otro.

- En componentes principales los vectores base tienen signos mezclados. Una observación se reconstruye sumando y restando imágenes completas.
- En la NMF los vectores base tienden a ser partes localizadas de las observaciones, y cada observación usa pocas partes.

El precio es que la NMF no tiene solución única, ni vectores base ordenados por importancia como los componentes principales. El número K hay que elegirlo.

Partes de los dígitos




Diez vectores base de 1,797 dígitos escritos a mano de 8×8 píxeles. Los componentes principales (arriba, rojo positivo y azul negativo) ocupan toda la imagen y tienen signos mezclados. Los vectores base de la NMF (abajo) son trazos, partes de los dígitos. Cada dígito se reconstruye sumando pocos trazos. El error relativo de reconstrucción es 0,33 y el 27 % de los pesos de W son cero.

Modelos de tópicos con NMF

Un tópico es un grupo de palabras que aparecen juntas en los documentos.

1. Representar cada documento con un vector de pesos TF-IDF, uno por palabra. El peso crece con la frecuencia de la palabra en el documento y baja si la palabra aparece en muchos documentos.
2. Factorizar la matriz documentos $\times$ palabras, $X \approx WH$, con K tópicos.
 - Cada fila de H es un tópico, con un peso por palabra. Las palabras de mayor peso describen el tópico.
 - Cada fila de W es la mezcla de tópicos de un documento. Asignar cada documento a su tópico de mayor peso da un agrupamiento de documentos.

Tópicos de un libro de estadística



Cada párrafo del libro *All of Statistics* (Wasserman, 2004) es un documento, sin fórmulas ni código. Son 341 documentos y 390 palabras. La NMF con ocho tópicos encuentra temas del libro, como selección de modelos, densidad y núcleos, cadenas de Markov, pruebas de hipótesis y grafos. Nadie le indicó esos temas.

Síntesis

Método	Forma de los grupos	Parámetros	Ruido
k-means	Convexos, de tamaño parecido	K	No
Fuzzy c-means	Convexos, con pertenencia gradual	K, m	No
Mezcla gaussiana	Elipses de cualquier orientación	K , tipo de covarianza	No
Jerárquico	Según el enlace	Enlace, altura de corte	No
Espectral	Arbitraria, si el grafo la refleja	K , vecinos del grafo	No
DBSCAN	Arbitraria, densidad parecida	ε , MinPts	Sí
HDBSCAN	Arbitraria, densidad variable	Tamaño mínimo	Sí

Ningún método es el mejor en todos los casos. La elección depende de la forma esperada de los grupos y de si hay ruido. Los resultados se validan con varios índices y, cuando existe, con conocimiento del dominio.

Errores frecuentes

- No estandarizar las variables. La distancia queda dominada por la variable de mayor escala.
- Interpretar los grupos como clases reales sin verificar que los datos tienen tendencia a agruparse.
- Correr k-means una sola vez. El resultado depende de la inicialización.
- Elegir K con un solo índice, o con el error dentro de los grupos, que siempre baja al aumentar K .
- Usar k-means en grupos alargados, anidados o de densidades distintas.
- Comparar agrupamientos por las etiquetas numéricas de los grupos, que son arbitrarias. Hay que usar índices invariantes a permutaciones, como el índice de Rand ajustado.
- Aplicar NMF a datos con valores negativos.

Referencias

- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*, 2.^a ed., capítulo 14. Springer.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*, capítulo 9. Springer.
- Dempster, A. P., Laird, N. M., Rubin, D. B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *JRSS B*, 39(1), 1–38.
- Bezdek, J. C. (1981). *Pattern Recognition with Fuzzy Objective Function Algorithms*. Plenum.
- Arthur, D., Vassilvitskii, S. (2007). k-means++: the advantages of careful seeding. *SODA*, 1027–1035.
- von Luxburg, U. (2007). A tutorial on spectral clustering. *Statistics and Computing*, 17(4), 395–416.
- Ester, M., Kriegel, H.-P., Sander, J., Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *KDD*, 226–231.
- Ankerst, M., Breunig, M. M., Kriegel, H.-P., Sander, J. (1999). OPTICS: ordering points to identify the clustering structure. *SIGMOD*, 49–60.
- Campello, R. J. G. B., Moulavi, D., Sander, J. (2013). Density-based clustering based on hierarchical density estimates. *PAKDD*, 160–172.
- Bezdek, J. C., Hathaway, R. J. (2002). VAT: a tool for visual assessment of (cluster) tendency. *IJCNN*, 2225–2230.
- Tibshirani, R., Walther, G., Hastie, T. (2001). Estimating the number of clusters in a data set via the gap statistic. *JRSS B*, 63(2), 411–423.
- Lee, D. D., Seung, H. S. (1999). Learning the parts of objects by non-negative matrix factorization. *Nature*, 401, 788–791.
- Geman, S., Geman, D. (1984). Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images. *IEEE PAMI*, 6(6), 721–741.