

Tarea 3

Árboles, modelos probabilísticos, procesos gaussianos y aprendizaje no supervisado

Table of contents

Requisitos mínimos de los datos	1
Partición y protocolo experimental	2
1. Random Forest e importancia de variables	2
2. Desbalance de clases: redes neuronales versus Random Forest	3
3. Calibración de modelos	4
4. Modelos en grafos probabilísticos	5
5. Procesos gaussianos	6
Alternativa A: GP univariado	6
Alternativa B: GP multioutput	6
6. Aprendizaje no supervisado: EM y GMM	7
Entregables	7
Criterios de evaluación	7

En esta tarea trabajaremos con varios modelos vistos en las últimas clases:

1. Árboles, Random Forest, importancia de variables y calibración.
2. Redes neuronales y problemas de clasificación desbalanceada.
3. Modelos en grafos probabilísticos.
4. Procesos gaussianos multioutput.
5. Aprendizaje no supervisado con EM, mezclas gaussianas y regularización espacial tipo MRF.

A diferencia de las tareas anteriores, **los datos deben ser elegidos por cada estudiante**. Esta decisión es parte de la evaluación: se espera que justifiquen por qué el dataset permite estudiar los fenómenos pedidos.

Requisitos mínimos de los datos

Puede usar un único dataset con varias vistas del problema, o más de un dataset si eso hace más natural resolver las secciones. Debe incluir una ficha con la siguiente información:

- Fuente del dataset, enlace o procedimiento de descarga.

- Descripción del dominio.
- Número de observaciones y variables.
- Significado de la variable objetivo.
- Tipos de variables: continuas, discretas, binarias, categóricas, temporales o espaciales.
- Proporción de clases.
- Tratamiento de valores faltantes, si aplica.

El dataset principal de clasificación debe cumplir:

- Al menos **8 variables predictoras** después de limpieza inicial.
- al menos **5 variables numéricas**.
- Al menos una variable categórica o binaria.
- Una tarea de clasificación binaria o multiclase.
- Desbalance de clases natural o inducido, con razón mayoría/minoría de al menos **3:1**.

Si el desbalance se induce artificialmente, debe reportar la distribución original.

Para las secciones de modelos en grafos y procesos gaussianos puede usar el mismo dominio, pero se permiten vistas diferentes:

- Para modelos en grafos: entre **6 y 12 variables** discretas o discretizadas, con al menos **500 observaciones**.
- Para procesos gaussianos: una variable de entrada ordenada, por ejemplo tiempo, dosis, distancia o ubicación 1D/2D, con al menos **80 observaciones**.

Partición y protocolo experimental

Para las secciones supervisadas use partición entrenamiento-validación-prueba, por ejemplo 60/20/20 o 70/15/15. La partición debe ser estratificada si hay clasificación.

No use el conjunto de prueba para:

- Seleccionar variables.
- Ajustar hiperparámetros.
- Calibrar probabilidades.
- Decidir umbrales.
- Elegir arquitectura de red neuronal.
- Escoger número de componentes en modelos no supervisados, si luego reporta desempeño final sobre test.

Debe fijar semillas aleatorias y describir el preprocesamiento. Toda normalización, imputación o codificación debe ajustarse usando solo entrenamiento.

1. Random Forest e importancia de variables

Entrene un modelo Random Forest para la tarea de clasificación principal.

Debe reportar:

- Métricas apropiadas para desbalance: **balanced accuracy**, F1 macro, recall por clase y matriz de confusión.
- Curva o tabla de sensibilidad a hiperparámetros, al menos para número de árboles, profundidad máxima y número de variables candidatas por split.
- Comparación entre un árbol individual y el Random Forest.
- Análisis de importancia de variables.

Para importancia de variables debe calcular y comparar al menos dos métodos:

1. **Disminución media de impureza** (*mean decrease in impurity*).
2. **Importancia por permutación**, idealmente usando validación o datos out-of-bag.

Responda:

1. ¿Las variables más importantes coinciden entre ambos métodos?
2. ¿Hay variables correlacionadas que puedan repartir o esconder importancia?
3. ¿Cambian las importancias cuando se ajusta `max_depth` o `max_features`?
4. ¿Qué variables parecen predictivas, pero no deberían interpretarse causalmente?
5. ¿Qué limitaciones tiene usar importancia de variables como explicación del modelo?

2. Desbalance de clases: redes neuronales versus Random Forest

Construya un problema de clasificación desbalanceado usando el dataset elegido. Si el dataset ya está desbalanceado, use esa distribución. Si no lo está, genere una versión desbalanceada mediante submuestreo controlado de una o más clases.

Compare al menos los siguientes modelos:

1. Random Forest estándar.
2. Random Forest con estrategia para desbalance, por ejemplo `class_weight`, submuestreo, sobremuestreo o ajuste de umbral.
3. Red neuronal MLP estándar.
4. Red neuronal MLP con estrategia para desbalance, por ejemplo pesos por clase en la entropía cruzada, focal loss, sobremuestreo o ajuste de umbral.

La red neuronal puede implementarse en PyTorch, TensorFlow, JAX o `sklearn`, pero debe describir arquitectura, función de pérdida, optimizador y criterios de parada.

Reporte:

- Distribución de clases en train, validación y test.

- Accuracy, balanced accuracy, F1 macro, F1 weighted, recall por clase y PR-AUC si corresponde.
- Matriz de confusión.
- Curvas precision-recall para la clase minoritaria.
- Análisis del compromiso entre detectar la clase minoritaria y aumentar falsos positivos.

Discuta:

1. ¿Qué modelo se sesga más hacia la clase mayoritaria?
2. ¿Qué técnica de compensación mejora más el recall de la clase minoritaria?
3. ¿La mejora en recall tiene costo en precisión?
4. ¿Qué modelo recomendaría si el costo de un falso negativo de la clase minoritaria es alto?
5. ¿El Random Forest fue más robusto que la red neuronal con pocos datos o variables heterogéneas?

3. Calibración de modelos

En muchas aplicaciones no basta con predecir una clase. También interesa que la probabilidad predicha sea interpretable.

Un clasificador está calibrado si, para los casos donde predice probabilidad cercana a p , la frecuencia observada del evento también es cercana a p :

$$\mathbb{P}(Y = 1 \mid \hat{p}(X) = p) \approx p.$$

Formalmente, si $\hat{p}_i$ es la probabilidad predicha para el evento positivo, una medida simple de calidad probabilística es el **Brier score**:

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{p}_i)^2.$$

También puede evaluar la calibración agrupando predicciones en bins:

$$\text{ECE} = \sum_{b=1}^B \frac{|I_b|}{N} |\text{acc}(I_b) - \text{conf}(I_b)|,$$

donde I_b es el conjunto de ejemplos cuyo score cae en el bin b , $\text{acc}(I_b)$ es la frecuencia real del evento y $\text{conf}(I_b)$ es la confianza promedio predicha.

Pregunta: Compare un Random Forest **sin calibración** contra el mismo modelo **con calibración**.

Debe explicar e implementar al menos dos técnicas de calibración:

- Platt scaling / sigmoid calibration.

- Isotonic regression.
- Temperature scaling, si lo adapta justificadamente.

Use sólo validación o calibración cruzada para ajustar el calibrador. No calibre usando test.

Reporte:

- Reliability diagram.
- Brier score antes y después de calibrar.
- ECE (Expected Calibration Error) antes y después de calibrar.
- ROC-AUC y PR-AUC antes y después.
- Métricas de clasificación usando un umbral fijo, por ejemplo 0.5.
- Métricas usando un umbral elegido en validación para favorecer la clase minoritaria.

Discuta:

1. ¿La calibración cambió las probabilidades aunque no cambiara la accuracy?
2. ¿Qué método calibró mejor: sigmoid o isotonic?
3. ¿Hubo sobreajuste del calibrador?
4. ¿En qué escenarios preferiría un modelo menos exacto pero mejor calibrado?
5. ¿Cómo interactúa calibración con desbalance de clases?

4. Modelos en grafos probabilísticos

Construya un ejemplo de modelo en grafo probabilístico usando el dataset elegido o una versión discretizada de éste.

El objetivo es representar dependencias entre variables, realizar inferencia y discutir independencias condicionales.

Condiciones mínimas:

- Use entre **6 y 12 variables**.
- Discretice variables continuas de manera justificada, por ejemplo cuantiles o umbrales del dominio.
- Incluya al menos una variable objetivo o variable de interés.
- Use al menos **500 observaciones**.
- Separe entrenamiento y prueba o use validación cruzada.
- Dibuje el grafo aprendido o propuesto.

Debe:

- Proponer o aprender una estructura DAG.
- Estimar tablas de probabilidad condicional.
- Calcular al menos tres consultas del tipo $p(Y \mid E = e)$.
- Analizar independencias condicionales usando d-separation.

- Evaluar log-verosimilitud o alguna métrica predictiva sobre datos no usados para ajustar.

Ejemplos de consultas:

$$p(\text{riesgo alto} \mid \text{edad alta, biomarcador alto}),$$

$$p(\text{evento} = 1 \mid \text{sensor}_1 = \text{alto}, \text{sensor}_2 = \text{bajo}).$$

Considere las preguntas:

- ¿Qué gana y qué pierde al discretizar variables para una red bayesiana?
- ¿Qué representa una independencia condicional en un grafo probabilístico?

5. Procesos gaussianos

Use un problema de regresión donde tenga sentido modelar suavidad, incertidumbre y correlación entre observaciones cercanas.

Puede elegir una de estas alternativas:

Alternativa A: GP univariado

Modele una variable continua $y(t)$ o $y(x)$ usando un proceso gaussiano:

$$f(x) \sim \mathcal{GP}(m(x), k(x, x')).$$

Debe comparar al menos dos kernels, por ejemplo RBF, Matérn, periodicidad o suma/producto de kernels.

Reporte:

- Media predictiva e intervalos de credibilidad.
- log marginal likelihood o métrica equivalente para comparar kernels.
- Sensibilidad a ruido y longitud de escala.
- Análisis de extrapolación fuera del rango observado.

Alternativa B: GP multioutput

Modele dos o más salidas relacionadas, por ejemplo dos sensores, dos contaminantes, demanda en dos estaciones, temperatura y humedad, o mediciones en ubicaciones cercanas.

Debe explicar cómo modela la correlación entre salidas. Puede usar una aproximación simple:

- Entrenar GPs independientes y comparar contra un modelo con variables compartidas.

- Usar un kernel separable de la forma:

$$k((x, a), (x', b)) = k_X(x, x') B_{ab},$$

donde a, b indican la salida y B es una matriz de correlación entre tareas; usar una librería que implemente multioutput GP.

Reporte:

- Predicción de cada salida con incertidumbre.
- Comparación contra regresión lineal, Random Forest o red neuronal simple.
- Discusión sobre cuándo la transferencia entre salidas ayuda o perjudica.
- Costo computacional del GP y cómo escala con el número de observaciones.

6. Aprendizaje no supervisado: EM y GMM

Explique y reimplemente de manera eficiente EM para GMM en el ejemplo ([Descargar](#)). Compare la solución actual con su implementación en términos de verosimilitud y tiempo de procesamiento.

Refine la solución usando un MRF. ¿Qué efecto tiene el parámetro β en un modelo GMM+MRF?

Entregables

Debe entregar:

- Una carpeta con un notebook por pregunta o un único notebook que contenga todo. En formato .zip (no .rar).
- Archivo `requirements.txt` o lista clara de dependencias.
- Instrucciones para descargar o reconstruir los datos.
- Tablas de resultados (dentro del notebook).
- Figuras principales (dentro del notebook).

Criterios de evaluación

La evaluación considerará:

- Pertinencia y justificación del dataset elegido.
- Limpieza y protocolo experimental.
- Implementación correcta de los modelos.
- Métricas apropiadas para desbalance y calibración.
- Calidad del análisis de importancia de variables.
- Claridad del modelo en grafo y de las consultas probabilísticas.
- Formulación y evaluación del proceso gaussiano.
- Implementación de EM y extensión con MRF.

- Calidad de figuras, tablas y conclusiones.
- Reproducibilidad del trabajo.

Es muy importante los análisis hechos por Ud., más que una colección de modelos sin interpretación.