


Classification/clustering with Mixture of Gaussians

Dr. Alejandro Veloz

Modelo mixto finito



Linear Models

Probabilistic Generative Models

- Regression
- Classification

Probabilistic Generative Model

- $\Pr(C)$: prior probability of class C
- $\Pr(\mathbf{x}|C)$: class conditional distribution of $\mathbf{x}$
- Classification: compute posterior $\Pr(C|\mathbf{x})$ according to Bayes' theorem

$$\begin{aligned}\Pr(C|\mathbf{x}) &= \frac{\Pr(\mathbf{x}|C) \Pr(C)}{\sum_C \Pr(\mathbf{x}|C) \Pr(C)} \\ &= k \Pr(\mathbf{x}|C) \Pr(C)\end{aligned}$$

Assumptions

- In classification, the number of classes is finite, so a natural prior $\Pr(C)$ is the multinomial

$$\Pr(C = c_k) = \pi_k$$

- When $\mathbf{x} \in \mathbb{R}^d$, then it is often OK to assume that $\Pr(\mathbf{x}|C)$ is Gaussian.
- Furthermore, assume that the same covariance matrix Σ is used for each class.

$$\Pr(\mathbf{x}|c_k) \propto e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_k)^T \Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu}_k)}$$

Posterior Distribution

$$\begin{aligned}\Pr(c_k | \mathbf{x}) &= \frac{\pi_k e^{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_k)}}{\sum_k \pi_k e^{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_k)}} \\ &= \frac{\pi_k e^{-\frac{1}{2}(\cancel{\mathbf{x}^T \boldsymbol{\Sigma}^{-1} \mathbf{x}} - 2\boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \mathbf{x} + \boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k)}}{\sum_k \pi_k e^{-\frac{1}{2}(\cancel{\mathbf{x}^T \boldsymbol{\Sigma}^{-1} \mathbf{x}} - 2\boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \mathbf{x} + \boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k)}}\end{aligned}$$

Consider two classes c_k and c_j

$$= \frac{1}{1 + \frac{\pi_j e^{\boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j}}{\pi_k e^{\boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k}}}}$$

Posterior Distribution

$$\begin{aligned} &= \frac{1}{1 + e^{-\left(\boldsymbol{\mu}_k^T - \boldsymbol{\mu}_j^T\right) \boldsymbol{\Sigma}^{-1} \mathbf{x} + \frac{1}{2} \boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j - \ln \frac{\pi_k}{\pi_j}}} \\ &= \frac{1}{1 + e^{-\left(\mathbf{w}^T \mathbf{x} + w_0\right)}} \end{aligned}$$

where $\mathbf{w} = \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_k - \boldsymbol{\mu}_j)$


and $w_0 = -\frac{1}{2} \boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \frac{1}{2} \boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j + \ln \frac{\pi_k}{\pi_j}$

Logistic Sigmoid


- Let $\sigma(a) = \frac{1}{1+e^{-a}}$
└──────────> Logistic sigmoid
- Then $\Pr(c_k | \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + w_0)$

Logistic Sigmoid

class conditionals



posterior



Prediction

$$\begin{aligned} \text{best class} &= \operatorname{argmax}_k \Pr(c_k | \mathbf{x}) \\ &= \begin{cases} c_1 & \sigma(\mathbf{w}^T \mathbf{x} + w_0) \geq 0.5 \\ c_2 & \text{otherwise} \end{cases} \end{aligned}$$

Class boundary: $\sigma(\mathbf{w}_k^T \bar{\mathbf{x}}) = 0.5$

$$\Rightarrow \frac{1}{1 + e^{-(\mathbf{w}_k^T \bar{\mathbf{x}})}} = 0.5$$

$$\Rightarrow \mathbf{w}_k^T \bar{\mathbf{x}} = 0$$

$\therefore$ linear separator

Multi-class Problems

- Consider Gaussian conditional distributions with identical Σ

$$\begin{aligned}\Pr(c_k|\mathbf{x}) &= \frac{\Pr(c_k) \Pr(\mathbf{x}|c_k)}{\sum_j \Pr(c_j) \Pr(\mathbf{x}|c_j)} \\&= \frac{\pi_k e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}_k)}}{\sum_j \pi_j e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}_j)}} \\&= \frac{\pi_k e^{-\frac{1}{2}(-2\boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \mathbf{x} + \boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k)}}{\sum_j \pi_j e^{-\frac{1}{2}(-2\boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \mathbf{x} + \boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j)}} \\&= \frac{e^{\boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \mathbf{x} - \frac{1}{2}\boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \ln \pi_k}}{\sum_j e^{\boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \mathbf{x} - \frac{1}{2}\boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j + \ln \pi_j}} = \frac{e^{\mathbf{w}_k^T \bar{\mathbf{x}}}}{\sum_j e^{\mathbf{w}_j^T \bar{\mathbf{x}}}} \Rightarrow \text{softmax}\end{aligned}$$

$$\text{where } \mathbf{w}_k^T = \left(-\frac{1}{2}\boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \ln \pi_k, \boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1}\right)$$

Softmax

- When there are several classes, the posterior is a **softmax** (sigmoid generalization)
- Softmax distribution: $\Pr(c_k|\mathbf{x}) = \frac{e^{f_k(\mathbf{x})}}{\sum_j e^{f_j(\mathbf{x})}}$
- Argmax distribution:


$$\Pr(c_k|\mathbf{x}) = \begin{cases} 1 & \text{if } k = \operatorname{argmax}_j f_j(\mathbf{x}) \\ 0 & \text{otherwise} \end{cases}$$

$$= \lim_{base \rightarrow \infty} \frac{base^{f_k(\mathbf{x})}}{\sum_j base^{f_j(\mathbf{x})}}$$


$$\approx \frac{e^{f_k(\mathbf{x})}}{\sum_j e^{f_j(\mathbf{x})}} \quad (\text{softmax approximation})$$

Softmax

class conditionals



posterior



Parameter Estimation

- Where do $\Pr(c_k)$ and $\Pr(\mathbf{x}|c_k)$ come from?

- Parameters: $\pi, \boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \boldsymbol{\Sigma}$

$$\Pr(c_1) = \pi, \quad \Pr(\mathbf{x}|c_1) = k_{\boldsymbol{\Sigma}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_1)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}_1)}$$

$$\Pr(c_2) = 1 - \pi, \quad \Pr(\mathbf{x}|c_2) = k_{\boldsymbol{\Sigma}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}_2)}$$

where $k_{\boldsymbol{\Sigma}}$ is the normalization constant that depends on $\boldsymbol{\Sigma}$

- Estimate parameters by
 - **Maximum likelihood**
 - Maximum a posteriori
 - Bayesian learning

Maximum Likelihood Solution

- Likelihood:

$$L(\mathbf{X}, \mathbf{y}) = \Pr(\mathbf{X}, \mathbf{y} | \pi, \boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \boldsymbol{\Sigma}) = \prod_n [\pi N(\mathbf{x}_n | \boldsymbol{\mu}_1, \boldsymbol{\Sigma})]^{y_n} [(1 - \pi) N(\mathbf{x}_n | \boldsymbol{\mu}_2, \boldsymbol{\Sigma})]^{1-y_n}$$


$y_n \in \{0,1\}$

- ML hypothesis:

$$\begin{aligned} \langle \pi^*, \boldsymbol{\mu}_1^*, \boldsymbol{\mu}_2^*, \boldsymbol{\Sigma}^* \rangle = \operatorname{argmax}_{\pi, \boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \boldsymbol{\Sigma}} \sum_n y_n \left[\ln \pi + \ln k_{\boldsymbol{\Sigma}} - \frac{1}{2} (\mathbf{x}_n - \boldsymbol{\mu}_1)^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_1) \right] \\ + (1 - y_n) \left[\ln(1 - \pi) + \ln k_{\boldsymbol{\Sigma}} - \frac{1}{2} (\mathbf{x}_n - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_2) \right] \end{aligned}$$

Maximum Likelihood Solution

- Set derivative to 0

$$0 = \frac{\partial \ln L(X, \mathbf{y})}{\partial \pi}$$

$$\Rightarrow 0 = \sum_n y_n \left[\frac{1}{\pi} \right] + (1 - y_n) \left[-\frac{1}{1 - \pi} \right]$$

$$\Rightarrow 0 = \sum_n y_n (1 - \pi) + (1 - y_n)(-\pi)$$

$$\Rightarrow \sum_n y_n = \pi (\sum_n y_n + \sum_n (1 - y_n))$$

$$\Rightarrow \sum_n y_n = \pi N \text{ (where } N \text{ is the \# of training points)}$$

$$\therefore \frac{\sum_n y_n}{N} = \pi$$

Maximum Likelihood Solution

$$0 = \partial \ln L(\mathbf{X}, \mathbf{y}) / \partial \boldsymbol{\mu}_1$$

$$\Rightarrow 0 = \sum_n y_n [-\boldsymbol{\Sigma}^{-1}(\mathbf{x}_n - \boldsymbol{\mu}_1)]$$

$$\Rightarrow \sum_n y_n \mathbf{x}_n = \sum_n y_n \boldsymbol{\mu}_1$$

$$\Rightarrow \sum_n y_n \mathbf{x}_n = N_1 \boldsymbol{\mu}_1$$

$$\therefore \frac{\sum_n y_n \mathbf{x}_n}{N_1} = \boldsymbol{\mu}_1 \quad \text{Similarly: } \frac{\sum_n (1-y_n) \mathbf{x}_n}{N_2} = \boldsymbol{\mu}_2$$

where N_1 is the # of data points in class 1

N_2 is the # of data points in class 2

Maximum Likelihood

$$\frac{\partial \ln L(X, \mathbf{y})}{\partial \Sigma} = 0$$

$\Rightarrow \dots$

$$\Rightarrow \Sigma = \frac{N_1}{N} \mathbf{S}_1 + \frac{N_2}{N} \mathbf{S}_2$$

where $\mathbf{S}_1 = \frac{1}{N_1} \sum_{n \in c_1} (\mathbf{x}_n - \boldsymbol{\mu}_1)(\mathbf{x}_n - \boldsymbol{\mu}_1)^T$

$$\mathbf{S}_2 = \frac{1}{N_2} \sum_{n \in c_2} (\mathbf{x}_n - \boldsymbol{\mu}_2)(\mathbf{x}_n - \boldsymbol{\mu}_2)^T$$


($\mathbf{S}_k$ is the empirical covariance matrix of class k)

When C is a latent variable

Modelo de Mezcla de Gaussianas

- Si bien la distribución Normal tiene importantes propiedades analíticas, tiene también serias limitaciones para modelar fenómenos reales complejos.
- Una manera abordar estas limitaciones consiste en utilizar una combinación de distintas distribuciones normales o gaussianas.


$$p(x) = \sum_{k=1}^K \alpha_k \mathcal{N}(x; \mu_k, \sigma_k^2), \text{ con } \alpha_i \geq 0, \sum_k \alpha_k = 1$$



Modelo multivariado

- Dado un conjunto de puntos $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ con $\mathbf{x}_i \in \mathbf{R}^d$
- La variable aleatoria se supone distribuida de acuerdo a una mezcla de K componentes normales multivariados. Es decir,

$$p(\mathbf{x}) = \sum_{k=1}^K \alpha_k \mathcal{N}(\mathbf{x}; \underline{\mu}_k, \Sigma_k), \text{ con } \sum_k \alpha_k = 1$$



Definición del problema

- Dada la representación mediante K componentes normales, el objetivo es estimar los valores de los parámetros $\underline{\mu}$, Σ y α

Si suponemos que los puntos son i.i.d la verosimilitud queda dada por:

$$p(\mathbf{X}|\Theta) = \prod_{n=1}^N \sum_{k=1}^K \alpha_k p(\mathbf{x}_n | \theta_k)$$

Generalmente, se utiliza una forma logaritmica de la verosimilitud para deshacerse de la productoria.

$$\log p(X|\alpha, \mu, \Sigma) = \sum_{i=1}^n \log \left(\sum_{k=1}^K \alpha_k \mathcal{N}(x_i | \mu_k, \Sigma_k) \right)$$

El algoritmo EM

Una manera efectiva para encontrar estimadores de máxima verosimilitud para modelos con variables latentes es el algoritmo de Maximización de la esperanza o **EM**.

El algoritmo comienza con una inicialización aleatoria de los parámetros del modelo. Luego, itera entre los siguientes dos pasos hasta converger:

- 1 **Calculo de la esperanza (E)**: Cálculo de log-verosimilitud esperada del modelo con respecto a la distribución de las variables latentes, dados los datos observados y la estimación actual de los parámetros.
- 2 **Maximización de log-verosimilitud (M)**: Actualización de los parámetros del modelo para maximizar la log-verosimilitud de los datos observados, dadas las variables latentes observadas a partir del paso anterior.

Paso E

La variable latente a calcular corresponde a la pertenencia de cada uno de los n puntos en cada uno de los K componentes gaussianos.

Sea $Z_i = k$ la variable que indica que x_i pertenece al componente k . Luego,

$$p(Z_i = k|x_i; \theta) = \frac{p(x_i|Z_i = k; \theta)p(Z_i = k; \theta)}{p(x_i; \theta)} = \frac{\alpha_k \cdot p(x_i|Z_i = k; \theta)}{\sum_{j=1}^K \alpha_j p(x_i|Z_i = j; \theta)}$$

Considerando que $p(x_i|Z_i = k; \theta) = \mathcal{N}(x_i; \underline{\mu}_k, \Sigma_k)$,

$$p(Z_i = k|x_i; \theta) = \frac{\alpha_k \mathcal{N}(x_i; \underline{\mu}_k, \Sigma_k)}{\sum_{j=1}^K \alpha_j \mathcal{N}(x_i; \underline{\mu}_j, \Sigma_j)} = \gamma(z_{ik})$$

$\gamma(z_{ik})$ se denomina responsabilidad del componente k por la observación i

La log-verosimilitud esperada con respecto a la distribución de las variables latentes se escribe como una suma ponderada de las log-verosimilitudes de todos los puntos bajo cada uno de los componentes:

$$Q(\theta) = \sum_{i=1}^n \sum_{k=1}^K \gamma(z_{ik}) \log \alpha_k \mathcal{N}(x_i | \mu_k, \Sigma_k)$$

Esta función Q representa la log-verosimilitud esperada sobre los datos observados y las distribuciones estimadas de variables latentes

Paso M

- θ corresponde a los vectores de medias, matrices de covarianza y pesos de mezcla.
- En este paso se actualizan los parámetros en θ de manera que se maximice la log-verosimilitud esperada $Q(\theta)$
- Las **medias** de cada componente se actualizan mediante

$$\underline{\mu}_k^* = \frac{\sum_{i=1}^n \gamma(z_{ik}) \mathbf{x}_i}{\sum_{i=1}^n \gamma(z_{ik})}$$

- El vector de medias del k -ésimo componente corresponde a una promedio ponderado de todos los puntos, usando las probabilidades de pertenencia de cada punto
- Esta ecuación proviene de la maximización de la log-verosimilitud esperada (Q) con respecto al vector de medias $\rightarrow \frac{\partial Q}{\partial \underline{\mu}_k} = 0$

- Las **covarianzas** para componente se actualizan mediante

$$\Sigma_k^* = \frac{\sum_{i=1}^n \gamma(z_{ik})(\mathbf{x}_i - \underline{\mu}_k^*)(\mathbf{x}_i - \underline{\mu}_k^*)^T}{\sum_{i=1}^n \gamma(z_{ik})}$$

- La nueva matriz de covarianza corresponde a un promedio ponderado de las desviaciones de cada punto desde la media del componente.
- Los pesos de la mezcla se actualizan mediante

$$\alpha_k^* = \frac{\sum_{i=1}^n \gamma(z_{ik})}{n}$$

- El nuevo peso del componente k -ésimo corresponde a la probabilidad total de los puntos que pertenecen a este componente, normalizado por la cantidad de puntos

Inicialización y convergencia

- Este procedimiento convierte a un máximo local
- Se repite hasta que la función de verosimilitud sufra cambios muy pequeños o permanezca constante.
- Toma bastantes más iteraciones que K-means
- Una alternativa es usar este último para encontrar una solución inicial, luego calcular las matrices de covarianza para cada grupo y finalmente, usar esta información para inicializar la mezcla de gaussianas.

En síntesis ¿Qué es el algoritmo EM?


- **E-step (Expectation):** Calcula la probabilidad de que cada punto pertenezca a cada componente (responsabilidades).
- **M-step (Maximization):** Actualiza los parámetros de las gaussianas usando las responsabilidades.
- Se repite hasta que converge el log-likelihood.
- Utilizado para ajustar modelos de mezcla, como el **Gaussian Mixture Model (GMM)**.

Ejemplo

Datos de entrada **Datos utilizados (1D):**

$$X = \{0.1, 0.2, 0.6, 1.2, 0.8, 1.0, 1.1, 0.9, 1.2, 1.3, 2.0, 1.8, 2.7, 3.2, 3.5, \\ 3.6, 3.1, 4.1, 5.0, 5.1, 4.9, 5.2, 5.3, 5.9, 6.2, 5.4\}$$

Visualización (histograma):



Paso 0: Inicialización

- Se escogen aleatoriamente 2 medias iniciales (por ejemplo, 3.6 y 1.8).
- Se inicializan las varianzas y pesos:

$$\mu_1 = 3.6, \quad \mu_2 = 1.8, \quad \sigma_1^2 = \sigma_2^2 = \text{var}(X), \quad \pi_1 = \pi_2 = 0.5$$

Paso 1: E-step

- Para cada punto x_i , calculamos:

$$\gamma_{ik} = \frac{\pi_k \cdot \mathcal{N}(x_i | \mu_k, \sigma_k^2)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(x_i | \mu_j, \sigma_j^2)}$$

- Esto nos da una matriz $N \times K$ de responsabilidades.

Paso 2: M-step

- Usamos las responsabilidades para actualizar los parámetros:

$$N_k = \sum_{i=1}^N \gamma_{ik}$$

$$\mu_k = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} x_i$$

$$\sigma_k^2 = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} (x_i - \mu_k)^2$$

$$\pi_k = \frac{N_k}{N}$$

Paso 3: Iteración y convergencia


- Repetimos los pasos E y M hasta que:

$$|\text{log-likelihood}_t - \text{log-likelihood}_{t-1}| < \varepsilon$$

- En este ejemplo, converge en pocas iteraciones.

Resultados finales

- Medias estimadas: $\mu_1 \approx 4.41$, $\mu_2 \approx 0.98$
- Varianzas pequeñas en cada grupo.
- Pesos aproximadamente 0.56 y 0.44 (12 a 14 puntos por grupo).



Conclusión

- El algoritmo EM permite estimar los parámetros de una mezcla de gaussianas sin etiquetas.
- Es eficiente y converge rápidamente con buenos datos iniciales.
- Este ejemplo muestra cómo segmentar automáticamente dos grupos en datos 1D.

Campos Aleatorios de Markov

Markov Random Fields

- Se representa una imagen S como una red bidimensional rectangular de $m \times n$ píxeles (o sites), compuesta por K regiones disjuntas.
- El nivel de gris de un pixel $s \in S$ será denotado como y_s
- El conjunto de píxeles de la imagen es $\mathbf{y} = \{y_s \mid s \in S\}$
- A cada píxel de la imagen se le asigna una etiqueta del conjunto $L = \{1, \dots, K\}$.
- El conjunto de etiquetas de todos los píxeles de la imagen es:

$$\mathbf{x} = \{x_s \mid x_s \in L, s \in S\},$$

donde $x_s = \ell$ significa que el pixel s tiene etiqueta $\ell \in L$.

- El espacio de soluciones $\Omega = \{1, \dots, K\}^{m \times n}$ posee $K^{m \times n}$ posibles realizaciones de $\mathbf{x} \in \Omega$

Markov Random Fields

- Varios métodos asumen que el conjunto de etiquetas son una realización de un campo aleatorio X .
- Esta estimación del conjunto real (desconocido) de etiquetas $\mathbf{x}^* \in \Omega$ se denota por $\hat{\mathbf{x}} \in \Omega$
- La asignación de una etiqueta a un pixel considera una **dependencia estocástica entre etiquetas de píxeles vecinos**.
- Dicha dependencia local se define a partir de la especificación de un **vecindario** N_s que debe satisfacer las siguientes condiciones:
 - $s \in N_s$
 - $r \in N_s, \text{ssi } s \in N_r$

Markov Random Fields

- Ejemplos de sistemas de vecindad:

	4	3	4	
4	2	1	2	4
3	1	s	1	3
4	2	1	2	4
	4	3	4	

	1	
1	s	1
	1	

2	1	2
1	s	1
2	1	2

Markov Random Fields

- **Cliques:** El concepto de clique es fundamental para caracterizar la dependencia local de las etiquetas de los píxeles de una imagen.
- Un clique $c \in C$ es un subconjunto de una vecindad predefinida, donde si dos píxeles $s, r \in c$, entonces $r \in N_s$

Clique de un punto:




Clique de 2 puntos:



Clique de 3 puntos:



Clique de 4 puntos:



Markov Random Fields

- Un campo aleatorio X corresponde a un campo aleatorio de Markov si:
 - i. $P(X=\mathbf{x}) > 0, \quad \forall \mathbf{x} \in \Omega$
 - ii. $P(x_i | x_k, k \neq i) = P(x_i | x_k, k \in N_i)$
- De la condición (ii) se deriva el hecho de que la etiqueta de un píxel depende de las etiquetas de sus vecinos.
- Además, $P(X)$ debe corresponder a una distribución de Gibbs para que X sea considerado un campo aleatorio de Markov.

Markov Random Fields

- La distribución de Gibbs se define por la siguiente expresión:

$$P(X = \mathbf{x}) = \frac{1}{Z} \exp\{-\beta U(\mathbf{x})\}$$

donde β es una constante positiva y Z es un término de normalización dado por:

$$Z = \sum_{\mathbf{x} \in \Omega} \exp(U(\mathbf{x}))$$

- El término $U(\mathbf{x})$ comúnmente se denomina función de energía o energía de Gibbs y está dado por:

$$U(\mathbf{x}) = \sum_{c \in C} V_c(\mathbf{x}_s)$$

- donde C denota el conjunto de todos los cliques de la imagen y $V_c(\mathbf{x}_s)$ (función potencial) está dado por:

$$V_c(\mathbf{x}_s) = \begin{cases} -1 & \text{si } x_s = x_r, \quad \forall s, r \in c \\ 1 & \text{si } x_s \neq x_r, \quad \forall s, r \in c \end{cases}$$




(a)



(b)



(c)



(d)



(e)



(f)

